



modelos Estruturais p/ séries Temporais

2011.1

Prof: Cristiano Fernandes

1ª parte (PL)



Aula
02/03

Modelo Espaço-Estado

$$y_t = z_t \alpha_t + d_t + \varepsilon_t \quad (\text{equação de medida})$$

$$\alpha_{t+1} = T_t \alpha_t + c_t + R_t \eta_t \quad (\text{evolução do estado})$$

(equações de estado)

y_t se relaciona com α_t

α_t se relaciona com α_{t-1}

Ex. 1) $y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$

1ª equação de medida

normalmente, tem que ter $y_t = y_t$

$$y_t = \underbrace{\begin{pmatrix} 1 & 0 \end{pmatrix}}_{z_t} \underbrace{\begin{pmatrix} y_t \\ y_{t-1} \end{pmatrix}}_{\alpha_t} + \varepsilon_t$$

$$y_{t+1} = \phi_1 y_t + \phi_2 y_{t-1} + \varepsilon_t$$

$$y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2}$$

$$\underbrace{\begin{pmatrix} y_{t+1} \\ y_t \end{pmatrix}}_{\alpha_{t+1}} = \underbrace{\begin{pmatrix} \phi_1 & \phi_2 \\ 1 & 0 \end{pmatrix}}_{T_t} \underbrace{\begin{pmatrix} y_t \\ y_{t-1} \end{pmatrix}}_{\alpha_t} + \begin{pmatrix} 1 \\ 0 \end{pmatrix} \varepsilon_{t+1}$$

outra representação, de forma que $\alpha_t^* = B \alpha_t$ onde $\det(B) \neq 0$
 \Rightarrow fácil verossimilhança via o m/mc

$$y_t = \begin{pmatrix} 1 & 0 \end{pmatrix} \begin{pmatrix} y_t \\ \phi_2 y_{t-1} \end{pmatrix} + \varepsilon_t$$

$$\underbrace{\begin{pmatrix} y_{t+1} \\ \phi_2 y_t \end{pmatrix}}_{\alpha_{t+1}^*} = \begin{pmatrix} \phi_1 & 1 \\ \phi_2 & 0 \end{pmatrix} \underbrace{\begin{pmatrix} y_t \\ \phi_2 y_{t-1} \end{pmatrix}}_{\alpha_t^*} + \begin{pmatrix} 1 \\ 0 \end{pmatrix} \varepsilon_t$$

$$B \Rightarrow \det B \neq 0$$

$$\Rightarrow \alpha_t^* = \begin{pmatrix} 1 & 0 \\ 0 & \phi_2 \end{pmatrix} \alpha_t$$

Ex. 2) $y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t$

$$\left\{ \begin{array}{l} y_t = z_t \alpha_t + \varepsilon_t \\ \alpha_{t+1} = T_t \alpha_t + R_t \eta_t \end{array} \right\} \rightarrow \begin{pmatrix} y_t \\ y_{t-1} \\ \vdots \\ y_{t-p} \end{pmatrix}$$

$$y_t = (1 \ 0 \ \dots \ 0) \begin{pmatrix} y_t \\ y_{t-1} \\ \vdots \\ y_{t-p} \end{pmatrix} + \varepsilon_t$$

$$\begin{pmatrix} y_{t+1} \\ y_t \\ \vdots \\ y_{t-p+1} \end{pmatrix} = \begin{pmatrix} \phi_1 & \phi_2 & \dots & \phi_p \\ 1 & 0 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & \dots & 1 & 0 \end{pmatrix} \begin{pmatrix} y_t \\ y_{t-1} \\ \vdots \\ y_{t-p} \end{pmatrix} + \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} \varepsilon_{t+1}$$

$$y_{t+1} = \phi_1 y_t + \phi_2 y_{t-1} + \dots + \phi_p y_{t-p+1} + \varepsilon_{t+1}$$

Ex. 3) $y_t \sim \text{MA}(1)$

$$y_t = \theta \varepsilon_{t-1} + \varepsilon_t \Rightarrow y_{t+1} = \theta \varepsilon_t + \varepsilon_{t+1}$$

$$\left\{ \begin{array}{l} y_t = z_t \alpha_t + \varepsilon_t \\ \alpha_{t+1} = T_t \alpha_t + R_t \eta_t \end{array} \right\} \rightarrow \begin{pmatrix} y_t \\ \varepsilon_t \end{pmatrix}$$

$$y_t = (1 \ 0) \begin{pmatrix} y_t \\ \varepsilon_t \end{pmatrix} + \varepsilon_t$$

$$\begin{pmatrix} y_{t+1} \\ \varepsilon_{t+1} \end{pmatrix} = \begin{pmatrix} 0 & \theta \\ 0 & 0 \end{pmatrix} \begin{pmatrix} y_t \\ \varepsilon_t \end{pmatrix} + \begin{pmatrix} 1 \\ 1 \end{pmatrix} \varepsilon_{t+1}$$

Exercício 0 ARMA.

Ex. 4) $y_t = \phi y_{t-1} + \theta \varepsilon_{t-1} + \varepsilon_t$ (ARMA)

$$\left\{ \begin{array}{l} y_t = z_t \alpha_t + \varepsilon_t \\ \alpha_{t+1} = T_t \alpha_t + R_t \eta_t \end{array} \right\} \Rightarrow \begin{array}{l} y_t \\ \varepsilon_t \\ \varepsilon_{t-1} \end{array}$$

$$y_{t+1} = \phi y_t + \theta \varepsilon_t + \varepsilon_{t+1}$$

$$y_t = (1 \quad 0 \quad 0) \begin{pmatrix} y_t \\ \varepsilon_t \\ \varepsilon_{t-1} \end{pmatrix} + \varepsilon_t$$

$$\begin{pmatrix} y_{t+1} \\ \varepsilon_{t+1} \\ \varepsilon_t \end{pmatrix} = \begin{pmatrix} \phi & \theta & 0 \\ 0 & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix} \begin{pmatrix} y_t \\ \varepsilon_t \\ \varepsilon_{t-1} \end{pmatrix} + \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} \varepsilon_{t+1}$$

Ex. 5) Regressões múltipla

ver soluções caderno de outra pessoa.



Aula
16/03.

Modelo

$$\begin{cases} y_t = z_t \alpha_t + d_t + \varepsilon_t, & \varepsilon_t \sim N(0, H_t) \\ \alpha_{t+1} = T_t \alpha_t + c_t + R_t \eta_t, & \eta_t \sim N(0, Q_t) \end{cases}$$

$$\begin{cases} \alpha_1 \sim N(a_1, P_1) & \Rightarrow \text{cond. inicial} \\ E[\varepsilon_t \eta_s'] = 0 \quad \forall t, s & \Rightarrow \text{choques descorrelacionados (pode ser relaxado)} \\ E[\eta_t' \alpha_s] = E[\varepsilon_t' \alpha_s] = 0 \quad \forall t & \Rightarrow \text{já mais pode relaxar} \\ E[c_t \varepsilon_s'] = 0 \quad \forall s, t & \Rightarrow \text{ruídos brancos} \\ E[\eta_t \eta_s'] = 0 \quad \forall s, t \end{cases}$$

Propriedades dos MEE lineares a Tempo Discreto.

(1) Estacionariedade de 2ª ordem

(2) Observabilidade

(1) Estacionariedade de 2ª ordem

Processo estocástico X_t é dito estacionário ss as seguintes condições são satisfeitas:

(i) $E[X_t] = \mu \quad \forall t, \mu < \infty$

(ii) $E[(X_t - E[X_t])(X_{t+h} - E[X_{t+h}])'] = \Gamma(h) \quad \forall t$
 $\forall h = 0, 1, 2, \dots$

Equações do MEE:

$$\begin{cases} y_t = z_t \alpha_t + \varepsilon_t \\ \alpha_{t+1} = T \alpha_t + R \eta_t \end{cases} \quad \begin{aligned} & (\text{fazendo } d_t = c_t = 0 \text{ spg.}) \\ & (\text{fazendo } z_t = z, T_t = T, R_t = R) \end{aligned}$$

cond (i): $E[y_t] = z E[\alpha_t] + E[\underbrace{\varepsilon_t}_0]$
 \downarrow
 depende de $E[\alpha_t]$

cond. (ii). $E[(y_t - E[y_t])(y_{t+h} - E[y_{t+h}])'] =$
 avaliar $\alpha = \Gamma_y(h)$

$$\begin{aligned} \cdot y_t - E[y_t] &= z\alpha_t + \varepsilon_t - z E[\alpha_t] \\ &= z(\alpha_t - E[\alpha_t]) + \varepsilon_t \end{aligned}$$

$$\cdot y_{t+h} - E[y_{t+h}] = z(\alpha_{t+h} - E[\alpha_{t+h}]) + \varepsilon_{t+h}$$

$$\begin{aligned} \Rightarrow (y_t - E[y_t])(y_{t+h} - E[y_{t+h}])' &= \\ &= [z(\alpha_t - E[\alpha_t]) + \varepsilon_t] [(\alpha_{t+h} - E[\alpha_{t+h}])' z' + \varepsilon_{t+h}'] \\ &= z(\alpha_t - E[\alpha_t])(\alpha_{t+h} - E[\alpha_{t+h}])' z' + \\ &\quad + z(\alpha_t - E[\alpha_t]) \varepsilon_{t+h}' + \varepsilon_t (\alpha_{t+h} - E[\alpha_{t+h}])' z' + \\ &\quad + \varepsilon_t \varepsilon_{t+h}' \end{aligned}$$

Passando valor esperado:

$$\begin{aligned} \cdot E[z(\alpha_t - E[\alpha_t])(\alpha_{t+h} - E[\alpha_{t+h}])' z'] &= \\ &= z E[(\alpha_t - E[\alpha_t])(\alpha_{t+h} - E[\alpha_{t+h}])'] z' = \\ &= z \Gamma_\alpha(h) z' \end{aligned}$$

$$\begin{aligned} \cdot E[z(\alpha_t - E[\alpha_t]) \varepsilon_{t+h}'] &= \\ &= z E[(\alpha_t - E[\alpha_t]) \varepsilon_{t+h}'] = \\ &= z E[\underbrace{\alpha_t}_{0} \underbrace{\varepsilon_{t+h}'}_0] - z E[\alpha_t] E[\varepsilon_{t+h}'] = 0 \end{aligned}$$

por quê? (*)

$$E[\varepsilon_t (\alpha_{t+h} - E[\alpha_{t+h}])' z'] =$$

$$= E[\underbrace{\varepsilon_t}_{\substack{\downarrow \\ 0}} \underbrace{\alpha_{t+h}}_{\substack{\downarrow \\ 0}} z' - \underbrace{E[\varepsilon_t]}_0 E[\alpha_{t+h}] z'] = 0$$

por que? (*)

$$E[\varepsilon_t \varepsilon_{t+h}'] = \begin{cases} 0 & \text{se } h \neq 0 \\ H & \text{se } h = 0 \end{cases}$$

$$(*) \quad \alpha_{t+1} = T\alpha_t + R_t \eta_t$$

$$\alpha_2 = T\alpha_1 + R\eta_1$$

$$\alpha_3 = T\alpha_2 + R\eta_2$$

$$= T(T\alpha_1 + R\eta_1) + R\eta_2$$

$$= T^2\alpha_1 + TR\eta_1 + R\eta_2$$

$$\alpha_4 = T\alpha_3 + R\eta_4$$

$$= T(T^2\alpha_1 + TR\eta_1 + R\eta_2) + R\eta_3$$

$$= T^3\alpha_1 + T^2R\eta_1 + TR\eta_2 + R\eta_3$$

$$\Rightarrow \left| \alpha_{t+1} = T^t \alpha_1 + \sum_{i=0}^{t-1} T^i R \eta_{t-i} \right|$$

$$E[\alpha_t \varepsilon_{t+h}'] =$$

$$E\left[\left(T^{t-1}\alpha_1 + \sum_{i=0}^{t-2} T^i R \eta_{t-i}\right) \varepsilon_{t+h}'\right]$$

$$\Rightarrow \text{Termos com } E[\alpha_1 \varepsilon_{t+h}'] = 0.$$

$$\text{com } E[\eta_{t-i} \varepsilon_{t+h}'] = 0.$$

Logo:

$$E[(y_t - E[y_t])(y_{t+h} - E[y_{t+h}])'] = \begin{cases} \Sigma_{\alpha}(0, t) z' + H & \text{se } h = 0 \\ \Sigma_{\alpha}(h, t) z' & \text{se } h \neq 0 \end{cases}$$

EX1:

$$1) \quad y_t = \mu_t + \varepsilon_t \quad \varepsilon_t \sim N(0, \sigma_\varepsilon^2)$$

$$\mu_{t+1} = \phi \mu_t + \eta_t \quad \eta_t \sim N(0, \sigma_\eta^2)$$

(*) Iterando μ_{t+1} :

$$\mu_2 = \phi \mu_1 + \eta_1$$

$$\mu_3 = \phi \mu_2 + \eta_2 = \phi^2 \mu_1 + \phi \eta_1 + \eta_2$$

$$\mu_4 = \phi \mu_3 + \eta_3 = \phi^3 \mu_1 + \phi^2 \eta_1 + \phi \eta_2 + \eta_3$$

$$|\phi| < 1$$

$$\Rightarrow E[\mu_{t+1}] = \phi E[\mu_t] + 0$$

→ tende a zero se $|\phi| < 1$

por que (*)

μ_t : segue AR(1)

(divisão de μ_t por μ_t)

$$E[\mu_t] = 0$$

$$\text{var}[\mu_t] = \gamma_\mu(0) = \frac{\sigma_\eta^2}{(1-\phi^2)}$$

funções só de h

$$\gamma_\mu(h) = \frac{\phi^h \sigma_\eta^2}{(1-\phi^2)}$$

$$\rho_\mu(h) = \frac{\gamma(h)}{\gamma(0)} = \phi^h$$

Estudar modelos AR (Hamilton).

→ AR(1) é estacionário se $|\phi| < 1$.

(se não $\gamma_\mu(h)$ explode, nos termos)

$$\lim_{h \rightarrow \infty} (\gamma_\mu(h)) < \infty$$

$$E[y_t] = E[\mu_t] + E[\varepsilon_t] = 0$$

variação da v.a. no tempo

$$\text{var}[y_t] = \text{var}[\mu_t] + \text{var}[\varepsilon_t]$$

$$\gamma_y(0) = \gamma_\mu(0) + \sigma_\varepsilon^2$$

obs: μ_t e ε_t independentes

$$\text{var}[\mu_t + \varepsilon_t] = \text{var}(\mu_t) + \text{var}(\varepsilon_t)$$

covariância da variável com 1 of

$$= \frac{\sigma_\eta^2}{(1-\phi^2)} + \sigma_\varepsilon^2$$

$$\gamma_y(h) = E[(y_t - E[y_t])(y_{t+h} - E[y_{t+h}])']$$

$$= E[y_t y_{t+h}']$$

$$= E[(\mu_t + \varepsilon_t)(\mu_{t+h} + \varepsilon_{t+h})']$$

$$= E[\mu_t \mu_{t+h}] + E[\mu_t \varepsilon_{t+h}'] + E[\varepsilon_t \mu_{t+h}] + E[\varepsilon_t \varepsilon_{t+h}']$$

$$= \gamma_\mu(h)$$

$$2) \quad y_t = \mu_t + \varepsilon_t$$

$$\mu_{t+1} = \mu_t + \eta_t$$

ds: mesmo anterior, mas $\phi = 1$.

cond. inicial

$$\mu_1 \sim N(a_1, P_1)$$

e todas as outras
inicialmente
expostas

$$\bullet \quad E[\mu_t] = ?$$

Iterando μ_{t+1} :

$$\mu_2 = \mu_1 + \eta_1$$

$$\mu_3 = \mu_2 + \eta_2 = \mu_1 + \eta_1 + \eta_2$$

$$\mu_4 = \mu_3 + \eta_3 = \mu_1 + \eta_1 + \eta_2 + \eta_3 \dots$$

$$\mu_{t+1} = \left(\mu_1 + \sum_{i=1}^t \eta_i \right) \Rightarrow E[\mu_{t+1}] = E[\mu_1] = a_1 \Rightarrow \text{da cond. inicial}$$

$$\therefore E[\mu_{t+1}] = a_1$$

$$\bullet \quad \text{var}[\mu_{t+1}] = \sigma_\mu(0)$$

$$= E[(\mu_{t+1} - a_1)(\mu_{t+1} - a_1)']$$

$$= E\left[\left(\mu_1 + \sum_{i=1}^t \eta_i - a_1\right)\left(\mu_1 + \sum_{i=1}^t \eta_i - a_1\right)'\right]$$

$$= E[\mu_1 \mu_1'] + E[\mu_1 \cdot \sum_{i=1}^t \eta_i'] + E[\sum_{i=1}^t \eta_i \cdot \mu_1'] +$$

$$+ E\left[\left(\sum_{i=1}^t \eta_i\right)\left(\sum_{j=1}^t \eta_j\right)'\right]$$

$$\begin{aligned} \mu_i = j &\Rightarrow \sigma_\eta^2 \\ \mu_i + j &\Rightarrow \emptyset \end{aligned}$$

$$\text{var}[\mu_{t+1}] = P_1 + t \sigma_\eta^2$$

$\Rightarrow \text{var}(\mu)$ depende de t

Processo não está estacionário.

$$\bullet \quad E[y_t] = E[\mu_t] + E[\varepsilon_t] = a_1$$

Próxima vida
 $\text{var}(\mu_t) = P_1 + (t-1)\sigma_\eta^2$?

$$\begin{aligned}
 \cdot \text{var}[y_t] &= \sigma_y(0) \\
 &= \text{var}(\mu_t) + \text{var}(\varepsilon_t) \\
 &= \sigma_\mu(0) + \sigma_\varepsilon^2 \\
 &= \rho_1 + (t-1)\sigma_\eta^2 + \sigma_\varepsilon^2
 \end{aligned}$$

\downarrow
 No caderno está t .
 Nas deveria ser $t-1$?

\Rightarrow depende de t : y não é estacionária.

Conclusão: Estacionariedade dependerá sempre do comportamento de (α_t) .

Voltando à demonstração:

$$\cdot E[y_t] = Z E[\alpha_t]$$

$$\cdot \Gamma_y(h, t) = \begin{cases} Z \Gamma_\alpha(h, t) Z' & , h \neq 0 \\ Z \Gamma_\alpha(0, t) Z' + H & , h = 0. \end{cases}$$

$$\alpha_{t+1} = T^t \alpha_1 + \sum_{j=0}^{t-1} T^j R \eta_{t-j}$$

$$E[\alpha_{t+1}] = T^t E[\alpha_1] = T^t a_1 = f(t)?$$

1ª condição:
sobre
média

\downarrow
 queremos avaliar
 se $E[\alpha_{t+1}]$ é função
 do tempo.

Supondo que todos os autovalores de T são distintos.

$$\text{Lembrando: } T f_i = \lambda_i f_i \quad i = 1, 2, \dots, m$$

onde λ_i autovalores
 f_i autovetores.

$$\Rightarrow TF_i - \lambda_i F_i = 0$$

$$(T - \lambda_i I) F_i = 0$$

como $F_i \neq 0$.

$\Rightarrow \det(T - \lambda_i I) = 0$: equações características

dará (m) autovalores, $\neq 0$.

supondo (α m-variada)

Vale a decomposição espectral:

$$T = F \Lambda (F^T)^{-1} = F \Lambda F^T \text{ (transp = inversa pois matriz ortogonal)}$$

Prova-se que:

$$T^T = F \Lambda^T F^{-1}$$

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix} \begin{pmatrix} x & t \\ s & h \end{pmatrix} =$$

$ax + bs$

$$\Rightarrow E[\alpha_{t+1}] = T^T a_t = F \Lambda^T F^{-1} a_t$$

$$E \begin{bmatrix} \alpha_{1,t+1} \\ \alpha_{2,t+1} \\ \vdots \\ \alpha_{m,t+1} \end{bmatrix} = \begin{pmatrix} f_{11} & f_{12} & \dots & f_{1m} \\ f_{21} & \dots & f_{2m} \\ \vdots & & \vdots \\ f_{m1} & \dots & f_{mm} \end{pmatrix} \begin{pmatrix} \lambda_1^t & & 0 \\ & \ddots & \\ 0 & & \lambda_m^t \end{pmatrix} \begin{pmatrix} f_{11}^t & f_{12}^t & \dots & f_{1m}^t \\ \vdots & \vdots & \ddots & \vdots \\ f_{m1}^t & \dots & \dots & f_{mm}^t \end{pmatrix}$$

$m \times m$ $m \times m$ $m \times m$

Transpostas de F

$$= \begin{pmatrix} f_{11} \lambda_1^t & f_{12} \lambda_2^t & \dots & f_{1m} \lambda_m^t \\ f_{21} \lambda_1^t & f_{22} \lambda_2^t & \dots & f_{2m} \lambda_m^t \\ \vdots & \vdots & \ddots & \vdots \\ f_{m1} \lambda_1^t & \dots & \dots & f_{mm} \lambda_m^t \end{pmatrix} \begin{pmatrix} f_{11}^t & f_{12}^t & \dots & f_{1m}^t \\ f_{21}^t & f_{22}^t & \dots & f_{2m}^t \\ \vdots & \vdots & \ddots & \vdots \\ f_{m1}^t & \dots & \dots & f_{mm}^t \end{pmatrix} \begin{pmatrix} a_1 \\ a_2 \\ \vdots \\ a_m \end{pmatrix}$$

$m \times m$ $m \times m$

fazer

$$= \begin{pmatrix} \Sigma \\ \vdots \end{pmatrix}$$

Para cada α_j temos o equivalente $\Pi \alpha_{\perp}$

$$E[\alpha_{i,t+1}] = \delta_1 \lambda_1^t + \delta_2 \lambda_2^t + \dots + \delta_m \lambda_m^t$$

$$\text{onde } \delta_i = |\lambda_i|^{-1} a_{i1}, \quad i=1, \dots, m$$



depende explicitamente de t , mas...

$$\text{Se } |\lambda_i| < 1 \quad \forall i=1, \dots, m$$

$$\text{fazendo: } \lim_{t \rightarrow \infty} E[\alpha_{i,t+1}] = 0.$$

logo: $|\lambda_i| < 1$: condições necessária e suficiente p/ estacionariedade de 1ª ordem.
 $\forall i=1, \dots, m$

obs: tb são p/ de 2ª ordem

2ª condições:
sobre
variância

$$\Gamma_{\alpha}(h, t) = ?$$

$$\Gamma_{\alpha}(h, t) = E[(\alpha_{t+1} - E[\alpha_{t+1}])(\alpha_{t+h+1} - E[\alpha_{t+h+1}])']$$

Explicitando α_{t+1} em função de α_{\perp} .

$$\begin{aligned} \alpha_{t+1} &= T\alpha_t + R\eta_t \\ &= T^t \alpha_1 + \sum_{j=0}^{t-1} T^j R \eta_{t-j} \end{aligned}$$

$$E[\alpha_{t+1}] = T^t E[\alpha_t] = T^t a_1$$

$$\Rightarrow \alpha_{t+1} - E[\alpha_{t+1}] = T^t (\alpha_1 - a_1) + \sum_{j=0}^{t-1} T^j R \eta_{t-j}$$

$$\Rightarrow \alpha_{t+h+1} - E[\alpha_{t+h+1}] = T^{t+h} (\alpha_1 - a_1) + \sum_{j=0}^{t+h-1} T^j R \eta_{t+h-j}$$

Então:

$$\Gamma_{\alpha}(h, t) = E \left[\left[T^t (\alpha_t - a_t) + \sum_{j=0}^{t-1} T^j R \eta_{t-j} \right] \left[T^{t+h} (\alpha_t - a_t) + \sum_{j=0}^{t+h-1} T^j R \eta_{t+h-j} \right]' \right]$$

$$= E \left[\left[T^t (\alpha_t - a_t) + \sum_{j=0}^{t-1} T^j R \eta_{t-j} \right] \left[(\alpha_t - a_t)' T^{t+h} + \sum_{j=0}^{t+h-1} \eta_{t+h-1-j}' R' T^j \right]' \right]$$

Temos os seguintes termos:

$$\begin{aligned} & \cdot E \left[T^t (\alpha_t - a_t) (\alpha_t - a_t)' T^{t+h} \right] = \\ & = T^t E \left[(\alpha_t - a_t) (\alpha_t - a_t)' \right] T^{t+h} = \\ & = T^t P_t T^{t+h} \end{aligned}$$

$$\cdot E \left[T^t (\alpha_t - a_t) \sum_{j=0}^{t+h-1} \eta_{t+h-1-j}' R' T^j \right]$$

dá 0

$$\cdot E \left[\sum_{j=0}^{t-1} T^j R \eta_{t-j} (\alpha_t - a_t)' T^{t+h} \right]$$

dá 0

$$\cdot E \left[\left(\sum_{j=0}^{t-1} T^j R \eta_{t-j} \right) \left(\sum_{i=0}^{t+h-1} \eta_{t+h-1-i}' R' T^i \right) \right]$$

Para $h=0$

$$\Gamma_{\alpha}(0, t) = T^t P_t T^{t+h} + \sum_{j=0}^{t-1} T^j (R Q R') T^j$$

Procurar
demo

Podemos demonstrar também que condições se resumem a:

$$|\lambda_i| < 1 \quad \forall i = 1, \dots, m$$

e $t \rightarrow \infty$

$\Rightarrow \Gamma(0, t) \rightarrow \Sigma(0)$ independente de

DS:

Fazer condições de estacionariedade p/ AR(1):

$$\alpha_t = \phi \alpha_{t-1} + \eta_t$$

$$\cdot \alpha_t = \alpha_1 \phi^t + \sum \phi^j \eta_{t-j}$$

$$\cdot \alpha_{t+h} = \alpha_1 \phi^{t+h} + \sum \phi^j \eta_{t+h-j}$$

$$\text{calcular } \gamma(h, t) = E[(\alpha_t - E(\alpha_t))(\alpha_{t+h} - E(\alpha_{t+h}))']$$

Supondo cond. de estacionariedade de 2ª ordem satisfeitas.

$$|\lambda_i(t)| < 1 \text{ e } t \rightarrow \infty.$$

Obter expressões para a matriz de covariâncias de α_t :

$$\text{Já vimos que: } E[\alpha_{t+1}] = 0.$$

$$\text{var}[\alpha_{t+1}] = ?$$

obs: operações em AL: ver caderno.

$$\begin{cases} \text{vec}(A) \\ A \otimes B \\ \text{vec}(ABC) = (C' \otimes A) \text{vec} B. \end{cases}$$

$$\alpha_{t+1} = T\alpha_t + R_t\eta_t$$

$$\begin{aligned} \text{var}(\alpha_{t+1}) &= T \underbrace{\text{var}(\alpha_t)}_{\Sigma_\alpha(0)} T' + R \underbrace{\text{var}(\eta_t)}_Q R' \\ &\downarrow \qquad \qquad \qquad Q: \text{ck. por hipótese.} \\ &= \text{var}(\alpha_t) \end{aligned}$$

$$= \Sigma_\alpha(0)$$

$$\Sigma_\alpha(0) = T \Sigma_\alpha(0) T' + RQR'$$

$$\begin{aligned} \text{vec}(\Sigma_\alpha(0)) &= \text{vec}(T \Sigma_\alpha(0) T') + \text{vec}(RQR') \\ &= (T \otimes T) \text{vec}(\Sigma_\alpha(0)) + (R \otimes R') \text{vec} Q \end{aligned}$$

$$(I - (T \otimes T)) \text{vec}(\Sigma_\alpha(0)) = (R \otimes R') \text{vec} Q$$

$$\boxed{\text{vec}(\Sigma_\alpha(0)) = (I - T \otimes T)^{-1} \text{vec} Q}$$

Divida:
como e
quando
usa?

Exercícios:

Considere os seguintes modelos em EE.

$$(1) \quad y_t = \underset{\substack{\downarrow \\ 2}}{\begin{bmatrix} 1 & 0 \end{bmatrix}} \begin{bmatrix} \mu_t \\ \beta_t \end{bmatrix} + \varepsilon_t$$

$$\begin{bmatrix} \mu_{t+1} \\ \beta_{t+1} \end{bmatrix} = \underset{\substack{\downarrow \\ T}}{\begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}} \begin{bmatrix} \mu_t \\ \beta_t \end{bmatrix} + \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \eta_t \\ \zeta_t \end{bmatrix}$$

$$\underset{\substack{\downarrow \\ \text{da notação anterior}}}{\tilde{\eta}_t} = \begin{pmatrix} \eta_t \\ \zeta_t \end{pmatrix} \Rightarrow E[\tilde{\eta}_t \tilde{\eta}_t'] = \begin{pmatrix} \sigma_\eta^2 & 0 \\ 0 & \sigma_\zeta^2 \end{pmatrix} = Q \quad \downarrow \text{da notação anterior}$$

obs: Equações $\begin{cases} y_t = \mu_t + \varepsilon_t \\ \mu_{t+1} = \mu_t + \beta_t + \eta_t \\ \beta_{t+1} = \beta_t + \zeta_t \end{cases}$ modelo linear local
tendência linear estocástica

$$\text{se } \sigma_\eta^2 = \sigma_\zeta^2 = 0 \Rightarrow y_t = a + \underset{\downarrow}{bt} + \varepsilon_t$$

porquê? de vai somando a cada

Calculando autovalores de T

$$|T - \lambda I| = 0$$

$$\left| \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} - \begin{pmatrix} \lambda & 0 \\ 0 & \lambda \end{pmatrix} \right| = \begin{vmatrix} 1-\lambda & 1 \\ 0 & 1-\lambda \end{vmatrix} = (1-\lambda)^2 = 0$$

$\lambda_1 = \lambda_2 = 1$

\Rightarrow Processo não estacionário

$$(2) \quad y_t = \overset{2_t}{\begin{bmatrix} 1 & 0 \end{bmatrix}} \begin{bmatrix} \mu_t \\ \beta_t \end{bmatrix} + \varepsilon_t$$

$$\underbrace{\begin{bmatrix} \mu_{t+1} \\ \beta_{t+1} \end{bmatrix}}_{\alpha_{t+1}} = \underbrace{\begin{bmatrix} \phi_1 & 1 \\ 0 & \phi_2 \end{bmatrix}}_T \underbrace{\begin{bmatrix} \mu_t \\ \beta_t \end{bmatrix}}_{\alpha_t} + \underbrace{\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}}_R \underbrace{\begin{bmatrix} \eta_t \\ \zeta_t \end{bmatrix}}_{\tilde{\eta}_t}$$

Analogamente:

$$\tilde{\eta}_t = \begin{pmatrix} \eta_t \\ \xi_t \end{pmatrix} \Rightarrow E[\tilde{\eta}_t \tilde{\eta}_t'] = \begin{pmatrix} \sigma_\eta^2 & 0 \\ 0 & \sigma_\xi^2 \end{pmatrix} = \Phi$$

Equações:

$$\begin{cases} y_t = \mu_t + \varepsilon_t \\ \mu_{t+1} = \phi_1 \mu_t + \beta_t + \eta_t \\ \beta_{t+1} = \phi_2 \beta_t + \xi_t \end{cases}$$

$$\alpha_t = \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} \quad T = \begin{pmatrix} \phi_1 & 1 \\ 0 & \phi_2 \end{pmatrix} \quad R = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \quad \tilde{\eta}_t = \begin{pmatrix} \eta_t \\ \xi_t \end{pmatrix}$$

$$\Phi = \begin{pmatrix} \sigma_\eta^2 & 0 \\ 0 & \sigma_\xi^2 \end{pmatrix}$$

$$Z = \begin{pmatrix} 1 & 0 \end{pmatrix}$$

(a) Sob que condições $|\lambda_i(t)| < 1 \quad i=1,2$

Autovalores de T:

$$|T - \lambda I| = 0$$

$$\left| \begin{pmatrix} \phi_1 & 1 \\ 0 & \phi_2 \end{pmatrix} - \begin{pmatrix} \lambda & 0 \\ 0 & \lambda \end{pmatrix} \right| = 0$$

$$\left| \begin{pmatrix} \phi_1 - \lambda & 1 \\ 0 & \phi_2 - \lambda \end{pmatrix} \right| = (\phi_1 - \lambda)(\phi_2 - \lambda) = 0$$

$$\phi_1 \phi_2 - \phi_1 \lambda - \phi_2 \lambda + \lambda^2 = 0$$

$$\lambda^2 - (\phi_1 + \phi_2)\lambda + (\phi_1 \phi_2) = 0$$

$$\lambda = \frac{(\phi_1 + \phi_2) \pm \sqrt{(\phi_1 + \phi_2)^2 - 4(\phi_1 \phi_2)}}{2}$$

$$\lambda = (\phi_1 + \phi_2) \pm \sqrt{(\phi_1 - \phi_2)^2}$$

$$= \phi_1 + \phi_2 \pm (\phi_1 - \phi_2)$$

Queremos $|\lambda| < 1$

$$|\phi_1 + \phi_2 - \phi_1 + \phi_2| < 1 \Rightarrow 2|\phi_2| < 1 \Rightarrow \boxed{|\phi_2| < 1/2}$$

$$|\phi_1 + \phi_2 + \phi_1 - \phi_2| < 1 \Rightarrow \boxed{|\phi_1| < 1/2}$$

b) Avaliar $\lim_{t \rightarrow \infty} \Gamma_\alpha(0, t)$

$$\lim_{t \rightarrow \infty} \Gamma_\alpha(h, t)$$

$$\lim_{t \rightarrow \infty} \Gamma_y(0, t)$$

$$\lim_{t \rightarrow \infty} \Gamma_y(h, t)$$

$$\Gamma_\alpha(0, t) = \underbrace{(T^* P_t T)}_{\text{matriz}} \Sigma T^T(R, Q, R)^{-1}$$

• $\Gamma_\alpha(h, t) = ?$

$$= E[(\alpha_t - E[\alpha_t])(\alpha_{t+h} - E[\alpha_{t+h}])']$$

• $E[\alpha_{t+1}] = E \begin{bmatrix} \mu_{t+1} \\ \beta_{t+1} \end{bmatrix}$

$$= E \begin{bmatrix} \phi_1 \mu_t + \beta_t + \eta_t \\ \phi_2 \beta_t + \xi_t \end{bmatrix}$$

$$\beta_t: AR(1) \Rightarrow E[\beta_{t+1}] = 0 \quad \Rightarrow E[\alpha_t] = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$E[\mu_{t+1}] = 0$$

$$\Gamma_{\alpha}(0, t) = T^t \rho_i T^{t'} + \sum T^j (R \Phi R') T^j$$

$$T^2 = \begin{pmatrix} \phi_1 & 1 \\ 0 & \phi_2 \end{pmatrix} \begin{pmatrix} \phi_1 & 1 \\ 0 & \phi_2 \end{pmatrix} = \begin{pmatrix} \phi_1^2 & \phi_1 + \phi_2 \\ 0 & \phi_2^2 \end{pmatrix}$$

$$T^3 = \begin{pmatrix} \phi_1^2 & \phi_1 + \phi_2 \\ 0 & \phi_2^2 \end{pmatrix} \begin{pmatrix} \phi_1 & 1 \\ 0 & \phi_2 \end{pmatrix} =$$

$$= \begin{pmatrix} \phi_1^3 & \phi_1^2 + \phi_1 \phi_2 + \phi_2^2 \\ 0 & \phi_2^3 \end{pmatrix}$$

$$T^4 = \begin{pmatrix} \phi_1^3 & \phi_1^2 + \phi_1 \phi_2 + \phi_2^2 \\ 0 & \phi_2^3 \end{pmatrix} \begin{pmatrix} \phi_1 & 1 \\ 0 & \phi_2 \end{pmatrix}$$

Observabilidade

MEE linear, discreto, invariante no tempo.

$$\begin{cases} y_t = Z \alpha_t \\ \alpha_{t+1} = T \alpha_t + R \eta_t \end{cases}$$

$p \times m$ $n \times m$

sistema observável se α_0 pode ser determinado a partir de conjunto de medidas de y .

• fazendo $\eta_t = 0 \forall t \in \mathbb{I}$:

$$\alpha_{t+1} = T \alpha_t \Rightarrow \alpha_{t+1} = T^t \alpha_0 \text{ (recursivamente)}$$

$$\boxed{\alpha_t = T^t \alpha_0}$$

$$y_t = Z \alpha_t \Rightarrow \boxed{y_t = Z T^t \alpha_0}$$

$$\begin{matrix} p \times m & m \times 1 \\ y_0 = Z \alpha_0 \\ y_1 = Z T \alpha_0 \\ y_2 = Z T^2 \alpha_0 \\ \vdots \\ y_{m-1} = Z T^{m-1} \alpha_0 \end{matrix} \begin{pmatrix} y_0 \\ y_1 \\ y_2 \\ \vdots \\ y_{m-1} \end{pmatrix} = \begin{pmatrix} Z \\ Z T \\ Z T^2 \\ \vdots \\ Z T^{m-1} \end{pmatrix} \begin{pmatrix} \alpha_{0,1} \\ \alpha_{0,2} \\ \vdots \\ \alpha_{0,m} \end{pmatrix}$$

$p \times m$ $\alpha_0: m \times 1$

(pois cada Z : $p \times m$
e matriz tem m linhas de matrizes $Z T^i$)

$$\underset{p \times 1}{\tilde{y}} = \underset{p \times m}{\tilde{M}} \underset{m \times 1}{\tilde{\alpha}_0}$$

• Para determinarmos os elementos de α_0 de forma única, a cond. necessária e suficiente será:

$\text{posto}(M) = m \Rightarrow$ é exatamente o tamanho de α_0 e faz com que haja solução única p/ α_0 no sistema acima.

como $\text{posto } M = \text{posto } M'$

$$\text{posto } M' = \text{posto } (Z', T'Z', \dots, (T^{m-1})'Z') = m$$

Se $p=1$, i.e. y_t é escalar $\Rightarrow M: m \times m$

cond de observabilidade pode ser investigada checando $\det M \neq 0$

Exs:

1) $y_t = \mu_t + \epsilon_t$

$$\mu_{t+1} = \mu_t + \beta_t + \eta_t$$

$$\beta_{t+1} = \beta_t + \zeta_t$$

$p=1$
 $m=2$

$$Z: p \times m \quad ZT: p \times m$$

$$T: m \times m$$

$$M \Rightarrow pm \times m: 2 \times 2$$

$$Z \Rightarrow 1 \times 2 \quad ZT \Rightarrow 1 \times 2$$

$$T \Rightarrow 2 \times 2 \quad T'Z' \Rightarrow 2 \times 1$$

Em forma EE:

$$y_t = \begin{pmatrix} 1 & 0 \end{pmatrix} \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} + \epsilon_t$$

$$\stackrel{m=2}{\Rightarrow} \begin{pmatrix} \mu_{t+1} \\ \beta_{t+1} \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \eta_t \\ \zeta_t \end{pmatrix}$$

$$Z = \begin{pmatrix} 1 & 0 \end{pmatrix} \Rightarrow Z' = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

$$T = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \Rightarrow T' = \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix}$$

$$T'Z' = \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

Logo: $M' = (Z', T'Z')$

$$= \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}$$

$\det M' = 1 \neq 0 \Rightarrow \text{posto } (M) = 2 = m$ cheio
observável.

$$2), y_t = \mu_t + \varepsilon_t$$

$$\mu_{t+1} = \mu_t + \eta_t$$

$$\beta_{t+1} = \beta_t + \zeta_t$$

$$y_t = \begin{pmatrix} 1 & 0 \end{pmatrix} \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} + \varepsilon_t$$

$$\begin{pmatrix} \mu_{t+1} \\ \beta_{t+1} \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \eta_t \\ \zeta_t \end{pmatrix}$$

$$z = \begin{pmatrix} 1 & 0 \end{pmatrix} \rightarrow \begin{matrix} p \times m \\ 1 \times 2 \end{matrix} \Rightarrow z' = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

$$T = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \rightarrow \begin{matrix} m \times m \\ 2 \times 2 \end{matrix} \Rightarrow T' = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

$$T'z' = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

$$\Rightarrow M' = \begin{pmatrix} 1 & 1 \\ 0 & 0 \end{pmatrix} \Rightarrow \det M' = 0$$

sistema não observável

$$3) \quad y_t = \mu_t + \beta_t + \varepsilon_t$$

$$\mu_{t+1} = \phi_1 \mu_t + \eta_t$$

$$\beta_{t+1} = \phi_2 \beta_t + \zeta_t$$

$$y_t = \begin{pmatrix} 1 & 1 \end{pmatrix} \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} + \varepsilon_t$$

$$\begin{pmatrix} \mu_{t+1} \\ \beta_{t+1} \end{pmatrix} = \begin{pmatrix} \phi_1 & 0 \\ 0 & \phi_2 \end{pmatrix} \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \eta_t \\ \zeta_t \end{pmatrix}$$

$$z = \begin{pmatrix} 1 & 1 \end{pmatrix}$$

$$z' = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$T = \begin{pmatrix} \phi_1 & 0 \\ 0 & \phi_2 \end{pmatrix} \Rightarrow T' = \begin{pmatrix} \phi_1 & 0 \\ 0 & \phi_2 \end{pmatrix}$$

$$\Rightarrow T' z' = \begin{pmatrix} \phi_1 & 0 \\ 0 & \phi_2 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} \phi_1 \\ \phi_2 \end{pmatrix}$$

$$\Rightarrow M' = \begin{pmatrix} 1 & \phi_1 \\ 1 & \phi_2 \end{pmatrix} \Rightarrow \det M' = \phi_2 - \phi_1 \neq 0$$

Para sistema observável: $\phi_1 \neq \phi_2$.

pt. menos posto (M') = 2.

4) Seja $y_t = \mu_t + \beta_t + \varepsilon_t \rightarrow$ 1º caso (3) com $\Phi_1 = \Phi_2 = 1$

Seja $\theta_t = \mu_t + \beta_t$

$\psi_t = \mu_t - \beta_t$

$y_t = \mu_t + \beta_t + \varepsilon_t$

$\mu_{t+1} = \mu_t + \eta_t$

$\beta_{t+1} = \beta_t + \zeta_t$

sistema não observável

• $y_t = \theta_t + \varepsilon_t$

outra forma de ver

• $\theta_{t+1} = \mu_{t+1} + \beta_{t+1}$
 $= (\mu_t + \eta_t) + (\beta_t + \zeta_t)$
 $= (\mu_t + \beta_t) + (\underbrace{\eta_t + \zeta_t}_{\delta_{1,t}})$
 $= \theta_t + \delta_{1,t}$

• $\psi_{t+1} = \mu_{t+1} - \beta_{t+1}$
 $= (\mu_t - \beta_t) + (\underbrace{\eta_t - \zeta_t}_{\delta_{2,t}})$
 $= \psi_t + \delta_{2,t}$

$\Rightarrow y_t = \begin{bmatrix} 1 & 0 \end{bmatrix} \begin{bmatrix} \theta_t \\ \psi_t \end{bmatrix} \rightarrow$ só na especificação


$\begin{bmatrix} \theta_{t+1} \\ \psi_{t+1} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \theta_t \\ \psi_t \end{bmatrix} + \begin{bmatrix} \delta_{1,t} \\ \delta_{2,t} \end{bmatrix}$

↓
 Nesta parametrização fica + fácil de ver que sistema é não observável.

Obs: \rightarrow observabilidade: será obrigatória a estimação dos parâmetros

\rightarrow estacionariedade: não " , vai depender da definição do modelo.

será importante definir nas cond. iniciais quais componentes são ou não estacionárias.



Estimações de MEE lineares e Gaussianos

$$y_t = z_t \alpha_t + \varepsilon_t$$

$$\alpha_{t+1} = T_t \alpha_t + R_t \eta_t \quad (t=1, \dots, n)$$

$$\text{onde } \varepsilon_t \sim N(0, H_t)$$

$$\eta_t \sim N(0, Q_t)$$

- Obs:
- equações do FK não exigem que sist seja invariante no tempo
 - n : tamanho da série (ou T)
 - FK não exige que choques tenham dist. Gaussianas, mas que sejam definidas sobre os 2 primeiros momentos
 - Gaussianidade: erro médio quadrático não ótimo
 - ótimo local (melhor estimador linear)

→ O que queremos?

(1) Estimar α_t dado certo conjunto de informações (observáveis)



Equivale a obter $p(\alpha_t | \mathcal{Y}_t)$: densidade condicional de α dado \mathcal{Y} .

$$E[\alpha_t | \mathcal{Y}_t] = \dots$$

$$\text{var}[\alpha_t | \mathcal{Y}_t] = \dots$$

Conjuntos possíveis de \mathcal{Y}_j :

$$\begin{aligned} \mathcal{Y}_{t-1} &= (y_1, y_2, \dots, y_{t-1}) \Rightarrow j=t-1 : \text{previstas} \\ \mathcal{Y}_t &= (y_1, y_2, \dots, y_t) \Rightarrow j=t : \text{atualizações} \\ \mathcal{Y}_n &= (y_1, y_2, \dots, y_{t-1}, y_t, \dots, y_n) \Rightarrow j=n : \text{suavizações} \end{aligned} \left. \vphantom{\begin{aligned} \mathcal{Y}_{t-1} \\ \mathcal{Y}_t \\ \mathcal{Y}_n \end{aligned}} \right\} \begin{array}{l} \text{usados} \\ \text{no} \\ \text{FK} \end{array}$$

(2) Estimar hiperparâmetros

(por MV nas matrizes do sistema)

⇒ Estimar função de estado usando previstas e atualizações

Exemplo:

considere o modelo linear local

$$\begin{cases} y_t = \mu_t + \varepsilon_t & \varepsilon_t \sim N(0, \sigma_\varepsilon^2) & \mu_1 \sim (a_1, p_1) \\ \mu_{t+1} = \mu_t + \eta_t & \eta_t \sim N(0, \sigma_\eta^2) & E[\varepsilon_t \mu_s] = E[\eta_t \mu_s] = 0 \quad \forall t \\ & & E[\varepsilon_t, \eta_s] = 0 \quad \forall t, s. \end{cases}$$

Obter $p(x_t | y_t)$ sem fazer uso do FK, apenas recorrendo a propriedades de vetores normais multivariados

→ Para y

$$y_1 = \mu_1 + \varepsilon_1$$

$$y_2 = \mu_2 + \varepsilon_2 = \mu_1 + \eta_1 + \varepsilon_1$$

$$y_n = \mu_1 + (\eta_1 + \eta_2 + \dots + \eta_{n-1}) + \varepsilon_n$$

$$\text{seja } y = (y_1 \ y_2 \ \dots \ y_n)'$$

$$E[y] = \begin{pmatrix} a_1 \\ \vdots \\ a_1 \end{pmatrix} = \mathbb{1} a_1$$

$$\text{Var}[y] = E[(y - E[y])(y - E[y])'] = \Omega$$

matriz
de var
covar

$$\Sigma_{yy} = \begin{bmatrix} \text{var}(y_1) & \text{cov}(y_1, y_2) & \dots & \text{cov}(y_1, y_n) \\ \text{cov}(y_1, y_2) & \dots & \dots & \vdots \\ \vdots & \dots & \dots & \text{var}(y_n) \end{bmatrix}_{n \times n}$$

variâncias:

$$\begin{aligned} \text{var}(y_1) &= E[(y_1 - a_1)^2] = \\ &= E[(\mu_1 + \varepsilon_1 - a_1)^2] = \text{var}(\mu_1) + E[\varepsilon_1^2] \\ &= p_1 \quad \sigma_{\varepsilon_1}^2 \end{aligned}$$

$$\text{var}(y_2) = E[(\mu_1 + \eta_1 + \varepsilon_1 - a_1)^2] = \text{var}(\mu_1) + E[\varepsilon_1^2] + E[\eta_1^2]$$

$$- \text{var}(y_n) = p_1 \cdot (n-1) \sigma_\eta^2 + \sigma_\epsilon^2$$

covariâncias

$$\begin{aligned} - \text{cov}(y_1, y_2) &= E[(y_1 - a_1)(y_2 - a_1)] \\ &= E[(\mu_1 + \epsilon_1 - a_1)(\mu_1 + \eta_1 + \epsilon_2 - a_1)] = \\ &= E[((\mu_1 - a_1) + \epsilon_1)((\mu_1 - a_1) + \eta_1 + \epsilon_2)] = \\ &= E[(\mu_1 - a_1)^2] = p_1 \end{aligned}$$

logo:

$$\Sigma_{yy} = \begin{bmatrix} p_1 + \sigma_\epsilon^2 & p_1 & \dots & p_1 \\ p_1 & p_1 + \sigma_\eta^2 + \sigma_\epsilon^2 & & \\ \vdots & p_1 + \sigma_\eta^2 & \ddots & \\ p_1 & p_1 + 2\sigma_\eta^2 & & p_1 + (n-1)\sigma_\eta^2 + \sigma_\epsilon^2 \end{bmatrix}$$

$$= \mathbb{1}\mathbb{1}'p_1 + \Sigma_{ij} \quad \text{onde} \quad \Sigma_{ij} = \begin{cases} (i-1)\sigma_\eta^2 & i < j \\ \sigma_\epsilon^2 + (i-j)\sigma_\eta^2 & i = j \\ (j-1)\sigma_\eta^2 & i > j \end{cases}$$

(diagonal)

$$\text{cov}(y_2, y_3) = E[(y_2 - a_1)(y_3 - a_1)]$$

$$\begin{aligned} &= E[(\mu_1 + \eta_1 + \epsilon_2 - a_1)(\mu_1 + \eta_1 + \eta_2 + \epsilon_3 - a_1)] \\ &= E[(\mu_1 - a_1)^2] + E[\eta_1^2] \\ &= p_1 + \sigma_\eta^2 \end{aligned}$$

obs. se cresce com o número de observações. do ponto de vista operacional é um problema.

→ Para μ

$$\mu_2 = \mu_1 + \eta_1$$

$$\mu_3 = \mu_2 + \eta_2 = \mu_1 + \eta_1 + \eta_2$$

⋮

$$\mu_n = \mu_1 + (\eta_1 + \eta_2 + \dots + \eta_{n-1})$$

$$\text{seja } \mu = (\mu_1, \mu_2, \dots, \mu_n)'$$

$$E[\mu] = \begin{pmatrix} a_1 \\ \vdots \\ a_1 \end{pmatrix} = \mathbb{1}a_1$$

$$\text{var}(\mu) = E[(\mu - E[\mu])(\mu - E[\mu])'] = \Sigma_{\mu}$$

$$\Sigma_{\mu\mu} = \begin{bmatrix} \text{var}(\mu_1) & \text{cov}(\mu_1, \mu_2) & \dots & \text{cov}(\mu_1, \mu_n) \\ \text{cov}(\mu_2, \mu_1) & \text{var}(\mu_2) & & \vdots \\ \vdots & & \ddots & \\ \text{cov}(\mu_n, \mu_1) & & & \text{var}(\mu_n) \end{bmatrix}$$

→ variâncias:

$$\text{var}(\mu_1) = E[(\mu_1 - a_1)^2] = p_1$$

$$\text{var}(\mu_2) = E[(\mu_2 - a_2)^2] =$$

$$= E[(\mu_1 + \eta_1 - a_1)^2]$$

$$= E[(\mu_1 - a_1)^2] + E[\eta_1^2] = p_1 + \sigma_{\eta}^2$$

$$\text{obs: } \mu_t = \mu_1 + \sum_{i=1}^{t-1} \eta_i$$

$$\begin{aligned} & (\mu_1 - a_1)^2 + 2(\mu_1 - a_1) \sum_{i=1}^{t-1} \eta_i \\ & + \left(\sum_{i=1}^{t-1} \eta_i \right)^2 \\ & \text{cov}(\eta_i, \eta_j) = 0 \quad p(i \neq j) \end{aligned}$$

$$\therefore \text{var}(\mu_t) = E[(\mu_1 + \sum_{i=1}^{t-1} \eta_i - a_1)^2] =$$

$$= E[(\mu_1 - a_1)^2] + \sum_{i=1}^{t-1} E[\eta_i^2] =$$

$$= p_1 + \sum_{i=1}^{t-1} \sigma_{\eta}^2$$

ou seja:

$$\text{var}(\mu_t) = p_1 + (t-1) \sigma_{\eta}^2 \quad t = 1, 2, \dots, n$$

→ covariâncias ⇒ dependerá da posição relativa entre i e j

$$\text{cov}(\mu_1, \mu_2) = E[(\mu_1 - a_1)(\mu_2 - a_2)]$$

$$= E[(\mu_1 - a_1)(\mu_1 + \eta_1 - a_1)] =$$

$$= E[(\mu_1 - a_1)^2] + E[(\mu_1 - a_1)(\eta_1)] = p_1$$

$$\text{cov}(\mu_1, \mu_3) = E[(\mu_1 - a_1)(\mu_3 - a_3)]$$

$$= E[(\mu_1 - a_1)(\mu_1 + \eta_1 + \eta_2 - a_1)] =$$

$$= E[(\mu_1 - a_1)^2] + E[(\mu_1 - a_1)\eta_1] + E[(\mu_1 - a_1)\eta_2]$$

$$= p_1$$

$$\text{cov}(\mu_1, \mu_1) = p_1$$

$$\begin{aligned}
- \text{cov}(\mu_2, \mu_3) &= E[(\mu_2 - a_1)(\mu_3 - a_1)] \\
&= E[(\mu_1 + \eta_1 - a_1)(\mu_1 + \eta_1 + \eta_2 - a_1)] \\
&= E[(\mu_1 - a_1)^2 + \eta_1((\mu_1 - a_1)^2 + \eta_1 + \eta_2)] = \\
&= E[(\mu_1 - a_1)^2] + E[\eta_1(\mu_1 - a_1)^2] + E[\eta_2(\mu_1 - a_1)^2] + \\
&\quad + E[\eta_1(\mu_1 - a_1)^2] + E[\underbrace{\eta_1 \eta_1}_{\sigma_\eta^2}] + E[\eta_1 \eta_2] \\
&= p_1 + \sigma_\eta^2
\end{aligned}$$

$$- \text{cov}(\mu_2, \mu_t) = p_1 + \sigma_\eta^2 \quad \text{para } t > 2$$

- Generalizando: $j > i$

$$\mu_i = \mu_1 + \sum_{r=1}^{i-1} \eta_r$$

$$\mu_j = \mu_1 + \sum_{s=1}^{j-1} \eta_s$$

$$\begin{aligned}
\text{cov}(\mu_i, \mu_j) &= E[(\mu_1 + \sum_{r=1}^{i-1} \eta_r - a_1)(\mu_1 + \sum_{s=1}^{j-1} \eta_s - a_1)] = \\
&= E[(\mu_1 - a_1)^2] + E[\sum_{r=1}^{i-1} \eta_r \cdot \sum_{s=1}^{j-1} \eta_s] = \\
&= p_1 + E[\dots]
\end{aligned}$$

$$E[\sum_{r=1}^{i-1} \eta_r + \sum_{s=1}^{j-1} \eta_s] =$$

$$= E[(\eta_1 + \eta_2 + \dots + \eta_{i-1})(\eta_1 + \eta_2 + \dots + \eta_{j-1})]$$

(se $i < j \Rightarrow$ termos $(i-1)$ termos $E[\eta^2]$)

$$= (i-1) \sigma_\eta^2$$

se $i > j$

$$= (j-1) \sigma_\eta^2$$

$$\begin{aligned}
\text{Logo: } \text{cov}(\mu_i, \mu_j) &= \begin{cases} p_1 + (i-1) \sigma_\eta^2 & \text{se } i < j \\ p_1 + (j-1) \sigma_\eta^2 & \text{se } i > j \end{cases} \\
&\quad (\text{e } p_1 \text{ se } i=j)
\end{aligned}$$

logo:

$$\Sigma_{\mu\mu} = \Sigma_{ij} \quad \text{onde} \quad \Sigma_{ij} = \begin{cases} p_i + (i-1)\sigma_\eta^2 & \text{se } i \leq j \\ p_i + (i-1)\sigma_\eta^2 & \text{se } i = j \\ p_i + (j-1)\sigma_\eta^2 & \text{se } i > j \end{cases}$$

→ Para y e μ conjuntamente:

$$\underbrace{\text{cov}(y, \mu)}_{\Sigma_{y\mu}} = E[(y - \mathbb{1}a_1)(\mu - \mathbb{1}a_1)']$$

cada termo individualmente:

$$\text{cov}(y_i, \mu_j) = E[(y_i - a_i)(\mu_j - a_j)]$$

$$y_i = \mu_i + \sum_{n=i}^{i-1} \eta_n + \varepsilon_i$$

$$\mu_j = \mu_i + \sum_{s=i}^{j-1} \eta_s$$

$$E[(y_i - a_i)(\mu_j - a_j)] = E\left[\left(\mu_i - a_i + \sum_{n=i}^{i-1} \eta_n + \varepsilon_i\right)\left(\mu_i - a_i + \sum_{s=i}^{j-1} \eta_s\right)\right]$$

$$= E[(\mu_i - a_i)^2] + E\left[\sum_{n=i}^{i-1} \eta_n \cdot \sum_{s=i}^{j-1} \eta_s\right]$$

$$= p_i + \underbrace{\text{já vimos que}}_{\begin{cases} (i-1)\sigma_\eta^2 & \text{se } i \leq j \\ (j-1)\sigma_\eta^2 & \text{se } i > j \end{cases}}$$

$$\text{Logo: } \Sigma_{y\mu} = \Sigma_{ij} \quad \text{onde} \quad \Sigma_{ij} = \begin{cases} p_i + (i-1)\sigma_\eta^2 & \text{se } i \leq j \\ p_i + (j-1)\sigma_\eta^2 & \text{se } i > j \end{cases}$$

Assim

Podemos caracterizar probabilisticamente os vetores aleatórios y e μ através do seguinte resultado:

$$\begin{pmatrix} \mu \\ y \end{pmatrix} \sim N \left[\begin{pmatrix} 1a_1 \\ 1a_1 \end{pmatrix}, \begin{pmatrix} \Sigma_{\mu\mu} & \Sigma_{\mu y} \\ \Sigma_{y\mu} & \Sigma_{yy} \end{pmatrix} \right]$$

onde $1a_1 = (a_1, \dots, a_1)' \quad n \times 1$

$$\Sigma_{\mu\mu} = \Sigma_{\mu\mu}^{ij} = \begin{cases} (i-1)\sigma_\eta^2 + p_1 & \text{se } i \leq j \\ (j-1)\sigma_\eta^2 + p_1 & \text{se } j > i \end{cases}$$

$$\Sigma_{yy} = \Sigma_{yy}^{ij} = \begin{cases} (i-1)\sigma_\eta^2 + p_1 & i < j \\ (i-1)\sigma_\eta^2 + p_1 + \sigma_\epsilon^2 & i = j \\ (j-1)\sigma_\eta^2 + p_1 & i > j \end{cases}$$

$$\Sigma_{\mu y} = \Sigma_{\mu y}^{ij} = \begin{cases} (i-1)\sigma_\eta^2 + p_1 & \text{se } i \leq j \\ (j-1)\sigma_\eta^2 + p_1 & \text{se } j > i \end{cases} = \Sigma_{\mu\mu}$$

Queremos estimar α dada a informação da série observada y . Assim, devemos obter a densidade condicional:

$$p(\alpha | y)$$

A partir dela, calculamos $E[\alpha | y]$, $\text{var}[\alpha | y]$ etc.
e assim caracterizar probabilisticamente α condicional a y .
Por exemplo:

É natural que adotemos

$$\hat{\alpha} = E[\alpha | y]$$

Para avançarmos, faremos uso do seguinte resultado
p/ vetores de variáveis aleatórias com dist Normal multivariada

Teorema: $\begin{pmatrix} X \\ Y \end{pmatrix} \sim N \left[\begin{pmatrix} \mu_x \\ \mu_y \end{pmatrix}, \begin{pmatrix} \Sigma_{xx} & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_{yy} \end{pmatrix} \right], \Sigma_{xy} = \Sigma_{yx}'$

então: $f(X|Y=y) \sim N(E[X|Y=y], \text{var}[X|Y=y])$

$$E[X|Y=y] = \mu_x + \Sigma_{xy} \Sigma_{yy}^{-1} (y - \mu_y)$$

$$\text{var}[X|Y=y] = \Sigma_{xx} - \Sigma_{xy} \Sigma_{yy}^{-1} \Sigma_{yx}$$

Fazendo: $\underline{x} = \underline{\mu}$ e $\underline{y} = y$, segue que:

$f(\underline{\mu} | Y = y) \sim N(E[\underline{\mu} | Y = y], \text{var}[\underline{\mu} | Y = y])$ onde

$$\begin{aligned} E[\underline{\mu} | Y = y] &= E[\underline{\mu}] + \Sigma_{\mu y} \Sigma_{yy}^{-1} (y - a, \underline{1}) \\ &= \underline{1}a_1 + \Sigma_{\mu y} \Sigma_{yy}^{-1} (y - a, \underline{1}) \\ &= \underline{1}a_1 + \Sigma_0 \end{aligned}$$

Observações

Na prática, esta forma de obter estimativa p/ o vetor de estado $\underline{\mu}$ não é recomendável pois

i. As matrizes Σ_{yy} e $\Sigma_{\mu y}$ possuem dimensões $n \times n$ onde n é o tamanho da amostra.

O esforço computacional de estimar será proporcional a n .

$$E[\underline{\alpha} | Y = y] = \begin{bmatrix} E[\alpha_1 | Y_n] \\ \vdots \\ E[\alpha_n | Y_n] \end{bmatrix} \Rightarrow \text{a cada instante } t=1, \dots, n \text{ as estimativas são calculadas utilizando toda a informação da amostra pois}$$
$$Y_n = (y_1, y_2, \dots, y_n)$$

ii. Se a série de observações vai crescendo no tempo, ou seja, a partir de n novas obs. são sendo adicionadas, as matrizes Σ_{yy} e $\Sigma_{\mu y}$ crescerão

copiar

23/03.

Passo da previsão no FK

(a) $y_t = z_t' \alpha_t + \varepsilon_t$, $\varepsilon_t \sim N(0, H_t)$

(b) $\alpha_{t+1} = T_t \alpha_t + R_t \eta_t$, $\eta_t \sim N(0, Q_t)$

$$E[\varepsilon_t' \eta_s] = 0 \quad \forall s, t$$

$$\alpha_1 \sim N(a_1, p_1)$$

$$E[\alpha_1, \varepsilon_t] = E[\alpha_1, \eta_t] = 0 \quad \forall t$$

Sejam:

valor esperado do vetor de estado no período $t+1$ dada observações até t

$$a_{t+1} = E[\alpha_{t+1} | \underline{y}_t]$$

onde $\underline{y}_t = (y_1, y_2, \dots, y_{t-1}, y_t)$

$$p_{t+1} = \text{var}[\alpha_{t+1} | \underline{y}_t]$$

De (b), segue que:

$$\bullet E[\alpha_{t+1} | \underline{y}_t] = E[T_t \alpha_t + R_t \eta_t | \underline{y}_t]$$

$$= T_t E[\alpha_t | \underline{y}_t] = T_t a_{t|t}$$

$$\Rightarrow \boxed{a_{t+1} = T_t a_{t|t}}$$

valor esperado

↳ Notação do Koopman equivale a $T_t E[\alpha_t | \underline{y}_t]$

obs: Se no modelo $\alpha_{t+1} = T_t \alpha_t + c_t + R_t \eta_t \Rightarrow a_{t+1} = T_t a_{t|t} + c_t$

$$\bullet \underbrace{\text{var}[\alpha_{t+1} | \underline{y}_t]}_{p_{t+1}} = E \left[\underbrace{(\alpha_{t+1} - E[\alpha_{t+1} | \underline{y}_t])}_{\text{imp}} \underbrace{(\alpha_{t+1} - E[\alpha_{t+1} | \underline{y}_t])'}_{a_{t+1}} \middle| \underline{y}_t \right]$$

onde $\alpha_{t+1} = T_t \alpha_t + R_t \eta_t$

$$\Rightarrow \alpha_{t+1} - a_{t+1} = T_t (\alpha_t - a_{t|t}) + R_t \eta_t$$

$$a_{t+1} = T_t a_{t|t}$$

$$\therefore p_{t+1} = E \left[(T_t (\alpha_t - a_{t|t}) + R_t \eta_t) (T_t (\alpha_t - a_{t|t}) + R_t \eta_t)' \middle| \underline{y}_t \right]$$

$$= E \left[(T_t (\alpha_t - a_{t|t}) + R_t \eta_t) ((\alpha_t - a_{t|t})' T_t' + \eta_t' R_t') \middle| \underline{y}_t \right]$$

$$p_{t+1} = E_t \left[T_t (\alpha_t - a_{t|t}) (\alpha_t - a_{t|t})' T_t' \right] + E_t \left[T_t (\alpha_t - a_t) \eta_t' R_t' \right] + \\ + E_t \left[R_t \eta_t (\alpha_t - a_{t|t})' T_t' \right] + E_t \left[R_t \eta_t \eta_t' R_t' \right]$$

$$\text{onde } E_t[\cdot] = E[(\cdot) | \underline{y}_t]$$

Envolvendo a equação (b) por substit. recursiva, temos:

$$\alpha_{t+1} = T_t \alpha_t + R_t \eta_t$$

$$\alpha_2 = T_1 \alpha_1 + R_1 \eta_1$$

$$\alpha_3 = T_2 \alpha_2 + R_2 \eta_2 = T_2 (T_1 \alpha_1 + R_1 \eta_1) + R_2 \eta_2$$

$$\alpha_4 = T_3 \alpha_3 + R_3 \eta_3 = T_3 (T_2 (T_1 \alpha_1 + R_1 \eta_1) + R_2 \eta_2) + R_3 \eta_3$$

$$= \underbrace{T_3 T_2 T_1}_{\prod_{i=1}^3 T_i} \alpha_1 + T_3 T_2 R_1 \eta_1 + R_3 \eta_3$$

entender

$$\Rightarrow \alpha_{t+1} = \sum_{j=1}^{t-1} \left[\prod_{i=0}^{j-1} T_{t-i} \right] R_{t-j} \eta_{t-j} + R_t \eta_t \quad (b')$$

Seja

$$\begin{aligned} A_t &= E_t \left[T_t (\alpha_t - a_t) (\alpha_t - a_t)' T_t' \right] = \\ &= T_t E_t \left[(\alpha_t - a_t) (\alpha_t - a_t)' \right] T_t' = \\ &= T_t P_{t|t} T_t' \end{aligned}$$

$$\begin{aligned} B_t &= E_t \left[T_t (\alpha_t - a_t) \eta_t' R_t' \right] = \\ &= T_t E_t \left[(\alpha_t - a_t) \eta_t' \right] R_t' = \\ &= T_t E_t \left[\alpha_t \eta_t' \right] R_t' - T_t a_t E_t \left[\eta_t' \right] R_t' \\ &= T_t E_t \left[\alpha_t \eta_t' \right] R_t' \end{aligned}$$

Mas: $E_t[\alpha_t \eta_t'] \Leftrightarrow E_{t+1}[\alpha_{t+1} \eta_{t+1}']$

Substituindo α_{t+1} encontrado em (5), temos:

$$E_{t+1}[\alpha_{t+1} \eta_{t+1}'] = E_{t+1} \left[\left(\sum_{j=1}^{t-1} \left[\prod_{i=0}^{j-1} T_{t-i} \right] R_{t-j} \eta_{t-j} + R_t \eta_t \right) \eta_{t+1}' \right] =$$

$$= \left(\sum_{j=1}^{t-1} \left[\prod_{i=0}^{j-1} T_{t-i} \right] R_{t-j} E_{t+1}[\eta_{t-j} \eta_{t+1}'] \right) + R_t E_{t+1}[\eta_t \eta_{t+1}']$$

mas:

$$\rightarrow E_{t+1}[\eta_{t-j} \eta_{t+1}'] = E[\eta_{t-j} \eta_{t+1}'] \quad j=1, 2, \dots, t-1$$

$$= 0 \text{ pois, por hipótese, } E[\eta_t \eta_s'] = 0 \quad \forall t \neq s.$$

$$\rightarrow E_{t+1}[\eta_t \eta_{t+1}'] = E[\eta_t \eta_{t+1}'] = 0 \text{ de forma análoga.}$$

Logo: $B_t \equiv 0 \quad \forall t.$

$$C_t = E_t[R_t \eta_t (\alpha_t - a_{t|x}) T_t']$$

$$= \left(\underbrace{R_t E_t[\eta_t \alpha_t']}_0 - \underbrace{R_t E_t[\eta_t]}_0 a_{t|x}' \right) T_t' = 0.$$

$$D_t = E_t[R_t \eta_t \eta_t' R_t'] = R_t E_t[\eta_t \eta_t'] R_t'$$

$$= R_t E[\eta_t \eta_t'] R_t'$$

$$= R_t Q_t R_t'$$

Portanto, segue que:

$$P_{t+1} = \text{var}[\alpha_{t+1} | \underline{y}_t] = T_t P_{t|x} T_t' + R_t Q_t R_t'$$



$$(I) y_t = z_t \alpha_t + \epsilon_t \quad \epsilon_t \sim N(0, H_t)$$

$$(II) \alpha_{t+1} = T_t \alpha_t + R_t \eta_t \quad \eta_t \sim N(0, Q_t)$$

Da aula anterior:

→ passo da previsão:

$$a_{t+1} = E[\alpha_{t+1} | y_t] = T_t a_{t|t} \quad \text{onde } a_{t|t} = E[\alpha_t | y_t]$$

$$P_{t+1} = \text{var}[\alpha_{t+1} | y_t] \\ = T_t P_{t|t} T_t' + P_t Q_t R_t'$$

Queremos agora:

$$\begin{cases} a_{t|t} = E[\alpha_t | y_t] \\ P_{t|t} = \text{var}[\alpha_t | y_t] \Rightarrow \text{matriz de varian\c{c}as} \end{cases}$$

ainda da aula passada:

$$(1) \begin{pmatrix} x \\ y \\ z \end{pmatrix} \sim N \left[\begin{pmatrix} \mu_x \\ \mu_y \\ \mu_z \end{pmatrix}, \begin{pmatrix} \Sigma_{xx} & \Sigma_{xy} & \Sigma_{xz} \\ \Sigma_{yx} & \Sigma_{yy} & \Sigma_{yz} \\ \Sigma_{zx} & \Sigma_{zy} & \Sigma_{zz} \end{pmatrix} \right]$$

Supondo $\mu_z = 0$ e $\Sigma_{zy} = 0$ ($\Sigma_{yz} = 0$), temos:

$$E[x | y=y, z=z] = \mu_{x|y} + \Sigma_{xz} \Sigma_{zz}^{-1} z$$

$$\text{var}[x | y=y, z=z] = \Sigma_{xx} - \Sigma_{xz} \Sigma_{zz}^{-1} \Sigma_{zx}$$

(2) Se x e y são dois vetores aleatórios e $g: \mathbb{R}^p \rightarrow \mathbb{R}^p$ (bijetivo), então $F_{x|y} = F_{x|g(y)} \Rightarrow E[x | y=y] = E[x | g(y)=g(y)]$

Calculamos $a_{t|t}$ e $P_{t|t}$

$$\bullet a_{t|t} = E[\alpha_t | y_t] \xrightarrow{\text{decompondo}} \\ = E[\alpha_t | y_{t-1}, y_t] =$$

$$= E[\alpha_t | y_{t-1}, v_t] \quad \text{onde } v_t = y_t - E[y_t | y_{t-1}]$$

erro de previsão + passo a frente (inovação)

$a_{t|t}$

Da q. (I) do modelo:

$$\begin{aligned} E[y_t | \underline{y}_{t-1}] &= E[z_t \alpha_t + \varepsilon_t | \underline{y}_{t-1}] \\ &= z_t E[\alpha_t | \underline{y}_{t-1}] \\ &= z_t a_t \end{aligned}$$

mostrar
que pode
usar
o inv.
de y_t

usando
o do
resultado 2).

Logo: $v_t = y_t - z_t a_t \Rightarrow$ conteúdo informacional de y_t
nas ε é modificado se usarmos v_t
podemos fazer isso pois v_t é transversal

$$\Rightarrow \left[\begin{aligned} a_{t|t} &= E[\alpha_t | \underline{y}_t] = \\ &= E[\alpha_t | \underline{y}_{t-1}, v_t] \end{aligned} \right]$$

usando resultado (1) e fazendo $x = \alpha_t$, $y = \underline{y}_{t-1}$, $z = v_t$

- Primeiro precisamos provar que $\mu_z = \mu_{v_t} = 0$
(p/ usar resultado) e $\Sigma_{zy} = \Sigma_{v_t \underline{y}_{t-1}} = 0$

$$* \mu_z = E[z] = 0$$

$$\therefore E[v_t] = 0$$

$$\text{mas } E[v_t] = E[E[v_t | \underline{y}_{t-1}]]$$

$$\begin{aligned} \text{e } E[v_t | \underline{y}_{t-1}] &= E[y_t - z_t a_t | \underline{y}_{t-1}] \\ &= E[y_t | \underline{y}_{t-1}] - z_t a_t \\ &\stackrel{\text{do modelo}}{=} z_t a_t - z_t a_t = 0. \end{aligned}$$

$$\therefore E[v_t] = E[0] = 0. \quad \text{ok!}$$

$$* \Sigma_{yz} = 0$$

$$\therefore \Sigma_{\underline{y}_{t-1} v_t} = \text{cov}(\underline{y}_{t-1}, v_t) = 0$$

$$\begin{aligned} \text{mas } \text{cov}(\underline{y}_{t-1}, v_t) &= E[(\underline{y}_{t-1} - E[\underline{y}_{t-1}])(v_t - E[v_t])'] \\ &= E[\underline{y}_{t-1} \cdot v_t'] - E[\underline{y}_{t-1}] \cdot E[v_t'] \\ &= E[\underline{y}_{t-1} \cdot v_t'] \end{aligned}$$

$$\underline{y}_{t-1} = \begin{bmatrix} y_{t-1} \\ y_{t-2} \\ \vdots \\ y_1 \end{bmatrix}$$

\Downarrow
matriz cujos elementos são
 $\{E[y_{t-g} v_t']\}_{g=1,2,\dots}$

$$E[y_{t-j} v_t'] = E[E[y_{t-j} v_t' | \underline{y}_{t-1}]]$$

(\downarrow v_t passado, pode sair de $E[\cdot]$)

$$E[y_{t-j} v_t' | \underline{y}_{t-1}] = y_{t-j} E[v_t' | \underline{y}_{t-1}] = 0.$$

$$\Rightarrow E[y_{t-1} v_t'] = 0 \quad \text{ok!}$$

Portanto, podemos usar o resultado e escrever:

$$E[\alpha_t | \underline{y}_t] = E[\alpha_t | \underline{y}_{t-1}] + \text{cov}[\alpha_t, v_t] (\text{var}[v_t])^{-1} v_t$$

a_t

(já sabemos quem é do passo da previsão em $t-1$)

\downarrow
Precisamos calcular estas componentes da equação.

- Calculando $\text{var}[v_t]$

$$\text{var}[v_t] = E[(v_t - E[v_t])(v_t - E[v_t])']]$$

$$= E[v_t v_t']$$

$$= E[E[v_t v_t' | \underline{y}_{t-1}]]$$

$$\text{Sabemos que } v_t = y_t - z_t a_t$$

$$= z_t \alpha_t + \varepsilon_t - z_t a_t$$

$$= z_t (\alpha_t - a_t) + \varepsilon_t$$

$$\Rightarrow E[v_t v_t' | \underline{y}_{t-1}] =$$

$$= E[(z_t (\alpha_t - a_t) + \varepsilon_t) (z_t (\alpha_t - a_t) + \varepsilon_t)' | \underline{y}_{t-1}]$$

$$= E[z_t (\alpha_t - a_t) (\alpha_t - a_t)' z_t' | \underline{y}_{t-1}] +$$

$$+ E[z_t (\alpha_t - a_t) \varepsilon_t' | \underline{y}_{t-1}] + E[\varepsilon_t (\alpha_t - a_t)' z_t' | \underline{y}_{t-1}]$$

$$+ E[\varepsilon_t \varepsilon_t' | \underline{y}_{t-1}]$$

$= 0$

$$z_t E[\alpha_t \varepsilon_t' | \underline{y}_{t-1}] - z_t a_t E[\varepsilon_t' | \underline{y}_{t-1}]$$

funções de α_t e η_{t-j} $\propto 0$

Escrever a expressão no lado da AHT

Calcular componente

$$\begin{aligned} E[v_t v_t' | y_{t-1}] &= z_t \underbrace{E[(\alpha_t - a_t)(\alpha_t - a_t)' | y_{t-1}]}_{P_t} z_t' + \underbrace{E[\varepsilon_t \varepsilon_t' | y_{t-1}]}_{H_t} \\ &= z_t P_t z_t' + H_t \end{aligned}$$

Logo:

$$\boxed{\text{var}(v_t') = E[v_t v_t'] = z_t P_t z_t' + H_t \triangleq F_t}$$

• Calculando $\text{cov}(\alpha_t, v_t)$

na definição:

$$\begin{aligned} \text{cov}(\alpha_t, v_t) &= E[(\alpha_t - E[\alpha_t])(v_t - E[v_t])'] \\ &= E[\alpha_t v_t'] - E[\alpha_t] E[v_t] \\ &= E[\alpha_t v_t'] \end{aligned}$$

$$= E[E(\alpha_t v_t' | y_{t-1})]$$

$$\begin{aligned} &\downarrow \\ \alpha_t v_t' &= \alpha_t (y_t' - a_t' z_t) \\ &= \alpha_t' ((\alpha_t - a_t) z_t' + \varepsilon_t') \end{aligned}$$

$$\begin{aligned} \Rightarrow E[\alpha_t v_t' | y_{t-1}] &= E[(\alpha_t (\alpha_t - a_t)' z_t' + \varepsilon_t') | y_{t-1}] = \\ &= E[\alpha_t (\alpha_t - a_t)' z_t' | y_{t-1}] + E[\varepsilon_t' | y_{t-1}] \end{aligned}$$

truque: subtrai a_t

$$\begin{aligned} &= E[(\alpha_t - a_t)(\alpha_t - a_t)' z_t' | y_{t-1}] \\ &= \underbrace{E[(\alpha_t - a_t)(\alpha_t - a_t)' | y_{t-1}]}_{P_t} z_t' \\ &= P_t z_t' \end{aligned}$$

$$\boxed{\text{cov}(\alpha_t, v_t) = E[P_t z_t'] = P_t z_t' = m_t}$$

usando os resultados p/ $\text{var}(y_t')$ e $\text{cov}(\alpha_t, v_t)$, podemos escrever:

$$E[\alpha_t | \tilde{y}_t] = E[\alpha_t | \tilde{y}_{t-1}] + \text{cov}(\alpha_t, v_t) (\text{var}(v_t))^{-1} v_t$$

Resultados
pt $a_{t|t}$

$$a_{t|t} = E[\alpha_t | \tilde{y}_t] = a_t + m_t f_t^{-1} v_t$$

onde:

$$\begin{cases} m_t = P_t z_t' \\ f_t = z_t P_t z_t' + H_t \\ v_t = y_t - z_t a_t \end{cases}$$

• $P_{t|t} = \text{var}[\alpha_t | \tilde{y}_t]$

$$= \text{var}[\alpha_t | \tilde{y}_{t-1}, y_t] =$$

$$= \text{var}[\alpha_t | \tilde{y}_{t-1}, v_t]$$

El t

que
podemos
usar v_t e
resultados
pt var

↳ podemos usar v_t ao invés de y_t
= podemos usar resultados (i) para var

Novamente fazendo $x = \alpha_t$, $y = y_{t+1}$ e $z = v_t$

$$\text{var}[\alpha_t | \tilde{y}_t] = \text{var}[\alpha_t | \tilde{y}_{t-1}, v_t]$$

$$= \underbrace{\text{var}[\alpha_t | \tilde{y}_{t-1}]}_{P_t} - \underbrace{\text{cov}[\alpha_t, v_t]}_{m_t} \underbrace{(\text{var}(v_t))^{-1}}_{f_t^{-1}} \underbrace{\text{cov}(\alpha_t, v_t)'}_{m_t'}$$

$$= P_t - m_t f_t^{-1} m_t'$$

$$= P_t - P_t z_t' f_t^{-1} (P_t z_t)'$$

Resultados
pt $P_{t|t}$

$$\therefore \boxed{P_{t|t} = \text{var}[\alpha_t | \tilde{y}_t] = P_t - P_t z_t' f_t^{-1} z_t P_t'}$$

→

RESUMINDO

Equações do FK

Previsas: $a_{t+1} = T_t a_{t|t}$

$$P_{t+1} = T_t P_{t|t} T_t' + R_t \Phi_t R_t'$$

Atualizações: $a_{t|t} = a_t + M_t F_t^{-1} v_t$
 $P_{t|t} = P_t - P_t Z_t' F_t^{-1} Z_t P_t$

$\downarrow \quad \quad \downarrow \quad \quad \downarrow$
atualizada prevista começa

onde $v_t = y_t - Z_t a_t$

$$F_t = Z_t P_t Z_t' + H_t$$

$$M_t = P_t Z_t'$$

→ Na prática:

Temos uma previsão sequencial

$\alpha_1 \sim N(a_1, P_1)$: distribuição a priori inicial conhecida
É o passo de previsão inicial

Começamos na atualização usando y_1 (1ª observação)

$$\begin{cases} a_{t|t} = a_1 + M_1 F_1^{-1} (v_1) \end{cases} \text{ usa } y_1$$

$$\begin{cases} P_{t|t} = P_1 + \dots \end{cases}$$

Com $a_{t|t}$ e $P_{t|t}$, jogamos nas fórmulas da previsão

— " —

Podemos resolver as fórmulas em função apenas de a_{t+1}/a_t e P_{t+1}/P_t se substituirmos $a_{t|t}$ e $P_{t|t}$ das equações de atualização nas de previsão.

Teremos FK 2 em 1

$$\begin{aligned} a_{t+1} &= T_t (a_t + M_t F_t^{-1} v_t) \\ &= T_t a_t + \underbrace{T_t M_t F_t^{-1}}_{K_t} v_t \end{aligned}$$

onde K_t é o ganho de Kalman.

$$\boxed{a_{t+1} = T_t a_t + K_t v_t}$$

observações entram aqui

$$\begin{aligned} \bullet \quad P_{t+1} &= T_t \left(P_t - \underbrace{P_t z_t' F_t'}_{M_t} \underbrace{z_t P_t}_{M_t'} \right) T_t' + R_t Q_t R_t' \\ &= T_t P_t \left(I - \cancel{M_t F_t' M_t'} \right) T_t' + R_t Q_t R_t' \end{aligned}$$

diminui

$$\boxed{P_{t+1} = T_t P_t L_t' + R_t Q_t R_t'} \quad \text{onde } L_t = I - K_t z_t$$



Não depende das observações.

Dependendo do caso, converge p/ um valor (steady-state). \bar{P}



Passo da suavização

$y = (y_1' \ y_2' \ \dots \ y_n')' = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \sim (n \times p) \times 1$

→ cada elemento y_i é um vetor $p \times 1$

↓
 y_n

Queremos: $\hat{\alpha}_t = E[\alpha_t | y] \quad t = 1, 2, \dots, n$

(antes α_t)

$V_t = \text{var}[\alpha_t | y]$

(antes P_t)

→ antes, vamos até t . Agora, até n .

→ cálculo
do var
da seq.
de suavizados

$\hat{\alpha}_t = E[\alpha_t | y] = E[\alpha_t | y_{t-1}, v_t, v_{t+1}, \dots, v_n]$

No vetor multivariado, do resultado, da aula passada:

$$\begin{cases} x = \alpha_t \\ y = y_{t-1} \\ z = (v_t, v_{t+1}, \dots, v_n)' \end{cases}$$

$$\therefore \hat{\alpha}_t = E[\alpha_t | y] = \underbrace{E[\alpha_t | y_{t-1}]}_{\alpha_t \text{ (do FK)}} + \underbrace{\text{cov}(\alpha_t, (v_t, v_{t+1}, \dots, v_n)')}_{\left(\text{var}(v_t, \dots, v_n) \right)^{-1} \cdot (v_t, v_{t+1}, \dots, v_n)'}$$

• Cálculo de $\text{var}(v_t, v_{t+1}, \dots, v_n)$

Mostraremos que v_i 's são independentes

Faremos isso mostrando que $p(v_1, v_2, \dots, v_n) = \prod_{i=1}^n p(v_i)$

Para y_i , podemos escrever:

$$p(y_1, y_2, \dots, y_n) = p(y_n, \underbrace{y_{n-1}, \dots, y_2, y_1}_{y_{n-1}})$$

$$= p(y_n | y_{n-1}) p(y_{n-1}) =$$

$$= p(y_n | y_{n-1}) \cdot p(y_{n-1} | y_{n-2}) =$$

$$= p(y_n | y_{n-1}) \cdot p(y_{n-1} | y_{n-2}) \cdot p(y_{n-2}) \dots =$$

$$= p(y_1) \prod_{t=2}^n p(y_t | y_{t-1}) \quad \text{onde } p(y_t | y_{t-1}) \sim N(z_t \alpha_t, F_t)$$

mas queremos $p(v_1, v_2, \dots, v_n)$

e sabemos que $v_t = y_t - z_t a_t$

Resultado auxiliar:

Se x é vetor aleatório $n \times 1$

e $y = g(x)$, g diferenciável e com inversa.

$$f_y(y) = f_x(g^{-1}(y)) |J(y)| \quad \text{onde } J(y) = \begin{pmatrix} \partial y_1 / \partial x_1 & \dots & \partial y_1 / \partial x_n \\ \vdots & & \vdots \\ \partial y_n / \partial x_1 & \dots & \partial y_n / \partial x_n \end{pmatrix}$$

$|J(y)|$ é o determinante

fazendo $x = (y_1, y_2, \dots, y_n)'$

$$y = (v_1, v_2, \dots, v_n)$$

$$\Rightarrow p(v_1, v_2, \dots, v_n) = p(y_1, y_2, \dots, y_n) \big|_{y_i = v_i + z_i a_i} |J|$$

$$\text{onde } \frac{\partial y_j}{\partial v_i} = \begin{cases} 1 & i=j \\ 0 & i \neq j \end{cases} \Rightarrow J = \begin{pmatrix} 1 & & 0 \\ & \ddots & \\ 0 & & 1 \end{pmatrix} \Rightarrow |J| = 1$$

$$\text{Logo: } p(v_1, v_2, \dots, v_n) = p(y_1, y_2, \dots, y_n) \big|_{y_t = v_t + z_t a_t}$$

$$= p(y_1) \prod_{t=2}^n p(y_t | y_{t-1}) \big|_{y_t = v_t + z_t a_t}$$

↓
dist. multivariada pois $y_t \sim p \times 1$

$$\text{Sendo } p(y_t | y_{t-1}) = \frac{1}{(2\pi)^{p/2} |F_t|^{1/2}} \exp \left\{ -\frac{1}{2} (y_t - z_t a_t)' F_t^{-1} (y_t - z_t a_t) \right\}$$

$$\therefore p(y_t | y_{t-1}) \big|_{y_t = v_t + z_t a_t} = \frac{1}{(2\pi)^{p/2} |F_t|^{1/2}} \exp \left\{ -\frac{1}{2} v_t' F_t^{-1} v_t \right\} =$$

$$= p(v_t)$$

$t = 2, \dots, n$

$$\Rightarrow p(v_1, v_2, \dots, v_n) = p(y_1) \prod_{t=2}^n p(v_t)$$

Calculamos $p(y_t)$:

$$t=1 \Rightarrow y_t = z_t \alpha_t + \epsilon_t \therefore y_1 = z_1 \alpha_1 + \epsilon_1$$

$$\cdot E[y_t] = z_t, E[\alpha_t] = z_t a_1$$

$$\begin{aligned} \cdot \text{var}[y_t] &= E[(y_t - E[y_t])(y_t - E[y_t])'] \\ &= E[(z_t(\alpha_t - a_1) + \epsilon_t)(z_t(\alpha_t - a_1) + \epsilon_t)'] \\ &= E[z_t(\alpha_t - a_1)(\alpha_t - a_1)'z_t'] + E[\epsilon_t \epsilon_t'] = \\ &= z_t P_t z_t' + H_t = F_t \end{aligned}$$

$$\text{como } v_t = y_t - z_t a_1 \Rightarrow E[v_t] = 0 \\ \text{var}[v_t] = F_t$$

$$\therefore p(y_t) = \frac{1}{(2\pi)^{p/2} |F_t|^{1/2}} \exp \left\{ -\frac{1}{2} (y_t - z_t a_1)' F_t^{-1} (y_t - z_t a_1) \right\}$$

$$\therefore p(v_t) = \frac{1}{(2\pi)^{p/2} |F_t|^{1/2}} \exp \left\{ -\frac{1}{2} v_t' F_t^{-1} v_t \right\}$$

$$\text{logo: } p(v_1, v_2, \dots, v_n) = \prod_{t=1}^n p(v_t) \Rightarrow \text{(i) } v_t \text{'s s\~ao independentes entre si}$$

$$\text{(ii) } f(v_t | v_{t-1}) = f(v_t)$$

$\Rightarrow (v_t, v_{t+1}, \dots, v_n)$ s\~ao tamb\~em Normais Multivariadas e independentes

Temos ent\~ao que $E[v_i v_j'] = 0 \quad \forall i, j = t, t+1, \dots, n$
 $i \neq j$

Essa independ\~encia entre v_t 's implica em:

$$\begin{aligned} \text{var}(v_t, v_{t+1}, \dots, v_n) &= E \left[\begin{pmatrix} v_t \\ v_{t+1} \\ \vdots \\ v_n \end{pmatrix} (v_t' \ v_{t+1}' \ \dots \ v_n') \right] \\ &= E \begin{bmatrix} v_t v_t' & v_t v_{t+1}' & \dots & v_t v_n' \\ \vdots & & & \\ v_n' v_t' & & & v_n v_n' \end{bmatrix} \end{aligned}$$

$$\therefore \text{Var}(v_t, v_{t+1}, \dots, v_n) = \begin{pmatrix} F_t & 0 & \dots & 0 \\ 0 & F_{t+1} & & \\ \vdots & & \ddots & \\ 0 & & & F_n \end{pmatrix}$$

• Cálculo de $\text{cov}(\alpha_t, (v_t, v_{t+1}, \dots, v_n)')$

$$\begin{aligned} \text{cov}(\alpha_t, (v_t, v_{t+1}, \dots, v_n)') &= E[\alpha_t (v_t', v_{t+1}', \dots, v_n')] \quad \text{pois } E[v_i] = 0 \\ &\quad \begin{matrix} m \times 1 & 1 \times p \end{matrix} \\ &= \underbrace{\begin{bmatrix} E[\alpha_t v_t'] & E[\alpha_t v_{t+1}'] & \dots & E[\alpha_t v_n'] \end{bmatrix}}_{m \times p} \end{aligned}$$

\Rightarrow Na expressão para $\hat{\alpha}_t$, temos:

$$\text{cov}(\alpha_t, (v_t, v_{t+1}, \dots, v_n)') \cdot \text{var}(v_t, v_{t+1}, \dots, v_n)^{-1} \cdot (v_t, v_{t+1}, \dots, v_n)' =$$

$$= \begin{bmatrix} E[\alpha_t v_t'] & E[\alpha_t v_{t+1}'] & \dots & E[\alpha_t v_n'] \end{bmatrix} \begin{bmatrix} F_t^{-1} & & 0 \\ & \ddots & \\ 0 & & F_n^{-1} \end{bmatrix} \begin{bmatrix} v_t \\ v_{t+1} \\ \vdots \\ v_n \end{bmatrix} =$$

$$= \begin{bmatrix} E[\alpha_t v_t'] & \dots & E[\alpha_t v_n'] \end{bmatrix} \begin{bmatrix} F_t^{-1} v_t \\ F_{t+1}^{-1} v_{t+1} \\ \vdots \\ F_n^{-1} v_n \end{bmatrix} =$$

$$= \sum_{j=t}^n E[\alpha_t v_j'] F_j^{-1} v_j$$

Logo:

$$\boxed{\hat{\alpha}_t = E[\alpha_t | y_n] = \underbrace{a_t}_{\text{estimativa}} + \underbrace{\sum_{j=t}^n E[\alpha_t v_j'] F_j^{-1} v_j}_{\text{previsão}}}$$

• Outros resultados dos quais precisaremos:

Seja $\alpha_t \triangleq \alpha_t - a_t$ (como se fosse um erro de previsão).

$$\text{var}(x_t) = \text{var}(\alpha_t) = P_t$$

Escrevendo v_t em funç es de x_t

$$\begin{aligned} v_t &= y_t - z_t \alpha_t \\ &= z_t \alpha_t + \varepsilon_t - z_t \alpha_t \\ &= z_t (\alpha_t - a_t) + \varepsilon_t \end{aligned}$$

$$\boxed{v_t = z_t x_t + \varepsilon_t} \quad (a)$$

Temos ainda que: (escrever x_{t+1} em funç es de x_t)

$$\begin{aligned} x_{t+1} &= \alpha_{t+1} - a_{t+1} \\ &= \underbrace{(T\alpha_t + R_t \eta_t)}_{\text{do modelo EE}} - \underbrace{(T_t a_t + K_t v_t)}_{\text{do FK}} = \\ &= T_t (\alpha_t - a_t) + R_t \eta_t - K_t (z_t x_t + \varepsilon_t) = \\ &\quad \quad \quad z_t \\ &= T_t x_t + R_t \eta_t - K_t z_t x_t + K_t \varepsilon_t \\ &= \underbrace{(T_t - K_t z_t)}_{L_t} x_t + R_t \eta_t - K_t \varepsilon_t = \end{aligned}$$

$$\boxed{x_{t+1} = L_t x_t + R_t \eta_t - K_t \varepsilon_t} \quad (b)$$

As equa  es (a) e (b) podem ser vistas como uma representa  o em inova  es do MEE:

$$\begin{cases} v_t = z_t x_t + \varepsilon_t \\ x_{t+1} = L_t x_t + \underbrace{(R_t \eta_t - K_t \varepsilon_t)}_{\text{ sas descorrelatadas}} \end{cases} \quad (c) \quad \begin{aligned} y_t &= z_t \alpha_t + \varepsilon_t \\ \alpha_{t+1} &= T_t \alpha_t + R_t \eta_t \end{aligned}$$

• Em $\hat{\alpha}_t$, onde tem-se $E[\alpha_t v_j']$, podemos escrever:

$$\begin{aligned} E[\alpha_t v_j'] &= E[\alpha_t (z_j x_j + \varepsilon_j)'] = \\ &= E[\alpha_t x_j'] z_j' \quad j = t \dots n \end{aligned}$$

calculando $E[\alpha_t x_j']$:

$$\begin{aligned}
E[\alpha_t \alpha_t'] &= E[E[\alpha_t \alpha_t' | \underline{y}_{t-1}]] \\
&= E[E[\alpha_t (\alpha_t - a_t)' | \underline{y}_{t-1}]] \quad \text{porque} \\
&= E[E[(\alpha_t - a_t)(\alpha_t - a_t)' | \underline{y}_{t-1}]] \\
&= E(P_t) = P_t
\end{aligned}$$

calculando sucessivamente:

$$\begin{aligned}
\rightarrow E[\alpha_t \alpha_{t+1}'] &= E[E[\alpha_t \alpha_{t+1}' | \underline{y}_{t-1}]] = \\
&= E[E[\alpha_t (L_t x_t + R_t \eta_t - K_t \varepsilon_t)' | \underline{y}_{t-1}]] = \\
&= E[E[\alpha_t (x_t' L_t' + \eta_t' R_t' - \varepsilon_t' K_t') | \underline{y}_{t-1}]] = \\
&= E[E[(\alpha_t x_t' L_t' | \underline{y}_{t-1})]] = \\
&= E[E[\alpha_t (\alpha_t - a_t)' L_t' | \underline{y}_{t-1}]] = \\
&= E[E[(\alpha_t - a_t)(\alpha_t - a_t)' L_t' | \underline{y}_{t-1}]] = \\
&= P_t L_t'
\end{aligned}$$

$$\begin{aligned}
\rightarrow E[\alpha_t \alpha_{t+2}'] &= E[E[\alpha_t \alpha_{t+2}' | \underline{y}_{t-1}]] = \\
&= E[E[\alpha_t (L_{t+1} x_{t+1} + R_{t+1} \eta_{t+1} - K_{t+1} \varepsilon_{t+1})' | \underline{y}_{t-1}]] = \\
&= E[E[\alpha_t (x_{t+1}' L_{t+1}' + \eta_{t+1}' R_{t+1}' - \varepsilon_{t+1}' K_{t+1}') | \underline{y}_{t-1}]] = \\
&= E[E[\alpha_t x_{t+1}' | \underline{y}_{t-1}]] L_{t+1}' \\
&= \underbrace{P_t L_t' L_{t+1}'}_{\text{por inducao}}
\end{aligned}$$

⋮

$$\rightarrow E[\alpha_t \alpha_n'] = P_t L_t' L_{t+1}' \dots L_{n-1}' \quad (\text{por inducao})$$

Podemos resumir:

$$\begin{aligned}
\hat{\alpha}_t &= a_t + \sum_{j=t}^{\infty} \underbrace{E[\alpha_t v_j']}_{E[\alpha_t \alpha_j']} F_j' v_j \\
&= P_t L_t' L_{t+1}' \dots L_{n-1}' z_j'
\end{aligned}$$

$$\hat{\alpha}_t = a_t + P_t Z_t' F_t^{-1} v_t + P_t L_t' Z_{t+1}' F_{t+1}^{-1} v_{t+1} + \dots + P_t L_t' L_{t+1}' \dots L_n' Z_n' F_n^{-1} v_n$$

Quando $t=n \Rightarrow$ passo de atualização coincide com o de smoothing

$$\hat{\alpha}_n = E[\alpha_n | y_1, \dots, y_n]$$

$$a_n | n = E[\alpha_n | y_n]$$

Logo: $\hat{\alpha}_n = a_n + P_n Z_n' F_n^{-1} v_n$ ($a_t | t = a_t + M_t F_t^{-1} v_t$ onde $M_t = P_t Z_t'$)

Voltando um passo atrás para $t=n-1$

$$\hat{\alpha}_{n-1} = a_{n-1} + \sum_{j=n-1}^n E[\alpha_j v_j'] F_j^{-1} v_j \quad (2 \text{ termos})$$

(n-1 em $\hat{\alpha}_t$)

$$= a_{n-1} + P_{n-1} Z_{n-1}' F_{n-1}^{-1} v_{n-1} + P_{n-1} L_{n-1}' Z_n' F_n^{-1} v_n$$

Portanto

$$\hat{\alpha}_t = a_t + P_t Z_t' F_t^{-1} v_t + P_t L_t' Z_{t+1}' F_{t+1}^{-1} v_{t+1} + \dots + P_t L_t' L_{t+1}' \dots L_n' Z_n' F_n^{-1} v_n$$

$$\Rightarrow \boxed{\hat{\alpha}_t = a_t + P_t r_{t-1}}$$

$$\text{onde } r_{t-1} = Z_t' F_t^{-1} v_t + L_t' Z_{t+1}' F_{t+1}^{-1} v_{t+1} + \dots + L_t' L_{t+1}' \dots L_n' Z_n' F_n^{-1} v_n$$

$t = n-2, n-3, \dots, \underline{n}$

$$P_t = n \Rightarrow r_{n-1} = Z_n' F_n^{-1} v_n$$

$$P_t = n-1 \Rightarrow r_{n-2} = Z_{n-1}' F_{n-1}^{-1} v_{n-1} + L_{n-1}' Z_n' F_n^{-1} v_n$$

onde r_{t-1} : soma ponderada das inovações v_j ocorridas após o tempo t .

$$r_t = Z_{t+1}' F_{t+1}^{-1} v_{t+1} + L_{t+1}' Z_t' F_t^{-1} v_t + \dots + L_{t+1}' \dots L_n' Z_n' F_n^{-1} v_n$$

com $r_n \equiv 0$ pois inovações até $t=n$.

Escrevendo de forma recursiva, temos:

$$\boxed{r_{t-1} = Z_t' F_t^{-1} v_t + L_t' r_t, \quad r_n \equiv 0.}$$

A estimativa suavizada do vetor de estado será dada por:

$$\hat{\alpha}_t = a_t + P_t \lambda_{t-1}$$

$\swarrow \quad \searrow \quad \downarrow$
 $E[\alpha_t | y_n] \quad E[\alpha_t | y_{t-1}] \quad \text{soma ponderada de inovações entre } t \text{ e } n$

onde: $\lambda_{t-1} = z_t' F_t^{-1} v_t + L_t' \lambda_t$ com $\lambda_n = 0$

↳ suavizador de intervalo fixo.

Calculo da variância suavizada

$$V_t = \text{var}(\alpha_t | y_n)$$

$$= \text{var}(\alpha_t | y_{t-1}, v_t, v_{t+1}, \dots, v_n)$$

No resultado n vetores multivariados, temos:

$$\begin{aligned} x &= \alpha_t \\ y &= y_{t-1} \\ z &= (v_t, \dots, v_n)' \end{aligned}$$

$$V_t = \text{var}(\alpha_t | y_{t-1}) - \underbrace{\text{cov}(\alpha_t, (v_t, v_{t+1}, \dots, v_n)')}_{\text{diagonal}} \underbrace{[\text{var}(v_t, \dots, v_n)]^{-1}}_{\text{diagonal}} \underbrace{\text{cov}(\alpha_t, (v_t, v_{t+1}, \dots, v_n))}_{\text{diagonal}}$$

$$V_t = P_t - \sum_{j=t}^n \text{cov}(\alpha_t, v_j) F_j^{-1} \text{cov}(\alpha_t, v_j)'$$

variância suavizada

variância prevista

⇒ V_t é mais preciso do que P_t

• Já vimos que:

$$\text{cov}(\alpha_t, v_j) = E[\alpha_t v_j'] = E[\alpha_t x_j'] z_j' \quad j = t, \dots, n$$

$$\Rightarrow V_t = P_t - \sum_{j=t}^n E[\alpha_t x_j'] z_j' F_j^{-1} z_j (E[\alpha_t x_j'])'$$

$$= P_t - [E[\alpha_t x_t'] z_t' F_t^{-1} z_t (E[\alpha_t x_t'])' + E[\alpha_t x_{t+1}'] z_{t+1}' F_{t+1}^{-1} z_{t+1} (E[\alpha_t x_{t+1}'])' + \dots + E[\alpha_t x_n'] z_n' F_n^{-1} z_n (E[\alpha_t x_n'])']$$

• Já vimos também que

$$E[\alpha_t x_t'] = P_t$$

$$E[\alpha_t x_{t+1}'] = P_t L_t'$$

⋮

Logo:

$$V_t = P_t - P_t z_t' F_t^{-1} z_t P_t - P_t L_t' z_{t+1}' F_{t+1}^{-1} z_{t+1} L_t P_t - \dots$$

$$- P_t L_t' \dots L_{n-1}' z_n' F_n^{-1} z_n L_{n-1} \dots L_t P_t$$

$$= P_t - P_t (z_t' F_t^{-1} z_t + L_t' z_{t+1}' F_{t+1}^{-1} z_{t+1} L_t + \dots) P_t$$

$$V_t = p_t - p_t N_{t-1} p_t$$

$$\text{onde } N_{t-1} = z_t' F_t^{-1} z_t + L_t' \left[z_{t+1}' F_{t+1}^{-1} z_{t+1} L_t + \dots + L_t' \dots L_{n-1}' z_n' F_n^{-1} z_n L_{n-1} \right] L_t$$

$$N_t = z_{t+1}' F_{t+1}^{-1} z_{t+1} + L_{t+1}' z_{t+2}' F_{t+2}^{-1} z_{t+2} L_{t+1} + \dots$$

$$\Rightarrow \left| N_{t-1} = z_t' F_t^{-1} z_t + L_t' N_t L_t \quad t = n, \dots, 1 \right|$$

Em $t = n-1$: começa a recursão \Rightarrow com $N_n = 0$

Portanto

$$\left\{ \begin{array}{l} V_t = p_t - p_t N_{t-1} p_t \\ \downarrow \\ \text{var}[\alpha_t | \underline{y}_n] \end{array} \right. \quad \begin{array}{l} \downarrow \\ \text{em } t=n: da' = \text{a estimativa da previs\~ao.} \end{array}$$

$$\text{onde: } N_{t-1} = z_t' F_t^{-1} z_t + L_t' N_t L_t \quad N_n = 0.$$

observa\~oes

$$\text{para o } \alpha_t, \text{ temos: } \left\{ \begin{array}{l} E[\alpha_t] = 0 \\ \text{var}[\alpha_t] = N_t \end{array} \right.$$

Resumo

$$\hat{z}_t = a_t + p_t \alpha_{t-1}$$


$$\alpha_{t-1} = z_t' F_t^{-1} v_t + L_t' \alpha_t$$

$$\alpha_n = 0$$

$$V_t = p_t - p_t N_{t-1} p_t$$

$$N_{t-1} = z_t' F_t^{-1} z_t + L_t' N_t L_t$$

$$N_n = 0.$$



Equações de Ricatti (steady state FK)

Equações FK

$$\text{Var} [\alpha_{t+1} | y_t] = P_{t+1}$$

$$\Rightarrow P_{t+1} = T_t P_t L_t' + R_t Q_t R_t' \Rightarrow \text{Nas depende de observações}$$

Considerando sistemas invariantes no tempo (matrizes do sistema independentem de t)

$$P_{t+1} = T P_t L_t' + R Q R'$$

$$\text{onde } L_t = T - K_t Z$$

$$\text{e } K_t = T P_t Z' F_t^{-1}$$

$$\text{e } F_t = Z P_t Z' + H$$

$$\Rightarrow P_{t+1} = T P_t [T - (T P_t Z' F_t^{-1}) Z]' + R Q R'$$

$$\boxed{P_{t+1} = T P_t T' - T P_t Z' F_t^{-1} Z P_t T' + R Q R'}$$

Equações de Ricatti

Supondo que $\lim_{t \rightarrow \infty} P_{t+1} = P_t = \bar{P}$

$$\Rightarrow \bar{P} = T \bar{P} T' - T \bar{P} Z' \bar{F}^{-1} Z \bar{P} T' + R Q R' \quad \text{e} \quad \bar{F} = Z \bar{P} Z' + H$$

precisamos resolver FK \bar{P}

Exemplo:

1) $y_t = \mu_t + \epsilon_t \quad \epsilon_t \sim N(0, \sigma_\epsilon^2)$
 $\mu_{t+1} = \mu_t + \eta_t \quad \eta_t \sim N(0, \sigma_\eta^2)$

Nível local

$$T = Z = 1 \quad R = 1$$

$$\bar{P} = \bar{P} - \underbrace{\bar{P} \bar{F}^{-1} \bar{P}}_{(\bar{P} + \sigma_\epsilon^2)^{-1}} + \sigma_\eta^2 \quad \therefore \quad \bar{P} = \bar{P} \left(1 - \frac{\bar{P}}{\bar{P} + \sigma_\epsilon^2} \right) + \sigma_\eta^2$$

$$\therefore x^2 - xh - h = 0 \quad \text{onde} \quad \bar{x} = \frac{\bar{p}}{\sigma_\epsilon^2}$$

$$h = \sigma_\eta^2 / \sigma_\epsilon^2 = q$$

Soluções: $x = \frac{h + \sqrt{h^2 + 4h}}{2}$ desde que $h > 0$.

2) $y_t = y_{t-1} \varphi_t + \epsilon_t$

$$\varphi_t = \phi \varphi_{t-1} + \eta_t$$

\Rightarrow sistema mas é invariante no tempo.

Jamais haverá soluções de Riccati

3)

$$y_t = \mu_t + \beta_t + \epsilon_t$$

$$\mu_{t+1} = \mu_t + \beta_t + \eta_t$$

$$\beta_{t+1} = \beta_t + \kappa_t$$

Tendência local

Na forma EE:

$$y_t = \begin{pmatrix} 1 & 1 \end{pmatrix} \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} + \epsilon_t$$

fazer

$$\begin{pmatrix} \mu_{t+1} \\ \beta_{t+1} \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \eta_t \\ \kappa_t \end{pmatrix}$$

$$z = \begin{pmatrix} 1 & 1 \end{pmatrix} \quad R = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \quad Q = \begin{pmatrix} \sigma_\eta^2 & 0 \\ 0 & \sigma_\kappa^2 \end{pmatrix}$$

$$T = \begin{pmatrix} 1 & 1 \\ 1 & 0 \end{pmatrix} \quad H = \sigma_\epsilon^2 I$$

$$\bar{P} = T \bar{P} T' - T \bar{P} z' \bar{F}^{-1} z \bar{P} T' + R Q R'$$

$$\bar{F} = \underset{1 \times 2}{z} \underset{2 \times 2}{\bar{P}} \underset{2 \times 1}{z'} + H = \begin{pmatrix} 1 & 1 \end{pmatrix} \bar{P} \begin{pmatrix} 1 \\ 1 \end{pmatrix} + \sigma_\epsilon^2$$

Observações faltantes

- Em $t = \tau, \tau+1, \dots, \tau^*-1 \Rightarrow$ observações de y_t não existem
- Como aplicar FK / Smoothing η observações faltantes?
Como preencher estas observações (dependerá do MEE usado)?

Modelo

$$\begin{aligned} y_t &= z_t \alpha_t + \epsilon_t & \epsilon_t &\sim N(0, H_t) \\ \alpha_{t+1} &= T_t \alpha_t + R_t \eta_t & \eta_t &\sim N(0, Q_t) \end{aligned}$$

Nos períodos em que \exists observações, as equações FK usadas são

$$\text{FK} \begin{cases} a_{t+1} = T_t a_t + K_t v_t & t \leq \tau-1 \\ P_{t+1} = T_t P_t L_t' + R_t Q_t R_t' & t \geq \tau^* \\ L_t = T_t - K_t z_t' \\ K_t = T_t P_t z_t' f_t^{-1} \end{cases}$$

Nos períodos de dados faltantes ($t = \tau, \tau+1, \dots, \tau^*-1$), não usamos expressões de FK pois $\nexists y_t \therefore \nexists v_t \Rightarrow \left. \begin{matrix} v_t = 0 \\ \nexists F_t \\ K_t = 0 \end{matrix} \right\} L_t = T_t$

Valor Esperado Inemos estas "extrapolar o estado", realizando a substituição:

$$a_t \longrightarrow a_{\tau+j} \quad j=1,2,\dots$$

$$(p | t \in (\tau, \tau^*-1))$$

$$\text{onde } a_{\tau+j} \hat{=} E[\alpha_{\tau+j} | y_{\tau-1}]$$

\downarrow última observação

Supondo sistema invariante no tempo

$$\alpha_{t+1} = T \alpha_t + R \eta_t$$

Iterando:

$$\alpha_{t+2} = T \alpha_{t+1} + R \eta_{t+1} = T^2 \alpha_t + T R \eta_t + R \eta_{t+1}$$

\vdots

Pl j passos a frente

$$\alpha_{t+j} = T^j \alpha_t + \sum_{i=1}^j T^{j-i} R \eta_{t+i-j}$$

Fazendo $t = \tau$

$$\alpha_{\tau+j} = T^j \alpha_{\tau} + \sum_{i=1}^j T^{j-i} R \eta_{\tau+i-1}$$

Assim:

$$E[\alpha_{\tau+j} | Y_{\tau-1}] = T^j E[\alpha_{\tau} | Y_{\tau-1}]$$

↓
mas tem obs. em τ mas tem estimativa direta

$$\begin{aligned} a_{\tau+j} &= E[\alpha_{\tau+j} | Y_{\tau}] \\ &= E[\alpha_{\tau+j} | Y_{\tau-1}] \end{aligned}$$

$$\boxed{a_{\tau+j} = T^j a_{\tau} \quad j = 1, 2, \dots, \tau^* - \tau - 1}$$

O FK nesse período será substituído por $a_{\tau+j}$, o que equivale a

$$\boxed{a_{t+1} = T a_t} \quad (t = \tau, \tau+1, \dots, \tau^*-1) \quad \text{ou} \quad \underline{a_{t+1} = T_{\tau} a_t}$$

pois

$$a_{\tau+1} = T a_{\tau}$$

$$a_{\tau+2} = T a_{\tau+1} = T^2 a_{\tau} \dots$$

Na prática

Fazer $v_t = 0$ na equação do FK

• Variância

Tb projetaremos a variância j passos a frente

↳ Atenção! É uma matriz

Queremos a expressão para

$$P_{\tau+j} = \text{var}(\alpha_{\tau+j} | Y_{\tau-1}) = E[(\alpha_{\tau+j} - a_{\tau+j})(\alpha_{\tau+j} - a_{\tau+j})' | Y_{\tau-1}]$$

mas:

$$\alpha_{t+j} = T^j \alpha_t + \sum_{i=1}^j T^{j-i} R \eta_{t+i-1}$$

$$a_{t+j} = T^j a_t$$

$$\Rightarrow (\alpha_{t+j} - a_{t+j}) = T^j (\alpha_t - a_t) + \sum_{i=1}^j T^{j-i} R \eta_{t+i-1}$$

$$\begin{aligned} \therefore P_{t+j} &= E \left[\left(T^j (\alpha_t - a_t) + \sum_{i=1}^j T^{j-i} R \eta_{t+i-1} \right) \left((\alpha_t - a_t)' T^{j'} + \sum_{i=1}^j \eta_{t+i-1}' R' T^{j-i'} \right) \right] \\ &= T^j E \left[(\alpha_t - a_t) (\alpha_t - a_t)' \right] T^{j'} + \sum_{i=1}^j T^{j-i} R E \left[\eta_{t+i-1} \eta_{t+i-1}' \right] T^{j-i'} R' \end{aligned}$$

(termos cruzados são nulos)

$$= T^j P_t T^{j'} + \sum_{i=1}^j T^{j-i} R Q R' (T^{j-i})' \quad j=1, 2, \dots, \tau-t-1$$

o que é equivalente a:

$$P_{t+1} = T P_t T' + R Q R'$$

pois $P_{t+1} = T P_t T' + R Q R'$

$$\begin{aligned} P_{t+2} &= T P_{t+1} T' + R Q R' = T [T P_t T' + R Q R'] T' + R Q R' \\ &= T^2 P_t (T')^2 + T R Q R' T' + R Q R' \\ &\vdots \end{aligned}$$

Na prática

fazer $K_t = 0$ (pois $\bar{F}_t' = 0$) no FK

$$\therefore L_t = T_t$$

$$\therefore P_{t+1} = T_t P_t T_t' + R_t Q_t R_t'$$

\vdots

RESUMINDO: usamos FK p/ os períodos de dados faltantes, fazendo $v_t = 0$ e $\bar{F}_t' = 0 \Rightarrow K_t = 0$

$$\textcircled{A} \quad \begin{cases} a_{t+1} = T_t a_t \\ P_{t+1} = T_t P_t T_t' + R_t Q_t R_t' \end{cases}$$

Para Suavizações

As equações são:

$$\begin{cases} \hat{\alpha}_t = a_t + P_t \lambda_{t-1} \\ \lambda_{t-1} = Z_t F_t^{-1} v_t + L_t' \lambda_t \end{cases} \quad \begin{cases} v_t = P_t - P_t N_{t-1} P_t \\ N_{t-1} = Z_t' F_t^{-1} Z_t + L_t' N_t L_t \end{cases}$$

$\lambda_n = 0, t = n, n-1, \dots, 1$ $N_n = 0, L_t = T_t - K_t Z_t$

Como $v_t = 0$ e $F_t^{-1} = 0$

$$\textcircled{b} \Rightarrow \begin{cases} \hat{\alpha}_t = a_t + P_t \lambda_{t-1} \\ \lambda_{t-1} = L_t' \lambda_t = T_t' \lambda_t \end{cases} \quad \textcircled{c} \begin{cases} v_t = P_t - P_t N_{t-1} P_t \\ N_{t-1} = T_t' N_t T_t \end{cases}$$

$t = \tau^*-1, \dots, \tau$

(Nos períodos de dados faltantes a_t e P_t são estimados com \textcircled{a})

Preenchimento das obs. faltantes

Podemos substituir as obs. faltantes através da seguinte estratégia:

y_t subst. por $E[y_t | \underline{y}_n]$ em $t = \tau, \tau+1, \dots, \tau^*-1$

Como $y_t = Z_t \alpha_t + \varepsilon_t, \forall t$

$$E[y_t | \underline{y}_n] = Z_t E[\alpha_t | \underline{y}_n] + E[\varepsilon_t | \underline{y}_n]$$

$$= Z_t \hat{\alpha}_t + \hat{\varepsilon}_t \Rightarrow \text{atenção! Nas é zero}$$

Nas confundir com $E[\varepsilon_t | \underline{y}_{t-1}]$

Atenção!

$$\hat{\varepsilon}_t = E[\varepsilon_t | \underline{y}_n] : \text{na pg 73, por 4.4} \Rightarrow \hat{\varepsilon}_t = H_t \mu_t$$

onde $H_t = \text{var}(\varepsilon_t)$

$$\mu_t = F_t^{-1} v_t - K_t' \lambda_t$$

Nas 9 obs. faltantes: $v_t = 0, F_t^{-1} = 0, K_t = 0$

$$\therefore E[y_t | \underline{y}_n] = \hat{y}_t = Z_t \hat{\alpha}_t$$

\downarrow
dado por \textcircled{b} $t = \tau, \tau+1, \dots, \tau^*-1$

Exemplo

$$1) \begin{cases} y_t = \mu_t + \varepsilon_t & \varepsilon_t \sim N(0, \sigma_\varepsilon^2) \\ \mu_{t+1} = \mu_t + \eta_t & \eta_t \sim N(0, \sigma_\eta^2) \end{cases}$$

$$T = 2 = R = 1$$

$$H = \sigma_\varepsilon^2$$

$$\Phi = \sigma_\eta^2$$

usando equações (A):

$$\text{FK} \quad \begin{cases} a_{t+1} = a_t \\ p_{t+1} = p_t + \sigma_\eta^2 \end{cases}$$


estimada por $a_{\tau-1}$
 $t = \tau, \tau+1, \dots, \tau^*-1$

Iterando: $\Rightarrow a_{\tau+1} = a_\tau$

$$a_{\tau+2} = a_{\tau+1} = a_\tau \Rightarrow a_{\tau+j} = a_\tau \quad j = 1, 2, \dots$$

$$\Rightarrow p_{\tau+1} = p_\tau + \sigma_\eta^2$$

$$p_{\tau+2} = p_{\tau+1} + \sigma_\eta^2 = p_\tau + 2\sigma_\eta^2 \Rightarrow p_{\tau+j} = p_\tau + j\sigma_\eta^2$$



por smoothing: $L=1$
 $v_t = 0$
 $F_t^* = 0$

$$\hat{a}_t = a_t + p_t \lambda_{t-1}$$

$$\lambda_{t-1} = \lambda_t \Rightarrow \lambda_\tau = \lambda_{\tau-1}$$

$$\begin{aligned} \hat{a}_{\tau+j} &= a_\tau + p_{\tau+j} \lambda_{\tau+j-1} \\ &= a_\tau + \underbrace{(p_\tau + j\sigma_\eta^2)}_{\text{do } (k)} \lambda_\tau \\ &= \underbrace{(a_\tau + p_\tau \lambda_\tau)}_a + \underbrace{(j\sigma_\eta^2 \lambda_\tau)}_b \end{aligned}$$

pre-nenhamento: $\hat{a}_{\tau+j} = a + bj, \quad j = 1, 2, \dots, \tau^* - \tau$

$$\Rightarrow \hat{y}_t = \hat{\alpha}_t \\ (= E[\alpha_t | y_{\sim t}])$$

ou

$$\hat{y}_t = \hat{\alpha}_t = a_t + \rho_t \alpha_t$$

$$\hat{y}_{t+1} = \hat{\alpha}_{t+1} = a + b$$

$$\hat{y}_{t+2} = \hat{\alpha}_{t+2} = a + (2b)$$

! nos entendi ou

$$2) y_t = \mu_t + \varepsilon_t$$

$$\mu_{t+1} = \mu_t + \beta_t + \eta_t$$

$$\beta_{t+1} = \beta_t + \kappa_t$$

Inicializações

$$\alpha_1 \sim N(a_1, P_1)$$

Na prática, não sabemos quem são a_1 e P_1

$$\alpha_1 \sim (\alpha_1 | y_0) : \text{a priori}$$

No FK:

$$v_t = y_t - a_t$$

$$? \rightarrow (P_t + \sigma_\epsilon^2 = F_t \quad (P_t P_t' z_t' + \sigma_\epsilon^2 = F_t) ?$$

$$\begin{cases} a_{t+1} = a_t + k_t v_t \\ P_{t+1} = P_t (1 - k_t) + \sigma_\eta^2 \\ k_t = P_t / F_t \end{cases}$$

Para $t=1 \Rightarrow v_1 = y_1 - a_1$
 $F_1 = P_1 + \sigma_\epsilon^2$

Para $t=2 \Rightarrow a_2 = a_1 + k_1 v_1$
 $= a_1 + \frac{P_1}{F_1} v_1 = a_1 + \frac{P_1}{P_1 + \sigma_\epsilon^2} (y_1 - a_1)$

$$\begin{aligned} & \leq P_2 = P_1 (1 - k_1) + \sigma_\eta^2 \\ & = P_1 \left(1 - \frac{P_1}{P_1 + \sigma_\epsilon^2} \right) + \sigma_\eta^2 = \frac{P_1}{P_1 + \sigma_\epsilon^2} \cdot \sigma_\epsilon^2 + \sigma_\eta^2 \end{aligned}$$

Fazendo $P_1 \rightarrow \infty$ obtemos:

$$\begin{cases} a_2 = a_1 + (y_1 - a_1) = y_1 \quad \forall a_1 \\ P_2 = \sigma_\epsilon^2 + \sigma_\eta^2 \end{cases}$$

ou seja, para $t=2, \dots, n$, as equações do FK não apresentam problema pois as distribuições são próprias (bem definidas)

Observação importante: Inicializar o FK em $t=1$ com $a_1, P_1 = K \rightarrow \infty$ equivale a adotar a priori $(\alpha_1 | y_0) \sim N(a_0 = y_0, P_0 = \sigma_\epsilon^2 + \sigma_\eta^2)$

→ Efeito das condições iniciais no alisamento

estimativa suavizada

$$\hat{\alpha}_t = a_t + p_t \eta_{t-1}$$

$$= a_t + p_t (v_t F_t^{-1} + L_t \eta_t) \quad \text{onde } L_t = 1 - k_t = \frac{\sigma_E^2}{f_1} = \frac{\sigma_E^2}{p_t + \sigma_E^2}$$

$$\therefore \hat{\alpha}_t = a_t + p_t \left[\frac{(y_t - a_t)}{p_t + \sigma_E^2} + \frac{\sigma_E^2}{p_t + \sigma_E^2} \eta_t \right]$$

Para $\hat{\alpha}_1$:

$$\hat{\alpha}_1 = a_1 + \frac{p_1 v_1}{p_1 + \sigma_E^2} + \frac{p_1 \sigma_E^2 \eta_1}{p_1 + \sigma_E^2}$$

$$\text{Se } p_1 \rightarrow \infty : \boxed{\hat{\alpha}_1 = a_1 + v_1 + \sigma_E^2 \eta_1}$$

variância suavizada

$$V_t = p_t - p_t^2 N_{t-1}$$

$$= p_t - p_t^2 (F_t^{-1} + L_t^2 N_t)$$

$$= p_t - p_t^2 \left(F_t^{-1} + \left(\frac{\sigma_E^2}{p_t + \sigma_E^2} \right) N_t \right)$$

Para V_1 :

$$V_1 = p_1 - p_1^2 \left(\frac{1}{p_1 + \sigma_E^2} + \frac{\sigma_E^2}{p_1 + \sigma_E^2} N_1 \right)$$

$$= \left(\frac{p_1}{p_1 + \sigma_E^2} \right) \sigma_E^2 + \sigma_E^4 N_1 \left(\frac{p_1}{p_1 + \sigma_E^2} \right)^2$$

$$\text{Se } p_1 \rightarrow \infty : \boxed{V_1 = \sigma_E^2 - \sigma_E^4 N_1}$$

⇒ Nesta forma, a média do distribúio suavizada é:

$$\hat{E}_t = \sigma_E^2 \mu_t \quad \hat{E}_1 = \hat{\sigma}_E^2 \mu_1$$

$$\mu_t = F_t^{-1} v_t - k_t \eta_t$$

$$\text{onde } k_t = \frac{p_t}{F_t} = \frac{p_t}{\sigma_E^2 + p_t}$$

$$\mu_1 = F_1^{-1} v_1 - k_1 \eta_1$$

$$= \left(\frac{1}{p_1 + \sigma_E^2} \right) v_1 - \left(\frac{p_1}{p_1 + \sigma_E^2} \right) \eta_1$$

$$\lim_{p_1 \rightarrow \infty} \mu_1 = 0 - \eta_1 = -\eta_1 \quad \lim_{p_1 \rightarrow \infty} \hat{E}_t = -\eta_1 \hat{\sigma}_E^2$$

Estimações dos Hiperparâmetros

→ MV: $p(y) = p(y_1, \dots, y_n) = \prod_{t=1}^n p(y_t | y_{t-1})$

onde $p(y_1 | y_0) = p(y_1)$

$p(y_t | y_{t-1}) \sim N(\overset{z_t a_t}{a_t}, F_t)$

e $v_t = y_t - a_t$

$p(y_t | y_{t-1}) = \frac{1}{(2\pi F_t)^{1/2}} \exp \left\{ -\frac{1}{2} \frac{(y_t - a_t)^2}{F_t} \right\}$ y : scalar.
($p=1$)

$$\begin{aligned} \therefore p(y) &= \prod_{t=1}^n p(y_t | y_{t-1}) = \frac{1}{(2\pi)^{n/2}} \left(\prod_{t=1}^n \frac{1}{F_t^{1/2}} \right) \prod_{t=1}^n \exp \left\{ -\frac{1}{2} \frac{v_t^2}{F_t} \right\} \\ &= \frac{1}{(2\pi)^{n/2}} \cdot \prod_{t=1}^n \frac{1}{F_t^{1/2}} \cdot \exp \left\{ -\frac{1}{2} \sum_{t=1}^n \frac{v_t^2}{F_t} \right\} \end{aligned}$$

Logo:

$$\log L(\psi | y) = \log p(y) = -\frac{n}{2} \log 2\pi - \frac{1}{2} \sum_{t=1}^n \log F_t - \frac{1}{2} \sum_{t=1}^n \frac{v_t^2}{F_t}$$

$$\therefore \log L = -\frac{n}{2} \log 2\pi - \frac{1}{2} \sum_{t=1}^n \left(\log F_t + \frac{v_t^2}{F_t} \right)$$

onde v_t e F_t são calculados usando o FK.

De forma alternativa, o log da verossimilhança pode ser obtido usando a representação em y do modelo de nível local

$y \sim N(a, \mathbb{1}, \Omega)$ → Normal Multivariada
(com n observações)

$$p(y) = \frac{1}{(2\pi)^{n/2} |\Omega|^{1/2}} \exp \left\{ -\frac{1}{2} [(y - a, \mathbb{1})' \Omega^{-1} (y - a, \mathbb{1})] \right\}$$

$$L(\psi) = \log p(y) = -\frac{n}{2} \log 2\pi - \frac{1}{2} \log |R| - \frac{1}{2} [(y-a, \eta)' R^{-1} (y-a, \eta)]$$

Podemos escrever:

(divida) $\rightarrow R = CFC'$ onde $|C| = 1$ e $CC' = I$
 \downarrow
 variáveis de cada t na diag. $(C' = C^{-1})$

c. cte.
do modelo
de nível
local.

$$\begin{aligned} R^{-1} &= (CFC')^{-1} \\ &= (C')^{-1} F^{-1} C^{-1} \\ &= C' F^{-1} C \end{aligned}$$

$$F = \begin{pmatrix} F_1 & 0 & \dots & 0 \\ 0 & F_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & F_n \end{pmatrix}$$

onde $\sum_{t=1}^n F_t = 0$

$$\Rightarrow i) \log |R| = \log |CFC'| = \log [1 \cdot |F| \cdot 1] = \log |F| = \log \prod_{t=1}^n F_t = \sum_{t=1}^n \log F_t$$

$$ii) (y-a, \eta)' R^{-1} (y-a, \eta) \quad \text{onde } v = C(y-a, \eta)$$

$$= (y-a, \eta)' C' F^{-1} C (y-a, \eta) =$$

$$= [C(y-a, \eta)]' F^{-1} [C(y-a, \eta)] = v' F^{-1} v =$$

$$= (v_1, \dots, v_n) \begin{pmatrix} F_1^{-1} & 0 & \dots & 0 \\ 0 & F_2^{-1} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & F_n^{-1} \end{pmatrix} \begin{pmatrix} v_1 \\ \vdots \\ v_n \end{pmatrix} =$$

$$= \sum_{t=1}^n \frac{v_t^2}{F_t}$$

(e encontramos
a mesma expressão
para log-verossimilhança)

\rightarrow Inicialização Difusa e MV

da cond. inicial

$$\log L_0 \triangleq \lim_{P_i \rightarrow \infty} \left(\log L + \frac{1}{2} \log P_i \right)$$

(divida) $L + P_i^{-1/2} ?$

$$\hat{=} -\frac{n}{2} \log 2\pi - \frac{1}{2} \sum_{t=1}^n \left(\log F_t + \frac{v_t^2}{F_t} \right) + \frac{1}{2} \log P_i =$$

mas depende de σ_ϵ^2 ou σ_η^2

$$= -\frac{n}{2} \log 2\pi - \frac{1}{2} \left(\log F_i + \frac{v_i^2}{F_i} \right) - \frac{1}{2} \sum_{t=2}^n \left(\log F_t + \frac{v_t^2}{F_t} \right) + \frac{1}{2} \log P_i =$$

$$= -\frac{1}{2} \left(\log \frac{F_1}{P_1} + \frac{v_1^2}{F_1} \right) - \frac{n}{2} \log 2\pi - \frac{1}{2} \sum_{t=2}^n \left(\log F_t + \frac{v_t^2}{F_t} \right)$$

Mas temos que:

$$i) \frac{F_1}{P_1} = \frac{P_1 + \sigma_\epsilon^2}{P_1} = 1 + \frac{\sigma_\epsilon^2}{P_1}$$

$$\lim_{P_1 \rightarrow \infty} \frac{F_1}{P_1} = 1 \quad \therefore \quad \lim_{P_1 \rightarrow \infty} \log \left(\frac{F_1}{P_1} \right) = 0$$

$$ii) \frac{v_1^2}{F_1} = \frac{(y_1 - a_1)^2}{P_1 + \sigma_\epsilon^2}$$

$$\lim_{P_1 \rightarrow \infty} \frac{(y_1 - a_1)^2}{P_1 + \sigma_\epsilon^2} = 0$$

Logo:

$$\log L_0 = -\frac{1}{2} \lim_{P_1 \rightarrow \infty} \left(\log \frac{F_1}{P_1} + \frac{v_1^2}{F_1} \right) - \frac{n}{2} \log 2\pi - \frac{1}{2} \sum_{t=2}^n \left(\log F_t + \frac{v_t^2}{F_t} \right)$$

$$\log L_0 = -\frac{n}{2} \log 2\pi - \frac{1}{2} \sum_{t=2}^n \left(\log F_t + \frac{v_t^2}{F_t} \right)$$

obs: Na prática, reparametrizamos $\sigma_\epsilon^2 = e^{\psi_\epsilon}$ $\psi_\epsilon, \psi_\eta \in \mathbb{R}$
 $\sigma_\eta^2 = e^{\psi_\eta}$

→ Concentrações de MV

Concentrações = reparametrizações do modelo em EE para reduzir a dimensionalidade da busca numérica

$$y_t = \alpha_t + \epsilon_t, \quad \epsilon_t \sim N(0, \sigma_\epsilon^2)$$

$$\alpha_{t+1} = \alpha_t + \eta_t, \quad \eta_t \sim N(0, q\sigma_\epsilon^2)$$

$$(\sigma_\epsilon^2, \sigma_\eta^2) \rightarrow (\sigma_\epsilon^2, q), \quad q = \sigma_\eta^2 / \sigma_\epsilon^2 \quad \text{razão sinal ruído}$$

$$\text{definir } P_t^* = \frac{P_t}{\sigma_\epsilon^2}, \quad F_t^* = \frac{F_t}{\sigma_\epsilon^2}$$

Para esta nova parametrização, o FK difuso será:

$$\rightarrow v_t = y_t - a_t$$

$$\rightarrow a_{t+1} = a_t + k_t v_t$$

$$\text{Logo: } k_t^* = \frac{p_t^*}{f_t^*} = \frac{p_t / \sigma_E^2}{f_t / \sigma_E^2} = \frac{p_t}{f_t} \quad \therefore \boxed{k_t^* = k_t}$$

$$\bullet f_t = p_t + \sigma_E^2$$

$$\therefore \frac{f_t}{\sigma_E^2} = p_t + 1 \quad \therefore \boxed{f_t^* = p_t^* + 1} \quad (\text{depende apenas de } q)$$

$$\rightarrow p_{t+1} = p_t (1 - k_t) + \sigma_\eta^2$$

$$\therefore \frac{p_{t+1}}{\sigma_E^2} = \frac{p_t}{\sigma_E^2} (1 - k_t) + \frac{\sigma_\eta^2}{\sigma_E^2}$$

$$\therefore p_{t+1}^* = p_t^* (1 - k_t) + q$$

Inicialização: $\begin{cases} a_2 = y \\ p_2^* = 1 + q \end{cases}$? devida

Com a nova parametrização, temos H o $\log L_0$:

$$\begin{aligned} \log L_0(\psi) &= -\frac{n}{2} \log 2\pi - \frac{1}{2} \sum_{t=2}^n (\log f_t + v_t^2 / f_t) \quad \left. \vphantom{\sum_{t=2}^n} \right\} F_t = f_t^* \sigma_E^2 \\ &= -\frac{n}{2} \log 2\pi - \frac{1}{2} \sum_{t=2}^n \left(\log f_t^* \sigma_E^2 + \frac{v_t^2}{f_t^* \sigma_E^2} \right) \\ &\quad \quad \quad \downarrow \\ &\quad \quad \quad \log f_t^* + \log \sigma_E^2 \\ &= -\frac{n}{2} \log 2\pi - \frac{1}{2} (n-1) \log \sigma_E^2 - \frac{1}{2} \sum_{t=2}^n \left(\log f_t^* + \frac{v_t^2}{f_t^* \sigma_E^2} \right) \end{aligned}$$

Observe que:

(i) f_t^* e v_t não envolvem σ_E^2

(ii) Maximizando para σ_E^2 :

$$\frac{\partial \log L_D}{\partial \sigma_E^2} = 0 \quad \therefore -\frac{1}{2} (n-1) \frac{1}{\sigma_E^2} + \frac{1}{(\sigma_E^2)^2} \cdot \frac{1}{2} \sum_{t=2}^n \frac{v_t^2}{F_t^*} = 0$$

$$\therefore \frac{1}{\sigma_E^2} \cdot \frac{1}{2} \sum_{t=2}^n \frac{v_t^2}{F_t^*} = \frac{1}{2} (n-1)$$

$$\therefore \left[\hat{\sigma}_E^2 = \left(\frac{1}{n-1} \right) \sum_{t=2}^n \frac{\hat{v}_t^2}{F_t^*} \right]$$

Finalmente, substituindo σ_E^2 por $\hat{\sigma}_E^2$ em $\log L_d(\Psi)$ resulta na log verossimilhança concentrada e difusa, dada por:

$$\log L_{dc}(\Psi) = -\frac{n}{2} \log 2\pi - \frac{1}{2} (n-1) \log \hat{\sigma}_E^2(q) - \frac{1}{2} \sum_{t=2}^n \log F_t^*(q)$$

Assim, na prática, a maximização é realizada apenas com respeito a q , ou seja, a busca dimensional é realizada com uma dimensão em \mathbb{R}^+ pois $q \in (0, \infty)$

→ Steady State (FK estacionário)

Como p_{t+1} não depende de y_t eventualmente: $\lim_{t \rightarrow \infty} p_{t+1} = \bar{p}$

$$p_{t+1} = p_t (1 - K_t) + \sigma_\eta^2 \quad ; \quad K_t = \frac{p_t}{F_t} = \frac{p_t}{p_t + \sigma_E^2}$$

$$\lim_{t \rightarrow \infty} \bar{p} = \bar{p} (1 - \bar{K}) + \sigma_\eta^2 \Rightarrow \text{Equações de Riccati onde } \bar{K} = \frac{\bar{p}}{\bar{p} + \sigma_E^2}$$

$$\bar{p} = \bar{p} \left(1 - \frac{\bar{p}}{\bar{p} + \sigma_E^2} \right) + \sigma_\eta^2$$

$$\bar{p} = \frac{\bar{p}}{\bar{p} + \sigma_E^2} (\bar{p} + \sigma_E^2 - \bar{p}) + \sigma_\eta^2$$

$$\therefore \bar{p} = \frac{\bar{p}}{\bar{p} + \sigma_E^2} \sigma_E^2 + \sigma_\eta^2 \quad \therefore \bar{p}^2 + \bar{p} \sigma_E^2 = \bar{p} \sigma_E^2 + \sigma_\eta^2 \bar{p} + \sigma_\eta^2 \sigma_E^2$$

$$\bar{p}^2 - \sigma_\eta^2 \bar{p} - \sigma_\eta^2 \sigma_E^2 = 0$$

$$\therefore \frac{\bar{p}^2}{(\sigma_E^2)^2} - \frac{\sigma_\eta^2}{\sigma_E^2} \frac{\bar{p}}{\sigma_E^2} - \frac{\sigma_\eta^2}{\sigma_E^2} = 0$$

$$\text{sejam } x = \frac{\bar{p}}{\sigma_E^2} \quad ; \quad h = \frac{\sigma_\eta^2}{\sigma_E^2} \cdot q$$

$$\Rightarrow x^2 - qx - q = 0$$

Soluções: $x = \frac{q \pm \sqrt{q^2 + 4q}}{2} \Rightarrow$ não faz sentido solução > 0 pois $x \in \mathbb{R}^+$.

$$x = \frac{q + \sqrt{q^2 + 4q}}{2}$$

$$\bar{p} = \sigma_E^2 x = \sigma_E^2 \left(\frac{q + \sqrt{q^2 + 4q}}{2} \right)$$

aula 16/04.

Inicializações do FK

Pl estimar MEE via FK, não necessário especificar cond inicial

$$\alpha_t \sim N(a_t, P_t)$$

$p \times 1$ $p \times p$

Pl processos estacionários \Rightarrow cond. inicial perde importância em $t \rightarrow \infty$
" não-estacionários \Rightarrow não é verdade.

A forma de especificar a condição inicial não depende da natureza estacionária da componente do vetor de estado.

Exemplo:

$$\begin{cases} y_t = \mu_t + \psi_t + \varepsilon_t \\ \mu_{t+1} = \mu_t + \eta_t \\ \psi_{t+1} = \phi \psi_t + \zeta_t \end{cases} \Rightarrow y_t = (1 \quad 1) \begin{pmatrix} \alpha_{1,t} \\ \alpha_{2,t} \end{pmatrix} + \varepsilon_t$$
$$\begin{pmatrix} \alpha_{1,t+1} \\ \alpha_{2,t+1} \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & \phi \end{pmatrix} \begin{pmatrix} \alpha_{1,t} \\ \alpha_{2,t} \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \eta_t \\ \zeta_t \end{pmatrix}$$

$\Rightarrow \alpha_{1,t} = \mu_t$ é não-estacionário

$\alpha_{2,t} = \psi_t$ é estacionário

\rightarrow Quando a componente for estacionária, estas é natural que a distribuição inicial seja incondicional deste elemento no vetor de estado.

(É a dist. de LP do processo. No LP \Rightarrow processo converge p/ esta condição).

No exemplo:

Dist. incondicional AB(1)

$$\begin{cases} \rightarrow E[\psi_{t+1}] = \phi E[\psi_t] \\ \text{como } E[\psi_{t+1}] = E[\psi_t] = \mu \Rightarrow \mu = \phi \mu \dots \mu = 0 \\ \text{(queremos média 0).} \\ \rightarrow \text{var}[\psi_{t+1}] = \phi^2 \text{var}[\psi_t] + \sigma_\eta^2 \\ \text{como } \text{var}[\psi_{t+1}] = \text{var}[\psi_t] = \sigma_\psi^2 \Rightarrow \sigma_\psi^2 = \phi^2 \sigma_\psi^2 + \sigma_\eta^2 \\ \text{(queremos var. ck.)} \end{cases}$$
$$\therefore \sigma_\psi^2 = \frac{\sigma_\eta^2}{1 - \phi^2}$$

obs: Pl autocovar, temos: $E[\psi_t \psi_{t+h}] = \phi^h \cdot \frac{\sigma_\eta^2}{(1 - \phi^2)}$

Assim, a dist. incondicional de $\Psi_{t+1} \sim N(0, \sigma_\eta^2 / (1 - \phi^2))$

Do vetor $\alpha_{1,1} = (\alpha_{1,1}, \alpha_{2,1}) \Rightarrow \alpha_{2,1} = 0$

$p_{2,1} = \frac{\sigma_\eta^2}{(1 - \phi^2)}$ } atencas!
cond. inicial deve ser
funças de parâmetros
desconhecidos \Rightarrow estimados
por mv.

De forma geral, as todas componentes de α_t forem estacionárias:
(ou subvetor de α_t), a dist. incondicional será dada por:

$$\alpha_{t+1} = T\alpha_t + R\eta_t \quad \eta_t \sim N(0, \Phi) \rightarrow \left\{ \begin{array}{l} \text{PI se estacionário, sistema} \\ \text{tem que ser invariante} \\ \text{no tempo.} \end{array} \right.$$

Supondo $|\lambda_i(T)| < 1 \quad i=1, \dots, p$

$$\Rightarrow E[\alpha_{t+1}] = TE[\alpha_t] \Rightarrow E[\alpha_t] = 0.$$

$$\text{Var}(\alpha_{t+1}) = T\text{Var}(\alpha_t)T' + R\Phi R'$$

$$\begin{aligned} \therefore \text{vec}[\text{Var}(\alpha_{t+1})] &= \text{vec}[T\text{Var}(\alpha_t)T'] + \text{vec}[R\Phi R'] \\ &= (T \otimes T) \text{vec}[\text{Var}(\alpha_t)] + R \otimes R' \text{vec}[\Phi] \end{aligned}$$

$$(I - T \otimes T) \text{vec}[\text{Var}(\alpha_t)] = [R \otimes R' \text{vec}(\Phi)]$$

$$\text{vec}[\text{Var}(\alpha_t)] = [I - T \otimes T]^{-1} [R \otimes R' \text{vec}(\Phi)]$$

Dúvida
como
calcula
na prática

$$\Rightarrow \underset{p \times 1}{a_1} \sim N \left(\underset{p \times 1}{0}, \underset{p \times p}{\text{Var}(\alpha_t)} \right)$$

(T e Φ podem envolver parâmetros desconhecidos, a serem estimados por mv).

→ Para as componentes não estacionárias, pode-se adotar uma distribuição difusa (ou prior difusa). Na ausência de informações iniciais, é razoável supor que todos os valores de α_t são equiprováveis.

Densidade seria como uma uniforme nos reais.

$$\alpha_{1,1} \sim N(a_{1,1}, p_{1,1}) \text{ onde } a_{1,1} \text{ é arbitrário (geralmente } = 0)$$

$$p_{1,1} = k, \quad k \rightarrow \infty$$

(Big Kappa)

$$\text{Como } \int_{-\infty}^{\infty} f(\alpha_{1,1}) d\alpha_{1,1} \rightarrow \infty \text{ (quando } k \rightarrow \infty) \Rightarrow \text{digamos que é impróprio}$$

1) Big Kappa

Isto terá efeito apenas localizado no FK.

Ele será bem definido para $t = d+1, d+2, \dots, n$ onde d é a dimensão do sub-vetor nas estações de α_t .

Exemplo: Nível local

$$y_t = \mu_t + \varepsilon_t$$

$$\mu_{t+1} = \mu_t + \eta_t$$

$$\mu_1 = \alpha_1 \sim N(a_1, P_1)$$

$$a_1 = 0$$

$$P_1 = K, K \rightarrow \infty$$

Equações de FK H este modelo:

$$a_{t+1} = a_t + k_t v_t$$

$$P_{t+1} = (1 - k_t) P_t + \sigma_\eta^2$$

$$v_t = y_t - a_t$$

$$k_t = \frac{P_t}{F_t} = \frac{P_t}{P_t + \sigma_\varepsilon^2}$$

$$Z = 1$$

$$T = 1$$

$$R = 1$$

$$K = T M F^{-1}$$

$$F_t = 2 P_t Z' + H$$

$$= P_t + \sigma_\varepsilon^2$$

$$M = P_t Z_t' = P_t$$

$$\Rightarrow K = \frac{P_t}{P_t + \sigma_\varepsilon^2}$$

$$T.P.L = \frac{1}{1 - k_t} \frac{\sigma_\varepsilon^2}{P_t} + \sigma_\eta^2$$

• Para $t = 1$:

$$a_2 = a_1 + k_1 v_1, \quad v_1 = y_1 - a_1$$

$$k_1 = \frac{P_1}{P_1 + \sigma_\varepsilon^2}$$

$$\therefore a_2 = a_1 + \left(\frac{P_1}{P_1 + \sigma_\varepsilon^2} \right) (y_1 - a_1)$$

$$e \quad P_2 = (1 - k_1) P_1 + \sigma_\eta^2 = \left(\frac{\sigma_\varepsilon^2}{P_1 + \sigma_\varepsilon^2} \right) P_1 + \sigma_\eta^2 \quad \left\{ \begin{array}{l} P_1 = K \\ a_1 = 0 \end{array} \right.$$

Quando $K \rightarrow \infty$:

$$\begin{cases} a_2 = a_1 + (y_1 - a_1) = y_1 \\ P_2 = \sigma_\varepsilon^2 + \sigma_\eta^2 \end{cases}$$

pois $\frac{P_1}{P_1 + \sigma_\varepsilon^2} \rightarrow 1$ quando $P_1 = K \rightarrow \infty$.

Em $t = 1$:

$$\begin{cases} a_2 = y_1 \\ P_2 = \sigma_\varepsilon^2 + \sigma_\eta^2 \end{cases}$$

\Rightarrow densidade $p(\alpha_{t+1} | y_t)$ bem definida, própria.

Pl $t = 2, 3, \dots$ não há problema pl calcular FK

É como esquecer 1º passo e começar FK pl $t = 2$

(*)

\Rightarrow Fazer pl
tendência local
e ver que a
partir de $t = 3$
teremos
pl bem
definida

Big Kappa \Rightarrow pode \bar{n} ser estatisticamente computacionalmente
erros de arredondamento.

2) Inicia
ligação
Exata

outra forma:

Realizar expansões de produtos de matrizes de FK em termos
de k^{-1} e reter apenas os primeiros 2 ou 3 termos.

fazer $k \rightarrow \infty$ e obter termo dominante.

Expressão Geral $\eta \alpha_t$:

$$\alpha_t = a + A\delta + R_0\eta_0$$

\downarrow \downarrow \downarrow \downarrow
 $m \times 1$ $m \times q$ $q \times 1$ $m \times (m-q)$
 conteúdo $\eta_0 \sim N(0, \Phi_0)$

A, R_0 : matrizes de Keras

$R_0\eta_0$: cond. inicial de
componente estocástica

δ : desvio.

(Das m componentes $\rightarrow q$ não estác.
 $m-q$ estác.)

Obs: se todos os elementos de α_t são estacionários $E(\alpha_t)$ e $Var(\alpha_t)$
podem ser obtidos através dos parâmetros do modelo.

Exemplo: (modelo \bar{n} estacionário)

$$\left\{ \begin{array}{l} y_t = \mu_t + \rho_t + \varepsilon_t \\ \mu_{t+1} = \mu_t + v_t + \xi_t \\ v_{t+1} = v_t + \eta_t \\ \rho_{t+1} = \phi \rho_t + \tau_t \end{array} \right. \quad \begin{array}{l} \text{tendência linear local} \\ \\ \\ \text{(resíduo AR(1)) pois nem sempre componentes} \\ \text{são suficientes para explicar variações} \\ \text{da série.} \end{array}$$

componente estacionária de ordem 1

$$y_t = (1 \ 1 \ 0) \begin{pmatrix} \rho_t \\ \mu_t \\ v_t \end{pmatrix} + \varepsilon_t$$

$$\begin{pmatrix} \rho_{t+1} \\ \mu_{t+1} \\ v_{t+1} \end{pmatrix} = \begin{pmatrix} \phi & 0 & 0 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} \rho_t \\ \mu_t \\ v_t \end{pmatrix} + \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} \tau_t \\ \xi_t \\ \eta_t \end{pmatrix}$$

⊛

Adolar difusa $\alpha_1 \sim N(0, \kappa)$ $\kappa \rightarrow \infty$ ou $t=1$

equivale a

$$y_1 \neq 0 \text{ tal que } y_1 = \alpha_1 + \epsilon_1 \Rightarrow \alpha_1 = y_1 - \epsilon_1$$

$$E[\alpha_1] = y_1 \quad (\neq 0)$$

$$\text{Var}(\alpha_1) = \sigma_\epsilon^2$$

$$\Rightarrow \alpha_1 \sim N(y_1, \sigma_\epsilon^2)$$

$$\text{Como } \alpha_{t+1} = \alpha_t + \eta_t \Rightarrow \alpha_2 = \alpha_1 + \eta_1$$

$$E[\alpha_2] = E[\alpha_1] = y_1$$


$$\begin{aligned} \text{Var}(\alpha_2) &= \text{Var}(\alpha_1) + \text{Var}(\eta_1) \\ &= \sigma_\epsilon^2 + \sigma_\eta^2 \end{aligned}$$

Logo: & a partir de $t=2$, usamos $\alpha_2 \sim N(y_1, \sigma_\epsilon^2 + \sigma_\eta^2)$ teremos o mesmo resultado do FK difuso $\alpha_1 \sim N(0, \kappa)$

\Rightarrow numa situaç es mais geral, onde α_t possui v rias componentes nas relacion rias, a cond. inicial difusa ser  dada por:

$$\alpha_1 \sim N \left[\begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}, \kappa \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \right] \text{ ou } \alpha_1 \sim N(0, \kappa I_p) \quad \kappa \rightarrow \infty$$

\Rightarrow fazer exerc cio p  tend ncia linear local e mostrar que p  $t=3, 4, \dots$ as eqs. de FK s o bem definidas.



μ_t e γ_t - variáveis estacionárias

$$\left. \begin{aligned} p_t \text{ - estacionária } (|\phi| < 1) \rightarrow E(p_t) = 0 \\ \text{var}(p_t) = \frac{\sigma_\varepsilon^2}{(1-\phi^2)} \end{aligned} \right\} p_t \sim N(0, \sigma_\varepsilon^2 / (1-\phi^2))$$

$$\Rightarrow \alpha_t = a + A\delta + R_0\eta_0, \quad \eta_0 \sim N(0, Q_0) \quad (I)$$

$$\begin{pmatrix} p_t \\ \mu_t \\ \gamma_t \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} + \underbrace{\begin{pmatrix} 0 & 0 \\ 1 & 0 \\ 0 & 1 \end{pmatrix}}_{\text{matriz de seleção; zero comp. estacionária}} \tilde{\delta} + \underbrace{\begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}}_{\text{caracteriza componente não estacionária}} \eta_0 \quad ; \quad Q_0 = \frac{\sigma_\varepsilon^2}{(1-\phi^2)}$$

caracteriza componentes estacionárias

$$\tilde{\delta} \text{ é v.a. com } \tilde{\delta} = \begin{pmatrix} \delta_1 \\ \delta_2 \end{pmatrix} \sim N \left[\begin{pmatrix} 0 \\ 0 \end{pmatrix}, K I_2 \right] \quad K \rightarrow \infty.$$

• Para α_t : $\alpha_t \sim N(a_t, P_t)$ da eq. (I).

onde $a_t = E[\alpha_t] = a$ ($= 0$ H modelos variáveis estacionárias)

$$P_t = E[(\alpha_t - a)(\alpha_t - a)'] = A \text{var}(\delta) A' + R_0 Q_0 R_0'$$

$$\therefore P_t = K A A' + R_0 Q_0 R_0' \quad \xrightarrow{K I_2}$$

$$= K P_{\infty} + P_*$$

\downarrow
 associada à parte estacionária associada à parte estacionária

Se não houver componentes estacionárias: $P_* = 0$

$$\Rightarrow \begin{cases} P_{\infty} = A A' \\ P_* = R_0 Q_0 R_0' \end{cases}$$

Pode-se mostrar que (por expansões de Taylor)

$$\rightarrow P_t = K P_{\infty, t} + P_{*, t} + O(K^{-1}) \quad t = 2, 3, \dots, n$$

$\rightarrow P_{\infty, t} \equiv 0$ para algum $t = d$ e assim para $t = d+1, d+2, \dots, n$

utiliza-se K padrão.

Mostra-se que para algum $t=d$ ($d \leq n$): $P_{0,t} = 0$

Assim p/ $t=1, 2, \dots, d$: usa FK inicializações exatas

$t=d+1, \dots, n$: usa FK padrões.

FK

Equações p/ FK exato inicial

para $t=1, 2, 3, \dots, d$

↑
1º momento em que $P_{0,t}$ zera

Equações do FK padrões

para $t=d+1, d+2, \dots, n$ usando $P_{d+1} = P_{*,d+1}$

↓
ou seja, com dados de $P_{*,d}$
 $P_{0,d}$

$$e \quad a_{d+1} = \hat{a}_{d+1}^{(0)}$$

suavizações

~~Algoritmo de suavizações não afetado pelas cond. iniciais exatas~~

(equações de recursões dadas)

⇓

p/ $t=d, d-1, \dots, 1$

Para $t=d+1, \dots, n \Rightarrow$ usam-se equações padrões de suavizações

Exemplo: Tendência linear local.

$$y_t = \begin{pmatrix} 1 & 0 \end{pmatrix} \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} + \epsilon_t, \quad \epsilon_t \sim N(0, \sigma_\epsilon^2)$$

$$\begin{pmatrix} \mu_{t+1} \\ \beta_{t+1} \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \eta_t \\ \xi_t \end{pmatrix}$$

(contas)

$$P_{0,3} = 0$$

calculado em $t=2$ como
previsas $t+1=3$.

Dúvida \Rightarrow $d=3$ (onde zera $P_{0,0}$)

ou $\boxed{d=2}$ (nº de componentes
n não estacionárias)

Estimativas de Parâmetros

- MEE possui um conjunto de parâmetros fixos e desconhecidos (elementos reais das matrizes Z_t, T_t, H_t e Φ_t)

=> Hiperparâmetros (vetor Ψ)

- Estimativas de Ψ usando princípio da verossimilhança

$$\begin{aligned} L(\Psi) &= p(y_1, y_2, \dots, y_n; \Psi) = \\ &= p(y_1, \Psi) \prod_{t=2}^n p(y_t | \tilde{y}_{t-1}; \Psi) \quad \leftarrow \text{ver em demos anteriores.} \\ &= \prod_{t=1}^n p(y_t | \tilde{y}_{t-1}; \Psi) \quad \text{com } p(y_1 | y_0) = p(y_1) \end{aligned}$$

- Da eq. das observações:

$$y_t = Z_t \alpha_t + \varepsilon_t, \quad \varepsilon_t \sim N(0, H_t)$$

$$\Rightarrow E[y_t | \tilde{y}_{t-1}] = Z_t a_t$$

$$\text{var}[y_t | \tilde{y}_{t-1}] = F_t = Z_t P_t Z_t' + H_t$$

$$v_t = y_t - Z_t a_t$$

Como $y_t | \tilde{y}_{t-1}$ é normal:

$$p(y_t | \tilde{y}_{t-1}) = \frac{1}{(2\pi)^{p/2} |F_t|^{1/2}} \exp \left\{ -\frac{1}{2} \underbrace{(y_t - Z_t a_t)'}_{v_t'} \underbrace{F_t^{-1}}_{v_t} (y_t - Z_t a_t) \right\}$$

↓
caso geral é $y_t \sim p \times 1$: multivariado.

contas

$$L(\Psi) = \prod_{t=1}^n \frac{1}{(2\pi)^{p/2} |F_t|^{1/2}} \exp \left\{ -\frac{1}{2} v_t' F_t^{-1} v_t \right\}$$

$$= \left(\frac{1}{(2\pi)^{np/2}} \right) \left(\prod_{t=1}^n |F_t|^{-1/2} \right) \left(\exp \left\{ -\frac{1}{2} \sum_{t=1}^n v_t' F_t^{-1} v_t \right\} \right)$$

$$\ell(\Psi) = \log(L(\Psi)) \quad \therefore \quad \ell(\Psi) = -\frac{np}{2} \log(2\pi) - \frac{1}{2} \sum_{t=1}^n \log |F_t| - \frac{1}{2} \sum_{t=1}^n v_t' F_t^{-1} v_t$$

$$\therefore \ell(\gamma) = -\frac{np}{2} \log(2\pi) - \frac{1}{2} \sum_{t=1}^n (\log |F_t| + v_t' F_t^{-1} v_t)$$



decomposição da verossimilhança em erro de previsões

Atenções!

Devemos estar atentos p/ como a inicialização será tratada no FK pois v_t e F_t (que aparecem em $\ell(\gamma)$) são avaliadas sequencialmente pelo FK.

$$v_t = y_t - z_t' a_t$$

$$F_t = z_t P_t z_t' + H_t$$

Vejamos como cada tratamento de inicialização afeta $\ell(\gamma)$:

a) Inicialização Prior Difusa. (big kappa)

- Enquanto "efeito" da prior difusa estiver atuando no FK
 $\Rightarrow \ell(\gamma)$ não incorpora os valores de a_t e P_t (via F_t e v_t)

Apenas quando $t = d+1$ tal que α_t tem dist. própria e
 que começamos a computar $\ell(\gamma)$. \Rightarrow ou seja, quando a_t, P_t passam a ter valores próprios

Exemplo:

Nível local

$$y_t = \mu_t + \epsilon_t \quad \epsilon_t \sim N(0, \sigma_\epsilon^2) \quad t = 1, 2, \dots, n$$

$$\mu_{t+1} = \mu_t + \eta_t \quad \eta_t \sim N(0, \sigma_\eta^2)$$

Escolhendo $\alpha_1 \sim N(0, K) \quad K \rightarrow \infty$ p/ $t=1 \Rightarrow a_t$ e P_t ainda estarão sob efeito de K

Para $t=2, 3, \dots, n$ não teremos mais problemas.

$$\Rightarrow \ell(\gamma) = -\frac{(n-1)}{2} \log(2\pi) - \frac{1}{2} \sum_{t=2}^n (\log |F_t| + v_t' F_t^{-1} v_t)$$

- Repar: p/ modelos com q componentes não estacionárias no vetor de estados

$$\Rightarrow \ell(\gamma) = -\frac{(n-q)}{2} p \cdot \log(2\pi) - \frac{1}{2} \sum_{t=q+1}^n [\log |F_t| + v_t' F_t^{-1} v_t]$$

obs: a_t e b_t são atualizados via FK de $t=1$ a q , mas não entram em $l(4)$ (via v_t e F_t). Apenas para $t=q+1, \dots, n$ é que passam a entrar no cálculo de $l(4)$

b) Inicialização exata.

Pode-se mostrar que nesse caso $l(4)$ será:

$$l_d(4) = \log L_d(4) = -\left(\frac{np}{2}\right) \log(2\pi) - \frac{1}{2} \sum_{t=1}^d w_t - \frac{1}{2} \sum_{t=d+1}^n [\log |F_t| + v_t' F_t^{-1} v_t]$$

\nearrow usar FK difuso
 \nearrow usar FK padiao

onde $w_t = \begin{cases} \log |F_{\infty,t}| & \text{se } F_{\infty,t} \text{ é pos. definida} \\ \log |F_{\infty,t}| + v_t^{(0)'} F_{\infty,t}^{-1} v_t^{(0)} & \text{se } F_{\infty,t} = 0. \end{cases}$

Prova:

Ponto de partida é definições da verossimilhança difusa

$$l_d(4) = \log L_d(4) = \lim_{k \rightarrow \infty} \left[\log L(4) + \frac{q}{2} \log k \right]$$

\nearrow a contribuição em $l(4)$ de α , é dada por $-\frac{q}{2} \log k$

onde $L(4) = -\frac{np}{2} \log(2\pi) - \frac{1}{2} \sum_{t=1}^n [\log |F_t| + v_t' F_t^{-1} v_t]$


- desmembrar $L(4)$ de $t=1 \dots d$ e $t=d+1, \dots, n$
- Entre $t=1 \dots d$, usamos o FK difuso, considerando as 2 possibilidades $\begin{cases} F_{\infty,t} \text{ pos. definida} \\ F_{\infty,t} = 0. \end{cases}$

a) Quando $F_{\infty,t}$ é pos. def, mostra-se que $\forall t=1, 2, \dots, d$

$$\Rightarrow \lim_{k \rightarrow \infty} [-\log |F_t| + p \log k] = -\log |F_{\infty,t}|$$

$$\lim_{k \rightarrow \infty} v_t' F_t^{-1} v_t = 0.$$

b) Quando



Outros comentários sobre estimações de parâmetros

- Estimados pelo princípio da verossimilhança.

Apresentarei propriedades desejáveis:

a) Não viesadas

$$\lim_{n \rightarrow \infty} E[\hat{\Psi}_n] = \Psi$$

b) consistentes

$$\text{plim } \hat{\Psi}_n = \Psi$$

c) Eficientes

$$\text{var}(\hat{\Psi}_n) \rightarrow \text{LCR}$$

d) Dist. Assintótica Normal

$$\hat{\Psi} \stackrel{a}{\sim} N(\Psi, I^{-1}(\hat{\Psi}))$$

} importante p/ termos
info de IC e TH.

- Para modelo de nível local

→ Duas formas de obter $l(\Psi)$:

(a) Pelo produto das ^{dist de y_t} _{sujeitas em funções de a_t e F_t}

$$p(y_t | y_{t-1}) \sim N(a_t, F_t)$$

$$\text{pois } E[y_t | y_{t-1}] = 2a_t = a_t$$

$$\text{var}[y_t | y_{t-1}] = 2P_t 2' + H = F_t$$

$$= P_t + \sigma_e^2 = F_t$$

$$\text{e } v_t = y_t - a_t$$

$$\therefore p(y_t | y_{t-1}) = \frac{1}{(2\pi F_t)^{1/2}} \exp \left\{ -\frac{1}{2} \frac{(y_t - a_t)^2}{F_t} \right\}$$

$$\therefore p(y) = \prod_{t=1}^n p(y_t | y_{t-1}) = (2\pi F_t)^{-n/2} \exp \left\{ -\frac{1}{2} \sum_{t=1}^n \frac{v_t^2}{F_t} \right\} \cdot \prod_{t=1}^n F_t^{-1/2}$$

$$\Rightarrow \log p(y) = -\frac{n}{2} \log 2\pi - \frac{1}{2} \sum_{t=1}^n \frac{v_t^2}{F_t} - \frac{1}{2} \sum_{t=1}^n \log F_t$$

$$\therefore l(\Psi) = -\frac{n}{2} \log 2\pi - \frac{1}{2} \sum_{t=1}^n (\log F_t + \frac{v_t^2}{F_t})$$

calculados usando F_t

(b) pela representação em y do modelo de nível local

$y \sim N(a, \mathbb{1}, \Sigma)$: Normal multivariado

$$y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$

$$p(y) = \frac{1}{(2\pi)^{n/2}} \cdot \frac{1}{|\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (y - a, \mathbb{1})' \Sigma^{-1} (y - a, \mathbb{1}) \right\}$$

$$\ell(y) = \log p(y) = -\frac{n}{2} \log(2\pi) - \frac{1}{2} \log |\Sigma| - \frac{1}{2} [(y - a, \mathbb{1})' \Sigma^{-1} (y - a, \mathbb{1})]$$

devida quem é C

$$\Sigma = (CFC') \quad \text{e } |C| = 1, \quad CC' = I$$

$$\Sigma^{-1} = (CFC')^{-1} \quad \text{mas } C' = C^{-1}$$

$$= (C')^{-1} F^{-1} C^{-1}$$

$$= C' F^{-1} C$$

$$\therefore \log |\Sigma| = \log |CFC'| = \log (|C| |F| |C'|)$$

$$= \log |F| = \sum \log F_t$$

$$F = \begin{pmatrix} F_1 & & \\ & \ddots & \\ & & F_n \end{pmatrix} \Rightarrow |F| = \prod_{t=1}^n F_t$$

$$\log |F| = \sum \log F_t$$

$$\oplus (y - a, \mathbb{1})' \Sigma^{-1} (y - a, \mathbb{1}) \quad \text{onde } v = C(y - a, \mathbb{1})$$

$$(y - a, \mathbb{1})' C' F^{-1} C (y - a, \mathbb{1})$$

$$v' F^{-1} v = v^2 / F_t$$

$$v' F^{-1} v = (v_1, v_2, \dots, v_n) \begin{pmatrix} F_1^{-1} & & 0 \\ & \ddots & \\ 0 & & F_n^{-1} \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{pmatrix} = \sum_{t=1}^n v_t^2 / F_t$$

→ Inicialização Difusa e MV

$$\log L_D \hat{=} \lim_{P_i \rightarrow \infty} \left(\log L + \frac{1}{2} \log P_i \right) \quad (\text{obs: } P_i = K : \text{Big Kappa})$$

$$= -\frac{n}{2} \log 2\pi - \frac{1}{2} \sum_{t=1}^n \left(\log F_t + v_t^2 / F_t \right) + \frac{1}{2} \log P_i =$$

↓
nas depende de

$$\sigma_E^2, \sigma_1^2, \sigma_\eta^2$$

$$= -\frac{n}{2} \log 2\pi - \frac{1}{2} (\log F_1 + v_1^2/F_1) - \frac{1}{2} \sum_{t=2}^n (\log F_t + v_t^2/F_t) + \frac{1}{2} \log P_1$$

$$\Rightarrow \log L_D = -\frac{n}{2} \log 2\pi - \frac{1}{2} (\log F_1 - \log P_1 + v_1^2/F_1) - \frac{1}{2} \sum_{t=2}^n (\log F_t + v_t^2/F_t)$$

$$= -\frac{n}{2} \log 2\pi - \frac{1}{2} \left(\log \frac{F_1}{P_1} + \frac{v_1^2}{F_1} \right) - \frac{1}{2} \sum_{t=2}^n (\log F_t + v_t^2/F_t)$$

$$= -\frac{n}{2} \log 2\pi - \frac{1}{2} \left(\log \frac{P_1 + \sigma_E^2}{P_1} + \frac{v_1^2}{P_1 + \sigma_E^2} \right) - \frac{1}{2} \sum_{t=2}^n (\log F_t + v_t^2/F_t)$$

Tomando $\lim_{P_1 \rightarrow \infty}$:

$$\lim_{P_1 \rightarrow \infty} \log \frac{P_1 + \sigma_E^2}{P_1} = 0$$

$$\lim_{P_1 \rightarrow \infty} \frac{v_1^2}{P_1 + \sigma_E^2} = 0$$

$$\Rightarrow \log L_D = -\frac{n}{2} \log 2\pi - \frac{1}{2} \sum_{t=2}^n (\log F_t + v_t^2/F_t)$$

Na prática, reparametrizaremos: $\sigma_E^2 = e^{\psi_E}$ onde ψ_E e $\psi_\eta \in \mathbb{R}$
 $\sigma_\eta^2 = e^{\psi_\eta}$

→ Concentrações de MV

⇒ Reparametrizações do modelo em EE para reduzir dimensionalidade da busca

Parâmetros $\sigma_E^2, \sigma_\eta^2 \rightarrow (\sigma_E^2, q)$ onde $q = \sigma_\eta^2 / \sigma_E^2$: razão sinal ruído.

$$\text{Definimos: } P_t^* = \frac{P_t}{\sigma_E^2} \quad \text{e} \quad F_t^* = \frac{F_t}{\sigma_E^2}$$

⇒ Expressões de FK na nova parametrizações

$$v_t = y_t - a_t$$

$$a_{t+1} = a_t + K_t v_t$$

$$P_{t+1} = P_t(1 - K_t) + \sigma_\eta^2$$

$$K_t = \frac{P_t}{F_t} = \frac{P_t / \sigma_E^2}{F_t / \sigma_E^2} = \frac{P_t^*}{F_t^*} = k_t^*$$

$$F_t = P_t + \sigma_E^2 \Rightarrow \frac{F_t}{\sigma_E^2} = \frac{P_t}{\sigma_E^2} + 1 \xrightarrow{\text{depende do } \sigma_E^2} \dots F_t^* = P_t^* + 1$$

$$\frac{p_{t+1}}{\sigma_E^2} = \frac{p_t}{\sigma_E^2} (1 - \kappa_t) + \frac{\sigma_\eta^2}{\sigma_E^2} \quad \dots \quad p_{t+1}^* = p_t^* (1 - \kappa_t) + q$$

Inicializações:

$$\text{Por Big Kappa. quando } \left. \begin{array}{l} a_1 = 0 \\ p_1^* = k \end{array} \right\} \begin{array}{l} a_2 = y_1 \\ p_2^* = 1 + q \end{array}$$

$$\begin{aligned} \text{obs } \textcircled{*} p_2^* &= p_1^* \left(1 - \frac{p_1^*}{F_1^*} \right) + q \\ &= p_1^* \left(1 - \frac{p_1^*}{p_1^* + 1} \right) + q \\ &= p_1^* \left(\frac{1}{p_1^* + 1} \right) + q \end{aligned}$$

$$\text{quando } p_1^* = k \rightarrow \infty \Rightarrow p_2^* = 1 + q \quad \left\{ \begin{array}{l} \text{cond. inicial.} \end{array} \right.$$

$$\textcircled{*} a_2 = a_1 + (y_1 - a_1)$$

$$\text{quando } a_1 = 0 \Rightarrow a_2 = y_1$$

Logo:

$$l_d(\psi) = \log L_d(\psi) = -\frac{n}{2} \log 2\pi - \frac{1}{2} \sum_{t=2}^n (\log F_t + v_t^2 / F_t)$$

substituindo F_t por $F_t^* \sigma_E^2$:

$$\begin{aligned} l_d(\psi) &= -\frac{n}{2} \log 2\pi - \frac{1}{2} \sum_{t=2}^n \left(\log F_t^* \sigma_E^2 + \frac{v_t^2}{F_t^* \sigma_E^2} \right) \\ &\quad \downarrow \\ &= -\frac{n}{2} \log 2\pi - \frac{1}{2} (n-1) \log \sigma_E^2 - \frac{1}{2} \sum_{t=2}^n \left(\log F_t^* + \frac{v_t^2}{F_t^* \sigma_E^2} \right) \end{aligned}$$

Observar que:

$$(i) F_t^* \text{ e } v_t \text{ não envolvem } \sigma_E^2$$

$$(ii) \frac{\partial \log l_d}{\partial \sigma_E^2} = 0 \Rightarrow -\frac{1}{2} (n-1) \frac{1}{\sigma_E^2} + \frac{1}{(\sigma_E^2)^2} \cdot \frac{1}{2} \sum \frac{v_t^2}{F_t^*} = 0$$


$$\therefore \frac{1}{\sigma_E^2} \cdot \frac{1}{2} \sum v_t^2 / F_t^* = \frac{1}{2} (n-1)$$

$$\therefore \hat{\sigma}_E^2 = \left(\frac{1}{(n-1)} \right) \sum_{t=2}^n \hat{v}_t^2 / F_t^*$$

Substituindo $\hat{\sigma}_E^2$ em σ_E^2 em $\log L_d(\psi)$, temos:

$$\log L_{dc}(\psi) = -\frac{n}{2} \log 2\pi - \frac{1}{2} (n-1) \log \hat{\sigma}_E^2(q) - \frac{1}{2} \sum_{t=2}^n \log F_t^*(q)$$

↓
 Maximização será realizada
 apenas com respeito a q .



Otimização Numérica

- $\Psi \in \mathbb{R}^v$
- função objetivo: $l(\Psi) = \log L(\Psi)$, $\Psi \in$ interior do espaço paramétrico
- estimador mv: $\hat{\Psi} = \arg \max_{\Psi \in \mathbb{R}^v} l(\Psi)$

Condições para maximizar uma função:

1) CPO: 1ª ordem (necessária)

$$g(\Psi) = \frac{\partial l}{\partial \Psi} = \left(\frac{\partial l}{\partial \Psi_1}, \frac{\partial l}{\partial \Psi_2}, \dots, \frac{\partial l}{\partial \Psi_v} \right)^T = 0 \quad (\text{gradiente ou vetor nulo})$$

2) CSO: 2ª ordem

$$H(\Psi) = - \frac{\partial^2 l}{\partial \Psi \partial \Psi'} \Big|_{\Psi = \hat{\Psi}} > 0.$$

$$\text{onde } H(\hat{\Psi}) = - \begin{pmatrix} \partial^2 l / \partial \Psi_1^2 & \partial^2 l / \partial \Psi_1 \partial \Psi_2 & \dots & \partial^2 l / \partial \Psi_1 \partial \Psi_v \\ \partial^2 l / \partial \Psi_1 \partial \Psi_2 & \partial^2 l / \partial \Psi_2^2 & \dots & \partial^2 l / \partial \Psi_2 \partial \Psi_v \\ \vdots & \vdots & \ddots & \vdots \\ \partial^2 l / \partial \Psi_1 \partial \Psi_v & \dots & \dots & \partial^2 l / \partial \Psi_v^2 \end{pmatrix}_{v \times v}$$

avaliada em $\Psi = \hat{\Psi}$ (sol. da CPO)

$$\Rightarrow \mathbf{z}' H \mathbf{z} > 0 \quad (\text{ou seja, } H \text{ é matriz positiva definida})$$

Obs: como H é a negativa do Hessiano \Rightarrow positiva definida (e na negativa ")

Ex: p/ $v=2$

$$\mathbf{z} = (z_1, z_2)^T$$

$$\Rightarrow \mathbf{z}' H \mathbf{z} = (z_1, z_2) \begin{pmatrix} h_{11} & h_{12} \\ h_{12} & h_{22} \end{pmatrix} \begin{pmatrix} z_1 \\ z_2 \end{pmatrix} \Rightarrow h_{11} z_1^2 + (h_{12} z_1 z_2) \times 2 + h_{22} z_2^2 > 0.$$

investigar

$$\Rightarrow h_{11} \text{ e } h_{22} > 0 \text{ são}$$

suficientes para garantir H pos. definida.

Difícilmente teremos soluções analíticas.

precisaremos de um método numérico para realizar a otimização

a) Métodos do Gradiente:

Algoritmos de otimização numérica definidos pela seguinte estrutura:

(i) cond. inicial $\Psi(0)$

(ii) forma iterativa que gera aproximações sucessivas $\hat{\Psi}^{(0)}, \hat{\Psi}^{(1)}, \dots, \hat{\Psi}^{(k)}$ para o ótimo $\hat{\Psi}$.

(iii) regra de parada que define o ótimo, ou seja, número máximo de iterações

obs: máx local (nas global) pois $l(\Psi)$ não é geralmente côncava

b) Métodos Quasi-Newton

Expansões de Taylor de $l(\Psi)$ em torno de uma iteração arbitrária $\Psi^{(k)}$:
(de 2ª ordem)

$$l(\Psi) = l(\Psi^{(k)}) + \left(\frac{\partial l}{\partial \Psi^{(k)}} \right)' (\Psi - \Psi^{(k)}) + \frac{1}{2} (\Psi - \Psi^{(k)})' \frac{\partial^2 l}{\partial \Psi^{(k)} \partial \Psi^{(k)}} (\Psi - \Psi^{(k)})$$

$$l = l(\Psi^{(k)}) + g(\Psi^{(k)})' (\Psi - \Psi^{(k)}) - \frac{1}{2} (\Psi - \Psi^{(k)})' H(\Psi^{(k)}) (\Psi - \Psi^{(k)})$$

Por construção: queremos $\frac{\partial l}{\partial \Psi} = 0$ (opo). Logo:

$$\frac{\partial l}{\partial \Psi} = g(\Psi) = g(\Psi^{(k)}) - H(\Psi^{(k)}) (\Psi - \Psi^{(k)}) = 0$$

⋮

Resolvendo para Ψ :

$$\Psi = \Psi^{(k)} + H^{-1}(\Psi^{(k)}) g(\Psi^{(k)})$$

$$\Rightarrow \left| \Psi^{(k+1)} = \Psi^{(k)} + \lambda H^{-1}(\Psi^{(k)}) g(\Psi^{(k)}) \right| \quad \lambda: \text{tamanho do passo.}$$

obs.: 1) Diversos algoritmos existentes: BHHH, BFGS etc.

2) Como $\ell(\psi)$ não é côncava, isto pode trazer problemas na busca do máximo.

→ critérios de Parada:

Normalmente é usado 1 ou mais critérios simultaneamente

(i) critério do gradiente (é o mais usado)

$$c_1 = \frac{\sum_{j=1}^v |g_j(\psi^{(k)})|}{v} < 10\epsilon$$

↳ média dos módulos de $\frac{\partial \ell}{\partial \psi_j}^{(k)}$

(ii) critério da verossimilhança

$$c_2 = \left| \frac{\ell(\psi^{(k)}) - \ell(\psi^{(k+1)})}{\ell(\psi^{(k)})} \right| < \epsilon$$

↳ variações da função de verossim no máximo tem que ser muito pequena.

(iii) critério de parâmetro

$$c_3 = \frac{1}{v} \sum_{j=1}^v \left| \frac{\psi_j^{(k+1)} - \psi_j^{(k)}}{\psi_j^{(k)}} \right| < 100\epsilon$$

↳ média do valor do parâmetro não muda muito (equivale a (ii))

→ Transformações de parâmetros

Alguns parâmetros do MEE podem ter restrições de valores.

Algoritmos de otimização linear \Rightarrow assumem espaço paramétrico \mathbb{R}^v (restrições)

É necessário realizar transformações de parâmetros.

Exemplo: $\psi_1 = \sigma_\epsilon^2 > 0 \Rightarrow$ define-se $\psi_1 = e^{2\theta}$ onde $\theta \in (-\infty, \infty)$

\Rightarrow estimamos $\hat{\theta} \Rightarrow \hat{\psi}_1 = e^{2\hat{\theta}}$

Para MEE, as transformações + úteis são:

parâmetros	restrições	transformações
σ^2	$\sigma^2 > 0$	$\psi = e^{2\theta}$
ρ	$0 < \rho < 1$	$\psi = \theta / \sqrt{1+\theta^2}$
ϕ	$-1 < \phi < 1$	$\psi = \theta / \sqrt{1+\theta^2}$
λ	$0 < \lambda < \pi$	$\psi = 2\pi / (2 + e^\theta)$

→ onde aparece p na FMV, coloca ψ .
 Então $\hat{\theta}$ e calcula $\hat{p} = \frac{|\hat{\theta}|}{\sqrt{1+\hat{\theta}^2}}$

Quando fizermos otimizações numérica, temos $\hat{\theta}$ (não o parâmetro original).

$$\theta^{(k+1)} = \theta^{(k)} + \lambda H^{-1}(\theta^{(k)}) g(\theta^{(k)}) \Rightarrow \text{Teremos o Hessiano avaliado em } \hat{\theta}$$

$$\Rightarrow \hat{\theta} \sim N(\theta, I^{-1}(\theta))$$

$$\text{Incerteza: } \hat{\theta}_j \pm 2 \sqrt{\text{var}(\hat{\theta}_j)}$$

Assintoticamente:

$$\hat{\theta} \sim N(\theta, \frac{I^{-1}(\theta)}{n})$$

→ $\text{var}(\hat{\theta}) = I^{-1}(\theta)$: informações de Fisher

$$\text{onde } I(\theta) = -E\left(\frac{\partial^2 \ell}{\partial \theta \partial \theta'}\right) = E\left(\frac{\partial \ell}{\partial \theta} \frac{\partial \ell}{\partial \theta'}\right)$$

$$\text{onde } \ell = \sum_{t=1}^n \log p(y_t | y_{t-1})$$

$$= -\frac{pn}{2} \ln 2\pi - \frac{1}{2} \sum_{t=1}^n [\ln |F_t| + \frac{1}{F_t}]$$

tem θ

Na prática \Rightarrow difícil termos expressões analíticas para $I(\theta)$

Usaremos no lugar de $I(\theta)$, as seguintes estimativas amostrais:

$$\hat{I}_{2D} = -\frac{1}{n} \frac{\partial^2 \ell}{\partial \theta \partial \theta'} \Big|_{\theta=\hat{\theta}} = -\frac{1}{n} \sum_{t=1}^n \frac{\partial^2 \ell_t}{\partial \theta \partial \theta'} \Big|_{\theta=\hat{\theta}}$$

ou

$$\hat{I}_{op} = \frac{1}{n} \frac{\partial \ell}{\partial \theta} \frac{\partial \ell}{\partial \theta'} \Big|_{\theta=\hat{\theta}} = \frac{1}{n} \sum_{t=1}^n \frac{\partial \ell}{\partial \theta} \frac{\partial \ell}{\partial \theta'} \Big|_{\theta=\hat{\theta}}$$

$$\Rightarrow \text{var}(\hat{\theta}) = E[(\hat{\theta} - \theta)(\hat{\theta} - \theta)'] = \frac{\hat{I}^{-1}(\theta)}{n}$$

Na prática, o cálculo de $g(\theta) = d\ell/d\theta$, H e \hat{I} podem ser realizadas através de 2 procedimentos no caso de MEE:

i) utilizando derivadas numéricas

$$\frac{d\ell}{d\psi_i} = \lim_{h \rightarrow 0} \frac{\ell(\psi_i + h) - \ell(\psi_i)}{h}$$

⇒ fazer H muito local

ii) semi-analiticamente ⇒ em mente: queremos calcular $\left[\frac{d\ell}{d\psi_i} \right]$

$$\ell(\psi) = \log L(\psi)$$

mas $L(\psi) = p(y; \psi)$; $y = (y_1, y_2, \dots, y_n)$

$$p(y, \alpha; \psi) = p(\alpha|y; \psi) \cdot p(y; \psi) \quad \text{---} \quad p(A|B) = \frac{p(A \cap B)}{p(B)}$$

$$\therefore \log p(y, \alpha; \psi) = \log p(\alpha|y; \psi) + \log p(y; \psi)$$

$$\therefore \boxed{\frac{\log p(y; \psi)}{\ell(\psi)} = \log p(y, \alpha; \psi) - \log p(\alpha|y; \psi)} \quad (I)$$

outra forma de escrever $\ell(\psi)$
em funç. de prod. conjunta
e condicional.

Seja $\tilde{E} = E[\cdot]$ em relação à densidade $p(\alpha|y; \psi)$

$$\Rightarrow \tilde{E}[\log p(y; \psi)] = \tilde{E}[\log p(y, \alpha; \psi)] - \tilde{E}[\log p(\alpha|y; \psi)]$$

$$\boxed{\log p(y; \psi) = \tilde{E}[\log p(y, \alpha; \psi)] - \tilde{E}[\log p(\alpha|y; \psi)]} \quad (II)$$

pois $p(y; \psi)$ não depende de α

score $\therefore \left[\frac{d\ell}{d\psi} \right]_{\psi=\tilde{\psi}} = \left[\frac{d \log L(\psi)}{d\psi} \right]_{\psi=\tilde{\psi}} = \left[\frac{d \log p(y; \psi)}{d\psi} \right]_{\psi=\tilde{\psi}} = \tilde{E} \left[\frac{d \log p(y, \alpha; \psi)}{d\psi} \right]_{\psi=\tilde{\psi}} - \underbrace{\tilde{E} \left[\frac{d \log p(\alpha|y; \psi)}{d\psi} \right]_{\psi=\tilde{\psi}}}_{(B)}$

→ Calculamos (B) = ?

$$B = \tilde{E} \left[\frac{d \log p(\alpha|y; \psi)}{d\psi} \right] = \int_{\mathbb{R}} \frac{d \log p(\alpha|y; \psi)}{d\psi} \cdot p(\alpha|y; \tilde{\psi}) d\alpha$$

$$= \int \frac{1}{p(\alpha|y; \psi)} \cdot \frac{dp(\alpha|y; \psi)}{d\psi} \cdot p(\alpha|y; \tilde{\psi}) d\alpha = \int \frac{dp(\alpha|y; \psi)}{d\psi} d\alpha =$$

Dividir por sua
probabilidade
para aparecer na
expressão?
fica + fácil de
derivar em ψ ?

Escreve score
como funç.
de dens.
conjunta
e condicional
($\alpha|y$)

III

$$= \frac{\partial}{\partial \Psi} \underbrace{\int p(\alpha|y) d\alpha}_{=1} = \frac{\partial}{\partial \Psi} 1 = 0$$

Logo, de III:

$$\left[\underbrace{\frac{\partial \log p(y; \Psi)}{\partial \Psi}}_{\text{score}} \right]_{\Psi=\tilde{\Psi}} = \tilde{\mathbb{E}} \left[\underbrace{\frac{\partial \log p(y, \alpha; \Psi)}{\partial \Psi}}_{(A)} \right]_{\Psi=\tilde{\Psi}} \quad \text{IV}$$

→ Precisamos calcular (A)

calculamos $p(y, \alpha; \Psi)$:

$$p(y, \alpha; \Psi) = p(y|\alpha; \Psi) p(\alpha; \Psi)$$

• cálculo de $p(y|\alpha; \Psi)$

$$p(y|\alpha; \Psi) = p(\underbrace{y_n}_{A}, \underbrace{y_{n-1}}_{B}, \dots, y_1 | \underbrace{\alpha_n \alpha_{n-1} \dots \alpha_1}_C)$$

$$= p(y_n | y_{n-1}, \dots, y_1, \underbrace{\alpha_n}_{\downarrow} = \alpha_1) p(y_{n-1}, \dots, y_1 | \alpha_n \dots \alpha_1)$$

como processo é Markoviano, só importa α_n

$$= p(y_n | \alpha_n) \cdot p(y_{n-1} y_{n-2} \dots y_1 | \alpha_n \alpha_{n-1} \dots \alpha_1)$$

iterativamente

$$= p(y_n | \alpha_n) \cdot p(y_{n-1} | \alpha_{n-1}) \cdot \dots \cdot p(y_1 | \alpha_1)$$

$$\Rightarrow \boxed{p(y|\alpha; \Psi) = \prod_{t=1}^n p(y_t | \alpha_t)}$$

• cálculo de $p(\alpha; \Psi)$

Também pela propriedade de processo Markoviano e uma manipulação anterior:

$$\boxed{p(\alpha; \Psi) = \prod_{t=1}^n p(\alpha_t | \alpha_{t-1}; \Psi)}$$

$$\text{Logo: } \boxed{p(y, \alpha; \Psi) = \prod_{t=1}^n p(y_t | \alpha_t; \Psi) \cdot p(\alpha_t | \alpha_{t-1}; \Psi)} \quad \text{V}$$

Escrever
longeja
como condicional
de $y|\alpha$ e mg
de α

$$\therefore \left[\log p(y, \alpha; \Psi) = \sum_{t=1}^n \log p(y_t | \alpha_t; \Psi) + \log p(\alpha_t | \alpha_{t-1}; \Psi) \right] \quad \text{VI}$$

Consideremos um MEE linear e Gaussiano:

$$\begin{cases} y_t = z_t \alpha_t + \varepsilon_t & \varepsilon_t \sim N(0, H_t) & (a) \\ \alpha_{t+1} = T_t \alpha_t + R_t \eta_t & \eta_t \sim N(0, Q_t) & (b) \end{cases}$$

cálculo de $\log p(y_t | \alpha_t)$

$$p(y_t | \alpha_t)$$

$$\mu(a): E[y_t | \alpha_t] = z_t \alpha_t$$

$$V[y_t | \alpha_t] = \text{var}(\varepsilon_t) = H_t$$

$$\Rightarrow p(y_t | \alpha_t) \sim N(z_t \alpha_t, H_t)$$

$$p(y_t | \alpha_t) = \frac{1}{(2\pi)^{p/2} |H_t|^{1/2}} \exp \left\{ -\frac{1}{2} (\overbrace{y_t - z_t \alpha_t}^{\varepsilon_t})' H_t^{-1} (\overbrace{y_t - z_t \alpha_t}^{\varepsilon_t}) \right\}$$

$$\therefore \left[\log p(y_t | \alpha_t) = -\frac{p}{2} \log(2\pi) - \frac{1}{2} \log |H_t| - \frac{1}{2} [\varepsilon_t' H_t^{-1} \varepsilon_t] \right] \quad \text{VII}$$

cálculo de $\log p(\alpha_t | \alpha_{t-1})$

$$\textcircled{D} \cdot p(\alpha_t | \alpha_{t-1})$$

$$\mu(b): E[\alpha_t | \alpha_{t-1}] = T_{t-1} \alpha_{t-1}$$

$$V[\alpha_t | \alpha_{t-1}] = R_{t-1} Q_{t-1} R_{t-1}'$$

$$\Rightarrow p(\alpha_t | \alpha_{t-1}) \sim N(T_{t-1} \alpha_{t-1}, R_{t-1} Q_{t-1} R_{t-1}')$$

Atenção!

está seria a variância, mas
nós podemos escrever assim pois
nós sabemos o determinante existe

Se pudermos escrever assim:

$$p(\alpha_t | \alpha_{t-1}) = \frac{1}{(2\pi)^{m/2} |R_{t-1} Q_{t-1} R_{t-1}'|^{1/2}} \exp \left\{ -\frac{1}{2} (\alpha_t - T_{t-1} \alpha_{t-1})' (R_{t-1} Q_{t-1} R_{t-1}')^{-1} (\alpha_t - T_{t-1} \alpha_{t-1}) \right\}$$

$$\log p(\alpha_t | \alpha_{t-1}) = -\frac{m}{2} \log(2\pi) - \frac{1}{2} \log |R_{t-1} Q_{t-1} R_{t-1}'| -$$

$$-\frac{1}{2} [(\alpha_t - T_{t-1} \alpha_{t-1})' (R_{t-1} Q_{t-1} R_{t-1}')^{-1} (\alpha_t - T_{t-1} \alpha_{t-1})]$$

Atenções

Em modelos Estruturais, a matriz R será uma matriz de flecos (apenas 0's e 1's)

$$\Rightarrow R_t = [I_n \ 0']'$$

onde I_n é matriz identidade e $0'$ é matriz de zeros.

$$\text{Portanto: } R_t' R_t = I_n$$

Exemplo:

Modelo Estrutural básico:

Tendência linear estocástica + racionalidade estocástica via dummies

$S=4$ (obs. trimestrais)

$$\Rightarrow y_t = \mu_t + \gamma_t + \varepsilon_t$$

$$\mu_{t+1} = \mu_t + \beta_t + \eta_t$$

$$\beta_{t+1} = \beta_t + \xi_t$$

$$\gamma_{t+1} = -(\gamma_t + \gamma_{t-1} + \gamma_{t-2}) + \omega_t$$

Escrevendo em EE:

$$y_t = [1 \ 0 \ 1 \ 0 \ 0] \begin{bmatrix} \mu_t \\ \beta_t \\ \gamma_t \\ \gamma_{t-1} \\ \gamma_{t-2} \end{bmatrix} + \varepsilon_t$$

$$\begin{bmatrix} y_t \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & -1 & -1 & -1 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} \mu_t \\ \beta_t \\ \gamma_t \\ \gamma_{t-1} \\ \gamma_{t-2} \end{bmatrix} + \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} \varepsilon_t \\ \eta_t \\ \xi_t \end{bmatrix}$$

$n=3$
 $m \times n$

$$\Rightarrow R_t = \begin{bmatrix} I_n \\ 0 \end{bmatrix} = [I_n \ 0']'$$

$$\Rightarrow \underset{n \times m}{R_t'} \underset{m \times n}{R_t} = \underset{(3 \times 3)}{I_{n \times n}}$$

$$m=5$$

$$n=3$$

Olhando a expressão $p(RQR')$ na verossimilhança de $\alpha_t | \alpha_{t-1}$:

$$RQR' = \begin{bmatrix} I_n \\ 0' \end{bmatrix} \Phi_{n \times n} \begin{bmatrix} I_n & 0' \end{bmatrix} = \Phi_{n \times n}$$

No exemplo, como $m > n \Rightarrow$ densidade não existente pois

$$|RQR'| = 0.$$

Para solucionar \Rightarrow utiliza Jacobiano na transformação de densidade de η_t para de $\alpha_t | \alpha_{t-1}$.

$$\alpha_t = T_{t-1} \alpha_{t-1} + R_{t-1} \eta_{t-1}$$

$$R_{t-1} \eta_{t-1} = \alpha_t - T_{t-1} \alpha_{t-1}$$

$$\therefore \underbrace{R_{t-1}' R_{t-1}}_I \eta_{t-1} = R_{t-1}' (\alpha_t - T_{t-1} \alpha_{t-1})$$

$$\eta_{t-1} = R_{t-1}' (\alpha_t - T_{t-1} \alpha_{t-1})$$

Realizando o procedimento da transformação corretamente:

$$p(\alpha_t | \alpha_{t-1}) = \frac{1}{(2\pi)^{m/2}} \frac{1}{|Q_{t-1}|^{1/2}} \exp \left\{ -\frac{1}{2} \eta_{t-1}' Q_{t-1}^{-1} \eta_{t-1} \right\}$$

$$\therefore \left| \log(p(\alpha_t | \alpha_{t-1})) = -\frac{m}{2} \log 2\pi - \frac{1}{2} \log |Q_{t-1}| - \frac{1}{2} \left\{ \eta_{t-1}' Q_{t-1}^{-1} \eta_{t-1} \right\} \right|$$

De VII e VIII em VI:

$$\log p(y, \alpha; \Psi) = \text{cte} - \frac{1}{2} \sum_{t=1}^{\tilde{n}} (\log |H_t| + \log |Q_t| + \varepsilon_t' H_t^{-1} \varepsilon_t + \eta_{t-1}' Q_{t-1}^{-1} \eta_{t-1})$$

encontrando: Termos que calculam vetor de score.

$$\left. \frac{\partial \ell}{\partial \Psi} \right|_{\Psi=\tilde{\Psi}} = \tilde{E} \left[\left. \frac{\partial}{\partial \Psi} \log p(y, \alpha; \Psi) \right|_{\Psi=\tilde{\Psi}} \right]$$

$$= E \left[\left. \frac{\partial}{\partial \Psi} \log p(y, \alpha; \Psi) \right| y \right] \Big|_{\Psi=\tilde{\Psi}}$$

\downarrow
valor esperado condicional

$$\frac{\partial}{\partial \Psi} \log p(\alpha, y; \Psi) = -\frac{1}{2} \frac{\partial}{\partial \Psi} \sum_{t=1}^n (\log |H_t| + \log |Q_t| + \varepsilon_t' H_t^{-1} \varepsilon_t + \eta_{t-1}' Q_{t-1}^{-1} \eta_{t-1})$$

$$\therefore \left. \frac{\partial \ell}{\partial \Psi} \right|_{\Psi=\tilde{\Psi}} = E \left[-\frac{1}{2} \frac{\partial}{\partial \Psi} \sum_{t=1}^n (\log |H_t| + \log |Q_t| + \varepsilon_t' H_t^{-1} \varepsilon_t + \eta_{t-1}' Q_{t-1}^{-1} \eta_{t-1}) \mid y \right]_{\Psi=\tilde{\Psi}}$$

$$= -\frac{1}{2} \frac{\partial}{\partial \Psi} \sum \left[\log |H_t| + \log |Q_t| + \underbrace{E[\varepsilon_t' H_t^{-1} \varepsilon_t \mid y]}_{(A1)} + \underbrace{E[\eta_{t-1}' Q_{t-1}^{-1} \eta_{t-1} \mid y]}_{(A2)} \right]_{\Psi=\tilde{\Psi}}$$

(A1)

(A2)

Atenções!
É condicional.

Obs: três resultados para avaliar (A1) e (A2)

i) Seja $z = x' B x$ uma forma quadrática

$$z = \text{tr}(z) = \text{tr}(x' B x) \\ = \text{tr}(x x' B)$$

ii) $E[z] = E(\text{tr}(z)) = \text{tr}(E[z])$

iii) Se x é vetor aleatório

$$V(x) = E[x x'] - E[x] (E[x])'$$

$$\therefore E[x x'] = V(x) + E[x] (E[x])'$$

→ Cálculo de (A1) e (A2)

$$A_1 = E[\varepsilon_t' H_t^{-1} \varepsilon_t \mid y] = E[\text{tr}(\varepsilon_t \varepsilon_t' H_t^{-1} \mid y)] = \\ = \text{tr}[E(\varepsilon_t \varepsilon_t' H_t^{-1} \mid y)] = \\ = \text{tr}[E(\varepsilon_t \varepsilon_t' \mid y) H_t^{-1}] = \\ = \text{tr}[(\text{var}(\varepsilon_t \mid y) + E[\varepsilon_t \mid y] \cdot E'[\varepsilon_t \mid y]) H_t^{-1}]$$

Mas $E[\varepsilon_t \mid y] = \hat{\varepsilon}_t$: estimativa suavizada de ε_t

$\text{var}(\varepsilon_t \mid y) =$ variância suavizada de ε_t

$$\Rightarrow A_1 = \text{tr}((\hat{\varepsilon}_t \hat{\varepsilon}_t' + \text{var}(\varepsilon_t \mid y)) H_t^{-1})$$

A forma análoga: $A_2 = \text{tr}((\hat{\eta}_{t-1} \hat{\eta}_{t-1}' + \text{var}(\eta_{t-1} \mid y)) Q_{t-1}^{-1})$

E assim:

$$\frac{\partial \ell}{\partial \Psi} \Big|_{\Psi = \tilde{\Psi}} = -\frac{1}{2} \frac{\partial}{\partial \Psi} \sum_{t=1}^{\infty} \left\{ \log |H_t| + \log |Q_{t-1}| + \tau \left((\hat{E}_t' \varepsilon_t + \text{var}(\varepsilon_t | y)) H_t^{-1} \right) + \tau \left((\eta_{t-1}' \hat{\eta}_{t-1} + \text{var}(\eta_t | y)) \hat{Q}_{t-1}^{-1} \right) \right\} \text{avaliado em } \Psi = \tilde{\Psi}$$

Observar que:

- apenas $H_t(\Psi)$ e $Q_t(\Psi)$ são necessárias a diferenciação com respeito a Ψ
- geralmente, H_t e Q_t são funções simples de Ψ , sendo fácil calcular o vetor de score.
- DK pg 145: Se α , possui apenas elementos difusos, o efeito da inicialização difusa exata desaparece no vetor de score.

Exemplo:

Modelo de nível local

$$\begin{cases} y_t = \mu_t + \varepsilon_t & \varepsilon_t \sim N(0, \sigma_\varepsilon^2) \\ \mu_{t+1} = \mu_t + \eta_t & \eta_t \sim N(0, \sigma_\eta^2) \end{cases}$$

$$H_t = \sigma_\varepsilon^2 = \Psi_1 \quad \Rightarrow \quad \log H_t = \log \Psi_1 \quad \Rightarrow \quad \frac{\partial \log H_t}{\partial \Psi_1} = \frac{1}{\Psi_1} \quad \frac{\partial \log H_t}{\partial \Psi_2} = 0$$


$$Q_t = \sigma_\eta^2 = \Psi_2 \quad \Rightarrow \quad \log Q_t = \log \Psi_2 \quad \Rightarrow \quad \frac{\partial \log Q_t}{\partial \Psi_1} = 0 \quad \frac{\partial \log Q_t}{\partial \Psi_2} = \frac{1}{\Psi_2}$$

Divide

$$\sigma_\varepsilon^2 = \Psi_1 = e^{2\theta}$$

Não deveria usar parâmetros locais aqui

Outra divisão: Na prática, usa ops. de suavização para calcular $\hat{E}_t, \text{var}(\varepsilon_t | y) \dots$



Algoritmo EM

- Procedimento iterativo n maximizações do log da verossimilhança
(n cada iteração, sempre aumenta na direção do ponto de máximo)
 - Apresenta convergência lenta nos últimos passos (trocar por outro algoritmo)
 - Não necessita de 2ª derivada do log da verossimilhança
- ⇒ Ponto de partida: função densidade conjunta

$$\underbrace{L(y_1, y_2, \dots, y_n, \alpha_1, \alpha_2, \dots, \alpha_n; \Psi)}_{p(y, \alpha; \Psi)} = \prod_{t=1}^n p(y_t | \alpha_t) p(\alpha_t | \alpha_{t-1})$$

(calculada na otimização)

log
verossimi-
lhância
conjunta

$$\overset{c}{l}(\Psi) = \log L(y, \alpha; \Psi) =$$

$$= \text{cte} - \frac{1}{2} \sum_{t=1}^n \left[\log |H_t| + \log |Q_{t-1}| + \varepsilon_t' H_t^{-1} \varepsilon_t + \eta_{t-1}' Q_{t-1}^{-1} \eta_{t-1} \right]$$

Score:

$$\frac{\partial l^c}{\partial \Psi} = -\frac{1}{2} \frac{\partial}{\partial \Psi} \sum_{t=1}^n \left[\log |H_t| + \log |Q_{t-1}| + \varepsilon_t' H_t^{-1} \varepsilon_t + \eta_{t-1}' Q_{t-1}^{-1} \eta_{t-1} \right]$$

Resolver $\frac{\partial l^c}{\partial \Psi} = 0$ e achar soluções de n v. os elementos de Ψ

1º passo: Realiza-se o passo E, onde o valor esperado é tomado em função de y (maximização)

$$\begin{aligned} E \left[\frac{\partial l^c}{\partial \Psi} | y \right] &= \left(\frac{\partial l}{\partial \Psi} \right) = -\frac{1}{2} \frac{\partial}{\partial \Psi} \sum_{t=1}^n \left\{ \log |H_t| + \log |Q_{t-1}| + \underbrace{E[\varepsilon_t' H_t^{-1} \varepsilon_t | y]}_{\text{valor esperado afeta aqui}} + E[\eta_{t-1}' Q_{t-1}^{-1} \eta_{t-1} | y] \right\} \\ &= -\frac{1}{2} \frac{\partial}{\partial \Psi} \sum_{t=1}^n \left\{ \log |H_t| + \log |Q_{t-1}| + \kappa [(\hat{\varepsilon}_t' \varepsilon_t + \text{var}(\varepsilon_t | y)) H_t^{-1}] \right. \\ &\quad \left. + \kappa [(\hat{\eta}_{t-1}' \eta_{t-1} + \text{var}(\eta_{t-1} | y)) Q_{t-1}^{-1}] \right\} \Bigg|_{\Psi=y} \end{aligned}$$

Cálculos:

• $\hat{\epsilon}_t, \hat{\eta}_{t-1}, \text{var}(\epsilon_t|y) + \text{var}(\eta_t|y)$ são calculados por $\psi = \tilde{\psi}$
 \hookrightarrow começamos com $\psi^{(0)}$

2º passo: Realizar o passo M; igualando $E(d\ell/d\psi) = 0$.

$$\frac{1}{2} \frac{d}{d\psi} \sum_{t=1}^n \left[\log |H_t| + \log |Q_{t-1}| + \kappa [(\hat{\epsilon}_t' \hat{\epsilon}_t + \text{var}[\epsilon_t|y]) H_t^{-1}] + \right. \\ \left. + \kappa [(\hat{\eta}_t' \hat{\eta}_t + \text{var}[\eta_t|y]) Q_t^{-1}] \right] \Big|_{\psi = \tilde{\psi}} = 0$$

$\psi^{(0)}$

No 1º passo,
 ajustando $\hat{\epsilon}_t, \hat{\eta}_t$,
 $\text{var}[\epsilon_t|y]$
 $\text{var}[\eta_t|y]$

\Rightarrow Nos ajusta H_t e Q_t

\Rightarrow iguala a 0 e acha

expressões m hiperparâmetros \Rightarrow nova estimativa de ψ por ψ^*
 (calculada a base em $\psi^{(0)}$)

Faz-se $\tilde{\psi} = \psi^*$

Repete-se iterativamente passo E e passo M, até convergência

Exemplos: Modelos de nível local

$$\begin{cases} y_t = \mu_t + \epsilon_t \\ \mu_{t+1} = \mu_t + \eta_t \end{cases}$$

$\psi = (\sigma_\epsilon^2, \sigma_\eta^2)'$ \Rightarrow escolha valores iniciais $\tilde{\psi}^{(0)}$

Passo E: começa com $\tilde{\psi}^{(0)}$ e obtém:

$$\begin{cases} \hat{\epsilon}_t = E[\epsilon_t|y] \\ \hat{\eta}_{t-1} = E[\eta_{t-1}|y] \\ \text{var}[\epsilon_t|y] \\ \text{var}[\eta_{t-1}|y] \end{cases} \Rightarrow \text{calculamos usando} \\ \text{FK e suavizações} \\ \text{(DK-20 e 21)}$$

Avalia, com estes valores:

$$\tilde{E}[\log p(y, x; \psi)] = -\frac{1}{2} \sum \left\{ \log \sigma_\epsilon^2 + \log \sigma_\eta^2 + \left[(\hat{\epsilon}_t^2 + \text{var}(\epsilon_t|y)) / \sigma_\epsilon^2 \right] + \right. \\ \left. + \left[\hat{\eta}_t^2 + \text{var}(\eta_t|y) / \sigma_\eta^2 \right] \right\}$$

valores iniciais ajustados

Passo m: $\frac{\partial}{\partial \Psi} \tilde{E}[\log p(y, \alpha; \Psi)] = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$

e achamos novos valores μ σ_ϵ^2 e σ_η^2

$$\Rightarrow \begin{bmatrix} \frac{\partial \tilde{E}[\log p(y, \alpha; \Psi)]}{\partial \sigma_\epsilon^2} \\ \frac{\partial \tilde{E}[\log p(y, \alpha; \Psi)]}{\partial \sigma_\eta^2} \end{bmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

→ Em relação a σ_ϵ^2

$$\frac{\partial \tilde{E}[\cdot]}{\partial \sigma_\epsilon^2} = -\frac{1}{2} \frac{\partial}{\partial \sigma_\epsilon^2} \left[\sum_{t=1}^n \log \sigma_\epsilon^2 + \frac{1}{\sigma_\epsilon^2} (\hat{\epsilon}_t^2 + \text{var}(\epsilon_t|y)) \right]$$

↖ estes valores calculados.

$$= -\frac{1}{2} \left[\frac{n}{\sigma_\epsilon^2} - \frac{1}{\sigma_\epsilon^4} \sum_{t=1}^n [\hat{\epsilon}_t^2 + \text{var}(\epsilon_t|y)] \right] = 0$$

$$\therefore \frac{n}{\sigma_\epsilon^2} - \frac{1}{\sigma_\epsilon^4} \sum_{t=1}^n (\hat{\epsilon}_t^2 + \text{var}(\epsilon_t|y)) = 0$$

$$\therefore \hat{\sigma}_\epsilon^2 = \frac{1}{n} \sum_{t=1}^n [\hat{\epsilon}_t^2 + \text{var}(\epsilon_t|y)]$$

Devido:
calcular
estas expressões
apenas 1 vez.
A partir daí
vai substituindo
recursivamente

usando expressões de DK H cálculo de $\hat{\epsilon}_t^2$ e $\text{var}(\epsilon_t|y)$:

$$\hat{\epsilon}_t = \sigma_\epsilon^2 u_t, \quad u_t = F_t^{-1} v_t - K_t \eta_t$$

$$\text{var}(\epsilon_t|y) = \sigma_\epsilon^2 - \sigma_\epsilon^4 D_t, \quad D_t = F_t^{-1} + K_t^2 N_t$$

$$\Rightarrow \hat{\sigma}_\epsilon^2 = \frac{1}{n} \sum_{t=1}^n \left[\hat{\sigma}_\epsilon^{(0)4} u_t^2 + \hat{\sigma}_\epsilon^{(0)2} - \hat{\sigma}_\epsilon^{(0)4} D_t \right]$$

$$= \frac{1}{n} \sum_{t=1}^n \hat{\sigma}_\epsilon^{(0)4} (u_t^2 - D_t) + \hat{\sigma}_\epsilon^{(0)2}$$

$$\boxed{\hat{\sigma}_\epsilon^2 = \hat{\sigma}_\epsilon^{(0)2} + \frac{\hat{\sigma}_\epsilon^{(0)4}}{n} \sum_{t=1}^n (u_t^2 - D_t)}$$

passo
iti

passo i

→ Em relação a $\hat{\sigma}_\eta^2$

$$\frac{\partial \hat{E}[\cdot]}{\partial \sigma_\eta^2} = -\frac{1}{2} \frac{\partial}{\partial \sigma_\eta^2} \left[\sum_{t=1}^n \log \sigma_\eta^2 + \frac{[\hat{\eta}_{t-1}^2 + \text{var}(\eta_t|y)]}{\sigma_\eta^2} \right]$$

Por analogia:

$$\hat{\sigma}_\eta^2 = \frac{1}{n} \sum (\hat{\eta}_{t-1}^2 + \text{var}(\eta_t|y))$$

usando expressões de DK para cálculo de $\hat{\eta}_t^2$ e $\text{var}(\eta_t|y)$:

$$\hat{\eta}_t = \sigma_\eta^2 \lambda_t \Rightarrow \hat{\eta}_{t-1} = \sigma_\eta^2 \lambda_{t-1}$$

$$\text{var}(\eta|y) = \sigma_\eta^2 - \sigma_\eta^4 \lambda_t \Rightarrow \text{var}(\eta_{t-1}|y) = \sigma_\eta^2 - \sigma_\eta^4 \lambda_{t-1}$$

$$\Rightarrow \hat{\sigma}_\eta^2 = \frac{1}{n-1} \sum_{t=2}^n [\hat{\sigma}_\eta^{4(0)} \lambda_{t-1}^2 + \hat{\sigma}_\eta^{2(0)} - \hat{\sigma}_\eta^{4(0)} \lambda_{t-1}]$$

$$\therefore \boxed{\hat{\sigma}_\eta^2 = \hat{\sigma}_\eta^{2(0)} + \frac{\hat{\sigma}_\eta^{4(0)}}{n-1} \sum_{t=2}^n (\lambda_{t-1}^2 - \lambda_{t-1})}$$

⇒ Esses novos valores são inseridos no passo E e gera-se uma nova maximização, iterativamente, até convergência