


Estudo e comentários Adicionais

M P 1



Exemplos de MEE

Modelo Geral

$$y_t = z_t \alpha_t + d_t + \varepsilon_t \quad \text{equações de medida (ou observação).}$$

$$\alpha_{t+1} = T_t \alpha_t + c_t + R_t \eta_t \quad \text{equações dos estados}$$

Cadeirno

Ex 1) $y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t \Rightarrow AR(2)$

repr. 1

$$y_t = (1 \quad 0) \begin{pmatrix} y_t \\ \phi_2 y_{t-1} \end{pmatrix} \quad \alpha_t$$

AR
 y_t aparece no y
 y_t / y_{t-1} aparece no α
 ε_t aparece no erro.

$$\begin{pmatrix} y_{t+1} \\ \phi_2 y_t \end{pmatrix} = \begin{pmatrix} \phi_1 & 1 \\ \phi_2 & 0 \end{pmatrix} \begin{pmatrix} y_t \\ \phi_2 y_{t-1} \end{pmatrix} + \begin{pmatrix} 1 \\ 0 \end{pmatrix} \varepsilon_{t+1}$$

repr. 2

$$y_t = (1 \quad 0) \begin{pmatrix} y_t \\ y_{t-1} \end{pmatrix} \quad \alpha_t$$

$$\begin{pmatrix} y_{t+1} \\ y_t \end{pmatrix} = \begin{pmatrix} \phi_1 & \phi_2 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} y_t \\ y_{t-1} \end{pmatrix} + \begin{pmatrix} 1 \\ 0 \end{pmatrix} \varepsilon_{t+1}$$

Ex 2) $y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t \Rightarrow AR(p)$

$$y_t = (1 \quad 0 \quad 0 \dots 0) \begin{pmatrix} y_t \\ y_{t-1} \\ \vdots \\ y_{t-p} \end{pmatrix} \quad \alpha_t$$

$$\begin{pmatrix} y_{t+1} \\ y_t \\ \vdots \\ y_{t-p+1} \end{pmatrix} = \begin{pmatrix} \phi_1 & \phi_2 & \dots & \phi_{p-1} & \phi_p \\ 1 & 0 & \dots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & \dots & \dots & 1 & 0 \end{pmatrix} \begin{pmatrix} y_t \\ y_{t-1} \\ \vdots \\ y_{t-p} \end{pmatrix} + \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} \varepsilon_{t+1}$$

Ex 3) $y_t = \theta \varepsilon_{t-1} + \varepsilon_t \Rightarrow$ MA (1)

MA

$$y_t = (1 \quad 0) \begin{pmatrix} y_t \\ \theta \varepsilon_t \end{pmatrix}$$

y_t aparece no y e no x
 ε_t aparece no x e no erro

$$\begin{pmatrix} y_{t+1} \\ \theta \varepsilon_{t+1} \end{pmatrix} = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} y_t \\ \theta \varepsilon_t \end{pmatrix} + \begin{pmatrix} 1 \\ \theta \end{pmatrix} \varepsilon_{t+1}$$

x_{t+1}

~~fica $\theta \varepsilon_{t+1} = \theta \varepsilon_t$?~~

Ex 4) $y_t = \phi y_{t-1} + \theta \varepsilon_{t-1} + \varepsilon_t$

$$y_t = (1 \quad 0 \quad 0) \begin{pmatrix} y_t \\ \phi y_{t-1} \\ \theta \varepsilon_t \end{pmatrix}$$

y_t aparece no y e no x
 y_{t-1} " no x
 ε_t aparece no x e no erro

$$\begin{pmatrix} y_{t+1} \\ \phi y_t \\ \theta \varepsilon_{t+1} \end{pmatrix} = \begin{pmatrix} \phi & 0 & 1 \\ \phi & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} y_t \\ \phi y_{t-1} \\ \theta \varepsilon_t \end{pmatrix} + \begin{pmatrix} 1 \\ 0 \\ \theta \end{pmatrix} \varepsilon_{t+1}$$

~~fica $\theta \varepsilon_{t+1} = \theta \varepsilon_t$~~

para relacionar o do MA

Ex 5) Regressões múltiplas.

$$Z' = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}$$

$$T' = \begin{pmatrix} \phi & \phi & 0 \\ 0 & 0 & 0 \\ 1 & 0 & 0 \end{pmatrix}$$

$$T'Z' = \begin{pmatrix} \phi & \phi & 0 \\ 0 & 0 & 0 \\ 1 & 0 & 0 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} = \begin{pmatrix} \phi \\ 0 \\ 1 \end{pmatrix}$$

$$T^2 = \begin{pmatrix} \phi & \phi & 0 \\ 0 & 0 & 0 \\ 1 & 0 & 0 \end{pmatrix} \begin{pmatrix} \phi & \phi & 0 \\ 0 & 0 & 0 \\ 1 & 0 & 0 \end{pmatrix} = \begin{pmatrix} \phi^2 & \phi^2 & 0 \\ 0 & 0 & 0 \\ \phi & \phi & 0 \end{pmatrix} \Rightarrow T^{2'} = \begin{pmatrix} \phi^2 & 0 & \phi \\ \phi^2 & 0 & \phi \\ 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} = \begin{pmatrix} \phi^2 \\ \phi^2 \\ 0 \end{pmatrix}$$

Hamilton

$$\xi \equiv \alpha$$

$$F \equiv T$$

$$\begin{aligned} \text{state} & \left\{ \begin{aligned} \xi_{t+1} &= F \xi_t + \eta_{t+1} \\ \text{obs} & \left\{ \begin{aligned} y_t &= H' \xi_t + A' x_t + w_t \end{aligned} \right. \end{aligned} \right. \end{aligned}$$

exogenous

$$(\eta_t \equiv \rho_t \eta_t)$$

$$(A' x_t \equiv c_t)$$

$$(w_t \equiv \varepsilon_t)$$

notações

η_t e w_t : ruídos br.

$$E[\eta_t w_t'] = 0$$

$$E[\eta_t \eta_t'] = \begin{cases} Q & t = \tau \\ 0 & t \neq \tau \end{cases} \quad Q: n \times n$$

$$E[w_t w_t'] = \begin{cases} R & t = \tau \\ 0 & t \neq \tau \end{cases} \quad R: m \times m$$

$$E[\eta_t \xi_t'] = 0 \quad \forall t$$

$$E[w_t \xi_t'] = 0 \quad \forall t$$

Ex 1) $(y_{t+1} - \mu) = \phi_1 (y_t - \mu) + \phi_2 (y_{t-1} - \mu) + \dots + \phi_p (y_{t-p+1} - \mu) + \varepsilon_{t+1}$

$$E[\varepsilon_t \varepsilon_t'] = \begin{cases} \sigma^2 & t = \tau \\ 0 & t \neq \tau \end{cases}$$

AR(p)

aparecem em α_t

$$\begin{bmatrix} y_t \\ y_{t-1} \\ y_{t-2} \\ \vdots \\ y_{t-p} \end{bmatrix}$$

$$\alpha_t^* = \begin{bmatrix} y_t \\ y_{t-1} \\ y_{t-2} \\ \vdots \\ y_{t-p} \end{bmatrix}$$

ou melhor

$$\alpha_t = \begin{bmatrix} y_t - \mu \\ y_{t-1} - \mu \\ \vdots \\ y_{t-p} - \mu \end{bmatrix}$$

obs: $y_t = \mu + (1 \ 0 \ \dots \ 0) \begin{bmatrix} y_t - \mu \\ y_{t-1} - \mu \\ \vdots \\ y_{t-p} - \mu \end{bmatrix}$

estado:

$$\begin{bmatrix} y_{t+1} - \mu \\ y_t - \mu \\ y_{t-1} - \mu \\ \vdots \\ y_{t-p+2} - \mu \end{bmatrix} = \begin{bmatrix} \phi_1 & \phi_2 & \dots & \phi_{p-1} & \phi_p \\ 1 & 0 & \dots & 0 & 0 \\ 0 & 1 & \dots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \dots & 1 & 0 \end{bmatrix} \begin{bmatrix} y_t - \mu \\ y_{t-1} - \mu \\ y_{t-2} - \mu \\ \vdots \\ y_{t-p+1} - \mu \end{bmatrix} + \begin{bmatrix} \varepsilon_{t+1} \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

Identidade

Ex. 2)

$$y_t = \mu + \varepsilon_t + \theta \varepsilon_{t-1} \rightarrow \text{MA}(1)$$

ou α entra ε_t
 ε_{t-1}

$$\alpha_t = \begin{bmatrix} \varepsilon_t \\ \varepsilon_{t-1} \end{bmatrix}$$

$$\Rightarrow y_t = \mu + [1 \quad \theta] \begin{bmatrix} \varepsilon_t \\ \varepsilon_{t-1} \end{bmatrix}$$

$$\begin{bmatrix} \varepsilon_{t+1} \\ \varepsilon_t \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \varepsilon_t \\ \varepsilon_{t-1} \end{bmatrix} + \begin{bmatrix} \varepsilon_{t+1} \\ 0 \end{bmatrix}$$

?

Ex. 3) ARMA(p,q) ou ARMA(n, n+1)

$$y_t - \mu = \phi_1(y_{t-1} - \mu) + \phi_2(y_{t-2} - \mu) + \dots + \phi_n(y_{t-n} - \mu) + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_{n-1} \varepsilon_{t-n+1}$$

$$\alpha_t = \begin{bmatrix} y_t - \mu \\ y_{t-1} - \mu \\ \vdots \\ y_{t-n} - \mu \\ \varepsilon_t \\ \varepsilon_{t-1} \\ \vdots \\ \varepsilon_{t-n+1} \end{bmatrix}$$

$$\alpha_t = \begin{bmatrix} y_t - \mu \\ y_{t-1} - \mu \\ \vdots \\ y_{t-n} - \mu \end{bmatrix}$$

estado.

$$\begin{bmatrix} y_{t+n-\mu} \\ y_{t-\mu} \\ \vdots \\ y_{t-n-\mu} \end{bmatrix} = \begin{bmatrix} \phi_1 & \phi_2 & \dots & \phi_{n-1} & \phi_n \\ 1 & 0 & \dots & 0 & 0 \\ 0 & 1 & \dots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & \dots & \dots & 1 & 0 \end{bmatrix} \begin{bmatrix} y_{t-\mu} \\ y_{t-1-\mu} \\ \vdots \\ y_{t-n-\mu} \end{bmatrix} + \begin{bmatrix} \varepsilon_{t+1} \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

obs

$$y_{t-\mu} = [1 \quad \theta_1 \quad \theta_2 \quad \dots \quad \theta_{n-1}] \begin{bmatrix} y_{t-\mu} \\ y_{t-1-\mu} \\ \vdots \\ y_{t-n-\mu} \end{bmatrix}$$

dividindo: ARMA

estado

$$\begin{bmatrix} \alpha_{t+1,1} \\ \alpha_{t+1,2} \\ \alpha_{t+1,3} \\ \vdots \\ \alpha_{t+1,n} \end{bmatrix} = \begin{bmatrix} \phi_1 & \phi_2 & \dots & \phi_{n-1} & \phi_n \\ 1 & 0 & \dots & 0 & 0 \\ 0 & 1 & \dots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \dots & 1 & 0 \end{bmatrix} \begin{bmatrix} \alpha_{t,1} \\ \alpha_{t,2} \\ \vdots \\ \alpha_{t,n} \end{bmatrix} + \begin{bmatrix} \varepsilon_{t+1} \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

1ª linha: $\alpha_{t+1,1} = \phi_1 \alpha_{t,1} + \phi_2 \alpha_{t,2} + \dots + \phi_n \alpha_{t,n} + \varepsilon_{t+1}$

2ª linha: $\alpha_{t+1,2} = \alpha_{t,1} = L \alpha_{t+1,1}$

3ª linha: $\alpha_{t+1,3} = \alpha_{t,2} = \alpha_{t-1,1} = L^2 \alpha_{t+1,1}$

jª linha: $\alpha_{t+1,j} = L^{j-1} \alpha_{t+1,1}$

$$\begin{bmatrix} \alpha_{t+1,1} \\ \alpha_{t+1,2} \\ \alpha_{t+1,3} \\ \vdots \\ \alpha_{t+1,n} \end{bmatrix} = \begin{bmatrix} \phi_1 & \phi_2 & \phi_3 & \dots & \phi_{n-1} & \phi_n \\ 1 & 0 & & & 0 & 0 \\ 0 & 1 & & & 0 & 0 \\ \vdots & \vdots & \ddots & \ddots & \vdots & \vdots \\ 0 & & & & 1 & 0 \end{bmatrix} \begin{bmatrix} L \alpha_{t+1,1} \\ L^2 \alpha_{t+1,1} \\ L^3 \alpha_{t+1,1} \\ \vdots \\ L^n \alpha_{t+1,1} \end{bmatrix} + \begin{bmatrix} \varepsilon_{t+1} \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

Logo, a 1ª linha pode ser escrita como:

$$\alpha_{t+1,1} = L \phi_1 \alpha_{t+1,1} + L^2 \phi_2 \alpha_{t+1,1} + \dots + L^n \phi_n \alpha_{t+1,1} + \varepsilon_{t+1}$$

$$(1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_n L^n) \alpha_{t+1,1} = \varepsilon_{t+1}$$

obs

$$y_t = \mu + [1 \quad \theta_1 \quad \theta_2 \quad \dots \quad \theta_{n-1}] \begin{bmatrix} \alpha_{t,1} \\ \alpha_{t,2} \\ \vdots \\ \alpha_{t,n-1} \end{bmatrix} \quad \begin{matrix} \alpha_{t,1} \\ \alpha_{t,2} \\ \vdots \\ \alpha_{t,n-1} \end{matrix} \quad \begin{matrix} = \alpha_{t-1,1} = L \alpha_{t,1} \\ \\ \\ = \alpha_{t-n,1} = L^{n-1} \alpha_{t,1} \end{matrix}$$

$$= \mu + [1 \quad \theta_1 \quad \theta_2 \quad \dots \quad \theta_{n-1}] \begin{bmatrix} \alpha_{t,1} \\ L \alpha_{t,1} \\ \vdots \\ L^{n-1} \alpha_{t,1} \end{bmatrix}$$

$$y_t = \mu + (1 + L \theta_1 + L^2 \theta_2 + \dots + L^{n-1} \theta_{n-1}) \alpha_{t,1}$$

$$(y_t - \mu) = (1 + L \theta_1 + L^2 \theta_2 + \dots + L^{n-1} \theta_{n-1}) \alpha_{t,1}$$

multiplicando ambos os lados por

$$(1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_n L^n), \text{ temos:}$$


$$(1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_n L^n) (y_t - \mu) = (1 + L \theta_1 + L^2 \theta_2 + \dots + L^{n-1} \theta_{n-1}) \times ((1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_n L^n) \cdot \alpha_{t,1})$$

$$(1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_n L^n) (y_t - \mu) = (1 + L\theta_1 + L^2\theta_2 + \dots + L^{n-1}\theta_{n-1}) \varepsilon_t$$

↓

que representa ARMA.

$$y_t - \mu = \phi_1 (y_{t-1} - \mu) + \phi_2 (y_{t-2} - \mu) + \dots + \phi_n (y_{t-n} - \mu) \\ + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_{n-1} \varepsilon_{t-n+1}.$$



Passo a passo: Estacionariedade de x e de y

Estacionariedade de x

- 1) Define estacionariedade de 2ª ordem $H x_t$
- 2) Faz C e R (e T) invariantes no tempo e escreve x_{t+1} recursivamente
 - 3) Calcula $E[x_{t+1}]$
 - 3.1) Escreve $E(\cdot)$
 - 3.2) Avalia condições $H E[x_{t+1}]$ indep. de t
 - 3.3) \hookrightarrow supondo autovalores de T distintos \Rightarrow escreve decomp. espectral e apresenta $T^t = F \Lambda^t F^T$
 - 3.4) Reescreve $E[x_{t+1}]$ usando decomp. espectral
 - 3.5) calcula componente $F \Lambda^t F^T$ (comb. linear de λ_i^t)
 - 3.6) Olha cada componente de $E[x_{t+1}]$ e faz $t \rightarrow \infty : |\lambda_i| < 1$
 - 3.7) Calcula $\lim_{t \rightarrow \infty} E[x_{t+1}] = (I - T)^{-1} C$
 - 4) Calcula $\Gamma_x(h, t)$, escrevendo x_{t+1} e x_{t+h+1} recursivamente
 - 4.1) Definições de $\Gamma_x(h, t) \Rightarrow$ desenvolve expressões, anula termos cruzados e lembra $E[(x_1 - a_1)(x_1 - a_1)'] = P_1$
 - 4.2) Avalia componente $T^t P_1 T^{t+h'}$ pela decomp. espectral, fazendo $|\lambda_i| < 1$ e $t \rightarrow \infty : \text{vai} \rightarrow 0$.
 - 4.3) Toma $\lim_{t \rightarrow \infty} \Gamma_x(h, t)$: fica apenas produto dos somatórios
 - 4.4) Calcula $E[\eta_{t-i} \eta_{t+h-j}']$ H cada termo do somatório e vê que é $\phi(t_0)$ $H j = i + h$
 - 4.5) Vai restar \sum em i de 0 a $t-1$ e onde tem j coloca $i+h$
 - 4.6) Usa novamente decomposição espectral de T
 - 4.7) Como $|\lambda_i| < 1 \Rightarrow$ somatório converge
 - 4.8) verificar produto de matriz para o caso $m=2$.
- 5) Provado $|\lambda_i(T)|$ cond. nec. e suf.

Estacionariedade de y :

- 1) Define estacionariedade de y_t
- 2) Faz z e d invariantes no tempo
- 3) Calcula $E[y_t]$ em função de $E[x_t]$

- 4) logo, se α_t estacionário $\Rightarrow E(y_t)$ cte.
- 5) calcula $\Gamma_y(h, t)$ em funçoes de $\Gamma_x(h, t)$
- 6) calcula componentes \Rightarrow termos cruzados = 0 pois recursivamente α_t é funcao de α_i
- 7) escreve forma final da $\Gamma_y(h, t) = \begin{cases} 2\Gamma_x(h, t)z' & \text{se } h \neq 0 \\ 2\Gamma_x(0, t)z' + 4 & \text{se } h = 0 \end{cases}$

Passo a Passo: Representações + 1 q mesma verossim. e previstas

- 1) considera matrizes Inv. no tempo, $c=d=0$ e resolver 2 representações
- 2) se $\alpha_t^* = B\alpha_t$ e $\det B \neq 0 \Rightarrow z^* = zB^{-1}$
↑
igual a y_t
- 3) escreve $E[\underbrace{\alpha_t^*}_{a_t^*} | y_{t-1}] = BE[\alpha_t | y_{t-1}] = Ba_t$
- 4) escreve $P_t^* = BP_tB'$
- 5) escreve funcoes de verossim.
 definicao de $L(y) = \prod p(y_t | y_{t-1})$ ^{preditiva}
 mostra que preditiva $\sim N(z a_t, P_t)$
 escreve $L(y)$ e $l(y)$ em funcoes de v_t
- 7) escreve $v_t^* = v_t$ e $f_t^* = f_t$
- 8) verossimilhanças iguais
- 9) funcoes de previstas.

Lista 1

1) Considerando prima em EE linear e Gaussiana

$$y_t = z_t \alpha_t + d_t + \varepsilon_t \quad t=1, 2, \dots, n$$

$$\alpha_{t+1} = T_t \alpha_t + C_t + R_t \eta_t$$

$$\text{onde } \begin{pmatrix} \varepsilon_t \\ \eta_t \end{pmatrix} \sim N \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} H_t & 0 \\ 0 & \Phi_t \end{pmatrix} \right)$$

$$E[\varepsilon_t \eta_t'] = 0 \quad \forall t$$

$$\alpha_1 \sim N(a_1, P_1)$$

$$E[\varepsilon_t \alpha_t'] = E[\eta_t \alpha_t'] = 0 \quad \forall t$$

Provar que cond. necessária e suficiente H estado e, consequentemente, variável observável, seja estacionário de 2ª ordem e que $| \lambda_i(T) | < 1$

T: invariante no tempo.

1ª Parte. Prova da estacionariedade de α

1) Defina estacionariedade de 2ª ordem H α_t

Se α_t e estacionário de 2ª ordem:

$$(i) E[\alpha_t] = \mu_\alpha \quad \forall t, \quad \mu_\alpha < \infty$$

$$(ii) E[(\alpha_t - E[\alpha_t])(\alpha_t - E[\alpha_t])'] = \Gamma_\alpha(h) \quad \forall t, \quad \forall h=0, 1, \dots$$

2) faz C e R ($\in T$) invariáveis no tempo e escreve α_{t+1} recursivamente

$$\alpha_{t+1} = C + T\alpha_t + R\eta_t$$

$$\Rightarrow \alpha_2 = C + T\alpha_1 + R\eta_1$$

$$\alpha_3 = C + T\alpha_2 + R\eta_2$$

$$= C + T(C + T\alpha_1 + R\eta_1) + R\eta_2$$

$$= (I+T)C + T^2\alpha_1 + TR\eta_1 + R\eta_2$$

$$\alpha_4 = C + T\alpha_3 + R\eta_3$$

$$= C + T[(I+T)C + T^2\alpha_1 + TR\eta_1 + R\eta_2] + R\eta_3$$

$$= (I+T+T^2)C + T^3\alpha_1 + T^2R\eta_1 + TR\eta_2 + R\eta_3$$

⋮

$$\alpha_{(t+1)} = (I+T+T^2+\dots+T^{t-1})C + T^t\alpha_1 + \sum_{i=0}^{t-1} T^i R\eta_{(t-i)}$$

Fazer demo:

- estacionariedade
- $d\alpha \Rightarrow y$
- exercício 4
- observabilidade
- (da lista 1)
- Em nível local t^0
- Em frequência local
- ler livro
- ver códigos
- concentração de prova
- resumo parte nova
- ver previsão $y_{t+1|t}$

Ver artigos aula passada
prova

classe finalista - Estatística
ext. 9 - Estatística

- equações
e funções

Ver códigos:
- Ver IC
- Ver previsões
desta / por
da amostra

Nas
situações
K=3
K=4
K=2

3.1) calcular $E[x_{t+1}]$ M cond. (i) estacionariedade

$$E[x_{t+1}] = E[(I+T+\dots+T^{t-1})]c + T^t E[x_1] + \sum_{i=0}^{t-1} T^i R E[\eta_{t-i}]$$

$$= (I+T+\dots+T^{t-1})c + T^t a_1$$

3.2) Avaliar condicao M $E[x_{t+1}]$ independente de t.

3.3) Segundo autovalores de T distintos, usar decomp. espectral e apresentar $T^t = F \Lambda^t F'$

$$T F_i = \lambda_i F_i \quad \text{onde } F_i: \text{autovetor}$$

$$\lambda_i: \text{autovalor } i=1, \dots, m$$

Pela decomposicao espectral, podemos escrever

$$T = F \Lambda F' \quad \text{onde } F: \text{matriz dos autovetores de } T$$

$$\Lambda: \text{ " diagonal dos autovalores de } T$$

Prova-se ainda que

$$T^t = F \Lambda^t F'$$

3.4) Reescrever $E[x_{t+1}]$ usando decomp. espectral

$$E[x_{t+1}] = (I+T+\dots+T^t)c + F \Lambda^t F' a_1$$

3.5) calcular componente $F \Lambda^t F' a_1$ (c.l. de λ_i^t)

$$F \Lambda^t F' a_1 = \begin{pmatrix} f_{11} & f_{12} & \dots & f_{1m} \\ f_{21} & f_{22} & \dots & f_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ f_{m1} & \dots & \dots & f_{mm} \end{pmatrix} \begin{pmatrix} \lambda_1^t & & & \\ & \lambda_2^t & & 0 \\ & & \ddots & \\ 0 & & & \lambda_m^t \end{pmatrix} \begin{pmatrix} f^{11} & f^{12} & \dots & f^{1m} \\ & & & \\ & & & \\ f^{m1} & \dots & \dots & f^{mm} \end{pmatrix} \begin{pmatrix} a_{11} \\ a_{21} \\ \vdots \\ a_{m1} \end{pmatrix}$$

$$= \begin{pmatrix} \delta_{11} \lambda_1^t + \delta_{12} \lambda_2^t + \dots + \delta_{1m} \lambda_m^t \\ \vdots \\ \delta_{m1} \lambda_1^t + \dots + \delta_{mm} \lambda_m^t \end{pmatrix} \quad \text{onde } \delta_{ij} = f(f_{ij} f^{ij} a_{ij})$$

↓
nas depende de t

3.6) Olhar cada componente de $E[x_{t+1}]$ e fazer $t \rightarrow \infty$ M $|\lambda_i| < 1$

para cada componente

$$E[x_{t+1,i}] = \delta_{i1} \lambda_1^t + \dots + \delta_{im} \lambda_m^t \Rightarrow \text{depende explicitamente de } t$$

mas se $|\lambda_i| < 1$, quando $t \rightarrow \infty$
 $\Rightarrow E[x_{t+1}] \rightarrow 0$

3.7) Calcular $\lim_{t \rightarrow \infty} E[x_{t+1}] = (I - T) c$

$$\begin{aligned} \lim_{t \rightarrow \infty} E[x_{t+1}] &= \lim_{t \rightarrow \infty} (I + T + \dots + T^{t+1}) c \\ &= (I - T)^{-1} c \quad ; \text{ de.} \end{aligned}$$

4) 4.1) Calcular $\Gamma_x(h, t)$ p/ cond (ii) de estacionariedade, colocando α de forma recursiva.

$$\Gamma_x(h, t) = E[(x_{t+1} - E[x_{t+1}]) (x_{t+h} - E[x_{t+h+1}])']$$

Sabemos que:

$$x_{t+1} = \underbrace{(I + T + \dots + T^{t+1}) c}_K + T^t x_1 + \sum_{i=0}^{t-1} T^i R \eta_{t-i}$$

$$E[x_{t+1}] = E[x_{t+h+1}] = K + T^t a_1$$

$$\Rightarrow \Gamma_x(h, t) = E\left[(K + T^t x_1 + \sum_{i=0}^{t-1} T^i R \eta_{t-i} - K - T^t a_1) (K + T^{t+h} x_1 + \sum_{i=0}^{t+h-1} T^i R \eta_{t-i} - T^{t+h} a_1)' \right]$$

a) desenvolve expressões e anula termos cruzados

b) move $E[(x_1 - a_1)(x_1 - a_1)'] = P_1$

$$\begin{aligned} &= E\left[\left(T^t (x_1 - a_1) + \sum_{i=0}^{t-1} T^i R \eta_{t-i} \right) \left((x_1 - a_1)' T^{t+h} + \sum_{i=0}^{t+h-1} \eta_{t-i}' R' T^i \right)' \right] \\ &= E\left[T^t (x_1 - a_1) (x_1 - a_1)' T^{t+h} \right] + T^t E\left[(x_1 - a_1) \sum_{i=0}^{t+h-1} \eta_{t-i}' R' T^i \right] + \\ &\quad + E\left[\left(\sum_{i=0}^{t-1} T^i R \eta_{t-i} \right) (x_1 - a_1)' \right] T^{t+h} + \\ &\quad + E\left[\left(\sum_{i=0}^{t-1} T^i R \eta_{t-i} \right) \left(\sum_{j=0}^{t+h-1} \eta_{t-j}' R' T^j \right)' \right] \\ &= T^t P_1 T^{t+h} + E\left[\left(\sum_{i=0}^{t-1} T^i R \eta_{t-i} \right) \left(\sum_{j=0}^{t+h-1} \eta_{t-j}' R' T^j \right)' \right] \end{aligned}$$

4.2) Avalia componente $T^t P_1 T^{t+h}$ pela decomp. spectral, fazendo $|\lambda_i| < 1$.

Sabemos que $T^t = F \Lambda^t F'$

Como $|\lambda_i| < 1$:

$$\lim_{t \rightarrow \infty} T^t P_1 T^{t+h} = 0.$$

e tomando $\lim_{t \rightarrow \infty}$

4.3) Toma $\lim_{t \rightarrow \infty} \Gamma_{\alpha}(h, t) \rightarrow$ fica apenas produto dos somatórios (passa $E(\cdot)$ H dentro)

$$\lim_{t \rightarrow \infty} \Gamma_{\alpha}(h, t) = \lim_{t \rightarrow \infty} \left(\sum_{i=0}^{t-1} \sum_{j=0}^{t+h-1} (T^i R E[\eta_{t-i} \eta_{t+h-j}'] R' T^j) \right)$$

4.4) calcula $E[\eta_{t-i} \eta_{t+h-j}']$ para cada termo do somatório e vê que é 0 ($\neq 0$) H $j = i+h$.

$$\Rightarrow E[\eta_{t-i} \eta_{t+h-j}'] = 0 \text{ se } t-i \neq t+h-j \\ = Q \text{ se } t-i = t+h-j \Rightarrow j = i+h$$

4.5) Vai restar \sum em i de 0 a $t-1$ e onde tem j coloca $i+h$:

$$\lim_{t \rightarrow \infty} \Gamma_{\alpha}(h, t) = \lim_{t \rightarrow \infty} \left[\sum_{i=0}^{t-1} T^i R Q R' T^{i+h} \right]$$

4.6) Usa novamente decomp. spectral de T

$$\lim_{t \rightarrow \infty} \Gamma_{\alpha}(h, t) = \lim_{t \rightarrow \infty} \left[\sum_{i=0}^{t-1} F \Lambda^i \underbrace{F' R Q R' F'}_S \Lambda^{i+h} F \right] \\ \left[\sum F \Lambda^i S \Lambda^{i+h} F \right]$$

4.7) como $|\lambda_i| < 1 \Rightarrow$ somatório converge

Como $|\lambda_i| < 1 \Rightarrow \sum$ infinito converge

4.8) Verificar produto de matriz H o caso $m=2$

5) Provado $|\lambda_i(T)|$ é cond. nec. e suf. H estado estacionário.

2ª Parte : Prova da estacionariedade de y

1) Define estacionariedade H y

Se y_t é estacionário

$$(i) E[y_t] = \mu_y \quad \forall t \quad (\mu_y < \infty)$$

$$(ii) \Gamma_y(h, t) = \Gamma_y(h) \quad \forall t, \quad h = 0, 1, \dots$$

2) Faz z e d invariantes no tempo

$$\text{Seja } z_t = z \text{ e } d_t = d$$

3) calcula $E[y_t]$ em funçoes de $E[\alpha_t]$

$$\begin{aligned} E[y_t] &= E[2\alpha_t + d + \varepsilon_t] \\ &= 2E[\alpha_t] + d \Rightarrow \text{depende explicitamente de } E[\alpha_t] \end{aligned}$$

4) Logo: se α_t estacionário: $E[\alpha_t] = \mu_\alpha \Rightarrow E[y_t] = 2\mu_\alpha + d$

5) Calcula $\Gamma_y(h, t)$ em funçoes de $\Gamma_\alpha(h, t)$

$$\begin{aligned} \Gamma_y(h, t) &= E[(y_t - E[y_t])(y_{t+h} - E[y_{t+h}])'] = \\ &= E[(2\alpha_t + \varepsilon_t - 2E[\alpha_t])(2\alpha_{t+h} + \varepsilon_{t+h} - 2E[\alpha_{t+h}])'] = \\ &= E[(2(\alpha_t - E[\alpha_t]) + \varepsilon_t)(2(\alpha_{t+h} - E[\alpha_{t+h}]) + \varepsilon_{t+h})'] = \\ &= E[2(\alpha_t - E[\alpha_t])(\alpha_t - E[\alpha_t])' 2'] + E[2(\alpha_t - E[\alpha_t])\varepsilon_t'] + \\ &\quad + E[\varepsilon_t(\alpha_{t+h} - E[\alpha_{t+h}])' 2'] + E[\varepsilon_t \varepsilon_{t+h}'] \end{aligned}$$

6) Calcula componentes: termos cruzados são nulos pois recursivamente
pt α_t nas funçoes de $(\alpha_t, \eta_t)' \times \varepsilon_t = 0$.

$$\bullet E[2(\alpha_t - E[\alpha_t])(\alpha_{t+h} - E[\alpha_{t+h}])' 2'] = 2' \Gamma_\alpha(h, t) 2$$

$$\bullet E[\varepsilon_t \varepsilon_{t+h}'] = \begin{cases} 0 & \text{se } h \neq 0 \\ H & \text{se } h = 0 \end{cases}$$

7) Escreve forma final da $\Gamma_y(h, t)$ como funçoes de $\Gamma_\alpha(h, t)$ e conclui

$$\Rightarrow \Gamma_y(h, t) = \begin{cases} 2 \Gamma_\alpha(h, t) 2' & \text{se } h \neq 0 \\ 2 \Gamma_\alpha(h, t) 2' + H & \text{se } h = 0 \end{cases} \Rightarrow \text{depende explicitamente de } \Gamma_\alpha(h, t)$$

- 4) duas representações diferentes de um mesmo modelo
 α_t e α_t^* \Rightarrow dois vetores de estado próprios

$$\text{sendo } \alpha_t^* = B \alpha_t \text{ (det } B \neq 0)$$

\Rightarrow funções de verossimilhança e funções de predição são as mesmas.

- (1) Considerar matrizes inv. no tempo, $z p z$, e $c = d = 0$, resolver os sistemas

$$(I) \begin{cases} y_t = z \alpha_t + \varepsilon_t \\ \alpha_{t+1} = T \alpha_t + R \eta_t \end{cases} \quad (II) \begin{cases} y_t = z^* \alpha_t^* + \varepsilon_t \\ \alpha_{t+1}^* = T^* \alpha_t^* + R^* \eta_t^* \end{cases}$$

- (2) Se $\alpha_t^* = B \alpha_t \Rightarrow$ igualar os y_t e achar $z^* = z B^{-1}$

$$\alpha_t^* = B \alpha_t \therefore y_t = z \alpha_t + \varepsilon_t = z^* (B \alpha_t) + \varepsilon_t$$

$$\therefore z \alpha_t = z^* B \alpha_t$$

$$\text{Como } \det B \neq 0 \Rightarrow \exists B^{-1} \therefore \boxed{z^* = z B^{-1}}$$

- (3) Encontre $E[\alpha_t^* | \underline{y}_{t-1}]$ sabendo que $E[\alpha_t | \underline{y}_{t-1}] = a_t$

$$E[\alpha_t^* | \underline{y}_{t-1}] = E[B \alpha_t | \underline{y}_{t-1}]$$

$$\therefore a_t^* = B a_t$$

- (4) Encontre $V[\alpha_t^* | \underline{y}_{t-1}]$ sabendo que $V[\alpha_t | \underline{y}_{t-1}] = P_t$

$$V[\alpha_t^* | \underline{y}_{t-1}] = V[B \alpha_t | \underline{y}_{t-1}]$$

$$= B V[\alpha_t | \underline{y}_{t-1}] B'$$

$$\therefore P_t^* = B P_t B'$$

- (6) Encontre funções de verossimilhança / log de veross.

$$L(\psi) = p(y_1, y_2, \dots, y_n; \psi)$$

Saber $\rightarrow = \prod_{i=1}^n p(y_t | \underline{y}_{t-1}; \psi)$ onde $p(y_t | \underline{y}_{t-1})$ é a densidade preditiva

- (6.1) Tomar representações 1 e resolve $E[y_t | \underline{y}_{t-1}] = z a_t$

$$\text{var}(y_t | \underline{y}_{t-1}) = z P_t z' + H = F_t$$

$$E[y_t | \underline{y}_{t-1}] = E[z \alpha_t + \varepsilon_t | \underline{y}_{t-1}]$$

$$= z a_t$$

$$\text{var}[y_t | \underline{y}_{t-1}] = \text{var}[z\alpha_t + \varepsilon_t | \underline{y}_{t-1}]$$

$$= E[(z\alpha_t + \varepsilon_t - z\alpha_t)(z\alpha_t + \varepsilon_t - z\alpha_t)' | \underline{y}_{t-1}] =$$

$$= E[(z(\alpha_t - \alpha_t) + \varepsilon_t)(z(\alpha_t - \alpha_t) + \varepsilon_t)' | \underline{y}_{t-1}] =$$

$$= E[(z(\alpha_t - \alpha_t) + \varepsilon_t)((\alpha_t - \alpha_t)'z' + \varepsilon_t') | \underline{y}_{t-1}] =$$

$$= z \underbrace{E[(\alpha_t - \alpha_t)(\alpha_t - \alpha_t)']}_{P_t} z' + z E_{t-1}[(\alpha_t - \alpha_t)\varepsilon_t'] + E_{t-1}[\varepsilon_t(\alpha_t - \alpha_t)'] + E_{t-1}[\varepsilon_t \varepsilon_t']$$

(Escrevendo recursivamente α_t :

$$\alpha_t = T\alpha_{t-1} + R\eta_{t-1}$$

$$\alpha_2 = T\alpha_1 + R\eta_1$$

$$\alpha_3 = T\alpha_2 + R\eta_2 = T(T\alpha_1 + R\eta_1) + R\eta_2$$

$$= T^2\alpha_1 + TR\eta_1 + R\eta_2$$

$$\alpha_4 = T\alpha_3 + R\eta_3 = T(T^2\alpha_1 + TR\eta_1 + R\eta_2) + R\eta_3$$

$$= T^3\alpha_1 + T^2R\eta_1 + TR\eta_2 + R\eta_3$$

$$\alpha_t = T^{t-1}\alpha_1 + \sum_{i=0}^{t-2} T^i R \eta_{t-i}$$

$$\Rightarrow E[(\alpha_t - \alpha_t)\varepsilon_t'] =$$

$$E[(T^{t-1}\alpha_1 + \sum_{i=0}^{t-2} T^i R \eta_{t-i} - \alpha_t)\varepsilon_t'] =$$

$$= T^{t-1}E[\alpha_1/\varepsilon_t'] + \sum_{i=0}^{t-2} T^i R E[\eta_{t-i}/\varepsilon_t'] - \alpha_t E[\varepsilon_t'] = 0.$$

$$\text{Logo: } \text{var}[y_t | \underline{y}_{t-1}] = zP_t z' + H = F_t$$

(6.2) Como $y_t | \underline{y}_{t-1} \sim N \Rightarrow p(y_t | \underline{y}_{t-1}) \sim N(z\alpha_t, F_t)$

(6.3) Escreve fórmula da Normal Multivariada em termos de v_t

$$p(y_t | \underline{y}_{t-1}) = \frac{1}{(2\pi)^{p/2} |F_t|^{1/2}} \exp \left\{ -\frac{1}{2} \underbrace{(y_t - z\alpha_t)'}_{v_t'} F_t^{-1} \underbrace{(y_t - z\alpha_t)}_{v_t} \right\}$$

$$= \frac{1}{(2\pi)^{p/2} |F_t|^{1/2}} \exp \left\{ -\frac{1}{2} v_t' F_t^{-1} v_t \right\}$$

$$= (2\pi)^{-p/2} |F_t|^{-1/2} \exp \left\{ -\frac{1}{2} v_t' F_t^{-1} v_t \right\}$$

(6.4) Encontre $L(\psi)$ e $\ell(\psi)$

$$\text{como } L(\psi) = \prod_{t=1}^n (2\pi)^{-p/2} |F_t|^{-1/2} \exp \left\{ -\frac{1}{2} v_t' F_t^{-1} v_t \right\}$$

$$\Rightarrow \ell(\psi) = \log(L(\psi)) = -\frac{np}{2} \log 2\pi - \frac{1}{2} \sum_{t=1}^n (\log |F_t| + v_t' F_t^{-1} v_t)$$

(7) Encontre $v_t^* \in F_t^*$ em funões de $v_t \in F_t \Rightarrow v_t^* = v_t \in F_t^* = F_t$

$$\rightarrow v_t^* = y_t - z_t^* a_t^*$$

$$= y_t - (zB^{-1})(Ba_t) = y_t - za_t \Rightarrow \boxed{v_t^* = v_t}$$

$$\rightarrow F_t^* = z^* P_t^* z^{*'} + H$$

$$= (zB^{-1})(BP_t B')(zB^{-1})' + H$$

$$= zB^{-1}BP_t B'(B')^{-1}z' + H$$

$$= zP_t z' + H = \boxed{F_t}$$

(8) Logo: $\ell^*(\psi) = \ell(\psi)$

(9) Funões de previses

$$\hat{y}_{t+1|t} = E[y_{t+1} | \underline{y}_t]$$

$$= E[z\alpha_{t+1} + \varepsilon_{t+1} | \underline{y}_t]$$

$$= za_{t+1|t}$$

$$\text{ou } \hat{y}_{t+1|t} = E[z^* \alpha_{t+1}^* + \varepsilon_{t+1} | \underline{y}_t]$$

$$= E[zB^{-1}B\alpha_{t+1} + \varepsilon_{t+1} | \underline{y}_t]$$

$$= za_{t+1|t}$$

Prova da cond. de observabilidade $\Rightarrow \det M' \neq 0$.

1) Escreve sistema invariante no tempo na forma

$$y_t = Z \alpha_t$$

$$\alpha_{t+1} = T \alpha_t + R \eta_t$$

2) Definição de observabilidade: sistema é dito observável se α_0 pode ser determinado por conjunto de medidas de y

3) Faz $\eta_t = 0 \quad \forall t$

4) Escreve α_{t+1} recursivamente em função de α_0

$$\alpha_{t+1} = T \alpha_t$$

$$\alpha_1 = T \alpha_0$$

$$\alpha_2 = T \alpha_1 = T^2 \alpha_0 \Rightarrow \boxed{\alpha_t = T^t \alpha_0}$$

5) Escreve y_t em função de α_0

$$y_t = Z \alpha_t \Rightarrow \boxed{y_t = Z T^t \alpha_0}$$

6) y conj. de medidas de $t=0$ a \underline{m} : escreve matriz $M = \begin{pmatrix} Z \\ ZT \\ \vdots \\ ZT^m \end{pmatrix}$

$$\left. \begin{array}{l} y_0 = Z \alpha_0 \\ y_1 = ZT \alpha_0 \\ \vdots \\ y_m = ZT^m \alpha_0 \end{array} \right\} y = \tilde{M} \alpha_0 \quad \text{onde } M = \begin{pmatrix} Z \\ ZT \\ \vdots \\ ZT^m \end{pmatrix}$$

\Rightarrow Para α_0 determinado de forma única \Rightarrow posto $M = m$

Equivalente a posto $M' = m \Rightarrow \det (Z' T^0 Z' \dots T^{m-1} Z') \neq 0$.

\Rightarrow Conclusão: A questão da observabilidade é obrigatória H estimações dos parâmetros.

Estudo x prova.

Modelo de nível local \rightarrow modelo de flutuação estocástica pp ST onde nível vai e etc.

$$\begin{cases} y_t = \mu_t + \varepsilon_t \\ \mu_{t+1} = \mu_t + \eta_t \quad (\text{e se } \mu_{t+1} = \phi \mu_t + \eta_t?) \end{cases}$$

\rightarrow Forma de Espaço Estado

Já está onde $Z = 1$ $R = 1$

$$T = 1$$

$$H = \sigma_\varepsilon^2$$

$$Q = \sigma_\eta^2$$

• É estacionário?

Não!

Como coeficiente de $\mu_t = 1 \Rightarrow$ raiz unitária
É um RW.

• É observável?

Sim!

Pois $Z = 1$ e' como se $\det M = 1$.

\rightarrow Características e casos Particulares.

• Razas sinal ruído

$$q = \sigma_\eta^2 / \sigma_\varepsilon^2 \Rightarrow \text{importante q ser explorado na questão da verossimilhança}$$

É um parâmetro que governa a magnitude da componente de nível local.

se $q > 1 \Rightarrow \sigma_\eta^2 > \sigma_\varepsilon^2$: variações do nível supera a variações do ruído

se $q < 1 \Rightarrow \sigma_\eta^2 < \sigma_\varepsilon^2$: nível do processo é "enfiado" pelo do ruído.

• Casos Particulares:

$$a) \quad q = 0 \Rightarrow \sigma_\eta^2 = 0 \therefore \mu_{t+1} = \mu_t = a$$

$\Rightarrow y_t = a + \varepsilon_t$: oscilações em torno de nível etc.

$a \Rightarrow$ estimado por m.p.o

$$\hat{a} = \left(\frac{1}{t}\right) \sum_{i=1}^t y_i$$

funções de previsões

$$\begin{aligned}\hat{y}_{t+1|t} &= E[y_{t+1} | \underline{y}_t] \\ &= E[a + \varepsilon_{t+1} | \underline{y}_t] \\ &= \hat{a}_t\end{aligned}$$

$$\begin{aligned}\text{var}(\hat{y}_{t+1|t}) &= E[(y_{t+1} - E(y_{t+1} | \hat{y}_t))(y_{t+1} - E(y_{t+1} | \hat{y}_t))'] \\ &= E[(y_{t+1} - E(y_{t+1} | \hat{y}_t))^2] \\ &= E[\varepsilon_{t+1}^2 | \hat{y}_t] = \sigma_\varepsilon^2\end{aligned}$$

b) $\sigma_\varepsilon^2 = 0$

$$y_t = \mu_t$$

$$\mu_{t+1} = \mu_t + \eta_t \Rightarrow \mu_2 = \mu_1 + \eta_1$$

$$\mu_3 = \mu_2 + \eta_2 = \mu_1 + \eta_1 + \eta_2$$

$$\vdots$$

$$\mu_t = \mu_1 + \sum_{i=1}^t \eta_i$$

$\Rightarrow y$ é passeio aleatório

funções previsões:

$$\begin{aligned}\hat{y}_{t+1|t} &= E[y_{t+1} | \underline{y}_t] = \\ &= E[\mu_t + \sum_{i=1}^{t+1} \eta_i | \underline{y}_t] \\ &= E[\mu_1 + \sum_{i=1}^t \eta_i + \sum_{i=t+1}^{t+1} \eta_i | \underline{y}_t] \\ &= E[y_t + \sum_{i=t+1}^{t+1} \eta_i | \underline{y}_t] = y_t\end{aligned}$$

$$\text{var}(\hat{y}_{t+1|t} | \underline{y}_t) =$$

$$E[(y_{t+1} - E(y_{t+1} | \underline{y}_t))^2]$$

$$E[(y_{t+1} - y_t)^2] = E[\sum_{i=1}^1 \eta_i | \underline{y}_t] = \boxed{5\sigma_\eta^2}$$

→ Funções de Previsão do MNL

$$\hat{y}_{t+h|t} = E[y_{t+h} | \underline{y}_t]$$

$$y_t = \mu_t + \varepsilon_t$$

$$\mu_{t+1} = \mu_t + \eta_t \Rightarrow \mu_2 = \mu_1 + \eta_1$$

$$\mu_3 = \mu_2 + \eta_2 = \mu_1 + \eta_1 + \eta_2$$

⋮

$$\mu_t = \mu_1 + \sum_{i=1}^t \eta_i$$

$$\Rightarrow y_t = \mu_1 + \sum_{i=1}^t \eta_i + \varepsilon_t$$

atencas
E incondicional
e $E[y_t | \underline{y}_{t-1}]$

ans: $E[y_t] = E[\mu_t] = \alpha_1$

$$\text{var}[y_t] = \underbrace{\text{var}[\mu_t | \underline{y}_{t-1}]}_{p_t} + t\sigma_\eta^2 + \sigma_\varepsilon^2$$

atencas!

$$\begin{aligned} \Rightarrow \hat{y}_{t+h|t} &= E\left[\mu_1 + \sum_{i=1}^{t+h} \eta_i + \varepsilon_{t+h} \mid \underline{y}_t\right] \\ &= E\left[\underbrace{\left(\mu_1 + \sum_{i=1}^t \eta_i\right)}_{\mu_t} + \sum_{i=t+1}^{t+h} \eta_i + \varepsilon_{t+h} \mid \underline{y}_t\right] \\ &= E[\mu_t | \underline{y}_t] = \hat{\mu}_{t|t} \Rightarrow \text{estimado pelo FK.} \end{aligned}$$

$$\begin{aligned} \text{Var}[\hat{y}_{t+h|t}] &= \text{var}[y_{t+h} - E[\hat{y}_{t+h|t} | \underline{y}_t]] \\ &= \text{var}\left[\underbrace{(\mu_t)}_{\hat{\mu}_{t|t}} + \sum_{i=t+1}^{t+h} \eta_i + \varepsilon_{t+h} - \hat{\mu}_{t|t}\right] \\ &= \text{var}\left[(\mu_t - \hat{\mu}_{t|t}) + \sum_{i=t+1}^{t+h} \eta_i + \varepsilon_{t+h}\right] \\ &= \left(p_{t|t} + h\sigma_\eta^2 + \sigma_\varepsilon^2\right) \end{aligned}$$

→ FK previsas / atualizaçes

$$Z = 1 \quad Q = \sigma_\eta^2$$

$$T = 1 \quad H = \sigma_\varepsilon^2$$

$$R = 1$$

$$\Rightarrow v_t = y_t - a_t$$

$$F_t = p_t + H_t = p_t + \sigma_e^2$$

$$k_t = p_t F_t^{-1} = \frac{p_t}{p_t + \sigma_e^2}$$

$$L_t = 1 - k_t = 1 - \frac{p_t}{p_t + \sigma_e^2} = \frac{\sigma_e^2}{p_t + \sigma_e^2}$$

$$M_t = p_t$$

$$\text{logo: } a_{t|t} = a_t + p_t \cdot \frac{1}{p_t + \sigma_e^2} (y_t - a_t)$$

$$= a_t + \frac{p_t}{p_t + \sigma_e^2} (y_t - a_t)$$

$$= \frac{p_t}{p_t + \sigma_e^2} y_t + \left(1 - \frac{p_t}{p_t + \sigma_e^2}\right) a_t \quad \Rightarrow \text{EWMA}$$

$$\bullet \quad p_{t|t} = p_t - \frac{p_t^2}{p_t + \sigma_e^2} = \sigma_e^2 \cdot \frac{p_t}{p_t + \sigma_e^2}$$

$$\Rightarrow a_{t+1} = a_{t|t} = \lambda y_t + (1-\lambda) a_t$$

$$p_{t+1} = p_{t|t} + \sigma_\eta^2 = \sigma_e^2 \cdot \frac{p_t}{p_t + \sigma_e^2} + \sigma_\eta^2$$

logo: funções de previsões

→ fazer sempre
dps. do FK

$$\begin{aligned} E[y_{t+h} | y_t] &= E[\mu_{t+h} + \varepsilon_{t+h} | y_t] \\ &= E\left[\mu_t + \sum_{i=1}^h \eta_i + \varepsilon_{t+h} | y_t\right] \\ &= E[\mu_t | y_t] = a_{t|t} \end{aligned}$$

$$\begin{aligned} \text{Var}[y_{t+h} | y_t] &= E\left[\left(\mu_t + \sum_{i=1}^h \eta_i + \varepsilon_{t+h} - a_{t|t}\right)^2\right] \\ &= p_{t|t} + h\sigma_\eta^2 + \sigma_e^2 \end{aligned}$$

→ FK 2 em 1

$$a_{t+1} = T a_t + K_t v_t$$

$$= a_t + \frac{P_t}{P_t + \sigma_E^2} (y_t - a_t)$$

! Já sai direto no EWMA

→ Suavizações

$$\lambda_{t-1} = Z' F_t^{-1} v_t + L_t' \lambda_t$$

$$\hat{a}_t = a_t + P_t \lambda_{t-1}$$

$$\lambda_{t-1} = \frac{1}{P_t + \sigma_E^2} (y_t - a_t) + \frac{\sigma_E^2}{P_t + \sigma_E^2} \lambda_t$$

t = n: Fazemos $\lambda_n = 0 \Rightarrow \lambda_{n-1} = \frac{1}{P_n + \sigma_E^2} (y_n - a_n)$

$$\Rightarrow \hat{a}_n = a_n + \frac{P_n}{P_n + \sigma_E^2} (y_n - a_n) \quad \text{— equivalente a } a_n \text{ do FK}$$

t = n-1: $\lambda_{n-2} = \frac{1}{P_{n-1} + \sigma_{n-1}^2} (y_{n-1} - a_{n-1}) + \frac{\sigma_E^2}{P_{n-1} + \sigma_E^2} \lambda_{n-1}$

$$\Rightarrow \hat{a}_{n-1} = \dots$$

→ Observações faltantes entre $t = \tau$ e $t = \tau^* - 1$

• Usando FK: $\exists y_t \Rightarrow v_t = 0, F_t = 0, K_t = 0$.

Última observação: y_{t-1} .

Para MNL

Eggs:
$$\begin{cases} a_{t+1} = a_t \\ P_{t+1} = P_t \\ a_{t+1} = T a_{t+1} = T a_t \\ P_{t+1} = T P_{t+1} T' + R \Phi_t R' \end{cases}$$

$$\Rightarrow \begin{cases} a_{t+1} = a_t \\ P_{t+1} = P_t \\ a_{t+1} = a_t \\ P_{t+1} = P_{t+1} + \sigma_\eta^2 = P_t + \sigma_\eta^2 \end{cases}$$

Para $t = \tau \Rightarrow$ calculamos a_τ com base na info em $\tau-1$

A partir daí $\Rightarrow t = \tau+1 \Rightarrow a_{\tau+1} = a_\tau$

$t = \tau+2 \Rightarrow a_{\tau+2} = a_{\tau+1} = a_\tau$

$$a_{\tau+j} = a_\tau$$

$t = \tau^* \Rightarrow a_{\tau^*} = a_{\tau^*-1} = a_\tau$

$$\hat{y}_t = a_\tau$$


Variancia em $t = \tau \Rightarrow$ calculamos P_τ

A partir daí: $t = \tau+1 \Rightarrow P_{\tau+1} = P_\tau + \sigma_\eta^2$

$t = \tau+2 \Rightarrow P_{\tau+2} = P_{\tau+1} + \sigma_\eta^2 = P_\tau + 2\sigma_\eta^2$

$$P_{\tau+j} = P_\tau + j\sigma_\eta^2$$

$t = \tau^* \Rightarrow P_{\tau^*} = P_\tau + (\tau^* - \tau)\sigma_\eta^2$



Na lista: variancia da um pico.
Ver!

• Usando suavizador

$$\hat{y}_t \Rightarrow v_t = 0, F_t = 0, K_t = 0, L_t = T_t$$

Eqs:

$$\hat{x}_t = a_t + P_t \lambda_{t-1}$$

$$\lambda_{t-1} = L_t' \lambda_t = T_t' \lambda_t$$

$$v_t = P_t - P_t N_{t-1} P_t$$

$$N_{t-1} = \underbrace{z_t' F_t^{-1} z_t}_{0} + L_t' N_t L_t = T_t' N_t T_t$$

Para MNL \rightarrow DO FK

$$\hat{x}_t = (a_t + P_t \lambda_{t-1})$$

$$\lambda_{t-1} = \lambda_t$$

$$v_t = P_t - P_t N_{t-1} P_t = (P_t - P_t^2 N_{t-1})$$

$$N_{t-1} = N_t$$

Comeca em $t = \tau^*$

A partir daí $\Rightarrow \lambda_{\tau^*+1} = \lambda_{\tau^*}$

$\lambda_{\tau^*+2} = \lambda_{\tau^*}$

$\lambda_{\tau^*} = \lambda_{\tau^*}$

para $\tau \leq \tau+j \leq \tau^*-1$

$$\hat{x}_{\tau+j} = a_\tau + (P_\tau + j\sigma_\eta^2) \lambda_{\tau^*}$$

$$= \underbrace{(a_\tau + P_\tau \lambda_{\tau^*})}_A + \underbrace{(j\sigma_\eta^2 \lambda_{\tau^*})}_B$$

A

B

$$\hat{\alpha}_\tau = A$$

$$\hat{\alpha}_{\tau+1} = A + B$$

$$\hat{\alpha}_{\tau+2} = A + 2B$$

} eq. de uma reta

$$\hat{\alpha}_{\tau^*-1} = A + (\tau^*-1-\tau)B.$$



Inicializações do FK

→ uma componente nas estações

1) Prior difusa, por Big kappa:

$$\alpha_1 \sim N(0, k) \quad k \rightarrow \infty.$$

Rodamos FK padrão até obter dist. própria

$$v_t = y_t - a_t$$

$$F_t = p_t + \sigma_E^2$$

$$k_t = \frac{p_t}{p_t + \sigma_E^2}$$

$$L_t = \frac{\sigma_E^2}{p_t + \sigma_E^2}$$

$$p_{t+1} = \sigma_E^2 \frac{p_t}{p_t + \sigma_E^2} + \sigma_\eta^2$$

$$a_{t+1} = a_t + \frac{p_t}{p_t + \sigma_E^2} (y_t - a_t)$$

$$\Rightarrow \left. \begin{aligned} a_2 &= a_1 + \frac{p_1}{p_1 + \sigma_E^2} (y_1 - a_1) \quad \therefore a_2 = y_1 \\ p_2 &= \sigma_E^2 \cdot \frac{p_1}{p_1 + \sigma_E^2} + \sigma_\eta^2 \quad \therefore p_2 = \sigma_E^2 + \sigma_\eta^2 \end{aligned} \right\} \text{dist. própria}$$

Função de verossimilhança:
$$l^{bk}(\psi) = -\frac{(n-1)}{2} \sum_{t=2}^n \log(1 + \frac{v_t^2}{F_t})$$

\downarrow
 $\frac{(y_t - a_t)^2}{p_t + \sigma_E^2}$

2) Inicialização Exata

$$\alpha_1 = \delta$$

$$\text{onde } A = 1$$

$$P_{10,1} = 1$$

↓ tem que zerar

var zerar em $t=2 \Rightarrow$ a partir de $t=2$ podemos usar

Neste caso, usamos log verossimilhança difusa:

$$l_d(\psi) = \lim_{K \rightarrow \infty} \left(\log L(\psi) + \frac{1}{2} \log K \right)$$

$$= \lim_{P_1 \rightarrow \infty} \left(\log L(\psi) + \frac{1}{2} \log P_1 \right)$$

$$= \lim_{P_1 \rightarrow \infty} \left[-\frac{n}{2} \log 2\pi - \frac{1}{2} \sum_{t=1}^n \left(\log F_t + \frac{v_t^2}{F_t} \right) + \frac{1}{2} \log P_1 \right]$$

$$= \lim_{P_1 \rightarrow \infty} \left[-\frac{n}{2} \log 2\pi - \frac{1}{2} \left(\log F_1 + \frac{v_1^2}{F_1} \right) + \frac{1}{2} \log P_1 - \frac{1}{2} \sum_{t=2}^n \left(\log F_t + \frac{v_t^2}{F_t} \right) \right]$$

$$= \lim_{P_1 \rightarrow \infty} \left[-\frac{n}{2} \log 2\pi - \frac{1}{2} \left(\log \frac{F_1}{P_1} + \frac{v_1^2}{F_1} \right) - \frac{1}{2} \sum_{t=2}^n \left(\log F_t + \frac{v_t^2}{F_t} \right) \right]$$

$$F_1 = P_1 + \sigma_E^2$$

$$l_d(\psi) = -\frac{n}{2} \log 2\pi - \frac{1}{2} \sum_{t=2}^n \left(\log F_t + \frac{v_t^2}{F_t} \right) + \lim_{P_1 \rightarrow \infty} \left(\log \left(\frac{P_1 + \sigma_E^2}{P_1} \right) + \frac{v_1^2}{P_1 + \sigma_E^2} \right)$$

Concentração da verossimilhança:

Conveniente reparametrização η diminuir a busca numérica

$$\text{Escrevemos } q = \frac{\sigma_\eta^2}{\sigma_E^2} \therefore \sigma_\eta^2 = q \sigma_E^2$$

$$\text{Calculamos } F_t^* \text{ e } P_t^* \text{ como } F_t^* = \frac{F_t}{\sigma_E^2} = \frac{P_t}{\sigma_E^2} + 1 = P_t^* + 1$$

Escrevemos FK reparametrizado

$$v_t = y_t - a_t$$

$$F_t^* = p_t^* + 1$$

$$a_{t+1} = a_t + k_t v_t$$

$$p_{t+1}^* = p_t^* (1 - k_t) + q$$

A log veros. difusa concentrada e' obtida substit. $F_t \rightarrow \sigma_E^2 F_t^*$ e $\sigma_E^2 p_t^*$:

$$l_{dc}(y) = -\frac{n}{2} \log 2\pi - \frac{1}{2} \sum_{t=2}^n \left(\log \sigma_E^2 F_t^* + \frac{v_t^2}{\sigma_E^2 F_t^*} \right)$$

$$= -\frac{n}{2} \log 2\pi - \frac{(n-1)}{2} \log \sigma_E^2 - \frac{1}{2} \sum_{t=2}^n \left(\log F_t^* + \frac{v_t^2}{\sigma_E^2 F_t^*} \right)$$



Maximizamos com respeito a σ_E^2

RESUMO

- Inicialização prior difusa
Big kappa ($P_i = K \rightarrow \infty$)

$\left\{ \begin{array}{l} \text{pt } t=2 \Rightarrow \text{dist. própria} \end{array} \right.$

Poderia inicialização exata: da mesma coisa

Podemos começar a computar FK e desprezar o 1º cálculo

\Rightarrow escreve $L(\psi)$ aproximada desmontando 1ª obs.

- log verossim. difusa

$$l_d(\psi) = \lim_{P_i \rightarrow \infty} \left(\log L(\psi) + \frac{1}{2} \log P_i \right)$$

\vdots desenvolve e chega a:

$$= -\frac{n}{2} \log 2\pi - \frac{1}{2} \sum_{t=2}^n \left(\log F_t + \frac{y_t^2}{F_t} \right)$$

\hookrightarrow mas pode aqui

- log verossim. concentrada

$$\text{Escreve } q = \frac{\sigma_\eta^2}{\sigma_\epsilon^2} \Rightarrow \sigma_\eta^2 = q \cdot \sigma_\epsilon^2$$

Calcula F_t^* e P_t^*

Escreve FK reparametrizado

Subst. F_t na log ver. por $F_t^* \sigma_\epsilon^2$

$$l_{dc}(\psi) = -\frac{n}{2} \log 2\pi - \frac{(n-1)}{2} \log \sigma_\epsilon^2 - \frac{1}{2} \sum_{t=2}^n \left(\log F_t^* + \frac{y_t^2}{F_t^* \sigma_\epsilon^2} \right)$$

\hookrightarrow deriva em σ_ϵ^2

$$\text{acha } \hat{\sigma}_\epsilon^2 = \frac{1}{n-1} \sum_{t=2}^n \frac{y_t^2}{F_t^*}$$

$$\Rightarrow \text{Escreve } l_{dc}(\psi) = -\frac{n}{2} \log 2\pi - \frac{(n-1)}{2} - \frac{(n-1)}{2} \log \hat{\sigma}_\epsilon^2 - \frac{1}{2} \sum_{t=2}^n \log F_t^*$$

\hookrightarrow só função de $\underline{\underline{\eta}}$

Modelo de tendência linear

$$y_t = \mu_t + \varepsilon_t \quad \rightarrow \text{Modelo de tendência linear determinística}$$

$$\mu_{t+1} = \mu_t + \beta_t + \eta_t \quad \rightarrow \text{tendência estocástica da série}$$

$$\beta_{t+1} = \beta_t + \kappa_t \quad \rightarrow \text{inclinação da tend. estocástica.}$$

→ Obs: casos particulares

$$1) \quad \sigma_\eta^2 = \sigma_\kappa^2 = 0 \quad \Rightarrow \quad \mu_{t+1} = \mu_t + \beta_t$$

$$\cdot \beta_{t+1} = \beta_t \quad \Rightarrow \quad \beta_1 = \beta_0$$

$$\beta_2 = \beta_1 = \beta_0$$

$$\cdot \mu_{t+1} = \mu_t + \beta_t \quad \therefore \quad \mu_1 = \mu_0 + \beta$$

$$\mu_2 = \mu_1 + \beta = \mu_0 + 2\beta$$

$$\therefore \mu_t = \mu_0 + \beta \cdot t$$

visa tendência linear determinística

$$2) \quad \sigma_\kappa^2 = 0 \quad \Rightarrow \quad \beta_{t+1} = \beta_t = \beta_{t-1} = \dots = \beta_0$$

$$\mu_{t+1} = \mu_t + \beta_0 \quad \therefore \quad \mu_1 = \mu_0 + \beta_0 + \eta_0$$

$$\mu_2 = \mu_1 + \beta_0 + \eta_1$$

$$= \mu_0 + 2\beta_0 + \eta_0 + \eta_1$$

$$\vdots$$

$$\mu_t = \mu_0 + t\beta_0 + \sum_{i=0}^{t-1} \eta_i$$

$$\text{ou } \mu_t = \mu_{t-1} + \beta + \eta_t$$

inclinação da tendência é fixa no tempo

$$3) \quad \sigma_\eta^2 = 0 \quad \Rightarrow \quad \mu_{t+1} = \mu_t + \beta_t \quad \rightarrow \text{chamado tendência suave}$$

4 2ª diferença é um RB.

$$\beta_{t+1} = \beta_t + \kappa_t$$

$$4) \quad \text{Se } \sigma_\varepsilon^2 = \sigma_\kappa^2 = 0$$

$$\Rightarrow y_t = \mu_t$$

$$\mu_{t+1} = \mu_t + \beta + \eta_t$$

$$\beta_{t+1} = \beta_t \quad \downarrow$$

parâmetro aleatório
com drift

→ Forma de Espaço de Estado

$$y_t = \begin{pmatrix} 1 & 0 \end{pmatrix} \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} + \varepsilon_t$$

$$\begin{pmatrix} \mu_{t+1} \\ \beta_{t+1} \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \eta_t \\ \kappa_t \end{pmatrix}$$

• É estacionário?

Avaliar $|\lambda_i(\tau)|$

$$\begin{vmatrix} 1-\lambda & 1 \\ 0 & 1-\lambda \end{vmatrix} = (1-\lambda)^2 \dots \lambda_1 = \lambda_2 = 1 \Rightarrow \text{Nas é estacionário}$$

• É observável?

Avaliar $\det(m')$

$$m' = (z' \quad T'z')$$

$$T'z' = \begin{pmatrix} 1 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$\Rightarrow m' = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \det(m') = 1 \Rightarrow \text{É observável}$$

• Função de Previsão:

$$\hat{y}_{t+s|t} = E[y_{t+s} | \underline{y}_t]$$

$$= E[z\alpha_{t+s} + \varepsilon_{t+s} | \underline{y}_t]$$

$$= z E[\alpha_{t+s} | \underline{y}_t]$$

$$= (1 \quad 0) \begin{pmatrix} E[\mu_{t+s} | \underline{y}_t] \\ E[\beta_{t+s} | \underline{y}_t] \end{pmatrix}$$

$$= E[\mu_{t+s} | \underline{y}_t] \rightarrow \text{divida: já sabemos sair daqui?}$$

$$\text{Mas } \mu_{t+1} = \mu_t + \beta_t + \eta_t$$

↓

$$\hat{m}_{t+s|t} = \hat{m}_{t|t} + z \hat{b}_{t|t} \quad ?$$

• Filtro de Kalman p/ este modelo: Provar que previsão é um EWMA.

$$* v_t = y_t - z\alpha_t \quad \therefore v_t = y_t - (1 \quad 0) \begin{pmatrix} m_t \\ b_t \end{pmatrix} \therefore v_t = y_t - m_t$$

$$\begin{aligned}
 * F_t &= 2 p_t z' + \sigma_\varepsilon^2 \\
 &= (1 \quad 0) \begin{pmatrix} p_t^{11} & p_t^{12} \\ p_t^{21} & p_t^{22} \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} + \sigma_\varepsilon^2 \\
 &= (p_t^{11} \quad p_t^{12}) \begin{pmatrix} 1 \\ 0 \end{pmatrix} + \sigma_\varepsilon^2 = p_t^{11} + \sigma_\varepsilon^2
 \end{aligned}$$

$$* M_t = \begin{pmatrix} p_t^{11} & p_t^{12} \\ p_t^{21} & p_t^{22} \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} p_t^{11} \\ p_t^{21} \end{pmatrix}$$

$$\begin{aligned}
 * K_t &= \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} p_t^{11} & p_t^{12} \\ p_t^{21} & p_t^{22} \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} \frac{1}{F_t} = \\
 &= \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} p_t^{11} \\ p_t^{21} \end{pmatrix} \frac{1}{F_t} = \begin{pmatrix} p_t^{11} + p_t^{21} \\ p_t^{21} \end{pmatrix} \cdot \frac{1}{F_t}
 \end{aligned}$$

$$\begin{aligned}
 * L_t &= \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} - \begin{pmatrix} K_1 \\ K_2 \end{pmatrix} \begin{pmatrix} 1 & 0 \end{pmatrix} \\
 &= \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} - \begin{pmatrix} K_1 & 0 \\ K_2 & 0 \end{pmatrix} = \begin{pmatrix} 1-K_1 & 1 \\ -K_2 & 0 \end{pmatrix}
 \end{aligned}$$

File completo Atualizações

$$* a_{t|t} = a_t + M_t F_t^{-1} v_t$$

$$\begin{pmatrix} m_{t|t} \\ b_{t|t} \end{pmatrix} = \begin{pmatrix} m_t \\ b_t \end{pmatrix} + \begin{pmatrix} p_t^{11} \\ p_t^{21} \end{pmatrix} \frac{1}{p_t^{11} + \sigma_\varepsilon^2} (y_t - m_t)$$

$$\therefore m_{t|t} = m_t + \frac{p_t^{11}}{p_t^{11} + \sigma_\varepsilon^2} (y_t - m_t)$$

$$= \frac{p_t^{11}}{p_t^{11} + \sigma_\varepsilon^2} y_t + \left(1 - \frac{p_t^{11}}{p_t^{11} + \sigma_\varepsilon^2} \right) m_t$$

$$b_{t|t} = b_t + \frac{p_t^{21}}{p_t^{11} + \sigma_\varepsilon^2} (y_t - m_t)$$

Da previsões Mas $a_t = T a_{t-1|t-1} = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} m_{t-1|t-1} \\ b_{t-1|t-1} \end{pmatrix} \Rightarrow \begin{aligned} m_t &= m_{t-1|t-1} + b_{t-1|t-1} \\ b_t &= b_{t-1|t-1} \end{aligned}$

$$\Rightarrow m_t | t =$$

$$b_t | t = \dots$$

FK 2 em 1

$$a_{t+1} = T a_t + K_t v_t$$

$$\begin{pmatrix} m_{t+1} \\ b_{t+1} \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} m_t \\ b_t \end{pmatrix} + \begin{pmatrix} k_1 \\ k_2 \end{pmatrix} (y_t - m_t)$$

$$m_{t+1} = m_t + b_t + k_1 (y_t - m_t)$$

$$= k_1 y_t + (1 - k_1) m_t + b_t$$

$$b_{t+1} = b_t + k_2 (y_t - m_t)$$

$$= k_2 y_t - k_2 m_t + b_t$$

como daqui
enxergo EWMA?

Suavizações

$$n_{t-1} = z' F_t^{-1} v_t + L_t' n_t$$

$$\begin{pmatrix} n_{t-1}^m \\ n_{t-1}^b \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix} \frac{1}{F_t} (y_t - m_t) + \begin{pmatrix} 1 - k_1 & 1 \\ -k_2 & 0 \end{pmatrix} \begin{pmatrix} n_t^m \\ n_t^b \end{pmatrix}$$

$$\begin{pmatrix} \hat{\mu}_t \\ \hat{\beta}_t \end{pmatrix} = \begin{pmatrix} m_t \\ b_t \end{pmatrix} + \begin{pmatrix} p_t^{11} & p_t^{12} \\ p_t^{21} & p_t^{22} \end{pmatrix} \begin{pmatrix} n_{t-1}^m \\ n_{t-1}^b \end{pmatrix}$$

$$N_{t-1} = z' F_t^{-1} z + L_t' N_t L_t$$

$$= \begin{pmatrix} 1 \\ 0 \end{pmatrix} \frac{1}{F_t} \begin{pmatrix} 1 & 0 \end{pmatrix} + \begin{pmatrix} 1 - k_1 & -k_2 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} N_t^{11} & N_t^{12} \\ N_t^{21} & N_t^{22} \end{pmatrix} \begin{pmatrix} 1 - k_1 & 1 \\ -k_2 & 0 \end{pmatrix}$$

$$= \frac{1}{F_t} \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} + \begin{pmatrix} \end{pmatrix}$$

Observações faltantes

Supondo faltantes de $t = \tau$ a τ^*-1

→ NO FK normal: $\tilde{y}_t \Rightarrow \tilde{v}_t, \tilde{F}_t$

$$\therefore v_t = 0, F_t = 0 \Rightarrow k_t = 0$$

Equações FK ficam:

$$\begin{cases} a_{t|t} = a_t \\ p_{t|t} = p_t \\ a_{t+1} = T a_{t|t} = T a_t \\ p_{t+1} = T p_{t|t} T' + R Q_t R' = T p_t T' + R Q_t R' \end{cases}$$

$$\begin{pmatrix} m_{t+1} \\ b_{t+1} \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} m_t \\ b_t \end{pmatrix} \quad \therefore \begin{cases} m_{t+1} = m_t + b_t \\ b_{t+1} = b_t \end{cases} \left. \vphantom{\begin{pmatrix} m_{t+1} \\ b_{t+1} \end{pmatrix}} \right\} \begin{array}{l} \text{reta com} \\ \text{inclinação} \\ \text{etc.} \end{array}$$


→ Para suavização: $v_t = 0, F_t = 0$

$$\begin{cases} \hat{\alpha}_t = a_t + p_t \lambda_{t-1} \\ \lambda_{t-1} = L_t' \lambda_t = T' \lambda_t \end{cases} \quad \begin{cases} v_t = p_t - p_t N_{t-1} p_t \\ N_{t-1} = T' N_t T \end{cases}$$

Preenchimento das Faltantes

$$y_t = z a_t \text{ (por FK)} \quad \therefore y_t = (1 \ 0) \begin{pmatrix} m_t \\ b_t \end{pmatrix} = m_t = \underline{m_{t-1} + b_{t-1}}$$

$$\text{ou } y_t = z \hat{\alpha}_t \text{ (por suavização).}$$



Inicialização do FK

As duas variáveis de estado são não estacionárias

Se tivesse estacionárias
faria pela distribuição
condicional

duas formas de inicialização:

- 1) Difusa (ou dita difusa ^{via Big Kappa} aproximada), chamada tb de "Prior Difusa"
É uma dist. imprópria, mas a ideia é que considere todos os
possíveis valores iniciais como equiprováveis.

$$\alpha_i \sim N \left[\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} K & 0 \\ 0 & K \end{pmatrix} \right] \quad \text{onde } K \text{ é um valor } \rightarrow \infty$$

\downarrow \downarrow
 a_i $P_i = K I$

(abordagem Big Kappa)

Vamos computando FK desde $t=1$, mas só passamos a considerar válidos os cálculos quando a distribuição se tornar própria.

Normalmente \Rightarrow $(t=d+1)$ dist. se torna própria onde d é o n.º de componentes n.º estacionárias.

Muito \Rightarrow Nesse caso
mostrar que para este modelo, dist. se torna própria
a partir de $t=3$.

Procedimento de inicialização difusa via big kappa não é muito
estável computacionalmente, podendo gerar erros de arredondamento
que podem comprometer os resultados do FK.

Além disso, q.º viramos a função de verossimilhança, vemos que
temos que desconsiderar 1º termo por conta disso.

O método alternativo é mais estável e preciso.

- 2) Inicialização Exata (ou dita difusa exata).

$$\text{Modelo geral pt } \alpha_i = a + A\delta + R_0\eta_0$$

\downarrow \downarrow
comp. comp.
n.º estac. estac.

$$\eta_0 \sim N(0, Q_0)$$

Nesse caso: 40' components nas estacionárias

$$\alpha_t = A \tilde{\delta}$$

$$\tilde{\delta} = \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} \sim N \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, K \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \right)$$

$$\Rightarrow a_t = E[\alpha_t] = 0$$

$$P_t = \text{var}(\alpha_t) = A \text{var} \delta A' = K A A' = K \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

(nas aparece P_* pois é relativa a comp. estacionária)

Para atualização \Rightarrow usa FK exato inicial até encontrar $P_{00,t+1} = 0$.

A partir daí \Rightarrow usa FK padrão.

$$F_{00,t} = Z P_{00,t} Z', \quad M_{00,t} = P_{00,t} Z_t'$$

$$F_t^{(1)} = F_{00,t}^{-1}$$

$$F_{*,t} = H_t$$

$$K_t^{(0)} = T M_{00,t} F_t^{(1)}$$

$$F_t^{(2)} = -F_{00,t}^{-1} F_{*,t} F_{00,t}^{-1}$$

$$L_t^{(0)} = T_t - K_t^{(0)} Z_t$$

$$K_t^{(1)} = T M_{00,t} F_t^{(2)}$$

$$v_t^{(0)} = y_t - Z_t a_t^{(0)}$$

$$L_t^{(1)} = -K_t^{(1)} Z_t$$

$$a_{t+1} = \hat{\alpha}_{t+1}^{(0)} = T_t \hat{\alpha}_t^{(0)} + K_t^{(0)} v_t^{(0)}$$

$$P_{00,t+1} = T P_{00,t} L_t^{(0)'} + K_t^{(0)}$$

Solução inicial $\Rightarrow a_t = 0$

$$F_{*,0} = \sigma_E^2$$

$$P_{00,1} = I$$

Para $t=1$:

$$F_{00,1} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = 1$$

$$M_{00,1} = Z_t' = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

$$F_1^{(1)} = 1$$

$$F_{*,0} = \sigma_E^2$$

$$K_1^{(0)} = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} \cdot 1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

$$F_0^{(2)} = -\sigma_E^2$$

$$L_1^{(0)} = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} - \begin{pmatrix} 1 \\ 0 \end{pmatrix} \begin{pmatrix} 1 & 0 \end{pmatrix} = \begin{pmatrix} 0 & 1 \\ 0 & 1 \end{pmatrix}$$

$$K_1^{(1)} = -\begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} \sigma_E^2 = -\begin{pmatrix} 1 \\ 0 \end{pmatrix} \sigma_E^2$$

$$L_1^{(1)} = \sigma_E^2 \begin{pmatrix} 1 \\ 0 \end{pmatrix} \begin{pmatrix} 1 & 0 \end{pmatrix} = \sigma_E^2 \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}$$

$$\Rightarrow P_{0,2} = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 0 & 1 \\ 0 & 1 \end{pmatrix}'$$

$$= \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 0 & 0 \\ 1 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$$

Para $t=3$

vai encontrar $P_{0,3} = 0$

Logo: FK padias pode começar a ser usado a partir $t=3$

com $P_{d+1} = P_{*,d+1}$

ou seja $\boxed{P_3 = P_{*,3}}$ e $\boxed{a_3 = \hat{a}_3^{(0)}}$

Funções de Verossimilhança

Neste caso, temos 2 componentes não estacionárias. Nas

Nas podemos usar Funções Verossimilhança tradicionais

Tradicional

$$L(\psi) = \prod_{i=1}^n p(y_t | \tilde{y}_{t-1}) \quad \rightarrow \text{fdp preditiva.}$$

onde $p(y_t | \tilde{y}_{t-1}) = \frac{1}{2\pi^{p/2} |F_t|^{1/2}} \exp \left\{ -\frac{1}{2} \underbrace{(y_t - za_t)'}_{v_t} F_t^{-1} \underbrace{(y_t - za_t)}_{v_t} \right\}$

$$\Rightarrow \ell(\psi) = \sum_{i=1}^n \log p(y_t | \tilde{y}_{t-1})$$

$$= \sum_{i=1}^n \left[-\frac{p}{2} \log 2\pi - \frac{1}{2} \log |F_t|^{1/2} - \frac{1}{2} v_t' F_t^{-1} v_t \right]$$

$$= -\frac{np}{2} \log 2\pi - \frac{1}{2} \sum_{i=1}^n \left(\log |F_t| + v_t' F_t^{-1} v_t \right)$$

Para este modelo $\rightarrow p = \textcircled{1}$

$$l(\gamma) = -\frac{n}{2} \log 2\pi - \frac{1}{2} \sum_{t=1}^n (\log |F_t| + v_t' F_t^{-1} v_t)$$

→ Trabalhando com funções verossimilhança, a abordagem bip-kappa

computamos FK desde o início, mas só passamos a considerar como válidos os valores a partir do momento em que dist.

x torna própria.

Nesse caso: $t = 3$

$$l^{bk}(\gamma) = -\frac{(n-q)p}{2} \log 2\pi - \frac{1}{2} \sum_{t=q+1}^n (\log |F_t| + v_t' F_t^{-1} v_t)$$

$$l(\gamma) = -(n-2) \log 2\pi - \frac{1}{2} \sum_{t=3}^n (\log |F_t| + v_t' F_t^{-1} v_t)$$

→ Funções Verossimilhança difusa

É definida como:

$$l_d(\gamma) = \log L_d(\gamma) = \lim_{k \rightarrow \infty} \left[\log L(\gamma) + \frac{q}{2} \log k \right]$$

envolvendo, temos:

$$l_d(\gamma) = -\frac{n \textcircled{p}}{2} \log 2\pi - \frac{1}{2} \sum_{t=1}^d w_t - \frac{1}{2} \sum_{t=d+1}^n (\log |F_t| + v_t' F_t^{-1} v_t)$$

onde w_t = depende de $F_{0,t}$ e $F_{x,t}$ do procedimento da inicialização exata.

Para este caso:

$$l_d(\gamma) = -\frac{n}{2} \log 2\pi - \frac{1}{2} \sum_{t=1}^2 \textcircled{w_t} - \frac{1}{2} \sum_{t=3}^n (\log |F_t| + v_t' F_t^{-1} v_t)$$

→ como pode explicitar?

→ Funções verossimilhança concentrada difusa.

A concentração é a reparametrização do modelo η reduzindo a dimensionalidade da busca numérica.

Nesse caso, temos 2 razões sinal ruído

$$q_\eta = \frac{\sigma_\eta^2}{\sigma_\varepsilon^2} \quad q_k = \frac{\sigma_k^2}{\sigma_\varepsilon^2}$$

É necessário definir:

$$P_t^* = \frac{1}{\sigma_\varepsilon^2} P_t \quad \text{e} \quad F_t^* = \frac{1}{\sigma_\varepsilon^2} F_t$$

Calcula F_t^* e na $l_d(4)$ substitui F_t por $\sigma_\varepsilon^2 F_t^*$

$$\begin{aligned} F_t &= Z P_t Z' + \sigma_\varepsilon^2 = (1 \quad 0) \begin{pmatrix} P_t^{11} & P_t^{12} \\ P_t^{21} & P_t^{22} \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} + \sigma_\varepsilon^2 \\ &= (P_t^{11} \quad P_t^{12}) \begin{pmatrix} 1 \\ 0 \end{pmatrix} + \sigma_\varepsilon^2 \end{aligned}$$

$$\therefore F_t = P_t^{11} + \sigma_\varepsilon^2$$

$$\boxed{F_t^* = P_t^{11*} + 1}$$

$$\Rightarrow l_d(4) = -n \log 2\pi - \frac{1}{2} \sum_{t=1}^n \underbrace{(\omega_t)}_{\text{como depende de } \sigma_\varepsilon^2} - \sum_{t=3}^n \left(\log |F_t^* \sigma_\varepsilon^2| + \frac{v_t^2}{F_t^* \sigma_\varepsilon^2} \right)$$

como depende de σ_ε^2

Na realidade, trabalhamos com

$$\sigma_\varepsilon^2 = e^{2\psi_\varepsilon} \therefore \psi_\varepsilon = \log \sigma_\varepsilon$$

Equações de Ricatti

$$\boxed{P_{t+1} = T_\varepsilon P_t L_t' + R_t \Phi_t R_t} \quad \text{Equações do passo de previsões do FK.}$$

$$\downarrow$$

$$L_t = T_\varepsilon - K_t Z$$

$$K_t = T P_t Z' F_t^{-1}$$

\vdots

$$\text{igual a } P_{t+1} = P_t = \bar{P}$$

Modelo Tendência linear

$$y_t = \mu_t + \varepsilon_t$$

$$\mu_{t+1} = \mu_t + \beta_t + \eta_t$$

$$\beta_{t+1} = \beta_t + \zeta_t$$

$$v_t = y_t - z_t' a_t$$

$$F_t = z_t P_t z_t' + \sigma_E^2$$

$$K_t = T P_t z_t' F_t^{-1}$$

$$L_t = T - K_t z_t$$

$$\Rightarrow y_t = (1 \ 0) \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} + \varepsilon_t$$

$$a_t = \begin{pmatrix} a_{t,1} \\ a_{t,2} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\begin{pmatrix} \mu_{t+1} \\ \beta_{t+1} \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \eta_t \\ \zeta_t \end{pmatrix}$$

$$P_t = \begin{pmatrix} K & 0 \\ 0 & K \end{pmatrix}$$

$t=1$ (FK 2 em 1)

$$\bullet v_1 = y_1 - z_1' a_1$$

$$= y_1 - (1 \ 0) \begin{pmatrix} a_{1,1} \\ a_{1,2} \end{pmatrix} = y_1 - a_{1,1}$$

$$\bullet F_1 = (1 \ 0) \begin{pmatrix} K & 0 \\ 0 & K \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} + \sigma_E^2 = (1 \ 0) \begin{pmatrix} K \\ 0 \end{pmatrix} + \sigma_E^2$$
$$= K + \sigma_E^2$$

$$\bullet K_1 = T P_1 z_1' F_1^{-1}$$

$$= \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} K & 0 \\ 0 & K \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} \frac{1}{K + \sigma_E^2}$$

$$= \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} K \\ 0 \end{pmatrix} \cdot \frac{1}{K + \sigma_E^2} = \begin{pmatrix} K \\ 0 \end{pmatrix} \cdot \frac{1}{K + \sigma_E^2} = \begin{pmatrix} \frac{K}{K + \sigma_E^2} \\ 0 \end{pmatrix}$$

$$\bullet L_1 = T - K_1 z_1 = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} - \begin{pmatrix} \frac{K}{K + \sigma_E^2} \\ 0 \end{pmatrix} (1 \ 0) = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} - \begin{pmatrix} \frac{K}{K + \sigma_E^2} & 0 \\ 0 & 0 \end{pmatrix}$$

$$\therefore L_1 = \begin{pmatrix} \frac{\sigma_E^2}{K + \sigma_E^2} & 1 \\ 0 & 1 \end{pmatrix}$$

$$\Rightarrow a_2 = T a_1 + K_1 v_1$$

$$= \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 0 \\ 0 \end{pmatrix} + \begin{pmatrix} \frac{K}{K + \sigma_E^2} \\ 0 \end{pmatrix} (y_1 - \cancel{a_{1,1}})$$

$$= \begin{pmatrix} 0 \\ 0 \end{pmatrix} + \begin{pmatrix} \frac{K y_1}{K + \sigma_E^2} \\ 0 \end{pmatrix} = \begin{pmatrix} \frac{K y_1}{K + \sigma_E^2} \\ 0 \end{pmatrix}$$

$$P_2 = T P_1 L_1' + R Q R'$$

$$= \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} K & 0 \\ 0 & K \end{pmatrix} \begin{pmatrix} \frac{\sigma_E^2}{K + \sigma_E^2} & 0 \\ 1 & 1 \end{pmatrix} + \begin{pmatrix} \sigma_E^2 & 0 \\ 0 & \sigma_\eta^2 \end{pmatrix} =$$

$$= \begin{pmatrix} K & K \\ 0 & K \end{pmatrix} \begin{pmatrix} \frac{\sigma_E^2}{K + \sigma_E^2} & 0 \\ 1 & 1 \end{pmatrix} + \begin{pmatrix} \sigma_E^2 & 0 \\ 0 & \sigma_\eta^2 \end{pmatrix} =$$

$$= \begin{pmatrix} \frac{K \sigma_E^2}{K + \sigma_E^2} + K & K \\ K & K \end{pmatrix} + \begin{pmatrix} \sigma_E^2 & 0 \\ 0 & \sigma_\eta^2 \end{pmatrix} =$$

$$= \begin{pmatrix} \frac{K \sigma_E^2}{K + \sigma_E^2} + K + \sigma_E^2 & K \\ K & K + \sigma_\eta^2 \end{pmatrix}$$

t=2

$$\cdot v_2 = y_2 - z a_2 = y_2 - (1 \ 0) \begin{pmatrix} \frac{K y_1}{K + \sigma_E^2} \\ 0 \end{pmatrix} = y_2 - \frac{K y_1}{K + \sigma_E^2}$$

$$\cdot F_2 = (1 \ 0) \begin{pmatrix} p_{11,2} & p_{12,2} \\ p_{21,2} & p_{22,2} \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} + \sigma_E^2$$

$$\therefore F_2 = (1 \ 0) \begin{pmatrix} p_{11,2} \\ p_{21,2} \end{pmatrix} + \sigma_E^2 \Rightarrow F_2 = p_{11,2} + \sigma_E^2 = \frac{k\sigma_E^2}{k + \sigma_E^2} + k + 2\sigma_E^2$$

$$\bullet K_2 = TP_2 Z' F_2^{-1}$$

$$= \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} p_{11,2} & p_{21,2} \\ p_{21,2} & p_{22,2} \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} \frac{1}{F_2} =$$

$$= \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} p_{11,2} \\ p_{21,2} \end{pmatrix} \frac{1}{F_2} = \begin{pmatrix} p_{11,2} + p_{21,2} \\ p_{21,2} \end{pmatrix} \cdot \frac{1}{F_2} = \begin{pmatrix} \frac{p_{11,2} + p_{21,2}}{F_2} \\ \frac{p_{21,2}}{F_2} \end{pmatrix}$$

$$\bullet L_2 = I - K_2 Z$$

$$= \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} - \begin{pmatrix} k_{1,2} \\ k_{2,2} \end{pmatrix} \begin{pmatrix} 1 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} - \begin{pmatrix} k_{1,2} & 0 \\ k_{2,2} & 0 \end{pmatrix}$$

$$= \begin{pmatrix} 1 - k_{1,2} & 1 \\ -k_{2,2} & 1 \end{pmatrix}$$

$$\Rightarrow a_3 = Ta_2 + k_2 v_2 =$$

$$= \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} a_{2,1} \\ a_{2,2} \end{pmatrix} + \begin{pmatrix} \frac{p_{11,2} + p_{21,2}}{F_2} \\ \frac{p_{21,2}}{F_2} \end{pmatrix} = \begin{pmatrix} a_{2,1} + a_{2,2} \\ a_{2,2} \end{pmatrix} + \begin{pmatrix} \frac{p_{11,2} + p_{21,2}}{F_2} \\ \frac{p_{21,2}}{F_2} \end{pmatrix}$$

Como $a_{2,2} = 0$

$$= \begin{pmatrix} a_{2,1} + \frac{p_{11,2} + p_{21,2}}{F_2} \\ a_{2,2} + \frac{p_{21,2}}{F_2} \end{pmatrix}$$

$$P_3 = TP_2L_2' + RQR$$

$$= \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} p_{11,2} & p_{12,2} \\ p_{21,2} & p_{22,2} \end{pmatrix} \begin{pmatrix} 1 - k_{1,2} & 1 \\ -k_{2,2} & 1 \end{pmatrix} + \begin{pmatrix} \sigma_E^2 & 0 \\ 0 & \sigma_\eta^2 \end{pmatrix}$$

$$= \begin{pmatrix} p_{11,2} + p_{21,2} & p_{12,2} + p_{22,2} \\ p_{21,2} & p_{22,2} \end{pmatrix} \begin{pmatrix} 1 - k_{1,2} & 1 \\ -k_{2,2} & 1 \end{pmatrix} + \begin{pmatrix} \sigma_E^2 & 0 \\ 0 & \sigma_\eta^2 \end{pmatrix}$$

$$= \begin{pmatrix} \textcircled{A} (p_{11,2} + p_{21,2}) - k_{2,2}(p_{12,2} + p_{22,2}) + \sigma_E^2 & \textcircled{B} p_{11,2} + p_{21,2} + p_{12,2} + p_{22,2} \\ \textcircled{C} p_{21,2} - p_{21,2} \cdot k_{1,2} - k_{2,2} \cdot p_{22,2} & \textcircled{D} p_{21,2} + p_{22,2} + \sigma_\eta^2 \end{pmatrix}$$

avaliando as expressões:

$$\textcircled{A} \quad p_{11,2} + p_{21,2} - k_{2,2}(p_{12,2} + p_{22,2}) + \sigma_E^2 =$$

$$= \frac{K\sigma_E^2}{K + \sigma_E^2} + K + \sigma_E^2 + K - \frac{p_{21,2}(p_{12,2} + p_{22,2}) + \sigma_E^2}{F_2} =$$

$$\frac{K(K + K + \sigma_\eta^2)}{\frac{K\sigma_E^2}{K + \sigma_E^2} + K + 2\sigma_E^2}$$

=

O que queremos?

Estimar α_t dado certo conjunto de informações observável

$$\tilde{y}_j \left\{ \begin{array}{l} j=t \Rightarrow \text{previsas} \\ j=t-1 \Rightarrow \text{atualizações} \\ j=n \Rightarrow \text{navigações} \end{array} \right\} \text{ FK}$$

→ serve p/ fazer extrações de componentes

Dois formas de fazer

1) Estimativas via recursiva

Queremos estimar α_t , se seja:

$$E[\alpha_t | y] \text{ e } \text{var}(\alpha_t | y)$$

Precisamos de $p(\alpha_t | y)$.

Seja modelo linear local.

$$\begin{aligned} y_t &= \alpha_t + \varepsilon_t & \varepsilon_t &\sim N(0, \sigma_\varepsilon^2) & \alpha_t &\sim (a_t, p_t) \\ \alpha_{t+1} &= \alpha_t + \eta_t & \eta_t &\sim N(0, \sigma_\eta^2) & E[\varepsilon_t \alpha_t] &= E[\eta_t \alpha_t] = 0 \quad \forall t \\ & & & & E[\varepsilon_t \varepsilon_s] &= 0 \quad \forall t, s. \end{aligned}$$

a) Calculando $E[y]$ e $\text{var}(y)$

$$y_1 = \alpha_1 + \varepsilon_1$$

$$y_2 = \alpha_2 + \varepsilon_2 = \alpha_1 + \eta_1 + \varepsilon_2$$

⋮

$$y_n = \alpha_1 + (\eta_1 + \dots + \eta_{n-1}) + \varepsilon_n$$

(Acha y_n recursivamente)

$$\text{Seja } y = (y_1, y_2, \dots, y_n)'$$

$$\Rightarrow E[y] = \begin{pmatrix} a_1 \\ \vdots \\ a_n \end{pmatrix} = \mathbb{1}a_1 \quad (\text{calcula } E[y] = \mathbb{1}a_1)$$

$$\text{var}(y) = E[(y - E(y))(y - E(y))']$$

$$= \begin{bmatrix} \text{var}(y_1) & \text{cov}(y_1, y_2) & \dots & \text{cov}(y_1, y_n) \\ \text{cov}(y_1, y_2) & & & \\ & & & \\ & & & \text{var}(y_n) \end{bmatrix}_{n \times n}$$

variâncias

$$\begin{aligned}\text{var}(y_1) &= E[(y_1 - a_1)^2] \\ &= E[(\alpha_1 + \varepsilon_1 - a_1)^2] = \text{var}(\alpha_1) + \text{var}(\varepsilon_1) \\ &= p_1 + \sigma_\varepsilon^2\end{aligned}$$

$$\begin{aligned}\text{var}(y_2) &= E[(y_2 - a_1)^2] \\ &= E[(\alpha_1 + \eta_1 + \varepsilon_1 - a_1)^2] = \text{var}(\alpha_1) + E[\varepsilon_1^2] + E[\eta_1^2] \\ &= p_1 + \sigma_\varepsilon^2 + \sigma_\eta^2\end{aligned}$$

$$\text{var}(y_n) = p_1 + \sigma_\varepsilon^2 + (n-1)\sigma_\eta^2$$

(calcula matriz $\text{var}(y)$ usando cada y_i sucessivamente)

covariâncias

$$\begin{aligned}\text{cov}(y_1, y_2) &= E[(y_1 - a_1)(y_2 - a_1)] \\ &= E[(\alpha_1 + \varepsilon_1 - a_1)(\alpha_1 + \eta_1 + \varepsilon_2 - a_1)] \\ &= E[(\alpha_1 - a_1 + \varepsilon_1)((\alpha_1 - a_1) + \eta_1 + \varepsilon_2)] = \\ &= p_1\end{aligned}$$

$$\begin{aligned}\text{cov}(y_2, y_3) &= E[(y_2 - a_1)(y_3 - a_1)] \\ &= E[(\alpha_1 + \eta_1 + \varepsilon_2 - a_1)(\alpha_1 + \eta_1 + \eta_2 + \varepsilon_3 - a_1)] \\ &= p_1 + \sigma_\eta^2\end{aligned}$$

$$\Rightarrow \text{var}(y) = \begin{bmatrix} p_1 + \sigma_\varepsilon^2 & p_1 & \dots & p_1 \\ p_1 & p_1 + \sigma_\eta^2 + \sigma_\varepsilon^2 & & \\ \vdots & p_1 + \sigma_\eta^2 & \ddots & \\ p_1 & p_1 + 2\sigma_\eta^2 & \dots & p_1 + (n-1)\sigma_\eta^2 + \sigma_\varepsilon^2 \end{bmatrix}$$

$$= \mathbf{1}\mathbf{1}' p_1 + \Sigma_{ij} \quad \text{onde} \quad \Sigma_{ij} = \begin{cases} (i-1)\sigma_\eta^2 & i < j \\ \sigma_\varepsilon^2 + (i-1)\sigma_\eta^2 & i = j \\ (j-1)\sigma_\eta^2 & i > j \end{cases}$$

matriz
n x n e
p₁

\Rightarrow a matriz $\text{var}(y)$ cresce com o número de observações.

b) Calculando $E[\alpha]$ e $\text{Var}(\alpha)$

$$\alpha_1 = \alpha_1$$

$$\alpha_2 = \alpha_1 + \eta_1$$

$$\alpha_3 = \alpha_2 + \eta_2 = \alpha_1 + \eta_1 + \eta_2$$

...

$$\alpha_n = \alpha_1 + (\eta_1 + \eta_2 + \dots + \eta_{n-1})$$

$$\text{Seja } \alpha = (\alpha_1, \alpha_2, \dots, \alpha_n)'$$

$$\Rightarrow E[\alpha] = \begin{pmatrix} a_1 \\ \vdots \\ a_1 \end{pmatrix} = \mathbb{1} a_1 \quad (\text{calcula } E(\alpha) = \mathbb{1} a_1)$$

$$\text{Var}(\alpha) = E[(\alpha - E(\alpha))(\alpha - E(\alpha))']$$

$$= \begin{bmatrix} \text{Var}(\alpha_1) & \text{Cov}(\alpha_1, \alpha_2) & \dots & \text{Cov}(\alpha_1, \alpha_n) \\ \vdots & \ddots & \ddots & \vdots \\ \text{Cov}(\alpha_i, \alpha_n) & \dots & \text{Var}(\alpha_n) \end{bmatrix}$$

variâncias

$$\text{Var}(\alpha_1) = E[(\alpha_1 - a_1)^2] = p_1$$

$$\begin{aligned} \text{Var}(\alpha_2) &= E[(\alpha_2 - a_1)^2] = \\ &= E[(\alpha_1 + \eta_1 - a_1)^2] = \\ &= p_1 + \sigma_\eta^2 \end{aligned}$$

...

$$\text{Var}(\alpha_n) = p_1 + (i-1) \sigma_\eta^2 \quad i=1, 2, \dots, n$$

covariâncias

$$\begin{aligned} \text{Cov}(\alpha_1, \alpha_2) &= E[(\alpha_1 - a_1)(\alpha_2 - a_1)] \\ &= E[(\alpha_1 - a_1)(\alpha_1 + \eta_1 - a_1)] \\ &= p_1 \end{aligned}$$

$$\text{Cov}(\alpha_1, \alpha_3) = \dots = p_1$$

$$\therefore \text{Cov}(\alpha_1, \alpha_n) = p_1$$

$$\text{Cov}(\alpha_2, \alpha_3) = \dots = p_1 + \sigma_\eta^2$$

Pl $j > i$

$$\alpha_i = \alpha_1 + \sum_{t=1}^{i-1} \eta_t$$

$$\text{cov}(\alpha_i, \alpha_j) = \begin{cases} p_1 + (i-1)\sigma_\eta^2 & \text{se } i \leq j \\ p_1 + (j-1)\sigma_\eta^2 & \text{se } i > j \end{cases}$$

$$\Rightarrow \text{var}(\alpha) = \begin{cases} p_1 + (i-1)\sigma_\eta^2 & \text{se } i \leq j \\ p_1 + (i-1)\sigma_\eta^2 & \text{se } i = j \\ p_1 + (j-1)\sigma_\eta^2 & \text{se } i > j \end{cases}$$

c) calculando $\text{cov}(y, \alpha)$ conjuntamente

$$\text{cov}(y, \alpha) = E[(y - \mathbb{1}a_1)(\alpha - \mathbb{1}a_1)']$$

cada termo individualmente

$$\text{cov}(y_i, \alpha_j) = E[(\alpha_i - a_1)(y_j - a_1)]$$

$$\therefore y_i = \alpha_i + \sum_{t=1}^{i-1} \eta_t + \varepsilon_i \quad \left\{ \begin{array}{l} \text{suavendo recursivamente} \end{array} \right.$$

$$\alpha_j = \alpha_1 + \sum_{s=1}^{j-1} \eta_s$$

$$\therefore (y_i - a_1) = (\alpha_i - a_1) + \sum_{t=1}^{i-1} \eta_t + \varepsilon_i$$

$$(\alpha_j - a_1) = (\alpha_1 - a_1) + \sum_{s=1}^{j-1} \eta_s$$

$$\therefore E[(y_i - a_1)(\alpha_j - a_1)'] = E\left[(\alpha_1 - a_1) + \sum_{t=1}^{i-1} \eta_t + \varepsilon_i \left((\alpha_1 - a_1) + \sum_{s=1}^{j-1} \eta_s \right)'\right]$$

$$= E\left[(\alpha_1 - a_1)^2 + E\left(\sum_{t=1}^{i-1} \eta_t \sum_{s=1}^{j-1} \eta_s\right)\right]$$

$$= p_1 + \begin{cases} (i-1)\sigma_\eta^2 & i \leq j \\ (j-1)\sigma_\eta^2 & i > j \end{cases}$$

d) caracterizar probabilisticamente y e α através do seguinte resultado:

$$\begin{pmatrix} \alpha \\ y \end{pmatrix} \sim N \left[\begin{pmatrix} \mathbb{1}a_1 \\ \mathbb{1}a_1 \end{pmatrix}, \begin{pmatrix} \text{var}(\alpha) & \text{cov}(\alpha, y) \\ \text{cov}(y, \alpha) & \text{var}(y) \end{pmatrix} \right]$$

onde $\underline{1}a_i = (a_1, \dots, a_i)'$ $i \times 1$

$$\text{var}(\underline{x}) = \begin{cases} (i-1)\sigma_\eta^2 + p_1 & i \leq j \\ (j-1)\sigma_\eta^2 + p_1 & i > j \end{cases}$$

$$\text{var}(\underline{y}) = \begin{cases} (i-1)\sigma_\eta^2 + p_1 & i < j \\ (i-1)\sigma_\eta^2 + p_1 + \sigma_\varepsilon^2 & i = j \\ (j-1)\sigma_\eta^2 + p_1 & i > j \end{cases}$$

$$\text{cov}(\underline{y}, \underline{x}) = \begin{cases} (i-1)\sigma_\eta^2 + p_1 & i \leq j \\ (j-1)\sigma_\eta^2 + p_1 & i > j \end{cases} \Rightarrow = \text{var}(\underline{x})$$

e) Queremos estimar \underline{x} dada info da \underline{y} e $\underline{1}$
 precisamos de $p(\underline{x}|\underline{y}) \Rightarrow$ pt obter $E(\underline{x}|\underline{y})$ e $\text{var}(\underline{x}|\underline{y})$

Resultados importantes para usarmos

$$\begin{pmatrix} \underline{x} \\ \underline{y} \end{pmatrix} \sim N \left[\begin{pmatrix} \mu_x \\ \mu_y \end{pmatrix}, \begin{pmatrix} \Sigma_{xx} & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_{yy} \end{pmatrix} \right] \text{ onde } \Sigma_{yx} = \Sigma_{xy}'$$

então $f(\underline{x}|\underline{y}=\underline{y}) \sim N(E[\underline{x}|\underline{y}=\underline{y}], \text{var}[\underline{x}|\underline{y}=\underline{y}])$

$$E[\underline{x}|\underline{y}=\underline{y}] = \mu_x + \Sigma_{xy} \Sigma_{yy}^{-1} (\underline{y} - \mu_y)$$

$$\text{var}[\underline{x}|\underline{y}=\underline{y}] = \Sigma_{xx} - \Sigma_{xy} \Sigma_{yy}^{-1} \Sigma_{yx}$$

fazendo $\underline{x} = \underline{\alpha}$ e $\underline{y} = \underline{y}$, temos:

$f(\underline{\alpha}|\underline{y}=\underline{y}) \sim N(E(\underline{\alpha}|\underline{y}=\underline{y}), \text{var}(\underline{\alpha}|\underline{y}=\underline{y}))$ onde

$$E[\underline{\alpha}|\underline{y}=\underline{y}] = E[\underline{\alpha}] + \text{cov}(\underline{\alpha}, \underline{y}) (\text{var}(\underline{y}))^{-1} (\underline{y} - \underline{1}a, \underline{1})$$

$$= \underline{1}a_i + \text{cov}(\underline{\alpha}, \underline{y}) (\text{var}(\underline{y}))^{-1} (\underline{y} - \underline{1}a, \underline{1})$$

$$= \underline{1}a_i + \underline{Z}_0 \rightarrow \text{divida}$$

precisa
saber o
q' dado?

f) Conclusões

Esta forma de se obter estimativa pt $\underline{\alpha}$ mas é recomendável pois

(i) $\text{var}(\underline{y})$ e $\text{var}(\underline{\alpha})$ têm dimensões $n \times n$ onde n é tamanho da amostra

A cada instante, a estimativa é calculada usando toda info da amostra.

(ii) Se n de obs. vai crescendo q tempo \Rightarrow matrizes $\text{Var}(y)$ e $\text{Var}(x)$ vão crescendo. O procedimento deverá ser todo repetido, sem aproveitar estimativa em n q estimar em $n+1$.
Procedimento \bar{n} é recursivo.

(iii) Elementos de $\text{Var}(x)$ e $\text{Var}(y)$ devem ser estimados por mv

(iv) Não é possível obter estimativas de previsões p/ x .

— " —

2) Pelo FK.

2.1) Passo da Previsão.

(I) $y_t = z_t \alpha_t + \varepsilon_t$, $\varepsilon_t \sim N(0, H_t)$

(No ex. anterior:

$$z_t = 1$$

(II) $\alpha_{t+1} = T_t \alpha_t + R_t \eta_t$, $\eta_t \sim N(0, Q_t)$

$$T_t = 1 \quad R_t = 1.$$

$$\begin{cases} y_t = \alpha_t + \varepsilon_t \\ \alpha_{t+1} = \alpha_t + \eta_t \end{cases}$$

Sejam:

$$a_{t+1} = E[\alpha_{t+1} | \underline{y}_t]$$

$$P_{t+1} = \text{var}[\alpha_{t+1} | \underline{y}_t] \quad \text{onde} \quad \underline{y}_t = (y_1, y_2, \dots, y_{t-1}, y_t)$$

Queremos:

$$a_{t+1} = E[\alpha_{t+1} | \underline{y}_t]$$

$$P_{t+1} = \text{var}[\alpha_{t+1} | \underline{y}_t]$$

a) cálculo a_{t+1}

$$a_{t+1} = E[\alpha_{t+1} | \underline{y}_t] =$$

$$= E[T_t \alpha_t + R_t \eta_t | \underline{y}_t]$$

$$= T_t E[\alpha_t | \underline{y}_t] \quad \therefore \boxed{a_{t+1} = T_t a_{t|t}}$$

$$(\text{se eq. fosse } \alpha_{t+1} = T_t \alpha_t + c_t + R_t \eta_t \Rightarrow a_{t+1} = T_t a_{t|t} + c_t)$$

b) Cálculo P_{t+1}

$$P_{t+1} = \text{var}(\alpha_{t+1} | \underline{y}_t) \quad \leftarrow \text{coloca cond. aqui}$$

$$= E[(\underbrace{\alpha_{t+1} - E[\alpha_{t+1} | \underline{y}_t]}_{a_{t+1}})(\underbrace{\alpha_{t+1} - E[\alpha_{t+1} | \underline{y}_t]}_{a_{t+1}})' | \underline{y}_t]$$

da equação (II)

$$\begin{aligned} \alpha_{t+1} &= T_t \alpha_t + R_t \eta_t \\ E[\alpha_{t+1}] &= a_{t+1} = T_t a_{t|t} \end{aligned} \quad \left\{ \begin{aligned} (\alpha_{t+1} - E[\alpha_{t+1} | \underline{y}_t]) &= T_t (\alpha_t - a_{t|t}) + R_t \eta_t \\ (\alpha_{t+1} - E[\alpha_{t+1} | \underline{y}_t])' &= (\alpha_t - a_{t|t})' T_t' + \eta_t' R_t' \end{aligned} \right.$$

b.1) Atm expressas P_{t+1}

$$\Rightarrow P_{t+1} = E[(T_t (\alpha_t - a_{t|t}) + R_t \eta_t)((\alpha_t - a_{t|t})' T_t' + \eta_t' R_t') | \underline{y}_t]$$

$$= E_t \left[\underbrace{T_t (\alpha_t - a_{t|t}) (\alpha_t - a_{t|t})' T_t'}_A + \underbrace{T_t (\alpha_t - a_{t|t}) \eta_t' R_t'}_B + \underbrace{R_t \eta_t (\alpha_t - a_{t|t})' T_t'}_C + \underbrace{R_t \eta_t \eta_t' R_t'}_D \right]$$

com condicional $E_t = E(\cdot | \underline{y}_t)$

b.2) Escrever eq. (II) recursivamente

$$\alpha_{t+1} = T_t \alpha_t + R_t \eta_t$$

$$\alpha_2 = T_1 \alpha_1 + R_1 \eta_1$$

$$\alpha_3 = T_2 \alpha_2 + R_2 \eta_2$$

$$= T_2 (T_1 \alpha_1 + R_1 \eta_1) + R_2 \eta_2$$

$$= T_2 T_1 \alpha_1 + T_2 R_1 \eta_1 + R_2 \eta_2$$

$$\alpha_4 = T_3 \alpha_3 + R_3 \eta_3$$

$$= T_3 (T_2 T_1 \alpha_1 + T_2 R_1 \eta_1 + R_2 \eta_2) + R_3 \eta_3$$

$$= \underbrace{T_3 T_2 T_1}_{\left(\prod_{i=1}^3 T_i\right)} \alpha_1 + \underbrace{T_3 T_2 R_1}_{\sum_{j=1}^3 \left(\prod_{i=0}^{j-1} T_{t-i}\right)} \eta_1 + \underbrace{T_3 R_2}_{\left(\prod_{i=0}^{2} T_{t-i}\right)} \eta_2 + R_3 \eta_3$$

$$\left(\prod_{i=1}^3 T_i\right) \alpha_1 + \sum_{j=1}^3 \left(\prod_{i=0}^{j-1} T_{t-i}\right) R_{t-j} \eta_{t-j} + R_t \eta_t$$

(expressas fica longa por conta de (T, R))

$$\Rightarrow \alpha_{t+1} = \left(\prod_{j=1}^{t-1} T_j\right) \alpha_1 + \sum_{j=1}^{t-1} \left[\prod_{i=0}^{j-1} T_{t-i}\right] R_{t-j} \eta_{t-j} + R_t \eta_t$$

b.3) cálculo das parcelas.

$$\begin{aligned} A &= E_t [T_t (\alpha_t - a_{t|t}) (\alpha_t - a_{t|t})' T_t'] = \\ &= T_t E_t [(\alpha_t - a_{t|t}) (\alpha_t - a_{t|t})'] T_t' \quad \therefore \quad \left[A = T_t \left(P_{t|t} \right) T_t' \right] \end{aligned}$$

$\text{var}(\alpha_t | \underline{y}_t)$

- $$\begin{aligned}
 B_t &= E_t [T_t (\alpha_t - a_t) \eta_t' R_t'] = \\
 &= T_t E_t [(\alpha_t - a_t) \eta_t'] R_t' \\
 &= T_t E_t [\alpha_t \eta_t'] - T_t E_t a_t E(\eta_t') R_t \\
 &= T_t E_t [\alpha_t \eta_t'] \\
 &\quad \downarrow \\
 &\text{equivale a}
 \end{aligned}$$

$$\begin{aligned}
 E_{t+1} [\alpha_{t+1} \eta_{t+1}'] &= E_{t+1} \left[\left(\prod_{j=1}^{t+1} T_j \right) \alpha_1 \cdot \eta_{t+1}' + \left(\sum_{j=1}^{t+1} \left[\prod_{i=0}^{j-1} T_{t-i} \right] R_{t-j} \eta_{t-j} \right) \cdot \eta_{t+1}' + R_t \eta_t \eta_{t+1}' \right] \\
 &= \left(\prod_{j=1}^{t+1} T_j \right) E_{t+1} [\alpha_1 \eta_{t+1}'] + \sum_{j=1}^{t+1} \left[\prod_{i=0}^{j-1} T_{t-i} \right] R_{t-j} E_{t+1} [\eta_{t-j} \eta_{t+1}'] + R_t E[\eta_t \eta_{t+1}'] = 0
 \end{aligned}$$

$\therefore B_t = 0 \quad \forall t$

- $C_t = 0$ (analogamente)

- $$\begin{aligned}
 D_t &= E_t [R_t \eta_t \eta_t' R_t'] = R_t \underbrace{E_t [\eta_t \eta_t']}_{\Phi_t} R_t' \\
 D_t &= R_t \Phi_t R_t'
 \end{aligned}$$

logo:

$$\begin{cases}
 P_{t+1} = \text{var}(\alpha_{t+1} | \underline{y}_t) \\
 = T_t P_t T_t' + R_t \Phi_t R_t'
 \end{cases}$$

Resumo previsas:

$$\begin{cases}
 a_{t+1} = E[\alpha_{t+1} | \underline{y}_t] = T_t a_t \\
 P_{t+1} = \text{var}[\alpha_{t+1} | \underline{y}_t] = T_t P_t T_t' + R_t \Phi_t R_t'
 \end{cases}$$

2.2) Passo de Atualizações

Queremos agora

$$\begin{cases} \hat{\alpha}_t | t = E[\alpha_t | \underline{y}_t] \\ P_t | t = \text{Var}[\alpha_t | \underline{y}_t] \end{cases}$$

a) Resultados importantes que usaremos:

$$a.1) \begin{pmatrix} x \\ y \\ z \end{pmatrix} \sim N \left[\begin{pmatrix} \mu_x \\ \mu_y \\ \mu_z \end{pmatrix}, \begin{pmatrix} \Sigma_{xx} & \Sigma_{xy} & \Sigma_{xz} \\ \Sigma_{yx} & \Sigma_{yy} & \Sigma_{yz} \\ \Sigma_{zx} & \Sigma_{zy} & \Sigma_{zz} \end{pmatrix} \right]$$

dividido
podemos
fazer.

Supondo $\mu_z = 0$ e $\Sigma_{zy} = 0$ ($\Sigma_{yz} = 0$), temos:

$$E[x | y = y, z = z] = \mu_{x|y} + \Sigma_{xz} \Sigma_{zz}^{-1} (z)$$

$$\text{Var}[x | y = y, z = z] = \Sigma_{xx|y} - \Sigma_{xz} \Sigma_{zz}^{-1} \Sigma_{zx}$$

a.2) Se x e y são 2 vetores aleatórios e $g: \mathbb{R}^p \rightarrow \mathbb{R}^p$ (bijetiva)
então

$$F_{x|y} = F_{x|g(y)} \Rightarrow E[x | y = y] = E[x | g(y) = g(y)]$$

b) cálculo de a_t

$$a_t = E[\alpha_t | \underline{y}_t]$$

↓ decomposição em \underline{y}_{t-1} e y_t

$$= E[\alpha_t | \underline{y}_{t-1}, y_t]$$

↓ substitui y_t por v_t

$$= E[\alpha_t | \underline{y}_{t-1}, v_t] \quad \text{onde } v_t = y_t - \underbrace{E[y_t | \underline{y}_{t-1}]}_{z_t a_t} \quad \begin{array}{l} \text{erro de previsão} \\ \text{1 passo a frente} \end{array}$$

b.1) Justificar que podemos usar v_t ao invés de y_t que dá o mesmo.

$$v_t = y_t - E[y_t | \underline{y}_{t-1}]$$

$$= E[z_t \alpha_t + \epsilon_t | \underline{y}_{t-1}]$$

$$= z_t (a_t) \quad \text{já calculamos } a_t = E[\alpha_t | \underline{y}_{t-1}]$$

$= y_t - z_t a_t \Rightarrow$ conteúdo informacional de y_t não é modificado
e usamos v_t (função bijetiva).

b.2) Podemos usar resultado 1 com

$$x = \alpha_t, \quad y = \underline{y}_{t-1}, \quad z = v_t$$

precisamos provar que $\begin{cases} \mu_z = \mu_{v_t} = 0 \\ \Sigma_{zy} = \Sigma_{v_t, \underline{y}_{t-1}} = 0. \end{cases}$

• $\mu_z = E(z) = 0$

$= E(v_t)$

→ usar lei das expectativas iteradas.

mas $E(v_t) = E[E(v_t | \underline{y}_{t-1})]$ } escreva v_t como $y_t - z_t \alpha_t$

$$E(v_t | \underline{y}_{t-1}) = E[y_t - z_t \alpha_t | \underline{y}_{t-1}]$$

$$= E[y_t | \underline{y}_{t-1}] - z_t \alpha_t$$

$$= z_t \alpha_t - z_t \alpha_t = 0.$$

$$\Rightarrow E(v_t) = 0.$$

• $\Sigma_{yz} = 0$

$$= \Sigma_{\underline{y}_{t-1}, v_t} = \text{cov}(\underline{y}_{t-1}, v_t)$$

$$\text{mas } \text{cov}(\underline{y}_{t-1}, v_t) = E[(y_{t-1} - E[y_{t-1}]) (y_t - E[y_t])']$$

$$= E[y_{t-1} \cdot v_t']$$

✓

$$\begin{pmatrix} y_{t-1} \\ y_{t-2} \\ \vdots \\ y_1 \end{pmatrix} (v_1 \ v_2 \ \dots \ v_t)$$

onde cada elemento dessa matriz será dado por

$$\{E[y_{t-j} v_t]\}_{j=1,2,\dots,t-1}$$

↓

Lei das exp. iteradas: $E[y_{t-j} v_t] = E[E[y_{t-j} v_t | \underline{y}_{t-1}]]$

$$= E[y_{t-j} E[v_t | \underline{y}_{t-1}]]$$

$$= 0$$

b.3) usar o resultado

⇒ Podemos usar o resultado 1:

$$E[\alpha_t | \underline{y}_t] = E[\alpha_t | \underline{y}_{t-1}] + \text{cov}[\alpha_t, v_t] (\text{var}(v_t))^{-1} v_t$$

b.4) cálculo de $\text{var}(v_t)$ e $\text{cov}(\alpha_t, v_t)$

$$\begin{aligned} \bullet \text{var}(v_t) &= E[(v_t - E[v_t])(v_t - E[v_t])'] \\ &= E[v_t v_t'] = E[E[v_t v_t' | y_{t-1}]] \\ &\quad \text{lei exp. iteradas} \end{aligned}$$

$$\begin{aligned} \text{mas } v_t &= y_t - z_t \alpha_t \\ &= z_t x_t + \varepsilon_t - z_t \alpha_t \\ &= z_t (x_t - \alpha_t) + \varepsilon_t \\ \therefore v_t' &= (x_t - \alpha_t)' z_t' + \varepsilon_t' \end{aligned}$$

$$\begin{aligned} \Rightarrow E[v_t v_t' | y_{t-1}] &= E[(z_t (x_t - \alpha_t) + \varepsilon_t) (x_t - \alpha_t)' z_t' + \varepsilon_t' | y_{t-1}]] \\ &= E[z_t (x_t - \alpha_t) (x_t - \alpha_t)' z_t'] + E[\varepsilon_t \varepsilon_t' | y_{t-1}] \end{aligned}$$

termos cruzados são nulos.

$$= z_t P_t z_t' + H_t$$

$$\therefore E[v_t v_t'] = E[E[v_t v_t' | y_{t-1}]] \Rightarrow \boxed{E[v_t v_t'] = z_t P_t z_t' + H_t \hat{=} f_t}$$

$\text{var}(v_t)$

$\bullet \text{cov}(\alpha_t, v_t) (= m_t)$

$$\begin{aligned} &= E[(\alpha_t - E[\alpha_t])(v_t - E[v_t])'] \\ &= E[\alpha_t v_t'] = E[E[\alpha_t v_t' | y_{t-1}]] \\ &\quad \text{lei da exp. iteradas} \end{aligned}$$

$$\begin{aligned} \text{mas } \alpha_t v_t' &= \alpha_t (y_t - z_t \alpha_t)' = \\ &= \alpha_t [z_t x_t + \varepsilon_t - z_t \alpha_t]' = \\ &= \alpha_t [z_t (x_t - \alpha_t) + \varepsilon_t]' = \\ &= \alpha_t [(x_t - \alpha_t)' z_t' + \varepsilon_t'] \end{aligned}$$

$$\begin{aligned} \therefore E[\alpha_t v_t' | y_{t-1}] &= E[\alpha_t (x_t - \alpha_t)' z_t' | y_{t-1}] + E[\alpha_t \varepsilon_t' | y_{t-1}] \\ &\quad \text{pois } \alpha_t \varepsilon_t' = 0 \\ &= E[(\alpha_t - \alpha_t) (x_t - \alpha_t)' z_t' | y_{t-1}] + 0 \\ &= 0 \end{aligned}$$

$$v_t = y_t - z_t \alpha_t$$

$$\alpha_t = E[x_t | y_{t-1}]$$

$$P_t = \text{var}(x_t | y_{t-1})$$

$$\alpha_{t+1} = E[x_{t+1} | y_t]$$

$$P_{t+1} = \text{var}(x_{t+1} | y_t)$$

$$f_t = \text{var}(v_t) = z_t P_t z_t' + H_t$$

$$m_t = \text{cov}(\alpha_t, v_t)$$

obs:
para
termos
cruzados,
para α_t que
já tem de x_t
e ε_t 's.

$$\Rightarrow M_t = \text{cov}(\alpha_t, v_t)$$

$$= E[(\alpha_t v_t' | y_{t-1})] \Rightarrow \boxed{M_t = P_t Z_t'}$$

b.5) substituir $\text{var}(v_t)$ e $\text{cov}(\alpha_t, v_t)$ em 6.3

$$\boxed{E[\alpha_t | y_t] = a_t + M_t F_t^{-1} v_t}$$

$a_{t|t}$

$$\text{onde } M_t = P_t Z_t'$$

$$F_t^{-1} = Z_t' P_t Z_t^{-1} + H_t$$

$$v_t = y_t - Z_t a_t$$

c) cálculo de $P_{t|t}$

$$P_{t|t} = \text{var}[\alpha_t | y_t]$$

↓ decompõe em y_{t-1} e y_t (ou v_t)

$$= \text{var}[\alpha_t | y_{t-1}, v_t]$$

usa resultado 1:

$$P_{t|t} = \underbrace{\text{var}(\alpha_t | y_{t-1})}_{P_t} - \underbrace{\text{cov}(\alpha_t, v_t)}_{M_t} \underbrace{\text{var}(v_t)}_{F_t}^{-1} \underbrace{(\text{cov}(\alpha_t, v_t))'}_{M_t'}$$

$$= P_t - M_t F_t^{-1} M_t'$$

$$= P_t - (P_t Z_t') F_t^{-1} (P_t Z_t')'$$

$$= P_t - P_t Z_t' F_t^{-1} Z_t P_t$$

\Rightarrow

$$\boxed{P_{t|t} = P_t - P_t Z_t' F_t^{-1} Z_t P_t}$$

é simétrica,
não precisa.

Próximas Atualizações

$$a_{t|t} = a_t + M_t F_t^{-1} v_t$$

$$P_{t|t} = P_t - P_t Z_t' F_t^{-1} Z_t P_t$$

atualizada.

prevista

correção

3) FK 2 em 1

Subst. $a_{t|t}$ e $P_{t|t}$ nas expressões da previsão.

$$\begin{aligned}
 a_{t+1} &= T_t a_{t|t} \\
 &= T_t [a_t + m_t F_t^{-1} v_t] \\
 &= T_t a_t + \underbrace{T_t m_t F_t^{-1}}_{K_t} v_t
 \end{aligned}$$

$$\therefore \begin{cases} a_{t+1} = T_t a_t + K_t v_t \end{cases} \quad \text{onde } K_t \text{ é o ganho de Kalman.}$$

$$\begin{aligned}
 P_{t+1} &= T_t P_{t|t} T_t' + R_t Q_t R_t' \\
 &= T_t \left(P_t - \underbrace{P_t z_t' F_t^{-1}}_{M_t} \underbrace{z_t P_t}_{M_t'} \right) T_t' + R_t Q_t R_t' \\
 &= T_t P_t \underbrace{(T_t' - M_t F_t^{-1} M_t' T_t')}_{L_t'} + R_t Q_t R_t'
 \end{aligned}$$

$$L_t' = T_t' - P_t z_t' F_t^{-1} z_t P_t T_t' \rightarrow \text{dividir} \quad \underline{\text{fazer}}$$

\Rightarrow Atenção: P_{t+1} não depende das observações y_t
dependendo do caso, converge para steady state

EXEMPLO

① $\begin{cases} y_t = \mu_t + \varepsilon_t \\ \mu_{t+1} = \mu_t + \eta_t \end{cases} \quad (\text{Nível local})$

$$\begin{aligned}
 z &= 1 & H &= \sigma_\varepsilon^2 \\
 r &= 1 & Q &= \sigma_\eta^2 \\
 R &= 1
 \end{aligned}$$

\rightarrow cálculo K_t

$$K_t = T_t M_t F_t^{-1} = \underbrace{T_t P_t z_t'}_1 \underbrace{z_t F_t^{-1}}_1 = P_t F_t^{-1} = \frac{P_t}{F_t} \quad (\text{Simplificar})$$

$$\begin{aligned}
 \text{Mas } F_t &= \text{var}(v_t) \\
 &= \text{var}(y_t - z_t a_t) = z_t z_t' + H = P_t + \sigma_\varepsilon^2
 \end{aligned}$$

$$\Rightarrow K_t = \frac{P_t}{P_t + \sigma_\varepsilon^2} \quad \Rightarrow 0 < K_t < 1$$

→ cálculo a_{t+1}

$$a_{t+1} = T_t a_t + K_t (y_t - T_t a_t)$$

$$= T_t a_t + K_t (y_t - T_t a_t)$$

$$= a_t + K_t (y_t - a_t)$$

$$= K_t y_t + (1 - K_t) a_t$$

$$\hookrightarrow E[\mu_t | y_{t-1}] = E[y_t | y_{t-1}] \quad \text{pois } y_t = \mu_t + \varepsilon_t$$

$$= K_t y_t + (1 - K_t) \hat{y}_{t|t-1} \Rightarrow \text{EWMA!}$$

⇒ Modelo de nível local: funções de previsões

$$y_t = \mu_t + \delta_t + \varepsilon_t$$

$$\mu_{t+1} = \mu_t + \beta_t + \eta_t$$

$$\beta_{t+1} = \beta_t + \zeta_t$$

$$\delta_t = \sum \delta_{t-j} + w_t$$

Modelo de previsões

usando FK convergência MHW.

$$y_t = \mu_t + \beta_t + \varepsilon_t$$

$$\mu_{t+1} = \mu_t + \beta_t + \eta_t$$

$$\beta_{t+1} = \beta_t + \zeta_t$$

Na forma EE:

$$y_t = \begin{pmatrix} 1 & 1 \end{pmatrix} \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} + \varepsilon_t$$

$$\begin{pmatrix} \mu_{t+1} \\ \beta_{t+1} \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \eta_t \\ \zeta_t \end{pmatrix}$$

$$Z = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}$$

$$R = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

$$T = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}$$

$$H = \sigma_\varepsilon^2$$

$$Q = \begin{pmatrix} \sigma_\eta^2 & 0 \\ 0 & \sigma_\zeta^2 \end{pmatrix}$$

$$\rightarrow \text{cálculo } K_t = T_t M_t F_t^{-1} = T_t Z F^{-1}$$

$$F = \text{var}(V_t) = TP_tT' + H$$


$$= TP_tT' + \sigma_e^2 I$$

$$\Rightarrow K = TP_tZ(TP_tT' + \sigma_e^2 I)^{-1}$$

$$= TP_tZ$$

divida

por



Passo de suavização

Estimativa suavizada (ou alocada) do estado.

$$y = \underline{y}_n = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \sim (n \times p) \times 1 \quad (\text{cada elemento } y \text{ é } p \text{ variáveis})$$

Queremos:

$$\hat{x}_t = E[x_t | \underline{y}_n] \quad t=1, 2, \dots, n$$

$$V_t = \text{var}[x_t | \underline{y}_n]$$

a) cálculo de \hat{x}_t

$$\hat{x}_t = E[x_t | \underline{y}_n]$$

↓ decompondo em \underline{y}_{t-1} e inovações até 'n

$$= E[x_t | \underline{y}_{t-1}, v_t, v_{t+1}, \dots, v_n]$$

a.i) usa resultado 1

$$\text{Seja } x = x_t$$

$$y = \underline{y}_{t-1}$$

$$z = (v_t, v_{t+1}, \dots, v_n)' \Rightarrow [\text{dimensões } (n-t+1) \cdot p \times 1]$$

usando resultado 1 da aula passada ($x \text{ dist } \left(\frac{x}{z} \right)$), temos:

$$\hat{x}_t = E[x_t | \underline{y}_n] = \underbrace{E[x_t | \underline{y}_{t-1}]}_{\hat{x}_t(FK)} + \text{cov}[x_t, (v_t, v_{t+1}, \dots, v_n)'] \cdot (\text{var}[(v_t, v_{t+1}, \dots, v_n)'])^{-1} \begin{pmatrix} v_t \\ v_{t+1} \\ \vdots \\ v_n \end{pmatrix}$$

a.i.i) Cálculo de $\text{var}(v_t, v_{t+1}, \dots, v_n)$

(i) mostrar que v_i 's são independentes

$$\text{P! tanto, mostraremos que } p(v_1, v_2, \dots, v_n) = \prod_{i=1}^n p(v_i)$$

(ii) calcula

$$p(y_1, y_2, \dots, y_n) = p(\underbrace{y_1, y_2, \dots, y_{n-1}}_{\underline{y}_{n-1}}, y_n) =$$

$$= p(y_n, \underline{y}_{n-1}) = p(y_n | \underline{y}_{n-1}) \cdot p(\underline{y}_{n-1}) =$$

lei de Bayes.

$$= p(y_n | \underline{y}_{n-1}) \cdot p(y_{n-1} | \underline{y}_{n-2}) \cdot p(\underline{y}_{n-2}) = p(y_n | \underline{y}_{n-1}) \cdot p(y_{n-1} | \underline{y}_{n-2}) \cdot p(\underline{y}_{n-2})$$

$$= \dots = p(y_1) \cdot \prod_{t=2}^n p(y_t | y_{t-1})$$

← recursivamente

lembrando:

$$p(y_1, y_2, \dots, y_n) = p(y_1) \cdot \prod_{t=2}^n p(y_t | \underline{y}_{t-1})$$

\Downarrow

$$p(y_t | \underline{y}_{t-1}) \sim N(z_t a_t, F_t)$$

do passo F_t

$$\text{onde } F_t = z_t' z_t + H$$

$p(v)$:

mas queremos

(i2) \leadsto
calcula

$$p(v_1, v_2, \dots, v_n)$$

$$\text{e sabemos que } v_t = y_t - z_t a_t$$

usando resultado:

Se x vetor aleatório $n \times 1$ e $y = g(x)$, g diferenciável e com inversa

e $x \sim n \times 1$ com $f_x(x)$

$$\Rightarrow f_y(y) = f_x(g^{-1}(y)) |J(y)|$$

onde $J(y) = \text{jacobiano}$

$$|J(y)| = \text{determinante}$$

$$\{J(y)\}^{ij} = \partial y_i / \partial x_j$$

$$j = 1, \dots, n$$

$$i = 1, \dots, n$$

$$\text{fazendo } x = (y_1, \dots, y_n)'$$

$$y = (v_1, \dots, v_n)'$$

$$\Rightarrow p(v_1, \dots, v_n) = p(y_1, \dots, y_n) |_{y_i = v_i + z_i a_i}$$

$$\frac{\partial y_i}{\partial v_j} = \begin{cases} 1 & i=j \\ 0 & i \neq j \end{cases} \Rightarrow |J| = 1 \quad (\text{pois } J=I)$$

$$\therefore p(v_1, \dots, v_n) = p(y_1, \dots, y_n) |_{y_i = v_i + z_i a_i}$$

$$= p(y_1) \prod_{t=2}^n p(y_t | \underline{y}_{t-1}) |_{y_t = v_t + z_t a_t}$$

$$\text{mas } p(y_t | \underline{y}_{t-1}) = \frac{1}{(2\pi)^{p/2} |F_t|^{1/2}} \exp \left\{ -\frac{1}{2} \underbrace{(y_t - z_t a_t)' F_t^{-1} (y_t - z_t a_t)}_{v_t'} \right\}$$

$$\therefore p(v_t) = \frac{1}{(2\pi)^{p/2} |F_t|^{1/2}} \exp \left\{ -\frac{1}{2} v_t' F_t^{-1} v_t \right\}$$

$$\therefore p(v_1, \dots, v_n) = p(y_1) \cdot \prod_{t=2}^n p(v_t)$$

para $t=1 \Rightarrow y_1 = z_1 \alpha_1 + \varepsilon_1$

$$E(y_1) = z_1 E(\alpha_1) = z_1 a_1$$

$$\text{var}(y_1) = E[(y_1 - E(y_1))(y_1 - E(y_1))']$$

$$\therefore y_1 - E(y_1) = z_1(\alpha_1 - a_1) + \varepsilon_1$$

$$\begin{aligned} \Rightarrow \text{var}(y_1) &= E[(z_1(\alpha_1 - a_1) + \varepsilon_1)((\alpha_1 - a_1)' z_1' + \varepsilon_1')] = \\ &= z_1 P_\alpha z_1' + 4, = F_1 \end{aligned}$$

para $v_1 = y_1 - z_1 a_1 \Rightarrow E(v_1) = 0$
 $\text{var}(v_1) = F_1$

$$\therefore p(y_1) = \frac{1}{(2\pi)^{p/2}} \frac{1}{|F_1|^{1/2}} \exp\left\{-\frac{1}{2} (y_1 - z_1 a_1)' F_1^{-1} (y_1 - z_1 a_1)\right\}$$

$$v_1 = y_1 - z_1 a_1 \quad |J| = 1$$

$$\therefore p(v_1) = p(y_1) \big|_{y_1 = v_1 + z_1 a_1} \quad |J| = 1 \Rightarrow p(v_1) = p(y_1)$$

Logo:

$$p(v_1, \dots, v_n) = \prod_{i=1}^n p(v_i) \Rightarrow v_t \text{'s são independentes}$$

$$p(v_t | v_{t-1}) = p(v_t)$$

$$\therefore E[v_i v_j'] = 0 \quad \forall \begin{matrix} i = t, t+1, \dots, n \\ j = t, t+1, \dots, n \end{matrix} \quad i \neq j$$

(ii) Encontrar $\text{var}(v_t, v_{t+1}, \dots, v_n)$ como matriz diagonal

$$\text{var}((v_t, v_{t+1}, \dots, v_n)) = E \left[\begin{pmatrix} v_t \\ v_{t+1} \\ \vdots \\ v_n \end{pmatrix} (v_t \ v_{t+1} \ \dots \ v_n) \right]$$

$$= \begin{bmatrix} F_t & & & \\ & F_{t+1} & & \\ & & \ddots & \\ & & & F_n \end{bmatrix}$$

* matriz variâncias
de cada $v_i : p \times p$

a.1.2) calcular $\text{cov}(\alpha_t, (v_t, v_{t+1}, \dots, v_n)') =$

$$= E \left[\alpha_t \begin{pmatrix} v_t' & v_{t+1}' & \dots & v_n' \end{pmatrix} \right] =$$

$\begin{matrix} (1 \times 1) & (1 \times p) \end{matrix}$

$$= \begin{bmatrix} E[\alpha_t v_t'] & \dots & E[\alpha_t v_n'] \end{bmatrix}$$

a.1.3) substitui no resultado e fiz cálculos:

$$\hat{\alpha}_t = E[\alpha_t | y_n] = a_t + \begin{bmatrix} E[\alpha_t v_t'] & \dots & E[\alpha_t v_n'] \end{bmatrix} \cdot \begin{pmatrix} F_t^{-1} & & \\ & \ddots & \\ & & F_n^{-1} \end{pmatrix} \begin{pmatrix} v_t \\ v_{t+1} \\ \vdots \\ v_n \end{pmatrix}$$

$\begin{matrix} (n-t+1) \times (n-t+1) \dots p \\ (n-t+1) \times 1 \end{matrix}$
 $\begin{bmatrix} F_t^{-1} v_t & F_{t+1}^{-1} v_{t+1} & \dots & F_n^{-1} v_n \end{bmatrix}' \sim p$
 $\begin{matrix} p \times p & p \times 1 \end{matrix}$

$$= a_t + \begin{bmatrix} E[\alpha_t v_t'] & \dots & E[\alpha_t v_n'] \end{bmatrix} \begin{bmatrix} F_t^{-1} v_t \\ F_{t+1}^{-1} v_{t+1} \\ \vdots \\ F_n^{-1} v_n \end{bmatrix}$$

$$\hat{\alpha}_t = a_t + \sum_{j=t}^n E[\alpha_t v_j'] F_j^{-1} v_j$$

estimativa atualizada \rightarrow $\hat{\alpha}_t$
 estimativa prevista \rightarrow $E[\alpha_t v_j']$
 vamos escrever v_t em termos de x_t

b) outros resultados dos quais precisamos para escrever $\hat{\alpha}_t$ de forma alternativa:

Escrever MBE y_t com v_t
 b.1) seja $x_t \triangleq \alpha_t - a_t$ (como x poss um erro de previsão)

$$\text{var}(x_t) = \text{var}(\alpha_t) = P_t$$

Escrevendo v_t em função de x_t :

$$\begin{aligned} v_t &= y_t - z_t a_t \\ &= z_t x_t - z_t a_t + \varepsilon_t \\ &= z_t (x_t - a_t) + \varepsilon_t \end{aligned}$$

$$v_t = z_t x_t + \varepsilon_t \quad (I)$$

→ observando x_{t+1} , em funç. de x_t
 Temos ainda que:

$$\begin{aligned} x_{t+1} &= x_{t+1} - a_{t+1} \\ &= \underbrace{(T_t x_t + R_t \eta_t)}_{\text{do MEE}} - \underbrace{(T_t a_t + K_t v_t)}_{\text{do FK}} \\ &= T_t (\underbrace{x_t - a_t}_{x_t}) + R_t \eta_t - K_t (z_t x_t + \varepsilon_t) \\ &= (T_t - K_t z_t) x_t + R_t \eta_t - K_t \varepsilon_t \end{aligned}$$

onde:

$$L_t = T_t - K_t z_t$$

$$\therefore \boxed{x_{t+1} = L_t x_t + R_t \eta_t - K_t \varepsilon_t} \quad (\text{II})$$

As equações (I) e (II) podem ser vistas como MEE 14 as inovações:

$$\begin{cases} v_t = z_t x_t + \varepsilon_t \\ x_{t+1} = L_t x_t + R_t \eta_t - K_t \varepsilon_t \end{cases}$$

(as duas descorrelatadas)

c) Cálculo de $E(x_t v_j')$ na expressão de z_t em função de x_t

$$\begin{aligned} E[x_t v_j'] &= E[x_t (z_j x_j + \varepsilon_j)'] \\ &= \underbrace{E[x_t x_j']} \cdot z_j' \quad j = t, \dots, n \end{aligned}$$

$$\text{mas } E[x_t x_j'] = \underbrace{E[E(x_t x_j' | y_{t-1})]}_{\text{lei das exp. iteradas}}$$

$$\begin{aligned} \text{- Para } j=t \Rightarrow E[x_t x_t'] &= E[E(x_t x_t' | y_{t-1})] \\ &= E[E(x_t (x_t - a_t)' | y_{t-1})] \\ &= E[E[(x_t - a_t)(x_t - a_t)' | y_{t-1}]] \\ &= E[P_t] = P_t \end{aligned}$$

Successivamente ↓

$$\begin{aligned} \text{- Para } j=t+1 \Rightarrow E[x_t x_{t+1}'] &= E[E(x_t x_{t+1}' | y_{t-1})] = \\ &\quad \downarrow \text{do MEE dual} \\ &= E[E[x_t (L_t x_t + R_t \eta_t - K_t \varepsilon_t)' | y_{t-1}]] \\ &= E[E[x_t (x_t' L_t' + \eta_t' R_t' + \varepsilon_t' K_t') | y_{t-1}]] \\ &= E[E[x_t x_t' L_t' | y_{t-1}]] = \\ &= E[E[x_t (x_t - a_t)' L_t' | y_{t-1}]] \Rightarrow P_t L_t' \end{aligned}$$

Para $j = t+1$

$$\begin{aligned}
 E[\alpha_t x'_{t+2}] &= E[E(\alpha_t (L_{t+1} x_{t+1} + R_{t+1} \eta_{t+1} - K_{t+1} \varepsilon_{t+1})' | \underline{y}_{t-1})] = \\
 &= E[E[\alpha_t x'_{t+1} L'_{t+1} + \alpha_t \eta'_{t+1} R'_{t+1} - \alpha_t \varepsilon'_{t+1} K'_{t+1} | \underline{y}_{t-1}]] = \\
 &= E[E[\alpha_t x'_{t+1} L'_{t+1} | \underline{y}_{t-1}]] = \\
 &= E[\underbrace{E[\alpha_t x'_{t+1} | \underline{y}_{t-1}]}_{P_t L'_t} \cdot L'_{t+1}] \\
 &= P_t L'_t L'_{t+1}
 \end{aligned}$$

⋮

Para $j = n \Rightarrow E[\alpha_t x'_n] = P_t L'_t L'_{t+1} \dots L'_{n-1}$

Logo:

$$E[\alpha_t v'_j] z'_j = P_t L'_t L'_{t+1} \dots L'_{j-1} z'_j$$

d) substitui na expressão de \hat{z}_t

$$\begin{aligned}
 \hat{\alpha}_t &= a_t + \sum_{j=t}^n E[\alpha_t v'_j] F_j^{-1} v_j \\
 &= a_t + [P_t z'_t F_t^{-1} v_t + P_t L'_t z'_{t+1} F_{t+1}^{-1} v_{t+1} + \dots + P_t L'_t \dots L'_{n-1} z'_n F_n^{-1} v_n]
 \end{aligned}$$

e) Igualdade FK ^{atualizações} e smoothing em $t=n$

Em $t=n$: FK ^{atualizações} tem que se igualar a smoothing

Da atuali- $\hat{\alpha}_n = a_n + M_n F_n^{-1} v_n \quad \therefore \quad \hat{\alpha}_n = a_n + \underbrace{P_n}_{M_n} F_n^{-1} v_n$
 zações \downarrow
 FK $a_{n|n}$

(obs: $a_{n|n} = E[\alpha_n | \underline{y}_n]$ e $\hat{\alpha}_n = E[\alpha_n | y_1, \dots, y_n]$)

Inicializações + MV

→ Se todas componentes forem estacionárias

usa cond. inicial como distribuições incondicionais

$$\alpha_{t+1} = T\alpha_t + R\eta_t$$

$$\Rightarrow E[\alpha_{t+1}] = TE[\alpha_t] = 0 \therefore E[\alpha_t] = 0$$

$$\text{Var}[\alpha_{t+1}] = T \text{Var}[\alpha_t] T' + RQR'$$

se estacionário é igual

$$\Rightarrow \text{vec}[\text{Var}(\alpha_t)] = (I - T \otimes T)' [R \otimes R' \text{vec}(Q)]$$

como calcular na prática?

logo: $\alpha_t \sim N(0, \text{Var}(\alpha_t))$

nas α_t , como no texto

Função MV: Dada por

$$l(\psi) = \log L(\psi) = \log \left(\prod_{t=1}^n p(y_t | \underline{y}_{t-1}, \psi) \right)$$

$$= -\frac{np}{2} \log(2\pi) - \frac{1}{2} \sum_{t=1}^n (\log |F_t| + \underline{v}_t' F_t^{-1} \underline{v}_t)$$

→ Se houver componentes nas estacionárias

a) Prior difusa

• de forma geral com p componentes \tilde{n} estacionárias

$$\alpha_1 \sim N \left[\begin{pmatrix} 0 \\ \vdots \\ 0 \end{pmatrix}, K I_p \right]$$

divida:

se houver comp. estacionárias
continue inicializando
estas com incondicional

• chamada via "big kappa"

Não é muito estável computacionalmente ...

Na pg 3:

o que quer
dizer q deixa
 y_t fixo

Aqui já se inicia com k de valor muito alto.

função mv: chamada de $l^{bk}(\psi)$

(nas é chamada difusa, que é a outra da inicialização exata)

$$v_t = y_t - z_t' a_t \quad t=1, \dots, n$$

$$F_t = z_t' P_t z_t + H_t$$

usa a mv original, mas só passa a considerar inicialização propriamente dita quando dist. passar a ser própria

$$l(\psi)^{bk} = -\frac{(n-q)p}{2} \log(2\pi) - \frac{1}{2} \sum_{t=q+1}^n [\log |F_t| + v_t' F_t^{-1} v_t]$$

Vai ser
sta, nas
importa
que haja
componente
estacionária

Equações de a_t e P_t são atualizadas desde $t=1$ até (q) (na k)
mas F_t e v_t só entram na Fmv quando dist.
passar a ser própria

b) Inicialização Exata

Mais bem definido e + geral.

Escreve termos do F_k em função de k via expansões de Taylor, usando apenas os 2/3 primeiros termos como dominantes fazendo $k \rightarrow \infty$.

Expressão Geral:

$$x_t = a + \underbrace{A\delta}_{\text{parte nas stac.}} + \underbrace{R_0\eta_0}_{\text{parte stac.}}$$

$$\Rightarrow a_t = E[x_t] = a \quad \left(= 0 \text{ H modelos n\~ao estacion\~arios} \right)$$

x n\~ao haver componentes estacion\~arios?

$$P_t = K P_0 + P_* \quad \text{onde } x \text{ faz } k \rightarrow \infty \text{ em } t \text{ apropriado.}$$

$$\text{onde } P_{0,1} = A A'$$

$0 \dots R \dots P_0'$

Vai calculando $P_{00,t}$ e $P_{*,t}$ em cada t usando FK corrigido:

Para algum $t = d \Rightarrow P_{00,t+1} = 0$ e assim em $t = d+1, d+2, \dots, n$ passa a usar FK padrao.

Na pg 4: E $t+1$, nas t .

No exemplo: 2 comp. \bar{n} estacionarias

$P_{00,3} = 0 \Rightarrow$ usa FK padrao a partir de $t=3$, até T

Funcao MV: chamada $l^d(\psi)$

$$l_d(\psi) = \log L_d(\psi) = \lim_{K \rightarrow \infty} \left[\log L(\psi) + \left(\frac{q}{2}\right) \log K \right]$$

Nas deviana em $\left(\frac{d}{2}\right)$?

$$\Rightarrow l_d(\psi) = \log L_d(\psi) = -\left(\frac{np}{2}\right) \log 2\pi - \frac{1}{2} \sum_{t=1}^d w_t - \frac{1}{2} \sum_{t=d+1}^n \left[\log |F_t| + \frac{1}{v_t' F_t^{-1} v_t} \right]$$

$$\text{onde } w_t = \begin{cases} \log |F_{00,t}| \\ \log |F_{*,t}| + \dots \end{cases}$$

Neste caso, $l_d(\psi)$ e' computado desde $t=1$ (em todos os valores de t), mas somatório deve ser separado de 1 a d , $d+1$ a n .

Fazer
lde

concentrada

