

2^a parte (P2)

Resumo Notas de Aula I

→ Em MEE

$ST = \text{Tendência} + \text{Ciclo} + \text{Sazonalidade} + \text{Irregular}$

a) Macroeconomia I

Dois componentes: tendência + irregular / ciclo

Economia afetada por 2 tipos de choques.

- permanentes: efeito permanente na série
- transitórios: efeito passageiro

⇒ Tendência, associada a choques permanentes
na estacionária por construção

Transitórios: estacionário por construção

b) Macroeconomia II

Três componentes: tendência + sazonalidade + irregular

c) Meteorologia:

Três componentes: tendência + ciclo + irregular

- componentes de uma ST = fatos estilizados
↳ ver p/ séries financeiras.
- componentes são normalmente estocásticas (locais)
(× deterministas - globais)
- Estudos empíricos ⇒ Artigo Nelson e Plosser
p/ séries econômicas, mais adequado considerar componentes
estocásticas.
- Nos modelos ME ⇒ componentes estimadas recursivamente via FK
ou suavizações

Modelo de Tendência

• Tendência: difícil definições

(componente de baixa frequência,
apresenta maior suavidade quando estimada.)

• Classificações:

- Determinística: funções determ. do tempo
(TS)

(trend stationary)

- Estocástica: DS.

a) Tend. Determinística:

$$y_t = \sum_{j=0}^d \beta_j t^j + \psi(L) a_t, \quad a_t \sim N(0, \sigma^2)$$

↓
polinômio
(normalmente até 2º grau)

onde $\psi(L) = \sum_{j=0}^{\infty} \psi_j L^j$ (ao invés de considerar RB, usa ARMA)

↓
erro se propaga

↓
quando colocamos apenas RB ainda pode haver correlações.

$$\Rightarrow E[y_t] = E\left[\sum_{j=0}^d \beta_j t^j\right] + E[\psi(L)a_t] = \sum_{j=0}^d \beta_j t^j$$

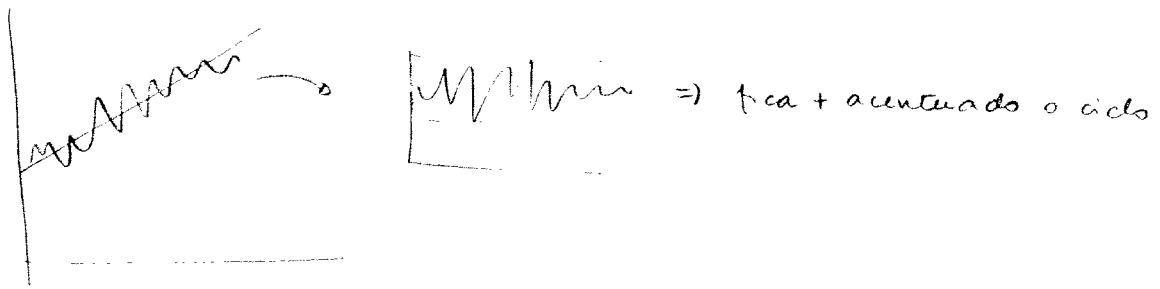
$$\begin{aligned} \text{var}[y_t] &= \text{var}[\psi(L)a_t] = \\ &= \text{var}[a_t + \psi_1 a_{t-1} + \psi_2 a_{t-2} + \dots] \\ &= \underbrace{[1 + \psi_1^2 + \psi_2^2 + \dots]}_{\left(\sum_{j=0}^{\infty} \psi_j^2\right)} \sigma_a^2 \end{aligned}$$

$$\gamma(k) = \sigma^2(\psi_k \psi_0 + \psi_{k+1} \psi_1 + \dots)$$

Obs 1: poderíamos ter log y_t ao invés de y_t

Obs 2: funções polinomiais normalmente até grau 2.

Obs 3: quanto mais suave for a tendência \Rightarrow maior é o ciclo
(flutuações em torno da tendência)



Obs 4. NAS é adequado pois nas séries econômicas, tendência é essencialmente estocástica.

Obs 5: Modelo típico de séries Temporais: parte estacionária ARMA
 " $\bar{\pi}$ " " é TS

A cov e autocov vem do ARMA

→ Caso Particular

$$d=1 \text{ e } a_t \sim AR(1)$$

$$y_t = \beta_0 + \beta_1 t + a_t$$

• Para a_t :

$$a_t = \phi a_{t-1} + \varepsilon_t \quad \therefore \quad (1 - \phi L) a_t = \varepsilon_t$$

$$\therefore a_t = \frac{\varepsilon_t}{1 - \phi L}$$

$$\Rightarrow E[a_t] = 0$$

$$\text{var}[a_t] = \frac{\sigma_\varepsilon^2}{1 - \phi^2}$$

$$\rho(k) = \phi^k$$

} processo AR(1) w tendência

• Para y_t :

$$E[y_t] = \beta_0 + \beta_1 t$$

$$\text{var}[y_t] = \text{var}[a_t] = \frac{\sigma_\varepsilon^2}{1 - \phi^2}$$

$$\rho(y_t, y_{t-k}) = \phi^k$$

• Previsões s-passos a frente

$$y_t = \beta_0 + \beta_1 t + a_t$$

$$y_{t+s} = \beta_0 + \beta_1 (t+s) + a_{t+s}$$

$$\begin{aligned}\therefore \hat{y}_{t+s|t} &= E[y_{t+s} | \underline{y}_t] = \\ &= \hat{\beta}_0 + \hat{\beta}_1(t+s) + E[a_{t+s} | \underline{y}_t]\end{aligned}$$

Atenuas: iterando a_t , temos

$$a_t = \phi a_{t-1} + \varepsilon_t$$

$$a_{t+1} = \phi a_t + \varepsilon_{t+1}$$

$$\begin{aligned}a_{t+2} &= \phi a_{t+1} + \varepsilon_{t+2} \\ &= \phi^2 a_t + \phi \varepsilon_{t+1} + \varepsilon_{t+2}\end{aligned}$$

$$\Rightarrow E[a_{t+s} | \underline{y}_t] = \phi^s a_t$$

Logo:

$$\hat{y}_{t+s|t} = \hat{\beta}_0 + \hat{\beta}_1(t+s) + a_t \phi^s \quad \text{contribuições} \rightarrow 0 \text{ quando } s \rightarrow \infty$$

$$= (\hat{\beta}_0 + \hat{\beta}_1 t) + \hat{\beta}_1 s + a_t \phi^s + a_t - a_t$$

$$= y_t + \hat{\beta}_1 s + (\phi^s - 1) a_t$$

$$\text{var}[e_{t+s|t}] = \frac{\sigma^2(1 - \phi^{2s})}{(1 - \phi^2)} \quad s = 1, 2, \dots$$

↓
erro de
previsão
s passos a frente


Fazer

Obs: Da parte estacionária \Rightarrow média condicional converge p/ média incondicional

$$E[a_t] = 0$$

No caso da variância \Rightarrow limite assintótico é do ARMA

$$\text{var} \rightarrow \frac{\sigma^2}{1 - \phi^2}$$



variância aumenta e estabiliza.

- Para retirar tendência do processo, efetuamos regressões por MQO

$$y_t^* = y_t - (\hat{\beta}_0 + \hat{\beta}_1 t) = \hat{a}_t$$

NAS é recomendado tirar tendência por 1ª diferença em processos TS.

Neste caso, teríamos:

✓
introduz
raiz unitária

$$w_t = y_t - y_{t-1}$$

$$= (1-L)y_t = (1-L)\left(\beta_0 + \beta_1 t + \frac{\varepsilon_t}{1-\phi L}\right) =$$

$$= \beta_1(t - (t-1)) + \frac{\varepsilon_t}{1-\phi L} (1-L)$$

$$= \beta_1 + (1-L) \frac{\varepsilon_t}{1-\phi L}$$

$$\begin{aligned} (1-\phi L)(1-L)y_t &= (1-\phi)\beta_0 + (\varepsilon_t - \varepsilon_{t-1}) \\ &= (1-\phi)\beta_1 + (1-L)\varepsilon_t \end{aligned}$$

ARIMA (1,1,1) com raiz unitária
($\theta=1$)

⇒ Operações de tirar tendência por primeira diferença NAS é adequada pt tendência TS pois implica em MA nas invertível, nas desajustável do ponto de vista estatístico.

Por quê?

obs: Se processo TS genérico q polinômio de grau d, precisaríamos diferenciar a série d vezes, introduzindo MA q d raízes unitárias

— " —

obs: Processos TS foram muito usados H var. macroeconômicas nos anos 70/80

$$y_t = a + bt + \varepsilon_t \quad \text{onde } \varepsilon_t \sim \text{ARMA}(p,q)$$

Estimava-se por MQO e ciclo era resíduo do modelo

⇒ Problema:

- componente cíclica fica super-dimensionada, podendo gerar ciclos espúrios.

- no processo TS, choques possuem efeito transiente (só afetam processo no tempo t)

NAS são carregados H outros instantes. Pode se propagar um pouco, mas "morre" rapidamente (velocidade depende de ϕ)

Em economia, choques são normalmente permanentes até pt justificar a tendência (aumento população, inovações tecnológicas)

✓
só pode ser capturado por tendência

b) Tendência Estocástica (processos DS) \rightarrow difference stationary
(estacionário q 1ª diferença)

i) Passeio Aleatório (RW)

(ex: preços de ativos na Bolsa)

$$y_t = y_{t-1} + \varepsilon_t \quad (\text{AR com } \phi = 1) \Rightarrow \text{Nas tem cond. de equilíbrio}$$

onde $\varepsilon_t \sim \text{NID}(0, \sigma^2)$

Iterando y_t :

$$y_{t+1} = y_t + \varepsilon_{t+1}$$

$$y_{t+2} = y_{t+1} + \varepsilon_{t+2} = y_t + \varepsilon_{t+1} + \varepsilon_{t+2}$$

$$\Rightarrow y_t = y_0 + \sum_{i=1}^t \varepsilon_i \quad : \text{ choques nas sal mais transitórios, carregados ao longo do tempo.}$$

Logo: $E[y_t] = 0$ (se $y_0 = 0$) \rightarrow Nas é atrator pois processo é estacionário

$$\text{var}[y_t] = t\sigma^2 \rightarrow \text{cresce no tempo.}$$

$$\rho(y_t, y_{t-k}) = \left(1 - \frac{k}{t}\right)^{1/2} \rightarrow \text{muda ao longo do tempo}$$

Calcular

obs: Para retirar tendência, efetuamos n° de diferenciações adequadas

$$\Delta y_t = \varepsilon_t$$

ds: $y_t \sim I(d)$

significa que $\Delta^d y_t$ é estacionária (não precisa ser RB, apenas estacionária 2ª)

Ex: IBovespa: $I(1)$

Retornos IBOV: $I(0)$

ii) Passeio Aleatório q Drift

(ex: PIB, m1, preços no mercado etc.)

$$y_t = a_0 + y_{t-1} + \varepsilon_t$$

Iterando y_t :

$$y_1 = a_0 + y_0 + \varepsilon_1$$

$$y_2 = a_0 + y_1 + \varepsilon_2 = y_0 + 2a_0 + \varepsilon_1 + \varepsilon_2$$

$$\dots y_t = a_0 + a_0 t + \sum_{i=1}^t \varepsilon_i$$

Logo: $E[y_t] = y_0 + a_0 t$ (parece tendência determinística, mas var cresce no tempo, nas ϵ ale.)

$$\text{var}(y_t) = t\sigma^2$$

$$\rho(y_t, y_{t-k}) = \left(1 - \frac{k}{t}\right)^{1/2}$$

• Previsões 2 passos a frente:

$$\begin{aligned} y_{t+s} &= y_0 + a_0(t+s) + \sum_{i=1}^{t+s} \epsilon_i \\ &= \underbrace{y_0 + a_0 t + \sum_{i=1}^t \epsilon_i}_{y_t} + a_0 s + \sum_{i=t+1}^{t+s} \epsilon_i \\ &= y_t + a_0 s + \sum_{i=t+1}^{t+s} \epsilon_i \end{aligned}$$

Obs: Num passeio aleatório, choques possuem efeito permanente

$$\frac{\partial y_{t+s}}{\partial \epsilon_i} = 1 \quad (i = 1, 2, \dots, t+s-1)$$

$$\Rightarrow \hat{y}_{t+s|t} = E[y_{t+s} | y_t] = y_t + a_0 s$$

$$\text{var}[e_{t+s|t}] = E[(y_{t+s} - \hat{y}_{t+s|t})^2] =$$

$$\checkmark \quad = \text{var}\left(\sum_{i=t+1}^{t+s} \epsilon_i\right) = s\sigma^2 \quad s = 1, 2, \dots$$

erro de
previsão
2 passos
a frente



aumento da variância
 \Rightarrow tendência nas km
sustentação estatística.

Obs: Relações drift define a sustentabilidade da tendência
variância

$$(y_t = y_0 + a_0 t + \sum_{i=1}^t \epsilon_i \Rightarrow \text{se var for pequena, } y_0 + a_0 t \text{ pode dominar})$$

fazer pg 26, 27, 28, 29, 30 (fazer caderno tb)

Notas de Aula III (final 04/05
e aula 11/05)

→ Modelos Estruturais

- Abordagem de componentes nas observações
- Série temporal decomposta em componentes ortogonais que tem interpretação direta
(ex: tendência, sazonalidade e ciclo)
- Componentes dos processos estocásticos (evoluem no tempo)
- Nesse arcabouço, há transições mais entre TS e DS
É mais fácil caracterizar os 2 tipos.
(vai se ajustar naturalmente por conta das variâncias)

Diaphana Gmel

es. das obn: $y_t = \mu_t + \sigma_t + \psi_t + \varepsilon_t$

eps. dos estados: μ_t
 σ_t
 ψ_t

Para processo DS

composants locaux

Para Proceso TS

Componentes globais
(estimadas por MQO)
caso particular dos ME

$$y_t = \mu_t + r_t + \varepsilon_t$$

$$\mu_t = a + bt$$

$$x_t = \sum (\delta_j \cos \omega_j t + \delta_j^* \sin \omega_j t)$$

$$\epsilon_t \sim \text{NID}(0, \sigma^2)$$

\Rightarrow NE podem ser vistos como modelos de regressão onde os regressores são funções do tempo ($t, \cos \omega t, \sin \omega t$) e os coeficientes dos regressores (a, b, γ, γ^*) evoluem estocasticamente no tempo.

- Para estimar vetor de estado $\alpha_t = \{\mu_t, \sigma_t, \psi_t\}$, usa FK, filtragem.
(estimacões condicional ao conj. de info: previsões, atualizações,

Modelos de Tendência

Tendência: componente que domina a previsão 2-passos a frente

a) Modelo de nível local

Tend. estocástica adequado p/ o caso de nível nos m.cte.

ex: Desemprego no Brasil

$$\begin{cases} y_t = \mu_t + \varepsilon_t & \varepsilon_t \sim \text{NID}(0, \sigma_\varepsilon^2) \\ \mu_{t+1} = \mu_t + \eta_t & \eta_t \sim \text{NID}(0, \sigma_\eta^2) \end{cases}$$

$$\text{onde } E[\varepsilon_t \eta_s] = 0 \quad \forall t, s$$

$$E[\varepsilon_t \mu_s] = E[\eta_t \mu_s] = 0 \quad \forall t$$

$$\mu_1 \sim N(a, P_1)$$


• Razão sinal ruído

$$q = \sigma_\eta^2 / \sigma_\varepsilon^2 \quad 0 < q < \infty \quad (\text{importante p/ ser explorado na questão da verossimilhança})$$

É o parâmetro que governa a magnitude da componente de nível local em relação ao ruído do modelo.

- se q grande (> 1) \Rightarrow variações do nível superam variações do ruído

componente muito instável



- se q pequeno (< 1) \Rightarrow nível do processo fica engolfado pelo ruído.

mais interessante.

ds: quando $q = 0 \Rightarrow \mu_{t+1} = \mu_t \quad \forall t \Rightarrow y_t = a + \varepsilon_t$
(variações em torno de a)

Casos Particulares

a) $\sigma_{\eta}^2 = 0 \Rightarrow q = 0$

$$y_t = \mu_t + \varepsilon_t$$

$$\mu_t = \mu_{t-1} = \mu$$

\Rightarrow Nível é cte, a ser estimado por MQO

$$\hat{\mu} = \left(\frac{1}{t}\right) \sum_{i=1}^t y_i$$

• Equações de previsões

$$\hat{\mu}_{t+1|t} = \hat{\mu}_t$$

$$\text{var}(y_{t+1|t}) = \sigma^2$$

mostrar

b) $\sigma_{\varepsilon}^2 = 0$

$$y_t = \mu_t \quad (\text{choque é zero})$$

$$\mu_t = \mu_{t-1} + \eta_t$$

$\Rightarrow y_t = y_{t-1} + \eta_t$: passeio Aleatório

• Equações de previsões

$$\hat{y}_{t+1|t} = y_t$$

$$\text{var}(y_{t+1|t}) = 0$$

mostrar

Caso Geral

$$\begin{cases} y_t = \mu_t + \varepsilon_t \\ \mu_t = \mu_{t-1} + \eta_t \end{cases}$$

$$\text{Iterando } \mu_t: \mu_1 = \mu_0 + \eta_1$$

$$\mu_2 = \mu_1 + \eta_2 = \mu_0 + \eta_1 + \eta_2$$

$$\mu_t = \mu_0 + \sum_{i=1}^t \eta_i$$

$$\text{Logo: } E(y_t) = E(\mu_t) = E(\mu_0) = \mu_0$$

$$\text{var}(y_t) = \text{var}(\mu_0) + \text{var}\left(\sum_{i=1}^t \eta_i\right) + \text{var}(\varepsilon_t)$$

$$\Rightarrow \text{var}(y_t) = \sigma_0^2 + t\sigma_{\eta}^2 + \sigma_{\varepsilon}^2$$

processo não é estacionário

- Previsões 2-passos a frente:

$$y_{t+2} = \mu_{t+2} + \varepsilon_{t+2}$$

$$\mu_{t+2} = \mu_t + \sum_{i=1}^2 \eta_{t+i} \quad (\text{da iterações})$$

$$\begin{aligned} \Rightarrow \hat{y}_{t+2|t} &= E[y_{t+2} | \mathcal{Y}_t] \\ &= E[\mu_{t+2} | \mathcal{Y}_t] \\ &= E[\mu_t | \mathcal{Y}_t] = \hat{\mu}_{t|t} \quad (\text{estimado pelo FK}) \Rightarrow \text{passo de atualização} \end{aligned}$$


$$\text{var}[y_{t+2|t}] = 2\sigma_\eta^2 + \sigma_\varepsilon^2$$

$$\begin{aligned} \text{var}[e_{t+2}] &= \text{var}[y_{t+2} - \hat{y}_{t+2|t}] \\ &= \text{var}[(\mu_{t+2} + \varepsilon_{t+2}) - (\hat{\mu}_{t|t})] \\ &= \text{var}\left[\left(\mu_t + \sum_{i=1}^2 \eta_{t+i} + \varepsilon_{t+2}\right) - \hat{\mu}_{t|t}\right] = \\ &= \text{var}\left[(\mu_t - \hat{\mu}_{t|t}) - \sum_{i=1}^2 \eta_{t+i} + \varepsilon_{t+2}\right] \end{aligned}$$

$$\begin{aligned} \Rightarrow \text{var}[e_{t+2}] &= E[e_{t+2}^2 | \mathcal{Y}_t] \\ &= E\left[(\mu_t - \hat{\mu}_{t|t})^2 | \mathcal{Y}_t\right] + \sum_{i=1}^2 E[\eta_{t+i}^2] + E[\varepsilon_{t+2}^2] \\ &= \underbrace{p_{t|t}}_{\text{vem da incerteza do estado}} + 2\underbrace{\sigma_\eta^2}_{\text{vem do choque}} + \sigma_\varepsilon^2 \end{aligned}$$

- Previsões 1 passo a frente é um EWMA

$$\hat{y}_{t+1|t} = E[y_{t+1} | \mathcal{Y}_t] = (1 - \lambda_t)y_t + \lambda_t \hat{y}_{t|t-1}$$



obs: vantagens do MNL são
 $y_t = \mu + \varepsilon_t$
 média

Em $\mu = \frac{1}{T} \sum y_i \Rightarrow$ pondera
 mais todo
 mundo igual

com MNL: EWMA.

(pesos decaem p/ obs
 + antigas)

• Resumo p/ MNL

Nível	σ_E^2	σ_η^2
cte.	*	0
nível local	*	*
processo aleatório	0	*

• Forma Reduzida

- Devemos tomar diferenças no ME até torná-lo estacionário
- Devemos achar um equivalente ARIMA(p,d,q) com restrições adicionais nos parâmetros

Todo modelo ARIMA, por construção, é identificável.

Devemos escrever ME sob forma ARIMA p/ ver se é identificável ou não.

(identificável em termos de estimação de parâmetros)

Caso geral da Forma Reduzida

$$\Phi_p(L) \Delta^d y_t = c + \Theta_q(L) \varepsilon_t \Rightarrow \text{ARIMA}(p,d,q) + c$$

Para MNL:

$$y_t = \mu_t + \varepsilon_t$$

$$\mu_t = \mu_{t-1} + \eta_t$$

→ tira 1ª diferença:

$$\Delta y_t = \Delta \mu_t + \varepsilon_t$$

$$\Delta \mu_t = \eta_t$$

$$\Delta y_t = \eta_t + \varepsilon_t$$

- É uma CL de processos estacionários
- logo Δy_t é estacionário
- Devemos procurar forma ARIMA equivalente a esta transformação

→ Dado que Δy_t é estacionário, devemos ver se escrevemos a que forma ARIMA equivale.

Como saber: ver FAC

→ calcula $E(\cdot)$, $var(\cdot)$ e $cov(\cdot)$

$$E[\Delta y_t] = 0$$

$$\begin{aligned} var[\Delta y_t] &= var(\eta_t) + var(\Delta \varepsilon_t) \\ &= \sigma_\eta^2 + 2\sigma_\varepsilon^2 \end{aligned}$$

$$\begin{aligned} k=1: cov(\Delta y_t, \Delta y_{t-1}) &= E[\Delta y_t \Delta y_{t-1}] \\ &= E[(\eta_t + \Delta \varepsilon_t)(\eta_{t-1} + \Delta \varepsilon_{t-1})] \\ &= E[(\eta_t + \varepsilon_t - \varepsilon_{t-1})(\eta_{t-1} + \varepsilon_{t-1} - \varepsilon_{t-2})] \\ &= -\sigma_\varepsilon^2 \Rightarrow \rho(1) = \frac{-\sigma_\varepsilon^2}{2\sigma_\varepsilon^2 + \sigma_\eta^2} \end{aligned}$$

$$\begin{aligned} k=2: cov(\Delta y_t, \Delta y_{t-2}) &= E[\Delta y_t \Delta y_{t-2}] \\ &= E[(\eta_t + \varepsilon_t - \varepsilon_{t-1})(\eta_{t-2} + \varepsilon_{t-2} - \varepsilon_{t-3})] \\ &= 0 \end{aligned}$$

$$\Rightarrow cov(\Delta y_t, \Delta y_{t-k}) = 0 \quad k \geq 2$$

logo: processo é um $MA(1) \rightarrow FAC \neq 0 \text{ p/ } k=1$
 (Δy_t) $FAC = 0 \text{ p/ } k \geq 2$

obs:
 se Δy_t é $MA(1)$
 $\Rightarrow y_t$ é $ARIMA(0,1,1)$
 1ª diferença
 cas varia m

Obs: modelos ARMA

$$MA(q) \Rightarrow \rho(k) = \begin{cases} \neq 0 & k=1, 2, \dots, q \\ = 0 & k=q+1, \dots \end{cases}$$

$$AR(q) \Rightarrow \rho(k) = \begin{cases} \text{exponencial ou} \\ \text{ruído amortecido} \end{cases}$$

$$FAC: \rho(k) = \frac{cov(\Delta y_t, \Delta y_{t-k})}{var(\Delta y_t)}$$

continuando...

→ Devemos tomar um ARMA genérico e identificar parâmetros e equações p/ calculá-los ($E(\cdot)$, $var(\cdot)$, $cov(\cdot)$ etc.)

No caderno:

$$\text{Seja } z_t \sim \text{MA}(1) \Rightarrow z_t = w_t + \theta w_{t-1}, \quad w_t \sim N(0, \sigma_w^2)$$

$$\begin{cases} E[z_t] = 0 \\ \text{var}[z_t] = (1 + \theta^2) \sigma_w^2 \\ \gamma(1) = E[z_t, z_{t-1}] = \theta \sigma_w^2 \Rightarrow \rho(1) = \frac{\theta}{(1 + \theta^2)} \end{cases}$$

obs p/ MA1

$$\bullet E[z_t^2] = E[(w_t + \theta w_{t-1})^2]$$

$$= E[w_t^2 + \theta^2 w_{t-1}^2 + 2\theta w_t w_{t-1}]$$

$$= E[w_t^2] + \theta^2 E[w_{t-1}^2] = \sigma_w^2 (1 + \theta^2)$$

$$\bullet E[z_t, z_{t-1}] = E[(w_t + \theta w_{t-1})(w_{t-1} + \theta w_{t-2})]$$

$$= \theta \sigma_w^2$$

Temos estas que

para Δy_t

$$E[\Delta y_t] = 0$$

$$\text{var}[\Delta y_t] = -\sigma_\epsilon^2$$

$$\rho_{\Delta y_t}(1) = \frac{-\sigma_\epsilon^2}{\sigma_\eta^2 + 2\sigma_\epsilon^2} = \frac{-1}{q + 2}$$

(\div por σ_ϵ^2)

$$\text{onde } q = \frac{\sigma_\eta^2}{\sigma_\epsilon^2}$$

\Downarrow
2 parâmetros: q, σ_ϵ^2

e 2 eqs p/ determinar
(var e $\rho(1)$)

para z_t

$$E[z_t] = 0$$

$$\text{var}[z_t] = (1 + \theta^2) \sigma_w^2$$

$$\rho_{z_t}(1) = \frac{\theta}{(1 + \theta^2)}$$

\Downarrow

2 parâmetros: θ, σ_w^2

e 2 eqs p/ determinar
(var e $\rho(1)$)

Queremos verificar que tipo de restrições a forma reduzida do ME implica no seu ARMA equivalente

ou seja p/ Δy_t : $0 < q < \infty$
p/ z_t : $-1 < \theta < 1$ } como se relacionam?

Igualando as FAC's:

$$\frac{\theta}{(1+\theta^2)} = \frac{-1}{q+2} \Rightarrow \theta(q+2) = -(1+\theta^2)$$

$$\theta^2 + (q+2)\theta + 1 = 0$$

$$\theta = \frac{-(q+2) \pm \sqrt{(q+2)^2 - 4}}{2} \quad \text{onde } q \in (0, \infty)$$

$$\text{fazendo } q \rightarrow 0: \theta = \frac{-2 \pm 0}{2} = -1$$

$$q \rightarrow \infty: \theta = 0 \quad (\text{usando as regras algébricas})$$

← Fazer

Logo: Espaço paramétrico está restrito: $-1 < \theta < 0$.

Obs 1: se realmente acreditarmos que o modelo que melhor se adequa é um MNL, isto implica em $\Delta y_t \sim MA(1) \Rightarrow$ restrições sobre θ é natural.

Obs 2: se supusermos

$$E[\epsilon_t \eta_s] = \sigma_{\epsilon\eta}^2 \quad (\text{nas s's mais descorrelatadas})$$

calculemos novamente $E(\Delta y_t)$, $\text{var}(\Delta y_t)$, $\gamma_{\Delta y_t}(1)$

$$\Delta y_t = \eta_t + \Delta \epsilon_t$$

$$\Rightarrow E[\Delta y_t] = 0 \quad (\text{nas é afetado pela nova hipótese})$$

$$\bullet \text{var}(\Delta y_t) = E[(\Delta y_t)^2] =$$

$$= E[\eta_t^2 + (\Delta \epsilon_t)^2 + 2\eta_t \Delta \epsilon_t] =$$

$$= E[\eta_t^2] + E[(\epsilon_t - \epsilon_{t-1})^2] + 2E[\eta_t(\epsilon_t - \epsilon_{t-1})] =$$

$$= \sigma_\eta^2 + 2\sigma_\epsilon^2 + 2\sigma_{\epsilon\eta} \quad \leftarrow \text{divida (nas é apenas } \sigma_{\epsilon\eta})$$

$$\bullet \gamma_{\Delta y_t}(1) = E[\Delta y_t \Delta y_{t-1}]$$

$$= E[(\eta_t + \epsilon_t - \epsilon_{t-1})(\eta_{t-1} + \epsilon_{t-1} - \epsilon_{t-2})]$$

$$= -\sigma_\epsilon^2 \quad (\text{tb nas é afetado por novas suposições})$$

Terminos:Para Δy_t :

3 parâmetros

$$\sigma_\eta^2, \sigma_\varepsilon^2, \sigma_{\varepsilon\eta}$$

Para z_t

2 parâmetros

$$\theta \text{ e } \sigma_\omega^2$$

\Rightarrow modelo com covariâncias entre os choques $na5$ é identificável

ds13: conceito de modelo identificável: diz respeito a estimar os parâmetros ($na5$ é a única coisa de observável, que tem a ver com as componentes).

- Forma UCAZIMA

Representa um passo intermediário entre a forma estrutural e a reduzida.

Para o MNL:

$$\Delta y_t = \eta_t + \Delta \varepsilon_t$$

$$\therefore y_t = \left(\frac{\eta_t}{\Delta} \right) + \varepsilon_t$$

↓
tendência

$$y_t = T_t + \varepsilon_t \Rightarrow \text{componentes tendência e irregular}$$

Para T_t , temos:

$$T_t = \frac{\eta_t}{\Delta} \quad \therefore \quad \Delta T_t = \eta_t \quad \therefore \quad T_t = T_{t-1} + \eta_t \Rightarrow \text{tendência é um passeio aleatório (ARIMA (0,1,0))}$$

ds: utilidade da forma UCAZIMA está na possibilidade de representar um modelo de CNO como a soma de processos ARIMA (p,d,q)

b) Modelo de Tendência local

Tendência linear estocástica, adequado H capturar tendências em ST de agregados macroeconômicos (PIB, Prod. Ind.), séries associadas a crescimento populacional, preços e salários (nominais) etc.

$$\begin{cases} y_t = \mu_t + \varepsilon_t & \varepsilon_t \sim N(0, \sigma_\varepsilon^2) \\ \mu_t = \mu_{t-1} + \beta_{t-1} + \eta_t & \eta_t \sim N(0, \sigma_\eta^2) \Rightarrow \mu_t \text{ é a tendência} \\ & \text{(nível + inclinação)} \\ \beta_t = \beta_{t-1} + \zeta_t & \zeta_t \sim N(0, \sigma_\zeta^2) \Rightarrow \beta_t \text{ é a inclinação estocástica} \\ & \text{(acrescimento do nível)} \end{cases}$$

$$\text{onde } E[\varepsilon_t \eta_s] = E[\eta_t \zeta_s] = E[\varepsilon_t \zeta_s] = 0 \quad \forall t, s$$

$$E[\varepsilon_t \alpha_0] = E[\eta_t \alpha_0] = E[\zeta_t \alpha_0] = 0$$

$$\underline{\alpha} = \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} \Rightarrow \alpha_0 \sim N(\alpha_0, P_0)$$

• Razões sinal ruído

Neste caso, definiremos 2 razões sinal ruído, uma para cada componente do MLL

$$q_\eta = \frac{\sigma_\eta^2}{\sigma_\varepsilon^2} \quad q_\zeta = \frac{\sigma_\zeta^2}{\sigma_\varepsilon^2}$$

\Rightarrow Interpretações das componentes

• μ_t : é a tendência linear estocástica da série
(+ complicada do que apenas um RW)
é modificada por 2 choques: σ_η^2 e σ_ζ^2

• β_t : é a inclinação estocástica da série
se a série estiver em log $\Rightarrow 100\beta_t\%$ é a tx. de crescimento instantâneo de y_t

Casos particulares

$$(i) \quad \sigma_\eta^2 = \sigma_\zeta^2 = 0$$

Tendência se torna determinística

$$\Rightarrow y_t = \alpha + \beta t + \varepsilon_t \quad \text{onde } \alpha = \mu_0 \text{ e } \beta = \beta_0$$

$$\text{pois: } y_t = \mu_t + \varepsilon_t$$

$$\mu_t = \mu_{t-1} + \beta_{t-1}$$

$$\beta_t = \beta_{t-1} = \beta_0$$

$$\mu_t = \mu_{t-1} + \beta_0$$

$$\mu_1 = \mu_0 + \beta_0$$

$$\mu_2 = \mu_1 + \beta_0 = \mu_0 + 2\beta_0$$

$$\vdots$$

$$\mu_t = \mu_0 + t\beta_0$$

$$\Rightarrow y_t = \mu_0 + \beta_0 t + \varepsilon_t$$

des: se fizermos estimativa e obtivermos $\sigma_{\epsilon}^2 = 10^{-5}$ (muito baixa)

\Rightarrow pode-se desconsiderar estocasticidade da componente

(ii) $\sigma_{\epsilon}^2 = 0, \sigma_{\eta}^2 \neq 0$

$\Rightarrow \mu_t = \mu_{t-1} + \beta + \eta_t$: RW com drift

$\beta_t = \beta_{t-1} = \beta$

(iii) $\sigma_{\eta}^2 = 0, \sigma_{\zeta}^2 \neq 0$

$\Rightarrow \begin{cases} y_t = \mu_t + \epsilon_t \\ \mu_t = \mu_{t-1} + \beta_{t-1} \rightarrow \mu_t \text{ dita tendência suave} \\ \beta_t = \beta_{t-1} + \zeta_t \end{cases}$

se tirarmos a 1ª e a 2ª diferenças:


$\Delta \mu_t = \beta_{t-1}$

$\Delta^2 \mu_t = \Delta \beta_{t-1} = \zeta_{t-1}$

\Rightarrow processo terá tendência suave.

A 2ª derivada da componente de tendência é um ruído br. Portanto, tendência é uma "integral" dupla de um RB, o que a torna suave, pois cada operação de integral equivale a um filtro passa baixo.

(elimina componentes de alta frequência)



$\frac{d^2 \mu_t}{dt^2} = \zeta_t \Rightarrow \mu_t = \iint \zeta_{t-1} dt$

obs (relações com filtro HP \Rightarrow depois)

• Forma de Espaço de Estado

$$y_t = (1 \ 0) \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} + \varepsilon_t$$

$$\begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} = \underbrace{\begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}}_{T: m \times m} \begin{pmatrix} \mu_{t-1} \\ \beta_{t-1} \end{pmatrix} + \underbrace{\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}}_{R: m \times n} \underbrace{\begin{pmatrix} \eta_t \\ \zeta_t \end{pmatrix}}_{n \times 1}$$

$\alpha_t: m \times 1$

$$y_t = z_t \alpha_t + \varepsilon_t$$

$$\alpha_t = T \alpha_{t-1} + \eta_t$$

obs: Note caso $m=n$, ou seja, número de desvios é igual ao número de componentes (mas poderia ser menor).

• Funções de previsão

(Nas tem a ver q FK, vem a partir da equação do modelo)

duas formas de fazer:

I) $y_t = \mu_t + \varepsilon_t$

$$y_{t+k} = \mu_{t+k} + \varepsilon_{t+k}$$

$$\begin{aligned} \hat{y}_{t+k|t} &= E[y_{t+k} | \mathcal{Y}_t] = \\ &= E[\mu_{t+k} | \mathcal{Y}_t] + \underbrace{E[\varepsilon_{t+k} | \mathcal{Y}_t]}_0 \end{aligned}$$

Iterando μ_t :

$$\mu_t = \mu_{t-1} + \beta_{t-1} + \eta_t$$

$$\mu_{t+1} = \mu_t + \beta_t + \eta_{t+1}$$

$$\mu_{t+2} = \mu_{t+1} + \beta_{t+1} + \eta_{t+2}$$

$$= \mu_t + \beta_t + \beta_{t+1} + \eta_{t+1} + \eta_{t+2}$$

$$\mu_{t+k} = \mu_t + \sum_{i=0}^k \beta_{t+i} + \sum_{i=1}^k \eta_{t+i}$$

$$\begin{aligned} \Rightarrow \hat{y}_{t+k|t} &= E[\mu_{t+k} | \mathcal{Y}_t] = \\ &= \underbrace{E[\mu_t | \mathcal{Y}_t]}_{\hat{\mu}_{t|t}} + \sum_{i=0}^k \underbrace{E[\beta_{t+i} | \mathcal{Y}_t]}_{\hat{\beta}_{t+i}} \\ &= \hat{\mu}_{t|t} + k \hat{\beta}_{t|t} \end{aligned}$$

$$\text{II)} \quad y_t = 2\alpha_t + \varepsilon_t$$

$$\hat{y}_{t+k|t} = 2 E[\alpha_{t+k} | y_t]$$

Temos que, iterando:

$$\alpha_t = T\alpha_{t-1} + \eta_t$$

$$\alpha_{t+k} = T^k \alpha_t + (\dots \times \eta_{t+k})$$

$$E[\alpha_{t+k} | y_t] = T^k \underbrace{E[\alpha_t | y_t]}_{\text{vem do FK}}$$

$$= \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}^k \begin{pmatrix} \hat{\mu}_{t|t} \\ \hat{\beta}_{t|t} \end{pmatrix}$$

$$= \begin{pmatrix} 1 & k \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \hat{\mu}_{t|t} \\ \hat{\beta}_{t|t} \end{pmatrix} = \begin{pmatrix} \hat{\mu}_{t|t} + k\hat{\beta}_{t|t} \\ \hat{\beta}_{t|t} \end{pmatrix}$$

$$\Rightarrow \hat{y}_{t+k|t} = (1 \quad 0) \begin{pmatrix} \hat{\mu}_{t|t} + k\hat{\beta}_{t|t} \\ \hat{\beta}_{t|t} \end{pmatrix} \quad \Rightarrow \boxed{\hat{y}_{t+k|t} = \hat{\mu}_{t|t} + k\hat{\beta}_{t|t}}$$

\Rightarrow equações de tendência linear

Fazer $\Rightarrow \begin{matrix} \hat{\mu}_{t|t} \\ \hat{\beta}_{t|t} \end{matrix} \}$ mas dados por amostragem exponencial simples.

Obs: Nessas equações, trabalharemos com $\hat{\Psi}$ (hiperparâmetros fixos conhecidos, estimados) \Rightarrow plug-in

A incerteza a respeito de $\hat{\Psi}$ não é transmitida para as componentes calculadas com FK.

• MSE da previsão

$$\text{MSE}[\hat{y}_{t+k|t}] = E[y_{t+k} - \hat{y}_{t+k|t}]^2$$

Para este modelo:

$$y_{t+k} = \mu_{t+k} + \varepsilon_{t+k}$$

$$\hat{y}_{t+k|t} = \hat{\mu}_{t|t} + k\hat{\beta}_{t|t}$$

$$\Rightarrow \text{MSE}[\hat{y}_{t+k|t}] = E[(\mu_{t+k} + \varepsilon_{t+k} - \hat{\mu}_{t|t} - k\hat{\beta}_{t|t})^2] =$$

$$= E[(\mu_{t+k} - \hat{\mu}_{t|t}) + \varepsilon_{t+k} - k\hat{\beta}_{t|t}]^2]$$

= ... fazer

matricialmente, temos:

$$\text{MSE}[\hat{y}_{t+k|t}] = E[(z\alpha_{t+k} + \varepsilon_t - z\alpha_{t+k|t})^2]$$

$$= E[z(\alpha_{t+k} - \alpha_{t+k|t})(\alpha_{t+k} - \alpha_{t+k|t})' z'] + \sigma_\varepsilon^2$$

$$= z \underbrace{E[(\alpha_{t+k} - \alpha_{t+k|t})(\alpha_{t+k} - \alpha_{t+k|t})']}_{\text{MSE}[\hat{\alpha}_{t+k|t}]} z' + \sigma_\varepsilon^2$$

Iterando $\hat{\alpha}_{t+k|t} = T^S \alpha_{t|t} +$ Σ

fazer.

$$\Rightarrow \text{MSE}[\hat{y}_{t+k|t}] = z T^S P_{t|t} T^{S'} z'$$

fazer

• forma reduzida

lembRANDO: o objetivo é obter modelo estacionário e ver se pode ser escrito como modelo ARIMA.

Nesse caso, ver qual modelo ARIMA pode representar o ME e verificar questões do modelo ser identificável.

$$\begin{cases} y_t = \mu_t + \varepsilon_t \\ \mu_t = \mu_{t-1} + \beta_{t-1} + \eta_t \\ \beta_t = \beta_{t-1} + \zeta_t \end{cases}$$

• Tomando 1ª diferença:

$$\Delta y_t = \Delta \mu_t + \Delta \varepsilon_t$$

$$\Delta \mu_t = \beta_{t-1} + \eta_t$$

$$\Delta \beta = \zeta_t$$

$$\therefore \Delta y_t = \beta_{t-1} + \eta_t + \Delta \varepsilon_t \quad (\text{ainda não é estac. por causa de } \beta_{t-1})$$

β_t é um RW

• Tomando 2ª diferença:

$$\begin{aligned} \Delta^2 y_t &= \Delta \beta_{t-1} + \Delta \eta_t + \Delta^2 \varepsilon_t \\ &= \zeta_{t-1} + \Delta \eta_t + \Delta^2 \varepsilon_t \end{aligned} \Rightarrow \text{é estacionário}$$

só há RB do lado direito

• Agora precisamos identificar o modelo ARIMA ao qual se relaciona.
Precisamos calcular FAC's.

$$\text{Seja } w_t = \zeta_{t-1} + \Delta \eta_t + \Delta^2 \varepsilon_t$$

$$\therefore E[w_t] = 0$$

$$\text{var}[w_t] = E[(\zeta_{t-1} + \eta_t - \eta_{t-1} + \varepsilon_t - 2\varepsilon_{t-1} + \varepsilon_{t-2})^2] \quad \text{atenção!}$$

$$= \text{var}[\zeta_{t-1}] + 2 \text{var}[\eta_t] + 6 \text{var}[\varepsilon_t] =$$

$$= \sigma_\zeta^2 + 2\sigma_\eta^2 + 6\sigma_\varepsilon^2$$

$$\text{cov}(w_t, w_{t-k})$$

↳ fazendo $k=1, 2, 3, \dots$

$$\begin{aligned}
 \text{cov}[w_t, w_{t-1}] &= E[(\zeta_{t-1} + \Delta\eta_t + \Delta^2\epsilon_t)(\zeta_{t-2} + \Delta\eta_{t-1} + \Delta^2\epsilon_{t-1})] \\
 &= E[(\zeta_{t-1} + \eta_t - \eta_{t-1} + \epsilon_t - 2\epsilon_{t-1} + \epsilon_{t-2})(\zeta_{t-2} + \eta_{t-1} + \eta_{t-2} \\
 &\quad + \epsilon_{t-1} - 2\epsilon_{t-2} + \epsilon_{t-3})] \\
 &= -\sigma_\eta^2 - 4\sigma_\epsilon^2
 \end{aligned}$$

$$\begin{aligned}
 \text{cov}[w_t, w_{t-2}] &= E[(\zeta_{t-1} + \eta_t - \eta_{t-1} + \epsilon_t - 2\epsilon_{t-1} + \epsilon_{t-2}) \\
 &\quad (\zeta_{t-3} + \eta_{t-2} - \eta_{t-3} + \epsilon_{t-2} - 2\epsilon_{t-3} + \epsilon_{t-4})] \\
 &= \sigma_\epsilon^2
 \end{aligned}$$

$$\Rightarrow \text{cov}[w_t, w_{t-k}] = \begin{cases} -\sigma_\eta^2 - 4\sigma_\epsilon^2 & , k=1 \\ \sigma_\epsilon^2 & , k=2 \\ 0 & , k \geq 3 \end{cases} \Rightarrow \text{MA}(2)$$

Logo: $w_t = \Delta^2 y_t \sim \text{MA}(2)$

$\Rightarrow y_t \sim \text{ARIMA}(0, 2, 2)$ com 3 hiperparâmetros: $\sigma_\epsilon^2, \sigma_\eta^2, \sigma_\zeta^2$

obs: Para as correlações em função de η e ζ , temos:

$$\begin{aligned}
 \rho(k) &= \frac{\text{cov}(w_t, w_{t-k})}{\text{var}(w_t)} \\
 &= \begin{cases} \frac{-\sigma_\eta^2 - 4\sigma_\epsilon^2}{2\sigma_\eta^2 + \sigma_\zeta^2 + 6\sigma_\epsilon^2} = \frac{-\eta - 4}{2\eta + \zeta + 6} & k=1 \\ \frac{1}{2\eta + \zeta + 6} & k=2 \\ 0 & k \geq 3 \end{cases}
 \end{aligned}$$

Seja $z_t \sim \text{MA}(2)$

$z_t = \theta_1 e_{t-1} + \theta_2 e_{t-2}$: precisamos de 3 equações

para estimar os parâmetros

onde $e_t \sim \text{NID}(0, \sigma_e^2)$

$\Rightarrow \text{var}, \delta(1) \text{ e } \delta(2)$

e igualamos com as

$$E[z_t] = 0$$

$$\begin{aligned} \text{var}[z_t] &= E[z_t^2] = E[(\theta_1 e_{t-1} + \theta_2 e_{t-2} + e_t)^2] \\ &= \theta_1^2 \sigma_e^2 + \theta_2^2 \sigma_e^2 + \sigma_e^2 = \\ &= (1 + \theta_1^2 + \theta_2^2) \sigma_e^2 \end{aligned}$$

$$\begin{aligned} \gamma_2(1) &= E[z_t \cdot z_{t-1}] = \\ &= E[(\theta_1 e_{t-1} + \theta_2 e_{t-2} + e_t)(\theta_1 e_{t-2} + \theta_2 e_{t-3} + e_{t-1})] = \\ &= \theta_1 \sigma_e^2 + \theta_1 \theta_2 \sigma_e^2 = \\ &= (\theta_1 + \theta_1 \theta_2) \sigma_e^2 \end{aligned}$$

$$\begin{aligned} \gamma_2(2) &= E[z_t \cdot z_{t-2}] = \\ &= E[(\theta_1 e_{t-1} + \theta_2 e_{t-2} + e_t)(\theta_1 e_{t-3} + \theta_2 e_{t-4} + e_{t-2})] \\ &= \theta_2 \sigma_e^2 \end{aligned}$$

Temos entas que

para Δy_t

$$E[\Delta y_t] = 0$$

$$\begin{aligned} \text{var}[\Delta y_t] &= \sigma_\gamma^2 + 2\sigma_\eta^2 + 6\sigma_e^2 \\ &= 6 + 9\gamma + 29\eta \end{aligned}$$

$$\rho(1) = \frac{-(4 + 9\eta)}{6 + 9\gamma + 29\eta}$$

$$\rho(2) = \frac{1}{6 + 9\gamma + 29\eta}$$

\Downarrow

Daqui, temos que

$$\frac{\rho(1)}{\rho(2)} = -(4 + 9\eta)$$

para z_t

$$E[z_t] = 0$$

$$\text{var}[z_t] = (1 + \theta_1^2 + \theta_2^2) \sigma_e^2$$

$$\gamma(1) = (\theta_1 + \theta_1 \theta_2) \sigma_e^2$$

$$\gamma(2) = \theta_2 \sigma_e^2$$

\Downarrow

Daqui, temos que

$$\frac{\rho(1)}{\rho(2)} = \frac{\theta_1 + \theta_1 \theta_2}{\theta_2}$$


$$\theta_1 \left(\frac{1 + \theta_2}{\theta_2} \right) = -(4 + 9\eta)$$

Para que o $MA(2)$ seja invertível, temos algumas restrições sobre os parâmetros θ_1 e θ_2 .

$$z_t = (1 + \theta_1 L + \theta_2 L^2) w_t$$

$$\Rightarrow \phi(L) = 1 + \theta_1 L + \theta_2 L^2 = 0 \quad \Leftrightarrow |L_i| > 1, \quad i=1,2.$$

se mapearmos esta restrição no plano $\theta_1 \times \theta_2$



- Se acharmos estas θ_1 e θ_2 fora da região hachurada \Rightarrow não será bom aproximar modelo por MLL

- Para os casos particulares do MLL:

- se $\sigma_\eta^2 = 0$ (inclinação fixa) $\Rightarrow \frac{\theta_1(1+\theta_2)}{\theta_2} = -1$

θ_1, θ_2 estarão na região de não invertibilidade

- se $\sigma_\eta^2 > 0$ e $\sigma_\eta^2 = 0$ (tendência suave) \Rightarrow modelo sempre invertível

provar!

forma UGARIMA

fazer

Outros modelos de tendência estocástica

Podemos estender este procedimento para outros modelos de tendência.

- quadrática
- amortecida
- curvas de crescimento.

Ex: Tendência linear amortecida


$$y_t = \mu_t + \varepsilon_t$$

$$\mu_t = \mu_{t-1} + \beta_{t-1} + \eta_t$$

$$\beta_t = \phi \beta_{t-1} + \gamma_t \Rightarrow AR(1) \quad |\phi| < 1.$$

monstramos que função de previsões deste modelo é:

$$\hat{y}_{t+h|t} = \hat{\mu}_t + \hat{\beta}_t \left[\frac{(1-\phi^s)}{1-\phi} \right] \rightarrow \text{fazer}$$



(ver lista 2)

Podemos sempre trabalhar com esta forma e deixar que ϕ seja estimado (se $\phi = 1$, não há valor assintótico).

ϕ aparecerá na matriz T : $\begin{pmatrix} 1 & 1 \\ 0 & \phi \end{pmatrix}$

Notas de aula IV (final 11/05 e
aula 18/05 e aula 25/05)

- Sazonalidade: flutuações periódicas dentro do período de 1 ano
 - período + ou - regular
 - associadas a clima ou convenções sociais

- s : período de sazonalidade

tempo que flutuações leva p/ se repetir

4: séries trimestrais

12: " mensais

52: " semanais

Obs: se a série for diária, pode haver + de um tipo de sazonalidade ($s=365$, diária e $s=7$, semanal)

- Diferença entre sazonalidade e ciclo: no período

↓
dentro de 1 ano
questões climáticas
e sociais

↓
periódicidade e amplitude
nas séries bem definidas
(ex: ciclos econômicos).
P/ fenômenos naturais, há +
regularidade.

- Componente sazonal pode ser indesejável.

O que é sazonal \Rightarrow é separado.

pode ser necessário retirar da série p/ ter + clareza na visualização de outras componentes (ex: tendência)

- Ajustamento sazonal ou desazonalização:

processo de retirada / filtragem da comp. sazonal de uma ST

$$y_t^{(a)} = y_t - \gamma_t \rightarrow \text{p/ fazer a série ser desazonalizada}$$

\Rightarrow ver pela FAC se há ciclo em $k=12$

Atenção: $y_t^{(a)}$ não é a tendência!

Ainda há o erro

$$y_t = \mu_t + \gamma_t + \epsilon_t \Rightarrow y_t^{(a)} = \mu_t + \epsilon_t : \text{picos de sazonalidade retirados da série, mas os ruídos e}$$

• Procedimentos de ajuste:

- model based: modelos estruturais (SEATS/ TRAMO)
- métodos semi-heurísticos: x12 ARIMA - (1966)

• Escalas da sazonalidade:

aditiva, multiplicativa ou mista

1) Aditiva: padrão nos modelos lineares

amplitude \propto mantém \pm constante ao longo do tempo.

$$y_t = \mu_t + \delta_t + \epsilon_t$$

δ_t comp. sazonal ou fator sazonal

$$\therefore y_t^{(a)} = y_t - \hat{\delta}_t = \hat{\mu}_t + \hat{\epsilon}_t$$

2) Multiplicativa: padrão x12 ARIMA

amplitude aumenta ao longo do tempo (ex: série trilinear)

modelo não linear (pois componentes \propto multiplicam), mas pode ser obtido modelo linear ajustando p/ o log da série.


$$y_t = \mu_t \cdot \delta_t \cdot \epsilon_t$$

$$\therefore y_t^{(a)} = \frac{y_t}{\hat{\delta}_t} = \hat{\mu}_t \cdot \hat{\epsilon}_t$$

Obs: se não souber o modelo a priori é aditivo ou multiplicativo,

usa aditivo p/ y_t e faz teste a posteriori com resíduos.

se obtiver p/ resíduos:



\Rightarrow precisa usar log

(Variação no final da série é maior)

\Rightarrow transformando multiplicativo em aditivo

$$\ln y_t = \ln \mu_t + \ln \delta_t + \ln \epsilon_t$$

$$\therefore y_t' = \mu_t' + \delta_t' + \epsilon_t' \quad (\text{modelo efetivamente ajustado})$$

mas queremos: desazonalizar a série original, não o seu log.

$$y_t^{(a)} = \frac{y_t}{\delta_t} = \frac{\exp(y_t')}{\exp(\hat{\delta}_t')} = \underbrace{\mu_t \cdot \varepsilon_t}$$

Obs: Interpretação do fator sazonal multiplicativo δ_t

$$100 \left(\frac{\hat{y}_t - \hat{\mu}_t}{\hat{\mu}_t} \right) = 100 \left(\frac{\hat{\delta}_t \hat{\mu}_t - \hat{\mu}_t}{\hat{\mu}_t} \right) = 100 (\hat{\delta}_t - 1) = 100 (e^{\hat{\delta}_t'} - 1)$$

Ex: ajustando um ME ao log da série \Rightarrow encontramos fator sazonal = 0,3 = $\hat{\delta}_t'$

Como $e^{0,3} = 1,35 \Rightarrow$ no mês de janeiro a série, em média, tem um aumento de 35% em relação à sua tendência.

\Rightarrow Por que a transformação logarítmica é indicada em algumas situações?

- (a) lineariza o modelo (linear nas componentes)
- (b) traz simetria aos resíduos: se resíduos possuem dist. assimétrica, transf. logarítmica pode torná-la \approx simétrica. contribui p/ $\hat{\eta}$ rejeições da hipótese de normalidade.

(c) muda a escala

$$\text{se } y_t \sim I(1)$$

$$\Delta \log y_t \sim I(0): \text{é estacionário}$$

$$\Delta \log y_t = \log \left(\frac{y_t}{y_{t-1}} \right) = \log (1 + \Delta y_t / y_{t-1}) \approx \Delta y_t / y_{t-1} \text{ se } \Delta y_t \ll y_{t-1}$$

\Rightarrow escala passa a ser de variações relativas ou %

\nearrow
Não é importante o ME

(d) estabiliza a variância:

Para um tipo especial de heteroscedasticidade, a transf. logarít. estabiliza a variância

Prova: Supor

$$y_t = \mu_t \delta_t \varepsilon_t, \quad \varepsilon_t \sim \text{lognormal} \left(\exp\left(\frac{1}{2\sigma^2}\right), \exp(2\sigma^2) - \exp(\sigma^2) \right)$$

$$\Rightarrow E[y_t | \mu_t \sigma_t] = \mu_t \sigma_t E[\epsilon_t]$$

$$= \mu_t \sigma_t \exp(1/2\sigma^2)$$

$$\bullet \text{var}[y_t | \mu_t \sigma_t] = (\mu_t \sigma_t)^2 [\exp(2\sigma^2) - \exp(\sigma^2)]$$

$$= (\mu_t \sigma_t)^2 \exp(\sigma^2) [\exp(\sigma^2) - 1]$$

$$\propto E[y_t | \mu_t \sigma_t]^2 \quad \text{divida}$$

ou seja:

Na escala original $\Rightarrow y$ é heterocedástica

Qual a transf. adequada H estabilizar a variância de y ?

Seja a transf.

$$z_t = h(y_t)$$

$$\text{var}(z_t | \mu_t \sigma_t) = \text{var}(h(y_t | \mu_t \sigma_t))$$

Expansão de Taylor em torno de $w_t = E[y_t | \mu_t \sigma_t]$

$$\Rightarrow z_t = h(y_t) \approx h(w_t) + h'(w_t)(y_t - w_t)$$

$$\text{var}(h(y_t) | \mu_t \sigma_t) \approx [h'(w_t)]^2 \text{var}[y_t | \mu_t \sigma_t] = \text{cte. (é o que queremos)}$$

Se escolhermos $z_t = \log(y_t)$

$$\therefore h(w_t) = \log(w_t)$$

$$\Rightarrow \text{var}(\log(y_t) | \mu_t \sigma_t) = \left[\frac{1}{w_t} \right]^2 \text{var}[y_t | \mu_t \sigma_t] \propto \frac{E[y_t | \mu_t \sigma_t]^2}{\text{divida}}$$

Conclusão: Transformação logarítmica estabiliza a variância
e a lei da variância por do tipo
 $\text{var}[y_t | \mu_t \sigma_t] \propto E[y_t | \mu_t \sigma_t]^2$

\rightarrow Cada mês tem fator sazonal \Rightarrow sazonalidade determinística
(conceito que varia entre os meses do ano)

\rightarrow Fatores a cada mês variam, mas dinâmicos, \Rightarrow sazonalidade estocástica
(varia p o mesmo mês)

\Rightarrow benefício de se trabalhar com MBE

Tratamento de Sazonalidade em Modelos Estatísticos

obs: • Primeiro trataremos no contexto determinístico.

(será caso particular da estocástica quando $\sigma^2 \rightarrow 0$)

- No caso de ST, usamos p. ex. ARIMA(2

$$y_t = \phi y_{t-1} + \phi_{12} y_{t-12} + \epsilon_t$$

razonalidade é tratada internamente

Não dá p. filtrar \Rightarrow Não usamos no contexto MEF

\Rightarrow três procedimentos p. o controle da sazonalidade

(i) variáveis dummy

(ii) funções trigonométricas

(iii) variável endógena defasada: y_{t-12}

} apenas estes são adequados p. tratamento nos ME.

i) Sazonalidade por variáveis dummy.

(é o mais simples de ser implementado)

- o coeficiente de cada dummy representa o fator sazonal do mês, trimestre etc. de interesse

Exemplo: Seja ST trimestral ($s=4$)

Modelo inicial seria


$$\begin{cases} y_t = \beta + \gamma_1 D_{1t} + \gamma_2 D_{2t} + \gamma_3 D_{3t} + \gamma_4 D_{4t} + \epsilon_t, & t=1, 2, \dots, T \\ D_{it} = 1 & \text{se } (i=t) \\ & \text{caso contrário} \end{cases}$$

nas é exatamente $i=t$, mas $t \sim i$

obs: • β intercepto, tratado como uma etc no lugar da tendência (poro agora é na sazonalidade)

• $\gamma_1, \gamma_2, \gamma_3, \gamma_4$: variáveis explicativas

• uma dummy p. cada trimestre.



	t	D_{1t}	D_{2t}	D_{3t}	D_{4t}
2010	Q1	1	0	0	0
	Q2	0	1	0	0
	Q3	0	0	1	0
	Q4	0	0	0	1
2011	Q1				
	Q2				
	Q3				
	Q4				

etc.

$$y_t = \beta + \sum_{j=1}^4 \gamma_j \cdot D_{jt} + \epsilon_t$$

$$= (\beta \quad \gamma_1 \quad \gamma_2 \quad \gamma_3 \quad \gamma_4) \begin{pmatrix} 1 \\ D_{1t} \\ D_{2t} \\ D_{3t} \\ D_{4t} \end{pmatrix} + \epsilon_t$$

Problema: Modelo apresenta multicolinearidade perfeita
(um dos regressores pode ser obtido como CL dos outros)

\Rightarrow NAs poderemos coletar tantas dummies quantos períodos sazonais

NAs não podemos dessa forma resolver problema por NQR
(matriz $X'X$ não é invertível).

No exemplo:

$$y_t = \beta' x_t + \epsilon_t, \quad t = 1, 2, \dots, T$$

$$\text{onde } \beta' = (\beta \quad \gamma_1 \quad \gamma_2 \quad \gamma_3 \quad \gamma_4)$$

$$x_t = \begin{pmatrix} 1 \\ D_{1t} \\ D_{2t} \\ D_{3t} \\ D_{4t} \end{pmatrix}$$

$$y_{T \times 1} = X_{T \times K} \cdot \beta_{K \times 1} + \epsilon_{T \times 1} \quad \text{Na notação matricial}$$

onde: $X = \begin{bmatrix} 1 & X_{21} & X_{31} & \dots & X_{k1} \\ 1 & X_{22} & X_{32} & \dots & X_{k2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & X_{2T} & X_{3T} & \dots & X_{kT} \end{bmatrix}$

No exemplo: $X_{kt} = (1 \quad D_{1t} \quad D_{2t} \quad D_{3t} \quad D_{4t})$

Supondo $T = 6$: 6 observações, 4 temas.

$$X = \begin{pmatrix} 1 & D_{11} & D_{21} & D_{31} & D_{41} \\ 1 & D_{12} & D_{22} & D_{32} & D_{42} \\ 1 & D_{13} & D_{23} & D_{33} & D_{43} \\ 1 & \vdots & \vdots & \vdots & \vdots \\ 1 & \vdots & \vdots & \vdots & \vdots \\ 1 & D_{16} & D_{26} & D_{36} & D_{46} \end{pmatrix} \begin{matrix} \nearrow T \\ 6 \times 5 \end{matrix} \begin{matrix} \nearrow K \\ 5 \end{matrix}$$

$$X = \begin{pmatrix} 1 & 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 \end{pmatrix}_{6 \times 5}$$

$\Rightarrow X_{4t} = X_{2t} + X_{3t} + X_{4t} + X_{5t} \quad \forall t$
multicolinearidade perfeita
entre os regressores

Soluções de MQO para o estimador é:

$$\hat{\beta} = (X'X)^{-1} X'y$$

$$(X'X) = \begin{pmatrix} T & \sum X_{2t} & \sum X_{3t} & \dots & \sum X_{kt} \\ \sum X_{2t} & \sum X_{2t}^2 & \sum X_{2t}X_{3t} & \dots & \sum X_{2t}X_{kt} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum X_{kt} & \dots & \dots & \dots & \sum X_{kt}^2 \end{pmatrix} \quad ; \text{somadas de 0 e 1}$$

\Rightarrow primeira linha da matriz $X'X$ soma = soma das outras linhas

No ex: $X'X = \begin{pmatrix} 6 & 2 & 2 & 1 & 1 \\ 2 & 2 & 0 & 0 & 0 \\ 2 & 0 & 2 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 1 \end{pmatrix} \Rightarrow \nexists (X'X)^{-1}$

Para evitar multicolinearidade perfeita

⇒ introduzir algum tipo de restrição nos parâmetros do modelo.

⇒ resulta em diferentes parametrizações

Os parâmetros são os γ 's (fatores sazonais). ⇒ Haveria alguma relação entre eles.

Cada parametrização irá estimar γ 's a partir de um parâmetro ≠

Power preditivo e previsões são os mesmos independente da parametrização.

⇒ Dependendo do nível tomado como referência, parâmetros são diferentes, mas previsões são as mesmas.

(a) Parametrizações 1

restrições

Faz um dos coeficientes $\gamma_j = 0$

⇒ uma das dummies terá sua regressão abandonada

A escolha de qual é arbitrária

Se abandonarmos D_{4t} (dummy do 4º trimestre), temos:

modelo: $y_t = \beta + \gamma_1 D_{1t} + \gamma_2 D_{2t} + \gamma_3 D_{3t} + \varepsilon_t \quad t = 1, 2, \dots, T$

obs: Fazemos $\gamma_4 = 0 \therefore D_{4t} = 0 \forall t$.
4º trimestre é caracterizado qdo $D_{1t} = D_{2t} = D_{3t} = 0$ ($D_{4t} = 1$) correspondência a
Se refizermos contas ⇒ não haveria + multicolinearidade perfeita

$$D_{jt} = \begin{cases} 1 & t = j, j+5, j+10, \dots, j = 1, 2, 3 \\ 0 & t \neq j, j+5, j+10, \dots \end{cases}$$

obs: Sob Normalidade, estimador MV = estimador MQO

Pelo método dos momentos:

fazer

• Para o 4º trimestre:

$$E[y_t | x_t] = E[y_t | D_{1t}, D_{2t}, D_{3t} = 0] = \beta$$

$$\therefore \boxed{\hat{\beta} = \bar{y}_4}$$

onde \bar{y}_j : média amostral do trimestre

• Para os outros trimestres

$$E[y_t | D_{jt} = 1] = \beta + \gamma_j \therefore \hat{\gamma}_j = \bar{y}_j - \beta \therefore \boxed{\bar{\gamma}_j = \bar{y}_j - \bar{y}_4} \quad j = 1, 2, 3$$

• Para os trimestres (exceto 4º).

$$E[y_t | D_{jt}] = \alpha + \theta_j \quad \therefore \quad \hat{\theta}_j = E[y_t | D_{jt}] - \alpha \quad j = 1, 2, 3$$

• Para o 4º trimestre

$$E[y_t | D_{4t}] = \alpha - (\underbrace{\theta_1 + \theta_2 + \theta_3}_{\theta_4}) = \alpha + \theta_4 \quad \therefore \quad \hat{\theta}_4 = E[y_t | D_{4t}] - \alpha$$

Restrições:

$$\text{como } \hat{\theta}_1 + \hat{\theta}_2 + \hat{\theta}_3 + \hat{\theta}_4 = 0$$

$$\Rightarrow (E[y_1 | D_{1t}] - \alpha) + (E[y_2 | D_{2t}] - \alpha) + (E[y_3 | D_{3t}] - \alpha) + (E[y_4 | D_{4t}] - \alpha) = 0$$

$$\therefore \sum_{j=1}^4 E[y_t | D_{jt}] - 4\alpha = 0.$$

$$\therefore \alpha = \frac{1}{4} \sum_{j=1}^4 E[y_t | D_{jt}]$$

Pelo método dos momentos:

$$\hat{\alpha} = \frac{1}{4} \sum_{j=1}^4 \bar{y}_j \quad \text{onde } \bar{y}_j = \frac{1}{n_j} \sum_{t=1}^{n_j} y_t^{(j)} : \text{média amostral no trimestre } j$$

↓
Obs: usamos n_j pois podemos ter uma amostra desbalanceada (pode ter nº diferente de obs p/ 1º, 2º, 3º, 4º tr)

Obs: Média total da série

$$\bar{y} = \frac{1}{n} \sum_{t=1}^n y_t \quad \text{onde } n = \sum_{j=1}^4 n_j$$

$$\text{Se amostra for balanceada: } \bar{y} = \frac{1}{4} \sum_{j=1}^4 \bar{y}_j$$

$$\text{Nesse caso: } \hat{\alpha} = \bar{y}$$

ou seja:

$$\hat{\theta}_j = E[y_t | D_{jt}] - \alpha, \quad j = 1, 2, 3, 4$$

$$\therefore \hat{\theta}_j = \bar{y}_j - \bar{y} \quad j = 1, 2, 3, 4 \quad \Rightarrow \text{fator sazonal de cada trimestre é medido em relação à média da série}$$

ATENÇÃO: Ver observação de ex. numéricas pg. 15, 16, 17, 18

⇒ Na verdade:

$\hat{\mu}$: média aritmética do 4º tri

Nos outros trimestres ⇒ vê-se há flutuações sazonais
(em relação ao 4º tri, trimestre base)

(b) Parametrizações 2

restrições | Abandona o intercepto e coloca uma dummy H cada período
(mesma estrutura anterior, mas agora sai intercepto)

modelo. $y_t = \delta_1 D_{1t} + \delta_2 D_{2t} + \delta_3 D_{3t} + \delta_4 D_{4t} + \varepsilon_t$ (Fatores sazonais, nomeados como δ_j)

$$D_{jt} = \begin{cases} 1 & t=j, t=j+2, t=j+2s, \dots \quad j=1,2,3,4 \\ 0 & t \neq j, t \neq j+2, t \neq j+2s, \dots \end{cases}$$

Pelo método dos momentos:

(faz)

para todos os trimestres

$$E[y_t | D_{jt}] = \delta_j \Rightarrow \hat{\delta}_j = \bar{y}_j, \quad j=1,2,3,4$$

onde \bar{y}_j é a média amostral de cada tri.


(c) Parametrizações 3

restrições | A soma dos coeficientes de sazonalidade é zero no período sazonal.

$$\sum_{j=1}^4 \theta_j = 0 \quad \therefore \quad \theta_1 = - \left(\sum_{j=2}^4 \theta_j \right) \Rightarrow \text{(Fatores sazonais nomeados como } \theta_j \text{)}$$

(É a parametrização adotada nos ME's)

Algo como:



⇒ No período: $\theta_1 + \theta_2 + \theta_3 + \theta_4 = 0$.

$$\text{Modelo: } y_t = \alpha + \sum_{j=1}^{s-1} \theta_j D_{jt} + \varepsilon_t, \quad t=1,2,\dots,T$$

$$D_{jt} = \begin{cases} 1 & t=j, j+2, \dots \\ 0 & t \neq j, j+2, \dots \\ -1 & t=2, 2s, 3s \end{cases}$$

No exemplo, equivale a:

$$1^\circ Q: y_t = \alpha + \theta_1 + \varepsilon_t$$

$$2^\circ Q: y_t = \alpha + \theta_2 + \varepsilon_t$$

$$3^\circ Q: y_t = \alpha + \theta_3 + \varepsilon_t$$

$$4^\circ Q: y_t = \alpha + (-\theta_1 - \theta_2 - \theta_3) + \varepsilon_t$$

=> Usando parametrizaçã 3:

O modelo determinístico com restrições dada pela soma dos fatores = 0:

Base p/ introdução da sazonalidade estocástica nos ME.

$$\left\{ \begin{array}{l} \text{Determinístico: } \sum_{j=1}^s \gamma_j = 0 \quad \therefore \quad \left| \sum_{j=1}^{s-1} \gamma_{t-j} = 0 \right| \quad \sim \text{Divide} \\ \text{Estocástico: } \sum_{j=1}^{s-1} \gamma_{t-j} = w_t, \quad w_t \sim N(0, \sigma_w^2) \end{array} \right.$$

$\gamma_s = - \sum_{j=1}^{s-1} \gamma_j$


ou $\gamma_t = - \sum_{j=1}^{s-1} \gamma_{t-j} + w_t$

→ Para o modelo com MNL e sazonalidade estocástica por dummies a ideia é:

$$\left\{ \begin{array}{l} y_t = \mu_t + \gamma_t + \varepsilon_t \\ \mu_{t+1} = \mu_t + \eta_t \\ \gamma_t = ? \Rightarrow \text{como explicitaremos?} \end{array} \right.$$

O ponto de partida é a parametrizaçã 3:

$$\sum_{j=1}^s \gamma_j = 0$$



No caso determinístico, se andarmos sempre 4 tri p/ frente, temos somatório = 0

Para $s=4$: $\left[\sum_{j=0}^{s-1} \gamma_{t-j} = 0 \right]$

pois $\gamma_t + \gamma_{t-1} + \gamma_{t-2} + \gamma_{t-3} = 0$: qualquer que seja t, cobrimos o período.

desenvolvendo

Para o ME, caso de sazonalidade estocástica, fazemos:

$$\sum_{j=0}^{s-1} \gamma_{t-j} = w_t \quad \text{onde } w_t \sim N(0, \sigma_w^2) : \text{flutuação estocástica}$$

$$\left(\text{onde } E \left[\sum_{j=0}^{s-1} \gamma_{t-j} \right] = 0 \right)$$

Obs: γ do ME não corresponde a γ determinístico (que naquele caso eram x por dummies)

$$\Rightarrow \left[\gamma_t = - \sum_{j=1}^{s-1} \gamma_{t-j} + w_t \right]$$

(*)

dummies que no ME ficam implícitas

Nas funções mais $D_{1,t}$, $D_{2,t}$ etc.

Fazemos apenas γ_t correspondente ao período em que estamos trabalhando

Para o MNL com sazonalidade, temos:

$$\begin{cases} y_t = \mu_t + \gamma_t + \varepsilon_t \\ \mu_{t+1} = \mu_t + \eta_t \\ \gamma_t = - \sum_{j=1}^{s-1} \gamma_{t-j} + w_t \end{cases}$$

por ex, supondo dados trimestrais, a ideia da equação (*) é:

t	$t+1$
Q1 2010	Q2 2010
$\gamma_{1,t}$	$\gamma_{2,t+1}$
$\gamma_{2,t}$	$\gamma_{3,t+1}$
$\gamma_{3,t}$	$\gamma_{4,t+1}$
$\gamma_{4,t}$	$\gamma_{1,t+1}$

rearrumando os fatores sazonais no trimestre

$$\text{como } \gamma_{1,t+1} = -\gamma_{4,t} \quad \text{e} \quad \gamma_{1,t} + \gamma_{2,t} + \gamma_{3,t} + \gamma_{4,t} = 0$$

$$\therefore \gamma_{4,t} = -(\gamma_{1,t} + \gamma_{2,t} + \gamma_{3,t}),$$

temos:

$$\begin{cases} \delta_{1,t+1} = -\delta_{1,t} - \delta_{2,t} - \delta_{3,t} \\ \delta_{2,t+1} = \delta_{1,t} \\ \delta_{3,t+1} = \delta_{2,t} \end{cases}$$

Na FEE, podemos escrever:

$$y_t = (1 \ 0 \ 0) \begin{pmatrix} \delta_{1,t} \\ \delta_{2,t} \\ \delta_{3,t} \end{pmatrix} + \varepsilon_t$$

$$\begin{pmatrix} \delta_{1,t+1} \\ \delta_{2,t+1} \\ \delta_{3,t+1} \end{pmatrix} = \begin{pmatrix} -1 & -1 & -1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix} \begin{pmatrix} \delta_{1,t} \\ \delta_{2,t} \\ \delta_{3,t} \end{pmatrix} + \begin{pmatrix} \omega_t \\ 0 \\ 0 \end{pmatrix}$$

na equação (*), temos:

$$\delta_t = \sum_{j=1}^{3-1} \delta_{t-j} + \omega_t \Rightarrow \delta_t = -\delta_{t-1} - \delta_{t-2} - \delta_{t-3} + \omega_t$$

$$\text{ou } \delta_{t+1} = -\delta_t - \delta_{t-1} - \delta_{t-2} + \omega_t$$

Na FEE, temos:

→ no sazonalidade

$$y_t = \delta_t + \varepsilon_t$$

$$\delta_{t+1} = -\delta_t - \delta_{t-1} - \delta_{t-2} + \omega_t$$

$$\Rightarrow \begin{pmatrix} \delta_{t+1} \\ \delta_t \\ \delta_{t-1} \end{pmatrix} = \begin{pmatrix} -1 & -1 & -1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix} \begin{pmatrix} \delta_t \\ \delta_{t-1} \\ \delta_{t-2} \end{pmatrix} + \begin{pmatrix} \omega_t \\ 0 \\ 0 \end{pmatrix}$$

uma parametrização

obs 1: Esta é a forma + simples de incluir sazonalidade no ME

obs 2: δ_t se refere ao fator sazonal do instante corrente.

obs 3: Se considerarmos tendência \Rightarrow matriz T não diagonal em blocos.

obs 4: Nas há influência da componente de tendência na sazonalidade e vice-versa.

como sabemos
ness caso
quando
periodicidade
é repetida?
é não é
de defasagem?

Modelo Estrutural Básico (MEB)

MLL + Sazonalidade Estocástica

$$\begin{cases} y_t = \mu_t + \delta_t + \varepsilon_t & \varepsilon_t \sim N(0, \sigma_\varepsilon^2) \\ \mu_t = \mu_{t-1} + \beta_{t-1} + \eta_t & \eta_t \sim N(0, \sigma_\eta^2) \\ \beta_t = \beta_{t-1} + \zeta_t & \zeta_t \sim N(0, \sigma_\zeta^2) \\ \delta_t = \sum_{j=1}^{s-1} \delta_{t-j} + \omega_t & \omega_t \sim N(0, \sigma_\omega^2) \end{cases}$$

⇒ dimensões dos estados:
 $1 + 1 + s - 1 = s + 1$
 $\downarrow \quad \downarrow \quad \downarrow$
 $\mu_t \quad \beta_t \quad \text{sazonalidade}$

onde: $E[\varepsilon_t \eta_s] = E[\varepsilon_t \zeta_s] = E[\varepsilon_t \omega_s] = 0 \quad \forall t, s$

$E[\varepsilon_t \alpha_0] = E[\eta_t \alpha_0] = E[\zeta_t \alpha_0] + E[\omega_t \alpha_0] = 0 \quad \forall t$

Se $\alpha_t = (\mu_t, \beta_t, \delta_t, \delta_{t-1}, \delta_{t-2})'$, então $\alpha_0 \sim N(a_0, P_0)$

\downarrow
 $s = 4$: entram 3
 componentes no v.e.
 tor de estado

obs: Ruídos das componentes são decorrelatados entre si.

↓
 onde entra
 a suposição?

Exemplo. Seja $s=4$, a FEE será

$$y_t = (1 \ 0 \ 1 \ 0 \ 0) \begin{pmatrix} \mu_t \\ \beta_t \\ \delta_t \\ \delta_{t-1} \\ \delta_{t-2} \end{pmatrix} + \varepsilon_t, \quad \varepsilon_t \sim N(0, \sigma_\varepsilon^2)$$

$$\alpha_t = \begin{pmatrix} \mu_t \\ \beta_t \\ \delta_t \\ \delta_{t-1} \\ \delta_{t-2} \end{pmatrix} = \begin{pmatrix} 1 & 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & -1 & -1 & -1 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \end{pmatrix} \begin{pmatrix} \mu_{t-1} \\ \beta_{t-1} \\ \delta_{t-1} \\ \delta_{t-2} \\ \delta_{t-3} \end{pmatrix} + \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} \eta_t \\ \zeta_t \\ \omega_t \end{pmatrix}$$

↓
 diagonal em blocos

$$Q = \begin{pmatrix} \sigma_\eta^2 & 0 & 0 \\ 0 & \sigma_\zeta^2 & 0 \\ 0 & 0 & \sigma_\omega^2 \end{pmatrix}$$

Funções de Previsão

$$\hat{y}_{t+s|t} = E[y_{t+s} | Y_t] = Z' E[\alpha_{t+s} | Y_t]$$

$$= Z' \alpha_{t+s|t} =$$

$$= \hat{\mu}_{t+s|t} + \hat{\gamma}_{t+s|t}$$

$$= \hat{\mu}_{t|t} + s \hat{\beta}_{t|t} + \hat{\gamma}_{t+s|t}$$

$$\text{onde } \hat{\gamma}_{t+s|t} = \hat{\gamma}_{t-s+s|t} \quad s = 1, 2, 3, \dots$$

↓
ou seja, vai ser projetado p/ aquele período o último fator sazonal estimado p/ um período correspondente.

⇒ o fator sazonal projetado p/ um trimestre é igual à última estimativa obtida pelo FK.

Nas previsões, trabalhamos de forma determinística. É um tipo de amortecimento exponencial onde pesos são calculados por MV

2) Sazonalidade por Variáveis Trigonométricas

⇒ Aproximar a componente sazonal através de uma soma de séries trigonométricas.

Obs: Teorema de Fourier

$f(t)$ função regular por partes (n° finito de descontinuidades)

⇒ admite expansão em séries trigonométricas

$$f(t) = \sum_{j=0}^{\infty} (\delta_j \cos j t + \delta_j^* \sin j t)$$

util p/ representar funções periódicas, como por exemplo, a componente sazonal de uma ST.

$$\delta_t = \sum_{j=1}^{s/2} (\delta_j \cos \lambda_j t + \delta_j^* \sin \lambda_j t)$$

$$\text{onde } \lambda_j = 2\pi j / s, \quad j = 1, 2, 3, \dots, s/2$$

s : período da série (ex: 4, 12 etc.)

$$s/2 = \begin{cases} s/2 & s \text{ par} \\ (s-1)/2 & s \text{ ímpar} \end{cases}$$

Obs 1: No caso de dummies, os γ_j são os próprios fatores sazonais variando com o tempo e a leitura dos fatores é direta ($\gamma_j = \gamma_1, \gamma_2, \dots$)

Obs 2: No caso de funções trigonométricas, a leitura do fator sazonal não é direta. A sazonalidade será a soma de senos e cossenos γ_j 's serão estimados mas fator sazonal será dado por $\gamma_t = \sum \gamma_j \cos(\lambda_j t) + \delta_j^* \sin(\lambda_j t)$

Obs 3: $\lambda_j = \frac{2\pi j}{s}$ são os harmônicos

Cada harmônico executa j ciclos completos no período da função

• $\lambda_1 = \frac{2\pi}{s}$ é a frequência fundamental (1º harmônico)

Exemplo: $y_t = \gamma_t + \epsilon_t$

$$(s=4) \quad \gamma_t = \sum_{j=1}^2 \left[\gamma_j \cos(\lambda_j t) + \delta_j^* \sin(\lambda_j t) \right]$$

$$\lambda_j = \frac{2\pi j}{s} = \frac{2\pi j}{4} = \frac{\pi}{2} \cdot j \quad j=1, 2$$

Abreviando expressões para γ_t :

$$\gamma_t = \left[\gamma_1 \cos(\lambda_1 t) + \delta_1^* \sin(\lambda_1 t) \right] + \left[\gamma_2 \cos(\lambda_2 t) + \delta_2^* \sin(\lambda_2 t) \right]$$

$$\lambda_1 = \pi/2$$

$$\lambda_2 = \pi \quad (\text{obs: } \sin(\pi t) = 0 \quad \forall t)$$

$$\therefore \gamma_t = \left[\gamma_1 \cos(\lambda_1 t) + \delta_1^* \sin(\lambda_1 t) \right] + \gamma_2 \cos(\lambda_2 t)$$

$$\therefore y_t = \underbrace{\gamma_1 \cos(\lambda_1 t)}_{x_{1t}} + \underbrace{\delta_1^* \sin(\lambda_1 t)}_{x_{2t}} + \underbrace{\gamma_2 \cos(\lambda_2 t)}_{x_{3t}} + \epsilon_t$$

\Rightarrow Precisaremos estimar 3 parâmetros associados a sazonalidade (por MGO)

γ_1, δ_1^* e $\gamma_2 \Rightarrow$ número de parâmetros quando trabalhamos com dummies

Obs: γ_1, δ_1^* e γ_2 são os fatores sazonais

Os fatores serão dados por:

$$\hat{\gamma}_t = \hat{\gamma}_1 \cos \frac{\pi}{2} t + \hat{\gamma}_1^* \sin \frac{\pi}{2} t + \hat{\gamma}_2 \cos \pi t$$

Na série trimestral:

$$\begin{array}{l} 1^{\circ} Q \rightarrow t=1 \\ 2^{\circ} Q \rightarrow t=2 \\ 3^{\circ} Q \rightarrow t=3 \\ 4^{\circ} Q \rightarrow t=4 \\ 1^{\circ} Q \rightarrow t=5 \end{array} \quad \left. \vphantom{\begin{array}{l} 1^{\circ} Q \\ 2^{\circ} Q \\ 3^{\circ} Q \\ 4^{\circ} Q \\ 1^{\circ} Q \end{array}} \right\} \text{1 ciclo.}$$

Para $t=1 \Rightarrow \gamma_1$ será o fator sazonal

(que deverá ser numericamente igual ao modelo determinístico por dummies da param. iii)

obs: $Q^{to} +$ bem comportada por a série em relação à sazonalidade, menos harmônicos são necessários p/ compor.

Os 1^{os} harmônicos ditarão o comportamento nesse caso.

$Q^{to} +$ " usarmos \Rightarrow mais estranho é o comportamento sazonal (se harmônicos + altos \tilde{n} porém muito importantes \Rightarrow não são estatisticamente relevantes, mas \tilde{n} não são abandonados)

• Modelo determinístico com tend. e sazonalidade

$$y_t = \underbrace{\beta_1 + \beta_2 t}_{\mu_t} + \underbrace{\sum_{j=1}^{s/2} (\gamma_j \cos \lambda_j t + \gamma_j^* \sin \lambda_j t)}_{\gamma_t} + \epsilon_t$$

observações:

• p/ s par e $j = s/2 \Rightarrow \sin \lambda_j t = \sin \pi t = 0, \forall t$

$$\downarrow$$

$$\frac{2\pi j}{s}$$

$\Rightarrow \exists$ apenas $\underbrace{s/2}_{\text{do cosseno}} + \underbrace{(s-1)/2}_{\text{p/ estimar por MBO (como nas dummies)}}$ = $s-1$ parâmetros de sazonalidade

• Calculados γ_j e $\gamma_j^* \Rightarrow$ calcula-se fator sazonal

$$\gamma_t = \sum (\gamma_j \cos \lambda_j t + \gamma_j^* \sin \lambda_j t)$$

prova

• Se usarmos todos os harmônicos na SF: estimativa por dummies
" na SF...

• Usando ident trigonométricas, pode-se demonstrar que:

$$\sum_{j=0}^{s-1} \gamma_{t-j} = 0$$

→ Modelo ci sf na forma EE

precisamos de uma forma recursiva pl fatores racionais

$$y_t = \mu_t + \gamma_t + \varepsilon_t$$

$$\text{onde } \gamma_t = \sum_{j=1}^{s/2} \gamma_{jt} \text{ onde } \gamma_{jt} = \gamma_j \cos(\lambda_j t) + \gamma_j^* \sin(\lambda_j t) \quad (a)$$

Queremos $\gamma_{j,t+1}$ como função de γ_{jt}

• Ainda pl γ_{jt} , temos:

$$\gamma_{jt} = \begin{cases} \gamma_j \cos(\lambda_j t) + \gamma_j^* \sin(\lambda_j t) & \text{pl } j=1 \text{ a } \frac{s}{2}-1 \\ \gamma_{s/2} \cos(\lambda_{s/2} t) & \text{pl } j = s/2 \end{cases} \quad (b)$$

• Fazendo $t=t+1$ na expressão (a) pl obter fórmula recursiva pl γ_{jt}

$$\begin{aligned} \gamma_{j,t+1} &= \gamma_j \cos \lambda_j (t+1) + \gamma_j^* \sin \lambda_j (t+1) \\ &= \gamma_j \cos (\lambda_j t + \lambda_j) + \gamma_j^* \sin (\lambda_j t + \lambda_j) \end{aligned}$$

$$\begin{cases} \cos(a+b) = \cos a \cos b - \sin a \sin b \\ \sin(a+b) = \sin a \cos b + \sin b \cos a \end{cases}$$

$$\gamma_{j,t+1} = \gamma_j [\cos \lambda_j t \cos \lambda_j - \sin \lambda_j t \sin \lambda_j] + \gamma_j^* [\sin \lambda_j t \cos \lambda_j + \cos \lambda_j t \sin \lambda_j]$$

$$= (\cos \lambda_j \quad \sin \lambda_j) \begin{pmatrix} \gamma_j \cos \lambda_j t + \gamma_j^* \sin \lambda_j t \\ -\gamma_j \sin \lambda_j t + \gamma_j^* \cos \lambda_j t \end{pmatrix} \begin{matrix} \rightarrow \gamma_{jt} \\ \rightarrow \gamma_{jt}^* \end{matrix} \quad (c)$$

$$\gamma_{j,t+1} = (\cos \lambda_j \quad \sin \lambda_j) \begin{pmatrix} \gamma_{jt} \\ \gamma_{jt}^* \end{pmatrix} \Rightarrow \text{fórmula de recursão}$$

(d)

(aparece
por cons-
trução)
nas fórm
significa
prático

—

2, -

Modelo Estrutural Básico com racionalidade em SF.

$$y_t = \mu_t + \delta_t + \varepsilon_t \quad \varepsilon_t \sim N(0, \sigma_\varepsilon^2)$$

$$\mu_t = \mu_{t-1} + \beta_{t-1} + \eta_t \quad \eta_t \sim N(0, \sigma_\eta^2)$$

$$\beta_t = \beta_{t-1} + \zeta_t \quad \zeta_t \sim N(0, \sigma_\zeta^2)$$

$$\delta_t = \sum_{j=1}^{S/2} \delta_{jt} \quad (\text{obs: compon. do vetor de estado são } \delta_{jt})$$

$$\begin{pmatrix} \delta_{jt} \\ \delta_{jt}^* \end{pmatrix} = \begin{pmatrix} \cos \lambda_j & \sin \lambda_j \\ -\sin \lambda_j & \cos \lambda_j \end{pmatrix} \begin{pmatrix} \delta_{j,t-1} \\ \delta_{j,t-1}^* \end{pmatrix} + \begin{pmatrix} w_t \\ w_t^* \end{pmatrix}, \quad w_t \sim N(0, \sigma_w^2)$$

$$\text{onde } E[\varepsilon_t \eta_s] = E[\varepsilon_t \zeta_s] = E[\varepsilon_t w_s] = 0 \quad \forall t, s$$

$$E[\varepsilon_t \alpha_0] = E[\eta_t \alpha_0] = E[w_t \alpha_0] = 0 \quad \forall t$$

$$\text{se } \alpha_t = (\mu_t, \beta_t, \delta_{1t}, \dots, \delta_{(S/2)t})' \Rightarrow \alpha_0 \sim N(\alpha_0, P_0)$$

Exemplo: se $S = 12$

$$\delta_t = \delta_{1t} + \delta_{2t} + \delta_{3t} + \delta_{4t} + \delta_{5t} + \delta_{6t}$$

estes fatores aparecerão no vetor de estado
junto com $\delta_{1t}^*, \delta_{2t}^*, \delta_{3t}^*, \delta_{4t}^*, \delta_{5t}^*$

(δ_{6t}^* não entra pois $\sin \pi t = 0$)

Sazonalidade Estocástica nos ME

a determinística é caso particular quando $\sigma_w^2 = 0$.

Trabalhando com modelagem por dummies p o MEB, temos.

$$\left\{ \begin{array}{l} y_t = \mu_t + \gamma_t + \varepsilon_t \\ \mu_t = \mu_{t-1} + \beta_{t-1} + \eta_t \\ \beta_t = \beta_{t-1} + \zeta_t \\ \gamma_t = - \sum_{j=1}^{s-1} \gamma_{t-j} + w_t \end{array} \right. \quad \left. \begin{array}{l} \text{tend. linear estocástica} \\ \text{raz. estocástica} \end{array} \right\}$$

→ Forma reduzida de um MEB : é identificável
muito conhecido

mas qual SARIMA equivalente? SARIMA(p, d, q) x (P, D, Q)

• Operador de diferenciação sazonal

$$\left[\Delta_s \hat{=} I - L^s \right] \quad \text{onde } s \text{ é a frequência da sazonalidade (mensal, trimestral etc.)}$$


Obs 1: se sazonalidade for determinística

$$\Delta_s y_t = y_t - y_{t-s} \Rightarrow \text{operações tiram totalmente a sazonalidade}$$

Obs 2: só se deve operar a sazonalidade estocástica após diferenciá-la em relação à tendência

Exemplo:

- Para modelo nas estac. na sazonalidade, temos decaimento lento nos períodos $s, 2s, \dots$



- Após aplicação de $\Delta_s \Rightarrow$ decaimento rápido



Obs 3. Estacionariedade \Rightarrow importante no contexto B&T
 No contexto ME não é necessário (nem pt tendência), mas vamos
 precisar trabalhar por conta da forma reduzida

• Operador $S_2(L)$

$$S_2(L) = 1 + L + L^2 + \dots + L^{s-1}$$

$$\begin{aligned} \therefore \Delta S_2(L) &= (1-L)(1+L+L^2+\dots+L^{s-1}) \\ &= 1 + \cancel{L} + \cancel{L^2} + \dots + \cancel{L^{s-1}} - L - L^2 - \dots - L^s \\ &= 1 - L^s = \Delta_s \end{aligned}$$

Obs 1: Operadores comutam

$$\text{Ex: } \underbrace{S_2(L) \Delta \Delta y_t}_{\Delta S_2(L)} = \Delta_s \Delta y_t$$

• Forma reduzida do MEB

Vai diferenciando equações y_t até torná-la estacionária
 Para quando estiver do lado direito apenas funções dos erros.

$$\Delta y_t = \underbrace{\Delta \mu_t}_{\beta_{t-1} + \eta_t} + \Delta \delta_t + \Delta \varepsilon_t$$

$$\therefore \Delta^2 y_t = \underbrace{\Delta \beta_{t-1}}_{\gamma_{t-1}} + \Delta \eta_t + \Delta^2 \delta_t + \Delta^2 \varepsilon_t$$

$$\boxed{\Delta^2 y_t = \gamma_{t-1} + \Delta \eta_t + \Delta^2 \delta_t + \Delta^2 \varepsilon_t} \quad (a)$$

Para a componente sazonal:

$$\delta_t = -\sum_{j=1}^{s-1} \delta_{t-j} + w_t$$

$$\therefore \delta_t + \sum_{j=1}^{s-1} \delta_{t-j} = w_t$$

$$\delta_t + \delta_{t-1} + \dots + \delta_{t-s+1} = w_t$$

$$S_s(L) \delta_t = w_t \Rightarrow \text{outra forma de escrever equações para comp sazonal}$$

de (a), aplicando $S_s(L)$:

$$S_s(L) \Delta^2 y_t = S_s(L) \zeta_{t-1} + S_s(L) \Delta \eta_t + S_s(L) \Delta^2 \varepsilon_t + S_s(L) \Delta^2 \varepsilon_t$$

Como operadores comutam:

$$\Delta \underbrace{\Delta S_s(L)}_{\Delta_s} y_t = S_s(L) \zeta_{t-1} + \underbrace{\Delta S_s(L)}_{\Delta_s} \eta_t + \underbrace{\Delta^2 S_s(L)}_{w_t} \varepsilon_t + \underbrace{\Delta \Delta S_s(L)}_{\Delta_s} \varepsilon_t$$

$$\Rightarrow \left[\Delta \Delta_s y_t = \underbrace{\Delta_s \eta_t}_{\substack{\text{gera} \\ 2 \text{ termos}}} + \underbrace{\Delta \Delta_s \varepsilon_t}_{\substack{\text{gera} \\ 4 \text{ termos}}} + \underbrace{\Delta^2 w_t}_{\substack{\text{gera } 3 \\ \text{termos}}} + \underbrace{S(L) \zeta_{t-1}}_{\substack{\text{gera } 5 \text{ termos}}} \right]$$

\Rightarrow Processo do lado direito é estacionário em q coef. 2

É um MA(s+1)

Para mostrar, calcula-se a FAC: não se anula buscamente após $s+1$

$$\underbrace{\Delta \Delta_s y_t}_{w_t} \sim \text{MA}(s+1)$$

\downarrow
FAC se anula após $s+1$.

Teremos $s+2$ equações (de $\gamma(0)$ a $\gamma(s+1)$)
e $s+2$ parâmetros a estimar.

da
apostila

$$\gamma(0) = 2\sigma_\eta^2 + 4\sigma_\varepsilon^2 + 6\sigma_w^2 + 5\sigma_\gamma^2$$

$$\gamma(1) = (s-1)\sigma_\gamma^2 - 4\sigma_w^2 - 2\sigma_\varepsilon^2$$

$$\gamma(2) = (s-2)\sigma_\gamma^2 + \sigma_w^2$$

$$\gamma(k) = (s-k)\sigma_\gamma^2 \quad k = 3, \dots, s-2$$

$$\gamma(s-1) = \sigma_\gamma^2 + \sigma_\varepsilon^2$$

$$\gamma(s) = -\sigma_\eta^2 - 2\sigma_\varepsilon^2$$

$$\gamma(s+1) = \sigma_\varepsilon^2$$

$$\gamma(k) = 0 \quad k \geq s+2.$$

fazer

Pergunta: Qual modelo SARIMA que é equivalente a este processo?

Se quisermos equivalência y AIRLINE, quais restrições precisaremos impor aos parâmetros?

$$\text{Airline: SARIMA } (0, 1, (1)) \times (0, 1, (1))_{12} \Rightarrow \text{FAC} \neq \text{em} \begin{cases} q = 1 \\ q = S-1 \\ q = S \\ q = S+1 \end{cases}$$

$$\begin{aligned} \text{Forma geral: } \Delta \Delta_S y_t &= (1 - \Theta_1 L^S)(1 - \theta_1 L) \varepsilon_t \\ &= \varepsilon_t - \theta_1 \varepsilon_{t-1} - \Theta_1 \varepsilon_{t-S} + \theta_1 \Theta_1 \varepsilon_{t-(S+1)} \end{aligned}$$

$$\gamma(0) = (1 + \theta_1^2 + \Theta_1^2 + \theta_1^2 \Theta_1^2) \sigma_\varepsilon^2$$

$$\gamma(1) = -\theta_1 \sigma_\varepsilon^2 - \theta_1 \Theta_1 \sigma_\varepsilon^2$$

$$\gamma(k) = 0 \quad k = 2, \dots, S-2$$

$$\gamma(S-1) = \dots$$

$$\gamma(S) = \dots$$

$$\gamma(S+1) = \dots$$

$$\gamma(k) = 0 \quad k \geq S+2$$

Vamos precisar ter $\sigma_\gamma^2 = 0$ e $\sigma_\omega^2 = 0$.

E neste caso temos $\Theta_1 = 1$.

provar

Modelo H ciclos (aula 25/05)


$$y_t = \mu_t + \psi_t + \varepsilon_t$$



ciclos são flutuações no nível que ocorrem de forma recorrente, com periodicidade \approx regular > 1 ano.

(Flutuações sobre tendência de LP)

→ Versão determinística



(idéia é usar modelo de componente sazonal na forma trigonométrica, considerando apenas o harmônico fundamental)

⇒ Para cada ciclo, trabalharemos com 1 frequência

$$y_t = \mu + \psi_t + \varepsilon_t$$

$$\psi_t = \alpha \cos \lambda_c t + \beta \sin \lambda_c t$$

$$\text{onde } \lambda_c = \frac{2\pi}{T_c} : \text{frequência.}$$

⇒ Temos que estimar α , β e λ (ou T)
 ↓
 estimadas não lineares

obs: Se conhecêssemos T , estimaríamos trivialmente por MQO. Como não conhecemos, duas opções.

- estima T separadamente pelo periodograma e outros parâmetros por MQO
- estima tudo junto por meio das não lineares.

MQO não: $S(\mu, \alpha, \beta, T) = \sum_{t=1}^T (y_t - (\mu + \cos(2\pi/T)t + \sin(2\pi/T)t))^2$

Obs 2: Para sazonalidade, ME por:

$$\begin{cases} y_t = \mu_t + \delta_t + \varepsilon_t \\ \delta_t = \sum_{j=1}^{s/2} \gamma_{jt} \rightarrow j=1 \text{ a } s/2: \text{ várias frequências} \\ \begin{pmatrix} \delta_{jt} \\ \delta_{jt}^* \end{pmatrix} = \begin{pmatrix} \cos \lambda & \sin \lambda \\ -\sin \lambda & \cos \lambda \end{pmatrix} \begin{pmatrix} \delta_{j,t-1} \\ \delta_{j,t-1}^* \end{pmatrix} + \begin{pmatrix} w_t \\ w_t^* \end{pmatrix} \end{cases}$$

\Rightarrow Para ciclo, apenas $j=1$ (uma frequência)

$y_t = \mu_t + \psi_t + \varepsilon_t$ \rightarrow Matriz T ($\mu_t = ct$)

$$\begin{pmatrix} \psi_t \\ \psi_t^* \end{pmatrix} = \rho \begin{pmatrix} \cos \lambda_c & \sin \lambda_c \\ -\sin \lambda_c & \cos \lambda_c \end{pmatrix} \begin{pmatrix} \psi_{t-1} \\ \psi_{t-1}^* \end{pmatrix} + \begin{pmatrix} k_t \\ k_t^* \end{pmatrix}$$

k_t, k_t^* : RB
des correlatados
 $\sim N(0, \sigma_k^2)$

$|\rho| < 1 \Rightarrow$ contribuição ~~por~~ amortecimento
do choque
(cte. de amortecimento)

$\lambda_c = 2\pi/T_c \Rightarrow$ frequência.

Atenções!

(i) Se $\lambda_c = 0$ ou $\lambda_c = \pi \Rightarrow$ ciclo se torna AR(1)

$$\begin{pmatrix} \psi_t \\ \psi_t^* \end{pmatrix} = \rho \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \psi_{t-1} \\ \psi_{t-1}^* \end{pmatrix} + \begin{pmatrix} k_t \\ k_t^* \end{pmatrix}$$

$\Rightarrow \psi_t = \rho \psi_{t-1} + k_t \quad ; \quad AR(1)$

(ii) cte. de amortecimento faz choque se irar q o tempo

\rightarrow Componente cíclica estocástica

$\psi_t = \rho [\cos \lambda_c \psi_{t-1} + \sin \lambda_c \psi_{t-1}^*] + k_t \quad \psi_t \sim N(0, \sigma_\psi^2)$

Impondo estacionariedade: $\rightarrow \Psi_t = \rho \cos \lambda_c \Psi_{t-1} + \rho \sin \lambda_c \Psi_{t-1}^* + k_t$ (2.46)

$$\text{var}(\Psi_t) = \rho^2 (\cos^2) \text{var}(\Psi_t) + \rho^2 (\sin^2) \text{var}(\Psi_t) + \text{var}(k_t)$$

$$\text{var}(\Psi_t) = (\cos^2 + \sin^2) \rho^2 \text{var}(\Psi_t) + \text{var}(k_t)$$

$$\text{var}(\Psi_t) = (1 - \rho^2) \sigma_k^2$$

$$E[\Psi_t] = 0$$

$$\text{var}(\Psi_t) = \text{cte.} \Rightarrow (1 - \rho^2) \text{var}(\Psi) = (1 - \rho^2) \sigma_\Psi^2 = \sigma_k^2$$

(?) divida

Parâmetros desconhecidos: ρ e σ_Ψ^2

Se $\rho \rightarrow 1$: $\sigma_k^2 \rightarrow 0 \Rightarrow$ ciclo se torna estacionário

$$\Psi_t = \Psi_0 \cos \lambda_c t + \Psi_0^* \sin \lambda_c t \text{ onde } \Psi_0 \sim N(0, \sigma_\Psi^2)$$

— " —

Modelo de ciclo na forma EE

$$\begin{pmatrix} \Psi_t \\ \Psi_t^* \end{pmatrix} = \underbrace{\rho \begin{pmatrix} \cos \lambda_c & \sin \lambda_c \\ -\sin \lambda_c & \cos \lambda_c \end{pmatrix}}_{A} \begin{pmatrix} \Psi_{t-1} \\ \Psi_{t-1}^* \end{pmatrix} + \begin{pmatrix} k_t \\ k_t^* \end{pmatrix}$$

$$\underset{\sim}{\Psi}_t = A \underset{\sim}{\Psi}_{t-1} + \underset{\sim}{k}_t \quad \text{onde } \underset{\sim}{\Psi}_t = \begin{pmatrix} \Psi_t \\ \Psi_{t-1} \end{pmatrix} \Rightarrow \text{Processo AR(1) Vetorial}$$

• Funções de Previsão

$$\underset{\sim}{\Psi}_{t+2} = A^2 \underset{\sim}{\Psi}_t + \sum_{i=1}^2 A^{2-i} \underset{\sim}{k}_{t+i} \quad : \text{suavizado de forma recursiva.}$$

$$\therefore \hat{\underset{\sim}{\Psi}}_{t+2|t} = E[\underset{\sim}{\Psi}_{t+2} | \underset{\sim}{y}_t] = A^2 E[\underset{\sim}{\Psi}_t | \underset{\sim}{y}_t]$$

$$= A^2 \underset{\sim}{\Psi}_{t|t}$$

$$\text{onde } A^2 = \rho^2 \begin{pmatrix} \cos 2\lambda_c & \sin 2\lambda_c \\ -\sin 2\lambda_c & \cos 2\lambda_c \end{pmatrix}$$

$$= \rho^{(2)} \begin{pmatrix} \cos(2)\lambda_c & \sin 2\lambda_c \\ -\sin 2\lambda_c & \cos 2\lambda_c \end{pmatrix}$$

$$\therefore \Psi_{t+2|t} = \rho^2 \cos 2\lambda_c \Psi_{t|t} + \rho^2 \sin 2\lambda_c \Psi_{t|t}^*$$

se $\rho = 1$: soma de senos e cossenos

$4 | \rho | < 1$: suavidade amortecida.

obs: se $s \rightarrow \infty$: $\Psi_{t+s|t} = 0$: componente de tendência

→ Forma reduzida

$$\tilde{\Psi}_t = A \tilde{\Psi}_{t-1} + K_t \quad : \text{ processo AR(1) vetorial}$$

tem
uma
diferença
e tornar
estacionário

$$\therefore (I - A) \tilde{\Psi}_t = K_t$$

$$\therefore \tilde{\Psi}_t = (I - A)^{-1} K_t$$

$$\text{onde } A = \rho \begin{pmatrix} \cos \lambda_c & \kappa \sin \lambda_c \\ -\kappa \sin \lambda_c & \cos \lambda_c \end{pmatrix}$$

$$\therefore \tilde{\Psi}_t = \begin{pmatrix} 1 - \rho \cos \lambda_c L & -\rho \kappa \sin \lambda_c L \\ \rho \kappa \sin \lambda_c L & 1 - \rho \cos \lambda_c L \end{pmatrix}^{-1} K_t$$

$$\therefore \tilde{\Psi}_t = \frac{1}{(1 - \rho \cos \lambda_c L)^2 + \rho^2 (\kappa \sin \lambda_c L)^2} \begin{pmatrix} \dots \end{pmatrix} \begin{pmatrix} K_t \\ K_t^* \end{pmatrix}$$

$$= \frac{1}{1 - 2\rho \cos \lambda_c L + \rho^2 (\cos \lambda_c L)^2 + \rho^2 (\kappa \sin \lambda_c L)^2} \begin{pmatrix} \dots \end{pmatrix} \begin{pmatrix} K_t \\ K_t^* \end{pmatrix}$$

$$\begin{pmatrix} \Psi_t \\ \Psi_t^* \end{pmatrix} = \frac{1}{1 - 2\rho \cos \lambda_c L + \rho^2 L^2} \begin{pmatrix} 1 - \rho \cos \lambda_c L & \rho \kappa \sin \lambda_c L \\ -\rho \kappa \sin \lambda_c L & 1 - \rho \cos \lambda_c L \end{pmatrix} \begin{pmatrix} K_t \\ K_t^* \end{pmatrix}$$

$$\Rightarrow \Psi_t = \frac{1}{1 - 2\rho \cos \lambda_c L + \rho^2 L^2} \left[(1 - \rho \cos \lambda_c L) K_t + (\rho \kappa \sin \lambda_c L) K_t^* \right]$$

variáveis explicativas e intervenções em ME

$\tilde{x}_t = (x_{1t} \ x_{2t} \ \dots \ x_{kt}) \sim k \times 1 \Rightarrow$ vetor de variáveis explicativas.

$\tilde{\gamma} = (\gamma_1 \ \gamma_2 \ \dots \ \gamma_k) \sim k \times 1 \Rightarrow$ vetor de parâmetros

Exemplos.
$$\begin{cases} y_t = \mu_t + \tilde{\gamma}' x_t + \varepsilon_t \\ \mu_{t+1} = \mu_t + \beta_t + \eta_t \\ \beta_{t+1} = \beta_t + \zeta_t \end{cases}$$

Há duas formas de introduzir variáveis explicativas em modelos estruturais:

1). Enxere o modelo na forma

$$y_t = z_t' x_t + c_t + \varepsilon_t \quad \text{onde } c_t = \tilde{\gamma}' x_t \Rightarrow \text{enxere variável explicativa como cte. somada ao modelo.}$$

onde $\tilde{\gamma}$: parâmetros fixos associados a x_t

- As inovações nas funções dos parâmetros originais $\Psi = (\sigma_\varepsilon^2, \sigma_\eta^2, \sigma_\zeta^2)$, mas tb de $\tilde{\gamma}$.

$$v_t = y_t - \hat{y}_{t|t-1} = y_t - (z_t' a_t + c_t)$$

$$\therefore v_t = v_t(\Psi, \gamma)$$

- Enxere a função de verossimilhança e maximiza em $\tilde{\gamma}$ tb.

$$l(\Psi, \gamma) \sim -\frac{1}{2} \sum \left(\ln f_t + \frac{v_t^2}{f_t} \right)$$

obs: tb é possível concentrar a verossimilhança em relação a γ e resolver o problema de otimização por MQ generalizado.

2). Incorpora γ no vetor de estado

$$y_t = \mu_t + \tilde{\gamma}' x_t + \varepsilon_t$$

- Nesse caso γ_t uma variável de estado ($\gamma: K \times 1 \rightarrow K$ components novas no vetor de estado).

$$y_t = \begin{pmatrix} 1 & 0 & \tilde{x}_t \end{pmatrix} \begin{pmatrix} \mu_t \\ \beta_t \\ \gamma_t \end{pmatrix} + \varepsilon_t$$

\downarrow
 $1 \times K$ $K \times 1$

$$\begin{pmatrix} \mu_t \\ \beta_t \\ \gamma_t \end{pmatrix} = \begin{pmatrix} 1 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & I \end{pmatrix} \begin{pmatrix} \mu_t \\ \beta_t \\ \gamma_t \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} \eta_t \\ \zeta_t \end{pmatrix}$$

obs. Consideramos aqui $\tilde{\gamma}_{t+1} = \tilde{\gamma}_t$ (mas há variações)
mas poderíamos considerar variações, por exemplo:

$$\tilde{\gamma}_{t+1} = \phi \tilde{\gamma}_t + \tilde{w}_t \Rightarrow \text{VAR}(1)$$

$\tilde{w}_t \sim N(0, Q_w)$ onde Q_w cheia
(covariâncias no deslocamento)

Mais que $\tilde{\gamma}_t$ varie, precisamos especificar como varia no tempo
sua equação de evolução, estrutura.

$$\begin{pmatrix} \gamma_{1,t+1} \\ \gamma_{2,t+1} \end{pmatrix} = \begin{pmatrix} \phi_1 & 0 \\ 0 & \phi_2 \end{pmatrix} \begin{pmatrix} \gamma_{1t} \\ \gamma_{2t} \end{pmatrix} + \begin{pmatrix} w_{1t} \\ w_{2t} \end{pmatrix}$$

- Pode-se mostrar que as estimativas de $\tilde{\gamma}$ obtidas via FK no passo de atualizações são equivalentes à mq recursivos

$$\tilde{\gamma}_t = \tilde{\gamma}_{t-1} + (\quad)$$

— " —

Atenção no uso de variáveis explicativas

- Se o objetivo inicial for extrair os componentes nas observáveis de uma série

⇒ Não devemos colocar variáveis explicativas

Elas concorrem com as componentes.

Se forem incluídas, componentes nas KAs mais a última interpretação

- Se o objetivo for previsões, a inclusão de variáveis explicativas pode melhorar o modelo.

Procedimento:

- Faz modelo de variável explicativa e roda.
- Olha resíduos
se ainda nas e' RB \Rightarrow pode incluir variável explicativa
(ainda assim significado das componentes pode mudar)

Outro exemplo de uso:

- Podemos querer separar a influência de k fatores na sazonalidade

(i) $y_t = \mu_t + \delta_t + \epsilon_t$ onde \hat{y}_t : sazonalidade total
(temperatura + feriados)

(ii) $y_t = \mu_t + \delta_t + \beta x_t + \epsilon_t$ onde x_t : temperatura
 δ_t : sazon. por conta de feriados.

(variável explicativa pode ser uma dummy)

Variáveis explicativas por Intervenções

Se no procedimento rodamos modelo e análise de resíduos apresenta problema (ex outliers)

\Rightarrow modela intervenções de variável explicativa a posteriori
(o que é atípico foi sendo identificado após rodar o modelo)


obs: i) infelizmente o que parece atípico antes de rodar o modelo pode acabar sendo absorvido por ele.

ii) análise de intervenções só pode ser feita a posteriori

\rightarrow tipos de variáveis usadas na análise de intervenções:

Dependerá a análise de resíduos na inovação padronizada.

$$v_t^* = \frac{v_t}{\sigma_v^{1/2}} \sim N(0, 1)$$



\rightarrow outlier: observações atípicas

- coloca dummy em t^* p/ melhor ajuste do modelo in-sample
- ponto atípico pode estar comprometendo modelo no que se refere a heterocedasticidade, normalidade etc.

Modelos y funciones de intervenciones


$$y_t = \mu_t + \gamma_t + \lambda w_t + \varepsilon_t$$

↓ ↓ ↓ ↓
tendência sazão férias de inverno erro

Para w_f , podemos ter:

(a) pulso


$$w_t = \begin{cases} 1 & t = t^* \\ 0 & t \neq t^* \end{cases}$$



caracteriza efeitos transitórios na série que apenas afetam em $t = t^*$

(b) escada


$$w_t = \begin{cases} 0 & t < t^* \\ 1 & t \geq t^* \end{cases}$$



caracteriza mudanças no nível da série, que representam efeitos permanentes (equivale a um pulso no nível da série)

(c) mudança de inclinação,

$$w_\tau = \begin{cases} 0 & \tau < \tau^* \\ \tau - \tau^* & \tau > \tau^* \end{cases}$$



(d) pulso decaído gradualmente

$$\omega_t = \begin{cases} 0 & t < t^* \\ \phi^{t-t^*} & t \geq t^* \end{cases}$$


onde ϕ é o fator de desconto
Quanto + perto é o valor de ϕ de 1
 \Rightarrow mais lento é o de aprendizado



$$\phi_3 > \phi_2 > \phi_1$$

(e) pulso crescendo lentamente e decaindo lentamente

$$w_t = \begin{cases} \phi_1^{t^*-t} & t \leq t^* \\ \phi_2^{t-t^*} & t > t^* \end{cases}$$



se $\phi_1 = \phi_2$: subida e descida nas mesmas.

Obs importante

Distinguir entre efeito permanente e transitório.

transiente: afeta apenas observações naquele período t .

permanente: há uma mudança de estrutura.

Análise de resíduos de inovações \Rightarrow nem sempre permite distinguir efeito permanente x transitório

\Rightarrow No ME: nos possibilita olhar resíduos no nível das variáveis de estado.

Obs: No MNL, efeito transitório em η_t é permanente em y_t

Diagnósticos

- Modelo: $y_t = z_t \alpha_t + \varepsilon_t$ $\varepsilon_t \sim N(0, \sigma_\varepsilon^2)$
 $\alpha_{t+1} = T_t \alpha_t + R_t \eta_t$ $\eta_t \sim N(0, \sigma_\eta^2)$

- Hipóteses:

i) $\left\{ \begin{array}{l} \text{linearidade das componentes} \\ \text{aditividade} \end{array} \right.$

ii) ε_t : Normal

Homocedástico

Descorrelatado: $E[\varepsilon_t, \varepsilon_{t-2}] = 0 \quad \forall t \neq 0$

- Método de ajuste: R^2 , MAPE, RMSE etc.
(adequação)

→ Para verificar linearidade:

Queremos: $y_t = \mu_t + \delta_t + \varepsilon_t$

se modelo for $y_t = \mu_t + \delta_t + \varepsilon_t \Rightarrow$ isso pode ser verificado visualmente
(razonabilidade vai aumentando tb. em amplitude)
se não identificar visualmente
 \Rightarrow olha resíduos

→ Para verificar ε_t :

$$\varepsilon_t = y_t - z_t \alpha_t$$

mas ε_t não é observado

$$\Rightarrow \hat{\varepsilon}_t = y_t - z_t \hat{\alpha}_{t|t-1} = v_t$$

\therefore Inovação v_t é estimativa de ε_t

Sabemos que $\left\{ \begin{array}{l} E[v_t] = 0 \\ E[v_t^2] = F_t \end{array} \right.$


\Rightarrow Inovação padronizada: $\tilde{v}_t = \frac{\hat{v}_t}{\hat{F}_t^{1/2}} \sim N(0, 1)$ \nearrow tb. divergir
for substituído
o teste.

obs: um dos diagnósticos é testar $\text{Var}(\tilde{v}) \approx 1$

• Normalidade:

a) histograma

b) Q-Q plot



dispersão dos pontos em reta 45° com alguma variabilidade estatística

c) Testes estatísticos:

• Jarque-Bera (simetria e curtose)

$$JB = \frac{n}{6} (\hat{S} - 0)^2 + \frac{n}{24} (\hat{K} - 3)^2 \sim \chi^2(2)$$

• A Darling (relação entre densidade empírica e sob H_0 (teórica))


$$AD = \int \frac{(F_n - F_0)^2}{F_0(1 - F_0)} dF$$

\Rightarrow Tem mais poder do que JB.

• Homocedasticidade: (variância do erro etc.)

O que pode ser feito?

a) Se modelo multiplicativo e ajustarmos modelo aditivo, teremos pl resíduos



: amplitude da inovação vai aumentando no tempo.

Teste no Stamp:

• Toma parte da amostra no início (I) e no final (II)

• Calcula estimativa $\hat{\sigma}_I^2$ e $\hat{\sigma}_{II}^2$

$$H(h) = \frac{\hat{\sigma}_{(II)}^2 / \sigma^2}{\hat{\sigma}_{(I)}^2 / \sigma^2} \sim F(h, h) \quad \text{onde } h \text{ é o tamanho da amostra em (I) e (II)}$$

$$H_0: \sigma_F^2 = \sigma_I^2$$

$$H_1: \sigma_F^2 \neq \sigma_I^2$$

A estatística de teste $H(h)$ pode ser escrita como:

$$H(h) = \frac{\sum_{t=T-h+1}^T v_t^2}{\sum_{t=d+1}^{d+h} v_t^2} \quad \text{onde } d \text{ é o n.º de variáveis nas estacionárias}$$


$$h = \left(\frac{T-d}{3} \right) \Rightarrow \text{tamanho de cada amostra tirando o meio da série}$$

Resultados: Se rejeitar H_0 , indica que $\text{var}(\Pi) > \text{var}(I)$

Solução: Trabalha com log.

b) Pode ser que comportamento da heteroscedasticidade seja outro.

Ex: Retorno de ações



\Rightarrow Então que fazer teste ARCH

$$v_t^2 = \beta_0 + \beta_1 v_{t-1}^2 + \dots + \beta_n v_{t-n}^2$$

$$H_0: \beta_1 = \beta_2 = \dots = 0.$$

$$LM = nR^2 \sim \chi^2(n)$$

Nesse caso, mesmo rejeitando H_0 , log não funciona.

• Des correlações

De forma mais geral, devemos olhar a dependência serial

Para avaliar dependência linear:

i) FAC: medidos, nas teóricas.

ii) Ljung-Box

$$a) H_0: \rho(1) = \rho(2) = \dots = \rho(m) = 0$$

H_a : caso contrário

$$Q(m) = T(T-2) + \sum_{j=1}^m \frac{\hat{\lambda}_j^2}{(T-j)} \sim \chi^2(d)$$

onde $d = m - n + 1$ \sim n.º de parâmetros estimados.

pf série trimestral: $n = 8$
mensal: $n = 12$ } H para sazonalidade 12.

e $\hat{\lambda}_j$: autocorrelações das inovações

b) Para saber se há tb. efeito ARCH, outra possibilidade é trabalhar q estatística Ljung-Box p/ v_t^2

$$\text{Teste q p/ } v_t^2 \Rightarrow v_t^2 = \alpha + \beta v_{t-1}^2 + \epsilon_t$$
$$\text{com } (v_t^2, v_{t-1}^2) \neq 0.$$



aula 08/06 (e final de oitoo)

Resíduos Auxiliares como Ferramenta de Diagnósticos

• Inovações: $v_t = \hat{\varepsilon}_t | t-1 = \hat{\eta}_t | t-1$

• Resíduos Auxiliares:

construir 2 tipos de resíduos, além da inovação
Específicos de ME, a partir do algoritmo de suavizações
calculados a cada instante t .

$$\hat{\varepsilon}_t = E[\varepsilon_t | y] \quad : \text{valor esperado suavizado de } \varepsilon_t$$

$$\hat{\eta}_t = E[\eta_t | y] \quad : \text{valor " " de } \eta_t \quad (\text{choque em } \mu_t)$$

obs: Nas oitaa choques das componentes β_t ou δ_t .

Em princípio, poderias até definir, mas é pouco usado.
mudança de nível está comumente associada a μ_t .

Usando algoritmo de suavizações:

para $\hat{\varepsilon}_t$ $\rightarrow \boxed{\hat{\varepsilon}_t = H_t \mu_t} \quad , t = n, n-1, \dots, 1$
onde $\mu_t = F_t' v_t - K_t' n_t$ (n_t da suavizações)
 $H_t = E[\varepsilon_t \varepsilon_t'] \quad (= \sigma_\varepsilon^2 \text{ no caso univariados})$

$$\boxed{\text{Var}[\varepsilon_t | y] = H_t - H_t D_t' H_t}$$

onde $D_t' = F_t' + K_t' + N_t K_t$ (N_t da suavizações)

para $\hat{\eta}_t$ $\rightarrow \boxed{\hat{\eta}_t = Q_t R_t' n_t}$
 $\boxed{\text{Var}[\hat{\eta}_t | y] = Q_t - Q_t R_t' N_t R_t' Q_t}$

\Rightarrow Estimativas suavizadas dos erros:

(1) sas intra-correlacionadas

(2) sas inter-correlacionadas

Portanto, elas compartilham características dos resíduos de
inovações. Isso porque as suavizadas, tem conjunto de informa-
ções em comum nos seus cálculos. Isso nos trará problema no

Notação

$$y = y_n = y_T \\ = (y_1, y_2, \dots, y_T = n)$$

Mostar?

diagnósticos pois são permanentes (nas usadas em testes estatísticos)

Estratégia:

usar $\hat{\eta}_t$ e $\hat{\epsilon}_t$ para distinguir entre choques transitórios e choques permanentes em y_t de forma a melhor caracterizar as análises de intervenções.

(Ajuste posterior, depois de observar comportamento do modelo)
choque: detecção de padrão anormal em resíduos (obs. atípica).

Exemplo: Super MNL

$$y_t = \mu_t + \epsilon_t$$
$$\mu_t = \mu_{t-1} + \eta_t \Rightarrow \mu_t = \mu_1 + \sum_{i=1}^t \eta_i$$

Ha' 2 tipos de choques:

(a) Em ϵ_t : transitório

Afetará apenas y_t em t
outlier tratado via funções pulso

$$D_t = \begin{cases} 1 & t = t^* \\ 0 & t \neq t^* \end{cases} \Rightarrow y_t = \mu_t + \delta D_t + \epsilon_t$$

(b) Em η_t : dada recursividade em μ_t , em virtude de sua natureza markoviana e raiz unitária, um choque em η_j , $1 \leq j \leq t$ será incorporado a μ_t de forma permanente e, assim, afeta y_t também de forma permanente.

obs: Nas é permanente eterno.

pode ir se compensando com η_t subsequentes.
Dependendo do nível do choque, pode ir sendo carregado.

Como fazer na prática?

Roda programas, calculando $\hat{\epsilon}_t$ e $\hat{\eta}_t$

Detectar períodos onde $\hat{\epsilon}_t \geq K \sigma_{\hat{\epsilon}_t}$ e $\hat{\eta}_t \geq K \sigma_{\hat{\eta}_t}$

- Se detectar em $\hat{E}_t \Rightarrow$ coloca funções pulso e stima parâmetro δ .
É uma "ajuda" externa ao modelo, melhora estatísticas in-sample.
- Se detectar em $\hat{\eta}_t \Rightarrow$ trata funções pulso em μ_t ou seada em y_t

Supondo que em $t = t^*$ há um choque em η_t

Portanto, η_{t^*} é grande $= k \sigma_\eta$, $k = 2, 2.5, 3, \dots$
(Normalmente fazemos $k > 2$)

Para $t \geq t^*$, μ_t conterá este choque:

$$y_t = \mu_t + \eta_t^* + \eta_{t-1} + \dots + \eta_1, \quad t = t^*$$

$$y_t = \mu_t + \eta_t + \eta_{t^*} + \dots + \eta_1, \quad t > t^*$$

\Rightarrow Para $t \geq t^*$: y_t mudará de nível de forma permanente

Ao detectarmos "outlier" em $\hat{\eta}_t$, podemos tratá-lo como:

(i) via funções pulso em μ_t

(ii) via funções seada em $\begin{cases} 1 & t \geq t^* \\ 0 & t < t^* \end{cases}$ em y_t

(i)

$$y_t = \mu_t + \epsilon_t$$

$$\mu_t = \mu_{t-1} + \delta D_t + \eta_t$$

$$D_t = \begin{cases} 1 & t = t^* \\ 0 & t \neq t^* \end{cases}$$

(ii)

$$y_t = \mu_t + \delta E_t + \epsilon_t$$

$$\mu_t = \mu_{t-1} + \eta_t$$

$$E_t = \begin{cases} 1 & t \geq t^* \\ 0 & t < t^* \end{cases}$$



(cont. aula 08/06)

Modelos Estruturais Multivariados

- Generalizações de modelos estruturais univariados.
- Mais complexos em relação à estimação (FK e MV), identificações paramétrica, interpretações e diagnósticos.

→ Modelos univariados:

$$y_{it} = \mu_{it} + \gamma_{it} + \varepsilon_{it}$$

diagnósticos sobre resíduos:

$$\text{inovação padronizada} \Rightarrow \frac{v_{it}}{F_{it}^{1/2}} = \frac{y_{it} - \tilde{y}_{it|t-1}}{F_{it}^{1/2}}$$

testes JB, Ljung Box etc.

→ Modelos multivariados:

$$y_t = \begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \tilde{\mu}_t + \tilde{\gamma}_t + \tilde{\varepsilon}_t$$

$$\text{inovação padronizada: } v_t = \begin{pmatrix} v_{1t} \\ v_{2t} \end{pmatrix} \sim N(0, \tilde{F}_t)$$

diagnósticos precisam ser bi, tri, multivariados
(cada marginal não é univariada, mas teste univariados
nas suas componentes)

- Motivações p/ modelos multivariados

flexibilidade: estimar componentes comuns entre ST's
melhora inferência / previsões / simulações

$$z_t = f(y_{1t}, y_{2t}) \Rightarrow \text{resultado / variável } z_t \text{ é variável comum de 2 fatores de risco.}$$

Se tratar y_{1t} e y_{2t} de forma separada, perde possibilidade de ter influências diretas entre as duas.

1) Modelo FUTSE (flexibly unrelated TS equations)

$$y_t = \mu_t + \varepsilon_t \quad , \quad \varepsilon_t \sim N(0, \Sigma_\varepsilon) \quad \xrightarrow{p \times p}$$

$$\mu_{t+1} = \mu_t + \eta_t \quad , \quad \eta_t \sim N(0, \Sigma_\eta) \quad \xrightarrow{p \times p}$$

obs: N° de parâmetros é grande quando n aumenta
(matrizes Σ tem var/covar)

ex: se $p=2 \Rightarrow$ 3 par de Σ_ε
3 par de Σ_η

se $p=5 \Rightarrow$ 15 par de Σ_ε
15 par de Σ_η

$$n^\circ \text{ par} = n + \begin{pmatrix} n \\ 2 \end{pmatrix}$$

↓ ↓
var covar

Exemplo: $p=2$

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

$$\varepsilon_t \sim N \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} \sigma_{\varepsilon_1}^2 & \sigma_{\varepsilon_1 \varepsilon_2} \\ \sigma_{\varepsilon_1 \varepsilon_2} & \sigma_{\varepsilon_2}^2 \end{pmatrix} \right)$$

$$\eta_t \sim N \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} \sigma_{\eta_1}^2 & \sigma_{\eta_1 \eta_2} \\ \sigma_{\eta_1 \eta_2} & \sigma_{\eta_2}^2 \end{pmatrix} \right)$$

$$\begin{pmatrix} \mu_{1,t+1} \\ \mu_{2,t+1} \end{pmatrix} = \begin{pmatrix} \mu_{1,t} \\ \mu_{2,t} \end{pmatrix} + \begin{pmatrix} \eta_{1,t} \\ \eta_{2,t} \end{pmatrix}$$

y_{1t} só depende de μ_{1t}

y_{2t} " " de μ_{2t}

No FUSE: v.a's não se comunicam explicitamente.
A comunicação vem das covariâncias

No caso $2 \times 2 \Rightarrow$ 6 parâmetros

FUSE é de difícil estimação.

Objetivo: montar modelo FUSE mais simples, com menos parâmetros

↓
No modelo geral, cada y só depende de sua componente e de seu erro.

A dependência vem da estrutura de matrizes var/covar

¶ diminuir o n° de parâmetros, colocamos restrições.

Definições: Modelo Homogêneo

= Processo estocástico de 2ª ordem, p-variado, e' dito homogêneo se todas as combinações lineares de suas componentes possuem as mesmas propriedades de 2ª ordem.

$y_t = (y_{1t}, y_{2t}, \dots, y_{pt})$ é homogêneo se

$\forall \alpha \in \mathbb{R}^p$, processo univariado $z_t = \nabla^d (\alpha' y_t)$ possui FAC independente de α . se y nas por estacionário

(Como eles independem de $\alpha \Rightarrow$ FAC tb não depende).

$$\begin{aligned} \text{Ex: } z_t &= 1y_{1t} + 2y_{2t} \\ &= 0,5y_{1t} + 0,7y_{2t} \end{aligned} \quad \left. \vphantom{\begin{aligned} z_t &= 1y_{1t} + 2y_{2t} \\ &= 0,5y_{1t} + 0,7y_{2t} \end{aligned}} \right\} \text{ possuem a mesma FAC.}$$

Proposição 1: Se y_t segue um SUTIE de nível local, então y_t será homogêneo se e só se:

$$\Sigma \eta = q \Sigma \varepsilon, \quad q \in \mathbb{R}^+$$

obs: Para $p=5$

SUTIE Geral: $\Psi = 30 \text{ par.}$

SUTIE Homogêneo: $\Psi = 15 + 1 \text{ par.}$

Mostrar:

$$\begin{cases} y_{it} = \mu_{it} + \varepsilon_{it} \\ \mu_{it} = \mu_{it-1} + \eta_{it} \end{cases} \Rightarrow \Delta y_{it} = \eta_{it-1} + \Delta \varepsilon_{it}$$

$$E[\Delta y_{it}] = 0$$

$$E[\Delta y_{it}^2] = \sigma_{\eta_i}^2 + 2\sigma_{\varepsilon_i}^2$$

$$E[\Delta y_{it}, \Delta y_{it-1}] = -\sigma_{\varepsilon_i}^2$$

$$\Rightarrow \rho_{\Delta y_i}(1) = \frac{-\sigma_{\varepsilon_i}^2}{\sigma_{\eta_i}^2 + 2\sigma_{\varepsilon_i}^2}$$

$$\rho_{\Delta y_i} = \frac{-\sigma_{\varepsilon_i}^2}{q\sigma_{\varepsilon_i}^2 + 2\sigma_{\varepsilon_i}^2} = -\frac{1}{q+2} \Rightarrow \text{independe de } i$$

?

duvida: não entra aqui termo de correlação?
 $\sigma_{\eta_1, \eta_2} \quad \sigma_{\varepsilon_1, \varepsilon_2}$

$$z_t = D(\alpha_1 y_{1t} + \alpha_2 y_{2t})$$

$$= \alpha_1 D y_{1t} + \alpha_2 D y_{2t}$$

$$= \alpha_1 (\eta_{1t} + \varepsilon_{1t}) + \alpha_2 (\eta_{2t} + \varepsilon_{2t})$$

$$= \alpha_1 (\eta_{1t} + \varepsilon_{1t} - \varepsilon_{1,t-1}) + \alpha_2 (\eta_{2t} + \varepsilon_{2t} - \varepsilon_{2,t-1})$$

$$\gamma_0 = \alpha_1^2 \sigma_{\eta_1}^2 + 2\alpha_1^2 \sigma_{\varepsilon_1}^2 + \alpha_2^2 \sigma_{\eta_2}^2 + 2\alpha_2^2 \sigma_{\varepsilon_2}^2 + \alpha_1 \alpha_2 \sigma_{\eta_1 \eta_2} + 2\alpha_1 \alpha_2 \sigma_{\varepsilon_1 \varepsilon_2}$$

$$\gamma_1 = E \left[\left(\alpha_1 (\eta_{1,t-1} + \varepsilon_{1,t-1} - \varepsilon_{1,t-2}) + \alpha_2 (\eta_{2,t-1} + \varepsilon_{2,t-1} - \varepsilon_{2,t-2}) \right) \begin{pmatrix} \dots \\ t \end{pmatrix} \right]$$

$$= -\alpha_1^2 \sigma_{\varepsilon_1}^2 - \alpha_2^2 \sigma_{\eta_1}^2 + 2\alpha_1 \alpha_2 \sigma_{\varepsilon_1 \varepsilon_2} + \alpha_1 \alpha_2 \sigma_{\eta_1 \eta_2}$$

=

Prova ida: & SUTSE homogêneo $\Rightarrow \tilde{\Sigma} \eta = \rho \tilde{\Sigma} \varepsilon$

Para ci de y_{1t} e $y_{2t} \Rightarrow z_t = D(\alpha'y)$, achamos:

$$\gamma(0) = \alpha_1^2 \sigma_{\eta_1}^2 + \alpha_2^2 \sigma_{\eta_2}^2 + 2\alpha_1 \alpha_2 \sigma_{\eta_1 \eta_2} + 2\alpha_1^2 \sigma_{\varepsilon_{1t}}^2 + 2\alpha_2^2 \sigma_{\varepsilon_{2t}}^2 + 4\alpha_1 \alpha_2 \sigma_{\varepsilon_1 \varepsilon_2}$$

$$= \alpha_1^2 (\sigma_{\eta_1}^2 + 2\sigma_{\varepsilon_{1t}}^2) + \alpha_2^2 (\sigma_{\eta_2}^2 + 2\sigma_{\varepsilon_{2t}}^2) + 2\alpha_1 \alpha_2 (\sigma_{\eta_1 \eta_2} + 2\sigma_{\varepsilon_1 \varepsilon_2})$$

$$\gamma(1) = -\alpha_1^2 \sigma_{\varepsilon_1}^2 - \alpha_1 \alpha_2 \sigma_{\varepsilon_1 \varepsilon_2} - \alpha_1 \alpha_2 \sigma_{\varepsilon_1 \varepsilon_2} - \alpha_2^2 \sigma_{\varepsilon_2}^2$$

$$= \alpha_1^2 (-\sigma_{\varepsilon_1}^2) + \alpha_2^2 (-\sigma_{\varepsilon_2}^2) + 2\alpha_1 \alpha_2 (-\sigma_{\varepsilon_1 \varepsilon_2})$$

Prova volta: Se $\sum_{t=1}^q \tilde{z}_t \tilde{z}_t' = I$ então \tilde{z}_t é homogêneo

11. p = 2

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

$$\begin{pmatrix} \mu_{1,t+1} \\ \mu_{2,t+1} \end{pmatrix} = \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} + \begin{pmatrix} \eta_{1t} \\ \eta_{2t} \end{pmatrix}$$

Seja $\tilde{z}_t = \begin{pmatrix} \alpha_1 \\ \alpha_2 \end{pmatrix} \Rightarrow z_t = \Delta(\tilde{z}_t' y) = \Delta(\alpha_1 y_{1t} + \alpha_2 y_{2t})$
 $= \alpha_1 \Delta y_{1t} + \alpha_2 \Delta y_{2t}$

Mas $\Delta y_{1t} = \Delta \mu_{1t} + \Delta \varepsilon_{1t} = \eta_{1t} + \Delta \varepsilon_{1t}$

$\Delta y_{2t} = \Delta \mu_{2t} + \Delta \varepsilon_{2t} = \eta_{2t} + \Delta \varepsilon_{2t}$

$\Rightarrow z_t = \alpha_1 (\eta_{1t} + \Delta \varepsilon_{1t}) + \alpha_2 (\eta_{2t} + \Delta \varepsilon_{2t}) = \alpha_1 \eta_{1t} + \alpha_2 \eta_{2t} + \alpha_1 \varepsilon_{1t} - \alpha_1 \varepsilon_{1,t-1} + \alpha_2 \varepsilon_{2t} - \alpha_2 \varepsilon_{2,t-1}$

$\gamma(0) = E[z_t^2] = \alpha_1^2 \sigma_{\eta_1}^2 + \alpha_2^2 \sigma_{\eta_2}^2 + 2\alpha_1 \alpha_2 \sigma_{\eta_1 \eta_2} + 2\alpha_1^2 \sigma_{\varepsilon_1}^2 + 2\alpha_2^2 \sigma_{\varepsilon_2}^2 + 4\alpha_1 \alpha_2 \sigma_{\varepsilon_1 \varepsilon_2}$
 $= \alpha_1^2 \sigma_{\varepsilon_1}^2 (q+2) + \alpha_2^2 \sigma_{\varepsilon_2}^2 (q+2) + \alpha_1 \alpha_2 \sigma_{\varepsilon_1 \varepsilon_2} (q+2)$
 $= (q+2) [\alpha_1^2 \sigma_{\varepsilon_1}^2 + \alpha_2^2 \sigma_{\varepsilon_2}^2 + 2\alpha_1 \alpha_2 \sigma_{\varepsilon_1 \varepsilon_2}]$

$\gamma(1) = E[(\alpha_1 \eta_{1t} + \alpha_1 \varepsilon_{1t} - \alpha_1 \varepsilon_{1,t-1} + \alpha_2 \eta_{2t} + \alpha_2 \varepsilon_{2t} - \alpha_2 \varepsilon_{2,t-1})$
 $(\alpha_1 \eta_{1,t-1} + \alpha_1 \varepsilon_{1,t-1} - \alpha_1 \varepsilon_{1,t-2} + \alpha_2 \eta_{2,t-1} + \alpha_2 \varepsilon_{2,t-1} - \alpha_2 \varepsilon_{2,t-2})]$

$= -\alpha_1^2 \sigma_{\varepsilon_1}^2 - \alpha_1 \alpha_2 \sigma_{\varepsilon_1 \varepsilon_2} - \alpha_1 \alpha_2 \sigma_{\varepsilon_1 \varepsilon_2} - \alpha_2^2 \sigma_{\varepsilon_2}^2 =$

$= -\alpha_1^2 \sigma_{\varepsilon_1}^2 - 2\alpha_1 \alpha_2 \sigma_{\varepsilon_1 \varepsilon_2} - \alpha_2^2 \sigma_{\varepsilon_2}^2$

$\Rightarrow \rho_1 = \frac{\gamma(1)}{\gamma(0)} = -\frac{1}{q+2}$

— " —

Se ρ_1 independe de $\alpha \Rightarrow \rho_1 = f(\sigma_{\varepsilon_1}^2, \sigma_{\eta_1}^2)$

Se FAC da CL independe dos parâmetros, $\sum \eta = q \sum \varepsilon$

Assim $\gamma(0) = \gamma(1)$
 por independência

Proposição 2: Se y_t segue um SUTSE com j tipos de componentes ortogonais (ex: $\mu_t, \varepsilon_t, \psi_t, \dots$), então y_t será homogêneo SSR;

$$\Sigma_{\eta} = \begin{pmatrix} \Sigma_{\eta_1} & & 0 \\ & \Sigma_{\eta_2} & \\ 0 & & \ddots \\ & & & \Sigma_{\eta_j} \end{pmatrix} = \begin{pmatrix} q \Sigma_{\varepsilon_1} & & 0 \\ & q \Sigma_{\varepsilon_2} & \\ 0 & & \ddots \\ & & & q \Sigma_{\varepsilon_j} \end{pmatrix}$$

\leftarrow cada uma é que é um bloco.

Σ_{ε}

onde $\Sigma_{\varepsilon} = h \Sigma_{\varepsilon^*}$? divide

mas é vai de L a p

(como processos de cada componente são ortogonais, só há comunicações)

Propriedades Empíricas de PH's

- (i) Pode haver teorias "a priori" que justifiquem a adoção de estrutura de proporções entre as covariâncias
- (ii) As recursões de Kalman podem ser implementadas para cada uma das p -equações separadamente
- (iii) Há menos risco de não identificação paramétrica pela baixa dimensão de Ψ
 - ↳ Processo homogêneo é sempre identificável
- (iv) Estimadas por ML é mais simples.

MNL SUTSE HOMOGÊNEO

$$\begin{cases} y_t = \mu_t + \varepsilon_t & \varepsilon_t \sim N(0, \Sigma_{\varepsilon}) \\ \mu_{t+1} = \mu_t + \eta_t & \eta_t \sim N(0, \Sigma_{\eta}) \end{cases}$$

$$\Sigma_{\eta} = q \Sigma_{\varepsilon}$$

Para $p=2$

$$\begin{pmatrix} \sigma_{\eta_1}^2 & \sigma_{\eta_1 \eta_2} \\ \sigma_{\eta_1 \eta_2} & \sigma_{\eta_2}^2 \end{pmatrix} = q \begin{pmatrix} \sigma_{\varepsilon_1}^2 & \sigma_{\varepsilon_1 \varepsilon_2} \\ \sigma_{\varepsilon_1 \varepsilon_2} & \sigma_{\varepsilon_2}^2 \end{pmatrix}$$

$$\begin{cases} y_{it} = \mu_{it} + \varepsilon_{it} \\ \mu_{it+1} = \mu_{it} + \eta_{it} \end{cases}$$

$$\Rightarrow \Delta y_{it} = \eta_{it} + \Delta \varepsilon_{it}$$

$$E[\Delta y_{it}] = 0$$

$$E[\Delta y_{it}^2] = \sigma_{\eta_i}^2 + 2\sigma_{\varepsilon_i}^2$$

$$\begin{aligned} E[\Delta y_{it}, \Delta y_{it-1}] &= E[(\eta_{it} + \varepsilon_{it} - \varepsilon_{it-1})(\eta_{it-1} + \varepsilon_{it-1} - \varepsilon_{it-2})] \\ &= -\sigma_{\varepsilon_i}^2 \end{aligned}$$

$$\text{Por homogeneidade} \Rightarrow \sigma_{\eta_i}^2 = q \sigma_{\varepsilon_i}^2$$

$$\Rightarrow \rho(1) = \frac{-\sigma_{\varepsilon_i}^2}{\sigma_{\varepsilon_i}^2 (q+2)} = -\frac{1}{q+2} \Rightarrow \text{independe de } i$$

Logo: qualquer α de $y_{it} \Rightarrow$ independência de α_1, α_2
FAC.

• Conclusões:

Na forma reduzida do SUTSE homogêneo, as séries possuem a mesma dinâmica.

\Rightarrow Modelo bem restritivo

• Estimativas

Vetor de parâmetros

$$\Psi = (\sigma_{\varepsilon_1}^2, \sigma_{\varepsilon_2}^2, \sigma_{\varepsilon_1 \varepsilon_2}, q)$$

$$\text{Informações: } \underline{y}_{t-1} = (\underline{y}_{1,t-1}, \underline{y}_{2,t-1})$$

Dúvida
No modelo homogêneo,
as séries sempre
co-integradas?

como relacionar?

$$l(\psi) = \log L(\psi) = \sum_{t=1}^n \log p(y_{1t}, y_{2t} | \underline{y}_{t-1})$$

→ densidade conjunta bivariada

$$\rightarrow p(\underline{y}_t | \underline{y}_{t-1}) = ? \quad \text{Normal bivariada}$$

$$y_t = \underline{z}\alpha_t + \varepsilon_t$$

$$E[y_t | \underline{y}_{t-1}] = \underline{z} E[\alpha_t | \underline{y}_{t-1}] = \underline{z} a_t$$

$$\text{var}[y_t | \underline{y}_{t-1}] = \text{var}[\underline{z}\alpha_t + \varepsilon_t | \underline{y}_{t-1}] = \underline{z} P_t \underline{z}' + H_t = F_t$$

$$p(\underline{y}_t | \underline{y}_{t-1}) = \frac{1}{(2\pi)^{p/2} |F_t|^{1/2}} \exp \left\{ -\frac{1}{2} \underbrace{(\underline{y}_t - \underline{z}a_t)}_{\underline{v}_t}' \underbrace{F_t^{-1}}_{\underline{v}_t} (\underline{y}_t - \underline{z}a_t) \right\}$$

onde $p = 2$

$$\therefore l(\psi) = \sum_{t=1}^n \log \left[\frac{1}{(2\pi)^{p/2} |F_t|^{1/2}} \exp \left\{ -\frac{1}{2} \underline{v}_t' F_t^{-1} \underline{v}_t \right\} \right]$$

• Tratando com inicializações exata

$$l(\psi) = -n \log 2\pi - \underbrace{\frac{1}{2} \sum_{t=1}^n w_t}_{\text{Nas 2as afetados pela inicializações exata}} - \underbrace{\frac{1}{2} \sum_{t=d+1}^n \log |F_t| - \frac{1}{2} \sum_{t=d+1}^n \underline{v}_t' F_t^{-1} \underline{v}_t}_{\text{Nas 2as afetados pela inicializações exata}}$$

$$w_t = \begin{cases} \log |F_{0,t}| & \text{se } F_{0,t} \text{ e' pd} \\ \log |F_{*,t}| + \underline{v}_t^{(0)'} F_{*,t}^{-1} \underline{v}_t^{(0)}, & F_{0,t} = 0 \end{cases}$$

álvida

Neste caso
FUT & MNL

⇒ quantas
componentes
π stocásticos?
apenas 1 μ fixado y
ou considera p?

• tratando com inicializações difusa por big kappa

Nas haverá na função de veross. o termo de $\sum w_t$.

Calcularemos a função a partir de $t=1$

len

$$e^{(n-1) \log 2\pi}$$

→ Generalizações da Estrutura FOTSE

- Incorporar outros componentes: tend. linear estocástica, sazonalidade, ciclo etc.
- Super ortogonalidade entre componentes de \neq interpretações
- Exemplo: modelo cf nível e ciclo e $p=2$

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} + \begin{pmatrix} \psi_{1t} \\ \psi_{2t} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} \quad \text{onde } \varepsilon_t \sim N(0, \underline{\Sigma}_\varepsilon)$$

↓
3 parâmetros

$$\begin{pmatrix} \mu_{1,t+1} \\ \mu_{2,t+1} \end{pmatrix} = \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} + \begin{pmatrix} \beta_{1t} \\ \beta_{2t} \end{pmatrix} + \begin{pmatrix} \eta_{1t} \\ \eta_{2t} \end{pmatrix} \quad \text{onde } \eta_t \sim N(0, \underline{\Sigma}_\eta)$$

↓
3 parâmetros

$$\begin{pmatrix} \beta_{1,t+1} \\ \beta_{2,t+1} \end{pmatrix} = \begin{pmatrix} \beta_{1t} \\ \beta_{2t} \end{pmatrix} + \begin{pmatrix} \zeta_{1t} \\ \zeta_{2t} \end{pmatrix} \quad \text{onde } \zeta_t \sim N(0, \underline{\Sigma}_\zeta)$$

↓
3 parâmetros

$$\begin{pmatrix} \psi_{1,t+1} \\ \psi_{2,t+1} \\ \psi_{1,t+1}^* \\ \psi_{2,t+1}^* \end{pmatrix} = \begin{bmatrix} \rho \begin{bmatrix} \cos \lambda_c & \sin \lambda_c \\ -\sin \lambda_c & \cos \lambda_c \end{bmatrix} \otimes I_2 \end{bmatrix} \begin{pmatrix} \psi_{1t} \\ \psi_{2t} \\ \psi_{1t}^* \\ \psi_{2t}^* \end{pmatrix} + \begin{pmatrix} \kappa_{1t} \\ \kappa_{2t} \\ \kappa_{1t}^* \\ \kappa_{2t}^* \end{pmatrix}$$

$$\Downarrow$$

$$\begin{bmatrix} \rho \begin{bmatrix} & \\ & \end{bmatrix} & 0 \\ 0 & \rho \begin{bmatrix} & \\ & \end{bmatrix} \end{bmatrix}_{4 \times 4} \quad \text{onde } \kappa_t \sim N(0, \underline{\Sigma}_\kappa)$$

↓
3 parâmetros
(pois $\sigma_{\kappa_1}^2 = \sigma_{\kappa_1^*}^2$)

$$\lambda_c = \frac{2\pi}{T_c} \Rightarrow \text{a mesma } \forall \psi_1 \text{ e } \psi_2$$

$$0 < \rho < 1$$

Escrevendo o modelo acima na forma EE:

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \underbrace{\begin{pmatrix} 1 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 1 & 0 & 0 \end{pmatrix}}_{Z_{(2 \times 8)}} \underbrace{\begin{pmatrix} \mu_{1t} \\ \mu_{2t} \\ \beta_{1t} \\ \beta_{2t} \\ \psi_{1t} \\ \psi_{2t} \\ \psi_{1t}^* \\ \psi_{2t}^* \end{pmatrix}}_{(8 \times 1)} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

$$\begin{pmatrix} \mu_{1,t+1} \\ \mu_{2,t+1} \\ \beta_{1,t+1} \\ \beta_{2,t+1} \\ \psi_{1,t+1} \\ \psi_{2,t+1} \\ \psi_{1,t+1}^* \\ \psi_{2,t+1}^* \end{pmatrix} = \begin{pmatrix} 1 & 0 & 1 & 0 & & & & \\ 0 & 1 & 0 & 1 & & & & \\ 0 & 0 & 1 & 0 & & & & \\ 0 & 0 & 0 & 1 & & & & \\ & & & & 0 & & & \\ & & & & \sim & & & \\ & & & & & a & 0 & b & 0 \\ & & & & & 0 & a & 0 & b \\ & & 0 & & & c & 0 & a & 0 \\ & & & & & 0 & c & 0 & a \end{pmatrix} \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \\ \beta_{1t} \\ \beta_{2t} \\ \psi_{1t} \\ \psi_{2t} \\ \psi_{1t}^* \\ \psi_{2t}^* \end{pmatrix} + I_8 \begin{pmatrix} \eta_{1t} \\ \eta_{2t} \\ \zeta_{1t} \\ \zeta_{2t} \\ \kappa_{1t} \\ \kappa_{2t} \\ \kappa_{1t}^* \\ \kappa_{2t}^* \end{pmatrix}$$

$$\begin{aligned} a &= p \cos \lambda_c \\ b &= p \sin \lambda_c \\ c &= -p \sin \lambda_c \end{aligned} \quad \left. \begin{aligned} & \\ & \end{aligned} \right\} c = -b$$

As matrizes do sistema univariado equivalentes são:

$$Z = \begin{pmatrix} 1 & 0 & 1 & 0 \end{pmatrix}$$

$$T = \begin{pmatrix} 1 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & a & b \\ 0 & 0 & c & a \end{pmatrix}$$

$$R = I_4$$

Desta forma, temos que:

$$\begin{aligned} \cdot Z_0 \otimes I_2 &= \begin{pmatrix} 1 & 0 & 1 & 0 \end{pmatrix} \otimes \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 1 & 0 & 0 \end{pmatrix} \\ &\quad \downarrow \\ &\quad \text{dimensões} \\ &\quad \text{de } p \end{aligned}$$

"
Z do multivariado

$$\cdot T_0 \otimes I_2 = \begin{pmatrix} 1 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & a & b \\ 0 & 0 & c & a \end{pmatrix} \otimes \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

$$= \begin{pmatrix} 1 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & a & a & b & 0 \\ 0 & 0 & 0 & 0 & 0 & a & 0 & b \\ 0 & 0 & c & 0 & a & 0 & 0 & 0 \\ 0 & 0 & 0 & c & 0 & a & 0 & 0 \end{pmatrix}$$

De forma geral:

$$\underline{y}_t = (\underline{z}_t \otimes \underline{I}_p) \underline{\alpha}_t + \underline{\varepsilon}_t, \quad \underline{\varepsilon}_t \sim N(0, \underline{\Sigma}_\varepsilon)$$

$$\underline{\alpha}_{t+1} = (\underline{T}_0 \otimes \underline{I}_p) \underline{\alpha}_t + (\underline{P}_0 \otimes \underline{I}_p) \underline{\eta}_t, \quad \underline{\eta}_t \sim N(0, \underline{\Sigma}_\eta)$$

↓
Pirada: matriz
é cheia entre
componentes?

ou apenas entre comp.
equivalentes das séries?

→ Fatores comuns e cointegrações

• Generalizações do VUTSE: admitir que as séries têm certas propriedades em comum.

• considerações a priori p/ decidir que componentes são candidatas a ter fatores comuns.

• Idéia p/ MNL bivariado:

$$(I) \quad \begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} \quad \underline{\varepsilon}_t \sim N(0, \underline{\Sigma}_\varepsilon)$$

$$\begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} = \begin{pmatrix} \mu_{1,t-1} \\ \mu_{2,t-1} \end{pmatrix} + \begin{pmatrix} \eta_{1t} \\ \eta_{2t} \end{pmatrix} \quad \underline{\eta}_t \sim N(0, \underline{\Sigma}_\eta)$$

$$\text{onde } \underline{\Sigma}_\eta = \begin{pmatrix} \sigma_{\eta_1}^2 & \rho_{\eta_1, \eta_2} \sigma_{\eta_1} \sigma_{\eta_2} \\ \rho_{\eta_1, \eta_2} \sigma_{\eta_1} \sigma_{\eta_2} & \sigma_{\eta_2}^2 \end{pmatrix}$$

Obs: Nenhuma componente de uma série é transferida p/ outra dependência nem do fato que matrizes são cheias.

Modelo pode ser reescrito como:

(II)

$$y_{1t} = \mu_{1t} + \varepsilon_{1t}$$

$$y_{2t} = \pi \mu_{1t} + \bar{\mu}_t + \varepsilon_{2t}$$

$$\mu_{1t} = \mu_{1,t-1} + \eta_{1t}$$

$$\bar{\mu}_t = \bar{\mu}_{t-1} + \bar{\eta}_t$$

$$\text{onde } \pi = \frac{\rho \sigma_{\eta_2}}{\sigma_{\eta_1}}$$

$$\text{var} \begin{pmatrix} \eta_{1t} \\ \bar{\eta}_t \end{pmatrix} = \begin{pmatrix} \sigma_{\eta_1}^2 & 0 \\ 0 & (1-\rho^2) \sigma_{\eta_2}^2 \end{pmatrix}$$

⇒ Modelo equivalente onde $\underline{\Sigma}_\eta$ é diagonal.

Sistemas (I) e (II) são equivalentes pois:

Divida

Calcule FAC

- (i) a estrutura de dependência dos y 's permanece inalterada
- (ii) a previsões dos y_t 's e a funções de verossimilhança permanecem inalteradas.

\Rightarrow Sistema (II) é nova parametrização de (I) mas preserva características importantes.

É obtido através de transformações

$$\tilde{\alpha}_t = B \alpha_t^* \quad \text{onde } \det(B) \neq 0. \Rightarrow \text{transformações nas míseras do vetor de estado}$$

Através desta nova parametrização, fica + explícita a identidades de componentes comuns.

Prova:

Da apostila

(a) Seja $\eta_{2t} = \pi \eta_{1t} + \bar{\eta}_t$ onde $\pi = \rho_{\eta} \frac{\sigma_{\eta_2}}{\sigma_{\eta_1}}$

Escreva $\pi \bar{\eta}_t$ e calcule $E[\cdot]$, $var(\cdot)$ $cov(\eta_{1t}, \bar{\eta}_t)$

(ou $\bar{\eta}_t = \eta_{2t} - \pi \eta_{1t}$)

$\Rightarrow E[\bar{\eta}_t] = E[\eta_{2t} - \pi \eta_{1t}] = 0$

$\bullet cov(\eta_{1t}, \bar{\eta}_t) = E[\eta_{1t} \bar{\eta}_t]$
 $= E[\eta_{1t} (\eta_{2t} - \pi \eta_{1t})]$
 $= E[\eta_{1t} \eta_{2t}] - \pi E[\eta_{1t}^2]$
 $= \rho_{\eta} \sigma_{\eta_1} \sigma_{\eta_2} - \left(\rho_{\eta} \frac{\sigma_{\eta_2}}{\sigma_{\eta_1}} \right) \sigma_{\eta_1}^2 = 0$

$\bullet var(\bar{\eta}_t) = var[\eta_{2t} - \pi \eta_{1t}]$
 $= var[\eta_{2t}] + \pi^2 var[\eta_{1t}] - 2\pi cov[\eta_{1t}, \eta_{2t}]$
 $= \sigma_{\eta_2}^2 + \pi^2 \sigma_{\eta_1}^2 - 2\pi \sigma_{\eta_1} \sigma_{\eta_2}$
 $= \sigma_{\eta_2}^2 + \left(\rho_{\eta}^2 \frac{\sigma_{\eta_2}^2}{\sigma_{\eta_1}^2} \right) \sigma_{\eta_1}^2 - 2 \left(\rho_{\eta} \frac{\sigma_{\eta_2}}{\sigma_{\eta_1}} \right) \sigma_{\eta_1} \sigma_{\eta_2}$
 $= \sigma_{\eta_2}^2 - \rho_{\eta}^2 \sigma_{\eta_2}^2 = \sigma_{\eta_2}^2 (1 - \rho_{\eta}^2)$

Logo:
$$\text{cov} \begin{pmatrix} \eta_{1t} \\ \bar{\eta}_t \end{pmatrix} = \begin{pmatrix} \sigma_{\eta_1}^2 & 0 \\ 0 & \sigma_{\eta_2}^2 (1 - \rho_{\eta}^2) \end{pmatrix}$$

(b) Por outro lado:

Escreva μ_{2t} e $\bar{\eta}_t$ na expressão.

$$\mu_{2t} = \mu_{2t-1} + \eta_{2t}$$

$$= \mu_{2,t-1} + \bar{\eta}_t + \pi \eta_{1t} \rightarrow \text{escreva } \eta_{1t} \text{ como expressões de } \mu_{1,t}$$

$$= \mu_{2,t-1} + \bar{\eta}_t + \pi (\mu_{1,t} - \mu_{1,t-1})$$

$$\mu_{2t} - \pi \mu_{1t} = (\mu_{2,t-1} - \pi \mu_{1,t-1}) + \bar{\eta}_t$$

(c) Escreva $\bar{\mu}_t$

$$\text{Seja } \bar{\mu}_t = \mu_{2t} - \pi \mu_{1t}$$

$$\therefore \bar{\mu}_t = \bar{\mu}_{t-1} + \bar{\eta}_t$$

(d) Escreva y_{2t} como função de μ_{1t} e $\bar{\mu}_t$

Então:

$$y_{2t} = \mu_{2t} + \varepsilon_{2t}$$

$$= \bar{\mu}_t + \pi \mu_{1t} + \varepsilon_{2t}$$

Logo, podemos escrever o modelo como:

$$\begin{cases} y_{1t} = \mu_{1t} + \varepsilon_{1t} \\ y_{2t} = \pi \mu_{1t} + \bar{\mu}_t + \varepsilon_{2t} \\ \mu_{1t} = \mu_{1,t-1} + \eta_{1t} \\ \bar{\mu}_t = \bar{\mu}_{t-1} + \bar{\eta}_t \end{cases}$$

$$\text{onde } \text{cov} \begin{pmatrix} \eta_{1t} \\ \bar{\eta}_t \end{pmatrix} = \begin{pmatrix} \sigma_{\eta_1}^2 & 0 \\ 0 & \sigma_{\eta_2}^2 (1 - \rho_{\eta}^2) \end{pmatrix}$$

Do mesmo

(a) Escreva $\bar{\eta}_t$

$$\text{Seja } \bar{\eta}_t = \eta_{2t} - \pi \eta_{1t}$$

$$\text{onde } \pi = \rho_{\eta} \frac{\sigma_{\eta_2}^2}{\sigma_{\eta_1}^2}$$

$$\therefore \eta_{2t} = \bar{\eta}_t + \pi \eta_{1t}$$

(b) Escreva μ_{2t}

$$\mu_{2t} = \mu_{2,t-1} + \eta_{2t}$$

$$= \mu_{2,t-1} + \bar{\eta}_t + \pi \eta_{1t}$$

(c) $\mu_{2t} = \mu_{2,t-1} + \pi(\mu_{1t} - \mu_{1,t-1}) + \bar{\eta}_t$

seu
vetor
de estados.

$$\mu_{2t} - \pi\mu_{1t} = (\mu_{2,t-1} - \pi\mu_{1,t-1}) + \bar{\eta}_t$$

$$\bar{\mu}_t = \bar{\mu}_{t-1} + \bar{\eta}_t \quad \text{onde } \bar{\mu}_t = \mu_{2t} - \pi\mu_{1t}$$

(d)
seu
vetor
de estados.

\Rightarrow Logo, podemos escrever

$$\underbrace{\begin{pmatrix} \mu_{1t} \\ \bar{\mu}_t \end{pmatrix}}_{\alpha_t^*} = \begin{pmatrix} 1 & 0 \\ -\pi & 1 \end{pmatrix} \underbrace{\begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix}}_{\alpha_t}$$

$$\Rightarrow \alpha_t^* = B \alpha_t \quad \text{onde } \det B = 1 : \text{transformação não singular.}$$

Prova propriedades (i) e (ii)

(i) Estrutura de dependência dos y_{it} permanece inalterada

NO NOVO SISTEMA

$$\begin{cases} y_{1t} = \mu_{1t} + \varepsilon_{1t} \\ y_{2t} = \pi\mu_{1t} + \bar{\mu}_t + \varepsilon_{2t} \\ \mu_{1t} = \mu_{1,t-1} + \eta_{1t} \\ \bar{\mu}_t = \bar{\mu}_{t-1} + \bar{\eta}_t \end{cases}$$

FAC

Para y_{1t}

$$z_t = \Delta y_{1t} = \eta_{1t} + \varepsilon_{1t}$$

$$\gamma_0(z_t) = \sigma_{\eta_1}^2 + 2\sigma_{\varepsilon_1}^2$$

$$\gamma_1(z_t) = -\sigma_{\varepsilon_1}^2$$

FAC

Para y_{2t}

$$\begin{aligned} x_t = \Delta y_{2t} &= \pi \Delta \mu_{1t} + \Delta \bar{\mu}_t + \Delta \varepsilon_{2t} \\ &= \pi \eta_{1t} + \bar{\eta}_t + \varepsilon_{2t} \end{aligned}$$

$$* \gamma_0(x_t) = \pi^2 \sigma_{\eta_1}^2 + \sigma_{\bar{\eta}}^2 + 2\sigma_{\varepsilon_2}^2$$

$$\text{mas } \sigma_{\bar{\eta}}^2 = \text{var}[\bar{\eta}] = \text{var}[\eta_2 - \pi \eta_1]$$

$$= \sigma_{\eta_2}^2 + \pi^2 \sigma_{\eta_1}^2 - 2\pi \rho \sigma_{\eta_1} \sigma_{\eta_2}$$

$$= \sigma_{\eta_2}^2 + \pi^2 \sigma_{\eta_1}^2 - 2\pi \cdot \pi \sigma_{\eta_1}^2$$

$$= \sigma_{\eta_2}^2 - \pi^2 \sigma_{\eta_1}^2$$

$$\therefore \delta_0(x_t) = \sigma_{\eta_2}^2 + 2\sigma_{\varepsilon_2}^2$$

$$\pi = \rho \frac{\sigma_{\eta_2}}{\sigma_{\eta_1}}$$

$$\therefore \rho = \pi \frac{\sigma_{\eta_1}}{\sigma_{\eta_2}}$$

$$\ast \delta_1(x_t) = \text{cov}[\Delta y_{2,t}, \Delta y_{2,t-1}]$$

$$= \text{cov}[\pi \eta_{1,t} + \bar{\eta}_t + \Delta \varepsilon_{2t}, \pi \eta_{1,t-1} + \bar{\eta}_{t-1} + \Delta \varepsilon_{2,t-1}]$$

$$= -\sigma_{\varepsilon_2}^2$$

$$\in \text{cov}(y_{1t}, y_{2t})$$

$$\text{cov}(\Delta y_{1t}, \Delta y_{2t}) = \text{cov}[(\eta_{1t} + \varepsilon_{1t} - \varepsilon_{1,t-1}), (\pi \eta_{1t} + \bar{\eta}_t + \varepsilon_{2t} - \varepsilon_{2,t-1})]$$

$$= \pi \sigma_{\eta_1}^2 + \underset{0}{\text{cov}(\eta_{1t}, \bar{\eta}_t)} + \text{cov}(\varepsilon_{1t}, \varepsilon_{2t}) + \text{cov}(\varepsilon_{1,t-1}, \varepsilon_{2,t-1})$$

$$= \pi \sigma_{\eta_1}^2 + 0 + 2\sigma_{\varepsilon_1 \varepsilon_2} = \pi \sigma_{\eta_1}^2 + 2\sigma_{\varepsilon_1 \varepsilon_2}$$

$$\underline{\text{ou}} \text{ cov}(\Delta y_{1t}, \Delta y_{2t}) = \text{cov}[(\eta_{1t} + \varepsilon_{1t} - \varepsilon_{1,t-1}), (\eta_{2t} + \varepsilon_{2t} - \varepsilon_{2,t-1})]$$

$$= \text{cov}(\eta_{1t}, \eta_{2t}) + 2\sigma_{\varepsilon_1 \varepsilon_2}$$

$$= \sigma_{\eta_1 \eta_2} + 2\sigma_{\varepsilon_1 \varepsilon_2}$$

$$\text{mas } \pi \sigma_{\eta_1}^2 = \rho \frac{\sigma_{\eta_2}}{\sigma_{\eta_1}} \cdot \sigma_{\eta_1}^2 = \rho \sigma_{\eta_2} \sigma_{\eta_1} = \sigma_{\eta_1 \eta_2} \quad \text{ok!}$$

(ii) Previsões dos y_t 's e funções de verossimilhança permanecerão inalteradas.

Na forma EE

naum.

$$\textcircled{I} \quad \underline{y}_t = \begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \underbrace{\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}}_Z \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

$$\begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} = \underbrace{\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}}_T \begin{pmatrix} \mu_{1,t-1} \\ \mu_{2,t-1} \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \eta_{1t} \\ \eta_{2t} \end{pmatrix}$$

Param.
(II)

$$\tilde{y}_t = \begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \underbrace{\begin{pmatrix} 1 & 0 \\ \pi & 1 \end{pmatrix}}_B \begin{pmatrix} \mu_{1t} \\ \bar{\mu}_t \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

$$\begin{pmatrix} \mu_{1t} \\ \bar{\mu}_t \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \mu_{1,t-1} \\ \bar{\mu}_{t-1} \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \eta_{1t} \\ \bar{\eta}_t \end{pmatrix}$$

Seja o modelo original na forma EE

$$\begin{cases} y_t = \alpha_t + \varepsilon_t \\ \alpha_t = T \alpha_{t-1} + R \eta_t \end{cases}$$

seja $\alpha_t^* = B \alpha_t$

Ver lista ^

~~provar~~

ou

Dada nova parametrização:

$$\begin{cases} y_{1t} = \mu_{1t} + \varepsilon_{1t} \\ y_{2t} = \pi \mu_{1t} + \bar{\mu}_t + \varepsilon_{2t} \\ \mu_{1t} = \mu_{1t-1} + \eta_{1t} \\ \bar{\mu}_t = \bar{\mu}_{t-1} + \bar{\eta}_t \end{cases} \quad \text{cov} \begin{pmatrix} \eta_{1t} \\ \bar{\eta}_t \end{pmatrix} = \begin{pmatrix} \sigma_{\eta_1}^2 & 0 \\ 0 & \sigma_{\eta_1}^2 (1 - \rho_{\eta}^2) \end{pmatrix}$$

• se $\rho_{\eta}^2 = \pm 1 \Rightarrow \text{var}(\bar{\eta}_t) = 0$

$\therefore \bar{\mu}_t = \bar{\mu}_{t-1} \Rightarrow \text{constante } \forall t$

Temos apenas uma componente de tendência comum (μ_t^+)

$$\Rightarrow \begin{cases} y_{1t} = \mu_t^+ + \varepsilon_{1t} \\ y_{2t} = \pi \mu_t^+ + \bar{\mu} + \varepsilon_{2t} \\ \mu_t^+ = \mu_{t-1}^+ + \eta_t^+ \end{cases} \quad \text{onde } \eta_t^+ \sim N(0, \sigma_{\eta_1}^2)$$

• Nesse caso, se $\pi = 1$ (mas $\pi = \rho \frac{\sigma_{\eta_1}}{\sigma_{\eta_2}}$)

$$\begin{aligned} y_{1t} &= \mu_t^+ + \varepsilon_{1t} \\ y_{2t} &= \mu_t^+ + \bar{\mu} + \varepsilon_{2t} \end{aligned}$$

$$\Rightarrow \mu_{1t} - \mu_{2t} = \bar{\mu}$$

Diferença entre duas tendências
é constante = $\bar{\mu} \forall t$

\Rightarrow Modelo de balanced growth

• se ainda $\bar{\mu} = 0 : \mu_{1t} = \mu_{2t}$

\Rightarrow Tendências idênticas

— " —

A parte co-integração

processo estocástico p-variado $y_t = (y_{1t} \ y_{2t} \ \dots \ y_{pt})$ é dito
co-integrado de ordens \underline{d} e \underline{b} , $b \leq d$, i.e.

$$y_t \sim CI(d, b) \quad \underline{x}$$

(i) $y_{jt} \sim I(d)$, $j = 1, 2, \dots, p$: cada um dos elementos é
integrado da mesma ordem
(ou seja: mesmo n.º de vezes a
diferenciar y_t se tornar estacionário)

(ii) $\exists \underline{x} \in \mathbb{R}^p - \{0\}$ tal que $\underline{x}' y_t \sim I(d-b)$: combinações lineares
precisa ter ordem de inte-
gração menor do que
cada série individualmente

Exemplo:

Se $y_{jt} \sim I(1)$ e as (I) $\Rightarrow \exists \underline{x}' y_t \sim I(0)$: existe cl das
ou seja $d=1$ séries que será
estacionária
($b=1$)

→ Intuições:

- Séries não estacionárias não tem atrator
- mas há uma classe que pode variar de forma não estacionária
porém cl alguma sincronia, não divergem muito por conta
de forças económicas comuns
- conceito de séries multivariadas não estacionárias
(mas se aplica a séries estacionárias, esse caso fala-se em correla-
ções)

Exs: Titulos da dívida e maturidades t.s.

Petróleo, gasolina e diesel
consumos e renda agregada.

\Rightarrow O facto de ser co-integrado ocorre por conta de uma fator
comum (componente comum entre as séries)

No modelo \textcircled{II} reparametrizado com $\rho = \pm 1$

$$\left\{ \begin{array}{l} y_{1t} = \mu_t^+ + \varepsilon_{1t} \\ y_{2t} = \pi \mu_t^+ + \bar{\mu} + \varepsilon_{2t} \\ \mu_t^+ = \mu_{t-1}^+ + \eta_t^+ \end{array} \right\} \quad \begin{array}{l} y_{1t} \text{ e } y_{2t} \text{ s\aa s nas estacion\aa rias} \\ \text{pois } \mu_t^+ \text{ \AA RW.} \end{array}$$

$\Rightarrow y_{1t} \text{ e } y_{2t} \text{ s\aa s } I(1)$

Para verificarmos se y_{1t} e y_{2t} s\aa s CI.

- J\aa sabemos que t\aa m d comum: $d=1$ (ambas s\aa s $I(1)$)
- Precisamos ver se $\exists \alpha' y_t \sim I(0)$ estacion\aa rio

ou seja, queremos: $\alpha_1 y_{1t} + \alpha_2 y_{2t} \sim I(0)$

onde α_1, α_2 s\aa s arbit\aa rias

Escolhendo $\begin{cases} \alpha_1 = -\pi \\ \alpha_2 = 1 \end{cases}$

$$\begin{aligned} \Rightarrow -\pi y_{1t} + y_{2t} &= -\pi (\mu_t^+ + \varepsilon_{1t}) + \pi \mu_t^+ + \bar{\mu} + \varepsilon_{2t} = \\ &= -\pi \mu_t^+ - \pi \varepsilon_{1t} + \pi \mu_t^+ + \bar{\mu} + \varepsilon_{2t} = \\ &= \varepsilon_{2t} - \pi \varepsilon_{1t} + \bar{\mu} \sim I(0) \quad \text{e' estacion\aa rio.} \end{aligned}$$

Logo: Para $\rho = 1$, temos condi\aa oes suficiente
p\aa exist\aa ncia de componente comum
(e\aa s s\aa m co-integradas)

\Rightarrow Portanto, de forma equivalente ao modelo acima:

$$\left\{ \begin{array}{l} y_{1t} = \mu_t^+ + \varepsilon_{1t} \\ y_{2t} = \pi y_{1t} + \bar{\mu} + \varepsilon_t \end{array} \right. \quad t=1, \dots, T$$

Este modelo pode ser estimado diretamente.

Esta formula\aa oes permite estimar π por regress\aa o de y_{2t} em y_{1t}
e formular TH p\aa verificar se de fato s\aa s co-integradas.

Divida apostila por 10.



Modelo de Nível Local Multivariado

1) SUTSE restrito

$$\begin{cases} \underset{p \times 1}{y_t} = \underset{p \times 1}{\mu_t} + \underset{p \times 1}{\varepsilon_t} & , \quad \varepsilon_t \sim N(0, \underset{p \times p}{\Sigma_\varepsilon}) \\ \underset{p \times 1}{\mu_t} = \underset{p \times 1}{\mu_{t-1}} + \underset{p \times 1}{\eta_t} & , \quad \eta_t \sim N(0, \underset{p \times p}{\Sigma_\eta}) \end{cases} \quad \varepsilon_t \text{ e } \eta_t \text{ são independentes } \forall t$$

uma componente η para cada y : $p \times 1$

obs \Rightarrow modelo + geral no que diz respeito a parâmetros.

Muitos parâmetros η estimar, o que gera problemas na estimação / converg.

Uma simplificação é usar modelo (homogêneo)

Divide:
relações?

• Considere a seguinte partição:

$$\Sigma_\eta = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix} \quad \text{onde } \Sigma_\eta \text{ tem posto cheio}$$

$$\Sigma_{11} \sim k \times k$$

$$\Sigma_{12} \sim r \times k \quad \text{onde } r = p - k$$

Particionando todas as variáveis do problema de forma correspondente:

$$\begin{pmatrix} \underset{r \times 1}{y_{1t}} \\ \underset{k \times 1}{y_{2t}} \end{pmatrix} = \begin{pmatrix} \underset{r \times 1}{\mu_{1t}} \\ \underset{k \times 1}{\mu_{2t}} \end{pmatrix} + \begin{pmatrix} \underset{r \times 1}{\varepsilon_{1t}} \\ \underset{k \times 1}{\varepsilon_{2t}} \end{pmatrix}$$

$$\begin{pmatrix} \underset{r \times 1}{\mu_{1t}} \\ \underset{k \times 1}{\mu_{2t}} \end{pmatrix} = \begin{pmatrix} \underset{r \times 1}{\mu_{1t-1}} \\ \underset{k \times 1}{\mu_{2t-1}} \end{pmatrix} + \begin{pmatrix} \underset{r \times 1}{\eta_{1t}} \\ \underset{k \times 1}{\eta_{2t}} \end{pmatrix}$$

Seja $L \triangleq \begin{pmatrix} I_k & 0 \\ -\Pi & I_r \end{pmatrix} \rightarrow$ equivalente à matriz B η transformar x_t em x_t^* e excluir fator comum.

obs: usaremos L η efetuar transformações nas variáveis η preservar propriedades fundamentais inalteradas e conseguir preservar/avaliar a existência de componentes comuns / co-integração.

→ multiplicando as equações de estado por L , temos:

$$L \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} = L \begin{pmatrix} \mu_{1,t-1} \\ \mu_{2,t-1} \end{pmatrix} + L \begin{pmatrix} \eta_{1t} \\ \eta_{2t} \end{pmatrix}$$

$$\begin{pmatrix} I_k & 0 \\ -\pi & I_n \end{pmatrix} \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} = \begin{pmatrix} I_k & 0 \\ -\pi & I_n \end{pmatrix} \begin{pmatrix} \mu_{1,t-1} \\ \mu_{2,t-1} \end{pmatrix} + \begin{pmatrix} I_k & 0 \\ -\pi & I_n \end{pmatrix} \begin{pmatrix} \eta_{1t} \\ \eta_{2t} \end{pmatrix}$$

$n \times k$

$$\begin{cases} \mu_{1t} = \mu_{1,t-1} + \eta_{1t} & (k \times 1) \\ -\pi \mu_{1t} + \mu_{2t} = -\pi \mu_{1,t-1} + \mu_{2,t-1} - \pi \eta_{1t} + \eta_{2t} & (n \times 1) \end{cases}$$

Seja $\bar{\mu}_t = \mu_{2t} - \pi \mu_{1t} \quad (n \times 1)$

$$\Rightarrow \begin{cases} \mu_{1t} = \mu_{1,t-1} + \eta_{1t} & (k \times 1) \\ \bar{\mu}_t = \bar{\mu}_{t-1} + \bar{\eta}_t & (n \times 1) \end{cases} \Rightarrow L \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} = \begin{pmatrix} \mu_{1t} \\ \bar{\mu}_t \end{pmatrix}$$

→ Para as equações de observação, podemos escrever:

$$\begin{aligned} y_t = \begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} &= \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} \\ &= \underbrace{L^{-1} L \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix}}_{\begin{pmatrix} \mu_{1t} \\ \bar{\mu}_t \end{pmatrix}} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} \\ &= L^{-1} \begin{pmatrix} \mu_{1t} \\ \bar{\mu}_t \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} \end{aligned}$$

onde $L^{-1} = \frac{1}{\det L} \begin{pmatrix} I_k & \pi \\ 0 & I_n \end{pmatrix}$

L

$$\Rightarrow y_t = \begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} I_k & \pi \\ 0 & I_n \end{pmatrix} \begin{pmatrix} \mu_{1t} \\ \bar{\mu}_t \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

na nova parametrização temos:

$$y_t = \begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} I_k & \pi \\ 0 & I_n \end{pmatrix} \begin{pmatrix} \mu_{1t} \\ \bar{\mu}_t \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

$$\begin{pmatrix} \mu_{1t} \\ \bar{\mu}_t \end{pmatrix} = \begin{pmatrix} \mu_{1,t-1} \\ \bar{\mu}_{t-1} \end{pmatrix} + \begin{pmatrix} \eta_{1t} \\ \bar{\eta}_t \end{pmatrix} \quad \text{onde} \quad \begin{pmatrix} \eta_{1t} \\ \bar{\eta}_t \end{pmatrix} \sim N \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \Sigma_{\eta^*} \right)$$

Calculamos Σ_{η^*}

$$\eta^* = L \eta \quad (\text{ou } \mu^* = L \mu)$$

$$\text{cov}[L \eta] = L \Sigma_{\eta} L'$$

$$= \begin{pmatrix} I_k & 0 \\ -\pi & I_n \end{pmatrix} \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix} \begin{pmatrix} I_k & -\pi' \\ 0 & I_n \end{pmatrix} =$$

$$= \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ -\pi \Sigma_{11} + \Sigma_{21} & -\pi \Sigma_{12} + \Sigma_{22} \end{pmatrix} \begin{pmatrix} I_k & -\pi' \\ 0 & I_n \end{pmatrix} =$$

$$\downarrow$$

$$-\pi \Sigma_{11} + \Sigma_{21} = -\Sigma_{21} \Sigma_{11}^{-1} \Sigma_{11} + \Sigma_{21} = 0$$

$$\text{cov}[L \eta] = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ 0 & -\pi \Sigma_{12} + \Sigma_{22} \end{pmatrix} \begin{pmatrix} I_k & -\pi' \\ 0 & I_n \end{pmatrix} =$$

$$= \begin{pmatrix} \Sigma_{11} & -\Sigma_{11} \pi' + \Sigma_{12} \\ 0 & -\pi \Sigma_{12} + \Sigma_{22} \end{pmatrix} \rightarrow \begin{aligned} & -\Sigma_{11} (\Sigma_{21} \Sigma_{11}^{-1})' + \Sigma_{12} = \\ & = -\Sigma_{11} (\Sigma_{11}^{-1})' \Sigma_{21}' + \Sigma_{12} = \\ & = -\Sigma_{12} + \Sigma_{12} = 0. \end{aligned}$$

$$= \begin{pmatrix} \Sigma_{11} & 0 \\ 0 & -\pi \Sigma_{12} + \Sigma_{22} \end{pmatrix} \rightarrow \begin{aligned} & -\Sigma_{21} \Sigma_{11}^{-1} \Sigma_{12} + \Sigma_{22} = \\ & = \Sigma_{22} - \Sigma_{21} \Sigma_{11}^{-1} \Sigma_{12} \end{aligned}$$

$$\text{onde } \Pi = \Sigma_{21} \Sigma_{11}^{-1}$$

divisão
é definida
a priori?

Enrolados
a matriz
de cov
diagonal

Logo: $\text{cov}[L\eta] = \text{cov}[\eta^*] = \Sigma_{\eta^*} = \text{cov} \begin{pmatrix} \eta_{1t} \\ \bar{\eta}_t \end{pmatrix} = \begin{pmatrix} \Sigma_{11} & 0 \\ 0 & \Sigma_{\bar{\eta}} \end{pmatrix}$

onde $\Sigma_{\bar{\eta}} = \Sigma_{22} - \Sigma_{21} \Sigma_{11}^{-1} \Sigma_{12}$

2) Parametrizações do SURSE

Renomeando $\mu_{1t} = \mu_t^+$, o modelo reparametrizado pode ser reescrito como:

$$y_{1t} = \mu_t^+ + \varepsilon_{1t}$$

$$y_{2t} = \pi \mu_t^+ + \bar{\mu}_t + \varepsilon_{2t}$$

$$\mu_t^+ = \mu_{t-1}^+ + \eta_t^+$$

$$\bar{\mu}_t = \bar{\mu}_{t-1} + \bar{\eta}_t$$

$$\eta_t^+ \sim N(0, \Sigma_{\eta^+}) \quad \text{onde } \Sigma_{\eta^+} = \Sigma_{11}$$

$$\bar{\eta}_t \sim N(0, \Sigma_{\bar{\eta}}) \quad \text{onde } \Sigma_{\bar{\eta}} = \Sigma_{22} - \Sigma_{21} \Sigma_{11}^{-1} \Sigma_{12}$$

$$\text{e } \text{cov} \begin{pmatrix} \eta_t^+ \\ \bar{\eta}_t \end{pmatrix} = \begin{pmatrix} \Sigma_{\eta^+} & 0 \\ 0 & \Sigma_{\bar{\eta}} \end{pmatrix}$$

↓
Esta parametrização está pronta p/ discutir a questão de componentes comuns.

3) Modelo com níveis comuns.

Agora: queremos condições suficientes p/ existência de componentes comuns

(No caso do MNL, estamos buscando no nível)

devemos olhar posto Σ_{η} : se tiver posto cheio, não há componentes comuns. (todas as LI)

⇒ se $\text{posto}(\Sigma_{\eta}) = K < p \Rightarrow \mu_t^+$ contém K níveis comuns.
com Σ_{η^+} pd e $\Sigma_{\bar{\eta}} = 0$, temos:

divida:

posto $\Sigma_{\eta} = K < p$

implica

que μ_t^+ tem K níveis comuns e $\Sigma_{\bar{\eta}} = 0$?

ou se $\Sigma_{\bar{\eta}} = 0$ tb é

ou seja, não tem K comuns?

divida:

se $\Sigma_{\bar{\eta}} = 0$ de Σ_{η}
o posto η^+
não é cheio!

$$\begin{cases} y_{1t} = \mu_t^+ + \varepsilon_{1t} \\ y_{2t} = \pi \mu_t^+ + \bar{\mu} + \varepsilon_{2t} \\ \mu_t^+ = \mu_{t-1}^+ + \eta_t^+ \end{cases} \quad \text{onde } \eta_t^+ \sim N(0, \Sigma_\eta^+) \Rightarrow \text{apenas } k \text{ componentes}$$

evoluem segundo processo P.W.

\Rightarrow Esta é uma prova específica do MNL onde as primeiras k componentes são direcionadas por μ_t^+ e outras $(p-k)$ são de μ_t^+

Assim, na prática, para determinar se um ME possui "componentes comuns", observa-se o posto da matriz covariância dos choques dessa componente (no caso $p=2 \Rightarrow \rho_{\eta_1, \eta_2} = 1$)

Partindo de um SUTSE genérico, pt ver se há comp. comuns \Rightarrow olha posto Σ_η

divida:
se parametriza?

$$\text{pt } p=2: \begin{pmatrix} \sigma_1^2 & \sigma_{1,2} \\ \sigma_{1,2} & \sigma_2^2 \end{pmatrix} \Rightarrow \hat{\rho} = \frac{\sigma_{1,2}}{\sigma_1 \sigma_2}$$

se $\hat{\rho} \approx 1$: há uma componente comum.

obs: pt $p=2$: podemos ter até uma comp. comum.

pt p genérico: " " k comp. comuns.

Nyblom e Harvey (2001) \Rightarrow testes formais pt verif car existência de comp. comuns no arcabouço de ME

MODELOS ROTACIONADOS

Modelo (IIa) não é de fácil implementação.

Como componentes NO são as únicas, podemos procurar outro conjunto de " que apresentem melhor interpretação

No modelo (IIa), podemos escrever

$$y_t = \begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} I_K \\ \pi \end{pmatrix} \mu_t^+ + \begin{pmatrix} 0 \\ \bar{\mu} \end{pmatrix} + \varepsilon_t$$

$$\mu_t^+ = \mu_{t-1}^+ + \eta_t^+ \quad \eta_t^+ \sim \text{NID}(0, \Sigma_{\eta}^+)$$

Seja $\mu_t^* = (\Sigma_{\eta}^+)^{-1/2} \mu_t^+$ a nova componente

$$\Rightarrow \mu_t^+ = (\Sigma_{\eta}^+)^{1/2} \mu_t^*$$

Substituindo na eq. de estado:

$$(\Sigma_{\eta}^+)^{1/2} \mu_t^* = (\Sigma_{\eta}^+)^{1/2} \mu_{t-1}^* + \eta_t^+$$

$$\text{fazendo tb: } \eta_t^+ = (\Sigma_{\eta}^+)^{1/2} \eta_t^*$$

$$\Rightarrow (\Sigma_{\eta}^+)^{1/2} \mu_t^* = (\Sigma_{\eta}^+)^{1/2} \mu_{t-1}^* + (\Sigma_{\eta}^+)^{1/2} \eta_t^*$$

$$\therefore \boxed{\mu_t^* = \mu_{t-1}^* + \eta_t^*} \quad \text{onde } \eta_t^* \sim \text{N}\left(0, \underbrace{(\Sigma_{\eta}^+)^{-1/2} \Sigma_{\eta}^+ (\Sigma_{\eta}^+)^{1/2}}_{I_K}\right)$$

$$\sim \text{N}(0, I_K)$$

Na eq. de observação:

$$y_t = \begin{pmatrix} I_K \\ \pi \end{pmatrix} \mu_t^+ + \begin{pmatrix} 0 \\ \bar{\mu} \end{pmatrix} + \varepsilon_t$$

$$= \begin{pmatrix} I_K \\ \pi \end{pmatrix} \Sigma_{\eta}^{+1/2} \mu_t^* + \begin{pmatrix} 0 \\ \bar{\mu} \end{pmatrix} + \varepsilon_t$$

Seja $\pi^+ = (\mathbf{I}, \pi')'$

$$\Theta = \pi^+ \Sigma_{\eta}^{-1/2}$$

$$\mu_0 = (0, \bar{\mu}')'$$

Então y_t pode ser escrito como.

$$\begin{cases} y_t = \Theta \mu_t^* + \mu_0 + \varepsilon_t & \varepsilon_t \sim N(0, \Sigma_{\varepsilon}) \\ \mu_t^* = \mu_{t-1}^* + \eta_t^* & \eta_t^* \sim N(0, \mathbf{I}_K) \end{cases}$$

↓
Fatores comuns nas s as
mais correlatadas e têm
variância unitária

⇒ Este é o ponto

de partida η começamos

a fazer rotações (a partir da obtenção de componentes ortogonais)

• Se $(\Sigma_{\eta^*})^{1/2}$ for triangular superior $\Rightarrow \Theta$ será tal que $\Theta_{ij} = 0$ $\forall j > i$

