

Estudo e comentários Adicionais

p1 p2



## Dem. exemplos e exercícios do capítulo

### (1) Tendência determinística

(Processo TS)

$$y_t = \sum_{j=0}^d \beta_j t^j + \psi(L) a_t \quad \text{onde } a_t \sim N(0, \sigma^2)$$

calcule:  $E(y_t)$ ,  $\text{var}(y_t)$ ,  $\gamma(k)$

$$E(y_t) = \sum_{j=0}^d \beta_j t^j$$

$$\begin{aligned} \text{var}(y_t) &= \text{var}(a_t + \psi_1 a_{t-1} + \psi_2 a_{t-2} + \dots) \\ &= \sum_{i=0}^{\infty} \psi_i^2 \sigma_a^2 \end{aligned}$$

$$\gamma(k) = \sigma_a^2 (\psi_k \psi_0 + \psi_{k-1} \psi_1 + \dots)$$

→ Caso  $d=1$  e  $a_t \sim AR(1)$

$$\begin{cases} y_t = \beta_0 + \beta_1 t + a_t \\ a_t = \phi a_{t-1} + \varepsilon_t \end{cases}$$

calcule:  $E(y_t)$ ,  $\text{var}(y_t)$ ,  $\gamma(k)$ , previsões e erros de previsões,  
var. do erro de previsões.

$$E(y_t) = \beta_0 + \beta_1 t$$

$$\text{var}(y_t) = \text{var}(a_t) = \frac{\sigma^2}{1-\phi^2}$$

$$\gamma(k) = \text{cov}(y_{t-k}, y_t) = \phi^k \sigma^2$$

$$\begin{aligned} \hat{y}_{t+k|t} &= E[y_{t+k} | y_t] \\ &= E[\beta_0 + \beta_1(t+k) + a_{t+k} | y_t] \end{aligned}$$

$$\text{donde } E[a_{t+k} | y_t] = \phi^k \hat{a}_{t|t}$$

$$\begin{aligned} \Rightarrow \hat{y}_{t+k|t} &= \hat{\beta}_0 + \hat{\beta}_1(t+k) + \phi^k \hat{a}_{t|t} \\ &= \hat{y}_{t|t} + \hat{\beta}_1 k + (\phi^k - 1) \hat{a}_{t|t} \end{aligned}$$

$$a_{t+k} = \phi^k a_t + \sum_{i=1}^k \phi^{k-i} \varepsilon_{t+i}$$

$$\text{var}(a_{t+k}) = \sum_{i=1}^k \phi^{2i} \sigma_\varepsilon^2$$

↓  
soma PG razão  $\phi^2$ .

⇒ obs: P/ processos TS ⇒ NAS retirar tendência por diferenciação  
pois introduz raiz unitária  
MA nas inversões.

Neste caso:

$$\begin{aligned} w_t &= y_t - y_{t-1} \\ &= \beta + (1-L) \frac{\varepsilon_t}{1-\phi L} \end{aligned}$$

$$(1-\phi L) w_t = (1-\phi) \beta + \underbrace{(1-L) \varepsilon_t}_{\text{raiz unitária}}$$

(2) Tendência Estocástica

(a) RW

$$y_t = y_{t-1} + \varepsilon_t$$

calcular  $E[y_t]$ ,  $\text{var}(y_t)$ ,  $\rho(k)$

$$y_1 = y_0 + \varepsilon_1$$

$$y_2 = y_1 + \varepsilon_2$$

⋮

$$y_t = y_0 + \sum_{i=1}^t \varepsilon_i$$

$$\Rightarrow E[y_t] = y_0 = 0$$

$$\text{var}(y_t) = t \sigma_\varepsilon^2$$

$$\gamma(k) = \text{cov}(y_t, y_{t-k})$$

$$= E \left[ \sum_{i=1}^t \varepsilon_i, \sum_{i=1}^{t-k} \varepsilon_i \right]$$

$$= E [\varepsilon_1 + \varepsilon_2 + \dots + \varepsilon_t; \varepsilon_1 + \varepsilon_2 + \dots + \varepsilon_{t-k}]$$

$$= (t-k) \sigma_\varepsilon^2$$

$$\therefore \rho(k) = \frac{(t-k)}{t} = \left(1 - \frac{k}{t}\right)$$

(b) RW com drift

$y_t = a_0 + y_{t-1} + \varepsilon_t$  : Calculemos  $E(y_t)$ ,  $\text{var}(y_t)$ ,  $\rho(k)$ , previsões

$$y_1 = a_0 + y_0 + \varepsilon_1$$

$$y_2 = a_0 + y_1 + \varepsilon_2$$

$$= 2a_0 + y_0 + \varepsilon_1 + \varepsilon_2$$

$\vdots$

$$y_t = a_0 t + y_0 + \sum_{i=1}^t \varepsilon_i$$

$$\Rightarrow E(y_t) = a_0 t \quad (y_0 = 0)$$

$$\text{var}(y_t) = t\sigma^2$$

$$\rho(y_t, y_{t-k}) = \left(1 - \frac{k}{t}\right)$$

(3) MNL - casos particulares / caso geral (EWMA)

$$\begin{cases} y_t = \mu_t + \varepsilon_t \\ \mu_t = \mu_{t-1} + \eta_t \end{cases}$$

(a)  $\sigma_\eta^2 = 0$

$$y_t = \mu_t + \varepsilon_t$$

$$\mu_t = \mu_{t-1} = \mu \Rightarrow y_t = \mu + \varepsilon_t \quad : \text{ruído branco + cte.}$$

$$E(y_t) = \mu$$

$$\text{var}(y_t) = \sigma^2$$

(b)  $\sigma_\varepsilon^2 = 0$

$$y_t = \mu_t = \mu_{t-1} + \eta_t \quad : \text{RW}$$

(c) caso geral

$$\begin{cases} y_t = \mu_t + \varepsilon_t \\ \mu_t = \mu_{t-1} + \eta_t \end{cases}$$

Calculemos  $E(y_t)$ ,  $\text{var}(y_t)$  e previsões de  $y_{t+h}$

$$E[y_t] = E[\mu_t + \varepsilon_t] = E[\mu_t]$$

$$\mu_t = \mu_{t-1} + \eta_t$$

$$\mu_1 = \mu_0 + \eta_1$$

$$\mu_2 = \mu_1 + \eta_2$$

⋮

$$\mu_t = \mu_0 + \sum_{i=1}^t \eta_i$$

$$\therefore E[y_t] = \mu_0$$

$$\begin{aligned} \text{var}[y_t] &= t \cdot \text{var}[\eta_i] + \sigma_\varepsilon^2 + p_0 \quad \text{var}(\mu_0) \\ &= t \sigma_\eta^2 + \sigma_\varepsilon^2 + p_0. \end{aligned}$$

Previsões  $k$  passos à frente

$$\begin{aligned} \hat{y}_{t+k|t} &= E[y_{t+k} | \underline{y}_t] \\ &= E[\mu_{t+k} | \underline{y}_t] \end{aligned}$$

$$\mu_{t+k} = \mu_t + \sum_{i=1}^k \eta_{t+i}$$

$$\therefore E[\mu_{t+k} | \underline{y}_t] = \hat{\mu}_{t+k}$$

$$\begin{aligned} \text{var}[y_{t+k} | \underline{y}_t] &= \text{var}(\mu_t | \underline{y}_t) + k \sigma_\eta^2 + \sigma_\varepsilon^2 \\ &= p_{t|t} + k \sigma_\eta^2 + \sigma_\varepsilon^2 \end{aligned}$$

— II —

Para MNL:

$$\left. \begin{array}{ll} Z=1 & Q = \sigma_\eta^2 \\ T=1 & H = \sigma_\varepsilon^2 \\ R=1 \end{array} \right\}$$

FK

$$v_t = y_t - a_t$$

$$F_t = p_t + H_t = p_t + \sigma_\varepsilon^2$$

$$K_t = p_t F_t^{-1} = \frac{p_t}{p_t + \sigma_\varepsilon^2}$$

$$L_t = 1 - K_t = \frac{\sigma_\varepsilon^2}{p_t + \sigma_\varepsilon^2}$$

$$M_t = p_t$$

Atualizações

$$\Rightarrow \mu_{t+1} = \mu_t + p_t \cdot \frac{1}{p_t + \sigma_\varepsilon^2} (y_t - \mu_t)$$

$$= \frac{p_t}{p_t + \sigma_\varepsilon^2} y_t + \left(1 - \frac{p_t}{p_t + \sigma_\varepsilon^2}\right) \mu_t = \lambda y_t + (1 - \lambda) \mu_t$$

EWMA

Previsões

$$a_{t+1} = T_t a_{t|t}$$

$$\mu_{t+1} = \mu_t$$

$$= \lambda y_t + (1 - \lambda) \mu_t$$

(4) Forma reduzida do MNL

3

$$y_t = \mu_t + \varepsilon_t \rightarrow \text{nas } \varepsilon_t \text{ estacionário}$$

$$\mu_t = \mu_{t-1} + \eta_t$$

$$\Rightarrow \Delta y_t = \Delta \mu_t + \Delta \varepsilon_t$$

$$= \eta_t + \varepsilon_t - \varepsilon_{t-1} \rightarrow \varepsilon_t \text{ estacionário}$$

$$\bullet E[\Delta y_t] = 0$$

$$\bullet \text{var}(\Delta y_t) = \sigma_\eta^2 + 2\sigma_\varepsilon^2$$

$$\bullet \gamma(1) = \text{cov}(\Delta y_t, \Delta y_{t-1}) =$$

$$= E[(\eta_t + \varepsilon_t - \varepsilon_{t-1})(\eta_{t-1} + \varepsilon_{t-1} - \varepsilon_{t-2})]$$

$$= -\sigma_\varepsilon^2$$

$$\therefore \rho(1) = \frac{-\sigma_\varepsilon^2}{\sigma_\eta^2 + 2\sigma_\varepsilon^2} = \frac{-1}{q+2}$$

$$\bullet \gamma(2) = 0 \Rightarrow \gamma(k) = 0 \text{ para } k \geq 2$$

$$\Rightarrow \Delta y_t \sim \text{MA}(1)$$

comparando q MA(1) genérico:

$$z_t \sim \text{MA}(1) \Rightarrow z_t = w_t + \theta_1 w_{t-1}$$

$$E[z_t] = 0$$

$$\text{var}[z_t] = (1 + \theta_1^2) \sigma_w^2$$

$$\gamma(1) = E[(w_t + \theta_1 w_{t-1})(w_{t-1} + \theta_1 w_{t-2})]$$

$$= \theta_1 \sigma_w^2$$

$$\therefore \rho(1) = \frac{\theta_1}{(1 + \theta_1^2)}$$

$$\text{Precisamos ter: } -\frac{1}{q+2} = \frac{\theta_1}{(1 + \theta_1^2)}$$

$$\downarrow \qquad \downarrow$$
$$0 < q < \infty \qquad -1 < \theta < 1$$

$$\theta_1(q+2) = -(1 + \theta_1^2)$$

$$\text{Achar } \theta_1(q) \Rightarrow \theta = \frac{-(q+2) \pm \sqrt{(q+2)^2 - 4}}{2} \quad q \in (0, \infty)$$

Com esta restrição, o espaço paramétrico de  $\theta_1$  fica reduzido:

$$\left. \begin{array}{l} q \rightarrow 0 : \theta_1 = -1 \\ q \rightarrow \infty : \theta_1 = 0 \end{array} \right\} -1 < \theta_1 < 0$$

(b) Forma reduzida do MNL com correlações

$$\begin{cases} y_t = \mu_t + \varepsilon_t & \varepsilon_t \sim N(0, \sigma_\varepsilon^2) \\ \mu_t = \mu_{t-1} + \eta_t & \eta_t \sim N(0, \sigma_\eta^2) \\ E[\varepsilon_t \eta_t] = \sigma_{\varepsilon\eta} \end{cases}$$

$$\Rightarrow \Delta y_t = \eta_t + \varepsilon_t - \varepsilon_{t-1}$$

$$E[\Delta y_t] = 0$$

$$\text{var}[\Delta y_t] = \sigma_\eta^2 + 2\sigma_\varepsilon^2 + \sigma_{\varepsilon\eta}$$

$$\gamma(1) = E[(\eta_t + \varepsilon_t - \varepsilon_{t-1})(\eta_{t-1} + \varepsilon_{t-1} - \varepsilon_{t-2})]$$

$$= -\sigma_\varepsilon^2 - \sigma_{\varepsilon\eta}$$

$$\gamma(2) = 0$$

3 parâmetros  
 $\sigma_\varepsilon^2, \sigma_\eta^2, \sigma_{\varepsilon\eta}$

(5) TLL - Casos Particulares / caso geral

$$y_t = \mu_t + \varepsilon_t$$

$$\mu_t = \mu_{t-1} + \beta_{t-1} + \eta_t$$

$$\beta_t = \beta_{t-1} + \zeta_t$$

$\Rightarrow \mu_t$ : tendência linear estoc. da série  
 $\beta_t$ : inclinação estocástica.

$$(a) \sigma_\eta^2 = \sigma_\varepsilon^2 = 0.$$

$$\begin{cases} y_t = \mu_t + \varepsilon_t \\ \mu_t = \mu_{t-1} + \beta \\ \beta_t = \beta \end{cases}$$

$$\Rightarrow \mu_1 = \mu_0 + \beta$$

$$\begin{aligned} \mu_2 &= \mu_1 + \beta \\ &= \mu_0 + 2\beta \end{aligned}$$

:

$$\mu_t = \mu_0 + t\beta \Rightarrow y_t = \mu_0 + t\beta + \varepsilon_t$$

Modelo TS linear



$$(b) \sigma_{\xi}^2 = 0, \sigma_{\eta}^2 \neq 0$$

$$y_t = \mu_t + \varepsilon_t$$

$$\mu_t = \mu_{t-1} + \beta_{t-1} + \eta_t$$

$$\beta_t = \beta_{t-1} = \beta$$

$$\Rightarrow \mu_t = \mu_{t-1} + \beta + \eta_t : \text{RW com drift}$$

$$(c) \sigma_{\xi}^2 = 0, \sigma_{\eta}^2 \neq 0$$

$$\begin{cases} y_t = \mu_t + \varepsilon_t \\ \mu_t = \mu_{t-1} + \beta_{t-1} \rightarrow \mu_t \text{ é dita tendência suave.} \\ \beta_t = \beta_{t-1} + \zeta_t \end{cases}$$

$$\begin{cases} \Delta \mu_t = \beta_{t-1} \\ \Delta^2 \mu_t = \zeta_t \end{cases} \text{ filtro passa baixa.}$$

(c) Cálculo da Função de Previsão HTL.

$$\hat{y}_{t+k|t} = \hat{\mu}_{t|t} + \underbrace{k}_{k=1} \hat{\beta}_{t|t}$$

(6.a) usando eqs. de atualizações FK  $\Rightarrow$  mostrar método de Holt

$$\begin{cases} y_t = (1 \ 0) \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} + \varepsilon_t \\ \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \mu_{t-1} \\ \beta_{t-1} \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \eta_t \\ \zeta_t \end{pmatrix} \end{cases}$$

$$\begin{aligned} z &= (1 \ 0) & H &= \sigma_{\varepsilon}^2 \\ T &= \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} & \Phi &= \begin{pmatrix} \sigma_{\eta}^2 & 0 \\ 0 & \sigma_{\zeta}^2 \end{pmatrix} \\ R &= I \end{aligned}$$

Calcular  $m_t, f_t, v_t$

$$\begin{aligned} \Rightarrow m_t &= P_t' z_t' \\ &= \begin{pmatrix} p_t^{11} & p_t^{12} \\ p_t^{21} & p_t^{22} \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} p_t^{11} \\ p_t^{21} \end{pmatrix} \end{aligned}$$

$$\begin{aligned} f_t &= (1 \ 0) \begin{pmatrix} p_t^{11} & p_t^{12} \\ p_t^{21} & p_t^{22} \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} + \sigma_{\varepsilon}^2 = \begin{pmatrix} p_t^{11} & p_t^{12} \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} + \sigma_{\varepsilon}^2 \\ &= p_t^{11} + \sigma_{\varepsilon}^2 \end{aligned}$$

$$v_t = y_t - (1 \ 0) \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} \therefore v_t = y_t - m_t$$

Equações do FK

Atualizações

$$a_{t|t} = a_t + M_t F_t' v_t$$

$$P_{t|t} = P_t - P_t z_t' F_t' z_t P_t$$

Previsões

$$a_{t+1} = T_t a_{t|t}$$

$$P_{t+1} = T_t P_{t|t} T_t' + R_t \Phi_t P_t$$

onde:

$$v_t = y_t - z_t a_t$$

$$F_t = z_t P_t z_t' + H_t$$

$$M_t = P_t z_t'$$

(2) Formula Reduzida MTL.

$$\begin{cases} y_t = \mu_t + \varepsilon_t \\ \mu_t = \mu_{t-1} + \beta_{t-1} + \eta_t \\ \beta_t = \beta_{t-1} + \zeta_t \end{cases}$$

$$\Delta y_t = \beta_{t-1} + \eta_t + \Delta \varepsilon_t$$

$$\Delta^2 y_t = \zeta_t + \Delta \eta_t + \Delta^2 \varepsilon_t \quad \rightarrow \text{estacionário}$$

$$= \zeta_t + \eta_t - \eta_{t-1} + \underbrace{(1-L)^2 \varepsilon_t}_{(1-2L+L^2)}$$

$$= \zeta_t + \eta_t - \eta_{t-1} + \varepsilon_t - 2\varepsilon_{t-1} + \varepsilon_{t-2}$$

$$\Rightarrow E[\Delta^2 y_t] = 0$$

$$\text{var}[\Delta^2 y_t] = \sigma_\zeta^2 + 2\sigma_\eta^2 + 6\sigma_\varepsilon^2$$

$$\gamma(1) = \text{cov}[\Delta^2 y_t, \Delta^2 y_{t-1}] =$$

$$= E[(\zeta_t + \eta_t - \eta_{t-1} + \varepsilon_t - 2\varepsilon_{t-1} + \varepsilon_{t-2})(\zeta_{t-1} + \eta_{t-1} - \eta_{t-2} + \varepsilon_{t-1} - 2\varepsilon_{t-2} + \varepsilon_{t-3})] =$$

$$= -\sigma_\eta^2 - 2\sigma_\varepsilon^2 - 2\sigma_\varepsilon^2 = -\sigma_\eta^2 - 4\sigma_\varepsilon^2$$

$$\gamma(2) = \text{cov}[\Delta^2 y_t, \Delta^2 y_{t-2}] =$$

$$= E[(\dots) (\zeta_{t-2} + \eta_{t-2} - \eta_{t-3} + \varepsilon_{t-2} - 2\varepsilon_{t-3} + \varepsilon_{t-4})]$$

$$= \sigma_\varepsilon^2$$

$$\gamma(k) = 0 \quad \forall k \geq 3.$$

$$\Rightarrow \Delta^2 y_t \sim \text{MA}(2)$$

Para MA(2) genérico:

$$z_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2}$$

Da atualização  $m$  a  $t|t$ :

$$\begin{pmatrix} m_{t|t} \\ b_{t|t} \end{pmatrix} = \begin{pmatrix} m_t \\ b_t \end{pmatrix} + \begin{pmatrix} P_t^{''} \\ P_t^{'''} \end{pmatrix} \frac{1}{P_t^{''} + \sigma_e^2} (y_t - m_t)$$

$$\Rightarrow m_{t|t} = m_t + \frac{P_t^{''}}{P_t^{''} + \sigma_e^2} (y_t - m_t) \quad (1)$$

$$b_{t|t} = b_t + \frac{P_t^{'''}}{P_t^{''} + \sigma_e^2} (y_t - m_t) \quad (2)$$

Da previsões do FK:

$$\begin{pmatrix} m_t \\ b_t \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} m_{t-1|t-1} \\ b_{t-1|t-1} \end{pmatrix}$$

$$m_t = m_{t-1|t-1} + b_{t-1|t-1} \quad (3)$$

$$b_t = b_{t-1|t-1} \quad (4)$$

De (3) em (1):

$$m_{t|t} = m_{t-1|t-1} + b_{t-1|t-1} + \frac{P_t^{''}}{P_t^{''} + \sigma_e^2} (y_t - m_{t-1|t-1} - b_{t-1|t-1})$$

$$m_{t|t} = \underbrace{\frac{P_t^{''}}{P_t^{''} + \sigma_e^2}}_{\lambda_{t|t}} y_t + \underbrace{\left(1 - \frac{P_t^{''}}{P_t^{''} + \sigma_e^2}\right)}_{1 - \lambda_{t|t}} (m_{t-1|t-1} + b_{t-1|t-1})$$

$$m_{t|t} = \lambda_{t|t} y_t + (1 - \lambda_{t|t}) (m_{t-1|t-1} + b_{t-1|t-1})$$

De (1) em (2)

$$(y_t - m_t) = (m_{t|t} - m_t) \cdot \frac{P_t^{''} + \sigma_e^2}{P_t^{''}} \Rightarrow b_{t|t} = b_t + \frac{P_t^{'''}}{P_t^{''}} (m_{t|t} - m_t) \quad (5)$$

$$\text{De (3) e (4) em (5): } b_{t|t} = b_{t-1|t-1} + \frac{P_t^{'''}}{P_t^{''}} (m_{t|t} - m_{t-1|t-1} - b_{t-1|t-1})$$

8

usa  
quação  
de atualização

usa  
eq. de  
previsão  
sucessivo  
de  $t-1$

subst.  
previsão  
na  
atualização  
de  $m_t$

$$b_{t|t} = \underbrace{\left(1 - \frac{p_t^{21}}{p_t^{11}}\right)}_{1 - \lambda_{2t}} b_{t-1|t-1} + \underbrace{\left(\frac{p_t^{21}}{p_t^{11}}\right)}_{\lambda_{2t}} (m_{t|t} - m_{t-1|t-1})$$

$$E[z_t] = 0$$

$$\text{var}[z_t] = (1 + \theta_1^2 + \theta_2^2) \sigma_e^2$$

$$\gamma(1) = (\theta_1 + \theta_1 \theta_2) \sigma_e^2$$

$$\gamma(2) = \theta_2 \sigma_e^2$$

Igualar expressões e verificar restrições adicionais sobre parâmetros.

obs: Se  $\sigma_\gamma^2 = 0 \Rightarrow$  inclinação fixa  
 $\theta_1$  e  $\theta_2$  fora da região de invertibilidade.

Se  $\sigma_\gamma^2 = 0$  e  $\sigma_\gamma^2 > 0 \Rightarrow$  tendência suave  
 Modelo sempre invertível.

(8) Tendência linear amortecida

$$y_t = \mu_t + \epsilon_t$$

$$\mu_t = \mu_{t-1} + \beta_{t-1} + \eta_t$$

$$\beta_t = \phi \beta_{t-1} + \zeta_t$$

$\rightarrow$  calcular funções de previsão e forma reduzida

$$\begin{aligned} \hat{y}_{t+k|t} &= E[y_{t+k} | \mathcal{Y}_t] \\ &= E[\mu_{t+k} | \mathcal{Y}_t] \end{aligned}$$

$$\bullet E[\mu_{t+k} | \mathcal{Y}_t] =$$

$$\mu_{t+1} = \mu_t + \beta_t + \eta_{t+1}$$

$$\mu_{t+2} = \mu_{t+1} + \beta_{t+1} + \eta_{t+2}$$

$$= \mu_t + \beta_t + \beta_{t+1} + \eta_{t+1} + \eta_t$$

$$= \mu_t + \sum_{i=1}^k \beta_{t+i} + \sum_{i=1}^k \eta_{t+i}$$

$$\Rightarrow E[\mu_{t+k} | \mathcal{Y}_t] = \hat{\mu}_{t+k} + \sum_{i=1}^k E[\beta_{t+i} | \mathcal{Y}_t]$$

$$\bullet E[\beta_{t+i} | \mathcal{Y}_t]$$

$$\beta_{t+1} = \phi \beta_t + \zeta_{t+1}$$

$$\begin{aligned} \beta_{t+2} &= \phi \beta_{t+1} + \zeta_{t+2} \\ &= \phi^2 \beta_t + \phi \zeta_{t+1} + \zeta_{t+2} \end{aligned}$$

$$\beta_{t+i} = \phi^i \beta_t + \sum_{j=0}^{i-1} \phi^j \zeta_{t+i-j}$$

Logo:  $y_{t+k|t} = \hat{\mu}_{t+k|t} + \underbrace{\sum_{i=1}^k \phi^i \hat{\beta}_{t+k-i}}_{\text{PG razão } \phi}$

$$\left( \frac{1 - \phi^k}{1 - \phi} \right)$$

• forma reduzida

$$\Delta y_t = \beta_{t-1} + \eta_t + \Delta \varepsilon_t$$

$$\beta_t = \phi \beta_{t-1} + \zeta_t$$

$$(1 - \phi L) \beta_t = \zeta_t \quad \therefore \beta_t = \frac{\zeta_t}{1 - \phi L}$$

$$\Rightarrow \Delta y_t = \frac{\zeta_{t-1}}{1 - \phi L} + \eta_t + \Delta \varepsilon_t$$

$$\begin{aligned} (1 - \phi L) \Delta y_t &= \zeta_{t-1} + (1 - \phi L) \eta_t + (1 - \phi L)(\varepsilon_t - \varepsilon_{t-1}) \\ &= \zeta_{t-1} + \eta_t - \phi \eta_{t-1} + \varepsilon_t - \varepsilon_{t-1} - \phi \varepsilon_{t-1} + \phi \varepsilon_{t-2} \\ &= \zeta_{t-1} + \eta_t - \phi \eta_{t-1} + \varepsilon_t - (\phi + 1) \varepsilon_{t-1} + \phi \varepsilon_{t-2} \end{aligned}$$


∴ calcular ARIMA  
correspondente

(9)

Por que transformações logarítmica é indicada em algumas situações?

- a) lineariza o modelo
- b) traz simetria aos resíduos  $\Rightarrow$  torna normal
- c) muda a escala (trabalha com variáveis relativas)
- d) estabiliza a variância

↓  
pt um determinado tipo de heteroscedasticidade



(10) Quando tratamos sazonalidade com dummies, qual o problema de usar uma dummy por período?

Problema de multicolinearidade perfeita

Não conseguimos estimar regressores por MQO

obs: coeficientes das dummies não representam os fatores sazonais

Para evitar multicolinearidade perfeita:

introduzir algum tipo de restrição nos parâmetros do modelo, resultando em  $\neq$ s parametrizações.

$\Rightarrow \delta$ 's: fatores sazonais, estarão relacionados de alguma forma

1ª parametr: faz um dos  $\delta_j = 0$  (escolha arbitrária)

2ª parametr: abandona intercepto

3ª parametr: soma dos coeficientes de sazonalidade é zero no período

↓

No caso determinístico:  $\sum_{j=1}^s \delta_j = 0 \Rightarrow \sum_{j=1}^{s-1} \delta_{t-j} = 0$

ideia de soma  $\delta$  dos fatores no tempo de  $s$  períodos.

No caso estocástico:  $\sum_{j=1}^{s-1} \delta_{t-j} = w_t \quad w_t \sim N(0, \sigma_w^2)$

(11) Modelo Estrutural Básico: TLL + sazonalidade

$$\begin{cases} y_t = \mu_t + \delta_t + \epsilon_t \\ \mu_t = \mu_{t-1} + \beta_{t-1} + \eta_t \\ \beta_t = \beta_{t-1} + \gamma_t \\ \delta_t = \sum_{j=1}^{s-1} \delta_{t-j} + w_t \end{cases}$$

→ Funções de previsão:

$$\begin{aligned} \hat{y}_{t+h|t} &= E[\mu_{t+h} + \delta_{t+h} + \epsilon_{t+h} | \mathcal{Y}_t] \\ &= E[\underbrace{\mu_{t+h}}_{\text{do TLL}} | \mathcal{Y}_t] + E[\delta_{t+h} | \mathcal{Y}_t] \end{aligned}$$



$$\hat{y}_{t+s|t} = \hat{\mu}_{t|t} + z\hat{\beta}_{t|t} + \hat{\delta}_{t+s|t}$$

$$\downarrow$$

$$= \hat{\delta}_{t-s} + z1t \quad s=1,2,3, \dots$$

⇓

só é projetado o último período (fator sazonal) correspondente.

(ii) Sazonalidade por funções trigonométricas.

Cada fator sazonal será soma de senos e cossenos:

$$\delta_t = \sum_{j=1}^{s/2} (\delta_j \cos \lambda_j t + \delta_j^* \sin \lambda_j t)$$

onde  $\lambda_j = \left( \frac{2\pi j}{s} \right)$

⇒ usando todos os harmônicos: estimativa por mínimos = estimativas por SF.

MEB com funções Trigonômétricas:

$$y_t = \mu_t + \delta_t + \varepsilon_t$$

$$\mu_t = \mu_{t-1} + \beta_{t-1} + \gamma_t$$

$$\beta_t = \beta_{t-1} + \zeta_t$$

$$\delta_t = \sum_{j=1}^{s/2} \delta_{jt}$$

onde 
$$\begin{pmatrix} \delta_{jt} \\ \delta_{jt}^* \end{pmatrix} = \begin{pmatrix} \cos \lambda_j & \sin \lambda_j \\ -\sin \lambda_j & \cos \lambda_j \end{pmatrix} \begin{pmatrix} \delta_{j,t-1} \\ \delta_{j,t-1}^* \end{pmatrix} + \begin{pmatrix} w_t \\ w_t^* \end{pmatrix}$$

Se  $s=4 \Rightarrow$  NO vetor de estado

$$\begin{pmatrix} \delta_{1t} \\ \delta_{1t}^* \\ \delta_{2t} \end{pmatrix}$$

Por conveniência, no vetor de estado, teremos

$$\begin{pmatrix} \delta_t \\ \delta_{t-1} \\ \delta_{t-2} \end{pmatrix}$$

(12) Forma reduzida do MEB w sazonalidade por dummies:

$$\begin{cases} y_t = \mu_t + \gamma_t + \varepsilon_t \\ \mu_t = \mu_{t-1} + \beta_{t-1} + \eta_t \\ \beta_t = \beta_{t-1} + \zeta_t \\ \gamma_t = -\sum_{j=1}^{s-1} \gamma_{t-j} + w_t \end{cases} \Rightarrow \sum_{j=0}^{s-1} \gamma_{t-j} = w_t \Leftrightarrow S_s(L) \gamma_t = w_t$$

→ operador de diferenças sazonal =  $\Delta_s = 1 - L^s$

(observações:  $S_s(L) = 1 + L^1 + L^2 + \dots + L^{s-1}$  onde  $\boxed{\Delta S_s(L) = \Delta_s}$ )

Para  $y_t$ :

$$\begin{aligned} \Delta y_t &= \Delta \mu_t + \Delta \gamma_t + \Delta \varepsilon_t \\ &= \underbrace{\beta_{t-1}} + \Delta \gamma_t + \Delta \varepsilon_t \rightarrow \text{tirar } \beta_{t-1} \end{aligned}$$

Para  $\Delta y_t$

$$\begin{aligned} \Delta^2 y_t &= \Delta \beta_{t-1} + \Delta^2 \gamma_t + \Delta^2 \varepsilon_t \\ &= \zeta_{t-1} + \Delta^2 \gamma_t + \Delta^2 \varepsilon_t \rightarrow \text{já está na tendência} \\ &\quad \text{tirar na sazonalidade} \end{aligned}$$

$$S_s(L) \Delta^2 y_t = S_s(L) \zeta_{t-1} + \Delta^2 S_s(L) \gamma_t + \Delta^2 S_s(L) \varepsilon_t$$

$$\underbrace{\Delta \Delta S_s(L)}_{\Delta_s} y_t = S_s(L) \zeta_{t-1} + \underbrace{\Delta \Delta S_s(L)}_{w_t} \gamma_t + \underbrace{\Delta \Delta S_s(L)}_{\Delta_s} \varepsilon_t$$

$$\Delta \Delta_s y_t = S(L) \zeta_{t-1} + \Delta^2 w_t + \Delta \Delta_s \varepsilon_t \Rightarrow \text{Estacionário MA}(s+1)$$

Ex:  $s=4$

PI TLL  $\Rightarrow$  MA(2)

cl sazonalidade: + s-1 par.

$$\begin{aligned} \underbrace{(1-L)(1-L^4)}_{2_t} y_t &= (1+L+L^2+L^3) \zeta_{t-1} + (1-L)^2 w_t + \underbrace{(1-L)(1-L^4)}_{(1-L^4-L+L^5)} \varepsilon_t \\ &= \zeta_{t-1} + \zeta_{t-2} + \zeta_{t-3} + \zeta_{t-4} + w_t - 2w_{t-1} + w_{t-2} + \\ &\quad + \varepsilon_t - \varepsilon_{t-1} - \varepsilon_{t-4} + \varepsilon_{t-5} \end{aligned}$$

Estacionário MA(5)

Divida  $\Rightarrow$  como se ve forma reduzida p/ MEB e funções trigonométricas?

### (13) Variações Explicativas

Olhar numo adicional.

Atenções: Funções de Verosimilhança fica em funções de parâmetros de var. explicativas.

Divida  $\checkmark$  se procura de intervenções tb estiva?

### (14) Tipos de variáveis

pulso  $w_t = \begin{cases} 1 & t = t^* \\ 0 & t \neq t^* \end{cases}$

escada  $w_t = \begin{cases} 0 & t < t^* \\ 1 & t \geq t^* \end{cases}$

nucl. inclinada  $w_t = \begin{cases} 0 & t < t^* \\ t - t^* & t \geq t^* \end{cases}$

pulso decaindo gradualmente

" crescendo / caindo "

### (15) Diagnósticos do modelo

(a) Quais são as hipóteses p/ serem verificadas?

(i) linearidade das componentes  
aditividade

Podem ser verificados visualmente

sazonalidade vai aumentando em amplitude tb.

se não identificar  $\Rightarrow$  olhar resíduos

(ii) Resíduos  $\varepsilon_t$   $\longrightarrow$   $\left\{ \begin{array}{l} \text{Normalidade} \\ \text{Homocedasticidade} \\ \text{Des correlação} \end{array} \right.$

$$\varepsilon_t = y_t - z_t \alpha_t$$

Como  $\varepsilon_t$  não é observado

$$v_t = y_t - z_t \alpha_{t-1} \rightarrow E[v_t] = 0$$

$$\text{var}[v_t] = F_t$$

Normalizando:  $\tilde{v}_t = \frac{v_t}{F_t^{1/2}}$  — queremos  $N(0,1)$

Testes sobre  $\tilde{v}_t$ :

→ Normalidade: (testar  $H_0: \hat{\sigma}_v^2 = 1$ )

- histograma
- Q-Q plot
- Jarque-Bera  $\rightarrow H_0$ : normal.
- A Darling

→ Homocedasticidade

duas coisas podem ocorrer

• se modelo multiplicativo e ajustamos aditivo

$\rightarrow$  var do erro cresce.

Teste no início e final da amostra e vê se var de.

• pode ser que comportamento da heterocedasticidade seja outro:

$\rightarrow$  pode-se fazer teste ARCH, por exemplo.

→ Des correlação:

pf avaliar a dependência linear:

- olhar FAC
- teste de Ljung Box

$$H_0: \rho_1 = \rho_2 = \dots = \rho_m = 0$$

$H_a$ : caso contrário

(16) Resíduos Auxiliares como diagnósticos

⇒ Bom p/ variáveis explicativas

(ver resumo adicional)

(17) Modelos multivariados:

estimar componentes comuns em ST melhora o modelo  
(inferência, previsões etc.)

se tratar STs separadamente ⇒ perde possibilidade de influência

diagnósticos sobre inovações ⇒ multivariados

(18) Modelo SUTSE: número de parâmetros

$$\begin{array}{lll} y_t = \mu_t + \varepsilon_t & \varepsilon_t \sim N(0, \Sigma_\varepsilon) & \Rightarrow p + \binom{p}{2} \text{ parâmetros} \\ (p \times 1) & \text{--- } p \times p & \text{em } \Sigma_\varepsilon \text{ e } p + \binom{p}{2} \\ \mu_{t+1} = \mu_t + \eta_t & \eta_t \sim N(0, \Sigma_\eta) & \text{em } \Sigma_\eta \end{array}$$

⇒ v.a.'s não se comunicam explicitamente.

comunicação através das matrizes de covariância.

(19) Modelos homogêneos: forma de adicionar restrições ao modelo  
p/ diminuir n° de parâmetros

Definição:

Processo estocástico de 2ª ordem e homogêneo se  
todas as CL de suas componentes possuem as mesmas  
propriedades de 2ª ordem

ou seja

$$y_t = (y_{1t}, y_{2t}, \dots, y_{pt})' \text{ homogêneo}$$

se  $\exists \alpha$  tal que  $z_t = D^d(\alpha' y)$  univariado

possui FAC independente de  $\alpha$ .

(20) Prove que:

se  $y_t$  segue um SUTSE MNL então  $y_t$  é homogêneo  
se e somente se

$$\Sigma \eta = q \Sigma \varepsilon$$

→ Prova da volta

se  $\Sigma \eta = q \Sigma \varepsilon \Rightarrow y_t$  é homogêneo

Seja MNL SUTSE  $p=2$ :

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} \quad \text{onde } \Sigma \varepsilon = \begin{pmatrix} \sigma_{\varepsilon_1}^2 & \sigma_{\varepsilon_1 \varepsilon_2} \\ \sigma_{\varepsilon_1 \varepsilon_2} & \sigma_{\varepsilon_2}^2 \end{pmatrix}$$

$$\begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} = \begin{pmatrix} \mu_{1t-1} \\ \mu_{2t-1} \end{pmatrix} + \begin{pmatrix} \eta_{1t} \\ \eta_{2t} \end{pmatrix} \quad \Sigma \eta = \begin{pmatrix} \sigma_{\eta_1}^2 & \sigma_{\eta_1 \eta_2} \\ \sigma_{\eta_1 \eta_2} & \sigma_{\eta_2}^2 \end{pmatrix}$$

$$= q \Sigma \varepsilon$$

$$\text{Seja } z_t = (\alpha' \Delta y_t)$$

↓  
H estacionário

$$= \alpha_1 \Delta y_1 + \alpha_2 \Delta y_2$$

$$= \alpha_1 (\eta_{1t} + \varepsilon_{1t} - \varepsilon_{1t-1}) + \alpha_2 (\eta_{2t} + \varepsilon_{2t} - \varepsilon_{2t-1})$$

Calculamos a FAC de  $z_t$

$$\gamma(0) = \alpha_1^2 \sigma_{\eta_1}^2 + 2 \alpha_1^2 \sigma_{\varepsilon_1}^2 + \alpha_2^2 \sigma_{\eta_2}^2 + 2 \alpha_2^2 \sigma_{\varepsilon_2}^2 + 2 \alpha_1 \alpha_2 \sigma_{\eta_1 \eta_2} + 4 \alpha_1 \alpha_2 \sigma_{\varepsilon_1 \varepsilon_2}$$

$$= \alpha_1^2 \sigma_{\varepsilon_1}^2 (q+2) + \alpha_2^2 \sigma_{\varepsilon_2}^2 (q+2) + 2 \alpha_1 \alpha_2 \sigma_{\varepsilon_1 \varepsilon_2} (q+2)$$

$$= (\alpha_1^2 \sigma_{\varepsilon_1}^2 + \alpha_2^2 \sigma_{\varepsilon_2}^2 + 2 \alpha_1 \alpha_2 \sigma_{\varepsilon_1 \varepsilon_2}) (q+2)$$

$$\gamma(1) = E[(\alpha_1 \eta_{1t} + \alpha_1 \varepsilon_{1t} - \alpha_1 \varepsilon_{1t-1} + \alpha_2 \eta_{2t} + \alpha_2 \varepsilon_{2t} - \alpha_2 \varepsilon_{2t-1})$$

$$(\alpha_1 \eta_{1t-1} + \alpha_1 \varepsilon_{1t-1} - \alpha_1 \varepsilon_{1t-2} + \alpha_2 \eta_{2t-1} + \alpha_2 \varepsilon_{2t-1} - \alpha_2 \varepsilon_{2t-2})]$$

$$= -\alpha_1^2 \sigma_{\varepsilon_1}^2 - \alpha_1 \alpha_2 \sigma_{\varepsilon_1 \varepsilon_2} - \alpha_1 \alpha_2 \sigma_{\varepsilon_1 \varepsilon_2} - \alpha_2^2 \sigma_{\varepsilon_2}^2 =$$

$$= -(\alpha_1^2 \sigma_{\varepsilon_1}^2 + 2 \alpha_1 \alpha_2 \sigma_{\varepsilon_1 \varepsilon_2} + \alpha_2^2 \sigma_{\varepsilon_2}^2)$$

$$\therefore p(1) = -\frac{1}{q+2} \quad \text{independe de } \alpha_1 \text{ e } \alpha_2$$

→ Prova da ida

$$\text{Se } y_t \text{ é homogêneo} \Rightarrow \tilde{y} = q \tilde{e}$$

Sabemos que se  $y_t$  é homogêneo, a FAC de  $\tilde{y}' \Delta y_t$  independe de  $\alpha$

Para  $p=2$ , temos:

$$\begin{aligned} \gamma(0) &= \alpha_1^2 \sigma_{\eta_1}^2 + 2\alpha_1^2 \sigma_{\varepsilon_1}^2 + \alpha_2^2 \sigma_{\eta_2}^2 + 2\alpha_2^2 \sigma_{\varepsilon_2}^2 + 2\alpha_1 \alpha_2 \sigma_{\eta_1 \eta_2} + 4\alpha_1 \alpha_2 \sigma_{\varepsilon_1 \varepsilon_2} \\ &= \alpha_1^2 (\sigma_{\eta_1}^2 + 2\sigma_{\varepsilon_1}^2) + \alpha_2^2 (\sigma_{\eta_2}^2 + 2\sigma_{\varepsilon_2}^2) + 2\alpha_1 \alpha_2 (\sigma_{\eta_1 \eta_2} + 2\sigma_{\varepsilon_1 \varepsilon_2}) \end{aligned}$$

$$\gamma(1) = -(\alpha_1^2 \sigma_{\varepsilon_1}^2 + \alpha_2^2 \sigma_{\varepsilon_2}^2 + 2\alpha_1 \alpha_2 \sigma_{\varepsilon_1 \varepsilon_2})$$

Para cancelar o termo da numeradora

como prova?

¶ que  $p(1)$  independe de  $\alpha_1$  e  $\alpha_2$ , devemos cancelar o termo  $(\alpha_1^2 \sigma_{\varepsilon_1}^2 + \alpha_2^2 \sigma_{\varepsilon_2}^2 + 2\alpha_1 \alpha_2 \sigma_{\varepsilon_1 \varepsilon_2})$

$$\Rightarrow \alpha_1^2 \sigma_{\varepsilon_1}^2 \left( \frac{\sigma_{\eta_1}^2}{\sigma_{\varepsilon_1}^2} + 2 \right) + \alpha_2^2 \sigma_{\varepsilon_2}^2 \left( \frac{\sigma_{\eta_2}^2}{\sigma_{\varepsilon_2}^2} + 2 \right) + 2\alpha_1 \alpha_2 \sigma_{\varepsilon_1 \varepsilon_2} \left( \frac{\sigma_{\eta_1 \eta_2}}{\sigma_{\varepsilon_1 \varepsilon_2}} + 2 \right)$$

$$\text{O que só é possível se } \frac{\sigma_{\eta_1}^2}{\sigma_{\varepsilon_1}^2} = \frac{\sigma_{\eta_2}^2}{\sigma_{\varepsilon_2}^2} = \frac{\sigma_{\eta_1 \eta_2}}{\sigma_{\varepsilon_1 \varepsilon_2}}$$

(21) Prove que:

Se  $y_e$  seja um SUTSE com  $j$  tipos de componentes ortogonais, então  $y_e$  será homogêneo se e somente se:

$$\tilde{\Sigma}_\eta = \begin{pmatrix} \tilde{\Sigma}_{\eta_1} & & 0 \\ & \tilde{\Sigma}_{\eta_2} & \\ 0 & & \ddots \\ & & & \tilde{\Sigma}_{\eta_j} \end{pmatrix} = \begin{pmatrix} q_1 \tilde{\Sigma}_E & & 0 \\ & q_2 \tilde{\Sigma}_E & \\ 0 & & \ddots \\ & & & q_j \tilde{\Sigma}_E \end{pmatrix}$$

Vale o mesmo raciocínio da proposição anterior.

Como as  $\tilde{\Sigma}_{\eta_i}$  são ortogonais  $\tilde{\Sigma}_{\eta_i} \tilde{\Sigma}_{\eta_j} = 0 \quad \forall i \neq j$

e  $\tilde{\Sigma}_{\eta_i} = q_i \tilde{\Sigma}_E$  pela demonstração anterior.

provar m TLL  
SUTSE  
p=2.



(22) Propriedades Empíricas de PH'S

- (i) Pode haver teorias "a priori" que justifiquem a adoção desta estrutura
- (ii) FK pode ser implementado p cada uma das p comp. separadamente
- (iii) Menos risco na estimação parâmetros
- (iv) Estimacões MV + simples

(23) Funções de Verossimilhança p modelo NL SURSE Homos.

$$\begin{cases} y_t = \mu_t + \varepsilon_t & \varepsilon_t \sim N(0, \Sigma_\varepsilon) \\ \mu_t = \mu_{t-1} + \eta_t & \eta_t \sim N(0, \Sigma_\eta) \end{cases}$$

Para  $p=2$ :

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

$$\begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} = \begin{pmatrix} \mu_{1t-1} \\ \mu_{2t-1} \end{pmatrix} + \begin{pmatrix} \eta_{1t} \\ \eta_{2t} \end{pmatrix}$$

esta certo?

$$\begin{matrix} Z = I & H = \Sigma_\varepsilon \\ T = I & Q = \Sigma_\eta \end{matrix}$$

$$L(\theta) = \prod_{i=1}^n p(y_{1t}, y_{2t} | \mu_{t-1}) \Rightarrow \text{funções densidade conjunta bivariada}$$

Para  $p(y_{1t}, y_{2t}) = ?$

$$E \left[ \begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} \right] = (Z a_t) = \begin{bmatrix} \mu_{1t} \\ \mu_{2t} \end{bmatrix}$$

$$\text{var} \left[ \begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} \right] = (Z P_t Z' + H_t) = F_t$$

↓  
dividida

Dividido  
componentes x  
n de séries de  
y.

$$p(y_{1t}, y_{2t} | \underline{y}_t) = \frac{1}{(2\pi)^{2/2} |F_t|^{1/2}} e^{-\frac{1}{2} \left[ (2\mu_t - m_t)' F_t^{-1} (2\mu_t - m_t) \right]}$$

$$= \frac{1}{2\pi |F_t|^{1/2}} e^{-\frac{1}{2} \left[ v_t' F_t^{-1} v_t \right]}$$

Logo:

$$L(\psi) = \prod_{i=1}^n \frac{1}{2\pi |F_t|^{1/2}} e^{-\frac{1}{2} \left[ v_t' F_t^{-1} v_t \right]}$$

$$\ell(\psi) = \log L(\psi)$$

$$= -n \log(2\pi) - \frac{1}{2} \sum_{i=1}^n \left( \log |F_t| + v_t' F_t^{-1} v_t \right)$$

→ usando inicialização Big kappa:

vamos computando o FK até dist. ficar próxima

Nº comp. n estác. = 1 ou 2 ?

$$\ell(\psi) = -(n-2) \log 2\pi - \frac{1}{2} \sum_{i=3}^n \left( \log |F_t| + v_t' F_t^{-1} v_t \right)$$

→ usando inicialização exata:

$$\ell(\psi) = -n \log 2\pi - \frac{1}{2} \sum_{t=1}^d w_t - \frac{1}{2} \sum_{t=d+1}^n \log |F_t| - \frac{1}{2} \sum_{t=d+1}^n v_t' F_t^{-1} v_t$$

— " —

$$\ell_d(\psi) = \lim_{k \rightarrow \infty} \left( \log L(\psi) + \frac{1}{2} \log k \right)$$

$$= \lim_{P_i \rightarrow \infty} \left( \log L(\psi) + \frac{1}{2} \log(P_i) \right)$$

$$= \lim_{P_i \rightarrow \infty} \left[ -n \log 2\pi - \frac{1}{2} \sum_{i=1}^n \left( \log |F_t| + v_t' F_t^{-1} v_t \right) + \frac{1}{2} \log(P_i) \right]$$

dividir

$$= \lim_{P_t \rightarrow \infty} \left[ -n \log 2\pi - \frac{1}{2} \log (|F_t| + v_t' F_t^{-1} v_t) + \frac{1}{2} \log P_t - \frac{1}{2} \sum_{t=2}^n (\log |F_t| + v_t' F_t^{-1} v_t) \right]$$

?

Fazendo a concentrações do PH:

$$\sum \eta = q \sum \varepsilon$$

Calcula  $F_t^*$  reparametrizado (e  $P_t^*$ )

(24)

Modelo SUTSE generalizado

Prove qd modelos de TIL <sup>+ado</sup> podem ser escritos

$$y_t = (z_t \otimes I_p) \alpha_t + \varepsilon_t$$

para  $p=2$

$$\alpha_{t+1} = (T_0 \otimes I_p) \alpha_t + (L_0 \otimes I_p) \eta_t$$

→ Modelo unidimensional

$$\begin{cases} y_t = \mu_t + \psi_t + \varepsilon_t \\ \mu_t = \mu_{t-1} + \beta_{t-1} + \eta_t \\ \beta_t = \beta_{t-1} + \zeta_t \\ \begin{pmatrix} \psi_t \\ \psi_t^* \end{pmatrix} = \rho \begin{pmatrix} \cos \lambda_c & \sin \lambda_c \\ -\sin \lambda_c & \cos \lambda_c \end{pmatrix} \begin{pmatrix} \psi_{t-1} \\ \psi_{t-1}^* \end{pmatrix} + \begin{pmatrix} \kappa_t \\ \kappa_t^* \end{pmatrix} \end{cases}$$

$$\Rightarrow y_t = (1 \ 0 \ 1 \ 0) \begin{pmatrix} \mu_t \\ \beta_t \\ \psi_t \\ \psi_t^* \end{pmatrix} + \varepsilon_t$$

$$\begin{pmatrix} \mu_t \\ \beta_t \\ \psi_t \\ \psi_t^* \end{pmatrix} = \begin{pmatrix} 1 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & \rho \cos \lambda_c & \rho \sin \lambda_c \\ 0 & 0 & -\rho \sin \lambda_c & \rho \cos \lambda_c \end{pmatrix} \begin{pmatrix} \mu_{t-1} \\ \beta_{t-1} \\ \psi_{t-1} \\ \psi_{t-1}^* \end{pmatrix} + \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} \eta_t \\ \zeta_t \\ \kappa_t \\ \kappa_t^* \end{pmatrix}$$

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 1 \end{pmatrix} \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \\ \beta_{1t} \\ \beta_{2t} \\ \gamma_{1t} \\ \gamma_{2t} \\ \gamma_{1t}^* \\ \gamma_{2t}^* \end{pmatrix}$$

...

(25) Prove que MNL SUTSE  $p=2$  pode ser reparametrizado como:

$$y_{1t} = \mu_{1t} + \varepsilon_{1t}$$

$$y_{2t} = \pi \mu_{1t} + \bar{\mu}_t + \varepsilon_{2t}$$

$$\mu_{1t} = \mu_{1t-1} + \eta_{1t}$$

$$\bar{\mu}_t = \bar{\mu}_{t-1} + \bar{\eta}_t$$

onde  $\Sigma_\eta = \text{diagonal}$

Seja SUTSE MNL  $p=2$ :

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} \quad \Sigma_\varepsilon = \begin{pmatrix} \sigma_{\varepsilon_1}^2 & \sigma_{\varepsilon_1 \varepsilon_2} \\ \sigma_{\varepsilon_1 \varepsilon_2} & \sigma_{\varepsilon_2}^2 \end{pmatrix}$$

$$\begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} = \begin{pmatrix} \mu_{1t-1} \\ \mu_{2t-2} \end{pmatrix} + \begin{pmatrix} \eta_{1t} \\ \eta_{2t} \end{pmatrix} \quad \Sigma_\eta = \begin{pmatrix} \sigma_{\eta_1}^2 & \sigma_{\eta_1 \eta_2} \\ \sigma_{\eta_1 \eta_2} & \sigma_{\eta_2}^2 \end{pmatrix}$$

Seja  $\eta_{2t} = \pi \eta_{1t} + \bar{\eta}_t$  onde  $\pi = \rho \frac{\sigma_{\eta_2}}{\sigma_{\eta_1}}$

$$\therefore \bar{\eta}_t = \eta_{2t} - \pi \eta_{1t}$$

$$\Rightarrow E[\bar{\eta}] = E[\eta_{2t}] - \pi E[\eta_{1t}] = 0$$

$$\begin{aligned} \bullet \text{var}(\bar{\eta}) &= E[(\eta_{2t} - \pi \eta_{1t})^2] \\ &= \sigma_{\eta_2}^2 + \pi^2 \sigma_{\eta_1}^2 - 2\pi \text{cov}(\sigma_{\eta_{1t}}, \sigma_{\eta_{2t}}) \\ &= \sigma_{\eta_2}^2 + \rho^2 \sigma_{\eta_2}^2 - 2\rho \sigma_{\eta_1} \sigma_{\eta_2} \\ &= \sigma_{\eta_2}^2 + \rho^2 \sigma_{\eta_2}^2 - 2\rho \frac{\sigma_{\eta_2}}{\sigma_{\eta_1}} \cdot \sigma_{\eta_1} \cdot \sigma_{\eta_2} \\ &= \sigma_{\eta_2}^2 (1 - \rho^2) \end{aligned}$$

$$\begin{aligned} \bullet \text{cov}[\eta_{1t}, \bar{\eta}] &= E[\eta_{1t} (\eta_{2t} - \pi \eta_{1t})] \\ &= -\pi \sigma_{\eta_{1t}}^2 + \text{cov}(\eta_{1t}, \eta_{2t}) \\ &= -\rho \sigma_{\eta_1} \sigma_{\eta_2} + \rho \sigma_{\eta_1} \sigma_{\eta_2} = 0 \end{aligned}$$

Definição  
 $\eta_{2t} = \pi \eta_{1t} + \bar{\eta}_t$   
 onde  
 $\pi = \rho \frac{\sigma_{\eta_2}}{\sigma_{\eta_1}}$

Calcule  
 $E[\bar{\eta}], \text{var}(\bar{\eta})$   
 e  $\text{cov}(\eta_{1t}, \bar{\eta})$

$$\text{Logo } \Sigma \eta_t \bar{\eta} = \begin{pmatrix} \sigma_{\eta_1}^2 & 0 \\ 0 & \sigma_{\eta_2}^2 (1 - \rho^2) \end{pmatrix}$$

Substitui  
 $\mu_{2t}$  no eq.  
 de estado

Temos ainda que:

$$\mu_{2t} = \mu_{2t-1} + \eta_{2t}$$

$$\therefore \mu_{2t} = \mu_{2t-1} + \bar{\eta}_t + \pi \eta_{1t}$$

$$\mu_{2t} = \mu_{2,t-1} + \bar{\eta}_t + \pi (\mu_{1,t} - \mu_{1,t-1})$$

$$\frac{\mu_{2t} - \pi \mu_{1,t}}{\bar{\mu}_t} = \frac{\mu_{2,t-1} - \pi \mu_{1,t}}{\bar{\mu}_{t-1}} + \bar{\eta}_t$$

$$\Rightarrow \boxed{\bar{\mu}_t = \bar{\mu}_{t-1} + \bar{\eta}_t}$$

Faz  
 $\mu_{2t} = \bar{\mu}_t + \pi \mu_{1t}$

Substitui na equação de observação de  $y_{2t}$ :

$$\boxed{y_{2t} = \pi \mu_{1t} + \bar{\mu}_t + \varepsilon_{2t}}$$

Logo:

$$\left\{ \begin{array}{l} y_{1t} = \mu_{1t} + \varepsilon_{1t} \\ y_{2t} = \pi \mu_{1t} + \bar{\mu}_t + \varepsilon_{2t} \\ \mu_{1t} = \mu_{1,t-1} + \eta_{1t} \\ \bar{\mu}_t = \bar{\mu}_{t-1} + \bar{\eta}_t \end{array} \right. \quad \text{descorrelatados}$$

Por essa nova parametrização  $\Rightarrow$  + fácil explicitar  
 componentes  
 comuns.

(26) Prove que parametrizações (I) e (II) MML FOTSE são equivalentes, ou seja:

- (i) a estrutura de dependência dos  $y$ 's permanece inalterada
- (ii) a previsões dos  $y_t$ 's e a função de verossimilhança permanecem inalteradas.

Prova de (i)

Estrutura de dependência permanecer inalterada significa que a FAC é a mesma M as 2 parametrizações.

Tomemos a nova parametrização:

$$\begin{cases} y_{1t} = \mu_{1t} + \varepsilon_{1t} \\ y_{2t} = \pi \mu_{1t} + \bar{\mu}_t + \varepsilon_{2t} \\ \mu_{1t} = \mu_{1t-1} + \eta_{1t} \\ \bar{\mu}_t = \bar{\mu}_{t-1} + \bar{\eta}_t \end{cases}$$

seja  $\Delta y_{1t} = \eta_{1t} + \Delta \varepsilon_{1t} = \eta_{1t} + \varepsilon_{1t} - \varepsilon_{1t-1}$

$$\Delta y_{2t} = \pi \eta_{1t} + \bar{\eta}_t + \Delta \varepsilon_{2t} = \pi \eta_{1t} + \bar{\eta}_t + \varepsilon_{2t} - \varepsilon_{2t-1}$$

Para  $\Delta y_{1t}$ .  $\text{var}(\Delta y_{1t}) = \sigma_{\eta_1}^2 + \sigma_{\varepsilon_1}^2 + \sigma_{\varepsilon_1}^2 = \sigma_{\eta_1}^2 + 2\sigma_{\varepsilon_1}^2$

$$\cdot E[\Delta y_{1t}, \Delta y_{1t-1}] = E[(\eta_{1t} + \varepsilon_{1t} - \varepsilon_{1t-1})(\eta_{1t-1} + \varepsilon_{1t-1} - \varepsilon_{1t-2})]$$

$$\delta(1) = -\sigma_{\varepsilon_1}^2$$

$$\cdot E[\Delta y_{1t}, \Delta y_{1t-1}] = 0$$

$$\delta(k) = 0 \quad k \geq 2$$

Para  $\Delta y_{2t}$ .  $\text{var}(\Delta y_{2t}) = \pi^2 \sigma_{\eta_1}^2 + \sigma_{\bar{\eta}}^2 + 2\sigma_{\varepsilon_2}^2$

$$\cdot E[\Delta y_{2t}, \Delta y_{2t-1}] = -\sigma_{\varepsilon_2}^2$$

mas  $\sigma_{\bar{\eta}}^2 = \text{var}(\bar{\eta}) = \text{var}(\eta_{2t} - \pi \eta_{1t})$

$$= \sigma_{\eta_2}^2 + \pi^2 \sigma_{\eta_1}^2 - 2\pi \sigma_{\eta_1, \eta_2} = \sigma_{\eta_2}^2 + \rho^2 \frac{\sigma_{\eta_2}^2 \cdot \sigma_{\eta_1}^2}{\sigma_{\eta_1}^2} - 2\rho \frac{\sigma_{\eta_2} \cdot \sigma_{\eta_1} \cdot \rho}{\sigma_{\eta_1}} \rho$$

$$\Rightarrow \text{Var}[y_{2t}] = \sigma_{\eta_2}^2 + 2\sigma_{\varepsilon_2}^2$$

Podemos ainda calcular pelas 2 parametrizações:

$$\text{cov}(y_{1t}, y_{2t})$$

$$\begin{aligned} \rightarrow \text{cov}[y_{1t}, y_{2t}] &= \text{cov}[(\eta_{1t} + \varepsilon_{1t} - \varepsilon_{1t})(\eta_{2t} + \varepsilon_{2t} - \varepsilon_{2t})] \\ &= \sigma_{\eta_1 \eta_2} + 2\sigma_{\varepsilon_1 \varepsilon_2} \end{aligned}$$

ou

$$\begin{aligned} \text{cov}[y_{1t}, y_{2t}] &= \text{cov}[(\eta_{1t} + \varepsilon_{1t} - \varepsilon_{1t})(\pi\eta_{1t} + \bar{\eta}_t + \varepsilon_{2t} - \varepsilon_{2t-1})] \\ &= \pi\sigma_{\eta_1}^2 + 2\sigma_{\varepsilon_1 \varepsilon_2} \\ &= \rho \frac{\sigma_{\eta_1}^2 \cdot \sigma_{\eta_2}}{\sigma_{\eta_1}} + 2\sigma_{\varepsilon_1 \varepsilon_2} = \sigma_{\eta_1 \eta_2} + 2\sigma_{\varepsilon_1 \varepsilon_2} \end{aligned}$$

Prova de (ii) a

função de verossimilhança permanece inalterada.

Escrevendo as parametrizações na forma EE:

$$\textcircled{\text{I}} \quad \begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

$$\begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \mu_{1t-1} \\ \mu_{2t-1} \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \eta_{1t} \\ \eta_{2t} \end{pmatrix}$$

$$\textcircled{\text{II}} \quad \begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ \pi & 1 \end{pmatrix} \begin{pmatrix} \mu_{1t} \\ \bar{\mu}_t \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

$$\begin{pmatrix} \mu_{1t} \\ \bar{\mu}_t \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \mu_{1t-1} \\ \bar{\mu}_{t-1} \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \eta_{1t} \\ \bar{\eta}_t \end{pmatrix}$$



→ Função de verossimilhança p/ modelo (I)

$$L(\psi) = \prod_{t=1}^n p(y_{1t}, y_{2t} | y_{t-1})$$

↓  
função densidade de probabilidade da Normal bivariada

$$\frac{1}{(2\pi)|F_t|^{1/2}} \exp \left\{ -\frac{1}{2} v_t F_t^{-1} v_t \right\}$$

$$\text{onde } v_t = y_t - z_t \alpha_{t-1}$$

$$F_t = z_t \rho_t z_t' + H \quad (z = I) \\ = \rho_t + H$$

$$\Rightarrow \ell(\psi) = \log L(\psi)$$

$$= \sum_{t=1}^n \left[ -\log 2\pi - \frac{1}{2} \log |F_t| - \frac{1}{2} v_t F_t^{-1} v_t \right]$$

$$= -n \log 2\pi - \frac{1}{2} \sum_{t=1}^n (\log |F_t| + v_t F_t^{-1} v_t)$$

• Observações sobre inicializações

- Se usarmos inicializações difusa por big kappa, como há uma componente nas stac. relacionada ao nível, devemos calcular o FK mas considerar em  $L(t)$  apenas quando diff. se tornar própria.  
Nesse caso, na  $L(\psi)$ , temos  $t=2$  a  $n$

$$\ell(\psi) = -(n-1) \log 2\pi - \frac{1}{2} \sum_{t=1}^n (\log |F_t| + v_t F_t^{-1} v_t)$$

- Se usarmos inicializações difusa exata, a  $L(\psi)$  é computada desde  $t=1$  porém o FK é usado diferentemente: FK exato até  $F_{0,t} = 0$ . Isso ocorrerá em  $d=2$  (quando ultrapassar  $n^2$  comp. n stac.). Nesse caso:

$$\ell(\psi) = -n \log 2\pi - \frac{1}{2} \sum_{t=1}^n (\log |F_t| + v_t F_t^{-1} v_t)$$

• O vetor de estado da nova p. é uma transf. n singular de vetor de estado da p. original

$$\begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} = \underbrace{\begin{pmatrix} 1 & 0 \\ -\pi & 1 \end{pmatrix}}_B \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix}$$

$$\therefore \alpha_t^* = B \alpha_t \text{ e } \det B \neq 0.$$

a original	da nova
$y_t = z \alpha_t + \varepsilon_t$	$y_t = z^* \alpha_t^* + \varepsilon_t$
$\alpha_t = T \alpha_{t-1} + R \eta_t$	$\alpha_t^* = T \alpha_{t-1}^* + R^* \eta_t^*$

$$\Rightarrow z \alpha_t + \varepsilon_t = z^* \alpha_t^* + \varepsilon_t$$

$$\text{Como } \alpha_t^* = B \alpha_t$$

$$\Rightarrow z = z^* B \therefore z^* = z B^{-1} \\ \therefore z^* = B^{-1}$$

Para o modelo (II) temos:

$$l^*(\Psi) = -n \log 2\pi - \frac{1}{2} \sum_{t=1}^n (\log |F_t^*| + v_t^* F_t^{*-1} v_t^*)$$

Calculamos a nova parametrização:

$$\rightarrow v_t^* = y_t - z^{*'} a_t^* \quad \text{onde } a_t^* = B a_t$$

$$= y_t - \begin{pmatrix} 1 & 0 \\ \pi & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ -\pi & 1 \end{pmatrix} a_t$$

$$= y_t - \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} a_t = y_t - a_t = v_t$$

$$\rightarrow F_t^* = z^{*'} P_t^* z^{*'} + H$$

ou seja como  $\alpha_t^* = B \alpha_t$

$$\begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ -\pi & 1 \end{pmatrix} \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix}$$

$$\Rightarrow a_t^* = E[\alpha_t^*] = B a_t$$

$$\text{var}[a_t^*] = \text{var}[B a_t] = B P_t B'$$

Nesse caso:  $z^* = B^{-1}$

$$\Rightarrow F_t^* = B^{-1} B P_t (B^{-1} B^{-1})' + H_t$$

$$= P_t + H_t = F_t$$

Logo, como  $v_t$  e  $F_t$  são iguais a  $v_t^*$  e  $F_t^*$ , a função de verossimilhança é a mesma.

Prova de (ii) b

função de previsões permanece inalterada.

$$\hat{y}_{t+k|t} = E[y_{t+k} | \tilde{y}_t]$$

→ Para parametrização original

$$\begin{aligned}\hat{y}_{t+k|t} &= E[2\alpha_{t+k} + \varepsilon_{t+k} | \tilde{y}_t] \\ &= 2\alpha_{t+k|t}\end{aligned}$$

No modelo em questão  $2 = I$

$$\alpha_t = \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} = \begin{pmatrix} \mu_{1,t-1} \\ \mu_{2,t-1} \end{pmatrix} + \begin{pmatrix} \eta_{1,t-1} \\ \eta_{2,t-1} \end{pmatrix}$$

$$\Rightarrow \text{Para } \mu_{1t} : \mu_{1,t+1} = \mu_{1t} + \eta_{1,t+1}$$

$$\mu_{1,t+2} = \mu_{1,t+1} + \eta_{1,t+2} = \mu_{1t} + \eta_{1,t+1} + \eta_{1,t+2}$$

$$\vdots$$

$$\mu_{1,t+k} = \mu_{1t} + \sum_{i=1}^k \eta_{1,t+i}$$

$$\therefore E[\mu_{1,t+k} | \tilde{y}_t] = \mu_{1,t}$$

$$\text{Logo: } \begin{pmatrix} \hat{y}_{1,t+k|t} \\ \hat{y}_{2,t+k|t} \end{pmatrix} = \begin{pmatrix} \hat{\mu}_{1,t|t} \\ \hat{\mu}_{2,t|t} \end{pmatrix}$$

→ Para nova parametrização

$$\hat{y}_{t+k|t} = E[2^* \alpha_{t+k}^* + \varepsilon_{t+k} | \tilde{y}_t] \quad \text{onde } 2^* = B$$

$$= \underbrace{\begin{pmatrix} 1 & 0 \\ \pi & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ -\pi & 1 \end{pmatrix}}_I \alpha_{t+k|t}$$

ou, desenvolvendo:

$$\hat{y}_{t+k|t} = \begin{pmatrix} 1 & 0 \\ \pi & 1 \end{pmatrix} \alpha_{t+k|t}^*$$

Calculando  $\alpha_{t+k|t}^*$

$$\Rightarrow \alpha_{t+k|t}^* = E \left[ \begin{pmatrix} \mu_{t+k} \\ \bar{\mu}_{t+k} \end{pmatrix} \mid \underline{y}_t \right]$$

No MNL:

$$\mu_{t+k|t} = \mu_{t|t}$$

$$\bar{\mu}_{t+k|t} = \bar{\mu}_{t|t}$$

$$\Rightarrow \begin{pmatrix} \hat{y}_{1t+k|t} \\ \hat{y}_{2t+k|t} \end{pmatrix} = \begin{pmatrix} \mu_{t|t} \\ \pi \mu_{t|t} + \bar{\mu}_{t|t} \end{pmatrix}$$

Da definição:  $\bar{\mu}_t = \bar{\mu}_{2t} - \pi \mu_{1t}$

$$\therefore \bar{\mu}_{t|t} = \bar{\mu}_{2t|t} + \pi \mu_{1t|t}$$

$$\Rightarrow \begin{pmatrix} \hat{y}_{1t+k|t} \\ \hat{y}_{2t+k|t} \end{pmatrix} = \begin{pmatrix} \mu_{1t|t} \\ \mu_{2t|t} \end{pmatrix} \text{ de forma que a previsão é a mesma.}$$

Genericamente

→ Enxere modelos na FEE

→ Faz equivalência entre  $y_t$  dos 2 modelos

$$\Rightarrow z\alpha_t = z^*\alpha_t^* \therefore z\alpha_t = z^*B\alpha_t \therefore \boxed{z^* = zB^{-1}}$$

→ Calcula  $a_t^*$  e  $p_t^*$  como funções de  $a_t, p_t$

$$\Rightarrow a_t^* = Ba_t$$

$$p_t^* = Bp_t B'$$

→ Pl minimizilhanga, mostra que  $\hat{x}_t^* = \hat{x}_t$  e  $v_t^* = v_t$

→ Pl previsas: mostra que  $E[z^*\alpha_{t+k}^* + \varepsilon_{t+k} \mid \underline{y}_t] =$   
 $= E[z\alpha_{t+k} + \varepsilon_{t+k} \mid \underline{y}_t]$

(27) Dada a nova parametrização, calcule a variância de  $\sigma_{\eta}^2$  e mostre que as variáveis  $\eta_{1t}$  e  $\eta_{2t}$  foram perfeitamente correlacionadas  $\Rightarrow$  haverá apenas uma tendência comum.

ou seja, se  $\rho = \pm 1 \Rightarrow \bar{\mu}_t = \text{cte.}$

nova parametrização

$$\begin{cases} y_{1t} = \mu_{1t} + \varepsilon_{1t} \\ y_{2t} = \pi \mu_{1t} + \bar{\mu}_t + \varepsilon_{2t} \\ \mu_{1t} = \mu_{1t-1} + \eta_{1t} \\ \bar{\mu}_t = \bar{\mu}_{t-1} + \bar{\eta}_t \end{cases}$$

$$\begin{aligned} \bar{\eta}_t = \eta_{2t} - \pi \eta_{1t} \quad \therefore \quad \sigma_{\bar{\eta}}^2 &= \sigma_{\eta_2}^2 + \pi^2 \sigma_{\eta_1}^2 - 2\pi \sigma_{\eta_1, \eta_2} \\ &= \sigma_{\eta_2}^2 + \rho^2 \frac{\sigma_{\eta_2}^2}{\sigma_{\eta_1}^2} \cdot \sigma_{\eta_1}^2 - 2\rho \frac{\sigma_{\eta_2}}{\sigma_{\eta_1}} \cdot \rho \sigma_{\eta_1} \sigma_{\eta_2} \\ &= \sigma_{\eta_2}^2 (1 - \rho^2) \end{aligned}$$

$$\text{Se } \rho = \pm 1 \Rightarrow \sigma_{\bar{\eta}}^2 = 0.$$

$$\bar{\mu}_t = \bar{\mu}_{t-1} = \bar{\mu}$$

$$\Rightarrow y_{1t} = \mu_{1t} + \varepsilon_{1t}$$

$$y_{2t} = \pi \mu_{1t} + \bar{\mu} + \varepsilon_{2t}$$

$$\mu_{1t}^+ = \mu_{1t-1}^+ + \eta_{1t}$$

obs: Se  $\pi = 1 \Rightarrow$  diferença de tendências cte =  $\bar{\mu}$   
Modelo de balance growth.

Se  $\bar{\mu} = 0 \Rightarrow$  tendências idênticas.

(28) Defina co-integração:

Processo  $p$ -variado co-integrado de ordens  $d$  e  $b$

se  $\Rightarrow$  (a)  $y_{jt} \sim I(d)$ : todas as séries são integradas na mesma ordem  $d$

(b)  $\exists \alpha \neq 0$  tal que

$\alpha' y_t \sim I(d-b)$ : combinação linear apresenta ordem de integração  $< d$

Ex: se todas as séries são  $I(1) \Rightarrow \exists \alpha$  tal que  $\alpha' y \sim I(0)$

(29) Mostre que no modelo reparametrizado com  $\rho = 1$  as séries são co-integradas.

$$\begin{cases} y_{1t} = \mu_t^+ + \varepsilon_{1t} \\ y_{2t} = \pi \mu_t^+ + \bar{\mu} + \varepsilon_{2t} \\ \mu_t^+ = \mu_{t-1}^+ + \eta_t^+ \end{cases}$$

•  $y_{1t} = \mu_t^+ + \varepsilon_{1t}$  — as estacionárias

$$\begin{aligned} \therefore \Delta y_{1t} &= \Delta \mu_t^+ + \Delta \varepsilon_{1t} \\ &= \eta_t^+ + \Delta \varepsilon_{1t} \end{aligned}$$

$$\bullet y_{2t} = \pi \mu_t^+ + \bar{\mu} + \varepsilon_{2t}$$

$$\therefore \Delta y_{2t} = \pi \eta_t^+ + \Delta \varepsilon_{2t}$$

$$\bullet \alpha' y = \alpha_1 y_1 + \alpha_2 y_2$$

$$= \alpha_1 \mu_t^+ + \alpha_1 \varepsilon_{1t} + \alpha_2 \pi \mu_t^+ + \alpha_2 \varepsilon_{2t} \quad (\bar{\mu})$$

Se escolhermos  $\alpha_1 = -\pi$  e  $\alpha_2 = 1$

$$\Rightarrow \alpha' y = -\pi \varepsilon_{1t} + \varepsilon_{2t} \quad (\bar{\mu}) \sim \text{estacionária.}$$

Logo:  $\rho = 1$  é cond. suficiente p/ séries co-integradas.

obs:

No modelo II  $\rho = 1$

$$\begin{cases} y_{1t} = \mu_t^+ + \varepsilon_{1t} \\ y_{2t} = \pi \mu_t^+ + \bar{\mu}_t + \varepsilon_{2t} \\ \mu_t^+ = \mu_{t-1}^+ + \eta_t^+ \\ \bar{\mu}_t = \bar{\mu}_{t-1} + \bar{\eta}_t \end{cases}$$

$$\begin{cases} \Delta y_{1t} = \eta_t^+ + \Delta \varepsilon_{1t} \\ \Delta y_{2t} = \pi \eta_t^+ + \bar{\eta}_t + \Delta \varepsilon_{2t} \end{cases}$$

$$\alpha_1 y_1 + \alpha_2 y_2 = \alpha_1 \mu_t^+ + \alpha_1 \varepsilon_{1t} + \alpha_2 \pi \mu_t^+ + \alpha_2 \bar{\mu}_t + \alpha_2 \varepsilon_{2t}$$

↓

Se  $\alpha_1 = -\pi$  e  $\alpha_2 = 1$ , ainda fica  $\bar{\mu}_t$  que é m está c.

Nas garantimos  $\alpha' y_t \sim I(0)$

— " —

De forma equivalente ao modelo II e  $\rho = 1$ , podemos escrever

$$\begin{aligned} y_{1t} &= \mu_t^+ + \varepsilon_{1t} \\ y_{2t} &= \pi y_{1t} + \bar{\mu} + \bar{\varepsilon}_t \rightarrow \varepsilon_{1t} + \varepsilon_{2t} \end{aligned}$$

(30) Modelo de nível local multivariado.

Escrever modelo instável, fazer nova parametrização e rotações

(I)  
Modelo  
de instabilidades

$$\begin{cases} y_t = \mu_t + \varepsilon_t \\ \mu_t = \mu_{t-1} + \eta_t \end{cases}$$

$$\varepsilon_t \sim N(0, \Sigma_\varepsilon)$$

$$\eta_t \sim N(0, \Sigma_\eta)$$

obs

para saber se há componentes comuns, olha o posto de  $\Sigma_\eta$

(No caso de  $p=2$ , se  $\rho=1$ )

$$\text{pois } \sigma_\eta^2 = \sigma_{\varepsilon_2}^2 (1 - \rho^2)$$

$$\text{se } \rho = +1 \rightarrow \sigma_\eta^2 = 0$$

## (II) Modelo reparametrizado

obs: No caso  $p=2$ , escrevemos  $\eta_2$  em função de  $\eta_1$ .

Aqui, fazemos uma partição de  $k \times p-k$  séries.

$$\begin{aligned} \begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} &= \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} \\ \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} &= \begin{pmatrix} \mu_{1,t-1} \\ \mu_{2,t-1} \end{pmatrix} + \begin{pmatrix} \eta_{1t} \\ \eta_{2t} \end{pmatrix} \end{aligned}$$

Faremos transformações nas seguintes de  $\alpha_t = \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix}$

$$\text{Seja: } \bar{\mu}_t = \mu_{2t} - \pi \mu_{1t}$$

$$(\bar{\mu}_t + \bar{\eta}_t) = (\mu_{2,t-1} + \eta_{2t}) - \pi (\mu_{1,t-1} + \eta_{1,t-1})$$

$$\Rightarrow \bar{\eta}_t = \eta_{2t} - \pi \eta_{1t}$$

Podemos escrever:

$$\begin{pmatrix} \mu_{1t} \\ \bar{\mu}_t \end{pmatrix} = \underbrace{\begin{pmatrix} I_k & 0 \\ -\pi & I_n \end{pmatrix}}_L \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} \quad \text{onde } n = p-k$$

$$\alpha_t^* = L \alpha_t$$

Podemos escrever:

$$\begin{cases} y_{1t} = \mu_{1t} + \varepsilon_{1t} \\ y_{2t} = \pi \mu_{1t} + \bar{\mu}_t + \varepsilon_{2t} \\ \mu_{1t} = \mu_{1,t-1} + \eta_{1t} \\ \bar{\mu}_t = \bar{\mu}_{t-1} + \bar{\eta}_t \end{cases}$$



$$\begin{pmatrix} y_{1t} \\ y_{2t} \\ \tilde{y}_{1t} \\ \tilde{y}_{2t} \end{pmatrix} = \begin{pmatrix} I_k & 0 \\ \pi & I_n \end{pmatrix} \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \\ \tilde{\mu}_{1t} \\ \tilde{\mu}_{2t} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \\ \tilde{\varepsilon}_{1t} \\ \tilde{\varepsilon}_{2t} \end{pmatrix}$$

$$\begin{pmatrix} \mu_{1t} \\ \mu_{2t} \\ \tilde{\mu}_{1t} \\ \tilde{\mu}_{2t} \end{pmatrix} = \begin{pmatrix} \mu_{1t-1} \\ \mu_{2t-1} \\ \tilde{\mu}_{1t-1} \\ \tilde{\mu}_{2t-1} \end{pmatrix} + \begin{pmatrix} \eta_{1t} \\ \eta_{2t} \\ \tilde{\eta}_{1t} \\ \tilde{\eta}_{2t} \end{pmatrix}$$

Queremos:  $\mu_{1t}$  e  $\mu_{2t}$  descorrelatados

$$\Sigma_{\eta} = \begin{pmatrix} \Sigma_{\eta_1} & 0 \\ 0 & \Sigma_{\eta_2} \end{pmatrix}$$

Do modelo original

$$\Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}$$

Definimos:  $\tilde{\eta}_t = \eta_{2t} - \pi \eta_{1t}$

$$\begin{aligned} \text{cov}(\tilde{\eta}_t, \eta_{1t}) &= \text{cov}((\eta_{2t} - \pi \eta_{1t}) \eta_{1t}) \\ &= \text{cov}(\eta_{2t} \eta_{1t}) - \pi \text{var}(\eta_{1t}) \\ &= \Sigma_{21} - \pi \Sigma_{11} = 0 \quad \therefore \pi \Sigma_{11} = \Sigma_{21} \\ &\quad \pi = \Sigma_{21} \Sigma_{11}^{-1} \end{aligned}$$

$$\eta^* = L \eta$$

$$\therefore \text{cov}(\eta^*) = L \text{cov}(\eta) L'$$

$$= \begin{pmatrix} I_k & 0 \\ -\pi & I_n \end{pmatrix} \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix} \begin{pmatrix} I_k & -\pi' \\ 0 & I_n \end{pmatrix}$$

$$= \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \pi \Sigma_{11} + \Sigma_{21} & -\pi \Sigma_{12} + \Sigma_{22} \end{pmatrix} \begin{pmatrix} I_k & -\pi' \\ 0 & I_n \end{pmatrix}$$

$$= \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ 0 & -\pi \Sigma_{12} + \Sigma_{22} \end{pmatrix} \begin{pmatrix} I_k & -\pi' \\ 0 & I_n \end{pmatrix} = \begin{pmatrix} \Sigma_{11} & -\pi' \Sigma_{11} + \Sigma_{12} \\ 0 & -\pi \Sigma_{12} + \Sigma_{22} \end{pmatrix}$$

$$\text{mas } -\pi \Sigma_{12} + \Sigma_{22} = -\Sigma_{21} \Sigma_{11}^{-1} \Sigma_{12} + \Sigma_{22} = \Sigma_{\bar{\eta}}$$

Reparametrizações:

$$\begin{cases} \tilde{y}_{1t} = \tilde{\mu}_t^+ + \tilde{\varepsilon}_{1t} \\ \tilde{y}_{2t} = \pi \tilde{\mu}_t^+ + \bar{\mu}_t + \tilde{\varepsilon}_{2t} \\ \tilde{\mu}_t^+ = \tilde{\mu}_{t-1}^+ + \eta_t^+ \\ \bar{\mu}_t = \bar{\mu}_{t-1} + \bar{\eta}_t \end{cases} \quad \text{onde} \quad \begin{aligned} \eta_t^+ &\sim N(0, \Sigma_{\eta^+}) & \Sigma_{\eta^+} &= \Sigma_{11} \\ \bar{\eta}_t &\sim N(0, \Sigma_{\bar{\eta}}) & \Sigma_{\bar{\eta}} &= \Sigma_{22} - \Sigma_{21} \Sigma_{11}^{-1} \Sigma_{12} \end{aligned}$$

$$\text{cov} \begin{pmatrix} \eta^+ \\ \bar{\eta} \end{pmatrix} = \begin{pmatrix} \Sigma_{\eta^+} & 0 \\ 0 & \Sigma_{\bar{\eta}} \end{pmatrix}$$

$$\text{Se posto } \Sigma_{\eta} = k < p \Rightarrow \begin{cases} \mu_t^+ \text{ contém } k \text{ comp. comuns} \\ \Sigma_{\bar{\eta}} = 0 \end{cases}$$

Atenções!

$$\text{Se posto } \Sigma_{\eta} = k < p \Rightarrow \Sigma_{\bar{\eta}} = 0.$$

Posto da matriz = n.º autovalores  $\neq 0$  nulos.

$$\Sigma_{\eta} = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}$$

$$\Rightarrow \Sigma_{\eta} = P \Lambda P'$$

$$\Lambda = \begin{pmatrix} \Sigma_{11} & 0 \\ 0 & \Sigma_{22} - \Sigma_{21} \Sigma_{11}^{-1} \Sigma_{12} \end{pmatrix}$$

$$\text{Se posto } \Sigma_{\eta} = 0 \Rightarrow \underbrace{\Sigma_{22} - \Sigma_{21} \Sigma_{11}^{-1} \Sigma_{12}}_{\Sigma_{\bar{\eta}}} = 0.$$

$$\Rightarrow \text{Se } \Sigma_{\bar{\eta}} = 0 \Rightarrow \bar{\mu}_t = \bar{\mu}_{t-1}$$

$\Rightarrow$  apenas  $\mu_t^+$  evolui no tempo:  $k$  com  $p$  comuns.

Na prática, há vários ME possui componentes comuns

$\Rightarrow$  obter  $\Sigma_\eta$  e não se passa e' deis

### (31) Modelos Rotacionados

Do modelo reparametrizado, temos:

$$\tilde{y}_t = \begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} I_K \\ \pi \end{pmatrix} \mu_t^+ + \begin{pmatrix} 0 \\ \bar{\mu} \end{pmatrix} + \varepsilon_t$$

$$\mu_t^+ = \mu_{t-1}^+ + \eta_t^+ \quad \text{onde } \eta_t^+ \sim \text{NID}(0, \Sigma_{\eta}^+)$$

$\downarrow$

$$\mu_t^* = \Sigma_{\eta}^{+1/2} \cdot \mu_t^+$$

$$\Rightarrow \mu_t^* = \mu_{t-1}^* + \eta_t^* \quad \text{onde } \eta_t^* \sim \text{NID}(0, I)$$

Para  $y_t$  de observações temos

$$\begin{pmatrix} \tilde{y}_{1t} \\ \tilde{y}_{2t} \end{pmatrix} = \begin{pmatrix} I_K \\ \pi \end{pmatrix} \Sigma_{\eta}^{+1/2} \mu_t^* + \begin{pmatrix} 0 \\ \bar{\mu} \end{pmatrix} + \varepsilon_t$$

$$= \underbrace{\begin{pmatrix} \Sigma_{\eta}^{+1/2} \\ \pi \Sigma_{\eta}^{+1/2} \end{pmatrix}}_{\textcircled{1}} \mu_t^* + \underbrace{\begin{pmatrix} 0 \\ \bar{\mu} \end{pmatrix}}_{\mu_0} + \varepsilon_t \quad \text{onde } \mu_t^* \sim N(0, I)$$

Para  $p=2$

$$\mu_t^+ = \mu_{t-1}^+ + \eta_t^+$$

$$\mu_t^* = \frac{\mu_t^+}{\sigma_{\eta^+}}$$

$$\Rightarrow \mu_t^* = \mu_{t-1}^* + \eta_t^*$$

onde  $\eta_t^* \sim N(0, 1)$

Para  $y_t$ , temos

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} \sigma \\ \pi \sigma \end{pmatrix} \mu_t^* + \begin{pmatrix} 0 \\ \bar{\mu} \end{pmatrix} + \varepsilon_t$$

