

Forma | Modelo em Espaço de Estado (terminologia)

↓ problema real descrito
por equações matemáticas
↓
arabauco

podem ser colocados em Modelos E-E

- ARMA
- ARIMA
- VARMA
- REGRESSÃO (S/n, etc.)

Estado → ideia veio da Física

conjunto mínimo de info. p. descrever sistema de forma completa.

ex: Na mecânica → dois eixos p. descrever o sistema: posição e velocidade
(x, y, z) (v_x, v_y, v_z)

Na Termodin. → temperatura, pressão, velocidade
(T, P, V)


Em particular, origem está no processamento de sinais

$y_t = \theta_t + \epsilon_t$
recebe "mensagem" erro (ruído)
↓
não observado


Como, observando y_t , podemos filtrar a msg. θ_t ?

O que interessa, a "mensagem", é não observada

Ex: observando uma série de tempo



ou



(comportamento
em pouco + ruído)

$T_t + S_t$

componentes sa
estocásticas.

$$y_t = T_t + S_t + I_t$$

$$T_t = a + bt$$

$$S_t = \sum_{j=1}^n \delta_j \cdot D_{jt}, \quad D_{jt} = \begin{cases} 1 & j=t \\ 0 & j \neq t \end{cases} \quad (\text{dummy ou} \\ \text{senos e cossenos})$$

$$I_t = \varepsilon_t \sim N(0, \sigma^2) \quad \text{ruído branco}$$

$$y_t = (a + bt) + \left(\sum_{j=1}^n \delta_j D_{jt} \right) + \varepsilon_t \quad : \text{é um modelo de regressão} \\ \text{particular de } y_t = \beta_0 + \beta_1 x_{1t} + \beta_2 x_{2t} + \dots + \beta_p x_{pt} + \varepsilon_t$$

↳ como estimamos este modelo?

precisamos: conjunto de observações $\{y_t\}_{t=1}^T$

+ método (de estimação)

⇒ MQO (primeiro método que pensamos)

vetor de parâmetros desconhecidos: $\Psi = (a, b, \delta_1, \delta_2, \dots, \delta_n, \sigma^2)$

(a serem estimados)

função objetivo

$$S(\Psi^*) = \sum_{t=1}^T (y_t - \hat{y}_t)^2 = \sum_{t=1}^T (y_t - [(a+bt) + \sum_{j=1}^n \delta_j D_{jt}])^2$$

onde $\Psi^* = \{\Psi\} = \sigma^2$

↳ pois não conseguimos estimar σ^2 , já que não aparece na função objetivo

Ψ^* tal que $\min S(\Psi^*)$

$$-\frac{\partial S}{\partial \Psi^*} = 0 \quad \therefore \left(\frac{\partial S}{\partial \Psi_1} \quad \frac{\partial S}{\partial \Psi_2} \quad \dots \quad \frac{\partial S}{\partial \Psi_p} \right)^T = 0^T$$

$$\hat{\Psi}^* = (X'X)^{-1} X'y \quad y = (y_1, \dots, y_T)^T$$

mas esta questão é questionável.

Componentes de séries reais não são normalmente determinísticas (por ex, séries macroeconômicas).

Ex: Série de desemprego

Componente sazonal determinística não é tão ruim
mas componente "tendência" é ruim

NO EViews y estimar: Quick

Equation Estimation

decomp-sp c @trend c nas(1) @nas(2) ... @nas(11)

(
ck tend.

a

b

dummies sazonais em relação
aos 12.

c

obs: deixamos todas as dummies de sazonalidade

mesmo que elas não sejam significativas

estatisticamente.

Obs: sazonalidade

Todas as dummies de mês + a + as gens

$$E[y^{dez}] = a + b t_{dez}$$

$$e E[\epsilon_t] = 0$$

$$E[y^{Jan}] = a + b t_{jan} + \gamma_i$$

$$\Delta^{Jan-dez} = E[y^{Jan}] - E[y^{dez}]$$

$$= b (t^{jan} - t^{dez}) + \gamma_i = b + \gamma_j$$

Para um mês qualquer:

$$\Delta^{mês_j, dez} = b_j + \gamma_j$$

$H_0: \gamma_j = 0 \rightarrow$ meses que não são estatisticamente significantes

$H_1: \gamma_j \neq 0$ (seria como trabalhar com uma lista de meses de referência: dez + todos os não significativamente $\neq 0$)

→ Para se ter a ideia de existência de ciclo, poderíamos olhar o erro da regressão em relação à tendência + à sazonalidade e verificar se há alguma repetição em períodos > 1 ano.

⇒ Modelo não é satisfatório.

Autocorrelação dos resíduos: há alguma não estacionariedade (é bem forte) no resíduo.

Tendência não é determinística como pensamos (é estocástica). Podemos até pensar a ver ciclos mais econômicos.

(obs: E-views não faz ajuste p/ tendência estocástica)

11

Ainda trabalhando com tendência e sazonalidade.

$$y_t = \underbrace{(a_t + b_t t)}_{I_t} + \underbrace{\sum_{j=1}^J D_{jt}}_{S_t} + \underbrace{\varepsilon_t}_{I_t}$$

¶ cada $t \Rightarrow$ parâmetro é diferente

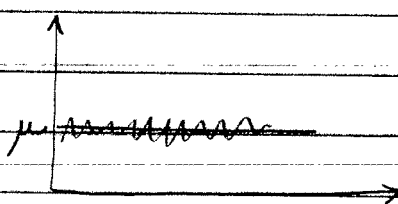
Propondo modelos onde constante tb saís função do tempo.

Modelos estruturais: modelos de regressão onde modelos explicativas e coeficientes saís função do tempo.

Supondo que estejamos trabalhando c/ séries anuais:
(n tem sazonalidade)

$$\begin{cases} y_t = a_t + b_t t + \varepsilon_t \\ a_t = " " \\ b_t = " " \end{cases} \rightarrow \text{mas } \forall \text{ cada } t = 1 \text{ a } T \text{ só teríamos 1 observação que } n \text{ permitiria estimar}$$

precisa colocar alguma estrutura p/ a_t e b_t .

$$\bullet y_t = \mu + \varepsilon_t \quad \Rightarrow \quad \hat{\mu} = \frac{1}{T} \sum_{i=1}^T y_t$$


(desincronante)

$$\bullet y_t = \mu_t + \varepsilon_t$$

↳ precisa propor processo de evolução de μ

$$\therefore \mu_t = \phi \mu_{t-1} + \eta_t \Rightarrow \text{processo estocástico que define evolução de } \mu$$

1) se $|\phi| < 1 \Rightarrow \text{AR}(1)$

Uilbra

como μ_t estacionário } y_t estacionário
e ε_t "

2) se $\phi = 1 \Rightarrow \mu_t \sim$ passeio aleatório
(não estacionário)

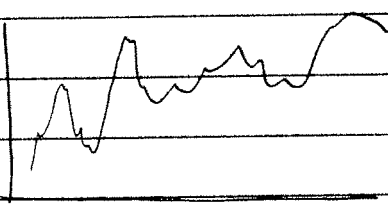
Neste caso $\Rightarrow y_t$ é não estacionário

Normalmente, usamos $\phi = 1$

Modelo de nível local
local level model

$$\begin{cases} y_t = \mu_t + \varepsilon_t \\ \mu_t = \mu_{t-1} + \eta_t \end{cases}$$

$\varepsilon_t \sim N(0, \sigma_\varepsilon^2)$
 $\eta_t \sim N(0, \sigma_\eta^2)$



o 1º modelo que caracteriza tendência estocástica.

A função de previsões deste modelo é um EWMA (método de amortecimento exponencial)

$$\hat{y}_{t+1|t} = E[y_{t+1} | y_t] = \lambda y_t + (1 - \lambda) \hat{y}_{t|t-1} \quad 0 < \lambda < 1$$

É um esquema, um método de previsões (com amortecimento) de séries de sazonalidade exponencial

obs 1: λ são funções dos parâmetros do Filtro de Kalman

obs 2: $\lim_{t \rightarrow \infty} \lambda_t \rightarrow \bar{\lambda}$

obs 3: se $\sigma_\eta^2 \rightarrow 0$: $\mu_t \rightarrow \mu_{t-1}$
Modelo tende à tendência determinística como caso particular

outros modelos: (tb q sazonalidade, apenas tendência)

Tendência
linear
local

$$y_t = \mu_t + \varepsilon_t \rightarrow \varepsilon_t \sim N(0, \sigma_\varepsilon^2)$$

$$\mu_t = \mu_{t-1} + \beta_{t-1} + \eta_t \rightarrow \eta_t \sim (0, \gamma^2) : \mu_t \text{ já é a tendência}$$

$$\beta_t = \beta_{t-1} + \zeta_t \rightarrow \zeta_t \sim N(0, \beta^2) : \text{passos aleatórios}$$

algo que compõe a tendência

outras notações $y_t = \mu_t + \varepsilon_t$

\Rightarrow NO Koopman

$$\mu_{t+1} = \mu_t + \beta_t + \eta_t$$

aparece assim.

$$\beta_{t+1} = \beta_t + \zeta_t$$

Fórmulas do FK

nas mudanças

Dois caminhos q verificam o modelo:
(testar)

Análítico

Empírico (por simulação)

A partir deste modelo, podemos gerar vários casos particulares.


$$1) \sigma_\eta^2 = \sigma_\zeta^2 = 0 \Rightarrow \mu_t = \mu_{t-1} + \beta_0$$

$$\mu_t = \mu_0 + \beta_0 t \text{ (tirando)}$$

$$\therefore y_t = \mu_0 + \beta_0 t + \varepsilon_t \Rightarrow \text{tendência linear}$$

ou: tendência determinística \Rightarrow chamada global

" estocástica \Rightarrow " local



modelo com racionalidade e ciclo

$$y_t = \mu_t + \delta_t + \psi_t + \varepsilon_t \quad \Rightarrow \text{equações da medida}$$

$$\left\{ \begin{array}{l} \mu_t = \dots \\ \delta_t = \dots \\ \psi_t = \dots \end{array} \right\} \quad \begin{array}{l} \text{equações} \\ \text{dos estados} \end{array}$$

obs: como estimar os parâmetros?

MPO pressupõe parâmetros fixos no tempo.

Neste caso, os parâmetros fixos são chamados de hiperparâmetros.

¶ estimar hiperparâmetros \Rightarrow MPO

¶ estimar parâmetros variáveis \Rightarrow Filtro de Kalman

Mas ¶ usar FK precisamos de hiperparâmetros e ¶
estimar hiperparâmetros, precisamos de FK.

— " —

Definição de uma representação em espaço estado linear:

$$y_t = z_t \alpha_t + d_t + \varepsilon_t \quad (\text{espera-se } m \ll p)$$

\nearrow mais geral na literatura = o normalmente

\searrow choque

$\begin{matrix} p \times 1 & p \times m & m \times 1 & p \times 1 & p \times 1 \end{matrix}$

α_t : vetor de estado não observado.

$$\alpha_{t+1} = T_t \alpha_t + C_t + R_t \eta_t \quad \text{fundo + choques}$$

\nearrow mais flexibilidade na representação

$\begin{matrix} m \times 1 & n \times m & m \times 1 & m \times 1 & m \times n & n \times 1 \end{matrix}$

$$\varepsilon_t \sim WN(0, H_t)$$

$\begin{matrix} p \times 1 & p \times p \end{matrix}$

$$\eta_t \sim WN(0, Q_t)$$

$\begin{matrix} n \times 1 & n \times n \end{matrix}$

$$\alpha_1 \sim N(a_1, P_1)$$

especificar a_1 e P_1 : condições iniciais

Podemos considerar:

$$\begin{pmatrix} \varepsilon_t \\ \eta_t \end{pmatrix} \sim N \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} H_t & 0 \\ 0 & Q_t \end{pmatrix} \right) \quad \begin{array}{l} \text{de correlatos.} \\ \text{(da definição} \\ \text{do modelo)} \end{array}$$

Diremos também que:

$$E(\varepsilon_t \alpha_t^T) = 0$$

$$E(\eta_t \alpha_t^T) = 0$$

Dado modelo, precisaremos do algoritmo de estimação

(Filtro de Kalman).

Muitos modelos econométricos / ST podem ser colocados na forma EE (mas existe uma forma única)

se $\alpha_t^* = B\alpha_t$ onde $\det(B) \neq 0 \Rightarrow$ funções de verossimilhança será a mesma.

Ex.1: $y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$ (AR-2 sem drift, podemos ignorar c_t e d_t ;
mas apresentações:

$$1) y_t = \begin{pmatrix} 1 & 0 \end{pmatrix} \begin{pmatrix} y_t = \alpha_{1t} \\ \phi_2 y_{t-1} = \alpha_{2t} \end{pmatrix} \Rightarrow \begin{pmatrix} \alpha_{1t} \\ \alpha_{2t} \end{pmatrix} = \alpha_t \quad \begin{array}{l} \alpha_t: \text{vetor de estado} \\ \text{equações das medidas} \end{array}$$

$$\begin{pmatrix} y_{t+1} \\ \phi_2 y_t \end{pmatrix} = \begin{pmatrix} \phi_1 & 1 \\ \phi_2 & 0 \end{pmatrix} \begin{pmatrix} y_t \\ \phi_2 y_{t-1} \end{pmatrix} + \begin{pmatrix} 1 \\ 0 \end{pmatrix} \varepsilon_{t+1} \Rightarrow \begin{array}{l} \text{equações dos} \\ \text{estados} \end{array}$$

$\alpha_{t+1} \quad T \quad \alpha_t \quad R_t \quad \eta_t$

$$2) \quad y_t = (1 \quad 0) \begin{pmatrix} y_t \\ y_{t-1} \end{pmatrix} \quad \Rightarrow \text{equações das medidas}$$

tanto faz E_t, E_{t+1} pois processo é estacionário

$$\begin{pmatrix} y_{t+1} \\ y_t \end{pmatrix} = \begin{pmatrix} \phi_1 & \phi_2 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} y_t \\ y_{t-1} \end{pmatrix} + \begin{pmatrix} 1 \\ 0 \end{pmatrix} E_{t+1} \Rightarrow \text{equações dos estados}$$

$$\text{logo: } x_t^* = \begin{pmatrix} y_t \\ y_{t-1} \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1/\phi_2 \end{pmatrix} \begin{pmatrix} y_t \\ \phi_2 y_{t-1} \end{pmatrix}$$

estado da 2ª representação

onde $|B| = 1/\phi_2 \neq 0$.

estado da 1ª representação

- Quando colocamos uma equação em uma representação espaço de estado: entramos com vetores e parâmetros em um pacote computacional e pedimos q estimar o estado sequencialmente

\Rightarrow estimará parâmetros fixos através da verossimilhança (neste caso, ϕ_1, ϕ_2 e σ_E^2)

- Qualquer modelo AR pode ser estimado na forma de espaço de estado.

$$\text{Ex. 2: } y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + E_t \rightarrow \text{Modelo AR-P}$$

Raízes do polinômio

característico dentro círculo unitário

\Rightarrow processo estacionário

de 2ª ordem

$$\phi(l) = 1 - \phi_1 l + \phi_2 l^2 - \dots - \phi_p l^p \quad (\text{raízes fora do círculo})$$

$$\phi(z) = 1 - \phi_1 z^{-1} + \phi_2 z^{-2} - \dots - \phi_p z^{-p} \quad (\text{raízes dentro do círculo})$$

$$y_t = (1 \ 0 \ 0 \ \dots \ 0) \begin{pmatrix} y_t \\ y_{t-1} \\ y_{t-2} \\ \vdots \\ y_{t-p} \end{pmatrix} \xrightarrow{\alpha_t}$$

$$\alpha_{t+1} = T\alpha_t + A\eta_t$$

$$\begin{pmatrix} y_{t+1} \\ y_t \\ y_{t-1} \\ \vdots \\ y_{t+1-p} \end{pmatrix} = \underbrace{\begin{pmatrix} \phi_1 & \phi_2 & \phi_3 & \dots & 0 & 0 & \phi_p & 0 \\ 0 & 1 & 0 & \dots & 0 & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & \dots & \dots & \dots & 0 & \dots & \dots & \dots \\ 0 & \dots & \dots & \dots & 1 & 0 & \dots & \dots \end{pmatrix}}_I \begin{pmatrix} y_t \\ y_{t-1} \\ y_{t-2} \\ \vdots \\ y_{t-p} \end{pmatrix} + \begin{pmatrix} 1 \\ 0 \\ \vdots \\ \vdots \\ 0 \end{pmatrix} \epsilon_{t+1}$$

Ex 3) $y_t \sim MA(1)$

$$y_t = \theta \epsilon_{t-1} + \epsilon_t$$

$$\Rightarrow y_t = (1 \ 0) \begin{pmatrix} y_t \\ \theta \epsilon_t \end{pmatrix} \xrightarrow{\alpha_t}$$

$$\begin{pmatrix} y_{t+1} \\ \theta \epsilon_{t+1} \end{pmatrix} = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} y_t \\ \theta \epsilon_t \end{pmatrix} + \begin{pmatrix} 1 \\ \theta \end{pmatrix} \epsilon_{t+1}$$

$$\alpha_{t+1} = T\alpha_t + R_t\eta_t$$

Se conseguimos escrever AR e MA, conseguimos escrever um ARMA
(Exercício)

$$y_t = \phi y_{t-1} + \theta \varepsilon_{t-1} + \varepsilon_t$$

$$(y_{t+1} = \phi y_t + \theta \varepsilon_t + \varepsilon_{t+1})$$

$$a) y_t = \begin{bmatrix} 1 & 0 & 0 \end{bmatrix} \begin{bmatrix} y_t \\ \phi y_{t-1} \\ \theta \varepsilon_t \end{bmatrix}$$

cuidado com índice de ε_t H

exer as equações de espaço de estado.

3 elementos
tem que
representar
equações

$$\begin{bmatrix} y_{t+1} \\ \phi y_t \\ \theta \varepsilon_t \end{bmatrix} = \begin{bmatrix} \phi & 0 & 1 \\ \phi & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} y_t \\ \phi y_{t-1} \\ \theta \varepsilon_t \end{bmatrix} + \begin{bmatrix} 1 \\ 0 \\ \theta \end{bmatrix} \varepsilon_{t+1}$$

Ex. 4) Regressão múltipla

$$y_t = \beta_0 + \beta_1 x_{1t} + \beta_2 x_{2t} + \dots + \beta_p x_{pt} + \varepsilon_t$$

$$y_t = (1 \ x_{1t} \ x_{2t} \ \dots \ x_{pt}) \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_p \end{pmatrix} + \varepsilon_t$$



$$\begin{cases} y_t = x_t' \beta + \varepsilon_t \\ \beta_t = \beta_{t-1} \end{cases}$$

$$T_t = I, R_t = 0$$

Filtro de Kalman estimará β

$$y_t = \beta_0 + \beta_1 x_{1t} +$$

cont.



Se for tempo contínuo:
as invés de eq. de diferenças estocásticas,
teríamos sist. de equações diferenciais

com tempo discreto
q dist. gaussianas

16/03/11

Modelo Espaço de Estado Linear (MEE linear)

processo estocástico

que depende de

$$y_t = Z_t x_t + d_t + \epsilon_t$$

px1 pxm mx1

$$\epsilon_t \sim N(0, H_t)$$

pxp

obs: var explícita

de pode ser βx_t^T ou

$$x_{t+1} = T_t x_t + c_t + R_t \eta_t$$

mxm mxn nx1

nxn

$$\eta_t \sim N(0, Q_t)$$

equações de

evoluções

(de estado)

$$\begin{cases} E(\epsilon_t \epsilon_s') = 0 \\ E(\eta_t \eta_s') = 0 \end{cases} \quad \forall s, t$$

(ruídos brancos)

cond. inicial

$$x_1 \sim N(a_1, P_1)$$

$$E[\epsilon_t \eta_s'] = 0, \quad \forall t, s$$

$$E[\eta_t' x_s] = E[\epsilon_t' x_s] = 0 \quad \forall t$$

algo contínuo muitas vezes nas aplicações na fórmula, mas é mais geral

estado pode ter

interpretação direta

ou não (nos modelos, nem

nas tem, mas em modelos estruturais)

faz parte da

definição do modelo EE.

(a desconexão entre choques pode ser relaxada)

jamais pode ser nulo

idéia: colocar no formato EE e estimar parâmetros

olhar eqs. como processos estocásticos e estudar propriedades.

Propriedades dos modelos EE lineares a Tempo Discreto

(1) Estacionariedade de 2ª ordem

(2) Observabilidade

Definição: As matrizes $Z_t, d_t, H_t, T_t, c_t, R_t, Q_t$ são chamadas matrizes do sistema

Vamos assumir que algumas matrizes são invariantes no tempo

Isso não invalidará resultados do Filtro de Kalman.

Por hipótese, nas deduições subsequentes, o sistema será tido como homogêneo invariante no tempo.

ou seja, vamos abandonar o subscrito t das matrizes do sistema (pode ser relaxada para c_t e d_t)

ex: $C_t = \beta X_t$ se X_t for série estacionária de 2ª ordem (nas apta propriedade)

Ex: $y_t = \mu_t + \varepsilon_t \quad \varepsilon_t \sim N(0, \sigma_\varepsilon^2)$

} sistema invariante

$\mu_{t+1} = \phi \mu_t + \eta_t \quad \eta_t \sim N(0, \sigma_\eta^2)$ no tempo

(i) Estacionariedade de 2ª ordem

processo vetorial

Definição: um processo estocástico $z(t)$ é dito estacionário de 2ª ordem se satisfizer as seguintes condições:
e somente se

médias do vetor de médias é finita

(i) $E[z_t] = \mu \quad \forall t, \mu < \infty$

(ii) $E[(z_t - E[z_t])(z_{t+h} - E[z_{t+h}])'] = \Gamma(h) \quad \forall t, \forall h=0,1,2,\dots$

matriz de autocovariâncias de lag h

(se $h=0 \Rightarrow$ matriz de var/covar)

no depende de h

Utilizando as equações do MEE segue que:

CPD: $E[y_t] = \alpha E[x_t] + E[d_t]$

↓
depende
de $E[x_t]$

spg. faremos $d_t = 0$

mas podemos ter d_t de ou
até $d_t = \beta x_t$ (com variável
explicativa exógena) desde

que x_t seja série estacionária
de 2º ordem

CSO: $E[(y_t - E[y_t])(y_{t+h} - E[y_{t+h}])'] = \Gamma_y(h)$?

↓
Vamos estudar se é
verdade.

$$\begin{cases} y_t = \alpha x_t + \varepsilon_t \\ E[y_t] = \alpha E[x_t] \end{cases}$$

$$\Rightarrow y_t - E[y_t] = \alpha (x_t - E[x_t]) + \varepsilon_t$$

$$y_{t+h} - E[y_{t+h}] = \alpha (x_{t+h} - E[x_{t+h}]) + \varepsilon_{t+h}$$

E assim, segue que:

$$(y_t - E[y_t])(y_{t+h} - E[y_{t+h}])' =$$

$$= [\alpha (x_t - E[x_t]) + \varepsilon_t] [(x_{t+h} - E[x_{t+h}])' \alpha' + \varepsilon_{t+h}'] =$$

$$= \alpha (x_t - E[x_t])(x_{t+h} - E[x_{t+h}])' \alpha' + \alpha (x_t - E[x_t]) \varepsilon_{t+h}' +$$

valor esperado cruzado x' d' Γ_x

valor esperado cruzado
= 0

$$+ \varepsilon_t (x_{t+h} - E[x_{t+h}])' \alpha' + \varepsilon_t \varepsilon_{t+h}'$$

Passando valor esperado:

$$\Gamma_y(h) = \alpha \Gamma_x(h) \alpha' + \alpha (E[x_t \varepsilon_{t+h}'] - E[x_t] E[\varepsilon_{t+h}']) + 0 +$$

$$E[\varepsilon_t \varepsilon_{t+h}']$$

$$= 0 \text{ se } h = 0 \\ = h \text{ se } h \neq 0$$

libria

Observações: Da eq. de obs $\alpha_{t+1} = T_t \alpha_t + c_t + R_t \eta_t$

recursivamente:

$$\alpha_{t+1} = T^t \alpha_1 + \sum_{j=0}^{t-1} T^j R \eta_{t-j}$$

$$\Rightarrow E[\alpha_t E'_{t+h}] = 0 \text{ pois}$$

$$E[E'_{t+h} \eta_t] = 0$$

$$\text{e } E[E'_{t+h} \alpha_1] = 0.$$

Logo: $\Gamma(h) = \sum_{h,t} T_\alpha(h) Z'$ $\text{re } h \neq 0$

$$= \sum_{0,t} T_\alpha(0) Z' + H \text{ re } h = 0$$

explicitamente

$$\Gamma_\alpha(h, t)$$

para y estacionário

depende de α " $(\Gamma_\alpha(h$

mas de
de do
temp

Ex1:

(1) $y_t = \mu_t + \varepsilon_t, \varepsilon_t \sim N(0, \sigma_\varepsilon^2)$

$\mu_{t+1} = \phi \mu_t + \eta_t, \eta_t \sim N(0, \sigma_\eta^2) \quad |\phi| < 1$

Processo AR(1)

$\therefore y_t$: é uma AR(1) + um choque

que é AR(1) e a componente μ_t

$$E[\mu_t] = 0$$

$$\text{var}[\mu_t] = \gamma(0) = \frac{\sigma_\eta^2}{(1-\phi^2)}$$

$$\gamma(h) = \frac{\phi^h \sigma_\eta^2}{(1-\phi^2)}$$

infos para
AR(1)

$$\rho(h) = \frac{\gamma(h)}{\gamma(0)} = \phi^h ?$$

Albra

$$\Rightarrow E[y_t] = E[\mu_t] = 0$$

$$\text{var}[y_t] = \gamma_y(0) = \frac{\sigma_\eta^2}{(1-\phi^2)} + \sigma_\epsilon^2$$

$$\gamma_y(h) = \gamma_\mu(h)$$

Na realidade, basta aplicarmos a fórmula anterior obtida de forma genérica p caso multivari

processo
n estacionário

$$(II) \begin{cases} y_t = \mu_t + \epsilon_t & \Rightarrow \text{chamado de tendência local} \\ \mu_{t+1} = \mu_t + \eta_t & \rightarrow \text{tendência com drift} \\ & \text{(passo aleatório)} \end{cases}$$

$$E[\mu_t] = ?$$

Obs: Iterando μ_{t+1}

$$\mu_2 = \mu_1 + \eta_1$$

$$\mu_3 = \mu_2 + \eta_2 = \mu_1 + \eta_1 + \eta_2$$

$$\Rightarrow \mu_{t+1} = \mu_1 + \sum_{s=1}^t \eta_s$$

Logo: $E[\mu_{t+1}] = a_1$ (da cond. inicial)

$$\text{var}[\mu_{t+1}] = \underbrace{P_1 + t\sigma_\eta^2}_{\text{var}(P_1)} \quad \begin{matrix} \text{soma de variâncias} \\ \text{de choques independentes} \end{matrix}$$

$$\Rightarrow \text{var}(\mu) \text{ depende de } t$$

\therefore processo y não é estacionário

$$\sigma_y(0, t) = (p_1 + \underbrace{(t\sigma_\eta^2)}_{\text{divida nas duas } x(t-1)}) + \sigma_\varepsilon^2$$

Logo:

Estacionariedade dependerá sempre de como o processo se comporta

Da demonstração, obtemos:

$$E[y_t] = z E[x_t] \quad \leftarrow \text{queremos olhar este processo.}$$

$$\Gamma_y(h, t) = \begin{cases} z \Gamma_x(h, t) z', & h \neq 0 \\ z \Gamma_x(0, t) z' + H, & h = 0 \end{cases}$$

$$x_{t+1} = T^t x_1 + \sum_{j=0}^{t-1} T^j R \eta_{t-j}$$

$$E[x_{t+1}] = T^t E[x_1] = T^t a_1 = f(t)?$$

queremos avaliar se é ou não nas funções do tempo.

⇒ Sabe-se que os autovalores de T são todos distintos

$$\text{Lembrando: } T F_i = \lambda_i F_i \quad i = 1, 2, \dots, m$$

(autovalor)

$$T F_i - \lambda_i F_i = 0 \therefore (T - \lambda_i I) F_i = 0$$

Como $F_i \neq 0$

$\therefore \det(T - \lambda_i I) = 0$: equações características

dará m autovalores $\neq 0$

libra

(queremos achar a condição p.p. a qual x_t não é estacionário de 2ª ordem)

Vale a decomposição espectral:

$$T = F \Lambda F^{-1} = F^{-1} \quad (\text{transp} = \text{inversa pois matriz ortogonal})$$

$\begin{matrix} m \times m & m \times m & m \times m \end{matrix}$

$\Lambda = \text{diagonal } (\lambda_1, \lambda_2, \dots, \lambda_m) = \begin{pmatrix} \lambda_1 & & 0 \\ & \lambda_2 & \\ 0 & & \ddots \\ & & & \lambda_m \end{pmatrix}$

(autovalores)

obs: se algum autovalor igual, há outras decomposições

Prova-se que:

$$T^t = F \Lambda^t F^{-1}$$

Assim segue que:

$$E[x_{t+1}] = T^t a_1 = F \Lambda^t F^{-1} a_1 =$$

$$\begin{pmatrix} E[x_{1,t+1}] \\ E[x_{2,t+1}] \\ \vdots \\ E[x_{m,t+1}] \end{pmatrix} = \begin{pmatrix} f_{11} & f_{12} & \dots & f_{1m} \\ f_{21} & f_{22} & \dots & f_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ f_{m1} & \dots & \dots & f_{mm} \end{pmatrix} \begin{pmatrix} \lambda_1^t & & 0 \\ & \lambda_2^t & \\ 0 & & \ddots \\ & & & \lambda_m^t \end{pmatrix} \begin{pmatrix} f^{11} & f^{12} & \dots & f^{1m} \\ f^{21} & & & \\ \vdots & & & \\ f^{m1} & \dots & \dots & f^{mm} \end{pmatrix} \begin{pmatrix} a_1 \\ a_2 \\ \vdots \\ a_m \end{pmatrix}$$

transposto

$$\Rightarrow E[x_{i,t+1}] = \delta_1 \lambda_1^t + \delta_2 \lambda_2^t + \dots + \delta_m \lambda_m^t, \quad \delta_i = f_{1i} f^{1i} a_{1i}, \quad i=1,2,\dots$$

Vale p/ todas as α_i

$$\Rightarrow E[\alpha_{i,t+1}] \text{ depende explicitamente de } t$$

Mas...

$$\text{Se } |\lambda_i| < 1, \quad \forall i=1, \dots, m, \quad \text{para } t \rightarrow \infty: E[x_{i,t}] \rightarrow 0$$

cond necessária
e suficiente p/ estacionarie-
dade de 1º ordem

(se a tb p/ 2º ordem).

Ulbra

obs: Em simulações \Rightarrow "warming up": x afasta das origens

descarta primeiras simulações

(garanti estacionariedade)

"análogo a $t \rightarrow \infty$

Queremos agora

$$\Gamma_x(h, t) = ?$$

para avaliar a estacionariedade
de 2ª ordem

$$\Gamma_x(h, t) = E[(x_{t+h} - E[x_{t+h}])(x_{t+h+h} - E[x_{t+h+h}])']$$

$$\cdot x_{t+h} = T x_t + R \eta_t = T^t x_1 + \sum_{j=0}^{t-1} T^j R \eta_{t-j}$$

$$\cdot E[x_{t+h}] = T E[x_t] = T^t a_1$$

$$x_{t+h} - E[x_{t+h}] = T^t (x_1 - a_1) + \sum_{j=0}^{t-1} T^j R \eta_{t-j}$$

$$x_{t+h+h} - E[x_{t+h+h}] = T^{t+h} (x_1 - a_1) + \sum_{j=0}^{t+h-1} T^j R \eta_{t+h-j}$$

$$\Rightarrow \Gamma_x(h, t) = E[(x_{t+h} - E[x_{t+h}])(x_{t+h+h} - E[x_{t+h+h}])']$$

$$= E\left[\left[T^t (x_1 - a_1) + \sum_{j=0}^{t-1} T^j R \eta_{t-j}\right] \left[(x_1 - a_1)' T^{t+h} + \sum_{j=0}^{t+h-1} \eta_{t+h-j}' R' T^j\right]\right]$$

obs: $E[\cdot]$ dos

termos
cruzados
 $= 0$

$$= T^t \underbrace{E[(x_1 - a_1)(x_1 - a_1)']}_{P_1} T^{t+h} + E\left[\sum_{j=0}^{t-1} T^j R \eta_{t-j} \sum_{j=0}^{t+h-1} \eta_{t+h-j}' R' T^j\right]$$

$$\text{Para } h=0: \Gamma_x(0, t) = T^t P_1 T^{t'} + \sum_{j=0}^{t-1} T^j (R \Phi R') T^{j'}$$

Podemos mostrar que fazendo

$$|\lambda_i| < 1$$

$$\text{e } t \rightarrow \infty$$

podemos tentar com

deixar a decomp. espectral

$$\text{e fazer } T = F \Lambda F$$

|| demonstrar

$$\Rightarrow \Gamma_x(0, t) \rightarrow \Sigma(0) \text{ matriz que independe de } t$$

Obs: No Harvey Koopman, não há preocupações com isso pois tratam de processos não estacionários.

Obs 2: Essa demo pode ser mais intuitiva se pensarmos em um processo autoregressivo simples

$$x_t = \phi x_{t-1} + \eta_t$$

\downarrow
T

$$x_t = \alpha_1 \phi^t + \sum \phi^j \eta_{t-j}$$

$$\Rightarrow E[x_t] = \alpha_1 \phi^t \rightarrow 0$$

$$x_{t+h} = \alpha_1 \phi^{t+h} + \sum \phi^j \eta_{t+h-j}$$

$$\gamma(h) = E[(x_t - E(x_t))(x_{t+h} - E(x_{t+h}))] = \dots \rightarrow \text{converge}$$

check se $|\phi| < 1$.

Supondo que as condições de estacionariedade de 2ª ordem são satisfeitas ($|\lambda_i(t)| < 1$ e $t \rightarrow \infty$), pode-se obter uma expressão geral para a matriz de covariância de x_t :

$$\alpha_{t+1} = T\alpha_t + R\eta_t$$

Ja' vimos que: $E[\alpha_{t+1}] = 0$.

$$\text{var}[\alpha_{t+1}] = ?$$

Algumas operações em Álgebra Matricial

i. Seja $A \sim m \times n$

$$A = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & \dots & \dots & a_{2n} \\ \vdots & & & \vdots \\ a_{m1} & \dots & \dots & a_{mn} \end{pmatrix}$$

$$\Rightarrow \text{vec}(A) = \begin{pmatrix} a_{11} \\ a_{21} \\ \vdots \\ a_{m1} \\ a_{12} \\ a_{22} \\ \vdots \\ a_{m2} \\ \vdots \\ a_{1n} \\ \vdots \\ a_{mn} \end{pmatrix}$$

propriedade
de empilhamento

ii. Seja $A \sim m \times n$

$$B \sim p \times q$$

cada elemento da matriz A
multiplica a matriz B

$$A \otimes B \cong \begin{pmatrix} a_{11}B & a_{12}B & \dots & a_{1n}B \\ a_{21}B & a_{22}B & \dots & a_{2n}B \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1}B & a_{m2}B & \dots & a_{mn}B \end{pmatrix} \quad m \times n \times p \times q$$

Kronecker

$$\text{iii) } \text{vec}(ABC) = (C' \otimes A) \text{vec}(B)$$

Agora, usando que $\alpha_{t+1} = T\alpha_t + R_t\eta_t$ e condições de estacionariedade de 2ª ordem:

$$\text{var}(\alpha_{t+1}) = \text{var}(T\alpha_t) + \text{var}(R\eta_t) = \text{var}(\alpha_{t+1}) = \text{var}(\alpha_t) = \Sigma_\alpha(0)$$

$$\text{var}(\alpha_{t+1}) = T \text{var}(\alpha_t) T' + R \text{var}(\eta_t) R'$$

$$\text{var}(\alpha_{t+1}) = T \text{var}(\alpha_{t+1}) T' + RQR'$$

$$\downarrow$$

$$= \text{var}(\alpha_t) = \Sigma_\alpha(0)$$

cte. por hipótese do sistema

$$\text{vec} \Sigma_\alpha(0) = \text{vec}(T \Sigma_\alpha(0) T') + \text{vec}(RQR')$$

A B C

$$= (T \otimes T) \text{vec}(\Sigma_\alpha(0)) + (R \otimes R) \text{vec}(Q)$$

$$\text{vec} \Sigma_\alpha(0) - (T \otimes T) \text{vec}(\Sigma_\alpha(0)) = (R \otimes R) \text{vec}(Q)$$

$$(I - T \otimes T) \text{vec}(\Sigma_\alpha(0)) = (R \otimes R) \text{vec}(Q)$$

$$\therefore \boxed{\text{vec}(\Sigma_\alpha(0)) = (I - T \otimes T)^{-1} \text{vec}(Q)}$$

Exercício:

Considere os seguintes modelos em EE

$$y_t = z_t \alpha_t + \varepsilon_t$$

$$\alpha_{t+1} = T \alpha_t + R \eta_t$$

$$(1) \quad y_t = \begin{bmatrix} 1 & 0 \end{bmatrix} \begin{bmatrix} \mu_t \\ \beta_t \end{bmatrix} + \varepsilon_t$$

$$\begin{bmatrix} \mu_{t+1} \\ \beta_{t+1} \end{bmatrix} = \begin{bmatrix} .1 & .1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \mu_t \\ \beta_t \end{bmatrix} + \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \eta_t \\ \varepsilon_t \end{bmatrix}$$

$\downarrow T$

alibra

$$\text{det}(T) = 1$$

$$\eta_t = \begin{pmatrix} \eta_t \\ \varepsilon_t \end{pmatrix} \rightarrow E[\eta_t \eta_t'] = \begin{pmatrix} \sigma_\eta^2 & 0 \\ 0 & \sigma_\varepsilon^2 \end{pmatrix} = \Phi$$

Equações:
$$\begin{cases} y_t = \mu_t + \varepsilon_t \\ \mu_{t+1} = \mu_t + \beta_t + \eta_t \\ \beta_{t+1} = \beta_t + \varepsilon_t \end{cases}$$

modelo linear local

tendência linear estocástica.

ex: Se $\sigma_\eta^2 = \sigma_\varepsilon^2 = 0 \Rightarrow y_t = a + bt + \varepsilon_t$: tendência determinística
é caso particular

Calculando autovalores de T:

$$|T - \lambda I| = 0$$

$$\left| \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} - \begin{pmatrix} \lambda & 0 \\ 0 & \lambda \end{pmatrix} \right| = \left| \begin{pmatrix} 1-\lambda & 1 \\ 0 & 1-\lambda \end{pmatrix} \right| = (1-\lambda)^2 = 0$$

$$\lambda_1 = \lambda_2 = 1$$

\Rightarrow Processo não estacionário

ex: se sistema tivesse 3ª componente \Rightarrow eq. característica com raiz polinomial de 3ª grau.

vetor α não é estacionário de 2ª ordem

Não adianta procurarmos $\Gamma_y(0)$ e $\Gamma_\beta(0)$, pois dependem de t .

$$(ii) \quad y_t = \begin{bmatrix} 1 & 0 \end{bmatrix} \begin{bmatrix} \mu_t \\ \beta_t \end{bmatrix} + \varepsilon_t$$

$$\begin{bmatrix} \mu_{t+1} \\ \beta_{t+1} \end{bmatrix} = \begin{bmatrix} \phi_1 & 1 \\ 0 & \phi_2 \end{bmatrix} \begin{bmatrix} \mu_t \\ \beta_t \end{bmatrix} + \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \eta_t \\ \varepsilon_t \end{bmatrix}$$

a) Estabelecer sob que condições $|\lambda_i(t)| < 1 \quad i=1,2,\dots$

(em ϕ_1 e ϕ_2)

(processo stoc. de 2ª ordem)

b) Avaliar $\lim_{t \rightarrow \infty} \Gamma_\alpha(0,t)$, $\Gamma_\alpha(h,t)$ e consequentemente

$\lim_{t \rightarrow \infty} \Gamma_y(0,t)$, $\Gamma_y(h,t)$ mostrando que condições

impostas nos ϕ 's são suficientes para estabelecer estacionariedade de 2ª ordem para x_t e y_t .

só fazemos xulido q sistemas
invariantes no tempo.

23/03/11

Propriedades de MEE (cont.)

No caso da estacionariedade,
vimos que depende dos
autovalores de T.

Observabilidade motivada pela seguinte pergunta:

↳ dado que observamos y nos últimos m, como posso recuperar a trajetória de x no mesmo intervalo.

"Em que condições é possível estabelecer, em um intervalo de tempo finito, a trajetória temporal do estado x_t de um sistema dinâmico, dada a história do vetor de medidas y_t no mesmo intervalo de tempo?"

Seja um MEE linear, discreto, invariante no tempo.

Sistema p-variável.

$$\begin{cases} y_t = z x_t \\ x_{t+1} = T x_t + R \eta_t \end{cases} \quad (I)$$

$\begin{matrix} \nearrow p \times 1 & \nearrow p \times m \\ \searrow m \times 1 & \searrow m \times m \end{matrix}$

→ Não há necessidade considerar o erro na eq. de medida.

Este sistema será dito observável se x_0 pode ser determi-

nado a partir de um conjunto de medidas de y.

A condição necessária e suficiente será dita a seguir:

fazendo $\eta_t \equiv 0 \forall t$ em I, segue que:

$$x_{t+1} = T x_t \Rightarrow x_{t+1} = T^t x_1$$

$$x_t = T^t x_0 \rightarrow \text{se linkar com eq. das obs.}$$

Mas $y_t = z x_t = z T^t x_0$ ($x \sim m \times 1$) → temos que observar m medidas do vetor y.

$$p \times 1 \rightarrow y_0 = z x_0 \leftarrow m \times 1$$

$$p \times 1 \rightarrow y_1 = z T x_0$$

$$y_2 = z T^2 x_0$$

$$y_{m-1} = z T^{m-1} x_0$$

$$\Rightarrow \begin{pmatrix} y_0 \\ y_1 \\ y_2 \\ \vdots \\ y_{m-1} \end{pmatrix} = \begin{pmatrix} z \\ zT \\ zT^2 \\ \vdots \\ zT^{m-1} \end{pmatrix} \begin{pmatrix} x_{0,1} \\ x_{0,2} \\ x_{0,3} \\ \vdots \\ x_{0,m} \end{pmatrix}$$

↙ $x_0 \sim m \times 1$ libera
essa relação tem que ser única H todas as medidas

$$y = M \alpha_0$$

$$p \times 1 \quad p \times m$$

- Assim, segue que para determinarmos os elementos de α_0 de forma única que a condição necessária e suficiente será:

$\text{posto}(M) = m$ (é exatamente o tamanho de α_0 e faz com que haja solução única α_0 no sistema acima)

$\text{posto } M = \# \text{ máximo de linhas/colunas linearmente independentes}$

- Como $\text{posto } M = \text{posto } M'$, então

$$\text{posto } M' = \text{posto}(Z', T'Z', \dots, (T^{m-1})'Z') = m$$

- Se $p=1$, i.e., y_t é escalar $M \sim m \times m$, e, assim, a condição de observabilidade pode ser investigada checando se $\det(M) \neq 0$. \rightarrow pois $p=1 \Rightarrow M$ será uma matriz quadrada

Exs:

(Geralmente, nesta parte do curso

$$1) y_t = \mu_t + \epsilon_t$$

tratamos modelos univariados

$$\mu_{t+1} = \mu_t + \beta_t + \eta_t$$

$p=1 \Rightarrow$ uma única série temporal

$$\beta_{t+1} = \beta_t + \xi_t$$

Para verificar, neste caso

checar se $\det \neq 0$ ou se

há uma linha que seja cl das outras

$$\Rightarrow y_t = \begin{bmatrix} 1 & 0 \end{bmatrix} \begin{bmatrix} \mu_t \\ \beta_t \end{bmatrix} + \epsilon_t$$

Modelo
de tendência
linear
estocástica

$$\epsilon - A\epsilon = \xi_t \Rightarrow 0$$

$$\Rightarrow y_t = a + bt + \epsilon_t$$

(tendência
determinística)

$$\begin{bmatrix} \mu_{t+1} \\ \beta_{t+1} \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \mu_t \\ \beta_t \end{bmatrix} + \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \eta_t \\ \xi_t \end{bmatrix}$$

Libra

\Rightarrow Questão: Será que conseguimos recuperar α_t 's dados y_t 's?

$$z = \begin{bmatrix} 1 & 0 \end{bmatrix} \Rightarrow z' = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad T = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$$

$$T'z' = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

$$M' = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \quad \text{tem posto} = 2 = m \Rightarrow \text{é observável.}$$

$$2) \quad y_t = \mu_t + \varepsilon_t$$

$$\mu_{t+1} = \mu_t + \eta_t$$

$$\beta_{t+1} = \beta_t + \zeta_t$$

$$\Rightarrow y_t = \begin{bmatrix} 1 & 0 \end{bmatrix} \begin{bmatrix} \mu_t \\ \beta_t \end{bmatrix} + \varepsilon_t$$

$$\begin{bmatrix} \mu_{t+1} \\ \beta_{t+1} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \mu_t \\ \beta_t \end{bmatrix} + \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \eta_t \\ \zeta_t \end{bmatrix}$$

↓
T

$$M' = (z', T'z')$$

$$T'z' = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

$$\Rightarrow M' = \begin{pmatrix} 1 & 1 \\ 0 & 0 \end{pmatrix} \Rightarrow \text{posto}(M') = 1, \text{ pois } l_1 = l_2 : \text{ sistema} \\ \neq 2 \quad \text{nas observáveis}$$

3) chequem para

MP₁ $\begin{cases} y_t = \mu_t + \beta_t + \varepsilon_t \\ \mu_{t+1} = \phi_1 \mu_t + \eta_t \\ \beta_{t+1} = \phi_2 \beta_t + \zeta_t \end{cases}$

↓
parâmetros
ajustados

Nas podemos estimar
modelos que nas é
observável. Modelos
nas faz sentido.

Estabelecer condições para Φ_1 e Φ_2 de forma que o sistema seja observável.

- Se $\Phi_1 = \Phi_2 = 1$ \rightarrow não é observável $\rightarrow M' = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} \Rightarrow \text{posto}(M') = 1$

$$\theta_t = \mu_t + \beta_t$$

$$\psi_t = \mu_t - \beta_t$$

$$\therefore y_t = \mu_t + \beta_t + \varepsilon_t$$

$$y_t = \theta_t + \varepsilon_t$$

$$\theta_{t+1} = \theta_t + \delta_{1t}$$



$$\begin{aligned} \theta_{t+1} &= \mu_{t+1} + \beta_{t+1} = (\mu_t + \beta_t) + (\eta_t + \xi_t) \\ &= \theta_t + \delta_{1t} \end{aligned}$$

$$\begin{aligned} \text{Também: } \psi_{t+1} &= \mu_{t+1} - \beta_{t+1} \\ &= (\mu_t - \beta_t) + (\eta_t - \xi_t) \\ &= \psi_t + \delta_{2t} \end{aligned}$$

$$\Rightarrow \begin{cases} y_t = [1 & 0] \begin{bmatrix} \theta_t \\ \psi_t \end{bmatrix} \end{cases}$$

MP2

\hookrightarrow só na especificação

y não depende de ψ . Nem θ e ψ se relacionam

$$\begin{aligned} \text{parametrizações} & \begin{cases} \begin{bmatrix} \theta_{t+1} \\ \psi_{t+1} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \theta_t \\ \psi_t \end{bmatrix} + \begin{bmatrix} \delta_{1t} \\ \delta_{2t} \end{bmatrix} \end{cases} \end{aligned}$$

Nesta parametrização fica + fácil de verificar.

Nos modelos que usaremos aqui \rightarrow tais que as observáveis p/ serem adequadas.

obs: No exercício 1, se tivéssemos trabalhado com $p=2$
 $(y \sim 2x+1)$

$$y_t = \begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \end{pmatrix} \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \\ \rho_{1t} \\ \rho_{2t} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

$N \sim (0, \Sigma)$

Não

caso nas x

comunicam aqui,

mas podem se comunicar nos ε .

— " —

A questão da observabilidade é obrigatória e estimação dos parâmetros do modelo.

A questão da estacionariedade não. É da definição do modelo

Na cond. inicial será importante definir quais componentes são estacionárias e quais não.

(obs: cond. inicial $\alpha_i \sim N(a_i, P_i)$)

Nas

estacionariedade

traz problemas no modelo de regressão, BLT etc.

$\begin{pmatrix} \alpha_{1,0} \\ \alpha_{1,1} \\ \alpha_{1,2} \end{pmatrix}$ componentes de α_1

obs. Existe uma correspondência entre modelos estruturais e modelos ARIMA de BLT.

— " —

Estimação de MEE lineares e Gaussianas

ex. do Filtro de Kalman não exigem que o sistema

$$y_t = z_t' \alpha_t + \varepsilon_t$$

seja invariante no tempo.

$$\alpha_{t+1} = T_t \alpha_t + R_t \eta_t$$

De forma geral, z_t

$(t=1, \dots, n)$ tamanho da série (out)

onde $\varepsilon_t \sim N(0, H_t)$

$\eta_t \sim N(0, Q_t)$

obs: Filtro de Kalman 16

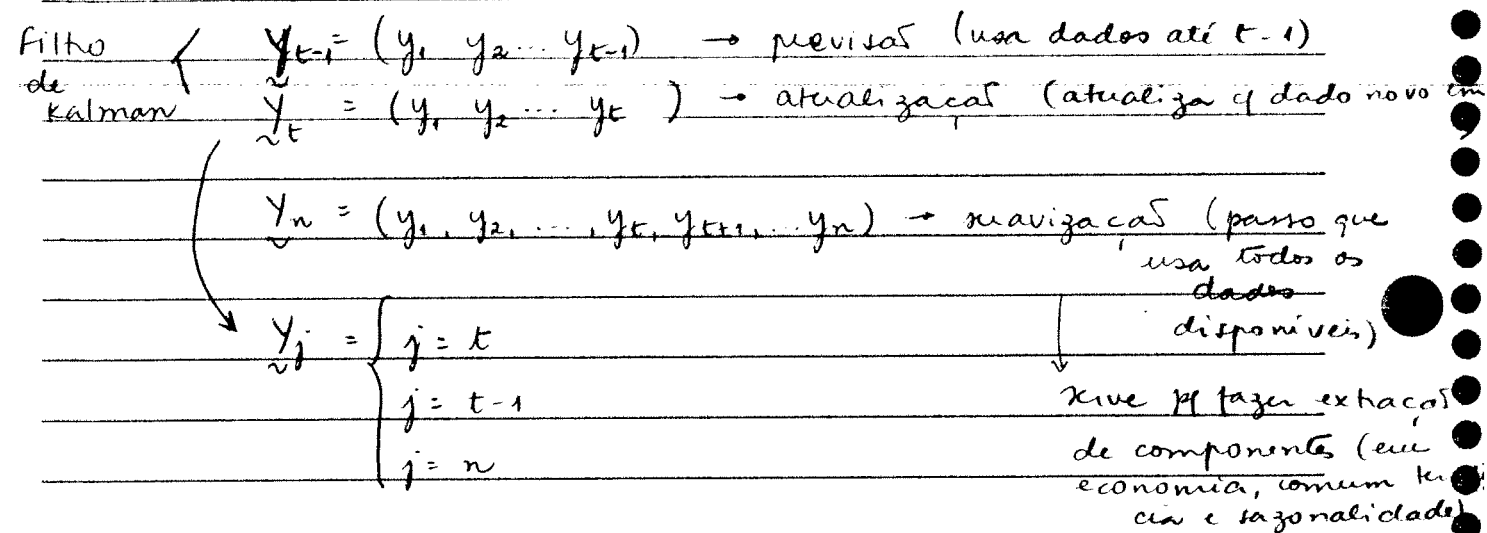
Mas considerando Gaussianidade, em média quadrática será ótimo.

não exige dist. Gaussiana dos choques, apenas 1^o e 2^o momentos

St Gaussianidade \rightarrow TK para o tempo local
(melhor estimador linear)

O que queremos?

- (1) Estimar α_t dado certo conjunto de informações (y_t)
 \hookrightarrow observável.



$p(\alpha_t | \tilde{y}_j)$? \rightarrow estimar α_t é ter esta densidade
(densidade condicional a

partes do que observamos em y)

$$\Downarrow$$
$$E[\alpha_t | \tilde{y}_j]$$
$$\text{var}[\alpha_t | \tilde{y}_j]$$

No curso: veremos a estimação usando previsões e atualizações \Rightarrow Filtro de Kalman
veremos um tipo de suavizações.

Toda dedução do FK, pressupõe que quaisquer elementos desconhecidos em alguma matriz serão considerados conhecidos. (faltam quase q certeza nas matrizes de covariância)

(2) Hiperparâmetros

\hookrightarrow nas matrizes do sistema por MV
 \hookrightarrow dados faltantes nestas matrizes.

utiliza

Dois âmbitos de estimacões $\left\{ \begin{array}{l} \text{do vetor de estados} \\ \text{dos hiperparâmetros das matrizes} \end{array} \right\}$ usando previsões e atualizações do sistema

Considere o modelo linear local

$$\begin{cases} y_t = \mu_t + \varepsilon_t & \varepsilon_t \sim N(0, \sigma_\varepsilon^2) & \mu_1 \sim N(a, P_1) \\ \mu_{t+1} = \mu_t + \eta_t & \eta_t \sim N(0, \sigma_\eta^2) \end{cases}$$

$$E[\varepsilon_t \mu_s] = E[\eta_t \mu_s] = 0 \quad \forall t$$

$$E[\varepsilon_t, \eta_s] = 0 \quad \forall t, s$$

Em princípio, podemos obter $p(x_t | y_t)$ sem fazer uso do FK, apenas recorrendo a propriedades de vetores normais multivariados.

Para y

$$y_1 = \mu_1 + \varepsilon_1$$

$$y_2 = \mu_2 + \varepsilon_2 = \mu_1 + \eta_1 + \varepsilon_2$$

\vdots

$$y_n = \mu_1 + (\eta_1 + \eta_2 + \dots + \eta_{n-1}) + \varepsilon_n$$

$$y = (y_1, y_2, \dots, y_n)' \Rightarrow E[y] = \begin{pmatrix} a_1 \\ a_1 \\ \vdots \\ a_1 \end{pmatrix} = \mathbb{1}a_1 = E[y]$$

$$\text{var}(y) = E[(y - E[y])(y - E[y])'] = \Sigma$$

$$= \begin{bmatrix} \text{var}(y_1) & \text{cov}(y_1, y_2) & \dots & \text{cov}(y_1, y_n) \\ \text{cov}(y_1, y_2) & \text{var}(y_2) & & \\ \vdots & & \ddots & \\ \text{cov}(y_{n-1}, y_n) & & & \text{var}(y_n) \end{bmatrix}_{n \times n}$$

///

• Variâncias

$$\text{var}(y_1) = p_1 + \sigma_E^2$$

$$\text{var}(y_2) = p_1 + \sigma_\eta^2 + \sigma_E^2$$

⋮

$$\text{var}(y_n) = p_1 + (n-1)\sigma_\eta^2 + \sigma_E^2$$

• covariâncias

$$\text{cov}(y_1, y_2) = E[(y_1 - a_1)(y_2 - a_1)]$$

$$= E[(\mu_1 + \varepsilon_1 - a_1)(\mu_1 + \eta_1 + \varepsilon_2 - a_1)] = p_1$$

Podemos escrever:

$$\Omega = 11'p_1 + \Sigma_{ij} \quad \text{onde } \Sigma_{ij} = \begin{cases} (i-1)\sigma_\eta^2 & , i < j \\ \sigma_E^2 + (i-1)\sigma_\eta^2 & , i = j \\ (j-1)\sigma_\eta^2 & , i > j \end{cases}$$

↓

crece com n

(com o n° de observações)

$i = 1, \dots, n$

Do ponto de vista operacional,

estariamos usando

matrizes enormes

se tivéssemos muitas

observações.

(Nas será este caminho a ser usado).

para μ

$$\mu_{t+1} = \mu_t + \eta_t$$

$$\mu_2 = \mu_1 + \eta_1$$

$$\mu_3 = \mu_2 + \eta_2 = \mu_1 + \eta_1 + \eta_2$$

⋮

$$\mu_n = \mu_1 + (\eta_1 + \eta_2 + \dots + \eta_{n-1})$$

$$\Rightarrow \mu = \begin{pmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_n \end{pmatrix} \Rightarrow E[\mu] = 1a_1$$

$\text{var}(\mu)$... terá a ver com
termos p_i e σ_{η}^2 na
matriz Ω (var de y)

Desenvolvendo, poderemos escrever:

$$\begin{pmatrix} y \\ \mu \end{pmatrix}_{n \times 1} \sim N \left(\begin{pmatrix} 1a_i \\ 4a_i \end{pmatrix}, \begin{pmatrix} \Omega & \Sigma_{y\mu} \\ \Sigma_{\mu y} & \Sigma_{\mu\mu} \end{pmatrix} \right)$$

$E[(y - E[y])(\mu - E[\mu])']$
 $E[(\mu - E[\mu])(\mu - E[\mu])']$

Resultado: (Teorema)

Seja $\begin{pmatrix} x \\ y \end{pmatrix} \sim N \left[\begin{pmatrix} \mu_x \\ \mu_y \end{pmatrix}, \begin{pmatrix} \Sigma_{xx} & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_{yy} \end{pmatrix} \right]$

Então:

$$p(x|y=y) \sim N \left(\underbrace{\mu_x + \Sigma_{xy} \Sigma_{yy}^{-1} (y - \mu_y)}_{\mu_{x|y}}; \underbrace{\Sigma_{xx} - \Sigma_{xy} \Sigma_{yy}^{-1} \Sigma_{yx}}_{\Sigma_{x|y}} \right)$$

Faça $x = \mu$, $y = y$ e assim:

$$p(\mu|y=y) \sim N(E[\mu|y=y]; \text{var}[\mu|y=y]) \quad (\text{Fazer!})$$

etc. \Rightarrow obter expressões explícitas.

Mesmo não usando FK, p este modelo apresentado,
seuendo de forma multivariada e estimando (e não
conhecendo)
 σ_e^2 e σ_{η}^2 por MV, obtemos o resultado acima p
vetores multivariados normais \Rightarrow Ditt. condicional
de μ dado y . clibra

$$y = m \times 1$$

$$z = n \times 1$$

$$y'z' = 1 \times m \times 1 \times n$$

Este processo de estimacao do desconhecido e' valido, mas
nao e' factivel do ponto de vista operacional. Nao e'
sequencial. Apresenta matizes muito grandes.

Neste caso, estamos fazendo estimativa suavizada:

$$E[\mu|y] = \begin{pmatrix} E[\mu_1|y] \\ E[\mu_2|y] \\ \vdots \\ E[\mu_n|y] \end{pmatrix}$$

usamos todas as informacoes

→ Usaremos o resultado anterior bastante agora

Lema do Resultado anterior.

Seja $\begin{bmatrix} x \\ y \\ z \end{bmatrix} \sim N \left(\begin{pmatrix} \mu_x \\ \mu_y \\ 0 \end{pmatrix}, \begin{pmatrix} \Sigma_{xx} & \Sigma_{xy} & \Sigma_{xz} \\ \Sigma'_{xy} & \Sigma_{yy} & 0 \\ \Sigma'_{xz} & 0 & \Sigma_{zz} \end{pmatrix} \right)$

x, y, z vetores de dimensao arbitria

particularizacoes sera usada no FK.

Entao:

$$(x|y=y, z=z) \sim N \left[E(x|y=y, z=z), \text{var}(x|y=y, z=z) \right]$$

onde:

$$E(x|y=y, z=z) = \mu_{x|y} + \Sigma_{xz} \Sigma_{zz}^{-1} z$$

$$\text{var}(x|y=y, z=z) = \Sigma_{xx} - \Sigma_{xz} \Sigma_{zz}^{-1} \Sigma_{zx}$$

Prova: aplique o lema anterior substituindo y por $(y'z')'$

$$\begin{pmatrix} 1 \times m & 1 \times n \end{pmatrix}$$

$$\begin{pmatrix} 1 \times m \\ 1 \times n \end{pmatrix}$$

Fazer!

$$\begin{cases} y_t = z_t' x_t + \varepsilon_t & (a) \\ x_{t+1} = T_t' x_t + R_t' \eta_t & (b) \end{cases}$$

Notações: $(x_t | y_{t-1}) \Rightarrow E[x_t | y_{t-1}] = a_t$
 $\text{var}[x_t | y_{t-1}] = P_t$

ou $a_{t+1} = E[x_{t+1} | y_t]$; $a_{t|t} = E[x_t | y_t]$
 $P_{t+1} = \text{var}[x_{t+1} | y_t]$; $P_{t|t} = \text{var}[x_t | y_t]$

1º passo: distribuições da previsões de $x_{t+1} \Rightarrow$ usar eq. (a)

$$x_{t+1} = T_t' x_t + R_t' \eta_t$$

$$\therefore E[x_{t+1} | y_t] = T_t' E[x_t | y_t]$$

$$\boxed{a_{t+1} = T_t' a_{t|t}} \rightarrow \text{No loopman } T_t' E[x_t | y_t]$$

(questões de notação)

$$\begin{aligned} \text{var}[x_{t+1} | y_t] = P_{t+1} &= \text{var}[T_t' x_t + R_t' \eta_t | y_t] \\ &= E[(A_t - E[A_t | y_t])(A_t - E[A_t | y_t])'] \end{aligned}$$

mas: $A_t = T_t' x_t + R_t' \eta_t$

$$\therefore E[A_t | y_t] = T_t' a_{t|t}$$

$$\begin{aligned} \therefore \underbrace{A_t - E[A_t | y_t]}_{B_t} &= T_t' x_t + R_t' \eta_t - T_t' a_{t|t} \\ &= T_t' (x_t - a_{t|t}) + R_t' \eta_t \end{aligned}$$

$$E[B_t B_t'] = \eta_t' R_t' + (x_t - a_{t|t})' T_t'$$

Logo:

$$E[B_t B_t'] = P_{t+1} =$$

$$= E[T_t (\alpha_t - a_{Ht}) \eta_t R_t'] + E[T_t (\alpha_t - a_{Ht}) (\alpha_t - a_{Ht})' T_t'] +$$

$$+ E[R_t \eta_t (\alpha_t - a_{Ht})] + E[R_t \eta_t \eta_t' R_t']$$

0 (Termos cruzados)

0

precisas
expensas.

$$\therefore P_{t+1} = T_t P_{t|t} T_t' + R_t Q_t R_t'$$

previas

No modelo de nível local

$$y_t = \mu_t + \epsilon_t \quad \epsilon_t \sim N(0, \sigma_\epsilon^2) \quad \text{onde } \epsilon: \text{parâmetro aleatório}$$

$$\mu_{t+1} = \mu_t + \eta_t \quad \eta_t \sim N(0, \sigma_\eta^2)$$

adequado
para séries
com estatísticas
variáveis

onde σ_η^2 tende a zero na sua estocástica

Importante: sempre importante ver como é o comportamento
e quanto a variância

2) Forma Reduzida

$$\Phi_p(L) \Delta^d y_t = c + \Theta_q(L) \epsilon_t \Rightarrow \text{ARIMA}(p, d, q) + c$$

→ questões de identificação pode ocorrer em modelos estruturais

Por exemplo $\rightarrow y_t = \alpha + \beta x_t + \epsilon_t \quad \text{onde } \epsilon_t \sim N(0, \sigma_\epsilon^2)$

$$E(y_t | x_t) = (\alpha + c) + \beta x_t$$

Na regressão

$$\hat{y} = \hat{\gamma}_0 + \hat{\gamma}_1 x_t \Rightarrow \begin{cases} \hat{\gamma}_0 = \alpha + c \\ \hat{\gamma}_1 = \beta \end{cases} \left. \begin{array}{l} 2 \text{ equações} \\ 3 \text{ incógnitas (parâmetros)} \end{array} \right\} \Rightarrow \text{Não identificável}$$

Todos modelos ARIMA, por construção, é sempre identificável

→ escrevermos modelos estruturais na forma ARIMA e ver
se é identificável ou não.

forma reduzida:

$$y_t = \mu_t + \varepsilon_t$$

$$\mu_{t+1} = \mu_t + \eta_t$$

$$\hookrightarrow \text{vale } \mu_t = \mu_{t-1} + \eta_{t-1}$$

Tanto μ_t
quanto η_t
são estacionários

Tira 1ª diferença:

$$\Delta y_t = \Delta \mu_t + \Delta \varepsilon_t$$

$$\Delta \mu_t = \eta_t$$

$$\Rightarrow \Delta y_t = \eta_t + \Delta \varepsilon_t$$

C.L. de processos estacionários \Rightarrow podemos procurar

forma ARIMA que

lembra a esta transformação

$$\rightarrow E[\Delta y_t] = 0$$

$$\rightarrow \text{var}(\Delta y_t) = \text{var}(\eta_t) + \text{var}(\Delta \varepsilon_t) = \sigma_\eta^2 + 2\sigma_\varepsilon^2$$

$$\hookrightarrow \text{var}(\varepsilon_t - \varepsilon_{t-1}) = \text{var}(\varepsilon_t) + \text{var}(\varepsilon_{t-1}) - 2\text{cov}(\varepsilon_t, \varepsilon_{t-1})$$

E como saber qual o ARMA correspondente?

$$\text{MA}(q) \Rightarrow \rho(k) \begin{cases} \neq 0 & k=1, 2, \dots, q \\ = 0 & k=q+1, \dots \end{cases}$$

$$\text{AR}(p) \Rightarrow \rho(k) \begin{cases} \text{exponencial ou} \\ \text{modo amortecido} \end{cases}$$

$$\rightarrow \text{FAC: } \rho(k) = \frac{\text{cov}(\Delta y_t, \Delta y_{t-k})}{\text{var}(\Delta y_t)}$$

$k=1$:

média = 0 vt

$$\text{COV}(\Delta y_t, \Delta y_{t-1}) = E[\Delta y_t \Delta y_{t-1}] =$$

$$= E[(\eta_t + \varepsilon_t - \varepsilon_{t-1})(\eta_{t-1} + \varepsilon_{t-1} - \varepsilon_{t-2})] =$$

$$= -\sigma_\varepsilon^2$$

$$\therefore \rho(1) = \frac{-\sigma_\varepsilon^2}{\sigma_\eta^2 + 2\sigma_\varepsilon^2} = \frac{-1}{q+2}$$

$$\text{onde } q = \sigma_\eta^2 / \sigma_\varepsilon^2$$

$$\text{Para } k \geq 2: \text{COV}(\Delta y_t, \Delta y_{t-k}) = 0$$

$$E[(\eta_t + \varepsilon_t - \varepsilon_{t-1})(\eta_{t-k} + \varepsilon_{t-k} - \varepsilon_{t-k-1})]$$

¶ $j \geq 2$, não há nenhum par no termo anterior

\Rightarrow É um processo MA(1) — $\text{FAC} \neq 0$ ¶ $k=1$

$= 0$ ¶ $k \geq 2$.

Resultado: Se y_t é MNL $\Rightarrow \Delta y_t \sim \text{MA}(1)$

Suponha que vamos estimar a 1ª diferença do processo como MA(1)

Seja $z_t \sim \text{MA}(1)$

$$\therefore z_t = w_t + \theta w_{t-1}, \quad w_t \sim N(0, \sigma_w^2)$$

$$\begin{cases} E[z_t] = 0 \\ \text{var}[z_t] = (1 + \theta^2) \sigma_w^2 \\ \gamma(1) = E[z_t z_{t-1}] = \theta \sigma_w^2 \end{cases}$$

$$\Rightarrow \rho(1) = \frac{\theta}{(1 + \theta^2)}$$

Queremos responder:

$$H_0: y_t \Rightarrow 0 < \rho < \infty \quad (\rho \text{ é o parâmetro a ser estimado na forma reduzida})$$

$$H_1: z_t \Rightarrow -1 < \theta < 1$$

$$H_0: y_t \Rightarrow \rho(i) = \frac{-1}{q+2}$$

$$H_1: z_t \Rightarrow \rho(i) = \frac{\theta}{1+\theta^2}$$

queremos ver se fazendo igualdade e variando q de 0 a ∞ , θ varia de -1 a 1

$$\rho(i) = \frac{\theta}{1+\theta^2} = \frac{-1}{q+2}$$

$$\therefore \theta = \frac{-(2+q) \pm \sqrt{q^2 + 4q}}{2} \quad \text{onde } q \in (0, \infty)$$

$$q \rightarrow 0: \theta = \frac{-2 \pm 0}{2} = -1$$

$$q \rightarrow \infty: \text{Truque algébrico: } x \text{ e } \div \text{ por } \sqrt{\dots}$$
$$\theta = 0$$

Espaço paramétrico H_0 mais restrito: $-1 < \theta < 0$

é o que encontramos quando reparamos y_t como $MA(1)$

Se realmente acreditarmos que modelo melhor a ser usado por MNL \Rightarrow essa restrição maior é natural

se supusermos $E[\epsilon_t \eta_t] = \sigma_{\epsilon\eta}$ (nas nas + denormalizados)

$$\Delta y_t = \eta_t + \Delta \epsilon_t$$

$\Rightarrow E[\Delta y_t] = 0$ — Nas é afetado pela nova hipótese

$$\text{Var}[\Delta y_t] = \sigma_\eta^2 + 2\sigma_\epsilon^2 + 2\sigma_{\epsilon\eta}$$

$$\begin{aligned} E[(\Delta y_t - E(\Delta y_t))^2] &= E[\Delta y_t^2] = \\ &= E[(\eta_t + \epsilon_t - \epsilon_{t-1})^2] \\ &= E[(\eta_t^2 + 2\eta_t(\epsilon_t - \epsilon_{t-1}) + (\epsilon_t - \epsilon_{t-1})^2)] \\ &= \sigma_\eta^2 + 2\sigma_{\epsilon\eta} + 2\sigma_\epsilon^2 \end{aligned}$$

$$\begin{aligned} \gamma(1) &= E[\Delta y_t \Delta y_{t-1}] \\ &= E[(\eta_t + \epsilon_t + \epsilon_{t-1})(\eta_{t-1} + \epsilon_{t-1} - \epsilon_{t-2})] \\ &= -\sigma_\epsilon^2 \text{ — Nas é afetado também.} \end{aligned}$$

$$\text{Logo } \rho(1) = \frac{-\sigma_\epsilon^2}{\sigma_\eta^2 + 2\sigma_{\epsilon\eta} + 2\sigma_\epsilon^2} = \frac{\theta}{1 + \theta^2}$$

11 Δy_t krus
3 parâmetros:
 $\sigma_\eta^2, \sigma_\epsilon^2, \sigma_{\epsilon\eta}$

11 z_t krus 2 parâmetros: θ
e σ_ϵ^2

Este modelo de covariância nas é identificável.

↓ diz respeito a ^{estimamos} parâmetros

(\bar{n} é a mesma coisa da observabilidade — que tem a ver com as componentes

nas páginas 11 e 12

Forma UCAZIMA

$$\Delta y_t = \eta_t + \Delta \varepsilon_t$$

$$\therefore y_t = \left(\frac{\eta_t}{\Delta} \right) + \varepsilon_t$$

chama de tendência

$$= T_t + \varepsilon_t$$

$$\therefore T_t = \frac{\eta_t}{\Delta} \therefore \Delta T_t = \eta_t \therefore T_t = T_{t-1} + \eta_t \Rightarrow \text{componente de passeio aleatório}$$

Notas III
pg 13

Modelo de Tendência linear local

$$y_t = \mu_t + \varepsilon_t \quad \sigma_{\varepsilon}^2$$

$$\mu_t = \mu_{t-1} + \beta_{t-1} + \eta_t \quad \sigma_{\eta}^2$$

$$\beta_t = \beta_{t-1} + \gamma_t \quad \sigma_{\gamma}^2$$

$$\text{Definir 2 razões sinal ruído: } q_{\eta} = \frac{\sigma_{\eta}^2}{\sigma_{\varepsilon}^2}, \quad q_{\gamma} = \frac{\sigma_{\gamma}^2}{\sigma_{\varepsilon}^2}$$

$\mu_t \Rightarrow$ tendência estocástica da série

μ_t : é uma tendência linear estocástica
(+ complicada do que um RW)

é modificada por 2 choques: um na própria tendência e outro na inclinação

$$\text{Se } \sigma_{\eta}^2 = \sigma_{\gamma}^2 = 0 \Rightarrow y_t = a + bt + \varepsilon_t$$

(importante! Olhar p/ casos particulares)

⇒ Ver casos particulares na apostila.

ex: 1) se fizermos estimativa e definimos a $\sigma_e^2 = 10^{-5}$ (muito baixa)

⇒ pode desconsiderar a estocasticidade da inclinação

2) se $\sigma_\beta^2 \neq 0$ e $\sigma_\eta^2 = 0$:

$$y_t = \mu_t + \epsilon_t$$

$$\mu_t = \mu_{t-1} + \beta_{t-1}$$

$$\beta_t = \beta_{t-1} + \xi_t$$

1ª diferença de μ_t : $\Delta \mu_t = \beta_{t-1}$

2ª

$$\Delta^2 \mu_t = \Delta \beta_{t-1} = \xi_{t-1}$$

O processo terá uma tendência suave.

curva suave
↘ suave

⇒ 2ª derivada da componente de

tendência é um ruído branco.

$$\frac{d^2 \mu_t}{dt^2} = \xi_t \Rightarrow \mu_t = \iint \xi_{t-1} dt$$

↘ operações de soma no ruído branco.

Passa a suavizá-lo.

Elimina componente de alta frequência

Este modelo de Tendência suave se comunica com filtro HP

(Usado para separar tendência

de ciclos de séries macroeconômicas)

Forma de Espaço de Estado:

↓

pl modelos estruturais e são invariantes no tempo

$$y_t = Z_t \alpha_t + \varepsilon_t = \begin{pmatrix} 1 & 0 \end{pmatrix} \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} + \varepsilon_t$$

$$\begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \eta_t \\ \tau_t \end{pmatrix}$$

\downarrow \downarrow \downarrow
 $\alpha_t = m \times 1$ $m \times m$ $(m \times n)$ $n \times 1$

(Neste caso $m=n$)

Mas pode ser que tenhamos menos choques do que componentes.

Funções de previsão:

Não tem nada a ver com FK

Vem sempre a partir da equação do modelo

Dois formas de fazer:

I) $y_t = \mu_t + \varepsilon_t, t=1, \dots, n$

II) $y_t = Z_t \alpha_t + \varepsilon_t$

$$y_{t+k} = \mu_{t+k} + \varepsilon_{t+k}$$

$$\hat{y}_{t+k} = Z E[\alpha_{t+k} | y_t]$$

$$\hat{y}_{t+k} = E[y_{t+k} | y_t]$$

$$= E[\mu_{t+k} | y_t] + E[\varepsilon_{t+k} | y_t]$$

$$\downarrow$$

$$E[\varepsilon_t] = 0 \forall t$$

Temos que $\alpha_t = T \alpha_{t-1} + \eta_t$

$$\alpha_{t+k} = T^k \alpha_t + (\dots) \eta_t$$

$$\Rightarrow E[\alpha_{t+k} | y_t] = T^k E[\alpha_t | y_t]$$

vem de FK

$$= T^k \begin{pmatrix} \hat{\mu}_{t+k} \\ \hat{\beta}_{t+k} \end{pmatrix}$$

$$\begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}^k = \begin{pmatrix} 1 & k \\ 0 & 1 \end{pmatrix}$$

$$= \begin{pmatrix} 1 & k \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \hat{\mu}_{t+k} \\ \hat{\beta}_{t+k} \end{pmatrix} = \begin{pmatrix} \hat{\mu}_{t+k} + k \hat{\beta}_{t+k} \\ \hat{\beta}_{t+k} \end{pmatrix}$$


$$\hat{y}_{t+k} = 2 E[x_{t+k} | \hat{y}_t] = (1 \ 0) \begin{pmatrix} \hat{\mu}_{t+k} + k \hat{\beta}_{t+k} \\ \hat{\beta}_{t+k} \end{pmatrix}$$

$$= \hat{\mu}_{t+k} + k \hat{\beta}_{t+k}$$



equações de tendência linear

Exercício: $\hat{\mu}_{t+k}$ e $\hat{\beta}_{t+k}$ mas dados por suavizamento exponencial simples.



precisa dar uma medida de incerteza em relação a esta previsão.

Obs: Nessas equações, trabalhamos ϕ $\hat{\Psi}$ (hiperparâmetros fixos conhecidos, estimados) \Rightarrow plug-in

A incerteza a respeito de $\hat{\Psi}$ não é transmitida pelas componentes calculadas com FK.

↓
Isso tb é feito nos modelos ARIMA:

$$y_t = \phi y_{t-1} + \epsilon_t$$

$$\hat{y}_{t+k|t} = \hat{\phi}^k y_t \rightarrow \text{Já usamos } y_t = \hat{\phi} y_{t-1} + \epsilon_t \text{ naturalmente}$$

• MSE da previsão:

$$MSE(\hat{y}_{t+k|t}) = E[y_{t+k} - \hat{y}_{t+k|t}]^2$$

Para o modelo:

$$y_{t+2} = \mu_{t+2} + \varepsilon_{t+2}$$

$$\hat{y}_{t+2|t} = \hat{\mu}_{t+2|t} + \lambda \hat{\beta}_{t+2|t}$$

$$\Rightarrow \text{MSE}(\hat{y}_{t+2|t}) = E[(y_{t+2} - \hat{y}_{t+2|t})^2] =$$

$$= E\left[\left((\mu_{t+2} - \hat{\mu}_{t+2|t}) + \varepsilon_{t+2} + \lambda \hat{\beta}_{t+2|t}\right)^2 \mid \mathcal{Y}_t\right]$$

matricialmente, temos uma expressão mais simples:

(

ver pg. 20 (notas III)

Fazer cálculos

Ver ex. pg. 21: duas previsões feitas a partir de $\{$ modelos estocásticos

Forma reduzida

objetivo: obter modelo estacionário e ver se pode ser
escrito como modelo ARIMA

E ver qual " " pode representar o modelo
estrutural.

Tb pode resolver a questão do modelo não identificável.

Toma 1ª dif : $\Delta y_t = \Delta \mu_t + \Delta \varepsilon_t$

e $\Delta \mu_t = \beta_{t-1} + \eta_t$ → Não é estacionário
pois β_t é uma RW

Toma 2ª dif:

$$\Delta^2 y_{t-1} = \Delta \beta_{t-1} + \Delta \eta_t + \Delta^2 \varepsilon_t$$

$$\therefore \Delta^2 y_t = z_{t-1} + \Delta \eta_t + \Delta^2 \varepsilon_t \quad \Rightarrow \text{aqui chegamos a um processo}$$

sistema RB do lado direito

Agora: precisa identificar o modelo ARIMA ao qual se relaciona.

Ver FAC's.

Teremos $E(\cdot)$, $\text{var}(\cdot)$ e $\gamma(k)$

$$w_t = z_{t-1} + \Delta \eta_t + \Delta^2 \varepsilon_t$$

$$\hookrightarrow (1-L)^2 \varepsilon_t = (1-2L+L^2) \varepsilon_t$$

$$\rightarrow E(w_t) = 0$$

$$\begin{aligned} \rightarrow \text{var}(w_t) &= \gamma(0) = \text{var}[z_{t-1} + \eta_t - \eta_{t-1} + \varepsilon_t - 2\varepsilon_{t-1} + \varepsilon_{t-2}] \\ &= \sigma_z^2 + 2\sigma_\eta^2 + 6\sigma_\varepsilon^2 \quad (\text{ver cálculos}) \end{aligned}$$

$$\rightarrow \text{cov}(w_t, w_{t-k}) = \begin{cases} -\sigma_\eta^2 - 4\sigma_\varepsilon^2, & k=1 \\ \sigma_\varepsilon^2, & k=2 \\ 0, & k \geq 3 \end{cases} \Rightarrow \text{MA}(2)$$

$$\text{TLL} \Rightarrow \text{MA}(2) \Rightarrow 3 \text{ hiperparâmetros} : \Psi^{\text{TLL}} = (\sigma_z^2, \sigma_\eta^2, \sigma_\varepsilon^2)$$

$$z_t = \theta_1 w_{t-1} + \theta_2 w_{t-2} + w_t \quad w_t \sim N(0, \sigma_w^2) : \Psi^z = (\theta_1, \theta_2, \sigma_w^2)$$

3 hiperparâmetros \Rightarrow precisamos de 3 equações.

variância, $\gamma(1)$ e $\gamma(2)$

$$E(w_t^2) = E(z_t^2)$$

$$E(w_t w_{t-1}) = E(z_t z_{t-1})$$

$$E(w_t w_{t-2}) = E(z_t z_{t-2})$$

forma reduzida
do TLL

MA(2)

tilbra

Restrições sobre θ_1 e θ_2 M MA(2) invertível

→ está w_t em função de z_t

$$z_t = (1 + \theta_1 L + \theta_2 L^2) w_t$$

$$\Rightarrow \phi(L) = 1 + \theta_1 L + \theta_2 L^2 \neq 0$$

$$(\lambda_1, \lambda_2) \text{ com } |\lambda_i| > 1 \quad \forall i=1,2$$

↓

Essa restrição pode ser mapeada em θ_1 e θ_2

Escrevendo $(L - \lambda_1)(L - \lambda_2)$

e veremos que θ_1 e θ_2 têm que estar numa certa região.

Ver pg. 25.

(Na realidade, escrevendo

$$f(v) = v^2 + \theta_1 v + \theta_2 \quad \text{com } |v_i| < 1$$

θ_1 e θ_2 não podem estar em toda a região nem compatíveis com MLL.

Ver áreas hachuradas na pg. 25.

Se acharmos θ_1 e θ_2 fora dessa região \Rightarrow Não está boa

idéia aproximá-lo

por MLL.

Ver pg. 27 \Rightarrow outros modelos de tendência

— II —

Sazonalidade \rightarrow Notas IV de aulas.

(eventos periódicos

período + re-regular.

ocorre no decorrer de 1 ano.

Diferença sazonalidade e ciclo: no período

dentro de 1 ano
por questões climáticas,
convenções sociais/adm

periodicidade nas séries
bem definida, ex. ciclos
econômicos.

(Tanto questões do período quanto
quanto de amplitude)

As questões naturais e mais bem
definidas.

=> O que é sazonal é operado.

temos que tirar da série as variações operadas por conta da
sazonalidade e avaliar tendência.

Não há maneira única de decompor série em tend. e sazonalidade.

Se vir série dessazonalizada => precisa saber qual foi o método
de dessazonalização.

Pode saber se série foi pouco dessazonalizada => Ver pela FAC se

ainda há ciclo em $k=12$

$$y_t^{(1)} = y_t - \delta_t$$

$y_t^{(1)}$ não é a tendência => há o erro ainda.

$$y_t = \mu_t + \delta_t + \epsilon_t \Rightarrow y_t - \delta_t = \mu_t + \epsilon_t$$

$\underbrace{y_t - \delta_t}_{y_t^{(1)}}$

é mais suave.

(picos da sazonalidade são retirados da série)

pg 3 das Notas IV

Dois tipos de sazonalidade: aditiva e multiplicativa

$$y_t = \mu_t + \delta_t + \varepsilon_t$$

\downarrow \downarrow
 tendência sazonalidade

• Veremos principais formas de se eliminar a sazonalidade

• Primeiros tratamentos no contexto determinístico.

Sazonalidade determiníst. surge da estocástica q^{da} alguma σ^2 por a zero.

Três modelos:

Obs: No caso de ST, ARIMA 12

$$y_t = \phi y_{t-1} + \phi_{12} y_{t-12} + \varepsilon_t$$

sazonalidade tratada internamente

Não dá pr filtrar a sazonalidade

(Não usamos)


1) Dummy

ST trimestral

1 dummy pr cada trimestre

β intercepto

4 variáveis explicativas



	t	D1 _t	D2 _t	D3 _t	D4 _t
2010	Q1	1	0	0	0
	Q2	0	1	0	0
	Q3	0	0	1	0
	Q4	0	0	0	1
2011	Q1	etc.			
	Q2				
	Q3				
	Q4				

Modelos poderiam ser trivialmente estimados por MQO

$$y_t = \beta + \sum_{j=1}^4 \gamma_j D_{jt} + \epsilon_t$$

Problema \rightarrow Não poderemos colocar tantas dummies quanto

os períodos da série, não conseguiremos resolver

o problema por MQO por conta de multicolinearidade perfeita

pg 10

$$(X'X) \Rightarrow \hat{\beta} = (X'X)^{-1} X'y$$

6
Não será inversível

Ver parametrizações possíveis

(i), (ii), (iii)

\rightarrow Usaremos parametrizações (iii)

pg 19.


de forma geral, temos:

$$\begin{cases} y_t = \mu_t + \delta_t + \varepsilon_t \\ \mu_{t+1} = \mu_t + \eta_t \\ \delta_t = ? \end{cases}$$

como explicitamos?

Ponto de Partida

$$\sum_{j=1}^4 \delta_j = 0 \quad (\text{da parametrização iii})$$



: como tudo é determinístico,
 e andarmos mas cobrimos
 sempre 4 trimestres \Rightarrow temos
 somatório = 0.

S=4

$$\Leftrightarrow \sum_{j=0}^{4-1} \delta_{t-j} = 0$$

$$\text{pois } \delta_t + \delta_{t-1} + \delta_{t-2} + \delta_{t-3} = 0$$



Qualquer que seja t: cobrimos o período.

obs: $\delta | \theta \Rightarrow$ coeficientes que x demais variáveis (nos exs.)(nas tem a ver com γ do ME).

$$\text{faremos: } \sum_{j=0}^{4-1} \delta_{t-j} = w_t, \quad w_t \sim N(0, \sigma_w^2)$$

(flutuações estocásticas)

$$(\text{obs: } E[\sum \delta_{t-j}] = 0)$$

$$\delta_t = - \sum_{j=1}^{s-1} \delta_{t-j} + w_t$$

— Dummies ficam implícitas

Nas ferias mais $D_{it}, E_{it} \dots$

Faemos apenas δ_t correspondente

do período em que estamos trabalhando

$$\Rightarrow \begin{cases} y_t = \mu_t + \delta_t + \varepsilon_t \\ \mu_{t+1} = \mu_t + \gamma_t \\ \delta_t = - \sum_{j=1}^{s-1} \delta_{t-j} + w_t \end{cases}$$

determinado
trimestre

<u>t</u>		<u>t+1</u>	(dados trimestrais)
Q1 2010 (p. ex.)	\Rightarrow	Q2 2010	

$\delta_{1,t}$	=	$\delta_{2,t+1}$	$\left\{ \begin{array}{l} \text{rearrumando os fatores} \\ \text{sazonais no trimestre} \end{array} \right.$
$\delta_{2,t}$	=	$\delta_{3,t+1}$	
$\delta_{3,t}$	=	$\delta_{4,t+1}$	
$\delta_{4,t}$	=	$\delta_{1,t+1}$	

• Como $\delta_{1,t+1} = \delta_{4,t}$ e $\delta_{4,t} + \delta_{3,t} + \delta_{2,t} + \delta_{1,t} = 0$

$$\Rightarrow \delta_{4,t} = -(\delta_{3,t} + \delta_{2,t} + \delta_{1,t})$$

$$\Rightarrow \delta_{1,t+1} = -\delta_{4,t} = -\delta_{1,t} - \delta_{2,t} - \delta_{3,t} + w_t$$

↑
coloca choque w_t
no estocástico.

• $\delta_{2,t+1} = \delta_{1,t}$

$\delta_{3,t+1} = \delta_{2,t}$

Tratando apenas a sazonalidade em y_t :

$$y_t = (1 \ 0 \ 0) \begin{pmatrix} \delta_{1t} \\ \delta_{2t} \\ \delta_{3t} \end{pmatrix} + \varepsilon_t$$

$$\begin{pmatrix} \delta_{1,t+1} \\ \delta_{2,t+1} \\ \delta_{3,t+1} \end{pmatrix} = \begin{pmatrix} -1 & -1 & -1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix} \begin{pmatrix} \delta_{1t} \\ \delta_{2t} \\ \delta_{3t} \end{pmatrix} + \begin{pmatrix} w_t \\ 0 \\ 0 \end{pmatrix}$$

No modelo original:

$$\delta_t = \sum_{j=1}^{3-1} \delta_{t-j} + w_t \Rightarrow \delta_t = -\delta_{t-1} - \delta_{t-2} - \delta_{t-3} + w_t$$

$$\delta_{t+1} = -\delta_t - \delta_{t-1} - \delta_{t-2} + w_t$$

$$\Rightarrow y_t = \delta_t + \varepsilon_t$$

$$\delta_{t+1} = -\delta_t - \delta_{t-1} - \delta_{t-2} + w_t$$

$$\Rightarrow \begin{pmatrix} \delta_{t+1} \\ \delta_t \\ \delta_{t-1} \end{pmatrix} = \begin{pmatrix} -1 & -1 & -1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix} \begin{pmatrix} \delta_t \\ \delta_{t-1} \\ \delta_{t-2} \end{pmatrix} + \begin{pmatrix} w_t \\ 0 \\ 0 \end{pmatrix}$$

última parametrização

Esta é a forma + simples de incluir racionalidade no ME.

Obs: Se considerarmos tendência \Rightarrow matriz T é diagonal em blocos.

Não haverá influência das comp. de tendência na racionalidade e vice-versa.

pag 19: Modelo estrutural Básico.

Uilbra

→ Sazonalidade por funções trigonométricas

Fator sazonal em t será dado por

$$\gamma_t = \sum_{j=1}^{s/2} (\gamma_j \cos \lambda_j t + \gamma_j^* \sin \lambda_j t)$$

Exemplo:

$$\begin{cases} y_t = \gamma_t + \varepsilon_t \\ \gamma_t = \sum_{j=1}^2 [\gamma_j \cos(\lambda_j t) + \gamma_j^* \sin(\lambda_j t)] \end{cases} \quad \rightarrow s=4: \text{ST trimestral}$$

$$\lambda_j = \frac{2\pi j}{s} = \frac{2\pi j}{4} = \frac{\pi}{2} j, \quad j=1, 2$$

Abrindo expressões para γ_t :

$$\gamma_t = [\gamma_1 \cos(\lambda_1 t) + \gamma_1^* \sin(\lambda_1 t)] + [\gamma_2 \cos(\lambda_2 t) + \gamma_2^* \cancel{\sin(\lambda_2 t)}]$$

$$\bullet \text{ Para } j=2 \Rightarrow \frac{\pi}{2} j = \pi \therefore \sin(\lambda_2 t) = \sin(\pi t) = 0 \quad \forall t$$

$$\Rightarrow y_t = \underbrace{\gamma_1 \cos(\lambda_1 t)}_{x_{1t}} + \underbrace{\gamma_1^* \sin(\lambda_1 t)}_{x_{2t}} + \underbrace{\gamma_2 \cos(\lambda_2 t)}_{x_{3t}} + \varepsilon_t$$

Precisaremos estimar 3 parâmetros (série trimestral, associadas à sazonalidade

$$\gamma_1, \gamma_1^* \text{ e } \gamma_2$$

como fazemos no caso determinístico).

(Não é coincidência).

Atencas! δ_1, δ_1^* e δ_2 sã os fatores racionais.

Eles sã dados por:

$$\delta_t = \underbrace{\hat{\delta}_1 \cos \lambda_1 t}_{\pi/2 t} + \underbrace{\hat{\delta}_1^* \sin \lambda_1 t}_{\pi/2 t} + \underbrace{\hat{\delta}_2 \cos \lambda_2 t}_{\pi t}$$

Para $Q_1 \rightarrow t=1$

$Q_2 \rightarrow t=2$

$Q_3 \rightarrow t=3$

$Q_4 \rightarrow t=4$

$Q_5 \rightarrow t=5$ da' a volta.

Se fizermos $t=1 \Rightarrow \delta_1$ sã o fator do 1º tri

(e numericamente sã = ao calculado

no modelo determinístico de param. fix)

Obs: NO somatório

Se $S=12 \Rightarrow$ somatório terã 6 cos e 6 sen

Para $j=1$: 1º harmônico (fundamental)

Para $j=2$: 2º harmônico

:

Na física \Rightarrow sã de temperatura e a + comportada em
relas a razionalidade.

Neste caso, sã sã necessário usar todos os
harmônicos, o 1º dita o comportamento.

Q^{to} + harmônicos usamos \Rightarrow mais esquentes sã os compa-
tamentos racionais

(k harmônicos + altos \hat{n} sã muito importantes

\Rightarrow sã sã estatisticamente

significantes)

mas sã sã abandonadas.

tilibra

Questões: como escrevemos este modelo na forma EE?

pg 26

$$y_t = \mu_t + \delta_t + \varepsilon_t$$

$$\delta_t = \sum_{j=1}^{12} \delta_{jt} \quad \text{onde } \delta_{jt} = \delta_j \cos(\lambda_{jt}) + \delta_j^* \sin(\lambda_{jt})$$

↙
vemos escrever δ_{jt} e obter como funções de t_{jt}
(ver apostila).

Modelo Airline

↙
sazonalidade multiplicativa

(amplitude aumentando no tempo)

→ Pacote STAMP

Formulate a model

Select components

level: μ_t } se ambos estocásticos \Rightarrow MLL

slope: β_t

(if slope \Rightarrow MML)

seasonal: (n aparece opcao dummy / trison.)

Estimation model: Maximum likelihood

No resultado \Rightarrow Summary statistics: do resíduo

libra

Normality \Rightarrow teste Jarque-Bera.
Q autocorrelação dos resíduos
 $\rho^2 = 1 - \rho^2$

H: rejeita hipótese
de homoscedasticidade.

Variances of disturbances:

$\sigma_\epsilon^2 \Rightarrow$ pequena em relacões aos outros pois as 3 components explicam

σ_η^2 praticamente todo

σ_v^2

σ_w^2

obs: 11 extrações de components

\Rightarrow faz sempre smoothing

Resíduo \tilde{u} está legal: crescendo e muita autocorrelação
(modelo mal especificado)


Olhando praticamente

prático

μ_t
suavizada

(level $\pm 2SE$)

2 desvios
padrão



$$\hat{\mu}_{t|n} \pm 1.96 \sqrt{\text{var}(\hat{\mu}_{t|n})}$$

$$P_{t|n} = E[(\alpha_t - \hat{\alpha}_t)(\alpha_t - \hat{\alpha}_t)']$$

$\hookrightarrow 13 \times 13$

$$\begin{bmatrix} \text{1º elemento} \\ \vdots \\ \text{é o do } \mu \end{bmatrix}$$

Temos prático μ_t

Temos " μ_t irregular \Rightarrow praticamente zero pois suavizada "rouba"
praticamente toda info.

" " " sazonalidade

Reestimar o modelo \Rightarrow log(airline)

• olhando summary statistics \Rightarrow H cai

• olhando distribuições (variâncias)

level praticamente fixo.

seasonal " determinístico

pede Anti-log analysis

$$\Rightarrow \text{Fez } \log y_t = \mu_t + \delta_t + \varepsilon_t$$

Depois que estimamos,

$$\log y_t = \hat{\mu}_t + \hat{\delta}_t$$

$$\Rightarrow y_t = e^{\hat{\mu}_t} e^{\hat{\delta}_t}$$

(escala original da série)

Resultados:

• resíduos padronizado: $\hat{v}_t^* = y_t - \hat{y}_{t|t-1}$

(V)
(F_t)

25/05/11

Aula passada:

- Sazonalidade
 - (estocástica)
 - (determinística)
 - ↳ caso particular da estocástica
- ↳ dummies
- ↳ trigonométricas

Notas V

pg 3.

MEB: Modelo Estrutural Básico

$$y_t = \mu_t + \gamma_t + \varepsilon_t$$

duas componentes principais (tendência + sazonalidade)

 μ_t : tend. linear stoc. γ_t : sazonal. estocástica

Forma reduzida de um MEB:

↳ é identificável.

muito conhecido.

mas qual o modelo SARIMA equivalente?

↳ tem que ser SARIMA (por conta da sazonal.)

SARIMA (p, d, q) × (P, D, Q)?

operador de diferenciação sazonal

$$\Delta_s \equiv I - L^s \quad \text{freq. da sazonalidade e é sempre conhecida}$$

(trimestral, mensal etc.)

$$(\neq \Delta = I - L)$$


$\Delta_s y_t = y_t - y_{t-s}$ se sazonalidade forse determinística, esta operação elimina totalmente a sazonalidade.

Só se deve operar a saz. estocástica numa série já diferenciada em relação a tendência.


D \Rightarrow retira a estacionariedade na tend.

Δ_s \Rightarrow " " " na sazonalidade

Para a série y_t



\Rightarrow modelo ^{com \hat{n} stac.} sazonal, decaimento nos períodos de saz. é lento



\Rightarrow modelo após aplicação Δ_s
 \Rightarrow decaimento rápido

É import. sazonalidade estacionária no contexto BRT
No contexto ME \hat{n} é necessário (nem p/ tend), mas vamos precisar verificar p/ olhar forma reduzida.

Precisamos definir tb:

$S_s(L) \hat{=} 1 + L + L^2 + \dots + L^{s-1} \rightarrow$ operador: vamos precisar dele

$$\Delta S_s(L) = (1-L) * (\quad) = \Delta_s = (1-L^s)$$

Vai tirando diferenças.

Quando para? \Rightarrow quando obtivermos do lado direito apenas
funções dos erros.

(ps4)

⊛ operadores $S(L)$ e Δ comutam.

Na
expressão.

$$\underbrace{S(L) \Delta \Delta y_t}_{\Delta S(L)} = \Delta S \Delta y_t$$

O termo diferenciado da sazonalidade não;

$$\rightarrow \text{Como } S(L) \delta_t = w_t \Rightarrow \text{Divide}$$

$$\rightarrow \Delta^2 S(L) \delta_t = \Delta^2 w_t$$

Recapitulando até aqui:

\rightarrow Partida: MEB

\rightarrow Chegada: forma reduzida

$$y_t = \mu_t + \delta_t + \varepsilon_t$$

$$\Delta \Delta y_t = \Delta \delta_t + \Delta \Delta \varepsilon_t + \Delta^2 w_t + S(L) \delta_t$$

$$\mu_t = \mu_{t-1} + \beta_{t-1} + \eta_t$$

\downarrow

apenas uma equação

é um
estado,
mas η
é componente
(η aparece
em y_t)

$$\beta_t = \beta_{t-1} + \zeta_t$$

$$S(L) \delta_t = w_t$$

(equivalente a modelo ARIMA)

$$z_t = ? \quad (\text{série correspondente})$$

$$E[z_t] = 0$$

$$\gamma(0) = E[z_t^2] = \dots$$

$$\gamma(j) = E[z_t z_{t-j}] = \dots$$

tilibra

Precisa desenvolver tudo:

$$z_t = \eta_t - \eta_{t-1} + (1-L)(\varepsilon_t - \varepsilon_{t-1}) + (1-L)^2 w_t + (1+L+\dots+L^{s-1})\{\}_{t-1}$$

ver resultados na pg 4

Obs: Quando modelamos por B&J, ~~razionalmente~~ modelamos por um modelo $MA(s+1)$.

A classe + comum de modelos usados é SARIMA multiplicativo

No caso que vimos \rightarrow modelo de saz. aditiva

Olhando as autocorrelações

temos as que correspondem a relações de CP e a relações (e as intermediárias) ~~razonais~~

Se, por ex., tivermos $s=4$:

$$\Delta \Delta_s y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \theta_3 \varepsilon_{t-3} + \theta_4 \varepsilon_{t-4} + \theta_5 \varepsilon_{t-5}$$



$MA(s+1)$

\rightarrow saz. aditiva

Nas raras vezes usamos este modelo dito de saz. aditiva.

Mais comum usar SARIMA multiplicativo.

$$\Delta \Delta_s y_t = \left[\frac{\Theta_q(L^s)}{\Phi_p(L^s)} \right] \eta_t$$

\hookrightarrow caracteriza dep. sazonal

$$\Theta_q(L) = 1 + \theta_1 L^s + \theta_2 L^{2s} + \dots + \theta_p L^{ps}$$

$$\Phi_p(L) = 1 - \phi_1 L^s - \phi_2 L^{2s} - \dots - \phi_p L^{ps}$$

Ajust. dep. sazonal,

mas n a relação de CP dependência

⇒ η_t ainda não está RB.

Pressão ajustada tb.

$$\varphi(L) \eta_t = \theta(L) \varepsilon_t \Rightarrow \eta_t = \frac{\theta_q(L)}{\varphi_p(L)} \varepsilon_t \quad (\text{agora sim } \varepsilon_t \text{ é RB})$$

$$\Rightarrow \Delta \Delta_s y_t = \frac{\Theta_q(L^s)}{\Phi_p(L^s)} \theta_q(L) \varepsilon_t$$

$$\Rightarrow \boxed{\Phi_p(L^s) \varphi_p(L) \Delta^d \Delta_s y_t = \Theta_q(L^s) \theta_q(L) \varepsilon_t} \Rightarrow \text{SARIMA}$$

Exemplo: $d = 0, 1, 2$

$\Rightarrow p = P = 0$

$D = 0, 1, 2$

$d = D = 1$

$q = Q = 1$

Fazendo $s = 4$

Não tem
para AR

$$\begin{aligned} \Delta \Delta_s y_t &= (1 + \Theta_1 L^4)(1 + \theta_1 L) \varepsilon_t \\ &= (1 + \Theta_1 L^4)(\varepsilon_t + \theta_1 \varepsilon_{t-1}) \\ &= \varepsilon_t + \theta_1 \varepsilon_{t-1} + \Theta_1 \varepsilon_{t-4} + \Theta_1 \theta_1 \varepsilon_{t-5} \end{aligned}$$

apenas θ_1 e Θ_1 como parâmetros

(aparece termo multiplicativo $\Theta_1 \theta_1$, daí o nome

SARIMA multiplicativo).

o FACp

des: Olha FAC. [✓] Pode ver direto MA ou AR.

& não ⇒ não ARMA

Usa critérios de identificação (AKAIKE, BIC etc.)

Aqui será a mesma coisa, mas temos que definir não só p, q , mas tb P, Q .

Libra

Olhamos AIC, BIC \Rightarrow ^{de} escolher o melhor ajuste

\Rightarrow Modelos multiplicativos \Rightarrow + parcimoniosos do que aditivos
mas tem de se olhar aditivos e calcular AIC e BIC M
escolher melhor modelo.

No exemplo anterior

SARIMA: $(0, 1, 1) \times (0, 1, 1) \Rightarrow$ Modelo Airline

(é um ponto de partida

M modelagem de ST

no acabamento de B&J)

Airline \Rightarrow modelo multiplicativo da parte sazonal e

parte \hat{n} sazonal: $\Phi_p \times \Psi_p$ e $\Theta_q \times \Psi_q$

Voltando às notas de aula: (pg 5)

Para Modelo Airline (SARIMA $(0, 1, 1) \times (0, 1, 1)$)

$$E[z_t] = 0$$


$$\gamma(0) = E[z_t^2]$$

$$\gamma(k) = E[z_t z_{t-k}] \Rightarrow \gamma(k) = 0 \text{ M } k=2 \text{ a } 5-2$$

$$\gamma(5-1) = \theta \sigma^2$$

$$\gamma(5) = \theta(1 + \theta^2) \sigma^2$$

$$\gamma(5+1) = ;$$



Que tipo de restrições básicas devemos impor ao MEB para
comunicar com AIRLINE?

forma reduzida do MEB ($\sigma_\eta^2 = \sigma_\omega^2 = 0$)



inclinação
cas

razonabilidade

(**) pg 5:

$$\text{MEB com } \sigma_\eta^2 = 0 \text{ e } \sigma_\omega^2 = 0 \Rightarrow \begin{cases} w_t = 0 \quad \forall t \\ \xi_t = 0 \quad \forall t \end{cases}$$

(tomar eq. reduzida geral e fazer $\sigma_\eta^2 = 0$ e $\sigma_\omega^2 = 0$):

$$\begin{aligned} \Delta \Delta_s y_t &= \Delta_s \eta_t + \Delta_s \Delta \varepsilon_t \\ &= \Delta_s (\eta_t + \Delta \varepsilon_t) \end{aligned}$$

$$\text{MA}(1) \Rightarrow z_t = \eta_t + \Delta \varepsilon_t = \eta_t + \varepsilon_t - \varepsilon_{t-1}$$

$$\sim \text{MA}(1) \Rightarrow \text{(prova)} \text{ usando FAC} \\ = \theta \varepsilon_{t-1} + \varepsilon_t$$

$$= \Delta_s (1 + \theta L) \varepsilon_t$$

$$\Delta \Delta_s y_t = (1 - L^s)(1 + \theta L) \varepsilon_t$$

$$\text{P/O Airline, temos: } \Delta \Delta_s y_t = (1 + \theta_s L)(1 + \theta_s L^s) \varepsilon_t$$

A correspondência se dá quando $\theta_s = -1$



Modelo $\tilde{\pi}$ é invertível na
parte sazonal.

Modelo de ciclo (pg. 4)

$$y_t = \mu_t + \psi_t + \varepsilon_t$$

??

: decomposição

mas é única,

componentes competem a explicar y_t

há modelos em que choque de μ_t e ψ_t

são correlatados ou não correlatados

↓


se for, geralmente não é identificável

(verificar se for perfeitamente

Dúvida

correlatado tb?)

Versões determinísticas



$$y_t = \mu_t + \psi_t + \varepsilon_t$$

↓

Na sazonalidade, temos ψ_t harmônicas

No ciclo, μ_t cada ciclo é particular \Rightarrow 1 frequência

$$\text{faz: } \delta_t = \sum_{j=1}^{J/2} [\delta_j \cos(\lambda_j t) + \delta_j^* \sin(\lambda_j t)]$$

$$\lambda_j = \frac{2\pi j}{s}$$

fácil de ser
estimado pois
s é conhecido.

Transforma

$\cos(\lambda_j t)$ e $\sin(\lambda_j t)$

em variáveis explicativas

\Rightarrow estima por MQO

na questão do ciclo, λ_c é fundamentalmente desconhecido

(nã sabemos direito qual o T, períodos do ciclo)

mas pode-se ter alguma ideia, pois quando vamos atrás de um já temos uma ideia pré-concebida do que buscamos.

Se formos estimar por MQO:

$$y_t = \alpha \cos \lambda_c t + \beta \sin \lambda_c t$$

nas suas funções conhecidas no tempo.

$$y_t = \mu + \underbrace{\alpha \cos \lambda_c t}_{x_{1t}} + \underbrace{\beta \sin \lambda_c t}_{x_{2t}} + \varepsilon_t \quad t=1, \dots, T$$

$$\lambda_c = \frac{2\pi}{T}$$

se conhecemos T, teríamos

representações lineares triviais q 2

variáveis explicativas

$$\text{por MQO: } S(\mu, \alpha, \beta, T_c) = \sum_{t=1}^T \left[y_t - \left(\mu + \cos\left(\frac{2\pi}{T}\right)t + \sin\left(\frac{2\pi}{T}\right)t \right) \right]^2$$

$$\frac{dS}{dT} = 0 \quad \leftrightarrow \quad \bar{T} \text{ é linear}$$

NAS poderemos usar MQO.

Teremos MQ NAS lineares

(montamos como MQ e solucionamos como MQNL)

Depois de obter o modelo, devemos obter R^2 .

Ex: Acharmos $T=13,4$ anos e $R^2=25\% \Rightarrow$ componente cíclica só explica 25% da série. (o resto poderia ser completamente aleatório).

Libbra

NAS podemos acreditar no T encontrado.

É uma informação problemática.

Pode ser espúrio.

↳ Tem sempre que ter uma ligação com a área de estudo,
de trabalho.

O achado estatístico do ciclo deve ter repêto teórico
bem embasado.

— " —

Para sazonalidade, fizemos:

$$\begin{cases} y_t = \mu_t + \gamma_t + \varepsilon_t \\ \gamma_t = \sum_{j=1}^{s/2} \gamma_{jt} \end{cases}$$

$$\begin{pmatrix} \gamma_{jt} \\ \gamma_{jt}^* \end{pmatrix} = \begin{pmatrix} \cos \lambda & \sin \lambda \\ -\sin \lambda & \cos \lambda \end{pmatrix} \begin{pmatrix} \gamma_{j,t-1} \\ \gamma_{j,t-1}^* \end{pmatrix} + \begin{pmatrix} w_t \\ w_t^* \end{pmatrix}$$

→ ruído σ_w^2

Obs: Neste modelo,
ruído σ_w^2 em todos
os harmônicos.

Para o ciclo: só temos uma frequência ($j=1$)

NAS não mais γ_t e sim ψ_t pois estamos tratando de ciclo.

$$y_t = \mu_t + \psi_t + \varepsilon_t$$

$$\begin{pmatrix} \psi_t \\ \psi_t^* \end{pmatrix} = \rho \begin{pmatrix} \cos \lambda_c & \sin \lambda_c \\ -\sin \lambda_c & \cos \lambda_c \end{pmatrix} \begin{pmatrix} \psi_{t-1} \\ \psi_{t-1}^* \end{pmatrix} + \begin{pmatrix} k_t \\ k_t^* \end{pmatrix}$$

→ σ_k^2

$$|\rho| < 1$$

contribui m que
ciclo fique vivo.

↳ contribui m amortecimento
do choque

Se fizermos $\sigma_k^2 = 0$ (determinístico)

Caso particular: modelo de ciclo determinístico.


$$y_t = \mu + \psi_t + \varepsilon_t$$

$$\psi_t = \alpha \cos \lambda_c t + \beta \sin \lambda_c t$$

Obs: ρ - amortecimento

k_t - choque: mantém ciclo vivo

Fora da amostra, não tem choque. Previstas ter a casa:



Como o ciclo é estocástico, faz sentido o comportamento α ir a zero com o tempo.

A estimativa de ρ dirá isso. Se ρ for próximo de 1, ciclo mais persistente.

Na FEE:

$$y_t = \begin{pmatrix} 1 & 0 \end{pmatrix} \begin{pmatrix} \psi_t \\ \psi_t^* \end{pmatrix} + \varepsilon_t$$

$$\begin{pmatrix} \psi_t \\ \psi_t^* \end{pmatrix} = \rho \begin{pmatrix} \cos \lambda_c & \sin \lambda_c \\ -\sin \lambda_c & \cos \lambda_c \end{pmatrix} \begin{pmatrix} \psi_{t-1} \\ \psi_{t-1}^* \end{pmatrix} + \begin{pmatrix} k_t \\ k_t^* \end{pmatrix}$$

Γ

$\Gamma = \Gamma(\rho, \lambda_c = 2\pi/T) \Rightarrow$ matriz Γ tem parâ-

metros desconhecidos
agora.
(ρ, T). cálculo

observações:

i) se $\lambda_0 = 0$ ou π

$$\begin{pmatrix} \Psi_t \\ \Psi_t^* \end{pmatrix} = \rho \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \Psi_{t-1} \\ \Psi_{t-1}^* \end{pmatrix} + \begin{pmatrix} K_t \\ K_t^* \end{pmatrix}$$


$$\Rightarrow \Psi_t = \rho \Psi_{t-1} + K_t \quad \Rightarrow \text{processo AR(1)} \\ |\rho| < 1.$$

porque é importante termos um AR(1)

Ex: k modelo $y_t = \mu_t + \epsilon_t + E_t$

e tomamos $v_t^* = y_t - \hat{y}_{t|t-1}$ inovações

e FAC ainda apresenta resíduos



\Rightarrow usar Ψ_t como AR(1) pode ajudar a melhorar o modelo.

Obs: ~~pg 10~~ pg 10

Ψ_t : Ψ_t é exatamente determinístico.

$$y_t = \mu + (\alpha \cos \lambda_0 t + \beta \sin \lambda_0 t) + E_t$$

$$(\alpha, \beta) \sim N \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} \sigma^2 & 0 \\ 0 & \sigma^2 \end{pmatrix} \right)$$

α, β podem ser fixos e desconhecidos, podem ser multiva-

riados estocásticos.

há 2 formas de modelar.

SOFTWARE

→ usar dados à direita

STAMP

Rainberg (lírio chuvas em Fortaleza)

Adotando modelo: $y_t = \mu_t + \psi_t + \varepsilon_t$

$$\mu_t = \mu_{t-1} + \eta_t$$

(η_t inclinação)

Formulak o model

Select components:

level (stochastic)

Inclinação

Cycle (pode ter ciclos de periodicidade \neq)

