

PONTIFÍCIA UNIVERSIDADE CATÓLICA  
DO RIO DE JANEIRO



**Laboratório de Estatística Computacional**

**DEPARTAMENTO DE ENGENHARIA ELÉTRICA**

# **Modelos Estruturais para Séries Temporais**

Prof. Cristiano Fernandes  
2005

# **NOTAS DE AULA - I**

# 1. INTRODUÇÃO

## 1.1 Objetivos e Motivação:

- O objetivo central do curso é a apresentação e discussão dos algoritmos utilizados para estimação, previsão e alisamento dos modelos em espaço de estado gaussianos e lineares. (MEEGL) para séries temporais (ST).
- Os algoritmos a serem estudados são o filtro de Kalman, os algoritmos de suavização e a verossimilhança por decomposição de erro de previsão.
- Ênfase especial será dada a uma classe especial dos MEEGL, os modelos estruturais, onde será abordada a formulação clássica de Harvey et al.
- Nos modelos estruturais uma ST é decomposta em componentes de interesse, tais como tendência, sazonalidade e ciclo. Esquemáticamente:

$$\text{ST} = \text{Tendência} + \text{Sazonalidade} + \text{Ciclo} + \text{Irregular}$$

- Este tipo procedimento tem-se mostrado bastante útil na prática, fornecendo subsídios para a resposta de várias perguntas de interesse na modelagem de séries reais.

- Macroeconomia- I: é usual tentar separar as séries de produção (e.g., PIB, PDB) em duas componentes:

tendência + irregular/ciclo.

- Muitos economistas acreditam que superposta às flutuações de curta duração na atividade econômica, a economia evolui ao longo de um caminho de crescimento, o qual pode ser pensado como a tendência.

- Para facilitar o entendimento desta questão, pode-se pensar a economia como sendo afetada por dois tipos de choques:

⇒ **choques permanentes** = possuem efeito permanente na produção: aumento de produtividade, desenvolvimento tecnológico, aumento da força de trabalho, aumento do nível educacional, etc.

⇒ **choques transientes** = possuem efeito passageiro na produção: choques fiscais (diminuir impostos) e monetários (taxa de juros), greves, etc.

- Assim, nesta visão, a tendência seria a parte da produção econômica associada com choques permanentes, e seria não estacionária, por construção.

- A parte da produção associada aos choques transitórios seria o ciclo, estacionário por construção.

- A componente cíclica de séries macroeconômicas contém as frequências que possuem período identificado como pertencentes a “ciclos econômicos” típicos.
- Estes períodos se situam entre 6 e 32 trimestres, isto é, entre 1.5 e 8 anos, isto é , com frequências no intervalo  $2\pi/6 < \omega < 2\pi/3$ .
- Portanto as técnicas/modelos de extração da componente cíclica de séries macroeconômicas devem deixar passar freqs. nesta banda.

- Uma vez determinado um modelo de ST que decompõe a série do PIB em tendência e ciclo, pode-se, tentativamente, responder à seguinte questão: qual a componente que explica a maior parte das variações do PIB ?

⇒ se a componente cíclica no PIB não existir ou for desprezível, o governo não deve se preocupar com as políticas de curto prazo (choques fiscais e monetários), devendo-se concentrar nas políticas de longa duração (educação, etc).

Macroeconomia- II: a dinâmica de muitas séries macroeconômicas (produção, desemprego, M1, etc) apresenta variação sazonal, que é um tipo de flutuação já esperada. Muitas vezes é de interesse obter uma estimativa da série “descontada” da sazonalidade, de forma a fornecer uma direção “clara” do movimento da série. Para operacionalizar esta estimação precisamos de um modelo c/ a seguinte decomposição:

tendência + sazonalidade + irregular


Meteorologia: é sabido que muitas séries de chuvas possuem ciclo. Por exemplo, Fortaleza, c/ ciclo com período entre 11 e 13 anos.

⇒ Para respondermos a perguntas do tipo: " o próximo ano será de seca severa ?" necessitaríamos de um modelo com a seguinte decomposição:

tendência(?) + ciclo + irregular

- A modelagem de ST de CNO permite-nos construir uma resposta para estes tipos de indagações.

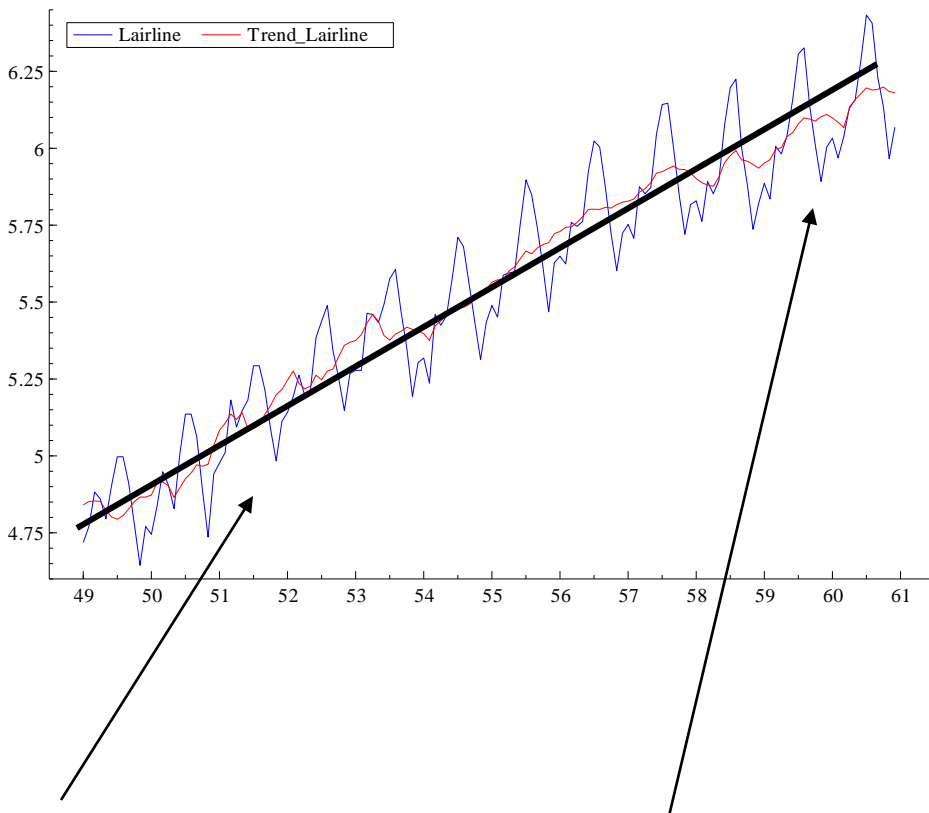
**Ex:  $\log(\text{airline}) = \text{Tendência} + \text{Sazonalidade} + \text{Irregular}$**





- As componentes de uma ST são também denominadas de atos estilizados.
- Uma dada ST pode possuir apenas alguns dos fatos estilizados listados.
- Estas componentes, em princípio, são estocásticas, ou seja, evoluem probabilisticamente ao longo do tempo. São também conhecidas por componentes locais.
- As componentes estocásticas contrapõe-se às componentes deterministas, cuja forma permanece inalterada ao longo do tempo, sendo por isso denominadas de componentes globais.
- Estudos empíricos (Nelson & Plosser, 1982) sugerem que, pelo menos para séries macroeconômicas, é mais adequado considerar que as componentes sejam estocásticas (raiz unitária).
- Nos modelos estruturais (ME) as componentes são estimadas recursivamente através de um algoritmo denominado de filtro de Kalman (FK), ou de forma mais completa utilizando os algoritmos de suavização.

## Exemplo de séries com componentes determinísticas e estocásticas: log(airline)



**tendência determinística**



$$\ln(y_t) = a + bt$$

**tendência estocástica**



**modelos estruturais**

- Observar os seguintes pontos nos modelos de CNO:

⇒ a natureza empírica das definições das componentes:

ex: o tamanho da ST pode determinar o que pode ser reconhecido como ciclo ou tendência;

⇒ o significado e a definição de uma componente depende da definição das outras componentes:

ex: a estimação da tendência necessita de um bom modelo para o ciclo e vice-versa;

⇒ a idéia defendida por alguns de que diferentes componentes presentes em uma ST estariam associadas à diferentes forças causais:

ex: as forças econômicas que impulsionam a tendência do nível da atividade econômica são independentes daquelas que criam as flutuações cíclicas.

⇒ a decomposição não é única, i.e., dado uma ST não-estacionária existem vários procedimentos de decomposição em tendência estocástica e ciclo, e os componentes efetivamente estimados por cada um destes procedimentos produzem diferentes estimativas dos componentes !

- Na literatura estatística contemporânea os modelos/métodos p/ ST baseados em CNO possuem a seguinte cronologia (não exaustiva):

1958- método de amortecimento exponencial de Holt (EWMA);  
1960- método de Holt-Winters p/ ST com tendência e saz.;  
1963- modelo de Brown;  
1976- modelos estruturais Bayesianos de Harrison-Stevens;  
1979- modelos de CNO de Nerlove e Carvalho;  
1983- modelos estruturais clássicos de Harvey;  
1988- modelos de Young;  
1990 em diante: modelos não-lineares/não-Gaussianos, utilizando métodos computacionalmente intensivos (MCMC, amostragem por importância, etc) p/ a sua estimação.

## 2. MODELOS DE TENDÊNCIA

### 2.1 Definição:

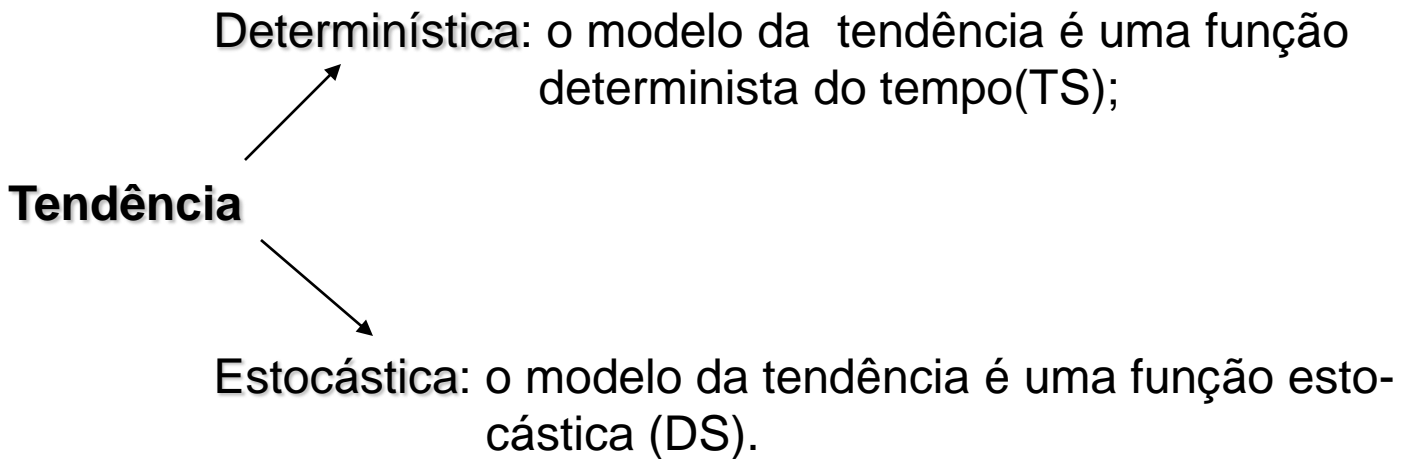
- O que é a tendência de uma ST ? várias definições...
  - parte da série que “muda pouco ao longo do tempo”;
  - componente de baixa frequência, que apresenta maior suavidade quando estimada;

*a trend is a trend is a trend  
but the question is, will it bend ?  
will it alter its course  
through some unforeseen force,  
and come to a premature end ?*

*Sir Alec Cairncross (1969)*

- A tendência de ST tem sido estimada através de:
  - filtros médias móveis;
  - regressão determinista em uma função do tempo;
  - modelos estocásticos.
- Inicialmente apresentaremos as principais distinções entre os modelos de tendência determinista e estocástica.

## 2.2 Classificação dos Processos de Tendência (Econometria)



- **Tendência Determinista ou processo *trend stationary* (TS):** definido pela seguinte equação:

$$y_t = \sum_{j=0}^d \beta_j t^j + \psi(L)a_t, \quad a_t \sim NID(0, \sigma^2)$$

onde  $\psi(L) = \sum_{j=0}^{\infty} \psi_j L^j$

Mostra-se que:  $E(y_t) = \sum_{j=0}^d \beta_j t^j$

$$\text{Var}(y_t) = \left( \sum_{j=0}^{\infty} \psi_j^2 \right) \sigma^2, \quad \sum_{j=0}^{\infty} \psi_j^2 < \infty$$

$$\gamma(k) = \sigma^2 (\psi_k \psi_0 + \psi_{k+1} \psi_1 + \psi_{k+2} \psi_2 + \dots)$$

- Caso particular: considere  $d=1$  e  $a_t \sim \text{AR}(1)$ :

$$y_t = \beta_0 + \beta_1 t + a_t,$$

$$a_t = \phi a_{t-1} + \varepsilon_t$$

$$|\phi| < 1, \varepsilon_t \sim \text{NID}(0, \sigma^2)$$

- Segue que:

$$E(y_t) = \beta_0 + \beta_1 t$$

$$\text{Var}(y_t) = \sigma^2 / (1 - \phi^2)$$

$$\rho(y_t, y_{t-k}) = \phi^k$$

- Previsão  $s$ -passos à frente:

$$y_t = \beta_0 + \beta_1 t + e_t$$

$$y_{t+s} = \beta_0 + \beta_1(t+s) + e_{t+s}$$

$$\hat{y}_{t+s|t} = E(y_{t+s} | Y_t) = \beta_0 + \beta_1(t+s) + E[e_{t+s} | Y_t]$$

$$\begin{aligned} \hat{y}_{t+s|t} &= \beta_0 + \beta_1(t+s) + e_t \phi^s \\ &= (y_t + \beta_1 s) + e_t(\phi^s - 1) \end{aligned}$$

$$\text{Var}(e_{t+s|t}) = \sigma^2 (1 - \phi^{2s}) / (1 - \phi^2) \quad s = 1, 2, \dots$$

- Para retirar a tendência do processo efetuamos uma regressão por MQO: a série s/ tendência será o resíduo da regressão

$$y_t^* = y_t - (\hat{\beta}_0 + \hat{\beta}_1 t) = \hat{a}_t$$

- Se tivéssemos retirado a tendência por primeira diferença:

$$w_t = y_t - y_{t-1} = \beta_1 + a_t - a_{t-1}$$

$$(1-L)(1-\phi L)y_t = \beta_1(1-\phi) + (1-L)\varepsilon_t$$

$$\Leftrightarrow y_t \sim ARIMA(1,1,1) \text{ com } \theta = 1.$$

- Portanto, a operação de filtrar a tendência por primeiras diferenças não será adequada se a tendência for determinista, (TS) pois implicará em um modelo MA não invertível, o que não é desejável do ponto de vista estatístico (pq ?)

- De um forma geral, p/ um processo TS genérico, com polinômio de grau d, necessitaríamos de diferenciar a série d vezes, introduzindo assim um processo MA c/ d raízes unitárias

$$y_t = \sum_{j=0}^d \beta_j t^j + \frac{\theta(L)}{\phi(L)} a_t \text{ então}$$




$$\nabla^d y_t = \theta_0 + \nabla^d [\theta(L) / \phi(L)] a_t$$

$$\theta_0 = d! * \beta_d.$$

- Exemplo de um processo TS sintético

$$y_t = 10 + 0.2t + a_t$$

$$a_t = 0.6a_{t-1} + e_t, e_t \sim NID(0,1)$$



## Exemplo de um processo TS ajustado à uma série com tendência estocástica

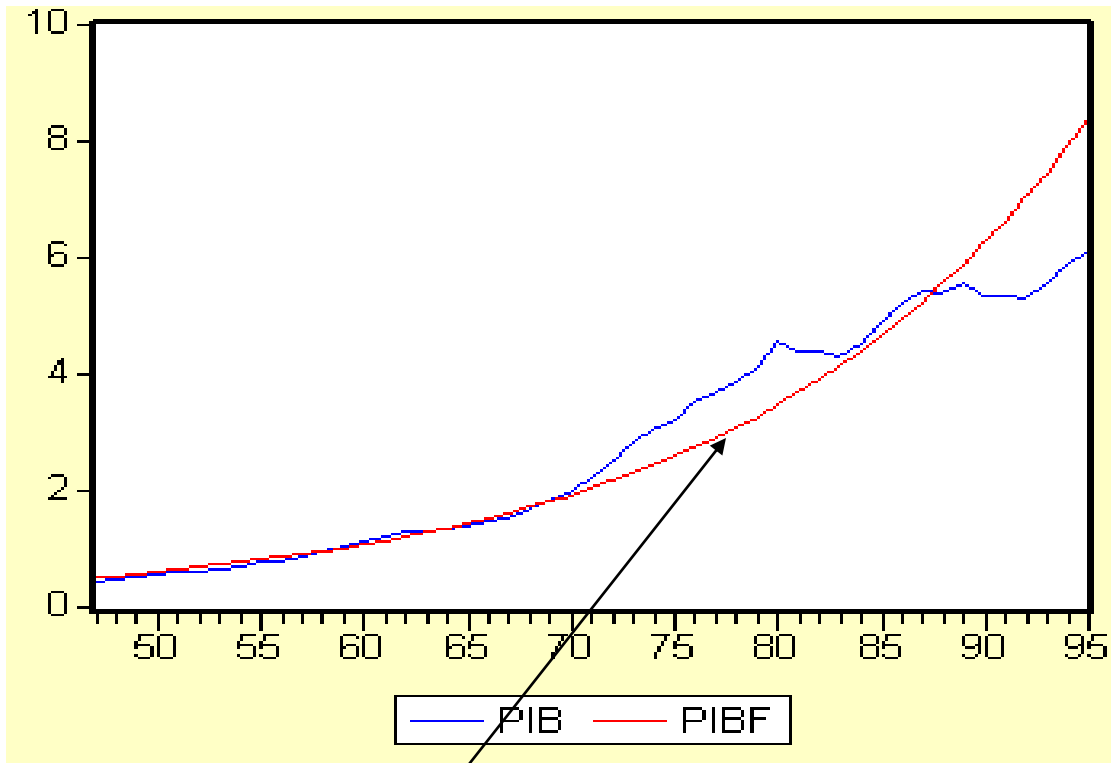
PIB anual brasileiro (1947-1995), preços de 1980

$$\text{PIB} = a \exp(bt) \exp(a_t), \quad a_t \sim N(0, \sigma^2)$$

$$\ln(\text{PIB}) = -0.711 + 0.0591 t$$

$t \quad (-16.770) \quad (38.799)$

$$R^2 = 0,97$$



**tendência determinística**

- Os processos TS foram utilizados em muitos trabalhos nas décadas de 70 e 80 p/ estimar a componente cíclica de agregados macro-econômicos:

$$y_t = a + bt + a_t, a_t \sim ARMA(p, q)$$

- Após estimado por MQO, o ciclo seria identificado com o resíduo do modelo.
- Problemas neste procedimento:
  - a componente cíclica fica super-dimensionada, podendo gerar ciclos espúrios;
  - no processo TS os choques possuem efeito transiente, i.e, somente afetam o processo no tempo t.
  - como o impacto das inovações tecnológicas na tendência possui efeito permanente, este só poderá ser capturado por uma tendência estocástica, ou DS.

- **Tendência Estocástica ou processos *difference stationary (DS)*:**

i. **passeio aleatório (random walk):** exemplo canônico de um processo não estacionário estocástico. Ex: série de preços de ativos na bolsa. Seja  $\varepsilon_t \sim \text{NID}(0, \sigma^2)$ .

$$y_t = y_{t-1} + \varepsilon_t \quad (AR \text{ com } \phi = 1)$$

$$y_t = y_0 + \sum_{i=1}^t \varepsilon_i$$

- Donde segue que:

$$E(y_t) = 0, \text{ se } y_0 = 0.$$

$$\text{Var}(y_t) = t \sigma^2$$

$$\rho(y_t, y_{t-k}) = \left(1 - \frac{k}{t}\right)^{1/2}$$

- Para retirar a tendência de um processo DS efetuamos um número de diferenciações adequadas:

$$\Delta y_t = \varepsilon_t.$$

- Para melhor entendermos a natureza do processo de diferenciação, um pouco mais de formalismo.

- Operadores:

- $L$  : operador de atraso  $L^k y_t = y_{t-k}$ .
- 1ª diferença:  $\Delta = 1 - L$  : operador de primeira diferença

$$\Delta y_t = (1 - L) y_t = y_t - y_{t-1}$$

- d diferenças:  $\Delta^d = (1 - L)^d$ ,  $d = 1, 2, 3, \dots$

$d$  = a ordem de integração da série: número de diferenciações para tornar a série estacionária.

se  $y_t \sim I(d) \therefore \Delta^d y_t$  é estacionária

Ex: - Ibovespa  $\sim I(1)$   
- retornos Ibovespa  $\sim I(0)$

ii. **passeio aleatório c/ drift**: Ex: PIB, M1 (\$ em circulação), preços no mercado financeiro.

$$y_t = a_0 + y_{t-1} + \varepsilon_t$$

$$y_t = y_0 + a_0 t + \sum_{i=1}^t \varepsilon_i$$

$$E(y_t) = y_0 + a_0 t$$

$$\rho(y_t, y_{t-k}) = \left(1 - \frac{k}{t}\right)^{1/2}$$

$$Var(y_t) = t\sigma^2.$$

- Vamos agora projetar a equação s passos à frente

$$y_{t+s} = y_0 + a_0(t+s) + \sum_{i=1}^{t+s} \varepsilon_i$$

$$y_{t+s} = \left(y_0 + a_0 t + \sum_{i=1}^t \varepsilon_i\right) + a_0 s + \sum_{i=t+1}^{t+s} \varepsilon_i$$

$$y_{t+s} = y_t + a_0 s + \sum_{i=t+1}^{t+s} \varepsilon_i$$

- Assim sendo num processo de passeio aleatório, que é um processo de tendência DS, os choques possuem efeito permanente, pois:

$$\frac{\partial y_{t+s}}{\partial \varepsilon_i} = 1, \quad i = 1, 2, \dots, t + s - 1$$

- Portanto um choque no passado não é esquecido no futuro, sendo seu efeito permanente. Contraste este resultado com o de um processo AR(1).

- Previsão s passos à frente


$$\hat{y}_{t+s|t} = E(y_{t+s} | Y_t) = y_t + a_0 s$$

$$Var(e_{t+s/t}) = Var\left(\sum_{i=t+1}^{t+s} \varepsilon_i\right) = s\sigma^2 \quad s = 1, 2, \dots$$

- Exemplos de séries sintéticas:


$$y_t = 2 + y_{t-1} + \varepsilon_t$$

$$\varepsilon_t \sim N(0,49), y_0 = 1$$



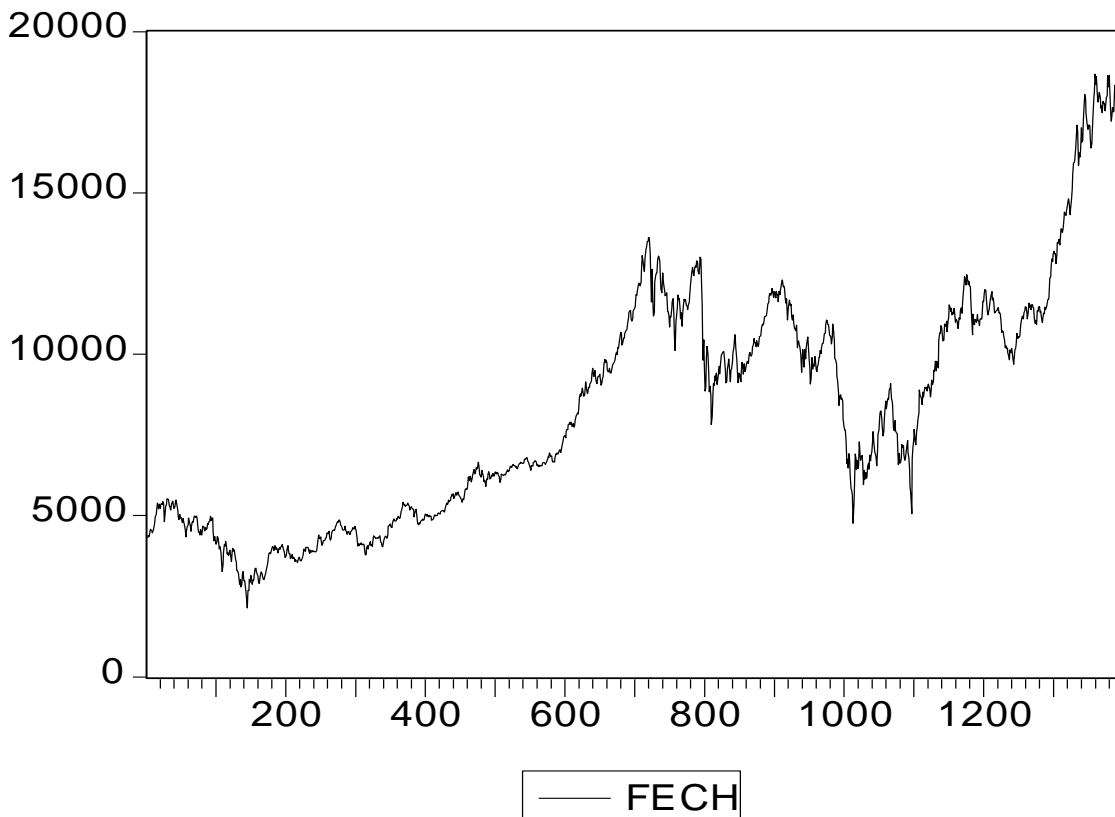
$$y_t = y_{t-1} + \varepsilon_t$$

$$\varepsilon_t \sim N(0,4), y_0 = 1$$





- Exemplo de série real descrita por um processo  
TS: cotação de fechamento do Ibovespa (01/08/94 à 31/03/2000)



Ajuste de um modelo AR(1) c/drift

$$\text{Ibov}_t' = 9.96 + 0.9998 \text{Ibov}_{t-1} \quad \sigma' = 230,86$$

Teste de Raiz unitária : ADF Test Statistic -1.586000

1% Critical Value -3.9698

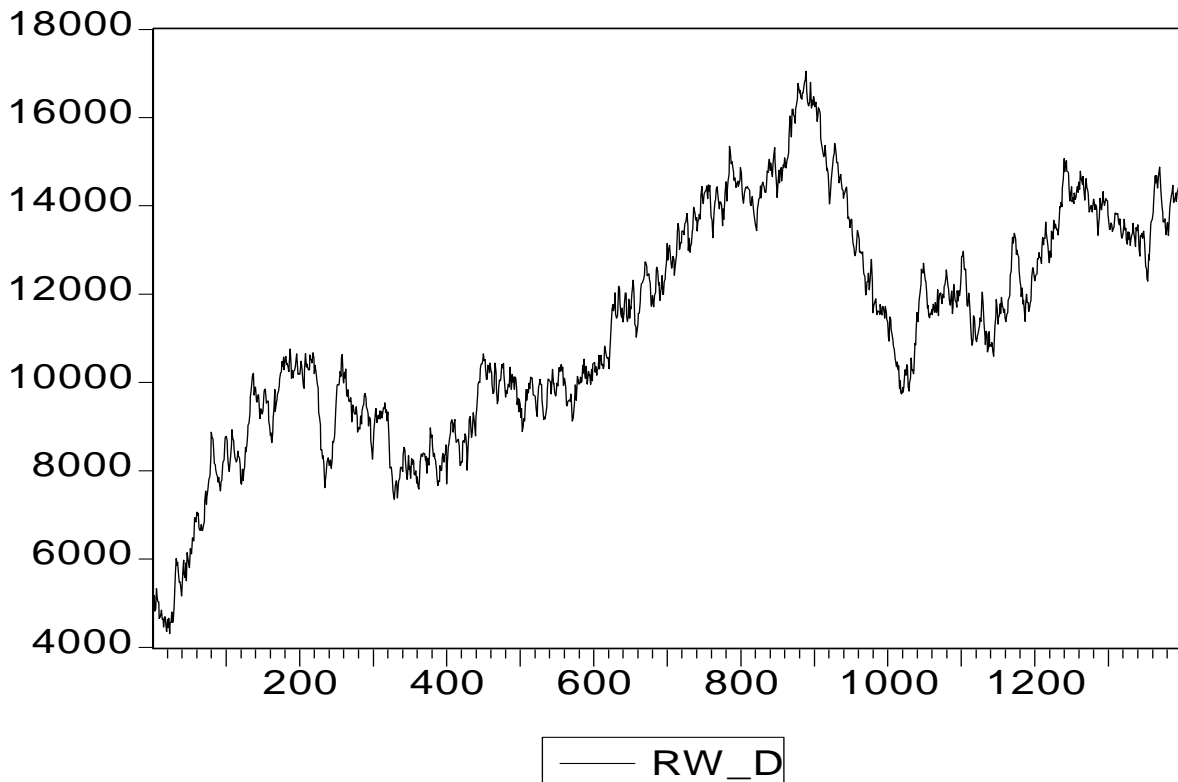
5% Critical Value -3.4155

10% Critical Value -3.1296

Realização do processo TS com parâmetros análogos ao do modelo estimado para a série do Ibovespa

$$y_t = 10 + y_{t-1} + \varepsilon_t$$

$$\varepsilon_t \sim N(0,231), y_0 = 5000$$



## Usando uma regressão TS para estimar um processo DS: os resultados de Nelson & Kang (1984):

- **Experimento:**

⇒ gerou a série através de um DS:  $y_t = y_{t-1} + \varepsilon_t$   
 $\varepsilon_t \sim N(0, \sigma^2)$

⇒ estimou por um TS:  $y_t = a + bt + u_t$   
 $u_t \sim N(0, \sigma_u^2)$

- **Resultados:**

i. se gerarmos uma ST RW , e regredirmos essa ST no tempo, usando MQO, o  $R^2$  será de aprox. 0.44, independente do tamanho da série (T). Este resultado é totalmente espúrio pois o RW não depende explicitamente do tempo.

ii. se o processo for um RW + drift, o  $R^2$  da regressão no tempo será ainda maior, e crescerá com T, alcançando o valor limite de 1 !

iii. os resíduos de uma regressão de um RW no tempo tendem a apresentar autocorrelações significativas p/ vários lags, com comportamento pseudo-cíclico de período aprox.  $2/3 T$ ! Estas autocorrelações são totalmente espúrias, e dependem de  $T$ .

Ex:  $n=100$ ,  $r=1000$ :  $r(1)=0.88$ ,  $r(2)=0.77$ ,  $r(3)=0.68$

⇒ podem sugerir um processo AR/ciclo (possivelmente não estacionário) p/ a série sem tendência ! O ciclo assim detectado é pura consequência da metodologia estatística em uso, não possuindo uma justificativa fundamental (efeito de Slutsky). Este efeito é também observado em outras metodologias de separação de componentes.

Obs: se um dado processo é DS, então a eliminação da tendência por regressão no tempo, não produzirá um processo estacionário. Isto é mais facilmente detectado para um processo RW + drift:

$$y_t = a_0 + y_{t-1} + \varepsilon_t$$

$$y_t = y_0 + a_0 t + \sum_{i=1}^t \varepsilon_i. \text{ Re tirando a tendência:}$$

$$z_t = y_t - a_0 t = y_0 + \sum_{i=1}^t \varepsilon_i, \text{ onde}$$

$$E(z_t) = y_0, \text{ mas}$$

$$\text{Var}(z_t) = t\sigma^2.$$

- Ou seja, os resíduos resultantes do ajuste de um processo DS por uma tendência determinística, não serão estacionários. Mais uma razão para que a eliminação da tendência em processos DS seja realizada através de diferenciação.

iv. o uso das estatísticas t's para testar a presença de dependência explícita de um RW no tempo, também produzirá resultados espúrios:

⇒ o teste rejeitará a hipótese de não relação com o tempo em 87% dos casos, para uma amostra de tamanho 100 e valor nominal de 5%, qdo na verdade não existe nenhuma relação !

- Em princípio, a identificação de uma tendência como TS ou DS pode ser realizada através de:

i. um teste de RU, embora, geralmente, estes testes não possuam poder elevado.

ii. ajustando um modelo estrutural com tendência estocástica e observando, pelos valores das variâncias dos erros, se a tendência é do tipo determinística. ( a ser visto).

- O teste de raiz unitária para distinguir tendências DS de TS é realizado utilizando eqs. do tipo (teste ADF tipo iii):

$$y_t = \alpha + \rho y_{t-1} + \beta t + \varepsilon_t$$

$$\Delta y_t = \alpha + \gamma y_{t-1} + \beta t + \varepsilon_t, \quad \gamma = \rho - 1$$

Ho:  $\gamma = 0, \beta = 0$  tendência DS

Ha:  $\gamma < 0, \beta \neq 0$  tendência TS

Ho:  $\gamma = 0, \beta \neq 0$  tendência mista DS e TS

- Na literatura econométrica/estatística existem vários procedimentos que produzem decomposições para ST univariadas em tendência estocástica e ciclo, cabendo citar entre eles:

- decomposição de Beveridge & Nelson (B&N) = apresenta correlação -1 entre tendência e ciclo.

- decomposição dos modelos estruturais= apresenta correlação 0 entre tendência e ciclo.

- A decomposição de B&N será apresentada nas próximas notas, mas não será cobrada como conteúdo deste curso.