

NOTAS DE AULA - II

⇒ Generalização da decomposição de B&N

- Seja y_t um processo ARIMA(p,1,q) com drift. Então segue que:

$$\Phi_p(L)\Delta y_t = a_0 + \Theta_q(L)\varepsilon_t$$

$$\Delta y_t = \Phi_p^{-1}(L)a_0 + \Phi_p^{-1}(L)\Theta_q(L)\varepsilon_t$$

- Sejam: $a_0^1 = \frac{a_0}{1 - \phi_1 - \dots - \phi_p}$; $\psi(L) \triangleq \frac{\Theta(L)}{\Phi(L)}$

- Segue, portanto que:

$$\Delta y_t = a_0^1 + \Psi(L)\varepsilon_t$$

$$\Delta y_t = a_0^1 + u_t, u_t = \Psi(L)\varepsilon_t$$

$$y_t = a_0^1 + y_{t-1} + u_t$$

$$y_t = y_0 + a_0^1 t + \sum_{i=1}^t u_i$$

- Projetermos esta eq. s-passos à frente:

$$y_{t+s} = y_0 + a_0^1(t+s) + \sum_{i=1}^{t+s} u_i$$

$$y_{t+s} = y_t + a_0^1 s + \sum_{i=t+1}^{t+s} u_i$$

- Concentremo-nos agora no último termo desta expressão. Lembremos que:

$$u_t = \Psi(L)\varepsilon_t = (1 + \Psi_1 L + \Psi_2 L^2 + \Psi_1 L^2 + \dots)\varepsilon_t$$

$$u_t = \varepsilon_t + \Psi_1 \varepsilon_{t-1} + \Psi_2 \varepsilon_{t-2} + \dots$$

$$u_{t+i} = \varepsilon_{t+i} + \Psi_1 \varepsilon_{t+i-1} + \Psi_2 \varepsilon_{t+i-2} + \dots$$

• Segue portanto que:

$$\sum_{i=1}^s u_{t+i} = \sum_{i=1}^s \varepsilon_{t+i} + \Psi_1 \sum_{i=1}^s \varepsilon_{t+i-1} + \Psi_2 \sum_{i=1}^s \varepsilon_{t+i-2} + \dots$$

$$\begin{aligned} &= (\varepsilon_{t+1} + \varepsilon_{t+2} + \varepsilon_{t+3} + \dots + \varepsilon_{t+s}) + \Psi_1 (\varepsilon_t + \varepsilon_{t+1} + \varepsilon_{t+2} + \varepsilon_{t+3} + \dots + \varepsilon_{t+s-1}) \\ &+ \Psi_2 (\varepsilon_{t-1} + \varepsilon_t + \varepsilon_{t+1} + \varepsilon_{t+2} + \varepsilon_{t+3} + \dots + \varepsilon_{t+s-2}) + \dots + \Psi_s (\varepsilon_{t+1-s} + \varepsilon_{t+2-s} + \dots + \varepsilon_t) + \\ &+ \Psi_{s+1} (\varepsilon_{t-s} + \varepsilon_{t+1-s} + \dots + \varepsilon_{t-1}) + \dots \\ &= \sum_{i=1}^s \varepsilon_{t+i} + \varepsilon_t \sum_{i=1}^s \Psi_i + \varepsilon_{t-1} \sum_{i=2}^{s+1} \Psi_i + \varepsilon_{t-2} \sum_{i=3}^{s+2} \Psi_i + \dots \end{aligned}$$

• A projeção de y , s -passos à frente, será dada por:

$$y_{t+s} = y_0 + a_0^1(t+s) + \sum_{i=1}^s u_{t+i}$$

$$y_{t+s} = y_t + a_0^1 s + \left(\sum_{i=1}^s \varepsilon_{t+i} + \varepsilon_t \sum_{i=1}^s \Psi_i + \varepsilon_{t-1} \sum_{i=2}^{s+1} \Psi_i + \varepsilon_{t-2} \sum_{i=3}^{s+2} \Psi_i + \dots \right)$$

• Finalmente, avaliando $E(y_{t+s}|Y_t)$, chega-se à:

$$\hat{y}_{t+s/t} = y_t + a_0' s + (\varepsilon_t \sum_{i=1}^s \Psi_i + \varepsilon_{t-1} \sum_{i=2}^{s+1} \Psi_i + \varepsilon_{t-2} \sum_{i=3}^{s+2} \Psi_i + \dots)$$

- Finalmente utilizando a definição de tendência estocástica na decomposição de B&N (B&N-I):

$$\mu_t = \lim_{s \rightarrow \infty} (\hat{y}_{t+s/t} - a_0^1 s) = y_t + \varepsilon_t \sum_{i=1}^{\infty} \psi_i + \varepsilon_{t-1} \sum_{i=2}^{\infty} \psi_i + \varepsilon_{t-2} \sum_{i=3}^{\infty} \psi_i + \dots$$

- Operacionalmente, a decomposição de B&N pode ser efetuada a partir de outro caminho (B&N-II):

$$y_{t+s} = \Delta y_{t+s} + \Delta y_{t+s-1} + \dots + \Delta y_{t+1} + y_t$$

$$\lim_{s \rightarrow \infty} \hat{y}_{t+s/t} = \lim_{s \rightarrow \infty} (\Delta \hat{y}_{t+s/t} + \Delta \hat{y}_{t+s-1/t} + \dots + \Delta \hat{y}_{t+1/t}) + y_t$$

Por tan to:

$$\mu_t = \lim_{s \rightarrow \infty} (\hat{y}_{t+s/t} - a_0^1 s) = \lim_{s \rightarrow \infty} [(\Delta \hat{y}_{t+s/t} + \Delta \hat{y}_{t+s-1/t} + \dots + \Delta \hat{y}_{t+1/t}) + y_t - a_0^1 s].$$

- A componente irregular/ciclo será calculada usando que $e_t \triangleq y_t - \mu_t$.
- Na prática B&N-I será mais adequado para estimar processos ARIMA(0,1,q), enquanto que B&N-II para estimar processos ARIMA(p,1,q).

- EXEMPLO: $y \sim \text{ARIMA}(0,1,1)$

⇒ Por B&N-I

$$y_t = y_{t-1} + a_0 + \varepsilon_t + \theta \varepsilon_{t-1}$$

$$\Psi_1 = \theta, \Psi_i = 0, i \geq 2.$$

$$\mu_t = \lim_{s \rightarrow \infty} (\hat{y}_{t+s/t} - a_0^1 s) = y_t + \varepsilon_t \sum_{i=1}^{\infty} \Psi_i + \varepsilon_{t-1} \sum_{i=2}^{\infty} \Psi_i + \varepsilon_{t-2} \sum_{i=3}^{\infty} \Psi_i + \dots$$

$$\mu_t = y_t + \varepsilon_t \theta$$

⇒ Por B&N-II

$$\hat{y}_{t+s/t} = (\Delta \hat{y}_{t+s/t} + \Delta \hat{y}_{t+s-1/t} + \dots + \Delta \hat{y}_{t+1/t}) + y_t$$

$$s=1 \quad \Delta \hat{y}_{t+1/t} = E_t(\Delta y_{t+1}) = \hat{y}_{t+1/t} - y_t = (a_0 + y_t + \theta \varepsilon_t) - y_t = a_0 + \theta \varepsilon_t$$

$$s=2 \quad \Delta \hat{y}_{t+2/t} = E_t(\Delta y_{t+2}) = \hat{y}_{t+2/t} - \hat{y}_{t+1/t} \\ = (2a_0 + y_t + \theta \varepsilon_t) - (a_0 + y_t + \theta \varepsilon_t) = a_0$$

...

$$s=s \quad \Delta \hat{y}_{t+s/t} = E_t(\Delta y_{t+s}) = \hat{y}_{t+s/t} - \hat{y}_{t+s-1/t} = a_0$$

$$\text{por tanto} \quad \sum_{i=1}^s \Delta \hat{y}_{t+i/t} = sa_0 + \varepsilon_t \theta.$$

$$\begin{aligned} \mu_t &= \lim_{s \rightarrow \infty} (\hat{y}_{t+s/t} - a_0^1 s) = \lim_{s \rightarrow \infty} [(\Delta \hat{y}_{t+s/t} + \Delta \hat{y}_{t+s-1/t} + \dots + \Delta \hat{y}_{t+1/t}) + y_t - a_0^1 s] \\ &= \lim_{s \rightarrow \infty} [\sum_{i=1}^s \Delta \hat{y}_{t+i/t} + (y_t - a_0^1 s)] = \lim_{s \rightarrow \infty} [sa_0 + \varepsilon_t \theta + (y_t - a_0^1 s)] = \\ &= y_t + \varepsilon_t \theta. \end{aligned}$$

- Decomposição de B&N na prática:

i. identifica e estima um modelo ARMA(p,q) para Δy , obtendo valores para

$$a_0^1 \text{ e } \psi(L) \hat{=} \frac{\Theta(L)}{\Phi(L)}$$

ii. usando o modelo estimado, avaliar para cada t e s:

$$\hat{y}_{t+s/t}, \quad t = 1, 2, \dots, T; \quad s = 1, 2, \dots, \infty$$

iii. para cada valor de t construir as somas, usando s=100.

$$\sum_{i=1}^s \Delta \hat{y}_{t+i/t} + y_t$$

Ex: $y = \log(r_t / r_{t-1})$, onde r_t é taxa de câmbio yen/dólar.

modelo estimado: $y_t \sim \text{ARIMA}(0,1,1)$

$$\Delta y_t = -0.0116 + \varepsilon_t + 0.3683 \varepsilon_{t-1}$$

Por uma questão de generalidade iremos utilizar B&N-II.

$$\mu_t = \lim_{s \rightarrow \infty} [\sum_{i=1}^s \Delta \hat{y}_{t+i/t} + (y_t - a_0^1 s)]$$

$$\Delta \hat{y}_{t+1/t} = -0.0116 + 0.3696 \varepsilon_t$$

$$\Delta \hat{y}_{t+2/t} = -0.0116$$

...

$$\Delta \hat{y}_{t+100/t} = -0.0116$$

$$\sum_{i=1}^{100} \Delta \hat{y}_{t+i/t} = 100(-0.0116) + 0.3696 \varepsilon_t = -1.16 + 0.3696 \varepsilon_t$$

$$\begin{aligned} \text{Por tanto } \mu_t &= \lim_{s \rightarrow \infty} [\sum_{i=1}^s \Delta \hat{y}_{t+i/t} + (y_t - a_0^1 s)] \\ &= -1.16 + 0.3696 \varepsilon_t + y_t - 0.0116 \cdot 100 \\ &= 0.3696 \varepsilon_t + y_t \end{aligned}$$

⇒ **Observações gerais sobre a decomposição de B&N:**


- i. sempre existirá para um processo $I(1)$.
- ii. as inovações que impactam a tendência e o ciclo são perfeitamente correlacionadas, o que para alguns faz sentido econômico.

Ex: os choques do petróleo nos EUA - afetaram, simultaneamente, o potencial de crescimento de longo prazo do PIB (tendência) e os movimentos de curto prazo do PIB (ciclo).

- iii. é um filtro assimétrico, pois somente utiliza a observação corrente e o passado para estimar a tendência corrente.

Esta característica contrasta o filtro B&N, um filtro de previsão, com a tendência de um ME, que é um alisamento exponencial.

- EX: série anual do PIB brasileiro, entre 1900 e 1992. Os valores do PIB entre 1900 e 1946 foram estimados por Haddad (1974) e a partir de 1947, os dados foram obtidos do IBGE.



- A seguir apresentaremos a estimativa da componente cíclica e de tendência usando TS e a decomposição de B&N.

⇒ Tendência determinística

$$y_t = -100.69 + 0.0542 t$$

(1.256) (0.000645)

Fig 3. Tendência Determinística





Fig 2. Ciclo Determinístico



- O gráfico sugere a existência de um ciclo com período maior do que o ciclo de Kondratieff que tem uma duração de 40 a 60 anos.

⇒ Tendência estocástica: decomposição de B&N

- O seguinte modelo ARMA foi encontrado para a primeira diferença do log da série do PIB

$$(1-0.0653 L)\Delta\log Y_t = \varepsilon_t$$

- Entretanto o coeficiente autorregressivo não é significativo, indicando que a série segue um passeio aleatório.

Fig 5. Tendência de Beveridge - Nelson





Fig 4. Ciclo de Beveridge-Nelson



- O gráfico indica claramente que a componente cíclica é desprezível, contrariando a evidência do modelo determinístico !
- Portanto, a partir do procedimento de B&N podemos concluir que não existe componente cíclica no PIB brasileiro, e que portanto, os choques monetários e fiscais, direcionados a esta componente são ineficazes, devendo o governo se preocupar com as medidas de impacto de longo termo, tais como: investimentos em educação, tecnologia e produtividade.

⇒ Outras decomposições de tendência/ciclo

iv. modelo de nível local c/ drift (Harvey)

–eq. das observ.: $y_t = \mu_t + \varepsilon_t \quad \varepsilon_t \sim N(0, \sigma_\varepsilon^2) \quad (I)$

–eq. do estado: $\mu_t = a_0 + \mu_{t-1} + \eta_t \quad \eta_t \sim N(0, \sigma_\eta^2) \quad (II)$

onde $E(\varepsilon_t \eta_s) = 0, \quad \forall t, s.$

- Observe que, contrário, a decomposição de B&N, as componentes nível e irregular são descorrelatadas.
- Resolvendo cada uma das eqs.acima segue que:

$$\mu_t = \mu_0 + a_0 t + \sum_{i=1}^t \eta_i, \text{ por tan to}$$

$$y_t = \mu_0 + a_0 t + \sum_{i=1}^t \eta_i + \varepsilon_t.$$

- Vamos agora provar que μ é realmente a tendência estocástica deste modelo, embora isso seja óbvio, por construção.

$$y_{t+s} = \mu_0 + a_0(t+s) + \sum_{i=1}^{t+s} \eta_i + \varepsilon_{t+s}$$

$$y_{t+s} = (y_t - \varepsilon_t) + a_0 s + \sum_{i=1}^s \eta_{t+i} + \varepsilon_{t+s}$$

$$y_{t+s} = \mu_t + a_0 s + \sum_{i=1}^s \eta_{t+i} + \varepsilon_{t+s}$$

donde segue que:

$$\hat{y}_{t+s/t} = \hat{\mu}_t + a_0 s.$$

- Portanto

$$\lim_{s \rightarrow \infty} (\hat{y}_{t+s/t} - a_0 s) = \mu_t.$$

- A questão agora é saber como estimar μ_t .
- Apresentaremos, inicialmente, um procedimento heurístico para estimar μ_t .
- A verdadeira solução para este problema de estimação, como veremos, será dado pelo filtro de Kalman, a partir do qual poder-se-á obter a estimativa suavizada da tendência.

⇒ Estimação de μ_t

- Diferenciando a eq (I), obtemos a seguinte equação, a qual denominamos de parametrização original:

$$\Delta y_t^{(0)} = \Delta \mu_t + \Delta \varepsilon_t = a_0 + \eta_t + \Delta \varepsilon_t$$

donde segue que:

$$E(\Delta y_t^{(0)}) = a_0$$

$$\text{Var}(\Delta y_t^{(0)}) = \sigma_n^2 + 2\sigma_\varepsilon^2 \quad (a)$$

$$\begin{aligned} \text{Cov}(\Delta y_t^{(0)}, \Delta y_{t+1}^{(0)}) &= -\sigma_\varepsilon^2 \quad i = 1 \\ &= 0 \quad i \geq 2 \end{aligned} \quad (b)$$

- Das propriedades (a) e (b) segue que $\Delta y \sim \text{MA}(1)$, ou seja, $y \sim \text{ARIMA}(0,1,1)$.

- Portanto podemos reescrever Δy como um processo MA(1) com drift:

$$\Delta y_t = a_0 + e_t + \theta e_{t-1}, \quad e_t \sim N(0, \sigma_e^2)$$

donde segue que:

$$\text{Var}(\Delta y_t) = (1 + \theta^2) \sigma_e^2 \quad (\text{a1})$$

$$\text{Cov}(\Delta y_t, \Delta y_{t-1}) = \theta \sigma_e^2 \quad (\text{b1})$$

- Na prática, assumimos que Δy pode ser aproximado por um MA(1) com drift. A partir destes parâmetros iremos obter os parâmetros do modelo de nível local.
- Isto é conseguido igualando-se as eqs (a e a1) e (b e b1):

$$a = a1: \quad (1 + \theta^2) \sigma_e^2 = \sigma_n^2 + 2\sigma_\varepsilon^2$$

$$b = b1: \quad \theta \sigma_e^2 = -\sigma_\varepsilon^2$$

$$\text{por tanto } \hat{\sigma}_\varepsilon^2 = -\hat{\theta} \hat{\sigma}_e^2 \Rightarrow \theta \in (-1, 0)$$

$$\hat{\sigma}_n^2 = \hat{\sigma}_e^2 (1 + \hat{\theta})^2$$

- O problema é como obter ε e η . Utilizaremos a previsão 1 passo à frente:

- Utilizando o modelo original:

$$\Delta y_{(t)}^{(0)} = a_0 + \eta_t + \Delta \varepsilon_t$$

$$y_t^{(0)} = y_{t-1}^{(0)} + a_0 + \eta_t + \Delta \varepsilon_t$$

$$y_{t+1}^{(0)} = y_t^{(0)} + a_0 + \eta_{t+1} + (\varepsilon_{t+1} - \varepsilon_t)$$

$$\hat{y}_{t+1/t}^{(0)} = y_t^{(0)} + a_0 - \varepsilon_t \quad (\text{i - a})$$

- Utilizando o modelo MA(1):

$$\Delta y_t^{(e)} = a_0 + e_t + \theta e_{t-1}$$

$$\hat{y}_{t+1/t}^{(e)} = y_t + a_0 + \theta e_t \quad (\text{ii - a})$$

- Finalmente igualando (i-a) com (ii-a), obtemos ε_t

$$\hat{\varepsilon}_t = -\hat{\theta} \hat{e}_t \quad \text{onde} \quad \hat{e}_t = y_t - \hat{y}_{t|t-1}.$$

- Para obter η_t utilizaremos a previsão de Δy_t

$$\Delta y_t^{(0)} = a_0 + \eta_t - \Delta \varepsilon_t$$

$$\eta_t = \Delta y_t^{(0)} - a_0 - \Delta \varepsilon_t$$

$$\eta_t = (y_t - y_{t-1}) - a_0 - (\varepsilon_t - \varepsilon_{t-1}), \text{ onde } \varepsilon_t = -\theta e_t \text{ e } e_t = y_t - \hat{y}_{t|t-1}.$$

$$\hat{\eta}_t = (y_t - y_{t-1}) - \hat{a}_0 + \hat{\theta}(\hat{e}_t - \hat{e}_{t-1}), \quad t = 2, \dots, T$$

- Finalmente, para obter μ_t utilizamos a eq. do estado do modelo de nível local:

$$\mu_t = a_0 + \mu_{t-1} + \eta_t$$

$$\hat{\mu}_t = \hat{a}_0 + \hat{\mu}_{t-1} + \hat{\eta}_t$$

onde $\hat{\eta}_t$ é dado pela expressão anterior.

- Finalmente, cabe observar que se considerássemos uma estrutura de correlação contemporânea entre os distúrbios:

$$\begin{aligned} E(\varepsilon_t \eta_s) &= q, \quad t = s \\ &= 0, \quad \forall t \neq s \end{aligned}$$

o modelo não seria identificável, i.e, a partir dos parâmetros da representação MA não poderíamos chegar, de forma inequívoca, aos parâmetros do modelo estrutural !

v. O Filtro de Hodrick-Prescott (HP):

- O filtro de HP (1980) foi originalmente desenvolvido com o objetivo de separar a componente de tendência da componente cíclica de séries macroeconômicas americanas, com ênfase no PIB.
- A decomposição do filtro de HP é a seguinte:

$$y_t = \mu_t + c_t$$

onde μ_t é a tendência, e c_t o ciclo.

- O filtro de HP propõe um procedimento para se obter μ_t , a partir do qual podemos obter c_t , simplesmente utilizando que $c_t = y_t - \mu_t$ (de forma análoga a decomposição de B&N).
- Este filtro é construído nos pressupostos de que:
 - a componente de tendência varia suavemente no tempo;
 - para longos períodos a componente cíclica tem média próxima de zero;
- A tendência é estimada por uma técnica de alisamento empregada na Atuária:

$$H = \min_{\{\mu_t\}_{t=1}^T} \left\{ \sum_{t=1}^T (y_t - \mu_t)^2 + \lambda \sum_{t=1}^T [(\mu_t - \mu_{t-1}) - (\mu_{t-1} - \mu_{t-2})]^2 \right\}$$

- O primeiro somatório representa a fidelidade entre os valores observados e a tendência e o segundo somatório a suavidade da tendência.
- Variando o parâmetro λ alteramos o *trade-off* entre o grau de ajuste da tendência aos dados e a sua suavidade.
- Observe que se a série estiver em log, então o termo do segundo somatório pode ser interpretado como a variação na taxa de crescimento da ST.
- Se $\lambda \rightarrow \infty$, então a solução do filtro de HP converge para uma tendência determinística (processo TS), pois nesta situação a suavização será máxima.

Prova: se $\lambda \rightarrow \infty$, no ótimo, as primeiras diferenças de μ devem estar arbitrariamente perto de um valor fixo β . Isto é:

$$\mu_t - \mu_{t-1} = \beta \quad \therefore \mu_t = \mu_0 + \beta t$$

- Quanto a escolha ótima do λ , baseado na visão a priori de que a componente cíclica responda por 5% da variação da ST e que a variação da taxa de crescimento seja de 1/8 em um trimestre, os autores chegam a um valor de $\lambda=1600$.
- Para resolver o problema de minimização do filtro de HP devemos encontrar os μ 's que satisfazem as condições necessárias para minimização , isto é,

$$\frac{\partial H}{\partial \mu_t} = 0, \quad t = 1, 2, \dots, T$$

- Após alguma álgebra é possível mostrar que a estimativa da tendência e ciclo serão dadas por:

$$\mu_t = \frac{\lambda^{-1}}{\lambda^{-1} + (1-L)^2(1-L^{-1})^2} y_t, \quad t = 1, 2, \dots, T$$

$$c_t = \frac{(1-L)^2(1-L^{-1})^2}{\lambda^{-1} + (1-L)^2(1-L^{-1})^2} y_t$$

- A componente cíclica, ou simplesmente o filtro HP, pode ser visto como um filtro que elimina frequências baixas (passa alto).
- A potência da função de transferência do filtro HP é dada por:

$$H_{HP}(\omega) = \left| \frac{4\lambda[1 - \cos(\omega)]^2}{4\lambda[1 - \cos(\omega)]^2 + 1} \right|^2$$

- Mais especificamente, pode-se demonstrar que o filtro HP com $\lambda=1600$, quando aplicado a dados trimestrais, elimina as frequências superiores a 32 trimestres, ou seja, à 8 anos, o período padrão de um ciclo de atividade econômica (*business cycle*).
- O filtro HP tem sido alvo de críticas por muitos pesquisadores (Harvey & Jaeger(1993), Cogley & Nason(1995), entre outros), os quais alegam a produção de ciclos espúrios em ST macroeconômicas não-estacionárias ou quase não-estacionárias (efeito Slutsky).

⇒ Ex: filtro de HP aplicado ao log do PIB brasileiro

- O filtro de HP foi ajustado utilizando-se a sua equivalência com um determinado modelo estrutural (a ser demonstrado).

**Fig 10. Tendência de Hodrick e Prescott
Log-PIB 1900-1992**





Fig 9. Ciclo de Hodrick-Prescott



- A componente cíclica estimada pelo filtro HP varia de -0,1575 a 0,1592 que é aproximadamente:
 - 337,6 vezes maior do que a estimativa obtida pela decomposição de B&N;
 - 2 vezes maior do que a estimativa obtida pelo modelo estrutural com tendência e ciclo;
 - metade da amplitude do ciclo determinístico.
- A tendência estimada pelo filtro de HP é bem mais suave do que a tendência estimada pelo modelo estrutural com tendência e ciclo (ainda não mostrado).
- É possível demonstrar que o filtro HP pode ser obtido como um caso especial de um modelo estrutural com tendência linear estocástica (MLL).
- No programa STAMP o filtro HP pode ser estimado diretamente a partir, através das seguintes opções:

Data \Rightarrow Transformations \Rightarrow HP detrending