

NOTAS DE AULA - VI

⇒ Modelos em Espaço de Estados

- O tratamento estatístico dos ME está baseado na forma de espaço de estados (EE).
- Uma vez que um modelo estatístico é colocado na forma de EE, então o FK fornece as estimativas do estado e dos hiperparâmetros do modelo.
- A forma em espaço de estados (EE) é uma maneira específica de escrever modelos lineares a tempo discreto, sendo definida através de duas equações estocásticas de diferenças. Considere a sua forma univariada:

–eq das observações ou das medidas :

$$y_t = Z_t' \alpha_t + d_t + \varepsilon_t, \quad t = 1, 2, \dots, T$$

–eq. do estado, do sistema ou de transição :

$$\alpha_{t+1} = T_t \alpha_t + c_t + R_t \eta_t$$

onde :

– α_t ($m \times 1$), é o vetor de estado, não observável

– $\varepsilon_t \sim NID(0, H_t)$

– η_t ($g \times 1$) $\sim NID(0, Q_t)$

– $\alpha_0 \sim N(a_0, P_0)$

– $E[\varepsilon_t \eta_t'] = 0, \quad \forall s, t$

– $E(\varepsilon_t \alpha_0') = E(\eta_t \alpha_0') = 0, \quad \forall t$

– as matrizes do sistema : Z_t ($m \times 1$); d_t (1×1); T_t ($m \times m$); c_t ($m \times 1$), R_t ($m \times g$), h_t (1×1) e Q_t ($g \times g$) são não estocásticas, podendo conter elementos desconhecidos.

- Muitos modelos estatísticos podem ser colocados na forma de EE: regressão linear, ARMA, ME, etc.
- É importante observar que a forma de EE não é única para um dado modelo estatístico.
- Entretanto se o estado entre duas formas de EE diferentes seguem uma transformação linear e inversível, i.e.,

$$\alpha_t^* = B\alpha_t, \quad B(m \times m), \text{ tal que } \det(B) \neq 0$$

então, pode-se demonstrar que a verossimilhança e a função de previsão permanecerão invariantes.

- Exemplos:

$$1. \quad y_t \sim \text{AR}(2): \quad y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$$

$$\text{i) } y_t = (1 \quad 0) \begin{pmatrix} y_t \\ \phi_2 y_{t-1} \end{pmatrix}$$

$$\begin{pmatrix} y_t \\ \phi_2 y_{t-1} \end{pmatrix} = \begin{pmatrix} \phi_1 & 1 \\ \phi_2 & 0 \end{pmatrix} \begin{pmatrix} y_{t-1} \\ \phi_2 y_{t-2} \end{pmatrix} + \begin{pmatrix} 1 \\ 0 \end{pmatrix} \varepsilon_t.$$

$$\text{ii) } y_t = (1 \quad 0) \begin{pmatrix} y_t \\ y_{t-1} \end{pmatrix}$$

$$\begin{pmatrix} y_t \\ y_{t-1} \end{pmatrix} = \begin{pmatrix} \phi_1 & \phi_2 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} y_{t-1} \\ y_{t-2} \end{pmatrix} + \begin{pmatrix} 1 \\ 0 \end{pmatrix} \varepsilon_t$$

- Observe que nestas duas formas de EE, a relação entre os vetores de estado é dada por:

$$\alpha_t^* = \begin{pmatrix} y_t \\ y_{t-1} \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1/\phi_2 \end{pmatrix} \begin{pmatrix} y_t \\ \phi_2 y_{t-1} \end{pmatrix}, \text{ e que} \\ \det B = 1/\phi_2 \neq 0.$$

2. $y_t \sim \text{AR}(p)$

$$y_t = (1 \quad 0 \quad 0 \quad \dots \quad 0) \begin{pmatrix} y_t \\ y_{t-1} \\ \vdots \\ y_{t-p+1} \end{pmatrix} \\ \begin{pmatrix} y_t \\ y_{t-1} \\ y_{t-2} \\ \vdots \\ y_{t-p+1} \end{pmatrix} = \begin{pmatrix} \phi_1 & \phi_2 & \dots & \phi_{p-1} & \phi_p \\ 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \end{pmatrix} \begin{pmatrix} y_{t-1} \\ y_{t-2} \\ y_{t-3} \\ \vdots \\ y_{t-p} \end{pmatrix} + \begin{pmatrix} 1 \\ 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix} \varepsilon_t$$

3. $y_t \sim \text{MA}(1)$: $y_t = \varepsilon_t + \theta \varepsilon_{t-1}$

$$\text{i. } y_t = (1 \quad 0) \begin{pmatrix} y_t \\ \theta \varepsilon_t \end{pmatrix} \qquad \text{ii. } y_t = (1 \quad \theta) \begin{pmatrix} \varepsilon_t \\ \varepsilon_{t-1} \end{pmatrix} \\ \begin{pmatrix} y_t \\ \theta \varepsilon_t \end{pmatrix} = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} y_{t-1} \\ \theta \varepsilon_{t-1} \end{pmatrix} + \begin{pmatrix} 1 \\ \theta \end{pmatrix} \varepsilon_t \qquad \begin{pmatrix} \varepsilon_t \\ \varepsilon_{t-1} \end{pmatrix} = \begin{pmatrix} 0 & 0 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} \varepsilon_{t-1} \\ \varepsilon_{t-2} \end{pmatrix} + \begin{pmatrix} 1 \\ 0 \end{pmatrix} \varepsilon_t$$

- Finalmente, pode-se demonstrar que um modelo ARMA(p,q) pode ser colocado sob as seguintes forma de EE:

- forma 1: primeiro mostre que uma ARMA(p,q) pode ser escrito como ARMA(m,m-1), onde $m = \max(p, q+1)$, com $\theta_j = 0, j > q$ e $\phi_i = 0, i > p$.

$$y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q}$$

$$y_t = \begin{pmatrix} 1 & \theta_1 & \theta_2 & \dots & \theta_{m-1} \end{pmatrix} \begin{pmatrix} \alpha_{1,t} \\ \alpha_{2,t} \\ \alpha_{3,t} \\ \vdots \\ \alpha_{m,t} \end{pmatrix}$$

$$\begin{pmatrix} \alpha_{1,t} \\ \alpha_{2,t} \\ \alpha_{3,t} \\ \vdots \\ \alpha_{m,t} \end{pmatrix} = \begin{pmatrix} \phi_1 & \phi_2 & \dots & \phi_{m-1} & \phi_m \\ 1 & 0 & \dots & 0 & 0 \\ 0 & 1 & \dots & 0 & 0 \\ 0 & 0 & \dots & 1 & 0 \end{pmatrix} \begin{pmatrix} \alpha_{1,t-1} \\ \alpha_{2,t-1} \\ \alpha_{3,t-1} \\ \vdots \\ \alpha_{m,t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_t \\ 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

- Por exemplo, $y \sim \text{ARMA}(2,1)$

$$y_t = \phi_1 y_t + \phi_2 y_{t-2} + \varepsilon_t + \theta_1 \varepsilon_{t-1} \quad (\text{I})$$

$$m = \max(2,2) = 2$$

$$y_t = (1 \quad \theta_1) \begin{pmatrix} \alpha_{1,t} \\ \alpha_{2,t} \end{pmatrix}$$

$$\begin{pmatrix} \alpha_{1,t} \\ \alpha_{2,t} \end{pmatrix} = \begin{pmatrix} \phi_1 & \phi_2 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} \alpha_{1,t-1} \\ \alpha_{2,t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_t \\ 0 \end{pmatrix}$$

i. $y_t = \alpha_{1,t} + \theta_1 \alpha_{2,t} = (1 + \theta_1 L) \alpha_{1,t}$, usando ii.

ii. $\alpha_{2,t} = \alpha_{1,t-1}$

iii. $\alpha_{1,t} = \phi_1 \alpha_{1,t-1} + \phi_2 \alpha_{2,t-1} + \varepsilon_t \therefore (1 + \theta_1 L + \theta_2 L^2) \alpha_{1,t} = \varepsilon_t$,
usando i.

ou

$$\alpha_{1,t} = \varepsilon_t / (1 + \theta_1 L + \theta_2 L^2).$$

Subst. em i, chegamos a (I).

- forma 2: primeiro mostre que uma ARMA(p,q) pode ser escrito como ARMA(m,m), onde $m = \max(p, q+1)$, com $\theta_j = 0, j > q$ e $\phi_i = 0, i > p$.

$$y_t = \phi_1 y_t + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q}$$

$$y_t = (1 \quad 0 \quad 0 \quad 0 \quad \dots \quad 0) \begin{bmatrix} \alpha_{1,t} \\ \alpha_{2,t} \\ \vdots \\ \alpha_{m,t} \end{bmatrix}_{m \times 1}$$

$$\begin{bmatrix} \alpha_{1,t} \\ \alpha_{2,t} \\ \vdots \\ \alpha_{m,t} \end{bmatrix} = \begin{bmatrix} \phi_1 & 1 & 0 & 0 & \vdots & 0 \\ \phi_2 & 0 & 1 & 0 & \vdots & 0 \\ \dots & \dots & \dots & \dots & \vdots & 1 \\ \phi_m & 0 & 0 & 0 & \vdots & 0 \end{bmatrix} \begin{bmatrix} \alpha_{1,t-1} \\ \alpha_{2,t-1} \\ \vdots \\ \alpha_{m,t-1} \end{bmatrix} + \begin{bmatrix} 1 \\ \theta_1 \\ \theta_2 \\ \vdots \\ \theta_{m-1} \end{bmatrix}_{m \times 1} \varepsilon_t$$

Por exemplo, $y \sim \text{ARMA}(2,1)$:

$$y_t = \phi_1 y_t + \phi_2 y_{t-2} + \varepsilon_t + \theta_1 \varepsilon_{t-1} \quad (\text{I})$$

$$m = \min(2,2) = 2$$

$$y_t = (1 \ 0) \begin{pmatrix} \alpha_{1,t} \\ \alpha_{2,t} \end{pmatrix}$$

$$\begin{pmatrix} \alpha_{1,t} \\ \alpha_{2,t} \end{pmatrix} = \begin{pmatrix} \phi_1 & 1 \\ \phi_2 & 0 \end{pmatrix} \begin{pmatrix} \alpha_{1,t-1} \\ \alpha_{2,t-1} \end{pmatrix} + \begin{pmatrix} 1 \\ \theta_1 \end{pmatrix} \varepsilon_t$$

i. $y_t = \alpha_{1,t}$

ii. $\alpha_{1,t} = \phi_1 \alpha_{1,t-1} + \alpha_{2,t-1} + \varepsilon_t$. Usando i, segue que

$$y_t = \phi_1 y_{t-1} + \alpha_{2,t-1} + \varepsilon_t$$

iii. $\alpha_{2,t} = \phi_2 \alpha_{1,t-1} + \theta_1 \varepsilon_t = \phi_2 y_{t-1} + \theta_1 \varepsilon_t$, usando i.

Susbtituindo iii em ii, obtemos (I).

⇒ **Propriedades de Sistemas Lineares Dinâmicos**

- Nem todo modelo que é colocado na forma EE possui boas propriedades estatísticas.
 - Por exemplo, pode ser que um determinado elemento do vetor de estado não seja estimável (identificável) a partir dos dados.
 - As propriedades que apresentaremos a seguir são estabelecidas, verificando-se algumas características das matrizes do sistema.
 - Para definir estas propriedades é necessário assumir que o sistema é invariante no tempo, isto é, que todas as matrizes do sistema não dependam explicitamente do tempo.
1. Estacionariedade = a estacionariedade de y está intimamente relacionada à estacionariedade do processo do vetor de estado.
- Em seguida temos que estabelecer sob que condições a eq. do sistema, que se trata de um processo autoregressivo vetorial de ordem 1, é estacionária.

- Calculando a média e variância para o vetor de estado:

$$\alpha_t = T^t \alpha_0 + \sum_{j=0}^{t-1} T^j v_{t-j}, \quad v_t = R \eta_t$$

$$E(\alpha_t) = T^t a_0$$

$$\begin{aligned} \text{Var}(\alpha_t) &= E[(\alpha_t - E(\alpha_t))(\alpha_t - E(\alpha_t))'] \\ &= T^t P_0 T^t + \sum_{j=0}^{t-1} T^j W T^j, \quad W = RQR' \end{aligned}$$

- Fica óbvio que ambas são funções explícitas de t . Entretanto se $t \rightarrow \infty$, esta dependência pode desaparecer, dependendo dos elementos da matriz T (estacionariedade assintótica).
- Para investigar este comportamento iremos utilizar a decomposição de T :

$$T = F \Lambda F^{-1} \quad (i)$$

, onde:

- F é a matriz de autovetores (F_i);
- $\Lambda = \text{diag}(\lambda_i)$, $i = 1, \dots, m$, é a matriz de autovalores;

os quais satisfazem $TF_i = \lambda_i F_i$.

- Iremos agora utilizar o resultado em (i) para obter uma expressão para T^t em termos dos seus autovalores e autovetores:

$$T = F \Lambda F^{-1}$$

$$T^j = (F \Lambda F^{-1})^j = F \Lambda^j F^{-1}, \text{ onde } \Lambda^j = \text{diag}(\lambda_i^j), i = 1, \dots, m$$

- Para simplificar as demonstrações vamos admitir que $m=2$:

$$T^j = F \Lambda^j F^{-1}$$

$$\begin{aligned} &= \begin{pmatrix} f_{11} & f_{12} \\ f_{21} & f_{22} \end{pmatrix} \begin{pmatrix} \lambda_1^j & 0 \\ 0 & \lambda_2^j \end{pmatrix} \begin{pmatrix} f^{11} & f^{12} \\ f^{21} & f^{22} \end{pmatrix} \\ &= \begin{pmatrix} f_{11} f^{11} \lambda_1^j + f_{12} f^{21} \lambda_2^j & f_{11} f^{12} \lambda_1^j + f_{12} f^{22} \lambda_2^j \\ f_{21} f^{11} \lambda_1^j + f_{22} f^{21} \lambda_2^j & f_{21} f^{12} \lambda_1^j + f_{22} f^{22} \lambda_2^j \end{pmatrix} \end{aligned}$$

- Usando esta expressão podemos calcular, por exemplo:

$$E(\alpha_t) = T^t a_0 = \begin{pmatrix} f_{11} f^{11} \lambda_1^t + f_{12} f^{21} \lambda_2^t & f_{11} f^{12} \lambda_1^t + f_{12} f^{22} \lambda_2^t \\ f_{21} f^{11} \lambda_1^t + f_{22} f^{21} \lambda_2^t & f_{21} f^{12} \lambda_1^t + f_{22} f^{22} \lambda_2^t \end{pmatrix} \begin{pmatrix} a_{0,1} \\ a_{0,2} \end{pmatrix}.$$

- Isolando o primeiro elemento deste valor esperado:

$$E(\alpha_{1t}) = (f_{11} f^{11} \lambda_1^t + f_{12} f^{21} \lambda_2^t) a_{0,1} + (f_{11} f^{12} \lambda_1^t + f_{12} f^{22} \lambda_2^t) a_{0,2}$$

- Se $|\lambda_i(T)| < 1$, $i=1,2$, então qdo $t \rightarrow \infty$, a média incondicional torna-se zero, portanto, independente de t . O mesmo comportamento pode ser observado para a matriz variância covariância e FAC.
- Portanto a condição suficiente para estacionariedade do processo do vetor de estado é que os autovalores da matriz T sejam todos menores do que um, em módulo.
- Se isto ocorrer, necessariamente, o processo para y também será estacionário.
- O ME de TLL é não estacionário, enquanto o de ciclo é estacionário.

$$\begin{pmatrix} \vdots \\ Z'T^{m-1} \end{pmatrix}$$

2. Observabilidade=

- Esta propriedade investiga se todos os elementos do vetor de estado podem ser estimados em um tempo t arbitrário a partir do conhecimento de y_t :

$$E(\alpha_t) = TE(\alpha_{t-1}) \therefore E(\alpha_t) = T^t a_0$$

$$\text{Mas } E(y_t) = Z' E(\alpha_t) = Z' T^t a_0$$

$$\therefore E(y_0) = Z' a_0$$

$$E(y_1) = Z' T a_0$$

$$E(y_2) = Z' T^2 a_0$$

$$E(y_{m-1}) = Z' T^{m-1} a_0. \text{ Agrupando vetorialmente:}$$

$$E \begin{pmatrix} y_0 \\ y_1 \\ y_2 \\ \vdots \\ y_{m-1} \end{pmatrix} = \begin{pmatrix} Z' \\ Z'T \\ Z'T^2 \\ \vdots \\ Z'T^{m-1} \end{pmatrix} a_0 = M \begin{pmatrix} a_{0,1} \\ a_{0,2} \\ \vdots \\ a_{0,m} \end{pmatrix}$$

$$E(Y_m) = M a_0 \therefore a_0 = M^{-1} E(Y_m).$$

É necessário e suficiente, pois, que a matriz M , seja invertível \therefore
 $\text{posto}(M) = m$ ou $\det(M) \neq 0$.

- Exemplo1 : considere o modelo LLT.

$$Z' = (1,0), \quad T = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}$$

$$M = \begin{pmatrix} Z' \\ Z'T \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix}, \quad \det M = 1 \Rightarrow \text{sistema é observável.}$$

- Exemplo 2:

$$y_t = \mu_t + \beta_t + \varepsilon_t \quad y_t = \begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} \mu_t \\ \beta_t \end{bmatrix} + \varepsilon_t$$

$$\mu_t = \mu_{t-1} + \eta_t \quad \begin{bmatrix} \mu_t \\ \beta_t \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \mu_{t-1} \\ \beta_{t-1} \end{bmatrix} + \begin{bmatrix} \eta_t \\ \xi_t \end{bmatrix}$$

$$\beta_t = \beta_{t-1} + \xi_t$$

$$Z' = (1,1), \quad T = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

$$M = \begin{pmatrix} Z' \\ Z'T \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}, \quad \det M = 0 \Rightarrow \text{sistema é não observável.}$$

Ou seja um dos elementos do vetor de estado é não identificável a partir dos dados.

- Reparametrizando o sistema, a não identificabilidade ficará mais clara:

Sejam:

$$\theta_t \triangleq \mu_t + \beta_t \quad \delta_{1t} = \eta_t + \xi_t$$

$$\psi_t \triangleq \mu_t - \beta_t \quad \delta_{2t} = \eta_t - \xi_t, \text{ ou seja a reparametrização é do tipo:}$$

$$\alpha_t^* = B \alpha_t, \quad B(m \times m), \text{ onde } \det(B) \neq 0.$$

$$\begin{pmatrix} \theta_t \\ \psi_t \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix}$$

$$\therefore y_t = \theta_t + \varepsilon_t, \text{ mas}$$

$$\mu_t + \beta_t = (\mu_{t-1} + \beta_{t-1}) + (\eta_t + \xi_t), \text{ i.e.}$$

$$\theta_t = \theta_{t-1} + \delta_{1t},$$

Por tanto o sistema pode ser re – escrito como:

$$\therefore y_t = \theta_t + \varepsilon_t$$

$$\theta_t = \theta_{t-1} + \delta_{1t}$$

$$\psi_t = \psi_{t-1} + \delta_{2t}$$

Nesta parametrização fica claro que um dos elementos do vetor de estado é redundante.

⇒ O filtro de Kalman

- Dado o sistema linear dinâmico, ou a representação em EE, a questão é saber como estimar o vetor de estado dada a ST de observações:

$$y_t = Z'_t \alpha_t + d_t + \varepsilon_t$$

$$\alpha_t = T_t \alpha_{t-1} + c_t + R_t \eta_t$$

com as seguintes condições:

$$\alpha_0 \sim N(a_0, P_0);$$

$$\varepsilon_t \sim N(0, h_t) \quad \eta_t \sim N(0, Q_t)$$

$$E(\varepsilon_t \eta'_s) = 0, \forall t, s$$

$$E(\xi_t \alpha'_0) = E(\eta'_t \alpha_0) = 0$$

- A resposta é o FK, que se trata de um algoritmo que fornece, recursivamente, a média e variância do vetor de estado, condicional nas observações, para todo t.
- Como o sistema é Gaussiano, estas informações serão suficientes para caracterizar toda a distribuição condicional do estado, dado as observações.

- É importante distinguir sob que conjunto de informação de Y estamos condicionando a distribuição do vetor de estado:

$$\text{FK} \begin{cases} p(\alpha_t | Y_{t-1}) \rightarrow \text{previsão ou filtragem: distr. a priori.} \\ p(\alpha_t | Y_t) \rightarrow \text{atualização: distr. a posteriori} \\ p(\alpha_t | Y_T) \rightarrow \text{suavização (smoothing).} \end{cases}$$

- Seja a seguinte notação:

$$a_t = E(\alpha_t | Y_t)$$

$$P_t = E[(\alpha_t - a_t)(\alpha_t - a_t)' | Y_t] \rightarrow \text{matriz de variância ou MSE}$$

$$a_{t|t-1} = E(\alpha_t | Y_{t-1})$$

$$P_{t|t-1} = E[(\alpha_t - a_{t|t-1})(\alpha_t - a_{t|t-1})' | Y_{t-1}]$$

- O passo inicial do FK é calcular a média e variância no tempo t , condicional às observações até o instante $t-1$.

$$\alpha_t = T_t \alpha_{t-1} + C_t + R_t \eta_t$$

$$E(\alpha_t | Y_{t-1}) = T_t E(\alpha_{t-1} | Y_{t-1}) + c_t + R_t E(\eta_t | Y_{t-1})$$

$$a_{t|t-1} = T_t a_{t-1} + c_t$$

$$P_{t|t-1} = E[(\alpha_t - a_{t|t-1})(\alpha_t - a_{t|t-1})' | Y_{t-1}] = T_t P_{t-1} T_t' + R_t Q_t R_t'$$

- Ou seja: $(\alpha_t | Y_{t-1}) \sim N(a_{t|t-1}, P_{t|t-1})$.

- Este resultado pode ser obtido de forma genérica através da solução da seguinte integral:

$$\begin{aligned} p(\alpha_t | Y_{t-1}) &= \int p(\alpha_t, \alpha_{t-1} | Y_{t-1}) d\alpha_{t-1} \\ &= \int p(\alpha_t | \alpha_{t-1}) p(\alpha_{t-1} | Y_{t-1}) d\alpha_{t-1} \end{aligned}$$

- No caso do ambiente Gaussiano a solução desta integral coincide com o resultado anterior.
- Para outros tipos de distribuição dos choques, geralmente não existirá solução analítica para esta integral, exigindo a utilização de métodos numéricos ou aproximações analíticas.
- A partir dos anos 90 ficou bastante em voga a solução destas integrais por métodos de simulação Monte Carlo, como, por exemplo, MCMC, muito utilizado pelos Bayesianos.
- Seja a definição de inovação em modelos de EE:

$$\begin{aligned} v_t &= y_t - \hat{y}_{t|t-1} = y_t - E(y_t | Y_{t-1}) \\ &= y_t - E(Z_t \alpha_t + d_t + \varepsilon_t | Y_{t-1}) \\ &= y_t - (Z_t' a_{t|t-1} + d_t) \\ &= (Z_t' \alpha_t + d_t + \varepsilon_t) - (Z_t' a_{t|t-1} + d_t) \\ v_t &= Z_t' (\alpha_t - a_{t|t-1}) + \varepsilon_t \end{aligned}$$

- Pode-se provar que:

$$E(v_t) = 0$$

$$E(v_t v_t') = f_t = Z_t' P_{t|t-1} Z_t + h_t$$

$$E(v_t v_s') = 0, \quad t \neq s$$

$$v_t \sim \text{Normal} \quad \therefore \quad v_t \sim \text{NID}(0, F_t).$$

- Ao tornar-se disponível no tempo t , a observação y_t é incorporada na estimação do vetor de estado, resultando nas equações de atualização:

$$a_t = a_{t|t-1} + P_{t|t-1} Z_t f_t^{-1} v_t$$

$$P_t = P_{t|t-1} - P_{t|t-1} Z_t f_t^{-1} Z_t' P_{t|t-1},$$

$$f_t = Z_t' P_{t|t-1} Z_t + h_t$$

$$\text{ou seja } (\alpha_t | Y_t) \sim N(a_t, P_t).$$

- Prova por indução:

$$t = 1$$

eq. estado: $\alpha_1 = T_1 \alpha_0 + c_1 + R_1 \eta_1$, donde segue que:

$$a_{1|0} = T_1 a_0 + c_1$$

$$P_{1|0} = T_1 P_0 T_1' + R_1 Q_1 R_1'.$$

Por tanto: $\alpha_1 = a_{1|0} + (\alpha_1 - a_{1|0}) \sim \text{Normal mult.}$

- Trabalhando agora com a eq. das observações:

$$eq. \text{ obs} : y_1 = Z_1' \alpha_1 + d_1 + \varepsilon_1 = Z_1' a_{1|0} + d_1 + Z_1(\alpha_1 - a_{1|0}) + \varepsilon_1$$

$$\hat{y}_{1|0} = Z_1' a_{1|0} + d_1$$

$$\begin{aligned} MSE(y_1 - \hat{y}_{1|0} | I_o) &= E[(y_1 - Z_1' a_{1|0} - d_1)(y_1 - Z_1' a_{1|0} - d_1)'] \\ &= E[(Z_1'(\alpha_1 - a_{1|0}) + \varepsilon_1)(Z_1'(\alpha_1 - a_{1|0}) + \varepsilon_1)'] \\ &= Z_1' P_{1|0} Z_1 + h_1 \\ &= f_1 \end{aligned}$$

$$\begin{aligned} Cov[(\alpha_1, y_1) | I_o] &= E[(\alpha_1 - a_{1|0})(y_1 - Z_1' a_{1|0} - d_1)'] = \\ &= E[(\alpha_1 - a_{1|0})(Z_1'(\alpha_1 - a_{1|0}) + \varepsilon_1)'] \\ &= E[(\alpha_1 - a_{1|0})(\alpha_1 - a_{1|0})' Z_1] + E[(\alpha_1 - a_{1|0}) \varepsilon_1'] \\ &= P_{1|0} Z_1 \end{aligned}$$

$$Por \text{ tanto} : \begin{pmatrix} \alpha_1 \\ y_1 \end{pmatrix} | I_o \sim N \left[\begin{pmatrix} a_{1|0} \\ Z_1' a_{1|0} + d_1 \end{pmatrix}, \begin{pmatrix} P_0 & P_{1|0} Z_1 \\ Z_1' P_{1|0} & Z_1' P_{1|0} Z_1 + h_1 \end{pmatrix} \right]$$

- Em seguida utilizamos um resultado da distribuição normal multivariada:

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim N \left(\begin{pmatrix} \mu_X \\ \mu_Y \end{pmatrix}, \begin{pmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{pmatrix} \right), \text{ então, } P(X | Y) \sim N(\mu_{X|Y}, \Sigma_{X|Y})$$

$$\mu_{X|Y} = \mu_X + \Sigma_{XY} \Sigma_{YY}^{-1} (y - \mu_Y)$$

$$\Sigma_{X|Y} = \Sigma_{XX} - \Sigma_{XY} \Sigma_{YY}^{-1} \Sigma_{YX}$$

- Estabelecendo as seguintes correspondências:

$$X = \alpha_1$$

$$Y = y_1$$

$$\Sigma_{XX} = P_{1|0} \quad \mu_X = a_{1|0}$$

$$\Sigma_{YY} = Z_1' P_{1|0} Z_1 + h_1 = F_1$$

$$\mu_Y = Z_1' a_{1|0} + d_1$$

$$\Sigma_{XY} = P_{1|0} Z_1$$

- Segue que:

$$(\alpha_1 | Y_1) \sim N(a_1, P_1), \text{ onde}$$

$$a_1 = a_{1|0} + P_{1|0} Z_1 f_1^{-1}(y_1 - (Z_1' a_{1|0} + d_1))$$

$$P_1 = P_{1|0} - P_{1|0} Z_1 f_1^{-1} Z_1' P_{1|0}$$

- Repetindo os passos acima p/ $t = 2, 3, \dots$, verificamos as fórmulas de atualização do FK.

- Da mesma forma que no passo preditivo, o passo de atualização corresponde ao cálculo de uma integral, uma vez que corresponde ao teorema de Bayes:

posterior \propto veross prior

$$p(\alpha_t | Y_t) \propto p(y_t | \alpha_t) p(\alpha_t | Y_{t-1})$$

$$p(\alpha_t | Y_t) = k p(y_t | \alpha_t) p(\alpha_t | Y_{t-1}), \text{ onde } k \text{ é tal que}$$

$$\int p(\alpha_t | Y_t) d\alpha_t = k \int p(y_t | \alpha_t) p(\alpha_t | Y_{t-1}) d\alpha_t = 1, \text{ ou}$$

$$k^{-1} = \int p(y_t | \alpha_t) p(\alpha_t | Y_{t-1}) d\alpha_t = p(y_t | Y_{t-1})$$

$p(y_t | Y_{t-1})$ é a densidade preditiva.

- No caso do ambiente Gaussiano esta densidade de atualização tem a mesma forma da densidade de previsão do estado, sendo ambas Gaussianas.
- Daí a necessidade de atualizar apenas a média e variância condicionais.

- Uma outra forma de apresentar as eqs do FK é fazer $t=t+1$ nas eqs. de previsão, e então substituir as eqs. de atualização, eliminando-as do FK:

$$\begin{aligned} a_{t+1|t} &= (T_{t+1} - K_t Z_t) a_{t|t-1} + K_t y_t + (d_{t+1} - K_t c_t) \\ &= T_{t+1} a_{t|t-1} + K_t v_t + d_{t+1} \end{aligned}$$

$$\begin{aligned} P_{t+1|t} &= T_{t+1} (P_{t|t-1} - P_{t|t-1} Z_t' f_t^{-1} Z_t P_{t|t-1}) T_{t+1}' + R_{t+1} Q_{t+1} R_{t+1}' \\ &= T_{t+1} P_{t+1} T_{t+1}' - K_t f_t K_t' + R_t Q_t R_t' \quad (\text{eq. de Riccati}) \end{aligned}$$

onde $K_t = T_{t+1} P_{t|t-1} Z_t' f_t^{-1}$ é o ganho de Kalman.

- Propriedades ótimas do FK:
 - i. No ambiente Gaussiano, o FK fornece o melhor estimador do vetor de estado, minimizando o MSE.
 - ii. Fora do ambiente Gaussiano, o FK fornece o melhor estimador linear do vetor de estado, minimizando o MSE.
 - iii. A estimativa da matriz P_t , $P_{t+1|t}$, não depende das observações, portanto será também a variância incondicional do estado, podendo assim ser estimada *off-line*.

⇒ Solução *steady state* da eq. de Riccati:

- Para um sistema invariante no tempo, é possível obter uma solução para a equação de Riccati.

$$P_{t+1|t} = T(P_{t|t-1} - P_{t|t-1}Z F^{-1}Z'P_{t|t-1})T' + RQR'$$

$$P_{t+1|t} = T(P_{t|t-1} - P_{t|t-1}Z (ZPZ' + h)^{-1}Z'P_{t|t-1})T' + RQR'$$

Fazendo $P_{t+1|t} = P_{t|t-1} = \bar{P}$, obtemos a eq. de Riccati algébrica (ERA):

$$\bar{P} - T\bar{P}T' + T\bar{P}Z(Z\bar{P}Z' + h)^{-1}Z'\bar{P}T - RQR' = 0$$

- A questão agora é saber sob que condições a ERA apresenta uma solução.
- Geralmente é difícil obter uma solução explícita da ERA, e neste caso, saber se esta solução é única e positiva definida.
- Se existir uma solução da ERA, então isto pode ser utilizado para aumentar a eficiência computacional do FK:

$$\Rightarrow a_{t+1|t} = \bar{T}a_{t|t-1} + \bar{K}v_t,$$

$$\bar{T} = T - \bar{K}Z \text{ e } \bar{K} = T\bar{P}Z F^{-1} = T\bar{P}Z(Z'\bar{P}Z + h)^{-1}$$

$$\Rightarrow P_{t+1|t} = \bar{P}$$

- Sob determinadas condições, entretanto, é possível estabelecer condições p/ solução da ERA:
 - i. Se o sistema é estacionário, $|\lambda_i(T)| < 1, \forall i, i = 1, \dots, m$, e $P_{1|0}$ é psd, então: $\lim_{t \rightarrow \infty} P_{t+1|t} = \bar{P}$. Se \bar{P} é única, a converg. é exponencial: $\|P_{t+1|t} - P_{t|t-1}\| \leq \beta \alpha^t$; $\beta \geq 1$ e $\alpha \in [0,1]$.
 - ii. Se o sistema é observável e $P_{1|0} - \bar{P}$ é pd, ou $P_{1|0} = \bar{P}$, então $\lim_{t \rightarrow \infty} P_{t+1|t} = \bar{P}$.
- Observe que para os ME, a segunda condição é que nos interessa, pois o sistema não é estacionário.

⇒ Condições iniciais do FK:

- Dependendo de forma do FK utilizado (1+1) ou (2 em 1) a condição inicial dirá respeito a:

$$\alpha_0 \sim N(a_0, P_0) \text{ ou}$$
$$\alpha_{1|0} \sim N(a_{1|0}, P_{1|0}).$$

- É também importante discriminar as componentes estacionárias das não estacionárias.

1. Condição inicial para componentes/modelos estacionários

Inicialmente, considere o seguinte modelo:

$$y_t = \mu_t + \varepsilon_t \quad \varepsilon_t \sim N(0, \sigma^2).$$
$$\mu_t = \phi \mu_{t-1} + \eta_t, \quad \eta_t \sim N(0, \sigma_\eta^2). \quad |\phi| < 1.$$

A distr. incondicional de μ_t será normal, com :

$$E(\mu_t) = 0$$

$$\text{Var}(\mu_t) = \phi^2 \text{Var}(\mu_t) + \sigma_\eta^2$$

$$\text{Var}(\mu_t) = \sigma_\eta^2 / (1 - \phi^2).$$

Por tanto é natural que inicializemos o FK com

$$a_0 = 0, \quad p_0 = \frac{\sigma_\eta^2}{1 - \phi^2}.$$

- Numa situação mais geral, teremos:

$$\alpha_t = T\alpha_{t-1} + c + R\eta_t, \text{ assumindo que } |\lambda_i(T)| < 1, \forall i, i = 1, \dots, m.$$

Calculando a média e variância incondicional:

$$E(\alpha_t) = TE(\alpha_{t-1}) + c$$

$$E(\alpha_t)(I - T) = c \quad \therefore E(\alpha_t) = (I - T)^{-1}c.$$

$$\text{Var}(\alpha_t) = T \text{Var}(\alpha_{t-1})T' + RQR'$$

$$\begin{aligned} \text{Vec}(\text{Var}(\alpha_t)) &= \text{Vec}(T \text{Var}(\alpha_{t-1})T' + \text{Vec}(RQR')) \\ &= (T \otimes T) \text{Vec}[\text{Var} \alpha_t] + R \otimes R \text{Vec} Q. \end{aligned}$$

(usando que:

$$A = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \\ a_{31} & a_{32} \end{pmatrix} \rightarrow \text{Vec}(A) = \begin{pmatrix} a_{11} \\ a_{21} \\ a_{31} \\ a_{12} \\ a_{22} \\ a_{32} \end{pmatrix}$$

$$\text{Vec}(ABC) = (C \otimes A') \text{Vec} B)$$

$$A \otimes B = \begin{pmatrix} a_{11}B & a_{12}B & a_{1m}B \\ \vdots & \vdots & \vdots \\ a_{n1}B & a_{n2}B & a_{nm}B \end{pmatrix}_{mp \times nq}$$

- Portanto, segue que:

$$\alpha_0 \sim N(a_0, P_0) \text{ ou}$$

$$a_0 = (I - T)^{-1} c \quad e$$

$$\text{Vect } P_0 = (I - T \otimes T)^{-1} (R \otimes R') \text{ Vec } Q.$$

2. Condição inicial para compon./modelos não estacionários

- Esta é a situação mais relevante p/ ME, onde a maioria das componentes são não estacionárias.
- Existem vários algoritmos disponíveis na literatura, mas iremos apenas considerar a solução da priori não informativa ou difusa: representa a situação de total ignorância sobre a distribuição dos valores possíveis de α ; todos os valores são “equiprováveis”.

$$\alpha_0 \sim N(a_0, P_0), \text{ com}$$

$$a_0 = 0 \text{ e}$$

$$P_0 = kI, \text{ sendo } k \text{ "muito grande"}.$$

- Por conveniência computacional, geralmente o FK é parametrizado em termos da variância da eq. das observações, σ_ε^2 ou simplesmente σ^2 . A explicação virá qdo abordarmos a estimação dos hiperparâmetros via MV.

- Exemplo: considere o ME de nível local

$$y_t = \mu_t + \varepsilon_t \quad \varepsilon_t \sim N(0, \sigma^2)$$

$$\mu_t = \mu_{t-1} + \eta_t \quad \eta_t \sim N(0, \sigma_\eta^2)$$

$$\begin{aligned} a_{t+1|t} &= a_{t|t-1} + k_t v_t \\ &= a_{t|t-1} + k_t (y_t - a_{t|t-1}) \\ &= (1 - k_t) a_{t|t-1} + k_t y_t, \quad (\text{EWMA !}) \end{aligned}$$

$$\text{onde } k_t = p_{t|t-1} / f_t = p_{t|t-1} / (p_{t|t-1} + h_t)$$

$$p_{t+1|t} = p_{t|t-1} - p_{t|t-1}^2 / f_t + \sigma_\eta^2$$

Usando que $h_t = \sigma^2$, $\sigma_\eta^2 = q\sigma^2$, $p_{t|t-1} = \sigma^2 p_{t|t-1}$ segue que:

$$k_t = p_{t|t-1} / (p_{t|t-1} + 1)$$

$$p_{t+1|t} = p_{t|t-1} - [p_{t|t-1}^2 / (1 + p_{t|t-1})] + q$$

prior difusa: $\alpha_{1|0} \sim N(a_{1|0} = 0, p_{1|0} = k, k \rightarrow \infty)$

$\rightarrow t = 1$, fazendo $k \rightarrow \infty$.

$$\begin{aligned} a_{2|1} &= (1 - k_1) a_{1|0} + k_1 y_1 = [1 - p_{1|0} / (p_{1|0} + 1)] a_{1|0} + [p_{1|0} / (p_{1|0} + 1)] y_1 \\ &= [1 - k / (k + 1)] 0 + [k / (k + 1)] y_1 = y_1, \end{aligned}$$

$$p_{2|1} = p_{1|0} - [p_{1|0}^2 / (1 + p_{1|0})] + q = k - [k^2 / (1 + k)] + q = 1 + q.$$

- Portanto, inicializando o FK com uma prior difusa, para o modelo de nível local, faz com que no segundo passo preditivo a distribuição já seja própria.
- Pode-se demonstrar, que em geral, se o vetor de estado possui “d” componentes não estacionárias, então em $t=d+1$, a distribuição a priori será própria.
- Portanto no MEB, apenas a partir de $t=14$ as inovações e distribuições serão bem definidas.

⇒ Máxima Verossimilhança e decomposição pelo erro de previsão

- Tipicamente alguns ou todos os elementos das matrizes do sistema são desconhecidos. Estes são aglutinados num vetor ψ , denominado do vetor de hiperparâmetros.
- Ex: considere o modelo de TTL com ciclo estocástico

$$Z = [1 \ 0 \ 1 \ 0]$$

$$T = \begin{pmatrix} 1 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & \rho \cos \lambda_c & \rho \sin \lambda_c \\ 0 & 0 & -\rho \sin \lambda_c & \rho \cos \lambda_c \end{pmatrix}$$

$$R = I_{(4 \times 4)}$$

$$h = \sigma_\varepsilon^2$$

$$\sigma_k^2 = (1 - \rho^2) \sigma_\psi^2$$

$$Q = \begin{pmatrix} \sigma_\eta^2 & 0 & & \\ & \sigma_\zeta^2 & & \\ 0 & & \sigma_k^2 & \\ & & & \sigma_k^2 \end{pmatrix}$$

$$\Psi = (\rho, \lambda_c, \sigma_\varepsilon^2, \sigma_\eta^2, \sigma_\psi^2)$$

- Métodos de estimação dos hiperparâmetros:

- máxima veross (MV)
- algoritmo EM

- Cálculo da MV:

função de densidade conjunta:

$$f(y_t, y_{t-1}, \dots, y_2, y_1 | \psi) = f(y_t | y_{t-1} y_2, \dots, y_1) f(y_{t-1}, y_{t-2}, \dots, y_1),$$

usando que $P(A, B) = P(A|B)P(B)$.

Aplicando sucessivamente, temos que:

$$f(y_t, y_{t-1}, \dots, y_2, y_1 | \psi) = \prod_{t=1}^T f(y_t | Y_{t-1}; \psi),$$

onde $f(y_t | Y_{t-1}; \psi)$ é a densidade preditiva,
calculada pela solução da integral:

$$\begin{aligned} f(y_t | Y_{t-1}; \psi) &= \int f(y_t, \alpha_t | Y_{t-1}; \psi) d\alpha_t \\ &= \int f(y_t | \alpha_t, Y_{t-1}; \psi) f(\alpha_t | Y_{t-1}; \psi) d\alpha_t \\ &= \int f(y_t | \alpha_t) f(\alpha_t | Y_{t-1}) d\alpha_t \end{aligned}$$

onde abandonamos a dependência em Ψ , por simplicidade de notação.

- A função verossimilhança é obtida diretamente a partir da função densidade conjunta, invertendo o seu argumento:

– função verossimilhança:

$$L(\psi|Y_t) = f(y_t, y_{t-1}, \dots, y_2, y_1 | \psi) = \prod_{t=1}^T f(y_t | Y_{t-1}; \psi),$$

Para o ambiente Gaussiano a densidade preditiva é facilmente calculável, sendo dada por:

$$f(y_t | Y_{t-1}; \psi) \sim N(\hat{y}_{t|t-1}, f_t), \text{ onde}$$

$$\hat{y}_{t|t-1} = Z_t' a_{t|t-1} + d_t$$

$$f_t = Z_t' P_{t|t-1} Z_t + \sigma^2 \text{ e o MEE é dado por:}$$

$$\begin{cases} y_t = Z_t \alpha_{t-1} + d_t + \varepsilon_t \\ \alpha_t = T_t \alpha_{t-1} + c_t + R_r \eta_t. \end{cases}$$

Por tanto:

$$\begin{aligned} L(\psi|Y_t) &= \prod_{t=1}^T (2\pi)^{-1/2} f_t^{-1/2} \exp\left\{-\frac{1}{2} v_t f_t^{-1} v_t'\right\} \\ &= (2\pi)^{-T/2} \prod_{t=1}^T f_t^{-1/2} \exp\left\{-\frac{1}{2} v_t f_t^{-1} v_t'\right\}, \text{ tirando o log} \end{aligned}$$

$$\log L(\psi|Y_t) = -\frac{T}{2} \log 2\pi - \frac{1}{2} \sum_{t=1}^T \log f_t - \frac{1}{2} \sum_{t=1}^T v_t f_t^{-1} v_t',$$

observando que $f_t = f_t(\psi)$ e $v_t = v_t(\psi)$.

- O problema de otimização (com restrições e não -linear) a ser resolvido consiste na solução de:

$$\text{máx } \log L(\Psi)$$

- Através de um artifício de transformação, STAMP transforma o problema em otimização sem restrição, adotando as seguintes transformações:
 - variâncias: $\sigma^2 = \exp(2\theta)$, $0 < \sigma^2 < \infty$
 - ctes. de amortecimento: $\rho = \begin{cases} |\theta|(1 + \theta^2)^{-1/2} & \text{p / incl. e ciclo, } 0 < \rho < 1 \\ \theta(1 + \theta^2)^{-1/2} & \text{p / AR(1), } |\rho| < 1 \end{cases}$
 - frequência: $\lambda = 2\pi / (2 + \exp(\theta))$, $0 < \lambda < \pi$

⇒ Concentração da Verossimilhança

- A dimensão da busca na otimização pode ser diminuída em uma dimensão se reparametrizarmos o vetor de hiperparâmetros Ψ .
- Em particular utilizaremos que $\Psi = (\Psi^*, \sigma^2)$, considerando o modelo univariado.
- Como resultado as equações do FK não envolverão σ^2 , e assim a verossimilhança também não envolverá σ^2 .

- Formalmente efetuando a nova parametrização nas expressões das variâncias do modelo:

$$\begin{aligned} -Q &\rightarrow Q\sigma^2 & -p_0 &\rightarrow p_0\sigma^2 \\ -f_t &\rightarrow f_t\sigma^2 & -p_{t|t-1} &\rightarrow p_{t|t-1}\sigma^2 \end{aligned}$$

Por tanto as eqs do FK, serão:

$$\begin{aligned} f_t &= Z_t' P_{t|t-1} Z_t + \sigma^2 \\ \sigma_\varepsilon^2 f_t &= Z_t' \sigma_\varepsilon^2 P_{t|t-1} Z_t + \sigma^2 \\ f_t &= Z_t' P_{t|t-1} Z_t + 1 \rightarrow \text{não envolve } \sigma^2, \text{ apenas } \Psi^*. \end{aligned}$$

$v_t = y_t - (Z_t' a_{t|t-1} + d_t)$, mas

$a_{t+1|t} = T_{t+1} a_{t|t-1} + K_t v_t + d_{t+1}$, e por sua vez usando a nova parametrização, chegamos à seguinte expressão p / K_t :

$$K_t = T_{t+1} P_{t|t-1} Z_t' f_t^{-1} = T_{t+1} P_{t|t-1} \sigma^2 Z_t' f_t^{-1} \sigma^{-2} = T_{t+1} P_{t|t-1} Z_t' f_t^{-1}.$$

Ou seja, v_t não envolverá σ^2 .

- Em seguida obtemos a verossimilhança na nova parametrização:

$$\log L(\psi^*, \sigma^2) = -\frac{T}{2} \log 2\pi - \frac{1}{2} \sum \log f_t - \frac{1}{2} \sum v_t^2 / f_t$$

$$f_t \rightarrow f_t \sigma^2$$

$$\log L(\psi^*, \sigma^2) = -\frac{T}{2} \log 2\pi - \frac{T}{2} \log \sigma_\varepsilon^2 - \frac{1}{2} \sum_{t=d+1}^T \log f_t - \frac{1}{2\sigma_\varepsilon^2} \sum_{t=d+1}^T v_t^2 / f_t$$

$$\text{Calculando } \frac{\partial L}{\partial \sigma^2} = -\frac{T}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum v_t^2 / f_t = 0$$

$$\text{Chegamos à } \sigma^2(\psi^*) = \frac{1}{T-d} \sum_{t=d+1}^T v_t^2 / f_t.$$

- Finalmente, substituindo esta expressão na eq. da veross., chegamos à veross. concentrada:

$$\log L_c(\psi^*) = -\frac{(T-d)}{2} \log(2\pi + 1) - \frac{(T-d)}{2} \log \hat{\sigma}_\varepsilon^2(\psi^*) - \frac{1}{2} \sum_{t=d+1}^T \log f_t$$