

# **NOTAS DE AULA - VII**

- Da mesma forma que no passo preditivo, o passo de atualização corresponde ao cálculo de uma integral, uma vez que corresponde ao teorema de Bayes:

posterior  $\propto$  veross prior

$$p(\alpha_t | Y_t) \propto p(y_t | \alpha_t) p(\alpha_t | Y_{t-1})$$

$$p(\alpha_t | Y_t) = k p(y_t | \alpha_t) p(\alpha_t | Y_{t-1}), \text{ onde } k \text{ é tal que}$$

$$\int p(\alpha_t | Y_t) d\alpha_t = k \int p(y_t | \alpha_t) p(\alpha_t | Y_{t-1}) d\alpha_t = 1, \text{ ou}$$

$$k^{-1} = \int p(y_t | \alpha_t) p(\alpha_t | Y_{t-1}) d\alpha_t = p(y_t | Y_{t-1})$$

$p(y_t | Y_{t-1})$  é a densidade preditiva.

- No caso do ambiente Gaussiano esta densidade de atualização tem a mesma forma da densidade de previsão do estado, sendo ambas Gaussianas.
- Daí a necessidade de atualizar apenas a média e variância condicionais.

- Uma outra forma de apresentar as eqs do FK é fazer  $t=t+1$  nas eqs. de previsão, e então substituir as eqs. de atualização, eliminando-as do FK:

$$\begin{aligned} a_{t+1|t} &= (T_{t+1} - K_t Z_t) a_{t|t-1} + K_t y_t + (c_{t+1} - K_t d_t) \\ &= T_{t+1} a_{t|t-1} + K_t v_t + c_{t+1} \end{aligned}$$

$$\begin{aligned} P_{t+1|t} &= T_{t+1} (P_{t|t-1} - P_{t|t-1} Z_t f_t^{-1} Z_t' P_{t|t-1}) T_{t+1}' + R_{t+1} Q_{t+1} R_{t+1}' \\ &= T_{t+1} P_{t+1} T_{t+1}' - K_t f_t K_t' + R_{t+1} Q_{t+1} R_{t+1}' \quad (\text{eq. de Riccati}) \end{aligned}$$

onde  $K_t = T_{t+1} P_{t|t-1} Z_t f_t^{-1}$  é o ganho de Kalman.

- **Propriedades ótimas do FK:**

- i. No ambiente Gaussiano e linear, o FK fornece a média condicional do vetor de estado, que é o estimador ótimo do estado no sentido de minimizar o MSE.
- ii. Fora do ambiente Gaussiano e linear, o FK fornece o melhor estimador linear do vetor de estado, minimizando o MSE.
- iii. A estimativa da matriz  $P_t$ ,  $P_{t+1|t}$ , não depende das observações, portanto será também a variância incondicional do estado, podendo assim ser estimada *off-line*.

## ⇒ Solução *steady state* da eq. de Riccati:

- Para um sistema invariante no tempo, é possível obter uma solução para a equação de Riccati.

$$P_{t+1|t} = T(P_{t|t-1} - P_{t|t-1}ZF_t^{-1}Z'P_{t|t-1})T' + RQR'$$

$$P_{t+1|t} = T(P_{t|t-1} - P_{t|t-1}Z(ZP_{t|t-1}Z' + h)^{-1}Z'P_{t|t-1})T' + RQR'$$

Fazendo  $P_{t+1|t} = P_{t|t-1} = \bar{P}$ , obtemos a eq. de Riccati algébrica (ERA):

$$\bar{P} - T\bar{P}T' + T\bar{P}Z(Z'\bar{P}Z + h)^{-1}Z'\bar{P}T' - RQR' = 0$$

- A questão agora é saber sob que condições a ERA apresenta uma solução.
- Geralmente é difícil obter uma solução explícita da ERA, e neste caso, saber se esta solução é única e positiva definida.
- Se existir uma solução da ERA, então isto pode ser utilizado para aumentar a eficiência computacional do FK:

$$\Rightarrow a_{t+1|t} = \bar{T}a_{t|t-1} + \bar{K}v_t,$$

$$\bar{T} = T - \bar{K}Z \text{ e } \bar{K} = TPZF^{-1} = TPZ(Z'PZ + h)^{-1}$$

$$\Rightarrow P_{t+1|t} = \bar{P}$$

- Sob determinadas condições, pode-se mostrar que é possível estabelecer condições p/ solução da ERA:
  - i. Se o sistema é estacionário,  $|\lambda_i(T)| < 1$ ,  $i = 1, \dots, m$ ,  
 e  $P_{1|0}$  é psd, então:  $\lim_{t \rightarrow \infty} P_{t+1|t} = \bar{P}$ . Se  $\bar{P}$  é única, a converg. é exponencial:  $\|P_{t+1|t} - P_{t|t-1}\| < \beta \alpha'$ ;  $|\beta| < 1$  e  $\alpha \in [0, 1]$ .
  - ii. Se o sistema é observável e  $P_{1|0} - \bar{P}$  é pd, ou  $P_{1|0} = \bar{P}$ , então  

$$\lim_{t \rightarrow \infty} P_{t+1|t} = \bar{P}.$$
- Observe que para os ME, a segunda condição é que nos interessa, pois o sistema não é estacionário.

## ⇒ Condições iniciais do FK:

- Dependendo de forma do FK utilizado (1+1) ou (2 em 1) a condição inicial dirá respeito a:

$$\alpha_0 \sim N(a_0, P_0) \text{ ou}$$
$$\alpha_{1|0} \sim N(a_{1|0}, P_{1|0}).$$

- É também importante discriminar as componentes estacionárias das não estacionárias.

## 1. Condição inicial para componentes estacionárias

Inicialmente, considere o seguinte modelo:

$$y_t = \mu_t + \varepsilon_t \quad \varepsilon_t \sim N(0, \sigma^2).$$
$$\mu_t = \phi \mu_{t-1} + \eta_t, \quad \eta_t \sim N(0, \sigma_\eta^2). \quad |\phi| < 1.$$

A distr. incondicional de  $\mu_t$  será normal, com :

$$E(\mu_t) = 0$$

$$\text{Var}(\mu_t) = \phi^2 \text{Var}(\mu_t) + \sigma_\eta^2$$

$$\text{Var}(\mu_t) = \sigma_\eta^2 / (1 - \phi^2).$$

Por tanto é natural que inicializemos o FK com

$$a_0 = 0, \quad p_0 = \frac{\sigma_\eta^2}{1 - \phi^2}.$$

- Numa situação mais geral, teremos:

$$\alpha_t = T\alpha_{t-1} + c + R\eta_t, \text{ assumindo que } |\lambda_i(T)| < 1, \forall i, i=1, \dots, m.$$

Calculando a média e variância incondicional:

$$E(\alpha_t) = T E(\alpha_{t-1}) + c$$

$$E(\alpha_t)(I - T) = c \quad \therefore E(\alpha_t) = (I - T)^{-1} c.$$

$$Var(\alpha_t) = T Var(\alpha_{t-1})T' + RQR'$$

$$\begin{aligned} Vec(Var(\alpha_t)) &= Vec(T Var(\alpha_{t-1})T' + RQR'^*) \\ &= (T \otimes T)Vec[Var \alpha_t] + R \otimes R Vec Q. \end{aligned}$$

(usando que :

$$A = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \\ a_{31} & a_{32} \end{pmatrix} \rightarrow Vec(A) = \begin{pmatrix} a_{11} \\ a_{21} \\ a_{31} \\ a_{12} \\ a_{22} \\ a_{32} \end{pmatrix}$$

$$Vec(ABC) = (C \otimes A') Vec B$$

$$A \otimes B = \begin{pmatrix} a_{11}B & a_{12}B & a_{1m}B \\ \vdots & \vdots & \vdots \\ a_{n1}B & a_{n2}B & a_{nm}B \end{pmatrix}_{m \times n \times q}$$



- Portanto, segue que:

$$\alpha_0 \sim N(a_0, P_0) \text{ ou}$$

$$a_0 = (I - T)^{-1} c \quad e$$

$$\text{Vect } P_0 = (I - T \otimes T)^{-1} (R \otimes R') \text{ Vec } Q.$$

## 2. Condição inicial para componentes não estacionárias

- Esta é a situação mais relevante p/ ME, onde a maioria das componentes são não estacionárias.
- Existem vários algoritmos disponíveis na literatura, mas iremos apenas considerar a solução da priori não informativa ou difusa: representa a situação de total ignorância sobre a distribuição dos valores possíveis de  $\alpha$ ; todos os valores são “equiprováveis”.

$$\alpha_0 \sim N(a_0, P_0), \text{ com}$$

$$a_0 = 0 \text{ e}$$

$$P_0 = kI, \text{ sendo } k \text{ "muito grande"}.$$

- Por conveniência computacional, geralmente o FK é parametrizado em termos da variância da eq. das observações,  $\sigma_\varepsilon^2$  ou simplesmente  $\sigma^2$ . A explicação virá qdo abordarmos a estimação dos hiperparâmetros via MV.

- Portanto, inicializando o FK com uma prior difusa, para o modelo de nível local, faz com que no segundo passo preditivo a distribuição já seja própria.
- Pode-se demonstrar, que em geral, se o vetor de estado possui “d” componentes não estacionárias, então em  $t=d+1$ , a distribuição a priori será própria.
- Portanto no MEB, apenas a partir de  $t=14$  as inovações e distribuições serão bem definidas.

## ⇒ Máxima Verossimilhança e decomposição pelo erro de previsão

- Tipicamente alguns ou todos os elementos das matrizes do sistema são desconhecidos. Estes são aglutinados num vetor  $\psi$ , denominado do vetor de hiperparâmetros.
- Ex: considere o modelo de TTL com ciclo estocástico

$$Z = [1 \ 0 \ 1 \ 0]$$

$$T = \begin{pmatrix} 1 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & \rho \cos \lambda_c & \rho \sin \lambda_c \\ 0 & 0 & -\rho \sin \lambda_c & \rho \cos \lambda_c \end{pmatrix}$$

$$R = I_{(4 \times 4)}$$

$$h = \sigma_\varepsilon^2$$

$$\sigma_k^2 = (1 - \rho^2) \sigma_\psi^2$$

$$Q = \begin{pmatrix} \sigma_\eta^2 & 0 & & \\ & \sigma_\zeta^2 & & \\ 0 & & \sigma_k^2 & \\ & & & \sigma_k^2 \end{pmatrix}$$

$$\Psi = (\rho, \lambda_c, \sigma_\varepsilon^2, \sigma_\eta^2, \sigma_\psi^2)$$

- Métodos de estimação dos hiperparâmetros:

- máxima veross (MV)
- algoritmo EM

- Cálculo da MV:

função de densidade conjunta:

$$f(y_t, y_{t-1}, \dots, y_2, y_1 | \psi) = f(y_t | y_{t-1} y_2, \dots, y_1) f(y_{t-1}, y_{t-2}, \dots, y_1),$$

usando que  $P(A, B) = P(A|B)P(B)$ .

Aplicando sucessivamente, temos que:

$$f(y_t, y_{t-1}, \dots, y_2, y_1 | \psi) = \prod_{t=1}^T f(y_t | Y_{t-1}; \psi),$$

onde  $f(y_t | Y_{t-1}; \psi)$  é a densidade preditiva,

calculada pela solução da integral:

$$\begin{aligned} f(y_t | Y_{t-1}; \psi) &= \int f(y_t, \alpha_t | Y_{t-1}; \psi) d\alpha_t \\ &= \int f(y_t | \alpha_t, Y_{t-1}; \psi) f(\alpha_t | Y_{t-1}; \psi) d\alpha_t \\ &= \int f(y_t | \alpha_t) f(\alpha_t | Y_{t-1}) d\alpha_t \end{aligned}$$

onde abandonamos a dependência em  $\Psi$ , por simplicidade de notação.

- A função verossimilhança é obtida diretamente a partir da função densidade conjunta, invertendo o seu argumento:

-função verossimilhança (sem concentrar):

$$L(\psi) = f(y_t, y_{t-1}, \dots, y_2, y_1 | \psi) = \prod_{t=d+1}^T f(y_t | \mathbf{Y}_{t-1}; \psi),$$

onde  $d = n^\circ$  de componentes não estacionárias do vetor de estado.

>> Para o ambiente Gaussiano a densidade preditiva é dada por:

$f(y_t | \mathbf{Y}_{t-1}; \psi) \sim N(\hat{y}_{t|t-1}, F_t)$ , onde

$$\hat{y}_{t|t-1} = \mathbf{Z}_t' \mathbf{a}_{t|t-1} + d_t$$

$F_t = \mathbf{Z}_t' \mathbf{P}_{t|t-1} \mathbf{Z}_t + \sigma^2$  e o MEE é dado por:

(na notação do Koopman:  $\mathbf{a}_{t|t-1} = \mathbf{a}_t$ ,  $\mathbf{P}_{t|t-1} = \mathbf{P}_t$ )

$$\begin{cases} y_t = \mathbf{Z}_t' \boldsymbol{\alpha}_{t-1} + d_t + \varepsilon_t \\ \boldsymbol{\alpha}_t = \mathbf{T}_t \boldsymbol{\alpha}_{t-1} + \mathbf{c}_t + \mathbf{R}_t \eta_t. \end{cases}$$

Portanto:

$$\begin{aligned} L(\psi) &= \prod_{t=d+1}^T (2\pi)^{-1/2} F_t^{-1/2} \exp \left\{ -\frac{1}{2} \mathbf{v}_t' F_t^{-1} \mathbf{v}_t \right\} = \prod_{t=d+1}^T (2\pi)^{-1/2} F_t^{-1/2} \exp \left\{ -\frac{1}{2} v_t^2 / F_t \right\} \\ &= (2\pi)^{-(T-d)/2} \prod_{t=d+1}^T F_t^{-1/2} \exp \left\{ -\frac{1}{2} v_t^2 / F_t \right\}, \text{ tirando o log (base e):} \end{aligned}$$

$$l(\psi) = \log L(\psi) = -\frac{(T-d)}{2} \log(2\pi) - \frac{1}{2} \sum_{t=d+1}^T \log F_t - \frac{1}{2} \sum_{t=d+1}^T v_t^2 / F_t,$$

observando que  $F_t = F_t(\psi)$  e  $v_t = v_t(\psi)$ .

- O problema de otimização (com restrições e não-linear) a ser resolvido consiste em determinar:

$$\hat{\Psi} = \text{máx } \log L(\Psi)$$

- Através de um artifício, pode-se utilizar um algoritmo de para otimização sem restrição, para resolver a otimização com restrição adotando transformações. Por exemplo;
  - variâncias:  $\sigma^2 = \exp(2\theta)$ ,  $0 < \sigma^2 < \infty$
  - ctes. de amortecimento:  $\rho = \begin{cases} |\theta|(1 + \theta^2)^{-1/2} \text{ p/ciclo}, & 0 < \rho < 1 \\ \theta(1 + \theta^2)^{-1/2} \text{ p/ AR}(1), & |\rho| < 1 \end{cases}$
  - frequência:  $\lambda = 2\pi / (2 + \exp(\theta))$ ,  $0 < \lambda < \pi$

Em todos estes casos  $-\infty < \theta < \infty$ , i.e., a otimização é efetuada sem restrição

⇒ Concentração da Verossimilhança

- A dimensão da busca na otimização pode ser diminuída em uma dimensão se reparametrizarmos o vetor de hiperparâmetros  $\Psi$ .
- Em particular utilizaremos que  $\Psi = (\Psi^*, \sigma^2)$ , considerando o modelo univariado. Geralmente  $\sigma^2 = \text{Var}(\varepsilon_t)$ .
- Como resultado, as equações do FK não envolverão  $\sigma^2$ , e assim a verossimilhança também não envolverá  $\sigma^2$ .

- Formalmente efetuando a nova parametrização nas expressões das variâncias do modelo:  
Nova parametrização:

$$\begin{aligned} - Q_t^* &= Q \sigma_\varepsilon^2 & - P_0^* &= P_0 \sigma_\varepsilon^2 \\ - F_t^* &= F_t \sigma_\varepsilon^2 & - P_{t|t-1}^*(P_t^*) &= P_{t|t-1}(P_t) \sigma_\varepsilon^2 \end{aligned}$$

(entre parênteses a notação do Koopman)

Portanto as eqs do FK na nova parametrização, serão:

$$\begin{aligned} F_t^* &= Z_t' P_{t|t-1}^*(P_t^*) Z_t + \sigma_\varepsilon^2 \\ \sigma_\varepsilon^2 F_t &= Z_t' \sigma_\varepsilon^2 P_{t|t-1}(P_t) Z_t + \sigma_\varepsilon^2 \\ F_t &= Z_t' P_{t|t-1}(P_t) Z_t + 1, \text{ não envolve } \sigma_\varepsilon^2, \text{ apenas } \Psi^*. \end{aligned}$$

$$v_t = y_t - Z_t' a_{t|t-1}(a_t), \text{ mas}$$

$a_{t+1|t}(a_{t+1}) = T_{t+1} a_{t|t-1}(a_t) + K_t v_t$  e por sua vez usando a nova parametrização, chegamos à seguinte expressão p/  $K_t$ :

$$K_t = T_{t+1} P_{t|t-1}^*(P_t^*) Z_t F_t^{*-1} = T_{t+1} P_{t|t-1}(P_t) \sigma_\varepsilon^2 Z_t F_t^{-1} \sigma_\varepsilon^{-2} = T_{t+1} P_{t|t-1}(P_t) Z_t F_t^{-1}.$$

Ou seja, ambos  $v_t$  e  $F_t$ , na nova parametrização, não envolverão  $\sigma_\varepsilon^2$ .  
Consequência: ao maximizarmos a veross. na nova parametrização os estimadores de  $\Psi^*$  não envolverão  $\sigma_\varepsilon^2$ .

- Em seguida obtemos a verossimilhança na nova parametrização:

$$l(\psi^*, \sigma_\varepsilon^2) = \log L(\psi^*, \sigma_\varepsilon^2) = -\frac{(T-d)}{2} \log 2\pi - \frac{1}{2} \sum_{t=d+1}^T \log F_t^* - \frac{1}{2} \sum_{t=d+1}^T v_t^2 / F_t^*$$

$$F_t^* = F_t \sigma_\varepsilon^2$$

$$l(\psi^*, \sigma_\varepsilon^2) = -\frac{(T-d)}{2} \log 2\pi - \frac{(T-d)}{2} \log \sigma_\varepsilon^2 - \frac{1}{2} \sum_{t=d+1}^T \log F_t - \frac{1}{2\sigma_\varepsilon^2} \sum_{t=d+1}^T v_t^2 / F_t$$

Calculando  $\frac{\partial L}{\partial \sigma_\varepsilon^2} = -\frac{(T-d)}{2\sigma_\varepsilon^2} + \frac{1}{2(\sigma_\varepsilon^2)^2} \sum_{t=d+1}^T v_t^2 / F_t = 0$

chegamos ao estimador de MV de  $\sigma_\varepsilon^2$  sem necessidade de, diretamente, realizar uma busca não linear, pois:

$$\hat{\sigma}_\varepsilon^2(\hat{\psi}^*) = \frac{1}{T-d} \sum_{t=d+1}^T v_t^2(\hat{\psi}^*) / F_t(\hat{\psi}^*).$$

- Finalmente, substituindo esta expressão na eq. da veross., chegamos à veross. concentrada:

$$l_c(\psi^*) = -\frac{(T-d)}{2} (\log 2\pi + 1) - \frac{(T-d)}{2} \log \hat{\sigma}_\varepsilon^2(\psi^*) - \frac{1}{2} \sum_{t=d+1}^T \log F_t(\psi^*)$$