

NOTAS DE AULA - VIII

- Exemplo: considere o ME de nível local

$$y_t = \mu_t + \varepsilon_t \quad \varepsilon_t \sim N(0, \sigma^2)$$

$$\mu_t = \mu_{t-1} + \eta_t \quad \eta_t \sim N(0, \sigma_\eta^2)$$

$$\begin{aligned} a_{t+1|t} &= a_{t|t-1} + k_t v_t \\ &= a_{t|t-1} + k_t (y_t - a_{t|t-1}) \\ &= (1 - k_t) a_{t|t-1} + k_t y_t, \quad (\text{EWMA !}) \end{aligned}$$

$$\text{onde } k_t = p_{t|t-1} / f_t = p_{t|t-1} / (p_{t|t-1} + h_t)$$

$$p_{t+1|t} = p_{t|t-1} - p_{t|t-1}^2 / f_t + \sigma_\eta^2$$

Usando que $h_t = \sigma^2$, $\sigma_\eta^2 = q\sigma^2$, $p_{t|t-1} = \sigma^2 p_{t|t-1}$ segue que:

$$k_t = p_{t|t-1} / (p_{t|t-1} + 1)$$

$$p_{t+1|t} = p_{t|t-1} - [p_{t|t-1}^2 / (1 + p_{t|t-1})] + q$$

prior difusa: $\alpha_{1|0} \sim N(a_{1|0} = 0, p_{1|0} = k, k \rightarrow \infty)$

$\rightarrow t = 1$, fazendo $k \rightarrow \infty$.

$$\begin{aligned} a_{2|1} &= (1 - k_1) a_{1|0} + k_1 y_1 = [1 - p_{1|0} / (p_{1|0} + 1)] a_{1|0} + [p_{1|0} / (p_{1|0} + 1)] y_1 \\ &= [1 - k / (k + 1)] 0 + [k / (k + 1)] y_1 = y_1, \end{aligned}$$

$$p_{2|1} = p_{1|0} - [p_{1|0}^2 / (1 + p_{1|0})] + q = k - [k^2 / (1 + k)] + q = 1 + q.$$

Cálculo da verossimilhança :

$$\psi = (\sigma_{\eta}^2, \sigma_{\varepsilon}^2) = (q\sigma_{\varepsilon}^2, \sigma_{\varepsilon}^2)$$

$$\psi = (q, \sigma_{\varepsilon}^2), \text{ portanto } \psi^* = q.$$

$$\log L_c(q) = -\frac{(T-1)}{2} \log(2\pi + 1) - \frac{(T-1)}{2} \log \sigma_{\varepsilon}^2(q) - \frac{1}{2} \sum_{i=2}^T \log f_t(q)$$

onde :

$$f_t = p_{t|t-1}(q) + 1$$

$$p_{t+1|t} = \frac{p_{t|t-1}}{1 + p_{t|t-1}} + q.$$

- Um panorama s/ otimização não-linear

$f(\psi) \rightarrow$ função objetivo

$$f(\psi) = \log L(\psi)$$

$$g(\psi) = \frac{\partial f}{\partial \psi} = \left(\frac{\partial f}{\partial \psi_1}, \frac{\partial f}{\partial \psi_2}, \dots, \frac{\partial f}{\partial \psi_p} \right)' \rightarrow p \times 1 (\text{gradiente})$$

$$H(\Psi) = \frac{\partial^2 f}{\partial \psi \partial \psi'} = \begin{pmatrix} \frac{\partial^2 f}{\partial \psi_1^2} & \frac{\partial^2 f}{\partial \psi_1 \psi_2} & \dots & \frac{\partial^2 f}{\partial \psi_1 \psi_p} \\ \frac{\partial^2 f}{\partial \psi_1 \psi_2} & \frac{\partial^2 f}{\partial \psi_2^2} & \dots & \frac{\partial^2 f}{\partial \psi_2 \psi_p} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial \psi_1 \psi_p} & \dots & \dots & \frac{\partial^2 f}{\partial \psi_p^2} \end{pmatrix} \rightarrow \text{Hessiano}$$

- Os algoritmos de otimização não linear baseada no método de quasi-Newton são baseados na expansão quadrática da função custo.

$$f(\psi) = f(\tilde{\psi}) + (\psi - \tilde{\psi})' g(\tilde{\psi}) + \frac{1}{2} (\psi - \tilde{\psi})' H(\tilde{\psi}) (\psi - \tilde{\psi})$$

$$\frac{\partial f}{\partial \psi} = g(\psi) = g(\tilde{\psi}) + 1/2 (H + H') (\psi - \tilde{\psi})$$

$$g(\psi) = g(\tilde{\psi}) + H(\psi - \tilde{\psi}) = 0, \text{ resolvendo } p / \psi :$$

$$\psi = \tilde{\psi} - H^{-1}(\tilde{\psi}) g(\tilde{\psi})$$

$$\psi^{(i+1)} = \psi^i - H^{-1}(\psi^i) g(\psi^i), \quad i = 1, 2, \dots, \text{niter}$$

$$\text{Obs : } \partial(x' Ax) / \partial x = (A + A')x.$$

- Problema: mesmo se a direção for de gradiente crescente, o passo tomado pode ser exagerado.

$$\psi^{(i+1)} = \psi^{(i)} - \lambda_i H^{-1}(\psi^{(i)}) g(\psi^{(i)}), \quad i = 1, 2, \dots, \text{niter}$$

onde λ_i controla a extensão do passo, garantindo que $f(\psi^{(i+1)}) \geq f(\psi^{(i)})$.

- Quando a função custo é o log da verossimilhança, o método de scoring, o qual substitui o Hessiano pelo seu valor esperado torna-se:

$$\psi^{(i+1)} = \psi^{(i)} + \lambda_i I^{-1}(\psi^{(i)})g(\psi^{(i)}), \quad i = 1, 2, \dots, \text{niter}$$

$$E(H(\psi^{(i)})) = -E\left(\frac{\partial^2 \log L}{\partial \psi \partial \psi'}\right) = I(\psi^{(i)}), \quad \text{onde } I(\psi^{(i)})^{-1} \text{ é o}$$

limite inferior de Cramér – Rao para a matriz
var iância – cov ariância dos hiperparâmetros.

- Cr itérios de convergência: o processo de otimização é finalizado quando os três cr itérios abaixo são satisfeitos:

i. veross. $\text{crit}_1 = |\ell(\psi_i) - \ell(\psi_{i+1})| / |\ell(\psi_i)| < \varepsilon$

ii. gradiente $\text{crit}_2 = \frac{1}{p} \sum_{j=1}^p |g_j(\psi_i)| < 10\varepsilon$

iii. parâmetro $\text{crit}_3 = \frac{1}{p} \sum_{j=1}^p \frac{|\psi_{i+1,j} - \psi_{i,j}|}{|\psi_{i,j}|} < 100\varepsilon$

- A mensagem final do processo de otimização pode tomar as seguintes formas:

	crit1	crit2	crit3
- very strong	< e	< e	< e
- strong	< e	< e	< 10e
- weak	< e	< 10e	< 10e
- very weak	< 10e	< 10e	< 10e

Exemplo da saída de STAMP:

```
Lairline = log(airline);  
Method of estimation is Maximum likelihood  
The present sample is: 49 (1) to 60 (12)
```

```
MaxLik initialising...  
it 1 f= 2.75996 e0= 0.30426 step= 1.00000  
it 2 f= 2.76849 e0= 0.64547 step= 1.00000  
it 3 f= 2.84211 e0= 0.26834 step= 1.00000  
it 4 f= 2.87831 e0= 0.11764 step= 0.50000  
it 5 f= 2.88073 e0= 0.04613 step= 0.50000
```

```
MaxLik iterating...  
it 4 f= 2.88365 df= 0.00005 e1= 0.00068 e2= 0.06698 step= 1.00000  
it 8 f= 2.88366 df= 0.00000 e1= 0.00000 e2= 0.00000 step= 0.00105
```

Equation 1.

Lairline = Trend + Dummy seasonal + Irregular

```
Estimation report  
Model with 4 parameters ( 2 restrictions).  
Parameter estimation sample is 49.1 - 60.12. (T = 144).  
Log-likelihood kernel is 2.883664.  
Very strong convergence in 8 iterations.  
( likelihood cvg 2.772031e-015  
gradient cvg 6.377121e-008  
parameter cvg 2.360301e-009 )
```

Eq 1 : Estimated variances of disturbances.

Component	Lairline (q-ratio)
Irr	0.00012951 (0.1852)
Lvl	0.00069945 (1.0000)
Slp	0.00000 (0.0000)
Sea	6.4129e-005 (0.0917)

Eq 1 : Estimated coefficients of final state vector.

Variable	Coefficient	R.m.s.e.	t-value	
Lvl	6.1809	0.016985	363.91	[0.0000]
Slp	0.0093707	0.0022176	4.2256	[0.0000]
Sea_1	-0.11016	0.015203	-7.2465	[0.0000]
Sea_2	-0.21568	0.013792	-15.638	[0.0000]
Sea_3	-0.069632	0.013744	-5.0664	[0.0000]
Sea_4	0.040004	0.013746	2.9102	[0.0042]
Sea_5	0.21936	0.013746	15.958	[0.0000]
Sea_6	0.23184	0.013744	16.868	[0.0000]
Sea_7	0.10554	0.013746	7.6779	[0.0000]
Sea_8	-0.0029544	0.013753	-0.21482	[0.8302]
Sea_9	-0.0024482	0.013766	-0.17784	[0.8591]
Sea_10	-0.014385	0.013781	-1.0438	[0.2985]
Sea_11	-0.11648	0.013786	-8.4487	[0.0000]

Eq 1 : Seasonal analysis (at end of period).

Seasonal Chi^2(11) test is 848.84 [0.0000].

	Seas 1	Seas 2	Seas 3	Seas 4	Seas 5
Value	-0.065006	-0.11648	-0.014385	-0.0024482	-0.0029544
	Seas 6	Seas 7	Seas 8	Seas 9	Seas 10
Value	0.10554	0.23184	0.21936	0.040004	-0.069632
	Seas 11	Seas 12			
Value	-0.21568	-0.11016			

- A vantagem deste método é que a saída da otimização não só oferece os valores ótimos, mas também a matriz variância, cujo elementos da diagonal são utilizados na construção de testes de hipótese, pois:

$$\sqrt{T}(\psi - \tilde{\psi}) \sim N(0, \text{Asy var}(\tilde{\psi})),$$

onde $\text{Asy var}(\tilde{\psi}) = I^{-1}(\tilde{\psi})$.

- Deve-se observar que este resultado só é válido se:
 - i. Ψ é um ponto interior do espaço paramétrico;
 - ii. as terceiras derivadas de $\log L$ existem e são contínuas na vizinhança do valor verdadeiro do parâmetro;
 - iii. Ψ é identificável.
- Na prática o gradiente e o Hessiano, podem ser obtidos numericamente ou analiticamente.

⇒ Tratamento de observações faltantes

- Suponha que existe uma observação faltante em $t=m$. O que ocorrerá com o FK ?

eq. de previsão:

$$a_{m|m-1} = T a_{m-1} + c_m$$

$$P_{m|m-1} = T P_{m-1} T' + R Q R'$$

eq. de atualização: usaremos a seguinte substituição

$$a_m = a_{m|m-1}$$

$$P_m = P_{m|m-1}. \text{ Por tanto em } t = m + 1, \text{ teremos:}$$

$$a_{m+1|m-1} = T a_m + c_{m+1} = T a_{m|m-1} + c_{m+1} = T^2 a_{m-1} + T c_{m+1} + c_m$$

$$\begin{aligned} P_{m+1|t} &= T P_m T' + R Q R' \\ &= T P_{m|m-1} T' + R Q R' \\ &= T (T P_{m-1} T' + R Q R') T' + R Q R' \\ &= T^2 P_{m-1} T'^2 + T R Q R' T' + R Q R'. \end{aligned}$$

Para estimar y em $t = m$, usaremos o algoritmo de suavização:

$$\hat{y}_m = E(y_{m|T}) = T a_{m|T}.$$

Como a veross. é afetada ?

- Não existe $p(y_m | Y_{m-1})$, pulamos e usamos

$$p(y_{m+1} | Y_m) = p(y_{m+1} | Y_{m-1})$$