

NOTAS DE AULA – IV

Componente Sazonal em Modelos Estruturais

⇒ **Componente Sazonal**

- **Sazonalidade**= representa as flutuações periódicas que ocorrem no período máximo de um ano, estando associadas a variações climáticas(estações do ano), tradições culturais/sociais (Carnaval, Páscoa, Natal, Dia das Mães, São João, etc), medidas legais e administrativas (início e fim do ano letivo,do ano fiscal) etc.

s: período de sazonalidade = tempo que a flutuação periódica leva para se repetir em 1 ano.

4, séries trimestrais;

12, séries mensais;

52, séries semanais;


- Uma série pode apresentar mais do que uma componente sazonal. Ex: se a série for diária, pode haver sazonalidades: diária ($s=365$), semanal ($s=7$), etc, cada qual associada a um fenômeno específico. Stamp, para séries diárias considera sazonalidade semanal ($s=7$).

- Em muitas circunstâncias, a componente sazonal pode ser vista como algo indesejável (*nuisance*), que obscurece a visualização de outras componentes de interesse da ST , por exemplo, a tendência.

Ex: - taxa de desemprego mensal;

- PIB trimestral.


- Denomina-se de **ajustamento sazonal** ou **dessazonalização** ao processo de retirada/filtragem da componente sazonal de uma ST de forma a se obter uma ST livre das flutuações sazonais.
- Muitas ST que fazem parte das estatísticas oficiais dos governos são publicadas dessazonalizadas.
- Exemplo: taxa de desemprego aberto mensal para o Brasil (1981.01 a 2000.08)



- Procedimentos
 - **model based**: modelos estruturais, SEATS/TRAMO (EuroStata)
 - **métodos semi-heurísticos**: X12 ARIMA (US Bureau of Census)

- **Escalas da sazonalidade:** a componente sazonal pode entrar no modelo na escala aditiva, multiplicativa ou mista.

I. **Saz. aditiva:** é o padrão nos modelos lineares.



$$y_t = \text{Tend} + \text{Saz} + \text{Irreg}$$


$$y_t = \mu_t + \gamma_t + \varepsilon_t$$

Série sazonalmente ajustada: $y_t^{(a)} = y_t - \hat{\gamma}_t = \hat{\mu}_t + \hat{\varepsilon}_t$

- Observe que a série sazonalmente ajustada não equivale a componente de tendência, uma vez que, após a subtração do fator sazonal, sobram a tendência estimada e a componente irregular estimada (resíduo).

- A componente sazonal calculada num determinado período (mês, trimestre, etc) é também denominada de fator sazonal.

- ii. **Saz multiplicativa:** é o padrão no método X-12 ARIMA, mas pode ser obtida de modelos lineares se ajustarmos um modelo para o log da série.



$$y_t = \text{Tend} * \text{Saz} * \text{Irreg}$$

$$y_t = \mu_t \gamma_t \varepsilon_t$$

Série sazonalmente ajustada: $y_t^{(a)} = y_t / \hat{\gamma}_t = \hat{\mu}_t \hat{\varepsilon}_t$

⇒ Obtendo fatores multiplicativos a partir de um modelo aditivo:

- Os procedimentos “model based” não são adequados para estimar fatores multiplicativos na forma original.
- Entretanto através da transformação logarítmica é possível tornar um modelo multiplicativo em aditivo:

>> mod. multiplicativo :

$$y_t = \mu_t \gamma_t \varepsilon_t$$

>> transformando em aditivo :

$$\ln y_t = \ln \mu_t + \ln \gamma_t + \ln \varepsilon_t$$

$$y'_t = \mu'_t + \gamma'_t + \varepsilon'_t. \text{ (este é o modelo efetivamente ajustado).}$$

>> Mas o que queremos é dessazonalizar a série original, e não o seu log :

$$y_t^{(a)} = y_t / \hat{\gamma}_t = \exp(y'_t) / \exp(\hat{\gamma}'_t).$$

>> Qual a interpretação do fator sazonal multiplicativo γ_t ?

$$100 \left(\frac{\hat{y}_t - \hat{\mu}_t}{\hat{\mu}_t} \right) = 100 \left(\frac{\hat{\gamma}_t \hat{\mu}_t - \hat{\mu}_t}{\hat{\mu}_t} \right) = 100(\hat{\gamma}_t - 1) = 100(\exp(\hat{\gamma}'_t) - 1).$$

Ex: ajustando um ME ao log da série, encontramos que o fator sazonal no mês de janeiro é 0.3. Como $\exp(0.3) \approx 1.35$, então no mês de janeiro a série, devido a flutuação sazonal, apresenta um aumento de 35% em relação a sua tendência.

⇒ Por que a transformação logarítmica é indicada em algumas situações:

i. **lineariza o modelo** = como vimos, um modelo originalmente multiplicativo, é transformado em modelo aditivo, isto é, linear nas componentes, através desta transformação.

ii. **traz simetria aos resíduos** = se os resíduos de um modelo possuem distribuição assimétrica a transformação logarítmica pode tornar a distribuição dos resíduos aprox. simétrica, contribuindo para a não rejeição da hipótese de normalidade.

iii. **muda a escala** = se $y_t \sim I(1)$, então $\Delta \log(y_t)$ é estacionário ($I(0)$), e além do mais,

$$\begin{aligned}\Delta \log y_t &= \log(y_t / y_{t-1}) = \log(1 + \Delta y_t / y_{t-1}) \\ &\approx \Delta y_t / y_{t-1}, \text{ se } \Delta y_t \ll y_{t-1}.\end{aligned}$$

ou seja, a escala passa a ser de variação relativa, ou percentual. Raramente utilizada em ME, embora seja comum em regressão de ST.

iv. **estabiliza a variância** = muitas vezes na escala original a variável dependente é heterocedástica, ou seja, a sua variância não é fixa no tempo, invalidando os testes estatísticos que pressupõem homocedasticidade. Para um tipo especial de heterocedasticidade, a transformação logarítmica estabiliza a variância.

Prova: supor

$$y_t = \mu_t \gamma_t \varepsilon_t, \varepsilon_t \sim \log \text{normal}(\exp(1/2\sigma^2), \exp(2\sigma^2) - \exp(\sigma^2)).$$

Por tanto

$$E(y_t | \mu_t \gamma_t) = \mu_t \gamma_t E(\varepsilon_t) = \mu_t \gamma_t \exp(1/2\sigma^2)$$

$$\begin{aligned} \text{Var}(y_t | \mu_t \gamma_t) &= (\mu_t \gamma_t)^2 (\exp(2\sigma^2) - \exp(\sigma^2)) \\ &= (\mu_t \gamma_t)^2 \exp(\sigma^2) [\exp(\sigma^2) - 1] \\ &\propto [E(y_t) | \mu_t \gamma_t]^2. \end{aligned}$$

• Ou seja, na escala original a variável y é heterocedástica. A questão é saber qual a transformação adequada que irá estabilizar a variância de y . Seja esta transformação:

$z_t = h(y_t)$. Então segue que:

$$\text{Var}(z_t | \mu_t \gamma_t) = \text{Var}(h(y_t | \mu_t \gamma_t)).$$

Suponha expansão de Taylor em torno de $w_t = E(y_t | \mu_t \gamma_t)$.

$$z_t = h(y_t) \approx h(w_t) + h'(w_t)(y_t - w_t)$$

$$\begin{aligned} \text{Var}(h(y_t) | \mu_t \gamma_t) &\approx [h'(w_t)]^2 \text{Var}(y_t | \mu_t \gamma_t) = \text{cte} \\ &\approx [h'(w_t)]^2 [E(y_t) | \mu_t \gamma_t]^2 = \text{cte} \end{aligned}$$

Se escolhermos $h(w_t) = \log(w_t)$, então

$$[h'(w_t)]^2 = [1/w_t]^2 \propto [E(y_t) | \mu_t \gamma_t]^2.$$

Ou seja, a transformação log estabiliza a variância se a lei da variância for do tipo $\text{Var}[(y_t) | \mu_t \gamma_t] \propto [E(y_t) | \mu_t \gamma_t]^2$.

⇒ Tratamento de sazonalidade em modelos estatísticos: existem três procedimentos para o controle da sazonalidade:

- i. variáveis dummy
- ii. funções trigonométricas
- iii. variável endógena defasada: y_{t-s} .

Apenas os dois primeiros são adequados para tratamento nos ME.

1. Sazonalidade por variáveis dummy:

- é o mais simples de ser implementado;
- o coeficiente de cada dummy representa o fator sazonal do mês (trimestre, etc) de interesse;
- A título de ilustração considere um período trimestral ($s=4$). Um modelo inicial seria:

$$y_t = \beta + \gamma_1 D_{1t} + \gamma_2 D_{2t} + \gamma_3 D_{3t} + \gamma_4 D_{4t} + \varepsilon_t, \quad t = 1, 2, \dots, T$$

$$D_{it} = 1 \quad i = t, \quad i = 1, 2, 3, 4$$

0 c.c.

- Entretanto esse modelo apresenta um problema - **multicolinearidade perfeita** (um dos regressores pode ser obtido como combinação linear dos outros regressores):

$$y_t = [\beta \ \gamma_1 \ \gamma_2 \ \gamma_3 \ \gamma_4] \begin{bmatrix} 1 \\ D_{1t} \\ D_{2t} \\ D_{3t} \\ D_{4t} \end{bmatrix} + \varepsilon_t, \quad t = 1, 2, \dots, T$$

$y_t = \beta' x_t + \varepsilon_t, \quad t = 1, 2, \dots, T$. Finalmente utilizando notação matricial:

$$y_{Tx1} = X_{Txk} \beta_{kx1} + \varepsilon_{Tx1},$$

$$X = \begin{bmatrix} 1 & X_{21} & X_{31} & \dots & X_{k1} \\ 1 & X_{22} & X_{32} & \dots & X_{k2} \\ \dots & & & & \\ 1 & X_{2T} & X_{3T} & \dots & X_{kT} \end{bmatrix}_{Txk}$$

A solução de MQO é dada por: $\hat{\beta} = (X'X)^{-1} X'y$, onde

$$(X'X) = \begin{bmatrix} T & \sum X_{2t} & \sum X_{3t} & \dots & \sum X_{kt} \\ \sum X_{2t} & \sum X_{2t}^2 & \sum X_{2t} X_{3t} & \dots & \sum X_{2t} X_{kt} \\ \sum X_{3t} & \sum X_{3t} X_{2t} & \sum X_{3t}^2 & \dots & \sum X_{3t} X_{kt} \\ \dots & \dots & \dots & \dots & \dots \\ \sum X_{kt} & \sum X_{kt} X_{2t} & \sum X_{kt} X_{3t} & \dots & \sum X_{kt}^2 \end{bmatrix}_{k \times k}$$

$X_{kt} = D_{kt} \quad t = 1, 2, \dots, 6 ; k = 1, 2, 3, 4$, segue que :

$$X = \begin{matrix} & X_{1t} & X_{2t} & X_{3t} & X_{4t} & X_{5t} \\ \begin{matrix} 1 \\ 2 \\ 3 \\ 4 \\ 5 \\ 6 \end{matrix} & \begin{bmatrix} 1 & 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 \end{bmatrix} \end{matrix}_{6 \times 5}$$

Segue que : $X_{1t} = X_{2t} + X_{3t} + X_{4t} + X_{5t}$, $\forall t$ (I). Ou seja, existe multicol. perfeita entre os regressores.

Consequência: a primeira linha da matriz $X'X$ será igual à soma das outras.

Prova : use (I) e a expressão de $X'X$, e que:

$$\sum X_{kt} = 6, k=1; \quad \sum X_{kt} = 2, k=2,3; \quad \sum X_{kt} = 1, k=4,5.$$

$$\sum X_{kt} X_{jt} = 0, \quad \forall k \neq j. \text{ Assim teremos:}$$

$$(X'X) = \begin{matrix} & \begin{bmatrix} 6 & 2 & 2 & 1 & 1 \\ 2 & 2 & 0 & 0 & 0 \\ 2 & 0 & 2 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 1 \end{bmatrix} \end{matrix}_{5 \times 5} \quad \gg \text{a coluna 1 é igual a soma das outras colunas.}$$

>> Para evitar multicol. perfeita deve-se introduzir algum tipo de restrição nos parâmetros do modelo de regressão, resultando em diferentes parametrizações do modelo. Estas diferentes parametrizações serão vistas a seguir.

>> Cada parametrização irá estimar o fator sazonal a partir de um patamar distinto, mas o poder preditivo e as previsões obtidas com estas parametrizações serão idênticas.

i) Parametrização 1

>> faz-se um dos coefs $\gamma_j = 0$, $j = 1, 2, 3, 4$, o que equivale a abandonar da regressão a dummy D_{jt} . Por exemplo, se abandonarmos a dummy do 4o trimestre o modelo resultante fica:

$$y_t = \beta + \gamma_1 D_{1t} + \gamma_2 D_{2t} + \gamma_3 D_{3t} + \varepsilon_t, \quad t = 1, 2, \dots, T$$

$$D_{jt} = \begin{cases} 1, & t = j, j+s, j+2s, \dots, \quad j = 1, 2, 3 \\ 0, & t \neq j, j+s, j+2s, \dots \end{cases}$$

$$E(y_t | D_{it} = 0, i = 1, 2, 3) = \beta \quad \Rightarrow \quad \hat{\beta} = \bar{y}_4$$

$$E(y_t | D_{jt} = 1, D_{it} = 0, i \neq j, i = 1, 2, 3) = \beta + \gamma_j \Rightarrow \quad \hat{\gamma}_j = \bar{y}_j - \bar{y}_4, \quad j = 1, 2, 3$$

onde \bar{y}_j é a média amostral da série no trimestre j , $j = 1, 2, 3, 4$.

Assim nessa parametrização o fator sazonal é medido em relação ao período basal.

ii) Parametrização 2

>> abandona o intercepto do modelo e coloca uma dummy para cada trimestre.

>> o patamar aqui é o zero.

$$y_t = \delta_1 D_{1t} + \delta_2 D_{2t} + \delta_3 D_{3t} + \delta_4 D_{4t} + \varepsilon_t$$

$$D_{jt} = \begin{cases} 1, & t = j, j+s, j+2s, \dots, \quad j = 1, 2, 3, 4 \\ 0, & t \neq j, j+s, j+2s, \dots \end{cases}$$

$$E(y_t | D_{jt}) = \delta_j \Rightarrow \hat{\delta}_j = \bar{y}_j, \quad j = 1, 2, 3, 4 \quad \text{onde}$$

\bar{y}_j é a média amostral da série no trimestre j , $j = 1, 2, 3, 4$.

>> pouco usual pois a maioria dos modelos têm intercepto/tendência.

iii) Parametrização 3

>> introduz restrição nos coeficientes sazonais: a soma dos fatores sazonais é zero no período sazonal.

$$\sum_{j=1}^s \theta_j = 0 \quad \therefore \quad \theta_s = - \left(\sum_{j=1}^{s-1} \theta_j \right) \text{ (adotada nos ME)}$$

$$y_t = \alpha + \sum_{j=1}^{s-1} \theta_j D_{jt} + \varepsilon_t, \quad t = 1, 2, \dots, T$$

$$D_{jt} = \begin{cases} 1, & t = j, j+s, j+2s, \dots \\ 0, & t \neq j, j+s, j+2s, \dots \end{cases}, \quad D_{jt} = \begin{cases} -1, & t = s, 2s, 3s, \dots \\ 0, & t \neq s, 2s, 3s, \dots \end{cases}$$

$$E(y_t | D_{jt}) = \alpha + \theta_j \Rightarrow \theta_j = E(y_t | D_{jt}) - \alpha, \quad j = 1, 2, 3$$

$$E(y_t | D_{j4}) = \alpha - (\theta_1 + \theta_2 + \theta_3) = \alpha + \theta_4 \Rightarrow \theta_4 = E(y_t | D_{j4}) - \alpha$$

$$0 = (\theta_1 + \theta_2 + \theta_3 + \theta_4) = \sum_{j=1}^4 E(y_t | D_{jt}) - 4\alpha$$

$$\alpha = (1/4) \sum_{j=1}^4 E(y_t | D_{jt}) \Rightarrow \hat{\alpha} = (1/4) \sum_{j=1}^4 \bar{y}_j, \text{ onde } \bar{y}_j = (1/n_j) \sum_{t=1}^{n_j} y_t^{(j)}$$

é a média da série para o trimestre $j, j = 1, 2, 3, 4$.

Mas a média total da série $\bar{y} = (1/n) \sum_{t=1}^n y_t$, onde $n = \sum_{j=1}^4 n_j$.

$$\bar{y} = (1/n) \left(\sum y_t^{(1)} + \sum y_t^{(2)} + \sum y_t^{(3)} + \sum y_t^{(4)} \right) = (1/n) \left(\sum_{j=1}^4 n_j \bar{y}_j \right)$$


Se a amostra for balanceada então $n_j = (1/4)n \therefore n_j / n = 1/4$ e assim

$$\bar{y} = 1/4 \sum_{j=1}^4 \bar{y}_j = \hat{\alpha}, \text{ ou seja}$$

$$\theta_j = E(y_t | D_{jt}) - \alpha, \quad j = 1, 2, 3 \Rightarrow \hat{\theta}_j = \bar{y}_j - \bar{y}, \quad j = 1, 2, 3, 4$$

o fator sazonal de cada trimestre é medido em relação à média da série.

❑ Para ilustrar as diferentes possibilidades de parametrização de variáveis dummies na caracterização de sazonalidade determinística, considere a série trimestral do índice de produção industrial dos EUA no período 1953Q1 a 2004Q4 (n=208).



Observe que:

- i. a amostra é balanceada, i.e., $n=208$, $n_j=208/4= 52$.
- ii. a modelagem da série não incluirá tendência, e assim, de partida, o modelo estará mal especificado, mas servirá para ilustrar o que se pretende.
- iii. as médias da série, por trimestre e total , são dadas abaixo:

| QUARTER | Mean | Std. Dev. | Obs. |
|---------|----------|-----------|------|
| 1 | 61.78288 | 27.42308 | 52 |
| 2 | 62.24191 | 27.55858 | 52 |
| 3 | 62.65968 | 27.69122 | 52 |
| 4 | 63.16506 | 27.87475 | 52 |
| All | 62.46238 | 27.44119 | 208 |

1. modelo 1= abandona a dummy do 4º trimestre.

Dependent Variable: IP
Method: Least Squares
Date: 05/20/10 Time: 11:40
Sample: 1953Q1 2004Q4
Included observations: 208

| Variable | Coefficient | Std. Error | t-Statistic | Prob. |
|--------------------|-------------|-----------------------|-------------|--------|
| C | 63.16506 | 3.832620 | 16.48091 | 0.0000 |
| @SEAS(1) | -1.382179 | 5.420143 | -0.255008 | 0.7990 |
| @SEAS(2) | -0.923154 | 5.420143 | -0.170319 | 0.8649 |
| @SEAS(3) | -0.505385 | 5.420143 | -0.093242 | 0.9258 |
| | | | | |
| R-squared | 0.000348 | Mean dependent var | 62.46238 | |
| Adjusted R-squared | -0.014353 | S.D. dependent var | 27.44119 | |
| S.E. of regression | 27.63741 | Akaike info criterion | 9.495261 | |
| Sum squared resid | 155820.6 | Schwarz criterion | 9.559445 | |
| Log likelihood | -983.5072 | Hannan-Quinn criter. | 9.521214 | |
| F-statistic | 0.023669 | Durbin-Watson stat | 0.002224 | |
| Prob(F-statistic) | 0.995057 | | | |

$$IP = 63.165 - 1.382*Q1 - 0.923*Q2 - 0.505*Q3$$

- >> a estimativa do intercepto é a média amostral da série no 4º trimestre.
- >> os outros coeficientes, que caracterizam o fator sazonal dos trimestres 1, 2 e 3, são estimados pela diferença entre a média amostral do trimestre correspondente e a média amostral do 4º trimestre.
- >> pelo teste F pode-se concluir, ignorando a mal especificação do modelo, que não se pode rejeitar a hipótese de inexistência de sazonalidade nesta série.

$$H_o: c(2)=c(3)=c(4)=0$$

↔ não há sazonalidade na série

$$H_a: c.c.$$

↔ há sazonalidade na série

- 1. modelo 2=** abandona o intercepto e inclui uma dummy para cada trimestre.

Dependent Variable: IP
Method: Least Squares
Date: 05/20/10 Time: 10:31
Sample: 1953Q1 2004Q4
Included observations: 208

| Variable | Coefficient | Std. Error | t-Statistic | Prob. |
|--------------------|-------------|-----------------------|-------------|--------|
| @SEAS(1) | 61.78288 | 3.832620 | 16.12028 | 0.0000 |
| @SEAS(2) | 62.24191 | 3.832620 | 16.24004 | 0.0000 |
| @SEAS(3) | 62.65968 | 3.832620 | 16.34905 | 0.0000 |
| @SEAS(4) | 63.16506 | 3.832620 | 16.48091 | 0.0000 |
| R-squared | 0.000348 | Mean dependent var | 62.46238 | |
| Adjusted R-squared | -0.014353 | S.D. dependent var | 27.44119 | |
| S.E. of regression | 27.63741 | Akaike info criterion | 9.495261 | |
| Sum squared resid | 155820.6 | Schwarz criterion | 9.559445 | |
| Log likelihood | -983.5072 | Hannan-Quinn criter. | 9.521214 | |
| Durbin-Watson stat | 0.002224 | | | |

$$IP = 61.783*Q1 + 62.242*Q2 + 62.660*Q3 + 63.165*Q4$$

- >> a estimativa de cada coeficiente é a média amostral da série no trimestre correspondente.
- >> observe que as estatísticas fundamentais da regressão (R^2 , DW, AIC, Soma do quadrado dos resíduos etc não são alteradas. A estatística F não pode ser computada para modelos sem intercepto).

1. **modelo 3**= introduz a restrição de que a soma dos coefs sazonais é nula no período sazonal.

Dependent Variable: IP

Method: Least Squares

Date: 05/20/10 Time: 10:46

Sample: 1953Q1 2004Q4

Included observations: 208

IP= C(1) + C(2)*@SEAS(1) + C(3)*@SEAS(2)+ C(4)*@SEAS(3) - @SEAS(4)
*(C(2)+C(3)+C(4))

| | Coefficient | Std. Error | t-Statistic | Prob. |
|--------------------|-------------|-----------------------|-------------|--------|
| C(1) | 62.46238 | 1.916310 | 32.59514 | 0.0000 |
| C(2) | -0.679500 | 3.319146 | -0.204721 | 0.8380 |
| C(3) | -0.220474 | 3.319146 | -0.066425 | 0.9471 |
| C(4) | 0.197295 | 3.319146 | 0.059441 | 0.9527 |
| R-squared | 0.000348 | Mean dependent var | 62.46238 | |
| Adjusted R-squared | -0.014353 | S.D. dependent var | 27.44119 | |
| S.E. of regression | 27.63741 | Akaike info criterion | 9.495261 | |
| Sum squared resid | 155820.6 | Schwarz criterion | 9.559445 | |
| Log likelihood | -983.5072 | Hannan-Quinn criter. | 9.521214 | |
| F-statistic | 0.023669 | Durbin-Watson stat | 0.002224 | |
| Prob(F-statistic) | 0.995057 | | | |

$$IP = 62.462 - 0.680*Q1 - 0.221*Q2 + 0.197*Q3, j=1,2,3$$

$$IP = 62.462 - (-0.680 - 0.221 + 0.197)*Q4, j=4$$

- >> a estimativa do intercepto (c(1)) é a média amostral da série.
- >> a estimativa de cada um coeficientes sazonais - c(2), c(3), c(4), c(5)=-(c(2)+c(3)+c(4)) - é a diferença entre a média amostral da série e a média amostral da série para o trimestre em questão.
- >> observe que as estatísticas fundamentais da regressão (R², DW, AIC, Soma do quadrado dos resíduos, F etc não são alteradas.)

- O modelo sazonal determinístico com restrição dada pela soma dos fatores sazonais no período sazonal iguala a zero (parametrização 3) servirá de base para a introdução de sazonalidade estocástica nos ME. A idéia é a seguinte:

$\sum_{j=1}^s \gamma_j = 0 \therefore \sum_{j=0}^{s-1} \gamma_{t-j} = 0$. A versão estocástica será dada por:

$$\sum_{j=0}^{s-1} \gamma_{t-j} = \omega_t, \quad \omega_t \sim \text{NID}(0, \sigma_\omega^2), \quad \text{ou}$$

$$\gamma_t = -\sum_{j=1}^{s-1} \gamma_{t-j} + \omega_t, \quad \omega_t \sim \text{NID}(0, \sigma_\omega^2).$$

- Portanto, o modelo com TLL e sazonalidade estocástica, por dummies, denominado do Modelo Estrutural Básico, será dado por:

$$\text{--eq. das observ.:} \quad y_t = \mu_t + \gamma_t + \varepsilon_t \quad \varepsilon_t \sim N(0, \sigma_\varepsilon^2)$$

$$\text{--eq. do estado:} \quad \mu_t = \mu_{t-1} + \beta_{t-1} + \eta_t \quad \eta_t \sim N(0, \sigma_n^2)$$

$$\beta_t = \beta_{t-1} + \zeta_t \quad \zeta_t \sim N(0, \sigma_\zeta^2)$$

$$\gamma_t = -\sum_{j=1}^{s-1} \gamma_{t-j} + \omega_t \quad \omega_t \sim N(0, \sigma_\omega^2)$$

onde:

$$E(\varepsilon_t \eta_s) = E(\varepsilon_t \zeta_s) = E(\varepsilon_t \omega_t) = 0, \quad \forall t, s.$$

$$E(\varepsilon_t \alpha_0) = E(\eta_t \alpha_0) = E(\zeta_t \alpha_0) = E(\omega_t \alpha_0) = 0, \quad \forall t.$$

$$\text{Se } \alpha_t = (\mu_t, \beta_t, \gamma_t, \gamma_{t-1}, \gamma_{t-2})', \text{ então } \alpha_0 \sim N(a_0, P_0).$$

Deve-se adicionar que os ruídos das componentes são descorrelatados entre si,

- Supondo $S=4$, o modelo acima possui a seguinte representação na forma de espaço de estados:

$$y_t = (1 \ 0 \ 1 \ 0 \ 0) \begin{pmatrix} \mu_t \\ \beta_t \\ \gamma_t \\ \gamma_{t-1} \\ \gamma_{t-2} \end{pmatrix} + \varepsilon_t \quad \varepsilon_t \sim N(0, \sigma_\varepsilon^2)$$

$$\alpha_t = \begin{pmatrix} \mu_t \\ \beta_t \\ \gamma_t \\ \gamma_{t-1} \\ \gamma_{t-2} \end{pmatrix} = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & -1 & -1 & -1 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \end{bmatrix} \begin{pmatrix} \mu_{t-1} \\ \beta_{t-1} \\ \gamma_{t-1} \\ \gamma_{t-2} \\ \gamma_{t-3} \end{pmatrix} + \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{pmatrix} \eta_t \\ \zeta_t \\ \omega_t \end{pmatrix}$$

$$\eta_t = (\eta_t \ \zeta_t \ \omega_t)' \sim N(0, Q), \quad Q = E(\eta_t \eta_t') = \begin{pmatrix} \sigma_\eta^2 & 0 & 0 \\ 0 & \sigma_\zeta^2 & 0 \\ 0 & 0 & \sigma_\omega^2 \end{pmatrix}.$$

- Uma outra possibilidade é considerar uma dependência do tipo passeio aleatório p/ cada fator sazonal, como em Harrison & Stevens, 1976:

$$\gamma_{jt} = \gamma_{j,t-1} + \omega_{jt}, \quad \omega_{jt} \sim N(0, \sigma_\omega^2), \quad t = 1, 2, \dots, T; \quad j = 1, 2, \dots, s, \text{ onde}$$

$$\sum_{j=1}^s \gamma_{jt} = 0.$$

>>Podemos re-escrever as S eqs anteriores de forma vetorial como:

$$\gamma_{jt} = \gamma_{jt-1} + \omega_{jt}, \omega_{jt} \sim N(0, \sigma_{\omega}^2), t = 1, 2, \dots, T; j = 1, 2, \dots, s, \text{ onde}$$

$$\gamma_t = \gamma_{t-1} + \omega_t, \omega_t \sim N(0, \Omega)$$

$$\text{Se impusermos } \sum_{j=1}^s \gamma_{jt} = 0 \Rightarrow \sum_{j=1}^s \omega_{jt} = 0, \text{ se } \sum_{j=1}^s \gamma_{ot} = 0.$$

$$\text{Então } \sum_{j=1}^s \omega_{jt} = 0 \Leftrightarrow (1, 1, \dots, 1)_{s \times 1} \begin{pmatrix} \omega_{1t} \\ \omega_{2t} \\ \vdots \\ \omega_{st} \end{pmatrix} = \mathbf{i}' \omega_t = 0. \text{ Ou seja, os}$$

choques sazonais na formulação de HS serão co-integrados.

$$\text{Se especificarmos } \text{Var}(\omega_t) = \Omega = \sigma_{\omega}^2 (\mathbf{I} - \mathbf{S}^{-1} \mathbf{i} \mathbf{i}') \quad (a)$$

então pode-se mostrar que essa será uma condição

suficiente que garante que $\sum_{j=1}^s \gamma_{jt} = 0$.

Prova : Considere a v.a. $z = \mathbf{i}' \omega_t$. Prove que

$E(z) = 0$, e que $\text{Var}(z) = 0$, usando (a).

Portanto $z = \mathbf{i}' \omega_t = \sum_{j=1}^s \gamma_{jt} = 0$ (com probabilidade 1).

⇒ Função de Previsão:

$$\begin{aligned}\hat{y}_{t+s|t} &= E(y_{t+s} | Y_t) = Z' E(\alpha_{t+s} | Y_t) = Z' \hat{\alpha}_{t+s|t} = \hat{\mu}_{t+s|t} + \hat{\gamma}_{t+s|t} = \\ &= \hat{\mu}_t + s \hat{\beta}_t + \hat{\gamma}_{t+s|t}, \text{ onde} \\ \hat{\gamma}_{t+s|t} &= \hat{\gamma}_{t-S+s|t}, \quad s = 1, 2, 3, \dots, \text{ ou seja:}\end{aligned}$$

o fator sazonal projetado para um trimestre é igual a última estimativa obtida pelo FK.

Idéia: aproximar a componente sazonal através de uma soma de séries trigonométricas.



•Teorema de Fourier = qualquer função periódica de período S , definida por um conjunto de S efeitos γ_t $t=1,2,\dots, S$ pode ser expressa como a combinação linear de senos e cossenos de período $\lambda= 2\pi/S$,

$$\gamma_t = \sum_{j=1}^{[S/2]} (\gamma_j \cos (\lambda_j t) + \gamma_j^* \text{sen} (\lambda_j t))$$


onde :

- $\lambda_j = 2\pi j / S$, $j = 1, 2, 3, \dots, [S / 2]$.
- S é o período da série; $S = 4, 12$, etc;
- $[S / 2] = \begin{cases} S / 2, & S \text{ par} \\ (S - 1) / 2, & S \text{ ímpar} \end{cases}$


- Observe as seguintes definições:
 - $\lambda_j = 2\pi j / S$, são os harmônicos. Cada harmônico executa j ciclos completos no período da função;
 - $\lambda_1 = 2\pi / S$ é a freq. fundamental.
- Função cosseno: harmônico fundamental ($j=1$) x 2° ($j=2$) e 6° harm ($j=6$).



Soma do fundamental e 6o harmônico p/ o cosseno.



Soma de todos os harmônicos da SF.



- Outras propriedades da componente sazonal por SF:

– p / S par e $j = S / 2$, $\text{sen} \lambda_j t = \text{sen} \pi t = 0, \forall t$. Assim sendo, existirá apenas $(S / 2) + (S / 2 - 1) = S - 1$ parâmetros para serem estimados por MQO, assim como na formulação por dummies;

– pode – se demonstrar, usando identidades trigonométricas,

que $\sum_{j=0}^{S-1} \gamma_{t-j} = 0$.

- O modelo determinístico com tendência e sazonalidade por SF é dado por:


$$y_t = \alpha + \beta t + \sum_{j=1}^{[S/2]} (\gamma_j \cos (\lambda_j t) + \gamma_j^* \text{sen} (\lambda_j t)) + \varepsilon_t$$

- Os parâmetros desconhecidos do modelo podem ser estimados por MQO, possibilitando assim o cálculo do fator sazonal do mês t , que é dado por:

$$\hat{\gamma}_t = \sum_{j=1}^{[S/2]} (\hat{\gamma}_j \cos (\lambda_j t) + \hat{\gamma}_j^* \text{sen} (\lambda_j t))$$

- É possível demonstrar que se utilizarmos todos os harmônicos na SF, então a estimativa dos fatores sazonais por dummies, coincidirá com a estimativa deste fatores por SF.

Ex: série mensal de vazão afluente média (em m³/seg) em um posto de avaliação localizado no rio Paraibuna.



- Modelo de sazonalidade por dummies, com restrição de soma dos fatores igual a zero no período.

| | Coefficient | Std. Error | t-Statistic | Prob. |
|--------------------|-------------|-----------------------|-------------|--------|
| C(1) | 69.77600 | 1.231404 | 56.66379 | 0.0000 |
| C(2) | 36.31224 | 4.060891 | 8.941940 | 0.0000 |
| C(3) | 42.95930 | 4.060891 | 10.57879 | 0.0000 |
| C(4) | 26.34165 | 4.060891 | 6.486668 | 0.0000 |
| C(5) | 9.871064 | 4.060891 | 2.430763 | 0.0155 |
| C(6) | -8.217172 | 4.060891 | -2.023490 | 0.0437 |
| C(7) | -15.36423 | 4.060891 | -3.783463 | 0.0002 |
| C(8) | -21.62894 | 4.060891 | -5.326156 | 0.0000 |
| C(9) | -29.47296 | 4.116383 | -7.159919 | 0.0000 |
| C(10) | -21.32145 | 4.116383 | -5.179657 | 0.0000 |
| C(11) | -17.47296 | 4.116383 | -4.244738 | 0.0000 |
| C(12) | -9.927510 | 4.116383 | -2.411707 | 0.0163 |
| R-squared | 0.479155 | Mean dependent var | 69.95037 | |
| Adjusted R-squared | 0.464502 | S.D. dependent var | 33.77748 | |
| S.E. of regression | 24.71758 | Akaike info criterion | 9.282231 | |
| Sum squared resid | 238884.9 | Schwarz criterion | 9.401306 | |
| Log likelihood | -1858.370 | Hannan-Quinn criter. | 9.329372 | |
| F-statistic | 32.70034 | Durbin-Watson stat | 0.934743 | |
| Prob(F-statistic) | 0.000000 | | | |

Equação do modelo

@seas(j) = 1, se t = mês j, j=1,2,...,12; 0, cc

HYDRO = C(1) + C(2)*@SEAS(1) + C(3)*@SEAS(2) + C(4)*@SEAS(3) +
 C(5)*@SEAS(4) + C(6)*@SEAS(5) + C(7)*@SEAS(6) + C(8)*@SEAS(7) +
 C(9)*@SEAS(8) + C(10)*@SEAS(9) + C(11)*@SEAS(10) + C(12)*@SEAS(11) +
 (-C(2)-C(3)-C(4)-C(5)-C(6)-C(7)-C(8)-C(9)-C(10) -C(11)-C(12))*@SEAS(12) + erro

fat_saz jan= 69.776

fat_saz fev= 36.31224 etc

Obs: o modelo é apenas ilustrativo do tratamento de sazonalidade. Outras estruturas de dependência existentes na série (que podem ser investigadas via FAC dos resíduos), que não a sazonal, não serão tratadas aqui.

- Modelo de sazonalidade por trigonmométricos, onde a soma dos fatores é igual a zero no período.

> primeiro temos que criar as séries de cossenos e senos:

$$\cos(\lambda_j t) \text{ e } \sin(\lambda_j t), \lambda_j = 2\pi j/12 = \pi j/6, j=1,2,\dots, 6 \text{ e } t=1,2,\dots,403$$

'programa sazonalidade por trigonométricos

scalar pi=@acos(-1)

' cria séries temporais de harmônicos senos e cossenos

for li=1 to 6

series cos{li}=cos((@trend+1)*pi*li/6)

series sen{li}=sin((@trend+1)*pi*li/6)

next

| Variable | Coefficient | Std. Error | t-Statistic | Prob. |
|--------------------|-------------|-----------------------|-------------|--------|
| C | 69.77600 | 1.231404 | 56.66379 | 0.0000 |
| COS1 | 15.75444 | 1.740382 | 9.052291 | 0.0000 |
| COS2 | -2.856061 | 1.742553 | -1.639009 | 0.1020 |
| COS3 | -3.633838 | 1.743638 | -2.084056 | 0.0378 |
| COS4 | -0.605764 | 1.742553 | -0.347630 | 0.7283 |
| COS5 | -0.478002 | 1.740382 | -0.274653 | 0.7837 |
| COS6 | -0.259804 | 1.231404 | -0.210982 | 0.8330 |
| SEN1 | 27.31628 | 1.742553 | 15.67601 | 0.0000 |
| SEN2 | 7.782136 | 1.740382 | 4.471511 | 0.0000 |
| SEN3 | 1.998069 | 1.739295 | 1.148781 | 0.2513 |
| SEN4 | 1.694487 | 1.740382 | 0.973630 | 0.3308 |
| SEN5 | -1.486657 | 1.742553 | -0.853149 | 0.3941 |
| R-squared | 0.479155 | Mean dependent var | 69.95037 | |
| Adjusted R-squared | 0.464502 | S.D. dependent var | 33.77748 | |
| S.E. of regression | 24.71758 | Akaike info criterion | 9.282231 | |
| Sum squared resid | 238884.9 | Schwarz criterion | 9.401306 | |
| Log likelihood | -1858.370 | Hannan-Quinn criter. | 9.329372 | |
| F-statistic | 32.70034 | Durbin-Watson stat | 0.934743 | |
| Prob(F-statistic) | 0.000000 | | | |

HYDRO = C(1) + C(2)*COS1 + C(3)*COS2 + C(4)*COS3 + C(5)*COS4 + C(6)*COS5 + C(7)*COS6 + C(8)*SEN1 + C(9)*SEN2 + C(10)*SEN3 + C(11)*SEN4 + C(12)*SEN5 + erro

>> aqui os fatores sazonais têm que ser calculados.

>> Como visto, uma vez estimado o modelo de sazonalidade por trigonométricos, o fator sazonal de cada mês t será dado por:

$$\hat{\gamma}_t = \sum_{j=1}^{[S/2]} (\hat{\gamma}_j \cos(\lambda_j t) + \hat{\gamma}_j^* \sin(\lambda_j t)) \quad t = 1, 2, \dots, 12$$

$$\hat{\gamma}_t = \sum_{j=1}^6 (\hat{\gamma}_j \cos(\frac{\pi j}{6} t) + \hat{\gamma}_j^* \sin(\frac{\pi j}{6} t))$$

O programa Eviews para implementar esse cálculo é dado a seguir:

'calcula fatores sazonais de cada mês no modelo trigonométrico

```

scalar i
scalar j
vector (6) c_cos
vector (6) c_sen
for i= 2 to 7
    c_cos(i-1)=c(i)
next

for j= 2 to 6
    c_sen(j-1)=c(j+6)
next
c_sen(6)=0

scalar jj
scalar m
vector(12) fat_saz

for jj=1 to 12
    fat_saz(jj)=0
    for m=1 to 6
        fat_saz(jj)= fat_saz(jj) + c_cos(m)*cos(jj*pi*m/6) + c_sen(m)*sin(jj*pi*m/6)
    next
next

```

>> Após obter os fatores sazonais do modelo por trigonométricos, observamos, conforme esperado, que eles coincidem com aqueles estimados através do modelo por dummies.

trigon

| FAT_SAZ | | | |
|---------|--------------------------------|--|--|
| | C1 | | |
| | Last updated: 05/17/12 - 19:26 | | |
| | | | |
| R1 | 36.31224 | | |
| R2 | 42.95930 | | |
| R3 | 26.34165 | | |
| R4 | 9.871064 | | |
| R5 | -8.217172 | | |
| R6 | -15.36423 | | |
| R7 | -21.62894 | | |
| R8 | -29.47296 | | |
| R9 | -21.32145 | | |
| R10 | -17.47296 | | |
| R11 | -9.927510 | | |
| R12 | 7.920974 | | |

dummies

| | |
|-------|-----------|
| C(2) | 36.31224 |
| C(3) | 42.95930 |
| C(4) | 26.34165 |
| C(5) | 9.871064 |
| C(6) | -8.217172 |
| C(7) | -15.36423 |
| C(8) | -21.62894 |
| C(9) | -29.47296 |
| C(10) | -21.32145 |
| C(11) | -17.47296 |
| C(12) | -9.927510 |

>> na coluna trigon $y_j = R(j)$, $j=1,2,\dots,12$
na coluna dummies $y_j = C(j)$, $j=2,3,\dots,12$

>> observar que, na coluna das dummies, $C(2)=\text{fat_saz jan}$, $C(3)=\text{fat_saz fev},\dots$, $C(12)=\text{fat_saz nov}$. Para calcular o fator sazonal de dezembro utilizamos que

$$\text{fat_saz dez} = (-C(2)-C(3)-C(4)-C(5)-C(6)-C(7)-C(8)-C(9)-C(10)-C(11)-C(12))=7.920974$$

- Forma recursiva para fatores sazonais por SF.

Se $\gamma_{jt} \equiv (\gamma_j \cos \lambda_j t + \gamma_j^* \sin \lambda_j t)$, então

$$\gamma_t = \sum_{j=1}^{[S/2]} (\gamma_j \cos \lambda_j t + \gamma_j^* \sin \lambda_j t) = \sum_{j=1}^{[S/2]} \gamma_{jt}$$

Observe que:

$$\gamma_{jt} = \begin{cases} \gamma_j \cos \lambda_j t + \gamma_j^* \sin \lambda_j t & j = 1, \frac{S}{2} - 1 \\ \gamma_{s/2} \cos \lambda_{s/2} t, & j = s/2 \end{cases}$$

- Fazendo $t=t+1$ na expressão p/ γ_{jt} :

Como $\gamma_{jt} = \gamma_j \cos \lambda_j t + \gamma_j^* \sin \lambda_j t$, então

$$\begin{aligned} \gamma_{j,t+1} &= \gamma_j \cos \lambda_j (t+1) + \gamma_j^* \sin \lambda_j (t+1) \\ &= [\cos \lambda_j \quad \sin \lambda_j] \begin{bmatrix} \gamma_j \cos \lambda_j t + \gamma_j^* \sin \lambda_j t \\ -\gamma_j \sin \lambda_j t + \gamma_j^* \cos \lambda_j t \end{bmatrix} \\ &= [\cos \lambda_j \quad \sin \lambda_j] \begin{bmatrix} \gamma_{jt} \\ \gamma_{jt}^* \end{bmatrix}, \end{aligned}$$

onde $\gamma_{jt}^* = -\gamma_j \sin \lambda_j t + \gamma_j^* \cos \lambda_j t$.

- De forma análoga, fazendo $t=t+1$ p/ γ_{jt}^*

$$\gamma_{jt}^* = -\gamma_j \sin \lambda_j t + \gamma_j^* \cos \lambda_j t, \text{ então:}$$

$$\begin{aligned} \gamma_{j,t+1}^* &= -\gamma_j \sin \lambda_j (t+1) + \gamma_j^* \cos \lambda_j (t+1) \\ &= [-\sin \lambda_j \cos \lambda_j] \begin{bmatrix} \gamma_j \cos \lambda_j t + \gamma_j^* \sin \lambda_j t \\ -\gamma_j \sin \lambda_j t + \gamma_j^* \cos \lambda_j t \end{bmatrix} \\ &= [-\sin \lambda_j \cos \lambda_j] \begin{bmatrix} \gamma_{jt} \\ \gamma_{jt}^* \end{bmatrix}. \end{aligned}$$

Finalmente unindo as duas equações, fazendo $t = t - 1$, e adicionando um termo aleatório, obtemos a forma estocástica de sazonalidade por SF:

$$\begin{pmatrix} \gamma_{jt} \\ \gamma_{jt}^* \end{pmatrix} = \begin{pmatrix} \cos \lambda_j & \sin \lambda_j \\ -\sin \lambda_j & \cos \lambda_j \end{pmatrix} \begin{pmatrix} \gamma_{j,t-1} \\ \gamma_{j,t-1}^* \end{pmatrix} + \begin{pmatrix} w_t \\ w_t^* \end{pmatrix},$$

$$\therefore w_t \text{ e } w_t^* \sim N(0, \sigma_w^2).$$

- Modelo Estrutural Básico:

$$y_t = \mu_t + \gamma_t + \varepsilon_t \quad \varepsilon_t \sim N(0, \sigma_\varepsilon^2)$$

$$\mu_t = \mu_{t-1} + \beta_{t-1} + \eta_t \quad \eta_t \sim N(0, \sigma_n^2)$$

$$\beta_t = \beta_{t-1} + \zeta_t \quad \zeta_t \sim N(0, \sigma_\xi^2)$$

$$\gamma_t = \sum_{j=1}^{S/2} \gamma_{jt}$$

$$\begin{pmatrix} \gamma_{jt} \\ \gamma_{jt}^* \end{pmatrix} = \begin{pmatrix} \cos \lambda_j & \text{sen} \lambda_j \\ -\text{sen} \lambda_j & \cos \lambda_j \end{pmatrix} \begin{pmatrix} \gamma_{jt-1} \\ \gamma_{jt-1}^* \end{pmatrix} + \begin{pmatrix} \omega_{tj} \\ \omega_{tj}^* \end{pmatrix},$$

$$\omega_{tj} \sim N(0, \sigma_\omega^2), \quad j = 1, 2, \dots, (S / 2)$$

$$\omega_{tj}^* \sim N(0, \sigma_\omega^2) \quad j = 1, 2, \dots, (S / 2) - 1$$

- Supondo S=12, o modelo anterior possui a seguinte representação na forma de espaço de estados:

$$y_t = \begin{bmatrix} 1 & 0 & 1 & 0 & 1 & \dots & 1 \end{bmatrix} \begin{bmatrix} \mu_t \\ \beta_t \\ \gamma_{1t} \\ \gamma_{1t}^* \\ \vdots \\ \gamma_{5t} \\ \gamma_{5t}^* \\ \gamma_{6t} \end{bmatrix} + \varepsilon_t$$

$$\begin{bmatrix} \mu_t \\ \beta_t \\ \gamma_{1t} \\ \gamma_{1t}^* \\ \vdots \\ \gamma_{6t} \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 & 0 & \dots & 0 \\ 0 & 1 & 0 & 0 & \dots & 0 \\ 0 & 0 & C_1 & & & \\ & & & \dots & & \\ 0 & & & & C_5 & \\ & & & & & -1 \end{bmatrix} \begin{bmatrix} \mu_{t-1} \\ \beta_{t-1} \\ \gamma_{1,t-1} \\ \gamma_{1,t-1}^* \\ \vdots \\ \gamma_{6,t-1} \end{bmatrix} + \mathbf{I}_{(13 \times 13)} \begin{bmatrix} \eta_t \\ \zeta_t \\ w_{1t} \\ w_{1t}^* \\ w_{6t} \end{bmatrix}$$

$$\text{onde } C_j = \begin{pmatrix} \cos(\frac{\pi j}{6}) & \sin(\frac{\pi j}{6}) \\ -\sin(\frac{\pi j}{6}) & \cos(\frac{\pi j}{6}) \end{pmatrix}, \quad j = 1, 2, 3, 4, 5, \quad C_6 = \cos(\frac{\pi 6}{6}) = -1$$

$$\eta_t = [\eta_t, \zeta_t, w_{1t}, w_{1t}^*, \dots, w_{6t}]^T, E(\eta_t \eta_t^T) = Q = \begin{bmatrix} \sigma_\eta^2 & 0 & \dots & 0 \\ 0 & \sigma_\zeta^2 & \dots & 0 \\ 0 & 0 & \sigma_w^2 I_{11 \times 11} \end{bmatrix}$$

Para $s=4$

$$y_t = (1 \ 0 \ 1 \ 0 \ 1) \begin{pmatrix} \mu_t \\ \beta_t \\ \gamma_{1t} \\ \gamma_{1t}^* \\ \gamma_{2t} \end{pmatrix} + \varepsilon_t \quad \varepsilon_t \sim N(0, \sigma_\varepsilon^2)$$

$$\alpha_t = \begin{pmatrix} \mu_t \\ \beta_t \\ \gamma_{1t} \\ \gamma_{1t}^* \\ \gamma_{2t} \end{pmatrix} = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & \cos \lambda_1 & \sin \lambda_1 & 0 \\ 0 & 0 & -\sin \lambda_1 & \cos \lambda_1 & 0 \\ 0 & 0 & 0 & 0 & -1 \end{bmatrix} \begin{pmatrix} \mu_{t-1} \\ \beta_{t-1} \\ \gamma_{1,t-1} \\ \gamma_{1,t-1}^* \\ \gamma_{2,t-1} \end{pmatrix} + \begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix} \begin{pmatrix} \eta_t \\ \zeta_t \\ \omega_{1t} \\ \omega_{1t}^* \\ \omega_{2t} \end{pmatrix}$$

$$\lambda_j = \frac{2\pi}{4} j = \frac{\pi}{2} j \begin{cases} \pi / 2, & j = 1 \\ \pi, & j = 2 \end{cases}$$

$$\eta_t = (\eta_t \ \zeta_t \ \omega_{1t} \ \omega_{1t}^* \ \omega_{2t})' \sim N(0, Q), \quad Q = E(\eta_t \eta_t') = \begin{pmatrix} \sigma_\eta^2 & 0 & 0 \\ 0 & \sigma_\zeta^2 & 0 \\ 0 & 0 & \sigma_\omega^2 \mathbf{I}_{3 \times 3} \end{pmatrix}.$$

>> Observe que embora cada choque sazonal possua a mesma distribuição $N(0, \sigma_\omega^2)$, cada um dos choques aparece explicitamente nesse modelo. É fácil de ver que essa formulação não é equivalente a considerar um único choque sazonal para todos os fatores sazonais.