

Modelos Estruturais Multivariados

(MSTSM)

• Generalização dos ME univariados

• Mais complexos em relação à estimação, identificação paramétrica, interpretação e diagnóstico

• Multivariado \Rightarrow D existência de componentes comuns que afetam simultaneamente um vetor de ST, como por exemplo: consumo nacional em duas cidades próximas e similares.

\Rightarrow melhor inferência e previsão.

Modelos mais importantes

$$y_t = (y_{1t}, y_{2t}, \dots, y_{pt})$$

1. SUTSE = Simultaneously correlated TS equations

$$\begin{aligned} y_t &= \mu_t + \varepsilon_t, & \varepsilon_t &\sim N(0, \Sigma_\varepsilon) \\ \mu_{t+1} &= \mu_t + \eta_t, & \eta_t &\sim N(0, \Sigma_\eta) \end{aligned}$$

$\xrightarrow{p \times 1} \quad \xrightarrow{p \times p} \quad \xrightarrow{p \times p}$

\rightarrow a origem da dependência entre as séries resulta da estrutura não-diagonal de Σ_ε e Σ_η .

\hookrightarrow covariâncias entre os choques

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}, \quad \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} \sim N \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} \sigma_{\varepsilon_1}^2 & \sigma_{\varepsilon_1 \varepsilon_2} \\ \sigma_{\varepsilon_1 \varepsilon_2} & \sigma_{\varepsilon_2}^2 \end{pmatrix} \right)$$

$$\begin{pmatrix} y_{1,t+1} \\ y_{2,t+1} \end{pmatrix} = \begin{pmatrix} \mu_{1,t+1} \\ \mu_{2,t+1} \end{pmatrix} + \begin{pmatrix} \eta_{1t} \\ \eta_{2t} \end{pmatrix}, \quad \begin{pmatrix} \eta_{1t} \\ \eta_{2t} \end{pmatrix} \sim N \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} \sigma_{\eta_1}^2 & \sigma_{\eta_1 \eta_2} \\ \sigma_{\eta_1 \eta_2} & \sigma_{\eta_2}^2 \end{pmatrix} \right)$$

\rightarrow difícil estimar se p é grande

SUTSE les deux séries. \rightarrow vide définitions formelles

$$\sum \eta = \rho \sum \varepsilon, \quad 0 < \rho < \infty$$

Mo cas $p=2$

$$\begin{pmatrix} \sigma_{\eta_1}^2 & \sigma_{\eta_1 \eta_2} \\ \sigma_{\eta_1 \eta_2} & \sigma_{\eta_2}^2 \end{pmatrix} = \rho \begin{pmatrix} \sigma_{\varepsilon_1}^2 & \sigma_{\varepsilon_1 \varepsilon_2} \\ \sigma_{\varepsilon_1 \varepsilon_2} & \sigma_{\varepsilon_2}^2 \end{pmatrix}$$

$$y_{it} = \mu_{it} + \varepsilon_{it}$$

$$\mu_{i,t+1} = \mu_{i,t} + \eta_{i,t}$$

$$\Delta y_{it} = \Delta \mu_{it} + \Delta \varepsilon_{it} = \eta_{i,t-1} + \Delta \varepsilon_{it} \quad i=1,2$$

$$\sim \text{MA}(1)$$

$$z_t = \Delta y_{it} = w_t + \theta w_{t-1}, \quad w_t \sim N(0, \sigma_w^2)$$

$$\rho(1) = \frac{E(z_t z_{t-1})}{\text{Var}(z_t)} = \frac{\theta}{1+\theta^2}$$

$$\text{Var}(z_t) = (1+\theta^2) \sigma_w^2$$

$$E(z_t z_{t-1}) = \theta \sigma_w^2$$

$$\text{Var}(\Delta y_{it}) = \sigma_{\eta_i}^2 + 2\sigma_{\varepsilon_i}^2$$

$$E(\Delta y_{it}, \Delta y_{i,t-1}) = -\sigma_{\varepsilon_i}^2$$

$$\rho(1) = \frac{E(\Delta y_{it}, \Delta y_{i,t-1})}{\text{Var}(\Delta y_{it})} = \frac{-\sigma_{\varepsilon_i}^2}{(\sigma_{\eta_i}^2 + 2\sigma_{\varepsilon_i}^2)} = \frac{-\sigma_{\varepsilon_i}^2}{\rho \sigma_{\varepsilon_i}^2 + 2\sigma_{\varepsilon_i}^2}$$

$$= \frac{-1}{(\rho+2)}$$

indépendant de i

\Rightarrow les séries y_{it} ne sont pas SUTSE les deux séries

tilibra

possibilita a escolha FAC no caso
 pouco conhecida, ou seja, as propriedades
 dinâmicas das séries serão iguais por este
 modelo.

→ modelo dimensionalmente restritivo, mas
 fácil de ser estimado

$$\Psi = (\sigma_{\varepsilon_1}^2, \sigma_{\varepsilon_2}^2, \sigma_{\varepsilon_1 \varepsilon_2}, \rho)$$

$$l(\Psi) = \log L(\Psi) = \sum_{t=d+1}^n \log p(y_{1t}, y_{2t} | y_{t-1})$$

$$L(\Psi) = \prod_{t=d+1}^n p(y_{1t}, y_{2t} | y_{t-1})$$

$$p(y_{1t}, y_{2t} | y_{t-1}) = \frac{1}{(2\pi)^2} |F_t|^{-1/2} \exp \left[-\frac{1}{2} U_t' F_t^{-1} U_t \right]$$

$$U_t = \begin{pmatrix} U_{1t} \\ U_{2t} \end{pmatrix} = \begin{pmatrix} y_{1t} - \mu_{1t|t-1} \\ y_{2t} - \mu_{2t|t-1} \end{pmatrix}$$

$$F_t = P_t + \sum_{\varepsilon} \quad , \quad \varepsilon \text{ errôres}$$

$$l(\Psi) = -\left(\frac{n-d}{2}\right) \log(2\pi) - \frac{1}{2} \sum_{t=d+1}^n \log |F_t| - \frac{1}{2} \sum_{t=d+1}^n U_t' F_t^{-1} U_t$$

$$\left(p(y_{1t}, y_{2t}, \dots, y_{pt} | y_{t-1}) = \frac{1}{(2\pi)^{p/2}} |F_t|^{-1/2} \exp \left\{ -\frac{1}{2} U_t' F_t^{-1} U_t \right\} \right)$$

→ É possível generalizar a estrutura SUTSE p/ incorporar modelos com outros componentes, e.g., tendência linear estocástica, sazonalidade e ciclo

⇒ Supondo ortogonalidade entre componentes de interpretações diferentes (μ_t e δ_t , δ_t e ψ_t , etc)

$$\text{Ex: } \begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} + \begin{pmatrix} \psi_{1t} \\ \psi_{2t} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}, \quad \underline{\varepsilon}_t \sim N(0, \Sigma_\varepsilon)$$

$$\begin{pmatrix} \mu_{1t} \\ \mu_{2t+1} \end{pmatrix} = \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \end{pmatrix} + \begin{pmatrix} \beta_{1t} \\ \beta_{2t} \end{pmatrix} + \begin{pmatrix} \eta_{1t} \\ \eta_{2t} \end{pmatrix}, \quad \underline{\eta}_t \sim N(0, \Sigma_\eta)$$

$$\begin{pmatrix} \beta_{1,t+1} \\ \beta_{2,t+1} \end{pmatrix} = \begin{pmatrix} \beta_{1,t} \\ \beta_{2,t} \end{pmatrix} + \begin{pmatrix} f_{1,t} \\ f_{2,t} \end{pmatrix}, \quad f_t \sim N(0, \Sigma_f)$$

$$\begin{pmatrix} \psi_{1t+1} \\ \psi_{2t+1} \\ \psi_{1t+1}^* \\ \psi_{2t+1}^* \end{pmatrix} = \begin{bmatrix} \rho \begin{bmatrix} \cos k_c \sin k_c \\ -\sin k_c \cos k_c \end{bmatrix} \otimes I_2 \end{bmatrix} \begin{pmatrix} \psi_{1t} \\ \psi_{2t} \\ \psi_{1t}^* \\ \psi_{2t}^* \end{pmatrix} + \begin{pmatrix} K_{1t} \\ K_{2t} \\ K_{1t}^* \\ K_{2t}^* \end{pmatrix}$$

$$L_P \begin{pmatrix} \rho E & 0 & 0 \\ 0 & 0 & \rho \begin{bmatrix} & \\ & \end{bmatrix} \end{pmatrix} \begin{pmatrix} K_t \\ K_t^* \end{pmatrix}$$

$$K_t \sim N(0, \Sigma_K)$$

$$\hookrightarrow 2 \times 2$$

$$4 \times 4$$

$$A = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \\ a_{31} & a_{32} \end{pmatrix} \rightarrow \text{vec}(A) = (a_{11} \ a_{21} \ a_{31} \ a_{12} \ a_{22} \ a_{32})^T$$

Produktvektor
Kronecker

$A \otimes B = \begin{pmatrix} a_{11}B & a_{12}B & \dots & a_{1n}B \\ a_{21}B & a_{22}B & \dots & a_{2n}B \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1}B & a_{m2}B & \dots & a_{mn}B \end{pmatrix}$

Calcular o modelo na forma EE

⇒ Consequência: a ordem de estrutura dos vetores de estado é por componente: 1º as Coss

$$\vec{d}_t \sim 8 \times 1$$

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 1 & 0 & 0 \end{pmatrix}$$

$\hookrightarrow \vec{z} \sim 2 \times 8$

$$\begin{pmatrix} \mu_{1t} \\ \mu_{2t} \\ \beta_{1t} \\ \beta_{2t} \\ \psi_{1t} \\ \psi_{2t} \\ \psi_{1t}^* \\ \psi_{2t}^* \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

$\hookrightarrow 2 \times 1$

$$\vec{T} \sim 8 \times 8$$

$$\begin{pmatrix} \mu_{1,t+1} \\ \mu_{2,t+1} \\ \beta_{1,t+1} \\ \beta_{2,t+1} \\ \psi_{1,t+1} \\ \psi_{2,t+1} \\ \psi_{1,t+1}^* \\ \psi_{2,t+1}^* \end{pmatrix} = \begin{pmatrix} 1 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & a & 0 & b & 0 \\ 0 & 0 & 0 & 0 & 0 & a & 0 & b \\ 0 & 0 & 0 & 0 & c & 0 & a & a \\ 0 & 0 & 0 & 0 & 0 & c & 0 & a \end{pmatrix} \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \\ \beta_{1t} \\ \beta_{2t} \\ \psi_{1t} \\ \psi_{2t} \\ \psi_{1t}^* \\ \psi_{2t}^* \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

$a = \rho \cos \lambda_c$
 $b = \rho \sin \lambda_c$
 $c = -\rho \sin \lambda_c$

$$+ \begin{pmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} \eta_{1t} \\ \eta_{2t} \\ \xi_{1t} \\ \xi_{2t} \\ \kappa_{1t} \\ \kappa_{2t} \\ \kappa_{1t}^* \\ \kappa_{2t}^* \end{pmatrix}$$

$\vec{\eta}_t \sim 8 \times 1$

$$\hookrightarrow \vec{R} \sim 8 \times 8 = I_8$$

tilibra

Sejam as matrizes equivalentes do modelo univariado

$$Z^U = (1 \ 0 \ 1 \ 0) \quad , \quad R^U = I_2$$

$$T^U = \begin{pmatrix} 1 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & a & b \\ 0 & 0 & c & a \end{pmatrix}$$

Então, utilizando a notação do produto de Kronecker (\otimes)

$$\Rightarrow Z^U \otimes I_2 = (1 \ 0 \ 1 \ 0) \otimes \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

$$= \begin{pmatrix} 1 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 1 & 0 & 0 \end{pmatrix} = \underline{\underline{\tilde{Z}}}$$

$$\Rightarrow T^U \otimes I_2 = \begin{pmatrix} 1 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & a & b \\ 0 & 0 & c & a \end{pmatrix} \otimes \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

(4x4) x (2x2)

$\sim 8 \times 8$

$$\begin{pmatrix} 1 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & a & 0 & b & 0 \\ 0 & 0 & 0 & 0 & 0 & a & 0 & b \\ 0 & 0 & 0 & 0 & 0 & c & 0 & a \\ 0 & 0 & 0 & 0 & 0 & c & 0 & a \end{pmatrix} = T$$

- Assim sendo, o modelo multivariado SVTSE pode ser expresso na seguinte forma:

$$\underline{y}_t = (\underline{Z}^v \otimes \underline{I}_p) \underline{\alpha}_t + \underline{\varepsilon}_t, \quad \underline{\varepsilon}_t \sim N(0, \underline{\Sigma}_\varepsilon)$$

$$\underline{d}_{t+1} = (\underline{T}^v \otimes \underline{I}_p) \underline{\alpha}_t + (\underline{R} \otimes \underline{I}_p) \underline{\eta}_t, \quad \underline{\eta}_t \sim N(0, \underline{\Sigma}_\eta)$$

- Podem-se acrescentar variáveis explicativas/interações ao modelo SVTSE

$$\underline{y}_t = (\underline{Z}^v \otimes \underline{I}_p) \underline{\alpha}_t + \underline{X}_t \underline{\delta} + \underline{\varepsilon}_t$$

$$\underline{d}_{t+1} = (\underline{T}^v \otimes \underline{I}_p) \underline{\alpha}_t + (\underline{R} \otimes \underline{I}_p) \underline{\eta}_t$$

onde $\underline{X}_t \sim p \times k$ $\underline{\delta} \sim 1 \times p$

$$\underline{X}_t = \begin{bmatrix} \underline{\chi}_{11t} & & & \\ & \underline{\chi}_{12t} & & \\ & & \ddots & \\ 0 & & & \underline{\chi}_{1pt} \end{bmatrix}$$

$$\underline{\delta} = [\underline{\delta}_1, \underline{\delta}_2, \dots, \underline{\delta}_p]'$$

$$\underline{\chi}_{1ti} = (\chi_{11t}, \chi_{12t}, \dots, \chi_{1pt})'$$

Ex: $\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix} + \begin{pmatrix} \delta_{11} \chi_{11t} + \delta_{12} \chi_{12t} + \dots + \delta_{1p} \chi_{1pt} \\ \delta_{21} \chi_{12t} + \delta_{22} \chi_{22t} + \dots + \delta_{2p} \chi_{2pt} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$

$$\begin{pmatrix} \chi_{11t} & \chi_{12t} & \dots & \chi_{1pt} & 0 & 0 & \dots & 0 \\ 0 & 0 & \dots & 0 & \chi_{12t} & \chi_{22t} & \dots & \chi_{2pt} \end{pmatrix} \begin{pmatrix} \delta_{11} \\ \delta_{12} \\ \vdots \\ \delta_{1p} \\ \delta_{21} \\ \delta_{22} \\ \vdots \\ \delta_{2p} \end{pmatrix}$$

$$\underline{X}_t = \begin{pmatrix} \underline{\chi}_{1t}' & 0 \\ 0 & \underline{\chi}_{2t}' \end{pmatrix}$$

$$\underline{\delta} = (\underline{\delta}_1, \underline{\delta}_2)$$

tilibra

Modelo homogêneo

de 2º ordem.

Def: Um processo estocástico p -variado é dito homogêneo se todas as combinações lineares de seus componentes possuem as mesmas propriedades estocásticas de 2º ordem.

Em outras palavras $y_t = (y_{1t} \ y_{2t} \ \dots \ y_{pt})'$ é homogêneo se $\forall \alpha \in \mathbb{R}^p$, o processo univariado estacionário $z_t = \tilde{\alpha}' y_t$ possui FAC indep. de $\tilde{\alpha}$.

Prop: Se y_t segue um SUTSE de nível local, então y_t será homogêneo SSS $\Sigma_y = \gamma \Sigma_e$

Prop: Se y_t segue um SUTSE com j tipos de componentes ortogonais, então y_t será homogêneo SSS

$$\Sigma_y = \begin{pmatrix} \Sigma_{y_1} & 0 & 0 \\ 0 & \Sigma_{y_2} & 0 \\ 0 & 0 & \Sigma_{y_j} \end{pmatrix} = \begin{pmatrix} q_1 \Sigma_* & 0 & 0 \\ 0 & q_2 \Sigma_* & 0 \\ 0 & 0 & q_j \Sigma_* \end{pmatrix}$$

$p \times p$

$$\Sigma_e = h \Sigma_*$$

$p \times 1$

Propriedades empíricas de processos homog.

i. Pode haver teorias "a priori" que justifiquem a ordem da estr. de propor entre as covariâncias

II. as regressões de Kalman podem ser implementadas para cada uma das p equações separadamente (Harvey)

III. menos risco de má identificação pelo baixo valor da dimensão paramétrica

IV. Estimados por MV e consider. simplificada (Harvey pp 439/40).

* Modelos de Componentes Comuns (Análise Fatorial Dinâmica)

Análise
de
Fatores

$$\left\{ \begin{array}{l} y_{it} = \sum_{j=1}^K \lambda_{ij} F_{jt} + \varepsilon_{it} \quad i=1, 2, \dots, p \\ F_{jt} = T_j F_{j,t-1} + \eta_{jt} \end{array} \right.$$

AFD

↳ MCC podem ser vistos como generalizações de AF pl o contexto de séries temporais

• As variáveis observáveis são os componentes de $y_t = (y_{1t} \ y_{2t} \ \dots \ y_{pt})'$ e os fatores latentes seriam os coordenados do vetor $x_t = (x_{1t} \ x_{2t} \ \dots \ x_{kt})'$

↳ Componentes: tendência

sazonabilidade
ciclo

> Comuns

=> Modelo de tendências comuns e co-integração

Considere o SUTSE de tendência linear estocástica

$$\begin{aligned}y_t &= \underline{\mu}_t + \varepsilon_t, \quad \varepsilon_t \sim N(0, \Sigma_\varepsilon) \\ \underline{\mu}_{t+1} &= \underline{\mu}_t + \underline{\beta}_t + \underline{\eta}_t, \quad \underline{\eta}_t \sim N(0, \Sigma_\eta) \\ \underline{\beta}_{t+1} &= \underline{\beta}_t + \underline{\zeta}_t, \quad \underline{\zeta}_t \sim N(0, \Sigma_\zeta)\end{aligned}$$

como $\sum_{t=1}^T \underline{\zeta}_t = \underline{0} \Rightarrow$ passeio aleatório + drift

$$\begin{aligned}y_t &= \underline{\mu}_t + \varepsilon_t, \quad \varepsilon_t \sim N(0, \Sigma_\varepsilon) \\ \underline{\mu}_{t+1} &= \underline{\beta} + \underline{\mu}_t + \underline{\eta}_t, \quad \underline{\eta}_t \sim N(0, \Sigma_\eta)\end{aligned}$$

Suponhamos posto $(\Sigma_\eta) = k < P$
séries

então o modelo pode ser re-escrito em termos de k tendências comuns $\underline{\mu}_t^+$

Sem perda de generalidade, seja $\underline{\beta} = \underline{0}$

$$\underline{\mu}_{t+1} = \underline{\mu}_t + \underline{\eta}_t$$

$$\underline{\mu}_2 = \underline{\mu}_1 + \underline{\eta}_1$$

$$\underline{\mu}_3 = \underline{\mu}_2 + \underline{\eta}_2 = \underline{\mu}_1 + \underline{\eta}_1 + \underline{\eta}_2$$

\vdots

$$\underline{\mu}_t = \underline{\mu}_1 + \sum_{i=1}^{t-1} \underline{\eta}_i$$

$$\text{Var}(\underline{\mu}_t) = \text{Var}(\underline{\mu}_1) + \sum_{i=1}^{t-1} \text{Var}(\underline{\eta}_i)$$

$$\text{Var}(\underline{y}_t) = V(\underline{y}_t) + (t-1) \Sigma_y \\ = \Sigma_y + (t-1) \Sigma_y$$

Suponhamos que Σ_y e Σ_{yt} possuem mesmo posto

Como, por hipótese $\text{posto}(\Sigma_y) < P$, então segue que

$$\text{posto}(\Sigma_y) < P \Leftrightarrow \text{posto} \text{Var}(\underline{y}_t) < P \Leftrightarrow \underline{y}_{t1}, \underline{y}_{t2}, \dots, \underline{y}_{tP} \text{ e LD}$$

Ou seja existe redundância entre os elementos de \underline{y}_t , i.e., alguns elementos podem ser ditos como combinações lineares de

- O resultado anterior permite associações diretas entre os conceitos de α -integridade e de rankings comuns. Relembrando

Def de CI \Rightarrow Um processo estocástico p-variado $\underline{y}_t = (y_{t1}, y_{t2}, \dots, y_{tp})'$ é dito α -integrado de ordem d e b , $b \leq d$, i.e.,

$$\underline{y}_t \sim CI(d, b) \quad \text{se}$$

$$(I) \quad y_{jt} \sim I(d), \quad j=1, 2, \dots, p$$

$$(II) \quad \exists \underline{\alpha} \in \mathbb{R}^p - \{0\}, \text{ tal que } \underline{\alpha}' \underline{y}_t \sim I(d-b)$$

$$\text{Ex: } y_{jt} \sim I(1), \forall j \quad d=1 \\ \underline{\alpha}' \underline{y}_t \sim I(0) \quad b=1$$

Proposição \rightarrow Um processo y_t pode seguir um modelo SVTSE de nível local admitindo uma representação de tendências comuns SSS $y_t \sim CI(1, \mu)$

SVTSE de nível local CI tendências comuns $\mu_t^+ \sim k \times 1$

$$y_t = \underbrace{\textcircled{1}}_{(p \times 1)} \underbrace{\mu_t^+}_{(k \times 1)} + \underbrace{\mu_\theta}_{(p \times 1)} + \underbrace{\varepsilon_t}_{(p \times 1)}, \quad \varepsilon_t \sim \text{NID}(0, \Sigma_\varepsilon) \quad (\text{I})$$

$$\underbrace{\mu_{t+1}^+}_{(k \times 1)} = \underbrace{\mu_t^+}_{(k \times 1)} + \underbrace{\eta_t^+}_{(k \times 1)}, \quad \eta_t^+ \sim \text{NID}(0, \Sigma_\eta^+)$$

$$\textcircled{1} = \begin{bmatrix} I_k \\ \bar{\Theta} \end{bmatrix} \begin{matrix} k \\ p-k \end{matrix}, \quad \mu_\theta = \begin{bmatrix} \bar{Q} \\ \bar{\mu} \end{bmatrix} \begin{matrix} k \\ p-k \end{matrix}$$

matriz de loadings

$$y_{1t} \sim k \times 1$$

$$y_{2t} \sim r \times 1, \quad r = p-k$$

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} I_k \\ \bar{\Theta} \end{pmatrix} \mu_t^+ + \begin{pmatrix} \bar{Q} \\ \bar{\mu} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

$$\begin{cases} y_{1t} = \mu_t^+ + \varepsilon_{1t} \\ y_{2t} = \bar{\Theta} \mu_t^+ + \bar{\mu} + \varepsilon_{2t} \end{cases} \quad (\text{II-a})$$

$$\begin{cases} \mu_{t+1}^+ = \mu_t^+ + \eta_t^+ \end{cases} \quad (\text{II-b})$$

• A presença de tendências comuns implica em que o vetor y_t é CI

• Neste modelo existem $r = p - k$ relações de CI

Prova: Seja $A \sim n \times p$ particionado como

$$A = \begin{pmatrix} A_1 \\ A_2 \end{pmatrix}$$

↑
(k+1)

→ O sistema de tendências comuns em (II-a) pode ser transformado em um sistema CI equivalente pré-multiplicando (II-a) por uma matriz $p \times p$

$$\begin{bmatrix} I_k & 0 \\ A_1 & A_2 \end{bmatrix}$$

$$\begin{bmatrix} I_k & 0 \\ A_1 & A_2 \end{bmatrix} \begin{bmatrix} y_{1t} \\ y_{2t} \end{bmatrix} = \begin{bmatrix} I_k & 0 \\ A_1 & A_2 \end{bmatrix} \begin{bmatrix} \mu_t^+ + \varepsilon_{1t} \\ \tilde{\Theta} \mu_t^+ + \bar{\mu} + \varepsilon_{2t} \end{bmatrix}$$

$$y_{1t} = \mu_t^+ + \varepsilon_{1t}$$

$$A_1 y_{1t} + A_2 y_{2t} = A_1 (\mu_t^+ + \varepsilon_{1t}) + A_2 \tilde{\Theta} \mu_t^+ + A_2 \bar{\mu} + A_2 \varepsilon_{2t}$$

Escolhendo $A_1 = -\tilde{\Theta}$, $A_2 = I_n$, segue que:

$$A_2 y_{2t} = A_2 \tilde{\Theta} \mu_t^+ + A_2 \bar{\mu} + A_2 \varepsilon_{2t}$$

$$y_{2t} = \tilde{\Theta} (y_{1t} - \varepsilon_{1t}) + \bar{\mu} + \varepsilon_{2t}$$

$$\begin{array}{ccccccc}
 \tilde{y}_{2t} & = & \tilde{\Theta} & \tilde{y}_{1t} & + & \bar{\mu} & + & \tilde{\varepsilon}_t \\
 \uparrow & & \uparrow & \uparrow & & \uparrow & & \nearrow \\
 (r \times 1) & & (r \times k) & (k \times 1) & & (r \times 1) & & \varepsilon_t = \varepsilon_{2t} - \bar{\Theta} \varepsilon_{1t} \\
 \uparrow & & & & & & & \\
 r = (p-k) & & & & & & &
 \end{array}$$

Prove

(I) $y_t = \mu_t + \varepsilon_t$, $\varepsilon_t \sim N(0, \Sigma_\varepsilon)$

(II) $\mu_{t+1} = \mu_t + \eta_t$, $\eta_t \sim N(0, \Sigma_\eta)$

\Rightarrow Se existe 1 componente comum, então

posto $(\Sigma_y) = p-1 < p$, i.e.,

as componentes de μ_t não são LI, e então
 existe $\alpha \sim p \times 1$ tal que

$$\alpha_1 \mu_{1t} + \alpha_2 \mu_{2t} + \dots + \alpha_p \mu_{pt} = 0$$

$$\alpha' \mu_t = 0$$

$$\alpha' \tilde{y}_t = \alpha' \mu_t + \alpha' \varepsilon_t$$

$$\alpha' \tilde{y}_t = \alpha' \varepsilon_t \sim I(0) \text{ , portanto o vetor } y_t \text{ será } (I(1, 1))$$

Se posto $(\Sigma_y) = k < p$ então:

(I) apenas k componentes são LI.

(II) $(p-k)$ componentes são LD.

$$\begin{pmatrix} \alpha_{11} & \alpha_{12} & \dots & \alpha_{1p} \\ \alpha_{21} & \alpha_{22} & \dots & \alpha_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \alpha_{k1} & \alpha_{k2} & \dots & \alpha_{kp} \end{pmatrix} \begin{pmatrix} \mu_{1t} \\ \mu_{2t} \\ \vdots \\ \mu_{pt} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

$k \times p \qquad \qquad p \times 1$

$$A \mu_t = 0$$

$$A y_t = A \mu_t + A \varepsilon_t$$

$$A y_t = A \varepsilon_t \sim I(0)$$